

¿Transformando la educación? Evidencia experimental sobre instrucción asistida por tecnología en India

Karthik Muralidharan y Abhijeet Singh y Alejandro J. Ganimian*

23 de marzo de 2019

Resumen

Estudiamos el impacto de un programa extraescolar de instrucción personalizada asistida por tecnología en los grados de la escuela media en la India urbana, mediante un sorteo que otorgó a los ganadores acceso gratuito al programa. Los ganadores del sorteo obtuvieron puntajes 0.37σ más altos en matemática y 0.23σ más altos en hindi en un período de apenas 4.5 meses. Las estimaciones por IV sugieren que asistir al programa durante 90 días aumentaría los puntajes en las pruebas de matemática y de hindi en 0.6σ y 0.39σ , respectivamente. Encontramos ganancias absolutas similares en los puntajes para todos los estudiantes, pero ganancias relativas mucho mayores para los estudiantes académicamente más débiles. Nuestros resultados sugieren que los programas de instrucción asistida por tecnología bien diseñados pueden mejorar marcadamente la productividad en la provisión de educación.

Códigos JEL: C93, I21, J24, O15

Palabras clave: aprendizaje asistido por computadora, productividad en educación, aprendizaje personalizado, enseñanza en el nivel adecuado, educación posprimaria, escuela media, escuela secundaria

*Muralidharan: Department of Economics, University of California San Diego, 9500 Gilman Drive, La Jolla CA; NBER; J-PAL. Correo electrónico: kamurali@ucsd.edu. Singh: Department of Economics, Stockholm School of Economics, Sveavägen 65, Stockholm, Sweden. Correo electrónico: abhijeet.singh@hhs.se. Ganimian: NYU Steinhardt School of Culture, Education, and Human Development, 246 Greene St, New York, NY. Correo electrónico: alejandro.ganimian@nyu.edu. Agradecemos a Esther Duflo (la editora), Abhijit Banerjee, James Berry, Peter Bergman, Prashant Bharadwaj, Gordon Dahl, Roger Gordon, Heather Hill, Priya Mukherjee, Chris Walters y a varios participantes de seminarios por sus comentarios. Agradecemos al personal de Educational Initiatives (EI)—en especial, a Pranav Kothari, Smita Bardhan, Anurima Chatterjee y Prasad Sreeprakash—por su apoyo a la evaluación. También agradecemos a Maya Escueta, Smit Gade, Riddhima Mishra y Rama Murthy Sripada por su excelente asistencia de investigación y su apoyo en el trabajo de campo. Por último, agradecemos a la iniciativa Post-Primary Education de J-PAL por financiar este estudio. El estudio se registró en el AEA Trial Registry (RCT ID: AEARCTR-0000980). La operación de los centros Mindspark por parte de EI fue financiada por la Central Square Foundation, la Tech Mahindra Foundation y Porticus. Todas las opiniones expresadas pertenecen a los autores y no a ninguna de las instituciones a las que están afiliados.

1 Introducción

Los países en desarrollo han logrado avances notables en la matriculación y la finalización escolar en las últimas dos décadas. Sin embargo, su productividad para convertir las inversiones educativas de tiempo y dinero en capital humano sigue siendo muy baja. Por ejemplo, en la India, más del 50 % de los estudiantes de 5.º grado no puede leer al nivel de segundo grado, pese a que las tasas de matriculación en la escuela primaria superan el 95 % (Pratham, 2017). Patrones similares se observan también en varios otros países en desarrollo (World Bank (2018)). Una de las principales explicaciones candidatas de esta baja productividad es que los patrones vigentes de gasto e instrucción educativos pueden no aliviar una restricción clave que limita el aprendizaje: el desajuste entre el nivel de la instrucción en el aula y los niveles de aprendizaje de los estudiantes (véase Glewwe and Muralidharan (2016) para una revisión de la evidencia).

En concreto, la rápida expansión de la educación en los países en desarrollo ha llevado a la matriculación de millones de estudiantes de primera generación, que carecen de apoyo pedagógico cuando se atrasan respecto del currículo. Los estudiantes que se atrasan pueden entonces aprender muy poco en la escuela si el nivel de la instrucción en el aula (basado en libros de texto que siguen estándares curriculares ambiciosos) está considerablemente por encima de su nivel de aprendizaje (Banerjee and Duflo, 2012; Pritchett and Beatty, 2015). En el Apéndice B, mostramos que tres problemas están generalizados en los contextos de los países en desarrollo: una gran proporción de estudiantes está por debajo de los estándares del grado, hay una heterogeneidad considerable en los niveles de aprendizaje de los estudiantes de un mismo grado, y existe un desajuste entre el nivel de aprendizaje de los estudiantes y el nivel del currículo y la pedagogía. Estos problemas se agravan en los grados superiores, porque los estudiantes suelen ser promovidos automáticamente al grado siguiente sin haber adquirido las habilidades fundamentales. Si bien las intervenciones pedagógicas que buscan “Enseñar en el Nivel Adecuado” con apoyo humano han tenido éxito en el nivel primario (Banerjee et al., 2016), hasta la fecha hay muy poca evidencia sobre estrategias de instrucción eficaces para la educación posprimaria en contextos de países en desarrollo con amplia heterogeneidad en los niveles de aprendizaje de los estudiantes.

Una opción prometedora para enfrentar este desafío es hacer un mayor uso de la tecnología en la instrucción. Si bien hay varios mecanismos por los cuales el aprendizaje asistido por computadora (CAL) puede mejorar la enseñanza y el aprendizaje,¹ una característica particularmente atractiva es su capacidad de ofrecer contenido adaptado individualmente para

¹Una lista no exhaustiva de los canales de impacto postulados incluye usar la tecnología para ofrecer de manera consistente contenido de alta calidad que pueda sortear las limitaciones del propio conocimiento de los docentes; ofrecer contenido interactivo atractivo (a menudo basado en juegos) que pueda mejorar la atención de los estudiantes; reducir la demora entre el momento en que los estudiantes intentan resolver un problema y el momento en que reciben retroalimentación; analizar los patrones de errores de los estudiantes para dirigir con precisión el contenido a aclarar áreas específicas de incomprensión, y personalizar el contenido para cada estudiante.

“Enseñar en el Nivel Adecuado” a todos los estudiantes, sin importar el grado de heterogeneidad en los niveles de aprendizaje dentro de un aula. Sin embargo, aunque la instrucción asistida por tecnología puede tener mucho *potencial* para mejorar la educación posprimaria en los países en desarrollo, hasta la fecha hay poca evidencia de éxitos notables (Banerjee et al., 2013).

Este artículo presenta evidencia experimental sobre el impacto de un programa de instrucción basado en tecnología (llamado Mindspark) que fue diseñado para abordar varias restricciones a una pedagogía eficaz en los países en desarrollo. Como reflejo de más de una década de desarrollo del producto, una característica clave del software es que usa su extensa base de datos de preguntas de prueba y respuestas de estudiantes a nivel de ítem para medir el nivel de aprendizaje inicial de cada estudiante y personalizar dinámicamente el material que se ofrece, de modo que se ajuste al nivel y al ritmo de progreso de cada estudiante. Mindspark puede ofrecerse en diversos contextos (en escuelas, en centros extraescolares o mediante estudio autoguiado); es independiente de la plataforma (puede implementarse en computadoras, tabletas o teléfonos inteligentes); y puede usarse tanto en línea como sin conexión.

En este artículo evaluamos los centros Mindspark extraescolares. Los centros programaban seis días de instrucción por semana, de 90 minutos por día. Cada sesión se dividía en 45 minutos de aprendizaje individual autodirigido en el software Mindspark y 45 minutos de apoyo pedagógico de un asistente docente en grupos de 12-15 estudiantes.² Los centros buscaban atender a estudiantes de barrios de bajos ingresos de Delhi y cobraban un arancel módico. Nuestra evaluación se llevó a cabo en una muestra de 619 estudiantes reclutados para el estudio en escuelas medias públicas de Delhi. Alrededor de la mitad de estos estudiantes fue seleccionada aleatoriamente para recibir un vale que ofrecía asistencia gratuita a los centros. Medimos los impactos del programa mediante pruebas de lápiz y papel sobre el aprendizaje de los estudiantes en matemática y en hindi (lengua), administradas de forma independiente antes y después de la intervención de 4.5 meses. Estas pruebas se vincularon mediante la teoría de respuesta al ítem (IRT) para que fueran comparables en una escala común entre ambas rondas de evaluación y entre los distintos grados.

Comenzamos presentando tres hechos clave sobre el contexto. Primero, mostramos que el logro promedio de los estudiantes de nuestra muestra (medido en la línea de base) está varios grados por detrás de los estándares correspondientes a su grado y que esta brecha crece con el grado. El estudiante promedio de 6.^o grado está alrededor de 2.5 grados por debajo de los estándares de 6.^o grado en matemática; en 9.^o grado, este déficit aumenta a 4.5 grados. Segundo, mostramos que hay una heterogeneidad considerable en los niveles de aprendizaje de los estudiantes dentro de un mismo grado. Los estudiantes matriculados en un mismo grado típicamente *abarcan*

²El asistente docente se centraba en ayudar a los estudiantes a completar las tareas y a prepararse para los exámenes, mientras que la instrucción la proveía principalmente el software Mindspark (véanse las secciones 2.1.1 y 5.1 para más detalles).

de cinco a seis grados en su preparación, y la gran mayoría de ellos está por debajo de los estándares del grado. Por lo tanto, la instrucción por defecto en el aula, basada en libros de texto correspondientes al grado, probablemente esté muy por encima del nivel de preparación de los estudiantes académicamente más débiles. En consonancia con esto, encontramos que el valor agregado absoluto en nuestras pruebas administradas de forma independiente es *cercano a cero* para el tercio inferior de los estudiantes del grupo de control, y no podemos rechazar que estos estudiantes no hayan logrado ningún progreso académico a lo largo del año escolar, pese a estar matriculados en la escuela.

Presentamos cuatro conjuntos principales de resultados basados en el experimento. Primero, encontramos que los estudiantes que ganaron un vale para el programa obtuvieron puntajes 0.37σ más altos en matemática y 0.23σ más altos en hindi en comparación con los estudiantes que se inscribieron pero no ganaron el sorteo. En relación con el grupo de control, los ganadores del sorteo experimentaron más del doble del valor agregado en los puntajes de matemática y alrededor de 2.4 veces el de hindi durante el período de estudio de 4.5 meses. Estas son estimaciones de intención de tratar (ITT) que reflejan una tasa de asistencia promedio del 58%. Usando el sorteo como variable instrumental de la asistencia (y supuestos adicionales discutidos en la sección 4.4), estimamos que asistir a los centros Mindspark durante 90 días (lo que corresponde a un 80% de asistencia durante medio año escolar) aumentaría los puntajes en las pruebas de matemática y de hindi en 0.6σ y 0.39σ , respectivamente.

Segundo, los efectos ITT no varían según los puntajes de línea de base de los estudiantes, su género o el nivel socioeconómico del hogar. Así, en consonancia con la promesa del aprendizaje asistido por computadora de adaptar la instrucción a cada estudiante, la intervención fue igualmente eficaz para mejorar los puntajes de *todos* los estudiantes. Sin embargo, aunque el impacto absoluto fue similar en todas las partes de la distribución inicial de puntajes, el impacto *relativo* fue mucho mayor para los estudiantes más débiles, porque el ritmo de progreso ‘habitual’ en el grupo de control fue cercano a cero para los estudiantes del tercio inferior de la distribución de puntajes de línea de base dentro de cada grado.

Tercero, examinamos la heterogeneidad de los efectos ITT según la dificultad de las preguntas de la prueba. Dado que los niveles de aprendizaje de los estudiantes estaban muy por debajo del nivel del grado en Matemática, el sistema Mindspark (que adaptaba el contenido al nivel de aprendizaje de cada estudiante) proveyó a los estudiantes principalmente contenido de dificultad inferior al nivel del grado. En hindi, donde las brechas de aprendizaje respecto de los estándares curriculares eran menores, los estudiantes recibieron contenido tanto del nivel del grado como de dificultad inferior. Los resultados en las pruebas reflejan este patrón de instrucción: en matemática, las ganancias en los puntajes solo se observan en las preguntas de dificultad inferior al nivel del grado; en cambio, en hindi, las ganancias se encuentran tanto en las preguntas del nivel del grado como en las de nivel inferior.

Por último, también estimamos los efectos ITT sobre los exámenes escolares anuales. Estos fueron administrados por la escuela (independientemente del equipo de investigación) y estaban dirigidos a un nivel correspondiente al grado. En consonancia con el patrón de instrucción de Mindspark descrito arriba, encontramos mejoras significativas en los puntajes promedio de los exámenes escolares en hindi, pero no en Matemática. También encontramos una heterogeneidad relevante según el nivel de aprendizaje inicial de los estudiantes. Los estudiantes tratados del tercil inferior de la distribución de puntajes de línea de base dentro de cada grado no muestran ninguna mejora en las pruebas escolares en ninguna materia (lo cual es consistente con que estos estudiantes no recibieron contenido del nivel del grado en Mindspark). En cambio, los estudiantes del tercil superior (que tenían más probabilidades de recibir contenido del nivel del grado en la plataforma Mindspark) también obtienen puntajes más altos en todas las materias en las pruebas escolares correspondientes a su grado.³

El valor agregado en los puntajes del grupo de tratamiento fue más de un 100 % mayor que el del grupo de control, y se logró a un costo por estudiante menor que el del sistema de escuelas públicas. Por lo tanto, el programa fue costo-efectivo incluso a la muy pequeña escala evaluada en este estudio, y probablemente sea muy costo-efectivo a mayor escala (ya que los costos marginales son mucho menores que el costo promedio en nuestro estudio). Además, dados los grandes déficits de aprendizaje en los países en desarrollo y la cantidad finita de años de escolaridad, también vale la pena considerar la productividad *por unidad de tiempo*. Por ejemplo, Muralidharan (2012) encuentra que otorgar bonos individuales por desempeño a los docentes en la India generó ganancias en los puntajes de 0.54σ y 0.35σ en matemática y lengua tras cinco años de exposición al programa. Este es uno de los mayores tamaños de efecto observados hasta la fecha en un estudio experimental sobre educación en países en desarrollo. Sin embargo, estimamos que asistir regularmente a los centros Mindspark podría producir ganancias similares en una décima parte del tiempo (medio año).

Los efectos presentados arriba representan una combinación del programa de aprendizaje asistido por computadora (CAL) Mindspark, la instrucción grupal y el tiempo de instrucción adicional (dado que estudiamos un programa extraescolar), y el diseño de nuestro estudio no nos permite distinguir experimentalmente entre estos canales de impacto. Sin embargo, un estudio experimental contemporáneo sobre el impacto de un programa extraescolar de tutoría grupal, que también se desarrolló en Delhi, también se dirigió a estudiantes de escuela media y tuvo una duración aún mayor de instrucción extraescolar, no encontró *ningún impacto* en los puntajes (Berry and Mukherjee, 2016). Estos resultados sugieren que el tiempo extra de

³Estos resultados también subrayan la importancia de asegurar que las pruebas usadas en la investigación educativa sean informativas en un rango amplio de logro de los estudiantes (especialmente en contextos de países en desarrollo con una gran variación en el aprendizaje de los estudiantes dentro de un mismo grado). Usar solo pruebas correspondientes al grado (o pruebas escolares) habría llevado a inferencias incorrectas sobre el impacto promedio del programa (véase la discusión en la sección 4.3.3).

instrucción extraescolar o la tutoría grupal por sí solos podrían haber tenido un impacto limitado en el aprendizaje de los estudiantes sin el programa CAL. Así, si bien nuestras estimaciones experimentales reflejan el impacto combinado de un programa de ‘aprendizaje combinado’, muy probablemente sean atribuibles al componente CAL y no a la instrucción grupal (véase la discusión en la sección 5.1).

Nuestros resultados son directamente relevantes para los debates de política sobre estrategias eficaces para enfrentar el desafío del desajuste entre los niveles de aprendizaje de los estudiantes y el nivel del currículo y la pedagogía (un problema generalizado en los países en desarrollo, como se documenta en el Apéndice B). Muchas de las intervenciones pedagógicas que han demostrado ser eficaces en las últimas dos décadas, tanto en el sur de Asia como en África, han abordado con éxito el desafío del desajuste mediante la “Enseñanza en el Nivel Adecuado” (TaRL). Los modelos prácticos de implementación han incluido proveer un asistente docente que retire del aula a los estudiantes rezagados y les enseñe competencias básicas (Banerjee et al., 2007), agrupar las aulas por nivel para facilitar una enseñanza más cercana al nivel de aprendizaje de los estudiantes (Duflo, Dupas and Kremer, 2011) y ofrecer campamentos de aprendizaje fuera del horario escolar para facilitar la enseñanza en el nivel adecuado, sin la presión de tener que completar el currículo (Banerjee et al., 2016).

Sin embargo, implementar esta idea a gran escala es difícil por dos razones. Primero, la mayoría de los modelos TaRL implica incorporar docentes adicionales en la escuela o capacitar nuevamente a los docentes existentes para que impartan una instrucción más diferenciada. Esto requiere mucha mano de obra y un cambio de conducta considerable por parte de los docentes existentes, algo que, según la evidencia actual, no es fácil de lograr Banerjee et al. (2016). Segundo, estos modelos pueden no ser viables en los grados posprimarios, porque el contenido se vuelve más sofisticado y la variación en los niveles de aprendizaje de los estudiantes también aumenta. Nuestros resultados sugieren que usar programas CAL como Mindspark, capaces de usar la tecnología para personalizar la instrucción para cada estudiante, puede ser una opción prometedora para ampliar la escala del enfoque TaRL en todos los niveles de escolaridad sin aumentar la carga de trabajo de los docentes. Además, dado que se puede proveer a los estudiantes una instrucción diferenciada manteniendo la estructura de cohortes por edad, la instrucción personalizada basada en tecnología podría ofrecer las ventajas pedagógicas de la agrupación por nivel y, al mismo tiempo, mitigar varios de sus problemas (véase la discusión en la sección 5.3).

La discusión anterior también ayuda a interpretar la gran heterogeneidad en los impactos de las intervenciones CAL hasta la fecha (véase, por ejemplo, la reciente revisión de Bulman and Fairlie (2016)). Para ubicar nuestros resultados en el contexto de la evidencia existente, realizamos una revisión exhaustiva de los estudios existentes, con atención a los *detalles* de las intervenciones CAL estudiadas (véase el Apéndice C). Nuestra revisión sugiere que empiezan

a surgir algunos patrones claros. Primero, las intervenciones centradas en el equipamiento que proveen computadoras en el hogar o en la escuela parecen no tener ningún impacto positivo en los resultados de aprendizaje.⁴ Segundo, los programas CAL centrados en la pedagogía que permiten a los estudiantes repasar contenido correspondiente a su grado a su propio ritmo obtienen mejores resultados, pero las ganancias son modestas y van de 0.1σ a 0.2σ .⁵ Por último, las intervenciones que generan las mayores ganancias (como la que estudiamos y la estudiada en Banerjee et al. (2007)) parecen ser las que usan la tecnología también para personalizar la instrucción. Por lo tanto, nuestros resultados sugieren que la personalización (y, con ella, la implementación de TaRL) puede ser un ingrediente importante para alcanzar todo el potencial de la instrucción asistida por tecnología.

En términos más generales, nuestra evidencia sobre la capacidad de la instrucción asistida por tecnología para ayudar a sortear las restricciones a la acumulación de capital humano en los países en desarrollo aporta al debate sobre el potencial de las nuevas tecnologías para que los países de bajos ingresos superen de un salto las restricciones al desarrollo. Entre los ejemplos de otros sectores figuran el uso de teléfonos móviles para sortear la falta de sistemas bancarios formales (Jack and Suri, 2014), el uso de máquinas de votación electrónica para mejorar la participación electoral de ciudadanos analfabetos (Fujiwara, 2015) y el uso de la autenticación biométrica para sortear las restricciones de alfabetización a la inclusión financiera (Muralidharan, Niehaus and Sukhtankar, 2016). Sin embargo, dadas las limitaciones tanto en la capacidad como en la disposición de los pobres a pagar por programas CAL (véase la discusión en la sección 5.3), las iniciativas lideradas por el gobierno probablemente deban desempeñar un papel importante para cumplir esta promesa.

El resto de este artículo se organiza de la siguiente manera. La sección 2 describe la intervención y el diseño experimental. La sección 3 describe nuestros datos. La sección 4 presenta nuestros resultados principales. La sección 5 analiza los mecanismos, los costos y las implicancias de política. La sección 6 concluye.

⁴Véanse, por ejemplo, Angrist and Lavy (2002); Barrera-Orsorio and Linden (2009); Malamud and Pop-Eleches (2011); Cristia et al. (2012); Beuermann et al. (2015). Estos resultados decepcionantes probablemente se expliquen porque las intervenciones centradas en el equipamiento han hecho poco por cambiar la instrucción y, en ocasiones, han desplazado el tiempo de estudio independiente de los estudiantes.

⁵Véanse, por ejemplo, Carrillo, Onofa and Ponce (2010); Lai et al. (2015, 2013, 2012); Linden (2008); Mo et al. (2014a); Barrow, Markman and Rouse (2009); Rouse and Krueger (2004). La evidencia anecdótica sugiere que las intervenciones CAL centradas en la pedagogía se han enfocado típicamente en contenido correspondiente al grado, en respuesta a la preferencia de las escuelas y los docentes por un software CAL que se corresponda con los temas cubiertos en clase y los refuerce.

2 Intervención y diseño del estudio

2.1 El software CAL Mindspark

Desarrollado por una empresa educativa india líder llamada Educational Initiatives (EI), el software Mindspark refleja más de una década de desarrollo iterativo del producto y busca aprovechar varios de los canales postulados a través de los cuales la tecnología educativa puede mejorar la pedagogía. Al momento del estudio, lo habían usado más de 400,000 estudiantes, contaba con una base de datos de más de 45,000 preguntas de prueba y administraba más de un millón de preguntas por día al conjunto de sus usuarios. El software es interactivo e incluye una evaluación continua de los estudiantes junto con juegos, videos y actividades didácticas con los que los estudiantes aprenden a través de explicaciones y retroalimentación. Aquí destacamos algunas de las características de diseño clave del software, y en el Apéndice D ofrecemos una descripción más detallada, con ejemplos para cada uno de los puntos que siguen.

Primero, se basa en un extenso corpus de *materiales didácticos de alta calidad*, con un banco de más de 45,000 preguntas de prueba, iterado a lo largo de varios años de diseño y pruebas de campo. El diseño del contenido procura reflejar la investigación actual sobre pedagogía eficaz relevante para contextos de bajos ingresos, como el uso de subtítulos en el mismo idioma para la enseñanza de la lectoescritura (Kothari et al., 2002). Además, el software permite que este material se *ofrezca con uniformidad* a cada estudiante, con lo que sortea tanto las limitaciones del conocimiento de los docentes como la heterogeneidad en conocimiento y capacidad de enseñanza entre docentes.

Segundo, el contenido es *adaptativo*: las actividades que se presentan a cada estudiante se basan en su desempeño. Esta adaptación es dinámica y ocurre tanto al comienzo, sobre la base de una evaluación diagnóstica, como luego con cada actividad posterior completada. Así, si bien la base de datos de contenido de Mindspark está vinculada a los estándares curriculares de cada grado del sistema educativo, una característica esencial del software es que el contenido presentado a los estudiantes no está atado al currículo ni al libro de texto del grado en el que el estudiante está matriculado. En otras palabras, permite una “Enseñanza en el nivel adecuado” dinámica para cada estudiante y puede atender eficazmente una heterogeneidad muy amplia en los niveles de aprendizaje de los estudiantes, algo que incluso a docentes muy capacitados y motivados les resultaría difícil lograr en el aula.

Tercero, incluso estudiantes con niveles promedio similares de comprensión de un tema pueden tener distintas áreas específicas de incomprensión conceptual. Por lo tanto, el enfoque pedagógico necesario para aliviar un ‘cuello de botella’ conceptual específico de cada estudiante puede variar entre estudiantes. Mindspark busca abordar este problema usando su amplia base de datos de millones de observaciones a nivel de estudiante y pregunta para identificar patrones en los errores de los estudiantes, clasificar el tipo de error y dirigir en consecuencia

una *instrucción remedial diferenciada* (véase el Apéndice D.4.2 para ejemplos). Esta atención a la comprensión de los patrones de errores de los estudiantes se apoya en una extensa literatura en educación que destaca el valor diagnóstico del análisis de errores para revelar las necesidades heterogéneas de cada estudiante (véase Radatz 1979 para una discusión). Sin embargo, si bien los especialistas en educación conocen bien el valor del análisis de errores, ponerlo en práctica en el aula no es trivial, y el uso de la tecnología reduce marcadamente su costo.⁶

Por último, la interfaz de usuario interactiva, combinada con la individualización del material para cada estudiante, facilita el *compromiso continuo* de los niños con el material. El software hace un uso limitado de videos didácticos (durante los cuales la atención de los estudiantes puede decaer) y, en cambio, exige que los estudiantes interactúen constantemente con el sistema. Este enfoque busca aumentar la atención y el compromiso de los estudiantes, dar retroalimentación sobre cada paso intermedio de la resolución de un problema y acortar el ciclo de retroalimentación entre el momento en que los estudiantes intentan resolver un problema y el momento en que se enteran de sus errores y de cómo corregirlos.

Como deja en claro la discusión anterior, Mindspark busca usar la tecnología para aliviar simultáneamente múltiples restricciones a la enseñanza y el aprendizaje eficaces de manera escalable. En trabajos futuros, esperamos realizar microexperimentos en la plataforma Mindspark para intentar aislar el impacto de componentes específicos del software en los resultados de aprendizaje (como la personalización, la retroalimentación diferenciada o el impacto de estrategias pedagógicas específicas). Sin embargo, desde la perspectiva de los economistas, nos interesa más estudiar en qué medida la instrucción asistida por tecnología puede *mejorar la productividad* en la provisión de educación. Por lo tanto, en este artículo nos centramos en estudiar el impacto de “pleno potencial” de la instrucción asistida por tecnología sobre los resultados educativos (que incluye todos los canales mencionados), y dejamos para trabajos futuros el análisis de la importancia relativa de los componentes específicos de Mindspark.

2.1.1 La intervención de los centros Mindspark

El software CAL Mindspark se ha implementado en diversos contextos: escuelas privadas y públicas, centros de instrucción extraescolares y uso individual por suscripción en el hogar. Aquí evaluamos el modelo de instrucción complementaria, ofrecido en centros Mindspark independientes dirigidos a estudiantes de hogares de bajos ingresos. Los estudiantes se inscribían en el programa eligiendo un turno de 90 minutos, fuera del horario escolar, al que debían asistir

⁶El énfasis en el análisis de errores refleja la larga experiencia de EI en la realización de análisis similares y en la provisión de retroalimentación diagnóstica a los docentes a partir de pruebas de lápiz y papel (Muralidharan and Sundararaman, 2010). Así, el proceso de desarrollo de Mindspark refleja el objetivo de EI de usar la tecnología para mejorar la productividad en la implementación de ideas que, según los especialistas en educación, mejoran la eficacia de la pedagogía.

seis días por semana. Los centros cobraban un arancel (subsidiado) de INR 200 (USD 3) por mes.⁷

La instrucción diaria programada en los centros Mindspark se dividía en 45 minutos de instrucción por computadora y 45 minutos de estudio grupal supervisado y guiado por un instructor. En el tiempo asignado a la instrucción por computadora, a cada estudiante se le asignaba una computadora equipada con Mindspark y con auriculares, que le proporcionaba actividades de matemática, hindi e inglés. Se destinaban dos días de la semana a matemática, dos días a hindi y un día a inglés, y los estudiantes podían elegir la materia un día por semana.

El componente de instrucción grupal incluía a todos los estudiantes de un turno determinado (típicamente, alrededor de 15 estudiantes) y era supervisado por un único instructor. Los instructores se contrataban localmente y eran responsables de supervisar a los estudiantes mientras trabajaban con el software CAL, impartir la instrucción grupal, facilitar el funcionamiento diario de los centros y fomentar la asistencia y la permanencia de los estudiantes inscritos.⁸ La instrucción en el componente grupal consistía en apoyo supervisado para las tareas y en el repaso de conceptos centrales de relevancia general para todos los niños, sin adaptación individual.

Así, la intervención ofrecía una experiencia de ‘aprendizaje combinado’ que incluía instrucción personalizada individual asistida por computadora junto con apoyo académico grupal adicional de un instructor. En consecuencia, todas nuestras estimaciones del impacto y la costo-efectividad del programa se basan en este programa compuesto. Además, en la medida en que la presencia de un adulto pueda ser esencial para asegurar que los estudiantes usen la tecnología (tanto en asistencia como en tiempo dedicado a la tarea), podría no tener mucho sentido intentar aislar el impacto de la tecnología por sí sola. En la sección 5.1, analizamos los resultados de una evaluación experimental paralela en el mismo contexto que no muestra *ningún impacto* en el aprendizaje de los estudiantes de un programa extraescolar de tutoría grupal (sin tecnología). Por lo tanto, una manera de interpretar nuestros resultados es como una estimación de la

⁷Los aranceles habituales de suscripción a Mindspark (en los modelos escolar y en línea) no eran asequibles para las familias de bajos ingresos. Por ello, los centros Mindspark se crearon con financiamiento filantrópico para que el producto fuera más accesible, y se ubicaron en barrios de bajos ingresos. Sin embargo, los financiadores prefirieron que se cobrara un arancel (subsidiado), lo que refleja una opinión muy difundida entre los donantes según la cual el costo compartido es necesario para no desperdiciar subsidios en quienes no valorarán ni usarán el producto (Cohen and Dupas, 2010). La intensidad del programa, así como el arancel cobrado, se diseñaron para ser comparables a las clases particulares extraescolares, que suelen darse en grupos de estudiantes y son comunes en la India. Según la India Human Development Survey de 2012, el 43% de los jóvenes de 11-17 años asistía a clases particulares pagas fuera de la escuela.

⁸Estos instructores fueron reclutados según dos criterios principales: (a) su potencial para interactuar con niños; y (b) su desempeño en una prueba muy básica de matemática y lengua. Sin embargo, no se les exigía haber completado un nivel mínimo de educación secundaria superior o universitaria, ni contar con credenciales de formación docente. Recibieron una capacitación inicial y cursos de actualización periódicos, y tuvieron acceso a una biblioteca de documentos y videos de orientación. Se les pagaban salarios mucho más bajos que a los docentes de escuelas públicas pertenecientes a la administración pública.

medida en que el uso de la tecnología *aumentó la productividad de un instructor*, y no de la tecnología por sí sola.

2.2 Muestra

La intervención se implementó en tres centros Mindspark de Delhi orientados a atender barrios de bajos ingresos. La muestra del estudio se reclutó en septiembre de 2015 en cinco escuelas medias públicas cercanas a los centros. Las cinco escuelas tenían los grados 6-8, tres de ellas tenían 9.^o grado y solo dos tenían los grados 4-5. Tres eran escuelas solo de niñas y las otras dos, escuelas solo de varones. Por eso, nuestra muestra de estudio tiene una mayor proporción de niñas en los grados 6-8. En cada escuela, personal de EI y de J-PAL South Asia visitó las aulas de los grados 4-9 para presentar los centros Mindspark a los estudiantes e invitarlos, junto con sus padres, a una demostración en el centro cercano (se entregaron folletos informativos para compartir con los padres).

En las sesiones de demostración, el personal de EI presentó el programa y el estudio a los estudiantes y a sus padres. Se les dijo a los padres que, si su hijo o hija quería participar en el estudio, debía completar una evaluación de línea de base y que alrededor de la mitad de los estudiantes sería elegida por sorteo para recibir un vale que eximiría del arancel habitual de INR 200 por mes hasta febrero de 2016 (es decir, durante casi la mitad del año escolar). A los estudiantes que no fueran elegidos por sorteo se les dijo que se les daría acceso gratuito a los centros después de febrero de 2016 si participaban en una evaluación de línea final en febrero de 2016. Sin embargo, a los perdedores del sorteo no se les permitió acceder al programa durante el período de estudio. Estas dos características del diseño ayudaron a reducir el desgaste muestral y a aumentar el poder estadístico, respectivamente.

Nuestra muestra de estudio comprende los 619 estudiantes que completaron las pruebas y encuestas de línea de base. Alrededor del 97.5 % de estos estudiantes estaba matriculado en los grados 6-9.⁹ Para evaluar la representatividad de nuestra muestra de estudio autoseleccionada (y las implicancias para la validez externa de nuestros resultados), comparamos datos administrativos sobre los puntajes en los exámenes finales escolares del año escolar anterior (2014-15) entre los participantes del estudio y la población completa de estudiantes de las mismas escuelas. Los participantes del estudio tienen puntajes previos al programa moderadamente más altos (de alrededor de 0.15σ) que los no participantes (Tabla A.1). Sin embargo, hay un soporte común casi completo en la distribución de puntajes previos al programa de participantes y no participantes (Figura A.1), lo que sugiere que nuestros resultados probablemente se extiendan a otros estudiantes de este contexto (en especial porque

⁹589 estudiantes estaban matriculados en los grados 6-9, 15 estaban matriculados en los grados 4-5 y, para 15 estudiantes, no se informó el grado de matriculación. Nuestro foco en los grados 6-9 refleja nuestro financiamiento de la JPAL Post Primary Education Initiative, que priorizaba el estudio de intervenciones para mejorar la educación posprimaria (después del quinto grado).

no encontramos heterogeneidad en el impacto según los puntajes de línea de base; véase la sección 4.3).

2.3 Aleatorización y cumplimiento

Los 619 participantes fueron asignados aleatoriamente de forma individual a los grupos de tratamiento y de control, con 305 estudiantes en el grupo de control y 314 en el de tratamiento. La aleatorización se estratificó según las preferencias de centro y turno.¹⁰ Los grupos de tratamiento y de control no diferían significativamente en la línea de base en cuanto a género, NSE o puntajes de línea de base (Tabla 1, Panel A).¹¹ De los 314 estudiantes a quienes se ofreció un vale para el programa, la tasa de asistencia promedio fue del 58 % (alrededor de 50 días de un máximo posible de 86 días). La distribución completa de la asistencia entre los ganadores del sorteo se presenta en la Figura A.2, y en la sección 4 presentamos tanto las estimaciones ITT de ganar el sorteo como las estimaciones por IV de la relación dosis-respuesta en función de los días de asistencia.

De los 619 estudiantes que participaron en la prueba de línea de base, 539 (87 %) también rindieron la prueba de línea final. La tasa de seguimiento fue del 85 % en el grupo de tratamiento y del 90 % en el grupo de control. Esta diferencia es significativa al nivel del 10 %, por lo que presentaremos estimaciones de los efectos del tratamiento ponderadas por la probabilidad inversa, así como cotas de Lee (2009) del efecto del tratamiento (sección 4.5.1). Tampoco encontramos diferencias significativas entre los grupos de tratamiento y de control en las características promedio (edad, género, NSE o puntajes de línea de base) de los estudiantes que rindieron tanto la prueba de línea de base como la de línea final y que conforman nuestra muestra principal de estudio (Tabla 1, Panel B).

3 Datos

3.1 Logro de los estudiantes

El resultado principal de interés de este estudio son los puntajes de los estudiantes en las pruebas. Los puntajes se midieron mediante pruebas de lápiz y papel en matemática y en hindi antes de la aleatorización (septiembre de 2015, línea de base) y cerca del final del año

¹⁰Se pidió a los estudiantes que indicaran sus turnos preferidos para asistir a los centros Mindspark, dados sus horarios escolares y otros compromisos. Como la demanda de algunos turnos era mayor que la de otros, generamos el turno factible más alto para cada estudiante, con el objetivo de asegurar que la mayor cantidad posible de estudiantes fuera asignada a su primer o segundo turno de preferencia. Luego, la aleatorización se llevó a cabo dentro de estratos de centro por turno.

¹¹La diferencia en la edad es significativa al nivel del 10 % ($p=0.07$), pero se trata de una de varias comparaciones. La variable de edad también tiene más datos faltantes, ya que estos se completaron en encuestas autoinformadas.

escolar (febrero de 2016, línea final).¹² Las pruebas se administraron de forma centralizada en los centros Mindspark, en un mismo horario para los estudiantes de tratamiento y de control, con supervisión del personal de J-PAL para asegurar la integridad de las evaluaciones.

Las pruebas fueron diseñadas de manera independiente por el equipo de investigación y buscaban captar un rango amplio de logro de los estudiantes. La dificultad de los ítems iba desde preguntas “muy fáciles”, diseñadas para captar competencias del nivel de la escuela primaria muy por debajo del nivel del grado, hasta competencias “correspondientes al grado” presentes en evaluaciones internacionales. Los puntajes se generaron con modelos de teoría de respuesta al ítem para ubicar a todos los estudiantes en una escala común entre los distintos grados y entre las evaluaciones de línea de base y de línea final. La escala común a lo largo del tiempo nos permite caracterizar las ganancias *absolutas* en los puntajes logradas por el grupo de control entre las dos rondas de evaluación. Las evaluaciones funcionaron bien para captar un rango amplio de logro, con muy pocos estudiantes sujetos a efectos techo o piso. Los detalles del diseño de las pruebas, la calificación y las propiedades psicométricas de cada pregunta se presentan en el Apéndice E.

3.2 Datos del sistema CAL Mindspark

El sistema CAL Mindspark registra todas las interacciones de cada estudiante con la plataforma de software. Esto incluye la asistencia, el contenido presentado, las respuestas a cada pregunta presentada y el nivel de grado estimado del logro del estudiante en cada momento. Estos datos están disponibles (solo) para el grupo de tratamiento. Usamos estos datos de tres maneras: para describir la media y la distribución de las brechas de aprendizaje respecto de los estándares curriculares en cada grado en la línea de base; para demostrar la personalización de la instrucción por parte de Mindspark; y para caracterizar la evolución del logro de los estudiantes del grupo de tratamiento durante el período del tratamiento.

3.3 Registros escolares

A nivel de las escuelas, recopilamos registros administrativos de los puntajes en los exámenes escolares de todos los estudiantes del experimento y de sus compañeros en las mismas escuelas y aulas. Estos datos se recopilaron tanto para el año escolar 2014-15 (para comparar la muestra de estudio autoseleccionada con la población completa de estudiantes de las mismas escuelas) como para el año escolar 2015-16 (para evaluar si el tratamiento afectó los puntajes en los exámenes escolares).

¹²Era importante evaluar a los estudiantes con un formato de lápiz y papel, y no mediante pruebas por computadora, para no confundir las verdaderas ganancias en los puntajes con una mayor familiarización con la tecnología informática en el grupo de tratamiento.

3.4 Datos de los estudiantes

Al momento de la evaluación de línea de base, los estudiantes respondieron una encuesta escrita autoadministrada que recogía información básica sobre su nivel socioeconómico y las características del hogar. En la línea final se administró una encuesta más breve sobre características que varían en el tiempo. También realizamos una breve encuesta telefónica a los padres en julio de 2016 para recopilar datos sobre el uso de clases particulares y su opinión sobre el programa Mindspark.

4 Resultados

4.1 Niveles de aprendizaje y variación en el statu quo

Los datos del sistema CAL de Mindspark ofrecen una evaluación del nivel de grado real del aprendizaje de cada estudiante, independientemente del grado en el que esté matriculado. Usamos estos datos para caracterizar los niveles de aprendizaje, las brechas y la heterogeneidad entre los estudiantes de nuestra muestra. Los resultados principales se presentan en la Figura 1, que muestra la distribución conjunta completa de los grados en los que estaban matriculados los estudiantes y de su nivel de aprendizaje evaluado al inicio del tratamiento.¹³

Destacamos tres patrones principales en la Figura 1. En primer lugar, la mayoría de los niños ya se encuentran muy por debajo de las competencias del grado al comienzo de la educación posprimaria. En 6.^o grado, el estudiante promedio está unos 2.5 grados atrasado en matemática y alrededor de medio grado atrasado en hindi.¹⁴ En segundo lugar, aunque el logro promedio de los estudiantes es mayor en los grados más avanzados, lo que indica cierto aprendizaje a lo largo del tiempo, la pendiente de las ganancias de logro (medida por la recta de mejor ajuste) es considerablemente más plana que la línea de igualdad entre los estándares curriculares y los niveles de logro reales. Esto sugiere que el logro académico promedio de los estudiantes avanza a un ritmo menor que el previsto por el currículo—para 9.^o grado, los estudiantes están (en promedio) casi 4.5 grados atrasados en matemática y 2.5 grados atrasados en hindi. En tercer lugar, la figura ilustra con crudeza la enorme dispersión en el logro entre estudiantes matriculados en el *mismo* grado: los estudiantes de nuestra muestra abarcan 5-6 niveles de grado en cada grado.

¹³Nótese que estos datos solo están disponibles para los estudiantes del grupo de tratamiento. Sin embargo, la Figura 1 usa datos de la prueba diagnóstica *inicial* y no refleja ninguna instrucción brindada por Mindspark.

¹⁴Si bien la mayoría de los patrones entre grados son similares en las dos materias, la evaluación que hace el sistema informático de las competencias de los niños respecto del grado puede ser más confiable en matemática que en lengua (donde las competencias están menos delimitadas entre grados). Los puntajes de línea de base en nuestras pruebas independientes en ambas materias son más altos para los estudiantes que el programa CAL evaluó como ubicados en un nivel de grado de logro más alto, lo cual ayuda a validar la clasificación por nivel de grado que realiza el programa CAL (véase la Figura A.3). En el Apéndice D se presentan más detalles sobre la prueba diagnóstica y la clasificación que realiza el software.

En el Apéndice B presentamos evidencia adicional que muestra que los patrones documentados en la Figura 1 probablemente se verifiquen en una amplia variedad de contextos de países en desarrollo. En concreto, mostramos con conjuntos de datos adicionales que (a) la amplia distribución de los niveles de aprendizaje dentro de un mismo grado también se observa en otros contextos y (b) una proporción considerable de los estudiantes de 5.^o grado (hacia el final de la escuela primaria inferior en la mayoría de los países) suele estar hasta tres niveles de grado por debajo del nivel esperado por el currículo. En el caso de la India (donde contamos con datos exactamente comparables de otros estados), mostramos que tanto la dispersión en los niveles de aprendizaje como el rezago respecto de las normas curriculares son aún más graves en muestras representativas más grandes de los estados de Madhya Pradesh y Rajasthan que en nuestra muestra de estudio en Delhi.

4.2 Efectos del programa (estimaciones de intención de tratar)

Los principales efectos del tratamiento pueden verse en la Figura 2, que presenta los puntajes medios en las evaluaciones de línea de base y de línea final en matemática y hindi para los ganadores y perdedores del sorteo. Si bien los puntajes mejoran a lo largo del tiempo en ambos grupos, los puntajes de la línea final son significativa y sustancialmente más altos para el grupo de tratamiento en ambas materias.

Estimamos los efectos de intención de tratar (ITT) de ganar el sorteo (β) mediante:

$$Y_{iks2} = \alpha_s + \gamma_s \cdot Y_{iks1} + \beta_s \cdot Treatment_i + \phi_k + \epsilon_{iks2} \quad (1)$$

donde Y_{ikst} es el puntaje del estudiante i , en el estrato de aleatorización k , en la materia s en el período t (normalizado a $\mu=0$, $\sigma=1$ en la prueba de línea de base); $Treatment$ es una variable indicadora de ser ganador del sorteo; ϕ es un vector de efectos fijos de estrato; y ϵ_{iks2} es el término de error.¹⁵

Encontramos que los estudiantes que ganaron el sorteo para asistir a los centros Mindspark obtuvieron puntajes 0.37σ más altos en matemática y 0.23σ más altos en hindi que los perdedores del sorteo después de apenas 4.5 meses (Tabla 2: cols. 1-2). En las columnas 3 y 4 omitimos los efectos fijos de estrato de la regresión, y señalamos que en este caso el término constante α proporciona una estimación del valor agregado (VA) absoluto en el grupo de control a lo largo del tratamiento.¹⁶ Si expresamos el VA en el grupo de tratamiento ($\alpha + \beta$) como un

¹⁵A lo largo del artículo usamos errores estándar robustos de Huber-White en lugar de errores estándar agrupados, debido a que la aleatorización de los estudiantes al estado de tratamiento fue individual (y no por grupos). Los shocks comunes derivados del día de la prueba y de efectos del lugar se neutralizan mediante la inclusión de efectos fijos de estrato, ya que todos los estudiantes del mismo estrato (tanto de tratamiento como de control) rindieron la prueba el mismo día en el mismo lugar.

¹⁶Esta interpretación es posible porque las pruebas de línea de base y de línea final están vinculadas a una métrica común mediante la teoría de respuesta al ítem. Esto no sería posible si los puntajes se normalizaran dentro de cada grado-materia-período, como es práctica habitual. Nótese que los efectos del tratamiento son

múltiplo del VA del grupo de control (α), nuestros resultados indican que los ganadores del sorteo lograron más del doble de progreso en matemática, y alrededor de 2.4 veces el progreso en hindi, en comparación con los perdedores del sorteo. Estos son resultados ITT basados en una asistencia promedio de alrededor del 58 % entre los ganadores del sorteo. En la sección 4.4 presentamos resultados por IV y estimaciones de una relación dosis-respuesta.

Además de presentar los impactos sobre un estadístico resumen normalizado del aprendizaje de los estudiantes, también presentamos los impactos sobre la proporción de preguntas respondidas correctamente en distintos dominios de competencias de cada materia (Tabla 3). Los efectos ITT son positivos y significativos en todos los dominios de preguntas de la prueba. En matemática, van desde un aumento del 12 % en el tipo de preguntas más fácil (cálculo aritmético), determinado según la proporción de respuestas correctas en el grupo de control, hasta un aumento del 38 % en competencias más difíciles como geometría y medición. De manera similar, en hindi, los efectos ITT van desde una ganancia del 6.4 % en los ítems más fáciles (completar oraciones) hasta una ganancia del 17 % en la competencia más difícil (responder preguntas a partir de la interpretación y la integración de ideas e información de un texto).

4.3 Heterogeneidad

4.3.1 Heterogeneidad según las características de los estudiantes

Investigamos si los efectos ITT varían según el género, el nivel socioeconómico o los puntajes iniciales mediante una especificación de interacción lineal, y no encontramos evidencia de heterogeneidad en estas dimensiones (Tabla 4). Dado que los puntajes de línea de base son un buen estadístico resumen de los insumos educativos previos, también presentamos estimaciones no paramétricas del efecto ITT en función de los puntajes de línea de base. Para ello, graficamos medias suavizadas localmente con ponderación por kernel de los puntajes de línea final en cada percentil de la distribución de puntajes de línea de base, por separado para los grupos de tratamiento y de control (Figura 3). Tanto en matemática como en hindi, observamos que los puntajes del grupo de tratamiento son más altos que los del grupo de control en todos los percentiles de los puntajes de línea de base, y que las ganancias parecen similares en todos los percentiles.

A continuación, contrastamos la igualdad de los efectos del tratamiento en distintos puntos de la distribución de puntajes *dentro del grado*. Para ello, regresamos los puntajes de línea final sobre los puntajes de línea de base, variables indicadoras de tratamiento y de terciles dentro del grado en la línea de base, y términos de interacción entre la variable de tratamiento y dos terciles (la regresión se estima sin constante). También aquí vemos escasa evidencia de heterogeneidad (Tabla 5). El coeficiente de la variable dicotómica de tratamiento en sí es estadísticamente

muy similares (0.38σ en matemática y 0.23σ en hindi) cuando los puntajes se normalizan en relación con la distribución dentro del grado en el grupo de control en la línea final (Tabla A.2).

significativo, pero los términos de interacción del tratamiento con el tercil de línea de base en general no son significativos.¹⁷

Nótese, sin embargo, que observamos una heterogeneidad considerable en el progreso de los estudiantes según el nivel de aprendizaje inicial *en el grupo de control*. Si bien los estudiantes del tercio superior de la distribución de puntajes de línea de base muestran un progreso académico significativo entre la línea de base y la línea final, llama la atención que no podamos rechazar la hipótesis nula de *ningún aumento* en los puntajes para el tercio inferior de los estudiantes del grupo de control durante el mismo período (con coeficientes cercanos a cero en ambas materias), lo que sugiere que los estudiantes de menor rendimiento no logran ningún progreso académico en el statu quo (Figura 4).

Así, ganar un vale parece haber beneficiado de manera bastante pareja a los estudiantes de todas las partes de la distribución de logro, lo que sugiere que el software Mindspark pudo enseñar igual de bien a todos los estudiantes. Sin embargo, dado que los estudiantes del tercil más bajo de la distribución de puntajes de línea de base dentro del grado no lograron ningún progreso académico en el grupo de control en ninguna de las dos materias, las ganancias *relativas* del tratamiento (medidas como un múltiplo de lo que los estudiantes habrían aprendido en ausencia del tratamiento) fueron mucho mayores para los estudiantes de menor rendimiento, aun cuando las ganancias absolutas son similares entre todos los estudiantes (Figura 4).

4.3.2 Heterogeneidad según las características de las pruebas

La instrucción personalizada, combinada con una heterogeneidad considerable en la preparación de los estudiantes (Figura 1), puede llevar a que estudiantes con distintos niveles de aprendizaje iniciales adquieran competencias de diversa dificultad. A continuación contrastamos directamente esta posibilidad. Comenzamos usando los datos del sistema CAL para examinar la distribución por nivel de grado de los contenidos que el software presentó a los estudiantes del grupo de tratamiento (véase la Figura A.4). En matemática, la mayor parte del contenido que Mindspark presentó a los estudiantes estaba por debajo del nivel del grado, con muy poco contenido al nivel del grado en el que el estudiante está matriculado. En cambio, en hindi, además de contenidos de grados inferiores, una parte sustancial de la instrucción de Mindspark en cada grado estuvo al nivel del grado.

Encontramos heterogeneidad en los impactos sobre los puntajes según las características de las pruebas, en consonancia con el patrón de instrucción en la plataforma CAL descrito arriba. La Tabla 6 presenta estimaciones separadas de los efectos del tratamiento sobre la proporción de

¹⁷Las estimaciones puntuales sugieren que los efectos del tratamiento en hindi fueron mayores para los estudiantes más rezagados, pero solo una de las dos interacciones (con el tercil medio) es significativa, y el coeficiente de una interacción lineal entre el tratamiento y el tercil dentro del grado no es significativo (no se muestra).

preguntas respondidas correctamente al nivel del grado y por debajo de él.¹⁸ Observamos que, si bien hubo grandes efectos del tratamiento en matemática en los ítems por debajo del nivel del grado, no hubo *ningún impacto en las preguntas del nivel del grado*. En hindi, en cambio, encontramos que el efecto del tratamiento es significativo tanto para las preguntas al nivel del grado como para las que están por debajo de él.

Estos patrones también se replican en los datos independientes que recolectamos sobre los puntajes en los exámenes escolares. La Tabla 7 presenta el efecto del tratamiento de recibir la oferta de un vale sobre los puntajes en los exámenes escolares anuales de fin de año, tomados en marzo de 2016.¹⁹ En línea con los resultados en los ítems del nivel del grado de nuestras propias pruebas, encontramos un aumento significativo de 0.19σ en los puntajes de hindi, pero ningún efecto significativo en matemática. Tampoco encontramos efectos significativos en las demás materias (ciencias, ciencias sociales o inglés), aunque todas las estimaciones puntuales son positivas.

4.3.3 Interacción entre las características de las pruebas y la preparación de los estudiantes

Si bien el impacto medio en los exámenes escolares no es significativo, los estudiantes con puntajes de línea de base más altos podrían tener más probabilidades de mejorar también en los exámenes escolares (del nivel del grado), porque tendrían más probabilidades de recibir contenidos del nivel del grado en el sistema Mindspark. Contrastamos esta posibilidad y encontramos evidencia consistente de que los puntajes en los exámenes escolares también mejoran para los estudiantes tratados del tercio superior de la distribución de puntajes de línea de base (Tabla 8). Para estos estudiantes, los puntajes en los exámenes escolares son más altos en *todas las materias* (con efectos del tratamiento de entre $0.2-0.5\sigma$), y las ganancias son significativas en cuatro de las cinco materias (hindi, matemática, inglés y estudios sociales). En promedio entre las materias, estos estudiantes obtuvieron puntajes 0.33σ más altos ($p=0.03$). En cambio, no encontramos mejoras en los puntajes de los exámenes escolares para los dos tercios inferiores de los estudiantes.²⁰

Contrastamos patrones similares en nuestras propias pruebas (Tabla A.3), y los resultados de matemática concuerdan con los hallados en los exámenes escolares: los estudiantes tratados del tercil superior obtienen mejores resultados en los ítems del nivel del grado ($p=0.08$), mientras

¹⁸Los ítems de nuestras pruebas, diseñadas para captar un amplio rango de logro, se asignaron a niveles de grado con la ayuda de un experto en currículo.

¹⁹En Delhi, los exámenes anuales son comunes a todas las escuelas para cada materia en cada grado. En nuestras regresiones, normalizamos los puntajes a $\mu=0$, $\sigma=1$ en cada grado/materia en el grupo de control.

²⁰De hecho, para el tercio inferior de los estudiantes, el coeficiente suele ser negativo (aunque por lo general no es estadísticamente significativo). Esto sugiere que el programa, al centrarse en el dominio de conceptos ajustado a los niveles de logro de los estudiantes, puede haber desplazado otras actividades (como la memorización mecánica y la práctica con preguntas de exámenes anteriores) que podrían conducir a un mejor desempeño en los exámenes escolares en el corto plazo.

que los estudiantes de los dos terciles inferiores no muestran ningún efecto del programa. Sin embargo, como reflejo de los grandes déficits de conocimientos de matemática en relación con el currículo, los estudiantes tratados de todos los terciles progresan en los ítems por debajo del nivel del grado (donde el efecto del tratamiento es positivo y estadísticamente significativo para todos los terciles).²¹

Estos resultados ilustran la importancia de realizar investigación educativa con pruebas bien calibradas que sean informativas en un amplio rango de logro de los estudiantes (especialmente en contextos de países en desarrollo con amplia variación en el aprendizaje de los estudiantes dentro de cada grado). En nuestro caso, basarse en evaluaciones del nivel del grado habría llevado a inferencias incorrectas sobre los impactos del programa, y a la conclusión de que el programa no tuvo impacto en matemática, a pesar de las muy grandes ganancias en los puntajes observadas en una prueba debidamente construida. Véase el Apéndice E para más detalles sobre el diseño de las pruebas de nuestro estudio, y Muralidharan (2017) para una discusión detallada sobre la construcción de pruebas para la investigación educativa en general.

4.4 Estimaciones por IV de la relación dosis-respuesta

Todos los resultados presentados hasta aquí son estimaciones ITT, basadas en una asistencia promedio de alrededor del 58 % entre los ganadores del sorteo.²² En esta sección presentamos estimaciones LATE del impacto de asistir efectivamente a los centros Mindspark y (con supuestos adicionales) estimaciones de los efectos del tratamiento predichos para distintos niveles de exposición al programa. Estimamos la relación dosis-respuesta entre los días de asistencia y el valor agregado mediante:

$$Y_{is2} = \alpha + \gamma \cdot Y_{is1} + \mu_1 \cdot Attendance_i + \eta_{is2} \quad (2)$$

donde Y_{ist} se define como antes, $Attendance$ es la cantidad de días en que un estudiante inició sesión en el sistema Mindspark (que es cero para todos los perdedores del sorteo) y η_{ist} es el término de error. Dado que la asistencia al programa puede ser endógena respecto de las

²¹En nuestras pruebas, las ganancias en hindi son mayores (y solo estadísticamente significativas) para el tercil inferior (Tabla A.3). Esto contrasta con los resultados escolares, donde las ganancias son mayores (y solo estadísticamente significativas) para el tercil superior (Tabla 8). Esto puede reflejar diferencias en el diseño de las pruebas. Dado que nos preocupaban más los efectos piso que los efectos techo de las pruebas, nuestras pruebas se centraron mayormente en la lectura con comprensión en niveles por debajo del grado, mientras que los exámenes escolares probablemente tendrían una proporción mucho mayor de ítems (más difíciles) del nivel del grado.

²²Alrededor del 13 % de los ganadores del sorteo asistió un día o menos. La asistencia media entre los demás fue de 57 días (alrededor del 66 %). La Figura A.2 grafica la distribución de la asistencia entre los ganadores del sorteo, y la Tabla A.4 presenta las correlaciones de la asistencia entre los ganadores del sorteo con diversas características de línea de base.

ganancias esperadas del programa, instrumentamos *Attendance* con la oferta aleatorizada de un vale.

Las estimaciones por IV sugieren que, en promedio, un día adicional de asistencia a los centros Mindspark aumentó los puntajes en 0.0067σ en matemática y 0.0043σ en hindi (Tabla 9: cols. 1-2). Estas estimaciones identifican la respuesta causal promedio (ACR) del tratamiento, que “capta un promedio ponderado de las respuestas causales a un cambio unitario en el tratamiento (en este caso, un día adicional de asistencia), para aquellos cuyo estado de tratamiento se ve afectado por el instrumento” (Angrist and Imbens, 1995). Usar estas estimaciones por IV para predecir el efecto de variar la cantidad de días de asistencia requiere supuestos adicionales sobre (a) la naturaleza de la heterogeneidad de los efectos del tratamiento entre estudiantes (ya que la ACR solo se identifica sobre un subconjunto de cumplidores, y no sobre la muestra completa) y (b) la forma funcional de la relación entre los días de asistencia y el efecto del tratamiento (ya que la ACR promedia los efectos causales sobre distintas intensidades de tratamiento).

Presentamos tres elementos de evidencia sugestiva de que suponer efectos del tratamiento constantes entre estudiantes puede ser razonable en este contexto. En primer lugar, los efectos ITT fueron constantes a lo largo de toda la distribución del logro inicial, que es una buena medida resumen de la heterogeneidad individual relevante (Figura 3, Tabla 4). Tampoco encontramos evidencia significativa de heterogeneidad del tratamiento según las características observadas previas al tratamiento (Tabla 4).

En segundo lugar, no podemos rechazar la igualdad entre las estimaciones por IV de la Ec.(3) y las estimaciones por MCO con una especificación de valor agregado (VA) (Tabla 9: cols. 3-4), lo que sugiere que el ATE y el LATE pueden ser similares en este caso. Tanto en matemática como en hindi, el valor p de la prueba de diferencia de Sargan (similar a una prueba de Hausman, pero que admite heterocedasticidad) que contrasta la equivalencia de los resultados por MCO y por IV es sustancialmente mayor que 0.1 (cols. 1-2).²³

Por último, el término constante de las especificaciones de VA por MCO (que corresponde a una asistencia nula) es similar cuando se estima con la muestra completa y cuando se estima usando solo los datos del grupo de tratamiento (Tabla 9: cols. 3-6).²⁴ El término constante se identifica usando tanto el grupo de control como los “never-takers” cuando se usa la muestra completa, pero se identifica solo sobre los “never-takers” cuando la muestra se restringe a los ganadores

²³Nótese que esta estrecha correspondencia entre las estimaciones de VA por MCO y por IV es consistente con abundante evidencia reciente de que los modelos de VA suelen coincidir estrechamente con las estimaciones experimentales y cuasiexperimentales (véanse, por ejemplo, Chetty, Friedman and Rockoff (2014); Deming et al. (2014); Singh (2015); Angrist et al. (2016))

²⁴No podemos rechazar la igualdad de la constante entre las regresiones ni en matemática ($p=0.38$) ni en hindi ($p=0.61$).

del sorteo. Así, la similitud de los resultados de los “never takers” y del grupo de control sugiere la igualdad de los resultados potenciales entre los distintos grupos de cumplimiento.²⁵

A continuación exploramos la forma funcional de la relación entre los días de asistencia y el efecto del tratamiento, tanto gráficamente (graficando el valor agregado contra la asistencia para los ganadores del sorteo) como analíticamente. El análisis gráfico sugiere una relación lineal en ambas materias (Figura 5). Además, si bien el valor agregado en los puntajes está fuertemente correlacionado con la cantidad de días de asistencia en una especificación lineal (Tabla 9: cols. 3-6), agregar un término cuadrático no mejora el ajuste, y el término cuadrático no es significativo (véase la Tabla A.5). Una relación dosis-respuesta lineal resulta además plausible si se considera la naturaleza adaptativa de la intervención, que le permite ser igualmente efectiva independientemente del nivel de aprendizaje inicial del estudiante o de su ritmo de progreso académico. Así, los rendimientos decrecientes de la exposición al programa podrían no aplicarse durante la duración relativamente corta del tratamiento en este estudio (lo cual es consistente con el patrón observado en la Figura 5).

Bajo los supuestos de efectos del tratamiento constantes y de una relación dosis-respuesta lineal, ambos razonables en este contexto, nuestros resultados por IV sugieren que asistir a los centros Mindspark durante 90 días, lo que equivale aproximadamente a medio año escolar con un 80 % de asistencia, conduciría a ganancias de 0.6σ en matemática y 0.39σ en hindi (última fila de la Tabla 9). Extrapolamos los resultados a 90 días, en lugar de a un año escolar completo, para mantener las predicciones cerca del rango de exposición al programa que brindó nuestro experimento (el máximo fue de 86 días). Duraciones de exposición al programa similares o mayores serían factibles, incluso con las tasas de asistencia observadas, si, por ejemplo, la intervención comenzara al inicio del año escolar y no a mitad de año como en este estudio.

Estas estimaciones son conservadoras y probablemente subestiman la relación dosis-respuesta, porque la variable *Attendance* incluye el tiempo dedicado en los centros Mindspark a la instrucción en otras materias que no evaluamos (especialmente inglés).²⁶ En la Tabla A.6 presentamos estimaciones análogas por IV y de valor agregado que solo consideran los días que los estudiantes dedicaron a las materias que evaluamos (matemática e hindi). Con estos resultados, y bajo los mismos supuestos que antes, estimamos que 90 días de asistencia a Mindspark, divididos en partes iguales entre las dos materias, conducirían a ganancias en los puntajes de 0.8σ en matemática y 0.54σ en hindi (última fila de la Tabla A.6).

²⁵Esta prueba es similar en espíritu a las pruebas sugeridas por Bertanha and Imbens (2014) y Brinch, Mogstad and Wiswall (2017) para extender la validez de las estimaciones RD e IV más allá del LATE a los efectos promedio del tratamiento.

²⁶Véase Muralidharan and Sundararaman (2015) para una ilustración de la importancia de tener en cuenta los patrones de uso del tiempo entre materias para hacer inferencias sobre la productividad de las intervenciones educativas.

4.5 Robustez

4.5.1 Desgaste muestral

Dado que la diferencia en el desgaste muestral entre los grupos de tratamiento y de control es significativa al nivel del 10 % (Tabla 1), evaluamos la robustez de nuestros resultados al desgaste muestral modelando la selección en la línea final a partir de características observadas, y presentamos efectos del tratamiento ponderados por la probabilidad inversa: los efectos ITT estimados permanecen prácticamente sin cambios (Tabla A.7). También calculamos las cotas de Lee (2009) para el efecto ITT: aunque las cotas son amplias, los efectos del tratamiento son siempre positivos y significativos (Tabla A.8).

4.5.2 Familiaridad con las preguntas de las pruebas

Nuestras pruebas independientes utilizaron ítems de varias evaluaciones externas, algunas de las cuales (en el contexto indio) fueron diseñadas por EI; esto plantea la posibilidad de que los resultados en nuestras evaluaciones estén sobrestimados debido a la duplicación de ítems entre nuestras pruebas y el banco de ítems de Mindspark. Cabe señalar que este banco de ítems contiene más de 45,000 ítems, por lo que la mera duplicación en la base de datos no implica que a un estudiante se le haya presentado el mismo ítem durante la intervención. No obstante, evaluamos esta preocupación calculando el efecto del tratamiento expresado como la proporción de respuestas correctas en ítems de evaluaciones de EI y en ítems de otras evaluaciones. Los efectos ITT son positivos, estadísticamente significativos y de magnitud similar para ambos conjuntos de ítems en matemática y en hindi (Tabla A.9).

4.5.3 Clases particulares

Nuestros resultados también podrían estar confundidos si ganar un vale de Mindspark hubiera generado cambios en el uso de clases particulares. Para evaluar esta posibilidad, recolectamos datos de los padres de los estudiantes del experimento, mediante encuestas telefónicas, sobre si el estudiante asistió a clases particulares pagas adicionales (distintas de Mindspark) en alguna materia en cada mes de julio de 2015 a marzo de 2016. Dividiendo este período en “preintervención” (julio a septiembre de 2015) y “posintervención” (octubre de 2015 a marzo de 2016), evaluamos si ganar un vale de Mindspark afectó la incidencia de las clases particulares en el período de “posintervención”. Presentamos estos resultados en la Tabla A.10. Si bien se observa un aumento moderado de las clases particulares para todos los estudiantes en el período postratamiento (consistente con un mayor uso de clases particulares cerca de los exámenes escolares anuales), no encontramos evidencia de un uso diferencial de clases particulares entre los ganadores del sorteo.

5 Discusión

5.1 Mecanismos

Las estimaciones presentadas más arriba reflejan una combinación del software de CAL, la enseñanza grupal y el tiempo de instrucción adicional, y no podemos identificar experimentalmente la contribución relativa de estos canales. En esta sección, presentamos cuatro conjuntos de evidencia adicional que señalan, cada uno, que el sistema de CAL fue el factor crítico detrás de las grandes ganancias en los puntajes que encontramos.

La primera evidencia, y la más importante, proviene de un estudio contemporáneo realizado en la misma localidad y con el mismo grupo etario de estudiantes: Berry and Mukherjee (2016) reportan los resultados de una evaluación aleatorizada que estudió el impacto de clases particulares extraescolares sobre los resultados de aprendizaje de estudiantes de escuela media (en los grados 6-8) en Delhi, al mismo tiempo que nuestro estudio. El programa también ofrecía seis días de instrucción por semana, durante tres horas por día (frente a 1.5 horas por día en los centros Mindspark), y también cobraba INR 200 por mes.²⁷ El programa de clases particulares era gestionado por una organización sin fines de lucro muy respetada, Pratham, que ha implementado varios programas educativos en la India que, según se ha encontrado, tienen impactos positivos significativos sobre el aprendizaje de los estudiantes en el nivel primario (véanse, por ejemplo, Banerjee et al. (2007, 2016)). A pesar de varias similitudes, había dos diferencias clave entre este programa y los centros Mindspark. En primer lugar, este programa se centraba en reforzar el conocimiento del currículo del grado y no estaba adaptado a la preparación académica de los estudiantes.²⁸ En segundo lugar, la instrucción era impartida en forma presencial por un tutor en grupos de hasta 20 estudiantes (una proporción de instructores por estudiante similar a la observada en los centros Mindspark), pero no utilizaba ninguna tecnología para la instrucción.

Al cabo de un año del programa, Berry and Mukherjee (2016) no encuentran *ningún impacto* sobre los puntajes de los estudiantes en evaluaciones independientes de matemática ni de lengua, a pesar de que el programa dedicó más del doble del tiempo de instrucción extraescolar provisto por los centros Mindspark durante nuestra evaluación (el doble del tiempo de instrucción programado por semana, y evaluado después de un año completo en lugar de 4.5 meses). Estos resultados sugieren que el tiempo de instrucción adicional con clases particulares grupales (los otros dos componentes de nuestra intervención además del CAL) por sí solo podría no haber

²⁷La edad promedio de los estudiantes en Berry and Mukherjee (2016) era de 12.06 años, frente a 12.67 en nuestro estudio. La leve diferencia se debe a que nuestra muestra también incluye estudiantes de 9.^o grado y no solo de los grados 6-8.

²⁸Si bien Pratham ha estado a la vanguardia de la implementación del enfoque de “Enseñanza en el Nivel Adecuado (TaRL)”, este programa en particular se centró en repasar contenidos del grado en respuesta a la demanda de los padres (según comunicación personal con los autores de Berry and Mukherjee (2016)).

tenido mucho impacto sobre el aprendizaje.²⁹ También sugieren que la restricción operativa para el aprendizaje de los estudiantes en este contexto no era el tiempo de instrucción, sino la (probable) ineficacia del tiempo de instrucción adicional dedicado a la modalidad por defecto de enseñar en el nivel correspondiente al grado, en un contexto donde la mayoría de los estudiantes están varios grados por detrás (como se observa en la Figura 1).

En segundo lugar, aportamos evidencia directa de que el software de CAL abordó eficazmente esta restricción a una pedagogía eficaz al orientar el material de instrucción al nivel de cada estudiante individual y, de ese modo, dar cabida a la amplia variación en la preparación de los estudiantes documentada en la Figura 1. Lo observamos en la Figura 6, donde el eje horizontal de cada subgráfico muestra el nivel de preparación académica evaluado de cada estudiante matriculado en un grado determinado, y el eje vertical muestra que el software de CAL presentó a los estudiantes material que se encontraba *en su nivel de grado o en niveles de grado adyacentes*.³⁰ Además, el sistema de CAL no solo da cabida a la variación en los niveles iniciales de aprendizaje, sino también al ritmo de aprendizaje entre estudiantes. La Figura 7 presenta gráficos no paramétricos del nivel promedio de dificultad de los ítems de matemática presentados a los estudiantes a lo largo de la intervención, y documenta que el software actualiza en tiempo real su estimación de los niveles de logro de los estudiantes y modifica la instrucción en consecuencia. La individualización de la actualización dinámica de contenidos se destaca aún más en la Figura A.6, donde utilizamos datos a nivel de estudiante para graficar trayectorias similares por separado para *cada estudiante* del grupo de tratamiento.

Enseñar eficazmente en un contexto con una heterogeneidad tan grande en los niveles y trayectorias de aprendizaje de los estudiantes dentro del mismo grado sería muy difícil incluso para docentes bien formados y motivados. En cambio, una vez que el software de CAL se programa para presentar contenidos según el nivel de aprendizaje evaluado de un estudiante y para ajustar los contenidos al ritmo de su progreso, el software puede manejar heterogeneidad adicional a un costo marginal nulo, lo cual no ocurre con un docente.³¹ Por lo tanto, es probable que el software de CAL haya sido el factor habilitante clave para que *todos* los estudiantes

²⁹Cabe señalar que es poco probable que estos resultados nulos se deban a que los estudiantes del grupo de control asistieran, en cambio, a otras clases particulares. Berry and Mukherjee (2016) reportan una primera etapa significativa sobre la asistencia de los ganadores del sorteo a *cualquier* clase particular y pueden descartar tamaños de efecto mayores que 0.15σ .

³⁰Tanto en matemática como en hindi, utilizamos datos de un único día cercano al inicio de la intervención, posterior a que todos los estudiantes hubieran completado su evaluación inicial, y en el que la instrucción asistida por computadora de Mindspark en la materia correspondiente estaba programada en los tres centros.

³¹Cabe señalar que la fortaleza del software reside no solo en su capacidad para personalizar el nivel de instrucción, sino en hacerlo con contenidos de calidad uniformemente alta en todos los niveles (con las características descritas en la sección 2.1). Aun si un docente quisiera repasar materiales de grados inferiores en clase, le resultaría muy difícil preparar eficazmente material que abarque varios grados y presentar contenidos diferenciados entre los estudiantes en un aula.

pudieran aprender, en comparación con la modalidad por defecto de una pedagogía acorde al grado en un aula estándar (o en un contexto de clases particulares grupales extraescolares).

En tercer lugar, los datos sobre la asignación de estudiantes a los turnos de Mindspark (que asistirían juntos a la instrucción grupal) sugieren fuertemente que la enseñanza se producía principalmente en la plataforma de CAL, y que el papel del instructor consistía en promover la adherencia. Lo observamos claramente en la Figura A.5, que muestra que los estudiantes de nuestro estudio (que están principalmente en los grados 6-9) fueron asignados a turnos de Mindspark que a menudo incluían estudiantes matriculados en *los grados 1-5 en el mismo turno*. Esto se debe a que la principal consideración de EI al asignar estudiantes a los turnos era la conveniencia horaria de estudiantes y padres. Así, a EI no le preocupaba tener estudiantes *de los grados 1-9 en el mismo turno*, una configuración de aula que tendría muy poco sentido para la instrucción grupal.³²

Por último, cabe señalar que los patrones de resultados en los puntajes que presentamos en la sección 4.3.2 también son consistentes con una instrucción impulsada principalmente por el software. Las ganancias en los puntajes de matemática se observaron en las preguntas por debajo del nivel del grado (que es lo que enseñaba el software de CAL) y no en las preguntas del nivel del grado (que el software de CAL no enseñaba). Esto también es consistente con el patrón de heterogeneidad observado según el nivel inicial de aprendizaje de los estudiantes, tanto en las pruebas escolares como en nuestras evaluaciones independientes.

Estas cuatro evidencias sugieren que el software de CAL fue el principal impulsor de los resultados que encontramos. Sin embargo, según EI, el instructor sí tuvo un papel importante en la promoción de la adherencia al alentar la asistencia regular de los estudiantes a los centros, asegurar el tiempo dedicado a la tarea mientras los estudiantes estaban frente a la computadora y supervisar la realización de las tareas escolares y la preparación de exámenes durante el período de instrucción grupal (que los padres demandaban). Esta discusión sugiere que puede haber complementariedades entre docentes y tecnología. Por lo tanto, nuestros resultados no deben interpretarse como el impacto del software de CAL por sí solo, sino más bien como una estimación del efecto del CAL en un contexto en el que también había un instructor para apoyar la adherencia al CAL. Alternativamente, dados los resultados nulos de las clases particulares grupales extraescolares dirigidas por instructores encontrados por (Berry and Mukherjee, 2016), nuestros resultados también pueden interpretarse como una muestra de la medida en que el uso de la tecnología en la educación puede aumentar la productividad de un instructor.

³²Cabe señalar que la evidencia previa sobre los impactos positivos de la instrucción grupal ha destacado la importancia de *homogeneizar* los grupos según el nivel de aprendizaje para lograr una instrucción eficaz (Banerjee et al., 2007, 2016). Por lo tanto, es muy poco probable que EI hubiera optado por turnos que abarcaran tantos grados, a menos que considerara que la instrucción grupal era de segundo orden respecto de la instrucción en el sistema de CAL.

5.2 Costo-efectividad

Dado que evaluamos un programa extraescolar, una comparación natural de costo-efectividad es con las clases particulares extraescolares, que están muy extendidas en nuestro contexto. La comparación directa con los resultados de Berry and Mukherjee (2016) sugiere que las clases particulares grupales extraescolares sobre materiales del grado no tuvieron impacto alguno sobre el aprendizaje en el mismo contexto, incluso con más del doble de la duración de la exposición en relación con el programa que estudiamos.

Una segunda comparación relevante para las políticas es con la productividad de las escuelas públicas (de donde se reclutó a los sujetos del estudio). El gasto mensual por alumno en estas escuelas de Delhi era de alrededor de INR 1500 (USD 22) en 2014-15; los estudiantes dedican 240 minutos por semana a matemática y hindi; y estimamos que la cota superior del valor agregado en estas escuelas fue de 0.33σ en matemática y 0.17σ en hindi durante el período de estudio de 4.5 meses. Específicamente, este fue el valor agregado *total* en el grupo de control en la Tabla 2, que también incluye los efectos de los insumos del hogar y de las clases particulares y, por lo tanto, probablemente sobrestima el valor agregado de las escuelas públicas.

A partir de nuestras estimaciones ITT, observamos que Mindspark agregó 0.37σ en matemática y 0.23σ en hindi durante el mismo período, con alrededor de 180 minutos por semana en cada materia. El programa Mindspark, tal como se implementó, tuvo un costo no subsidiado de alrededor de INR 1000 por estudiante (USD 15) por mes. Esto incluye los costos de infraestructura, hardware, personal y costos prorrateados de desarrollo de software. Así, incluso implementado con costos fijos altos y sin economías de escala, y con una asistencia del 58 %, el acceso a los centros Mindspark produjo más aprendizaje a un menor costo financiero y de tiempo que el gasto público por defecto.

Es probable que los costos de Mindspark en estado estacionario, a escalas relevantes para las políticas, sean mucho menores, ya que los (altos) costos fijos de desarrollo del producto ya se han incurrido. Si se implementara en escuelas públicas, incluso a una escala modesta de 50 escuelas, los costos por alumno se reducirían a alrededor de USD 4 por mes (incluidos los costos de hardware). Por encima de una escala de 1000 escuelas, los costos marginales por alumno (mantenimiento del software y soporte técnico) son de alrededor de USD 2 anuales, lo que representa una pequeña fracción del costo anual de USD 150 (a lo largo de 10 meses) durante nuestro piloto.³³ Por lo tanto, el programa tiene el potencial de ser muy costo-efectivo a escala.

Además, si bien el gasto en educación puede aumentar continuamente a lo largo del tiempo, el tiempo de los estudiantes es finito. Por lo tanto, también es útil evaluar la efectividad de las intervenciones educativas por unidad de tiempo, *con independencia* del costo financiero. Un

³³Estas cifras se basan en un presupuesto real para implementar Mindspark en escuelas públicas, elaborado y presentado por EI en 2017.

punto de comparación útil lo proporciona Muralidharan (2012), quien encuentra que otorgar bonificaciones individuales por desempeño a los docentes en la India generó ganancias en los puntajes de 0.54σ y 0.35σ en matemática y lengua para los estudiantes expuestos al programa durante cinco años. Este es uno de los mayores tamaños de efecto observados hasta la fecha en un estudio experimental sobre educación en países en desarrollo. Sin embargo, estimamos que asistir regularmente a los centros Mindspark durante medio año produciría ganancias similares (en una décima parte del tiempo).³⁴

La Figura 7 sugiere que los estudiantes que obtuvieron acceso a los centros Mindspark mejoraron un grado completo en matemática en apenas 4.5 meses (incluso con solo un 58 % de asistencia). Por lo tanto, utilizar Mindspark regularmente en las escuelas puede ser una opción especialmente prometedora para ayudar a cerrar las grandes brechas en la preparación de los estudiantes en plazos que podrían permitir que los estudiantes rezagados alcancen los estándares de instrucción del grado. Poner a prueba esta posibilidad es un tema importante para la investigación futura.

5.3 Implicancias para las políticas

A pesar de las grandes ganancias en los puntajes que encontramos, la demanda de los padres por los centros Mindspark fue baja en ausencia de los vales (que eximían del arancel). De hecho, los tres centros de nuestro estudio cerraron poco después de la conclusión de nuestro experimento ante la baja disposición a pagar de los padres (incluso al precio subsidiado que se cobraba a los estudiantes ajenos a nuestro estudio que asistían a los centros Mindspark). Los donantes que subsidiaban los aranceles de los estudiantes regulares de los centros Mindspark estipularon que solo seguirían financiando los subsidios si los centros podían operar al 80 % de su capacidad o por encima de ese nivel (y así demostrar la disposición de los padres a pagar al menos el precio subsidiado). En la práctica, los niveles de matriculación estuvieron considerablemente por debajo de esta meta, y los centros tuvieron que cerrar porque terminó el financiamiento filantrópico de los subsidios.³⁵ Por lo tanto, los modelos de CAL que cobran aranceles pueden limitar la posibilidad de que los estudiantes de bajos ingresos accedan a ellos, y la implementación eficaz de tecnología educativa en las escuelas públicas probablemente sea importante para brindar acceso a programas de CAL a los estudiantes más desfavorecidos.

³⁴Por supuesto, es probable que parte de estas ganancias se desvanezca con el tiempo, como se observó en Banerjee et al. (2007). Sin embargo, hoy es bien sabido que los efectos de *todas* las intervenciones educativas decaen con el tiempo (Jacob, Lefgren and Sims, 2010; Andrabi et al., 2011). Por eso no afirmamos que extender el programa Mindspark durante 5 años generaría ganancias en los puntajes diez veces mayores, sino que simplemente señalamos que las ganancias observadas a lo largo de 5 años en Muralidharan (2012) se lograron aquí en una décima parte del tiempo.

³⁵Sin embargo, Mindspark como producto funciona bien y EI continúa operando y mejorando los modelos de Mindspark con arancel completo para familias de NSE más alto, donde la demanda sigue siendo sólida. Dado que los centros cerraron en marzo de 2016, a los estudiantes del grupo de control, a quienes se les había ofrecido acceso gratuito a los centros después de la prueba de línea final, se les ofrecieron en cambio materiales educativos gratuitos como compensación por participar en el estudio.

Esta convicción se refleja en el creciente interés de las políticas en todo el mundo por utilizar la tecnología en la educación pública. Sin embargo, los responsables de políticas (especialmente en los países en desarrollo) se han concentrado principalmente en proveer hardware informático, sin prestar una atención equivalente al uso de la tecnología para mejorar la pedagogía.³⁶ Nuestros resultados (junto con la revisión de la evidencia en el Apéndice C) sugieren que estas inversiones en hardware probablemente generen retornos mucho mayores en términos de mejores resultados de aprendizaje si también se presta atención a implementar software como Mindspark (u otro similar) para mejorar la pedagogía en las escuelas públicas.

Nuestros resultados también son relevantes para los debates de políticas sobre la mejor forma de enseñar eficazmente en contextos con gran variación en la preparación de los estudiantes. Una opción de política ampliamente considerada es el agrupamiento de las aulas por nivel, pero esto puede no ser factible en muchos contextos de países en desarrollo.³⁷ Además, aun cuando es factible, el agrupamiento por nivel es controvertido y la evidencia mundial sobre su impacto es mixta (Betts, 2011). Nuestros resultados sugieren que los programas de CAL bien diseñados podrían ofrecer las ventajas pedagógicas del agrupamiento por nivel y, al mismo tiempo, mitigar varias de sus limitaciones, como se enumera a continuación.

En primer lugar, el CAL permite individualizar la instrucción a nivel de cada estudiante, mientras que las aulas agrupadas por nivel todavía deben atender la variación en los niveles y trayectorias de aprendizaje de los estudiantes con un protocolo de instrucción común. En segundo lugar, al permitir que los estudiantes trabajen a su propio ritmo, evita los posibles efectos negativos de que los estudiantes sean rotulados como pertenecientes a un grupo más débil. En tercer lugar, la actualización dinámica de contenidos mitiga el riesgo de un agrupamiento permanente prematuro de los ‘estudiantes de maduración tardía’. En cuarto lugar, permite diferenciar la instrucción sin cambiar a los compañeros en el aula. En quinto lugar, en comparación con las políticas de repetición de grado o de promoción acelerada, el uso de programas de CAL en las aulas permite preservar el agrupamiento social de los estudiantes por cohorte de edad (lo que puede favorecer un mejor desarrollo de las habilidades socioemocionales), a la vez que admite variación en el contenido académico presentado.

³⁶Por ejemplo, varios gobiernos estatales de la India han distribuido computadoras portátiles gratuitas a los estudiantes en los últimos años. Además, el avance en la implementación de la política nacional sobre tecnología en la educación suele medirse por la cantidad de escuelas con laboratorios de computación.

³⁷A diferencia de los países desarrollados, donde los estudiantes de escuela media y secundaria pueden elegir sus materias y cursar asignaturas más fáciles y más avanzadas, la mayoría de los sistemas educativos de los países en desarrollo del sur de Asia y de África subsahariana se caracterizan por preparar a los estudiantes para un único examen de egreso escolar de alto impacto. Por lo tanto, la organización por defecto de las escuelas consiste en tener a todos los estudiantes de un grado determinado en la misma aula, con el docente centrado en completar el currículo establecido por los libros de texto oficiales del grado correspondiente.

6 Conclusión

Presentamos evidencia experimental sobre el impacto de un programa de instrucción complementaria basado en tecnología en grados de posprimaria en la India urbana, y encontramos que obtener acceso al programa generó ganancias grandes y rápidas en los puntajes tanto en matemática como en lengua. La combinación de hechos presentados en las Figuras 1 y 6 pone de relieve tanto el desafío de enseñar eficazmente en condiciones de gran heterogeneidad en el aprendizaje de los estudiantes como el potencial del aprendizaje asistido por computadora (CAL) para abordar este desafío al poder “Enseñar en el Nivel Adecuado” (TaRL) a todos los estudiantes. Por lo tanto, conjeturamos que una razón clave de los grandes efectos que encontramos es la capacidad del programa de CAL para enseñar con igual eficacia a *todos* los estudiantes, incluidos aquellos que la instrucción habitual deja atrás (como se observa en la Figura 4).

Además de implementar eficazmente TaRL, los grandes efectos también pueden reflejar la capacidad del software para abordar eficazmente otras restricciones a la enseñanza y el aprendizaje eficaces. La alta calidad de los contenidos, combinada con una implementación y una interfaz eficaces, puede ayudar a sortear las restricciones de capital humano y de motivación docente. La estructura de los contenidos (que requiere una interacción regular del estudiante con el sistema) también puede ayudar a promover el compromiso de los estudiantes, en comparación con la participación pasiva en la instrucción típica en el aula. Los algoritmos que analizan los patrones de error de los estudiantes y proporcionan retroalimentación diferenciada y contenidos de seguimiento administrados en tiempo real permiten una retroalimentación más pertinente y mucho más frecuente. Todas estas características reflejan un desarrollo continuo e iterativo del programa a lo largo de un período extenso de más de una década.

Estos efectos podrían, de manera plausible, aumentarse aún más con un mejor diseño. Es posible que en contextos intraescolares haya una mayor adherencia al programa en términos de asistencia. También podría ser posible mejorar la eficacia de la instrucción dirigida por docentes en un entorno de ‘aprendizaje combinado’ utilizando la abundante información sobre el desempeño de los estudiantes para orientar mejor el esfuerzo docente en el aula. Estos ‘grandes datos’ sobre el logro de los estudiantes también ofrecen un gran potencial propio. En particular, un entorno de este tipo podría permitir experimentos aleatorizados de alta frecuencia sobre técnicas y enfoques pedagógicos eficaces (que pueden variar entre estudiantes) y construir una base de evidencia más sólida sobre prácticas docentes eficaces. Esta evidencia podría luego utilizarse para optimizar aún más la impartición de la instrucción en el programa y, de manera plausible, también la de la instrucción en el aula. Por último, las medidas detalladas y continuas del esfuerzo de los estudiantes pueden utilizarse directamente para

recompensarlos, con ganancias potencialmente grandes en la motivación, el esfuerzo y el logro de los estudiantes.³⁸

Sin embargo, también hay varias razones para ser cautelosos al extrapolar el éxito del programa de manera más amplia. La intervención, tal como se evaluó en este artículo, se implementó a una escala modesta de unos pocos centros en Delhi y con alta fidelidad por parte de los proveedores. Esa fidelidad puede no ser posible al implementarla a escala. Otras cuestiones se relacionan con la modalidad de implementación. Solo hemos evaluado Mindspark en centros extraescolares, y es plausible que la eficacia del sistema varíe significativamente según se implemente dentro o fuera de la escuela; según sea complementario a la instrucción actual en el aula o reemplace tiempo de instrucción actual; y según se implemente sin supervisión, bajo la supervisión de los docentes actuales o bajo la supervisión de terceros (p. ej., el personal de los centros Mindspark). Identificar las modalidades de implementación más eficaces del programa a mayor escala es un área importante para la investigación futura.³⁹

Una advertencia adicional es que nuestros resultados no deben interpretarse como un respaldo a restar importancia al papel de los docentes en la educación. Por el contrario, dado que la impartición de la educación implica varias tareas no rutinarias que varían en función de cada estudiante y situación, y requiere una comunicación compleja y sensible al contexto, es más probable que la tecnología complemente a los docentes en lugar de sustituirlos (como muestran de manera más general Autor, Levy and Murnane (2003)). Así, podría ser posible mejorar la productividad de los docentes y de las escuelas usando la tecnología para realizar tareas rutinarias (como calificar) y tareas intensivas en análisis de datos (como identificar patrones en las respuestas de los estudiantes y proporcionarles retroalimentación e instrucción diferenciadas), y permitiendo que los docentes dediquen más tiempo a aspectos de la educación en los que pueden tener una ventaja comparativa - como apoyar estrategias de aprendizaje grupal que pueden ayudar a desarrollar habilidades sociales y otras habilidades no cognitivas que pueden tener retornos considerables en el mercado laboral (Cunha, Heckman and Schennach, 2010; Heckman and Kautz, 2012; Deming, 2017).

En conjunto, nuestro estudio debe considerarse un ensayo de eficacia que documenta que los programas de aprendizaje basados en tecnología, bien diseñados e implementados, pueden producir grandes ganancias en los puntajes de los estudiantes en un período relativamente corto.

³⁸Hirshleifer (2015) aporta evidencia directa de que esto puede ser posible: utiliza datos de una intervención (distinta) de instrucción asistida por computadora para recompensar el esfuerzo de los estudiantes y documenta grandes efectos de 0.57σ .

³⁹Un ejemplo útil de este tipo de trabajo es la literatura que siguió a la documentación, por parte de Banerjee et al. (2007), de la eficacia de voluntarios locales sin titulación, que orientaban la instrucción a los niveles de logro de los estudiantes, para elevar el logro en escuelas primarias de dos ciudades indias. Estudios posteriores han analizado la eficacia de este enfoque pedagógico de “Enseñanza en el Nivel Adecuado” en campamentos de verano, en escuelas públicas, e impartido alternativamente por docentes de las escuelas y por otros voluntarios (Banerjee et al., 2016). El enfoque se está ampliando actualmente a escala en múltiples sistemas educativos estaduales.

El potencial de este enfoque puede ser especialmente alto en contextos de países en desarrollo que presentan una gran heterogeneidad en los niveles de aprendizaje entre estudiantes matriculados en el mismo grado, y una instrucción por defecto basada en libros de texto y en el currículo que deja atrás a muchos estudiantes (como se observa en nuestros datos). Existe evidencia sólida en diversos contextos de que los enfoques pedagógicos que permiten la “Enseñanza en el Nivel Adecuado” (TaRL) son muy eficaces, pero ampliarlos a escala no es trivial. Nuestros resultados sugieren que el potencial de la tecnología para implementar TaRL y mejorar marcadamente la productividad en la impartición de la educación es real, y que puede haber grandes retornos a una mayor innovación e investigación sobre formas eficaces de integrar la instrucción asistida por tecnología en las aulas y sobre formas eficaces de llevar estos beneficios a una escala mayor.

Referencias

- Andrabi, Tahir, Jishnu Das, Asim I. Khwaja, and Tristan Zajonc.** 2011. “Do value-added estimates add value? Accounting for learning dynamics.” *American Economic Journal: Applied Economics*, 3(3): 29–54.
- Angrist, Joshua, and Guido Imbens.** 1995. “Two-stage least squares estimation of average causal effects in models with variable treatment intensity.” *Journal of the American Statistical Association*, 90(430): 431–442.
- Angrist, Joshua, and Victor Lavy.** 2002. “New evidence on classroom computers and pupil learning.” *The Economic Journal*, 112(482): 735–765.
- Angrist, Joshua, Peter Hull, Parag Pathak, and Christopher Walters.** 2016. “Leveraging lotteries for school value-added: Testing and estimation.” *The Quarterly Journal of Economics*, Forthcoming.
- Autor, David, Frank Levy, and Richard J. Murnane.** 2003. “The Skill Content of Recent Technological Change: An Empirical Exploration.” *The Quarterly Journal of Economics*, 118(4): 1279–1333.
- Banerjee, Abhijit, and Esther Duflo.** 2012. *Poor economics: A radical rethinking of the way to fight global poverty*. New York, NY: Public Affairs.
- Banerjee, Abhijit, Paul Glewwe, Shawn Powers, and Melanie Wasserman.** 2013. “Expanding access and increasing student learning in post-primary education in developing countries: A review of the evidence.” Abdul Latif Jameel Poverty Action Lab.
- Banerjee, Abhijit, Rukmini Banerji, James Berry, Esther Duflo, Harini Kannan, Shobhini Mukherji, Marc Shotland, and Michael Walton.** 2016. “Mainstreaming an Effective Intervention: Evidence from Randomized Evaluations of ‘Teaching at the Right Level’ in India.” National Bureau of Economic Research, Inc NBER Working Papers 22746.
- Banerjee, Abhijit V, Shawn Cole, Esther Duflo, and Leigh Linden.** 2007. “Remedying Education: Evidence from Two Randomized Experiments in India.” *The Quarterly Journal of Economics*, 122(3): 1235–1264.
- Barrera-Osorio, Felipe, and Leigh L Linden.** 2009. “The use and misuse of computers in education: evidence from a randomized experiment in Colombia.” (World Bank Policy Research Working Paper No. 4836.) Washington, DC: The World Bank.
- Barrow, Lisa, Lisa Markman, and Cecilia Elena Rouse.** 2009. “Technology’s edge: The educational benefits of computer-aided instruction.” *American Economic Journal: Economic Policy*, 1(1): 52–74.
- Berry, J., and P. Mukherjee.** 2016. “Pricing of private education in urban India: Demand, use and impact.” *Unpublished manuscript*. Ithaca, NY: Cornell University.
- Bertanha, Marinho, and Guido Imbens.** 2014. “External Validity in Fuzzy Regression Discontinuity Designs.” National Bureau of Economic Research, Inc 20773.

- Betts, Julian.** 2011. “The Economics of Tracking in Education.” In *Handbook of the Economics of Education*, ed. Eric Hanushek, Stephen Machin and Ludger Woessmann, 341–381. Elsevier.
- Beuermann, Diether W, Julian Cristia, Santiago Cueto, Ofer Malamud, and Yyannu Cruz-Aguayo.** 2015. “One Laptop per Child at home: Short-term impacts from a randomized experiment in Peru.” *American Economic Journal: Applied Economics*, 7(2): 53–80.
- Bhattacharjea, S., W. Wadhwa, and R. Banerji.** 2011. *Inside primary schools: A study of teaching and learning in rural India*. ASER Centre, New Delhi.
- Bold, Tessa, Deon P. Filmer, Gayle Martin, Ezequiel Molina, Christophe Rockmore, Brian William Stacy, Jakob Svensson, and Waly Wane.** 2017. “What do teachers know and do? Does it matter? Evidence from primary schools in Africa.” The World Bank Policy Research Working Paper Series 7956.
- Borman, G. D., J. G. Benson, and L. Overman.** 2009. “A randomized field trial of the Fast ForWord Language computer-based training program.” *Educational Evaluation and Policy Analysis*, 31(1): 82–106.
- Brinch, Christian, Magne Mogstad, and Matthew Wiswall.** 2017. “Beyond LATE with a Discrete Instrument.” *Journal of Political Economy*, 125(4): 985–1039.
- Bulman, G., and R.W. Fairlie.** 2016. “Technology and Education: Computers, Software and the Internet.” In *Handbook of the Economics of Education*, ed. Eric Hanushek, Stephen Machin and Ludger Woessmann, 239–280. Elsevier.
- Buswell, Guy Thomas, and Charles Hubbard Judd.** 1925. *Summary of educational investigations relating to arithmetic*. University of Chicago.
- Campuzano, L., M. Dynarski, R. Agodini, K. Rall, and A. Pendleton.** 2009. “Effectiveness of reading and mathematics software products: Findings from two student cohorts.” *Unpublished manuscript*. Washington, DC: Mathematica Policy Research.
- Carrillo, Paul E, Mercedes Onofa, and Juan Ponce.** 2010. “Information technology and student achievement: Evidence from a randomized experiment in Ecuador.” (IDB Working Paper No. IDB-WP-223). Washington, DC: Inter-American Development Bank.
- Chetty, Raj, John N Friedman, and Jonah E Rockoff.** 2014. “Measuring the impacts of teachers I: Evaluating bias in teacher value-added estimates.” *The American Economic Review*, 104(9): 2593–2632.
- Cohen, Jessica, and Pascaline Dupas.** 2010. “Free distribution or cost-sharing? Evidence from a randomized malaria prevention experiment.” *The Quarterly Journal of Economics*, 125(1): 1–45.
- Cristia, Julian, Pablo Ibarrarán, Santiago Cueto, Ana Santiago, and Eugenio Severín.** 2012. “Technology and child development: Evidence from the One Laptop per Child program.” (IDB Working Paper No. IDB-WP-304). Washington, DC: Inter-American Development Bank.

- Cunha, Flavio, James J. Heckman, and Susanne M. Schennach.** 2010. "Estimating the Technology of Cognitive and Noncognitive Skill Formation." *Econometrica*, 78(3): 883–931.
- Das, Jishnu, and Tristan Zajonc.** 2010. "India shining and Bharat drowning: Comparing two Indian states to the worldwide distribution in mathematics achievement." *Journal of Development Economics*, 92(2): 175–187.
- Deming, David J.** 2017. "The growing importance of social skills in the labor market." *The Quarterly Journal of Economics*, 132(4): 1593–1640.
- Deming, David J., Justine S. Hastings, Thomas J. Kane, and Douglas O. Staiger.** 2014. "School choice, school quality, and postsecondary attainment." *American Economic Review*, 104(3): 991–1013.
- Dewan, Hridaykant, Namrita Batra, and Inder Singh Chabra.** 2012. "Transforming the Elementary Mathematics Curriculum: Issues and Challenges." In *Mathematics Education in India: Status and Outlook.*, ed. R. Ramanujan and K. Subramaniam. Mumbai, India: Homi Bhabha Centre for Science Education, Tata Institute for Fundamental Research.
- Duflo, E., P. Dupas, and M. Kremer.** 2011. "Peer effects, teacher incentives, and the impact of tracking: Evidence from a randomized evaluation in Kenya." *American Economic Review*, 101: 1739–1774.
- Dynarski, M., R. Agodini, S. Heaviside, T. Novak, N. Carey, L. Campuzano, B. Means, R. Murphy, W. Penuel, H. Javitz, D. Emery, and W. Sussex.** 2007. "Effectiveness of reading and mathematics software products: Findings from the first student cohort." *Unpublished manuscript*. Washington, DC: Mathematica Policy Research.
- Fairlie, R. W., and J. Robinson.** 2013. "Experimental Evidence on the Effects of Home Computers on Academic Achievement among Schoolchildren." *American Economic Journal: Applied Economics*, 5(3): 211–240.
- Fujiwara, Thomas.** 2015. "Voting technology, political responsiveness, and infant health: Evidence from Brazil." *Econometrica*, 83(2): 423–464.
- Glewwe, Paul, and Karthik Muralidharan.** 2016. "Improving School Education Outcomes in Developing Countries: Evidence, Knowledge Gaps, and Policy Implications." In *Handbook of the Economics of Education.*, ed. Eric Hanushek, Stephen Machin and Ludger Woessmann, 653–744. Elsevier.
- Goolsbee, Austan, and Jonathan Guryan.** 2006. "The impact of Internet subsidies in public schools." *The Review of Economics and Statistics*, 88(2): 336–347.
- Heckman, James J., and Tim Kautz.** 2012. "The Economics of Human Development and Social Mobility." *Labour Economics*, 19(4): 451–464.
- Hirshleifer, Sarojini.** 2015. "Incentives for effort or outputs? A field experiment to improve student performance." *Unpublished manuscript*. Cambridge, MA: Abdul Latif Jameel Poverty Action Lab (J-PAL).


- Jack, W., and T. Suri.** 2014. "Risk sharing and transactions costs: Evidence from Kenya's mobile money revolution." *The American Economic Review*, 104(1): 183–223.
- Jacob, Brian A, Lars Lefgren, and David P Sims.** 2010. "The persistence of teacher-induced learning." *Journal of Human resources*, 45(4): 915–943.
- Kothari, Brij, Avinash Pandey, and Amita R Chudgar.** 2004. "Reading out of the "idiot box": Same-language subtitling on television in India." *Information Technologies & International Development*, 2(1): pp–23.
- Kothari, Brij, Joe Takeda, Ashok Joshi, and Avinash Pandey.** 2002. "Same language subtitling: a butterfly for literacy?" *International Journal of Lifelong Education*, 21(1): 55–66.
- Kumar, Ruchi S., Hridaykant Dewan, and K.Subramaniam.** 2012. "The preparation and professional development of mathematics teachers." In *Mathematics Education in India: Status and Outlook.*, ed. R. Ramanujan and K. Subramaniam. Mumbai, India:Homi Bhabha Centre for Science Education, Tata Institute for Fundamental Research.
- Lai, Fang, Linxiu Zhang, Qinghe Qu, Xiao Hu, Yaojiang Shi, Matthew Boswell, and Scott Rozelle.** 2012. "Does computer-assisted learning improve learning outcomes? Evidence from a randomized experiment in public schools in rural minority areas in Qinghai, China." (REAP Working Paper No. 237). Rural Education Action Program (REAP). Stanford, CA.
- Lai, Fang, Linxiu Zhang, Xiao Hu, Qinghe Qu, Yaojiang Shi, Yajie Qiao, Matthew Boswell, and Scott Rozelle.** 2013. "Computer assisted learning as extracurricular tutor? Evidence from a randomised experiment in rural boarding schools in Shaanxi." *Journal of Development Effectiveness*, 52(2): 208–231.
- Lai, Fang, Renfu Luo, Linxiu Zhang, and Scott Huang, Xinzhe Rozelle.** 2015. "Does computer-assisted learning improve learning outcomes? Evidence from a randomized experiment in migrant schools in Beijing." *Economics of Education*, 47: 34–48.
- Lee, David.** 2009. "Training, Wages, and Sample Selection: Estimating Sharp Bounds on Treatment Effects." *The Review of Economic Studies*, 76: 1071–1102.
- Leuven, Edwin, Mikael Lindahl, Hessel Oosterbeek, and Dinand Webbink.** 2007. "The effect of extra funding for disadvantaged pupils on achievement." *The Review of Economics and Statistics*, 89(4): 721–736.
- Linden, L. L.** 2008. "Complement or substitute? The effect of technology on student achievement in India." Unpublished manuscript. Abdul Latif Jameel Poverty Action Lab (J-PAL). Cambridge, MA.
- Machin, Stephen, Sandra McNally, and Olmo Silva.** 2007. "New technology in schools: Is there a payoff?" *The Economic Journal*, 117(522): 1145–1167.
- Malamud, Ofer, and C. Pop-Eleches.** 2011. "Home computer use and the development of human capital." *The Quarterly Journal of Economics*, 126: 987–1027.

- Mo, Di, Johan Swinnen, Linxiu Zhang, Hongmei Yi, Qinghe Qu, Matthew Boswell, and Scott Rozelle.** 2013. “Can one-to-one computing narrow the digital divide and the educational gap in China? The case of Beijing migrant schools.” *World Development*, 46: 14–29.
- Mo, Di, Linxiu Zhang, Renfu Luo, Qinghe Qu, Weiming Huang, Jiafu Wang, Yajie Qiao, Matthew Boswell, and Scott Rozelle.** 2014*a*. “Integrating computer-assisted learning into a regular curriculum: Evidence from a randomised experiment in rural schools in Shaanxi.” *Journal of Development Effectiveness*, 6: 300–323.
- Mo, Di, L. Zhang, J. Wang, W. Huang, Y. Shi, M. Boswell, and S. Rozelle.** 2014*b*. “The persistence of gains in learning from computer assisted learning (CAL): Evidence from a randomized experiment in rural schools in Shaanxi province in China.” *Unpublished manuscript*. Stanford, CA: Rural Education Action Program (REAP).
- Mo, Di, Yu Bai, Matthew Boswell, and Scott Rozelle.** 2016. “Evaluating the effectiveness of computers as tutors in China.”
- Morgan, P., and S. Ritter.** 2002. “An experimental study of the effects of Cognitive Tutor Algebra I on student knowledge and attitude.” Pittsburg, PA: Carnegie Learning.
- Muralidharan, Karthik.** 2012. “Long-term effects of teacher performance pay: Experimental evidence from India.” *Unpublished manuscript*. San Diego, CA: University of California, San Diego.
- Muralidharan, Karthik.** 2017. “Field Experiments in Education in Developing Countries.” In *Handbook of Field Experiments*, ed. Abhijit Banerjee and Esther Duflo. Elsevier.
- Muralidharan, Karthik, and Abhijeet Singh.** 2018. “Improving Public Sector Governance at Scale: Experimental Evidence from a Large-Scale School Governance Improvement Program in India.” University of California San Diego mimeo., San Diego, CA.
- Muralidharan, Karthik, and Venkatesh Sundararaman.** 2010. “The impact of diagnostic feedback to teachers on student learning: Experimental evidence from India.” *The Economic Journal*, 120(F187-F203).
- Muralidharan, Karthik, and Venkatesh Sundararaman.** 2015. “The aggregate effect of school choice: Evidence from a two-stage experiment in India.” *The Quarterly Journal of Economics*, 130(3): 1011–1066.
- Muralidharan, Karthik, Jishnu Das, Alaka Holla, and Aakash Mohpal.** 2017. “The fiscal cost of weak governance: Evidence from teacher absence in India.” *Journal of Public Economics*, 145: 116–135.
- Muralidharan, Karthik, Paul. Niehaus, and Sandip. Sukhtankar.** 2016. “Building state capacity: Evidence from biometric smartcards in India.” *American Economic Review*, 106(10): 2895–2929.
- Murphy, R., W. Penuel, B. Means, C. Korbak, and A. Whaley.** 2001. “E-DESK: A review of recent evidence on the effectiveness of discrete educational software.” *Unpublished manuscript*. Menlo Park, CA: SRI International.

- NCERT.** 2006. *Position Paper of the National Focus Group on Curriculum, Syllabus and Textbooks*. National Council of Educational Research and Training, New Delhi.
- PASEC.** 2015. *Programme d'Analyse des Systèmes Éducatifs de la Confemen (PASEC) 2014: Education System Performance in Francophone Africa, Competencies and Learning Factors in Primary Education*. PASEC, Dakar, Senegal.
- Pearson, P.D., R.E. Ferdig, R.L. Blomeyer Jr., and J. Moran.** 2005. "The effects of technology on reading performance in the middle-school grades: A meta-analysis with recommendations for policy." *Unpublished manuscript*. Naperville, IL: Learning Point Associates.
- Pratham.** 2016. *Annual Status of Education Report 2015*. Pratham, New Delhi.
- Pratham.** 2017. *Annual Status of Education Report 2016*. Pratham, New Delhi.
- Pritchett, Lant, and Amanda Beatty.** 2015. "Slow down, you're going too fast: Matching curricula to student skill levels." *International Journal of Educational Development*, 40: 276–288.
- Radatz, Hendrik.** 1979. "Error analysis in mathematics education." *Journal for Research in mathematics Education*, 163–172.
- Rampal, Anita, and Jayasree Subramaniam.** 2012. "Transforming the Elementary Mathematics Curriculum: Issues and Challenges." In *Mathematics Education in India: Status and Outlook*, ed. R. Ramanujan and K. Subramaniam. Mumbai, India: Homi Bhabha Centre for Science Education, Tata Institute for Fundamental Research.
- Rockoff, Jonah E.** 2015. "Evaluation report on the School of One i3 expansion." *Unpublished manuscript*. New York, NY: Columbia University.
- Rouse, Cecilia Elena, and Alan B Krueger.** 2004. "Putting computerized instruction to the test: A randomized evaluation of a "scientifically based" reading program." *Economics of Education Review*, 23(4): 323–338.
- SACMEQ.** 2007. *Southern and Eastern Africa Consortium for Monitoring Educational Quality (SACMEQ), Various years*. University of Botswana, Gaborone. <http://www.sacmeq.org/>.
- SAFED.** 2017. *Annual Status of Education Report (ASER-Pakistan) 2016*. South Asia Forum for Education Development, Lahore.
- Sankar, Deepa, and Toby Linden.** 2014. "How much and what kind of teaching is there in elementary education in India? Evidence from three states." (South Asia Human Development Sector Report No. 67). Washington, DC: The World Bank.
- Singh, Abhijeet.** 2015. "Private school effects in urban and rural India: Panel estimates at primary and secondary school ages." *Journal of Development Economics*, 113: 16–32.
- Sinha, S., R. Banerji, and W. Wadhwa.** 2016. *Teacher performance in Bihar, India: Implications for education*. The World Bank, Washington D.C.


- Uwezo.** 2016. *Are Our Children Learning? Uwezo Uganda 6th Learning Assessment Report*. Twaweza East Africa, Kampala.
- van der Linden, Wim J, and Ronald K Hambleton.** 2013. *Handbook of modern item response theory*. Springer Science & Business Media.
- Waxman, H.C., M.-F. Lin, and G.M. Michko.** 2003. “A meta-analysis of the effectiveness of teaching and learning with technology on student outcomes.” *Unpublished manuscript*. CambridgeNaperville, IL: Learning Point Associates.
- Wise, B. W., and R. K. Olson.** 1995. “Computer-based phonological awareness and reading instruction.” *Annals of Dyslexia*, 45: 99–122.
- World Bank.** 2016. *What is happening inside classrooms in Indian secondary schools? A time on task study in Madhya Pradesh and Tamil Nadu*. The World Bank, Washington D.C.
- World Bank.** 2018. *World Development Report 2018: Learning to Realize Education's Promise*. World Bank, Washington, DC.

Figura 1: Niveles evaluados de logro de los estudiantes vs. grado en el que están matriculados




Nota: Esta figura muestra, para el grupo de tratamiento, el nivel estimado de logro de los estudiantes (determinado por el programa CAL Mindspark) en función del grado en el que están matriculados. Estos datos provienen de la prueba diagnóstica *inicial* y no reflejan ninguna instrucción provista por Mindspark. En ambas materias, encontramos tres patrones principales: (a) existe un déficit general entre el logro promedio y las normas esperadas para el grado; (b) este déficit es mayor en los grados más avanzados y (c) dentro de cada grado, existe una amplia dispersión del logro de los estudiantes.

Figura 2: Diferencia de medias en los puntajes entre ganadores y perdedores del sorteo




Nota: Esta figura muestra la media de los puntajes, normalizados con referencia a la línea de base, en los grupos de tratamiento y de control en las dos rondas de evaluación, con intervalos de confianza del 95 %. Los puntajes se vincularon a nivel de cada materia mediante modelos IRT, agrupando grados y agrupando la línea de base y la línea final, y se normalizaron para tener una media de cero y un desvío estándar de uno en la línea de base. Mientras que los puntajes de la línea de base estaban balanceados entre ganadores y perdedores del sorteo, los puntajes de la línea final son significativamente más altos para el grupo de tratamiento.

Figura 3: Análisis no paramétrico de los efectos del tratamiento por percentiles de la línea de base




Nota: Las figuras presentan gráficos suavizados de medias locales ponderadas por kernel que relacionan los puntajes de la línea final con los percentiles del logro en la línea de base, por separado para los grupos de tratamiento y de control, junto con intervalos de confianza del 95 %. En todos los percentiles del logro en la línea de base, los estudiantes del grupo de tratamiento obtienen puntajes más altos en la prueba final que el grupo de control, sin evidencia sólida de magnitudes absolutas diferenciales de las ganancias a lo largo de la distribución.

Figura 4: Crecimiento del logro en los grupos de tratamiento y de control




Nota: Esta figura muestra el crecimiento del logro de los estudiantes en los grupos de tratamiento y de control en matemática y en hindi, como en la Tabla 5. Los estudiantes del grupo de tratamiento muestran un valor agregado positivo en todos los terciles, mientras que no podemos rechazar la hipótesis nula de ausencia de progreso académico para los estudiantes del tercil inferior del grupo de control.

Figura 5: Relación dosis-respuesta




Nota: Esta figura explora la relación entre el valor agregado y la asistencia al programa Mindspark entre los ganadores del sorteo. Presenta el valor agregado medio en intervalos de asistencia, junto con un ajuste lineal y un gráfico no paramétrico suavizado por lowess.

Figura 6: Personalización precisa de la instrucción por parte del programa CAL Mindspark



Nota: Esta figura muestra, para el grupo de tratamiento, el nivel de grado de las preguntas administradas por el sistema adaptativo computarizado a los estudiantes en un único día cercano al comienzo de la intervención. En cada grado de matriculación, el nivel real de logro de los estudiantes estimado por el software CAL varía ampliamente; este amplio rango se cubre mediante la personalización del contenido instruccional por parte del software CAL.

Figura 7: Actualización dinámica e individualización del contenido en Mindspark



Nota: Esta figura muestra líneas suavizadas de medias locales ponderadas por kernel que relacionan el nivel de dificultad de las preguntas de matemática administradas a los estudiantes del grupo de tratamiento con la fecha de administración. El panel izquierdo presenta líneas separadas según el grado real de matriculación. El panel derecho presenta líneas separadas según el nivel de logro evaluado en la línea de base por el software CAL. Cabe señalar que también se grafican los intervalos de confianza del 95 % pero, dado el gran volumen de datos a nuestra disposición, las estimaciones son muy precisas y los intervalos de confianza son lo suficientemente estrechos como para no ser visualmente discernibles.

Tabla 1: Estadísticas descriptivas de la muestra y balance en variables observables

	Media (tratamiento)	Media (control)	Diferencia	EE	N (tratamiento)	N (control)
<u>Panel A: Todos los estudiantes de la muestra de línea de base</u>						
<i>Características demográficas</i>						
Mujer	0.76	0.76	0.004	0.034	314	305
Edad (años)	12.67	12.41	0.267	0.143	230	231
Índice de NSE	-0.03	0.04	-0.070	0.137	314	305
<i>Grado escolar</i>						
Grado 4	0.01	0.01	-0.003	0.007	305	299
Grado 5	0.01	0.02	-0.007	0.010	305	299
Grado 6	0.27	0.30	-0.035	0.037	305	299
Grado 7	0.26	0.26	0.005	0.036	305	299
Grado 8	0.30	0.28	0.017	0.037	305	299
Grado 9	0.15	0.13	0.024	0.028	305	299
<i>Puntajes de línea de base</i>						
Matemática	-0.01	0.01	-0.016	0.081	313	304
Hindi	0.05	-0.05	0.096	0.080	312	305
Presente en la línea final	0.85	0.90	-0.048	0.027	314	305
<u>Panel B: Solo estudiantes presentes en la línea final</u>						
<i>Características demográficas</i>						
Mujer	0.77	0.76	0.013	0.036	266	273
Edad (años)	12.61	12.37	0.243	0.156	196	203
Índice de NSE	-0.17	0.03	-0.193	0.142	266	273
<i>Grado escolar</i>						
Grado 4	0.01	0.01	-0.003	0.008	258	269
Grado 5	0.01	0.02	-0.011	0.011	258	269
Grado 6	0.28	0.30	-0.022	0.040	258	269
Grado 7	0.26	0.26	-0.001	0.038	258	269
Grado 8	0.30	0.28	0.020	0.040	258	269
Grado 9	0.14	0.12	0.017	0.029	258	269
<i>Puntajes de línea de base</i>						
Matemática	-0.03	-0.00	-0.031	0.086	265	272
Hindi	0.05	-0.07	0.124	0.084	266	273

Nota: Tratamiento y control se refieren aquí a los grupos que fueron asignados aleatoriamente para recibir la oferta de un vale de Mindspark hasta marzo de 2016. Las variables utilizadas en esta tabla provienen del relevamiento de línea de base de septiembre de 2015. El relevamiento constó de dos partes: (a) una encuesta autoadministrada a los estudiantes, de la que se toman las características demográficas, y (b) una evaluación de habilidades en matemática y en hindi, administrada mediante pruebas de lápiz y papel. Las pruebas se diseñaron para cubrir amplios rangos de logro y para vincularse entre grados, así como entre las evaluaciones de línea de base y de línea final, mediante ítems comunes. Los puntajes se escalan aquí mediante modelos de teoría de respuesta al ítem y se estandarizan para tener una media de cero y un desvío estándar de uno en la línea de base. El índice de NSE es un índice de riqueza generado a partir del primer factor de un análisis de componentes principales compuesto por indicadores de tenencia de diversos bienes de consumo durables y servicios en el hogar.

Tabla 2: Efectos de intención de tratar (ITT) en un marco de regresión

	(1)	(2)	(3)	(4)
	Var. dep.: Puntajes IRT estandarizados (línea final)			
	Matemática	Hindi	Matemática	Hindi
Tratamiento	0.37 (0.064)	0.23 (0.062)	0.37 (0.064)	0.24 (0.071)
Puntaje de línea de base	0.58 (0.042)	0.71 (0.040)	0.57 (0.051)	0.68 (0.033)
Constante	0.33 (0.044)	0.17 (0.044)	0.32 (0.031)	0.17 (0.035)
Efectos fijos de estrato	S	S	N	N
Observaciones	535	537	535	537
R cuadrado	0.403	0.493	0.397	0.473

Nota: Errores estándar robustos entre paréntesis. Tratamiento es una variable binaria que indica la oferta, asignada aleatoriamente, de un vale de Mindspark hasta marzo de 2016. Las pruebas de matemática y de hindi se diseñaron para cubrir amplios rangos de logro y para vincularse entre grados, así como entre las evaluaciones de línea de base y de línea final, mediante ítems comunes. Los puntajes se escalan aquí mediante modelos de teoría de respuesta al ítem y se estandarizan para tener una media de cero y un desvío estándar de uno en la línea de base.

Tabla 3: Efecto del tratamiento según la competencia específica evaluada

(a) Matemática

	(1)	(2)	(3)	(4)	(5)	(6)	(7)
<i>Var. dep.:</i> Proporción de preguntas respondidas correctamente							
	Cálculo aritmético	Problemas verbales - cálculo	Interpretación de datos	Fracciones y decimales	Geometría y medición	Números	Reconocimiento de patrones
Tratamiento	0.078 (0.016)	0.072 (0.016)	0.042 (0.021)	0.071 (0.020)	0.15 (0.024)	0.15 (0.022)	0.11 (0.028)
Puntaje de matemática en línea de base	0.13 (0.0080)	0.11 (0.010)	0.082 (0.015)	0.093 (0.012)	0.052 (0.014)	0.068 (0.012)	0.099 (0.016)
Constante	0.66 (0.0079)	0.50 (0.0076)	0.38 (0.010)	0.33 (0.010)	0.39 (0.012)	0.45 (0.011)	0.36 (0.014)
Observaciones	537	537	537	537	537	537	537
R cuadrado	0.357	0.229	0.097	0.157	0.097	0.135	0.112

(b) Hindi

	(1)	(2)	(3)	(4)
<i>Var. dep.:</i> Proporción de preguntas respondidas correctamente				
	Completar oraciones	Recuperar información explícita	Realizar inferencias directas	Interpretar e integrar ideas e información
Tratamiento	0.046 (0.022)	0.045 (0.016)	0.065 (0.022)	0.053 (0.015)
Puntaje de hindi en línea de base	0.13 (0.017)	0.14 (0.0075)	0.15 (0.011)	0.067 (0.013)
Constante	0.72 (0.011)	0.59 (0.0078)	0.51 (0.011)	0.31 (0.0077)
Observaciones	539	539	539	539
R cuadrado	0.182	0.380	0.309	0.136

Nota: Errores estándar robustos entre paréntesis. Las tablas anteriores muestran el impacto del tratamiento sobre competencias específicas. La variable dependiente de cada regresión es la proporción de preguntas relacionadas con la competencia que un estudiante respondió correctamente. Todas las preguntas de las pruebas fueron ítems de opción múltiple con cuatro opciones. Los puntajes de línea de base son puntajes IRT en la materia correspondiente, provenientes de la evaluación de línea de base. Tratamiento es una variable binaria que indica la oferta, asignada aleatoriamente, de un vale de Mindspark hasta marzo de 2016. Todas las regresiones incluyen efectos fijos por estrato de aleatorización.

Tabla 4: Heterogeneidad del efecto del tratamiento según género, nivel socioeconómico y puntaje de línea de base

	(1)	(2)	(3)	(4)	(5)	(6)
<i>Var. dep.: Puntajes IRT estandarizados (línea final)</i>						
COVARIABLES	<u>Mujer</u>		<u>NSE</u>		<u>Puntaje de línea de base</u>	
	Matemática	Hindi	Matemática	Hindi	Matemática	Hindi
Tratamiento	0.47 (0.14)	0.27 (0.095)	0.38 (0.065)	0.26 (0.062)	0.37 (0.064)	0.24 (0.070)
Covariable	-0.050 (0.14)	0.21 (0.15)	-0.0028 (0.035)	0.099 (0.021)	0.53 (0.076)	0.70 (0.047)
Interacción	-0.13 (0.14)	-0.046 (0.12)	0.023 (0.050)	-0.0041 (0.041)	0.081 (0.087)	-0.047 (0.071)
Observaciones	535	537	535	537	535	537
R cuadrado	0.399	0.474	0.398	0.494	0.399	0.473

Nota: Errores estándar robustos entre paréntesis. Tratamiento es una variable binaria que indica la oferta, asignada aleatoriamente, de un vale de Mindspark hasta marzo de 2016. El índice de NSE y los puntajes se definen como en las Tablas 1 y 2, respectivamente. Todas las regresiones incluyen efectos fijos por estrato y controlan por los puntajes de línea de base en la materia.

Tabla 5: Heterogeneidad del efecto del tratamiento por terciles dentro de cada grado

	(1)	(2)
<i>Var. dep.: Puntajes IRT estandarizados (línea final)</i>		
VARIABLES	Matemática	Hindi
Tercil inferior	0.13 (0.098)	-0.072 (0.10)
Tercil medio	0.30 (0.073)	0.14 (0.068)
Tercil superior	0.53 (0.092)	0.46 (0.085)
Tratamiento	0.33 (0.12)	0.41 (0.12)
Tratamiento*Tercil medio	0.083 (0.16)	-0.30 (0.16)
Tratamiento*Tercil superior	0.068 (0.16)	-0.24 (0.15)
Puntaje de línea de base	0.44 (0.066)	0.58 (0.062)
Observaciones	535	537
R cuadrado	0.545	0.545

Nota: Errores estándar robustos entre paréntesis. Tratamiento es una variable binaria que indica la oferta, asignada aleatoriamente, de un vale de Mindspark hasta marzo de 2016. Los puntajes se escalan como en la Tabla 2.

Tabla 6: Efecto del tratamiento en ítems vinculados a niveles de grado

	(1)	(2)	(3)	(4)
VARIABLES	Var. dep.: Proporción de preguntas respondidas correctamente			
	Matemática		Hindi	
	En o por encima del nivel del grado	Por debajo del nivel del grado	En o por encima del nivel del grado	Por debajo del nivel del grado
Tratamiento	0.0089 (0.032)	0.081 (0.013)	0.063 (0.027)	0.050 (0.014)
Puntaje de línea de base en la materia	0.047 (0.022)	0.099 (0.0069)	0.13 (0.016)	0.13 (0.0068)
Constante	0.31 (0.022)	0.49 (0.0089)	0.45 (0.019)	0.58 (0.0100)
Observaciones	291	511	292	513
R cuadrado	0.029	0.346	0.250	0.399

Nota: Errores estándar robustos entre paréntesis. La tabla muestra el impacto del tratamiento (ganar un vale asignado aleatoriamente) sobre las preguntas por debajo o en/por encima del nivel del grado de cada estudiante. La variable dependiente es la proporción de preguntas que un estudiante respondió correctamente. Todas las preguntas de las pruebas fueron de opción múltiple con cuatro opciones. Nuestras evaluaciones de línea final, diseñadas para ser informativas en los niveles reales de logro de los estudiantes, no incluyeron muchos ítems de nivel de 8.^o grado o superior. Por lo tanto, los estudiantes de 8.^o y 9.^o grado no se incluyen en las regresiones sobre ítems en/por encima del nivel del grado. Los puntajes de línea de base son puntajes IRT en la materia correspondiente, provenientes de la evaluación de línea de base. Todas las regresiones incluyen efectos fijos por estrato de aleatorización.

Tabla 7: Efecto del tratamiento en los exámenes escolares

	(1)	(2)	(3)	(4)	(5)	(6)
VARIABLES	Var. dep.: Puntajes estandarizados					
	Hindi	Matemática	Ciencias	Ciencias sociales	Inglés	Agregado
Tratamiento	0.196 (0.088)	0.059 (0.076)	0.077 (0.092)	0.108 (0.110)	0.081 (0.105)	0.100 (0.080)
Puntaje de hindi en línea de base	0.487 (0.092)		0.292 (0.064)	0.414 (0.096)	0.305 (0.067)	0.336 (0.058)
Puntaje de matemática en línea de base		0.303 (0.041)	0.097 (0.036)	0.262 (0.058)	0.120 (0.052)	0.167 (0.039)
Constante	1.006 (1.103)	0.142 (0.423)	0.931 (0.347)	1.062 (0.724)	1.487 (0.740)	0.977 (0.600)
Observaciones	597	596	595	594	597	597
R cuadrado	0.190	0.073	0.121	0.177	0.144	0.210

Nota: Errores estándar robustos entre paréntesis. Esta tabla muestra el efecto de recibir el vale de Mindspark sobre los exámenes escolares finales, realizados en marzo de 2016, tras la finalización de la intervención. Tratamiento es una variable binaria que indica la oferta, asignada aleatoriamente, de un vale de Mindspark hasta marzo de 2016. Los puntajes de los exámenes escolares se normalizan dentro de cada escuela*grado para tener una media de cero y un desvío estándar de uno en el grupo de control. Todas las regresiones incluyen efectos fijos por grado y por escuela.

Tabla 8: Efectos heterogéneos en las pruebas escolares, por terciles de logro en la línea de base

	(1)	(2)	(3)	(4)	(5)	(6)
VARIABLES	Hindi	Matemática	Ciencias	Cs. sociales	Inglés	Agregado
Tratamiento	0.058 (0.14)	-0.40 (0.11)	-0.15 (0.16)	-0.17 (0.16)	0.14 (0.11)	-0.052 (0.099)
Tratamiento*Tercil 2	0.11 (0.23)	0.55 (0.20)	0.31 (0.18)	0.15 (0.24)	-0.30 (0.14)	0.063 (0.16)
Tratamiento*Tercil 3	0.29 (0.18)	0.82 (0.27)	0.36 (0.19)	0.65 (0.24)	0.14 (0.15)	0.38 (0.13)
Tercil 2	-0.35 (0.27)	-0.27 (0.23)	-0.39 (0.18)	-0.61 (0.29)	0.14 (0.17)	-0.29 (0.19)
Tercil 3	-0.23 (0.31)	-0.48 (0.21)	-0.32 (0.21)	-1.02 (0.38)	0.096 (0.20)	-0.37 (0.21)
Puntaje de hindi en línea de base	0.53 (0.17)		0.35 (0.083)	0.67 (0.19)	0.25 (0.11)	0.40 (0.10)
Puntaje de matemática en línea de base		0.33 (0.072)	0.096 (0.033)	0.27 (0.058)	0.11 (0.051)	0.16 (0.039)
Constante	1.28 (1.09)	0.47 (0.40)	1.27 (0.39)	1.76 (0.76)	1.29 (0.74)	1.24 (0.60)
Observaciones	597	596	595	594	597	597
R cuadrado	0.201	0.098	0.132	0.203	0.155	0.226
Efecto del tratamiento por tercil (valores p entre corchetes)						
Tercil 1	0.058 [0.67]	-0.40 [0.002]	-0.15 [0.36]	-0.17 [0.31]	0.14 [0.23]	-0.052 [0.61]
Tercil 2	0.17 [0.27]	0.15 [0.28]	0.16 [0.13]	-0.02 [0.94]	-0.16 [0.25]	0.01 [0.92]
Tercil 3	0.348 [0.04]	0.42 [0.07]	0.21 [0.16]	0.48 [0.04]	0.28 [0.08]	0.33 [0.03]

Nota: Errores estándar robustos entre paréntesis. Tratamiento es una variable binaria que indica la oferta, asignada aleatoriamente, de un vale de Mindspark hasta marzo de 2016. Los puntajes se escalan como en la Tabla 7.

Tabla 9: Dosis-respuesta de la asistencia a Mindspark

	(1)	(2)	(3)	(4)	(5)	(6)
	<i>Var. dep.</i> : Puntajes IRT estandarizados (línea final)					
VARIABLES	Estimaciones por IV		VA por MCO (muestra completa)		VA por MCO (grupo de tratamiento)	
	Matemática	Hindi	Matemática	Hindi	Matemática	Hindi
Asistencia (días)	0.0067 (0.0011)	0.0043 (0.0011)	0.0072 (0.00090)	0.0037 (0.00091)	0.0086 (0.0018)	0.0030 (0.0018)
Puntaje de línea de base	0.56 (0.038)	0.68 (0.036)	0.58 (0.042)	0.71 (0.040)	0.62 (0.061)	0.68 (0.052)
Constante			0.31 (0.041)	0.18 (0.041)	0.22 (0.12)	0.24 (0.11)
Observaciones	535	537	535	537	264	265
R cuadrado	0.431	0.479	0.429	0.495	0.446	0.445
Estadístico F de Angrist-Pischke de instrumento débil	1207	1244				
Estadístico Diff-in-Sargan de exogeneidad (valor p)	0.14	0.92				
Estimaciones extrapoladas para 90 días de tratamiento (DE)	0.603	0.39	0.648	0.333	0.77	0.27

Nota: Errores estándar robustos entre paréntesis. A los estudiantes del grupo de tratamiento que fueron seleccionados aleatoriamente para la oferta del vale de Mindspark pero que no aceptaron la oferta se les asignó una asistencia del 0%, al igual que a todos los estudiantes del grupo de control. Las columnas (1) y (2) instrumentan la asistencia a Mindspark con la asignación aleatoria de una beca e incluyen efectos fijos por estrato de aleatorización; las columnas (3) y (4) presentan modelos de valor agregado por MCO en la muestra completa; las columnas (5) y (6) presentan modelos de valor agregado por MCO usando solo datos de los ganadores del sorteo. Los puntajes se escalan aquí como en la Tabla 2.


Apéndice en línea

¿Transformando la educación? Evidencia experimental sobre instrucción asistida por tecnología en India

Karthik Muralidharan y Abhijeet Singh y Alejandro J. Ganimian


Apéndice A Figuras y tablas adicionales

Figura A.1: Comparación del logro previo al programa entre participantes y no participantes del estudio




Nota: Los paneles comparan los puntajes finales del año escolar 2014-15, es decir, el año académico previo al programa, entre participantes y no participantes del estudio. Los puntajes se estandarizaron dentro de cada celda escuela*grado. Los participantes del estudio están positivamente seleccionados en el RCT en comparación con sus pares, pero la magnitud de la selección es modesta y hay un soporte común casi completo entre ambos grupos en el logro académico previo al programa. Véase la Tabla A.1 para más detalles.

Figura A.2: Distribución de la participación efectiva entre los ganadores del sorteo




Nota: Esta figura muestra la distribución de la asistencia a los centros Mindspark entre los ganadores del sorteo. Durante el período del estudio, los centros Mindspark abrieron 86 días hábiles.

Figura A.3: Comparación entre la evaluación inicial de Mindspark del nivel de grado del logro estudiantil y los puntajes (independientes) de línea de base




Nota: Los dos paneles muestran los puntajes medios en matemática y en hindi, respectivamente, para cada nivel de grado según la evaluación del software CAL de Mindspark al inicio de la intervención (es decir, poco después de la línea de base inicial), para los estudiantes del grupo de tratamiento. Los puntajes promedio en nuestras evaluaciones, administradas de forma independiente, aumentan con los niveles de grado del logro evaluados por el CAL. Esto valida que ambas evaluaciones captan una variación similar y que las evaluaciones de Mindspark del nivel de grado son significativas. Solo un estudiante fue evaluado en el nivel de 1.º grado en matemática, y solo 10 estudiantes en el nivel de 2.º grado en hindi, las categorías más bajas de nuestra muestra en ambas materias. En consecuencia, los puntajes son muy ruidosos en estas categorías (y es probable que el error de medición en las evaluaciones del CAL también sea mayor).

Figura A.4: Distribución de las preguntas administradas por el sistema CAL de Mindspark




Nota: Los dos paneles muestran la distribución, por nivel de grado, de las preguntas administradas por el sistema CAL de Mindspark durante el tratamiento, tanto en matemática como en hindi. En matemática, los estudiantes recibieron muy pocas preguntas del nivel del grado en el que están matriculados; esto refleja el diagnóstico del sistema sobre sus niveles de aprendizaje reales. En hindi, en cambio, los estudiantes recibieron una parte considerable de la instrucción en competencias del grado, lo cual es coherente con que los déficits iniciales de logro en hindi eran sustancialmente menores que en matemática (véase la Figura 1).

Figura A.5: Composición de los grupos de instrucción grupal en los centros Mindspark



Nota: Los dos paneles muestran la composición de los grupos en los centros Mindspark, según el grado en el que están matriculados los estudiantes y según su nivel de logro en matemática, evaluado por el sistema CAL de Mindspark. Distinguimos a los estudiantes del grupo de tratamiento de los estudiantes que pagaban arancel, que no formaban parte del estudio pero sí de la instrucción en grupos pequeños de cada grupo. Si bien nuestro estudio se centra en estudiantes de los grados 6-9, los centros atienden a estudiantes de los grados 1-8. Los estudiantes eligen su grupo por conveniencia logística, por lo que hay una variación sustancial en niveles de grado y en logro dentro de cada grupo, con pocas posibilidades de agrupar por nivel de logro. Esto confirma que no habría sido posible personalizar la instrucción en el componente de instrucción en grupos pequeños a cargo de un instructor.

Figura A.6: Trayectorias de aprendizaje de estudiantes individuales del grupo de tratamiento



Nota: Cada línea de los paneles es un gráfico suavizado por media local del nivel de grado de las preguntas de matemática administradas por el sistema adaptativo, en función de los días en que el estudiante utilizó el software de matemática de Mindspark (asistencia). Los paneles se organizan según el grado de matriculación y el cuartil de asistencia a Mindspark dentro del grado.

Tabla A.1: Comparación de los resultados de exámenes previos al programa entre participantes y no participantes del estudio

	RCT	Fuera del estudio	Diferencia	EE	N(RCT)	N(fuera del estudio)
Matemática	0.13	-0.01	0.14	0.05	409	4067
Hindi	0.16	-0.02	0.17	0.05	409	4067
Ciencias	0.09	-0.01	0.10	0.05	409	4067
Ciencias sociales	0.13	-0.01	0.15	0.05	409	4067
Inglés	0.14	-0.01	0.15	0.05	409	4067

Nota: Esta tabla presenta los puntajes medios de participantes y no participantes del estudio, estandarizados dentro de cada escuela*grado, en el año escolar 2014-15. Los participantes están, en promedio, positivamente seleccionados en comparación con sus pares.

Tabla A.2: Efectos de intención de tratar (ITT) con puntajes normalizados dentro de cada grado

	(1)	(2)	(3)	(4)
	Var. dep.: puntajes IRT estandarizados (línea final)			
	Matemática	Hindi	Matemática	Hindi
Tratamiento	0.38 (0.068)	0.23 (0.066)	0.38 (0.069)	0.23 (0.071)
Puntaje de línea de base	0.59 (0.045)	0.72 (0.039)	0.58 (0.051)	0.70 (0.031)
Constante	0.33 (0.047)	0.20 (0.046)	0.33 (0.034)	0.19 (0.035)
Efectos fijos de estrato	S	S	N	N
Observaciones	523	525	523	525
R cuadrado	0.384	0.480	0.380	0.470

Nota: Errores estándar robustos entre paréntesis. Tratamiento es una variable binaria que indica una oferta asignada aleatoriamente de un vale de Mindspark. El índice de NSE es un índice de riqueza construido con el primer factor de un análisis de componentes principales basado en indicadores de tenencia de diversos bienes durables y servicios en el hogar. Las pruebas de matemática y de hindi se diseñaron para cubrir amplios rangos de habilidad y para vincularse entre grados, así como entre las evaluaciones de línea de base y de línea final, mediante ítems comunes. Aquí los puntajes se escalan con modelos de teoría de respuesta al ítem y se estandarizan para tener media cero y desvío estándar uno en la línea de base de cada grado.

Tabla A.3: Efectos heterogéneos en las pruebas independientes, por terciles de logro en la línea de base

VARIABLES	(1)	(2)	(3)	(4)
	Var. dep.: proporción de respuestas correctas			
	Matemática		Hindi	
	En el nivel del grado o más	Por debajo del grado	En el nivel del grado o más	Por debajo del grado
Tratamiento	-0.030 (0.054)	0.059 (0.020)	0.095 (0.043)	0.10 (0.026)
Tratamiento*Tercil 2	0.036 (0.073)	0.056 (0.029)	-0.053 (0.065)	-0.071 (0.037)
Tratamiento*Tercil 3	0.13 (0.080)	0.023 (0.032)	-0.044 (0.062)	-0.079 (0.033)
Tercil 1	0.24 (0.045)	0.45 (0.017)	0.39 (0.041)	0.49 (0.022)
Tercil 2	0.26 (0.037)	0.46 (0.015)	0.38 (0.030)	0.58 (0.018)
Tercil 3	0.39 (0.042)	0.54 (0.018)	0.55 (0.037)	0.67 (0.019)
Puntaje de la materia en línea de base	-0.015 (0.032)	0.069 (0.010)	0.087 (0.023)	0.084 (0.011)
Observaciones	291	511	292	513
R cuadrado	0.096	0.371	0.301	0.433
Efecto total del tratamiento por tercil (valores p entre corchetes)				
Tercil 1	-0.030 [0.58]	0.059 [0.00]	0.095 [0.03]	0.10 [0.00]
Tercil 2	0.006 [0.91]	0.115 [0.00]	0.042 [0.38]	0.029 [0.24]
Tercil 3	0.10 [0.08]	0.082 [0.00]	0.051 [0.25]	0.021 [0.26]

Nota: Errores estándar robustos entre paréntesis. Tratamiento es una variable binaria que indica una oferta asignada aleatoriamente de un vale de Mindspark. El efecto total del tratamiento por tercil es la suma del coeficiente de tratamiento y de la interacción del tercil correspondiente con el tratamiento. Debajo del efecto agregado del tratamiento en cada tercil, reportamos entre corchetes los valores p de una prueba F de la hipótesis de que esta suma de ambos coeficientes es cero. La variable dependiente y los puntajes de línea de base se escalan como en la Tabla 6

Tabla A.4: Correlatos de la asistencia

VARIABLES	(1)	(2)	(3)	(4)
	Asistencia (días)			
Mujer	3.90 (3.90)	2.65 (3.92)	3.03 (3.88)	4.06 (3.88)
Índice de NSE	-3.33 (1.03)	-3.53 (1.05)	-3.47 (1.05)	-3.21 (1.05)
Clases particulares de matemática			-1.83 (4.43)	0.88 (4.55)
Clases particulares de hindi			7.10 (4.40)	5.13 (4.53)
Puntaje de matemática en línea de base		-0.99 (2.17)	-0.88 (2.24)	-0.81 (2.24)
Puntaje de hindi en línea de base		3.35 (2.12)	3.83 (2.15)	5.39 (2.14)
Constante	46.6 (3.40)	47.5 (3.42)	45.3 (3.79)	43.7 (3.78)
Efectos fijos de grado	N	N	N	S
Observaciones	313	310	310	301
R cuadrado	0.038	0.046	0.056	0.120

Nota: Errores estándar robustos entre paréntesis. Esta tabla muestra los correlatos de los días de asistencia en el grupo de tratamiento, es decir, los ganadores del sorteo a quienes se les había ofrecido un vale de Mindspark. Los estudiantes de contextos más pobres, y los estudiantes con mayor logro en hindi en la línea de base, parecen tener mayor asistencia, pero las magnitudes implícitas de estas correlaciones son pequeñas. Un aumento de un desvío estándar en el índice de NSE se asocia con una caída de la asistencia de alrededor de 3 días, y un aumento de un desvío estándar en los puntajes de hindi en la línea de base se asocia con 5 días adicionales de asistencia. No encontramos evidencia de diferencias en la asistencia por género ni por puntaje de matemática en la línea de base.

Tabla A.5: Relación dosis-respuesta cuadrática

	(1)	(2)	(3)	(4)
	Muestra completa	Hindi	Grupo de tratamiento	
	Matemática	Hindi	Matemática	Hindi
Asistencia (días)	0.0052 (0.0054)	0.0079 (0.0053)	0.0097 (0.0072)	0.0070 (0.0073)
Asistencia al cuadrado	0.000028 (0.000073)	-0.000058 (0.000072)	-0.000014 (0.000083)	-0.000048 (0.000085)
Puntaje de la materia en línea de base	0.58 (0.042)	0.71 (0.040)	0.62 (0.061)	0.68 (0.052)
Constante	0.31 (0.042)	0.18 (0.042)	0.20 (0.14)	0.19 (0.14)
Observaciones	535	537	264	265
R cuadrado	0.429	0.496	0.446	0.446

Nota: Errores estándar robustos entre paréntesis. Esta tabla modela en forma cuadrática la relación dosis-respuesta entre la asistencia a Mindspark y el valor agregado. Los resultados se estiman por MCO en la muestra completa y solo en el grupo de tratamiento.

Tabla A.6: Dosis-respuesta de la asistencia a Mindspark por materia

	(1)	(2)	(3)	(4)	(5)	(6)
	<u>Var. dep.: puntajes IRT estandarizados (línea final)</u>					
VARIABLES	Estimaciones por IV Matemática	Hindi	VA por MCO (muestra completa) Matemática	Hindi	VA por MCO (grupo de tratamiento) Matemática	Hindi
Días de instrucción en matemática	0.018 (0.0029)		0.019 (0.0024)		0.022 (0.0047)	
Días de instrucción en hindi		0.012 (0.0031)		0.011 (0.0026)		0.0084 (0.0050)
Puntaje de línea de base	0.56 (0.038)	0.68 (0.036)	0.58 (0.041)	0.71 (0.039)	0.61 (0.060)	0.68 (0.052)
Constante			0.31 (0.041)	0.18 (0.041)	0.22 (0.11)	0.24 (0.11)
Observaciones	535	537	535	537	264	265
R cuadrado	0.432 19	0.478 19	0.428	0.495	0.445	0.446
Estadístico F de Angrist-Pischke para instrumento débil	1211	1093				
Estadístico Diff-in-Sargan de exogeneidad (valor p)	0.12	0.80				
Estimaciones extrapoladas de 45 días de tratamiento (DE)	0.81	0.54	0.855	0.495	0.99	0.378

Nota: Errores estándar robustos entre paréntesis. A los estudiantes del grupo de tratamiento que fueron seleccionados aleatoriamente para la oferta del vale de Mindspark pero que no la aceptaron se les asignó una asistencia de 0%, al igual que a todos los estudiantes del grupo de control. Los días de asistencia en matemática/hindi se definen como el número de sesiones de CAL o de instrucción en grupos pequeños a las que se asistió en esa materia, dividido por dos. Las columnas (1) y (2) presentan regresiones por IV que instrumentan la asistencia con la asignación aleatoria de un vale e incluyen efectos fijos de estrato de aleatorización; las columnas (3) y (4) presentan modelos de valor agregado estimados por MCO para la muestra completa, y las columnas (5) y (6) presentan modelos de valor agregado estimados por MCO usando solo datos de los ganadores del sorteo. Aquí los puntajes se escalan como en la Tabla 2.

Tabla A.7: Estimaciones ITT con ponderación por probabilidad inversa

	(1)	(2)	(3)	(4)
	Var. dep.: puntajes IRT estandarizados (línea final)			
	Matemática	Hindi	Matemática	Hindi
Tratamiento	0.37 (0.063)	0.23 (0.062)	0.38 (0.062)	0.24 (0.061)
Puntaje de línea de base	0.59 (0.041)	0.71 (0.040)	0.57 (0.038)	0.68 (0.037)
Constante	0.32 (0.044)	0.18 (0.044)	0.32 (0.043)	0.17 (0.042)
Efectos fijos de estrato	N	N	S	S
Observaciones	535	535	535	535
R cuadrado	0.405	0.487	0.454	0.535

Nota: Errores estándar robustos entre paréntesis. *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$ Tratamiento es una variable binaria que indica una oferta asignada aleatoriamente de un vale de Mindspark. Los resultados de esta tabla están ponderados por la inversa de la probabilidad predicha de tener puntajes tanto en matemática como en hindi en la línea final; la probabilidad se predice con un modelo probit que usa como predictores los puntajes por materia en la línea de base, el sexo del niño, el índice de NSE y variables binarias para cada centro Mindspark. Las pruebas de matemática y de hindi se diseñaron para cubrir amplios rangos de habilidad y para vincularse entre grados, así como entre las evaluaciones de línea de base y de línea final, mediante ítems comunes. Los puntajes se escalan aquí como en la Tabla 2.

Tabla A.8: Estimaciones de cotas de Lee de los efectos ITT

	(1)	(2)
	Matemática	Hindi
Inferior	0.309 (0.092)	0.183 (0.102)
Superior	0.447 (0.085)	0.294 (0.082)
IC 95 % inferior	0.157	0.012
IC 95 % superior	0.587	0.43

Nota: Errores estándar analíticos entre paréntesis. Esta tabla presenta las cotas de Lee(2009) de los efectos ITT de ganar un vale tanto en matemática como en hindi. Usamos como variable dependiente los residuos de una regresión de los puntajes de la línea final sobre los puntajes de la línea de base (valor agregado), y escalamos los puntajes como en la Tabla 2, para que nuestro análisis de cotas sea análogo a los principales efectos ITT. Las cotas se ajustan usando variables binarias para los centros Mindspark.

Tabla A.9: Estimaciones ITT, según la fuente del ítem de prueba

VARIABLES	(1)	(2)	(3)	(4)
	Matemática Ítems EI	Ítems no EI	Hindi Ítems EI	Ítems no EI
Tratamiento	0.11 (0.013)	0.075 (0.011)	0.055 (0.017)	0.044 (0.011)
Puntaje de línea de base	0.092 (0.011)	0.096 (0.0084)	0.14 (0.0093)	0.12 (0.0052)
Constante	0.46 (0.0064)	0.47 (0.0055)	0.61 (0.0082)	0.48 (0.0056)
Observaciones	537	537	539	539
R cuadrado	0.226	0.358	0.308	0.416

Nota: Errores estándar robustos entre paréntesis. Tratamiento es una variable binaria que indica una oferta asignada aleatoriamente de un vale de Mindspark. Las pruebas de matemática y de hindi se armaron con ítems de distintas evaluaciones internacionales e indias, algunas de las cuales fueron desarrolladas por EI. Entre las evaluaciones desarrolladas por EI figuran el Student Learning Survey, el Quality Education Study y los Andhra Pradesh Randomized Studies in Education. Las variables dependientes se definen como la proporción de respuestas correctas en los ítems tomados de evaluaciones desarrolladas por EI y en los demás ítems no EI. Todas las preguntas de las pruebas fueron ítems de opción múltiple con cuatro opciones. Los puntajes de la línea de base son puntajes IRT normalizados para tener media cero y desvío estándar uno.

Tabla A.10: Efecto del tratamiento sobre la adopción de otras clases particulares privadas

VARIABLES	(1) Matemática	(2) Hindi	(3) Inglés	(4) Ciencias	(5) Ciencias sociales
Post sept-2015	0.019 (0.011)	0.018 (0.0096)	0.026 (0.0098)	0.018 (0.0080)	0.014 (0.0071)
Post * Tratamiento	0.013 (0.016)	-0.010 (0.012)	-0.0039 (0.013)	0.0017 (0.012)	-0.0056 (0.0086)
Constante	0.21 (0.0053)	0.13 (0.0040)	0.18 (0.0044)	0.14 (0.0041)	0.098 (0.0029)
Observaciones	3,735	3,735	3,735	3,735	3,735
R cuadrado	0.009	0.004	0.010	0.007	0.005
Número de estudiantes	415	415	415	415	415

Nota: Errores estándar robustos entre paréntesis. *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$. Esta tabla muestra estimaciones con efectos fijos individuales del efecto de recibir el vale de Mindspark sobre la adopción de otras clases particulares privadas en distintas materias. La variable dependiente indica si un niño asistía a clases particulares adicionales de esa materia en un mes dado entre julio de 2015 y marzo de 2016. Estos datos se recolectaron mediante entrevistas telefónicas con los padres de los estudiantes del estudio. Las observaciones son a nivel de mes*niño. Tratamiento es una variable binaria que indica una oferta asignada aleatoriamente de un vale de Mindspark.

Apéndice B Heterogeneidad en el aula y desajuste curricular

Como se discutió en las secciones 4.1 y 5.1, conjeturamos que una razón importante de los grandes efectos que encontramos es que el software de CAL logró adaptarse a la gran heterogeneidad en los niveles de aprendizaje de los estudiantes dentro de un mismo grado, al personalizar la instrucción y enseñar “en el nivel adecuado” a todos los estudiantes. En este apéndice, (a) presentamos evidencia de que los patrones de la Figura 1 (una gran proporción de estudiantes por debajo de los estándares del grado y una amplia variación en la preparación académica de los estudiantes matriculados en un mismo grado) también están presentes en otros contextos de países en desarrollo, y (b) analizamos evidencia cualitativa sobre la práctica pedagógica para mostrar que la práctica de enseñanza predeterminada en estos contextos es enseñar según el currículo y el libro de texto, que probablemente esté por encima de los niveles de aprendizaje de la mayoría de los estudiantes.

B.1 Comparación de la distribución del logro en nuestra muestra de estudio con otras muestras


Como se mencionó en la sección 4.1, una ventaja importante de los datos de CAL es que permiten caracterizar la media y la varianza de la preparación de los estudiantes respecto del grado, para producir la descripción de la Figura 1. Sin embargo, una limitación de los datos de la Figura 1 es que provienen de una muestra autoseleccionada de alrededor de 300 estudiantes en Delhi (aunque estos estudiantes son bastante similares a los demás estudiantes de su escuela, como se ve en la Figura A.1). A continuación mostramos que estos patrones se replican en conjuntos de datos mucho más grandes y representativos sobre el aprendizaje de los estudiantes en la India.

B.1.1 Rajasthan

En septiembre de 2017, con posterioridad a nuestro estudio, Educational Initiatives firmó un acuerdo con el Gobierno del estado indio de Rajasthan para introducir el software Mindspark en 40 escuelas públicas del estado. Esta implementación abarcó zonas urbanas y rurales de 4 distritos (Churu, Jhunjunun, Udaipur y Dungarpur) que se extienden entre los extremos norte y sur del estado de Rajasthan, y cubrió a 3276 estudiantes de los grados 6-8. Se realizó con todos estos estudiantes un ejercicio diagnóstico similar al que sustentó la Figura 1, y los datos se presentan en la Figura B.1.

Los patrones observados en la Figura 1 se replican por completo en esta muestra más grande y más representativa (aquí no hubo autoselección de estudiantes) de otro estado. Al igual que en la muestra del RCT de Delhi, observamos grandes déficits absolutos respecto de los

Figura B.1: Nivel de logro evaluado vs. grado de matriculación en 40 escuelas públicas de Rajasthan



estándares curriculares (que crecen en los grados superiores) y una amplia dispersión dentro de cada grado. En matemática, el estudiante promedio de 6.^o grado está 2.9 niveles de grado por debajo de los estándares curriculares (frente a 2.5 niveles de grado por debajo en Delhi), cifra que sube a casi 4 niveles de grado por debajo en 8.^o grado (similar a la muestra de Delhi). En hindi, el déficit medio de logro respecto de los estándares curriculares es de 1.5 niveles de grado en 6.^o grado, y sube a 2 niveles de grado en 8.^o grado.⁴⁰ Así, los patrones de los datos de Rajasthan son casi idénticos a los de Delhi.

Como los datos de Rajasthan abarcan a todos los estudiantes de las clases, también podemos examinar directamente la heterogeneidad dentro del aula en los niveles de aprendizaje (que no podemos observar en Delhi porque la muestra allí solo incluye a los estudiantes que se inscribieron en el programa extraescolar Mindspark). Con datos de 116 aulas de escuela media distintas en 40 escuelas, observamos que el aula mediana de estas escuelas tiene un rango de alrededor de 4 niveles de grado de logro tanto en matemática como en lengua. En línea con los

⁴⁰En 2017, Educational Initiatives modificó la prueba diagnóstica de modo que el grado máximo que se le asignara a un estudiante fuera el grado en el que está matriculado. Así, aunque los estudiantes podían avanzar a niveles por encima de los estándares curriculares de forma dinámica a través del sistema, no podían empezar por encima del nivel de su grado. Esto subestimaría la dispersión del logro en la muestra de Rajasthan respecto de la muestra de Delhi en hindi (esto no es un problema en matemática, ya que casi ningún estudiante está por encima del nivel de su grado en matemática en Delhi).

Tabla B.1: Heterogeneidad dentro del aula en 40 escuelas de Rajasthan

Grado		Matemática		Hindi	
		Rango	p90 - p10	Rango	p90 - p10
6	Media	3.2	2.2	3.5	2.8
	Mediana	3	2	4	3
	Máximo	5	4	5	4
	N	40	40	40	40
7	Media	4.1	3	3.9	3
	Mediana	4	3	4	3
	Máximo	6	5	5	4
	N	40	40	40	40
8	Media	4.2	3	4.2	3.3
	Mediana	5	3	4.5	3.5
	Máximo	6	5	6	5
	N	36	36	36	36
Total	Media	3.8	2.7	3.8	3
	Mediana	4	3	4	3
	Máximo	6	5	6	5
	N	116	116	116	116

datos de Delhi, la dispersión es mayor en los grados superiores y, como máximo, observamos una dispersión de hasta 6 niveles de grado en el logro (Tabla B.1).

Los datos de Rajasthan también nos permiten descomponer la variación dentro del grado de la Figura B.1 en variación entre aulas y dentro de las aulas. En concreto, encontramos que los efectos fijos de aula explican el 31 % (19 %) de la variación en los puntajes de 6.^o grado en matemática (hindi), el 24 % (15 %) de la variación en los puntajes de 7.^o grado en matemática (hindi) y el 19 % (7 %) de la variación en los puntajes de 8.^o grado en matemática (hindi). Así, la gran mayoría de la dispersión en los niveles de aprendizaje dentro de un mismo grado que se observa en la Figura Tabla B.1 se da *dentro* de las aulas y no entre ellas, lo que subraya el desafío que enfrentan los docentes para atender eficazmente esa variación.


B.1.2 Madhya Pradesh

Si bien los datos del sistema de CAL Mindspark en escuelas públicas de Rajasthan ofrecen la comparación más directa con la muestra de Delhi, es posible hacer una comparación alternativa con nuestras evaluaciones independientes. En un estudio separado y contemporáneo en el estado indio de Madhya Pradesh (MP) sobre el impacto de una reforma de la gestión escolar (Muralidharan and Singh, 2018), administramos un subconjunto común de ítems de las evaluaciones de línea final de Mindspark. La muestra de MP está compuesta por 2760 estudiantes de los grados 6-8 (presentes el día de la evaluación) en una muestra representativa de escuelas medias públicas de 5 distritos de Madhya Pradesh (MP).⁴¹ Tanto la evaluación

⁴¹Madhya Pradesh es el quinto estado más poblado de la India, con más de 75 millones de habitantes según el Censo de 2011. El sistema educativo del estado comprende más de 112,000 escuelas.

de Delhi como la de MP se administraron en febrero de 2016. En la Figura B.2 presentamos la distribución del logro en la muestra de Madhya Pradesh junto con el grupo de control del RCT de Mindspark en Delhi, solo en los ítems comunes a ambos estudios; los puntajes se normalizaron para tener media cero y DE uno en el grupo de control del RCT de Mindspark en Delhi. Los principales resultados son que (a) los niveles medios de aprendizaje en MP están alrededor de 0.45 desvíos estándar por debajo de los de la muestra de Delhi, y (b) el desvío estándar de los niveles de aprendizaje de los estudiantes es alrededor de un 25 % mayor que en la muestra de Delhi. Así, los dos hechos clave de la Figura 1 (de la muestra) de Delhi, (a) bajos niveles de aprendizaje y (b) alta variación dentro de un grado, se replican en los datos de MP y parecen ser incluso más pronunciados.

Figura B.2: Distribución del logro en el grupo de control del RCT de Mindspark vs. una muestra representativa de escuelas de Madhya Pradesh



B.1.3 Otros países y estados de la India

Replicar los patrones de la Figura 1 en otros contextos plantea dos desafíos. Primero, la mayoría de los conjuntos de datos de alta calidad sobre educación en países en desarrollo provienen de escuelas primarias, mientras que este artículo se centra en los grados de la posprimaria. Segundo, aunque otros conjuntos de datos pueden permitir documentar la existencia de varianza en los niveles de aprendizaje, las medidas de aprendizaje no suelen

Tabla B.2: Estándares de aprendizaje en 5.º grado en la India y otros países seleccionados

Estado/País	% de niños que no pueden leer un texto de nivel de 2.º grado	% de niños que no pueden resolver una división con divisor de un dígito	Estado/País	% de niños que no pueden leer un texto de nivel de 2.º grado	% de niños que no pueden resolver una división con divisor de un dígito
Andhra Pradesh	55.1	37.2	Odisha	51.6	26.6
Arunachal Pradesh	25.5	19.0	Punjab	69.2	47.9
Assam	38.0	13.6	Rajasthan	54.2	28.2
Bihar	42.0	32.6	Tamil Nadu	45.2	21.4
Chattisgarh	55.9	23.0	Telangana	47.1	30.4
Gujarat	53.0	16.1	Tripura	51.0	19.9
Haryana	68.3	48.9	Uttar Pradesh	43.2	22.6
Himachal Pradesh	70.5	53.7	Uttarakhand	63.7	37.0
Jharkhand	36.4	23.5	Bengala Occidental	50.2	29.0
Karnataka	42.1	19.7	Toda la India (rural)	47.8	25.9
Kerala	69.2	38.6	Pakistán (rural)	52.1	48.4
Madhya Pradesh	38.7	19.4	Baluchistán	41.7	39.9
Maharashtra	62.5	20.3	Punjab	65.0	59.6
Manipur	70.7	52.5	Sindh	36.6	24.3
Meghalaya	47.9	10.7	Uganda	40.1	60.8
Mizoram	46.0	27.7			
Nagaland	50.1	21.2			

Fuentes: Los datos de los estados de la India provienen de Pratham (2016); los de Pakistán, de SAFED (2017), y los de Uganda, de Uwezo (2016).

estar vinculadas a los estándares del grado, lo que dificulta cuantificar en equivalentes de grado las brechas de aprendizaje y su variación (como hacemos más arriba). Por eso nos concentramos en destacar una estadística clave sobre el aprendizaje en países en desarrollo: la proporción de estudiantes al final de la escuela primaria (quinto o sexto grado) que no pueden leer al nivel de segundo grado. La principal ventaja de esta estadística es que está disponible en muestras representativas de varios contextos, y además es una medida significativa del fenómeno que nos interesa – las brechas de aprendizaje (indica un mínimo de tres años de brecha) y la variación (ya que estos estudiantes estarán al menos tres años por detrás de los compañeros que están en los estándares curriculares). La Tabla B.2 presenta esta cifra para varios estados de la India y otros países.

Cabe señalar que los estudiantes de Rajasthan tienen un desempeño levemente mejor que el promedio nacional de la India rural, y que varios estados grandes (como Bihar, Madhya Pradesh y Uttar Pradesh) obtienen resultados sustancialmente más bajos, lo que indica que los desafíos ilustrados en la Figura B.1 probablemente sean aún más graves en esos contextos. También se observan patrones similares en otros dos países (Pakistán, con los principales estados por separado, y Uganda) en los que el grado evaluado, la tarea evaluada y la forma de reporte son comparables con las pruebas ASER de la India.

Tabla B.3: Heterogeneidad en el logro de estudiantes de 6.º grado en 24 países africanos

País	Matemática			Lectura		
	No competente	Competencia baja	Competencia alta	No competente	Competencia baja	Competencia alta
Todos los países PASEC	57.6	24.7	17.7	61.6	25.1	13.3
Todos los países SACMEQ	36.8	18.4	44.8	63	20.2	16.8
Benín	48.3	29	22.7	60.2	29	10.8
Botsuana	24.2	19.2	56.6	56.5	27.2	16.4
Burkina Faso	43.1	35.5	21.4	41.1	36.9	21.9
Burundi	43.5	49.1	7.4	13.2	46.8	39.9
Camerún	51.2	24.7	24.1	64.6	23.7	11.8
Chad	84.3	12.8	3	80.9	16.1	3
Rep. del Congo	59.3	23.5	17.1	71	23.1	5.9
Costa de Marfil	52	25.6	22.4	73.1	23.7	3.1
Kenia	19.8	19.6	60.6	38.3	32.1	29.6
Lesoto	52.5	25.5	22	81.1	13.6	5.3
Malawi	73.3	19.9	6.9	91.6	6.6	1.8
Mauricio	21.1	12.1	66.8	26.7	17.9	55.3
Mozambique	43.5	25	31.5	74.1	20.9	5
Namibia	38.7	25.5	35.8	81.7	12.2	6.1
Níger	91.5	6.4	2.1	92.4	6.3	1.4
Senegal	38.8	26.3	34.8	41.2	29.7	29.1
Seychelles	21.9	10.3	67.8	42.3	26.4	31.3
Sudáfrica	48.3	14.7	37	69.2	15.4	15.5
Suazilandia	7	20.7	72.2	44.3	37	18.7
Tanzania	10.1	12	77.9	43	25.5	31.5
Togo	61.6	22.6	15.8	52.5	27.9	19.7
Uganda	45.9	23.7	30.5	74.9	18	7.1
Zambia	72.6	14.9	12.4	91.8	6.5	1.7
Zimbabue	37.2	20.7	42.1	57.2	22.6	20.2

Fuentes: Esta tabla se basa en cifras presentadas en World Bank (2018), a partir de datos originales de SACMEQ (2007) , PASEC (2015) y los Indicadores del Desarrollo Mundial.

El patrón de grandes déficits de aprendizaje, con una heterogeneidad significativa dentro de un mismo grado, es mucho más general. La Tabla B.3 presenta datos del Informe sobre el Desarrollo Mundial 2018 (World Bank, 2018), que consolida datos de 24 países subsaharianos, provenientes de tres evaluaciones distintas, para clasificar a los estudiantes de 6.^o grado según su nivel de competencia en lectura y matemática. En la mayoría de los países, una proporción sustancial de los estudiantes se clasifica como “no competente” en matemática.⁴² Sin embargo, hay una heterogeneidad sustancial dentro de un mismo grado en cada país. En Kenia, por ejemplo, alrededor del 30-40 % de la muestra se clasifica en cada una de las tres categorías de competencia en matemática (no competente, competencia baja y competencia alta), lo que pone de relieve los desafíos de impartir un único programa de instrucción a todos los estudiantes de un aula.

En conjunto, los datos presentados en esta sección muestran que los dos patrones clave que destacamos en la Figura 1, (a) grandes déficits de aprendizaje respecto de los estándares curriculares y (b) gran heterogeneidad en los niveles de aprendizaje dentro de un mismo grado, son típicos de los sistemas educativos de muchos países en desarrollo.

B.2 Enseñar según el currículo

Una preparación académica insuficiente y muy dispersa dentro de un aula sería un desafío para la enseñanza en cualquier contexto. Pero el problema se agrava si los currículos y la pedagogía no responden a esta dispersión. Sumado a los bajos niveles generales de logro, esto genera un desajuste sustancial entre la enseñanza impartida en el aula y la capacidad de los estudiantes para aprovecharla. Nuestros datos ofrecen evidencia indirecta sólida de ello.

En primer lugar, observamos que los estudiantes en el tercil inferior de la distribución de logro en la línea de base dentro de cada grado (que están al menos algunos grados por detrás del nivel del currículo) no logran ningún progreso en sus niveles absolutos de aprendizaje pese a estar matriculados en la escuela – lo que sugiere que el nivel de la enseñanza en el aula estaba demasiado adelantado (y probablemente se ubicaba en el nivel del currículo). En segundo lugar, aunque no observamos un impacto promedio del programa para los estudiantes tratados en las pruebas escolares del grado, sí observamos efectos positivos significativos en estas pruebas para los estudiantes en el tercil superior de la distribución de logro en la línea de base dentro de cada grado. Dado que estos estudiantes estuvieron expuestos a contenidos de

⁴²Para tener una idea concreta de lo que significa “no competente”, en la evaluación PASEC implica la incapacidad de realizar operaciones aritméticas con números enteros salvo las más básicas (es decir, sin demostrar ningún conocimiento de decimales o fracciones ni la capacidad de responder preguntas sobre unidades de tiempo o longitud, ni preguntas básicas de geometría). En lectura, implica la incapacidad de combinar dos datos explícitos de un texto para extraer inferencias simples. En las evaluaciones SACMEQ, “no competente” en lectura implica la incapacidad de vincular e interpretar información ubicada en distintas partes del texto; en matemática, implica la incapacidad de traducir información verbal o gráfica en problemas verbales simples.

Mindspark más cercanos a su grado, esto sugiere que los exámenes escolares (y la enseñanza en la escuela) probablemente se ciñeron a los estándares curriculares del grado.

En esta sección, presentamos evidencia cualitativa adicional que muestra que la enseñanza en las aulas de las escuelas indias sigue de cerca el libro de texto y el currículo, sin importar cuán rezagados respecto de esos estándares puedan estar la mayoría de los estudiantes. Dos conjuntos principales de factores contribuyen a ello.

B.2.1 Currículo y programas de estudio

El primer conjunto se relaciona con los currículos, programas de estudio y evaluaciones prescriptos. La forma en que se fijan los estándares curriculares y luego se transmiten en la enseñanza en el aula está determinada en gran medida por el sistema de exámenes (de alto impacto), que luego sirve como mecanismo de selección para las perspectivas educativas futuras y, eventualmente, para los empleos administrativos y profesionales. En particular, no responde a factores contextuales sobre el logro real o las necesidades de los estudiantes.⁴³ Aunque el Marco Curricular Nacional de 2005 efectivamente recomendó aligerar el currículo y hacerlo más pertinente, esto ha sido difícil de lograr en la práctica.⁴⁴ Este énfasis en el aprendizaje orientado a los exámenes es particularmente marcado en la escuela media y secundaria, dados los importantes puntos de transición basados en exámenes después de 8.^o y 10.^o grado. Dado que la educación posprimaria depende en gran medida de que se hayan dominado las habilidades fundamentales, este énfasis implica que una proporción significativa de los estudiantes no puede aprovechar la enseñanza en el aula de manera significativa.⁴⁵

⁴³El Grupo Nacional de Enfoque sobre Currículo, Programas de Estudio y Libros de Texto, que sustentó el Marco Curricular Nacional revisado en 2005, describió el sistema educativo indio como “en gran medida un sistema monolítico que perpetúa un tipo de educación que ha derivado en un conjunto de prácticas adoptadas para el desarrollo del currículo, los programas de estudio y los libros de texto que se guía por los patrones y requisitos del sistema de exámenes, y no por las necesidades determinadas por una combinación de criterios basados en los requerimientos de aprendizaje del niño, los fines de la educación y los contextos socioeconómicos y culturales de los estudiantes.” (NCERT, 2006)

⁴⁴Véase, p. ej., Dewan and Chabra (2012) sobre la oposición a revisar los currículos de matemática: “Aunque el NCF es muy claro en este tema, los funcionarios estatales siguen sintiendo que reducir contenidos conduce a una pérdida de conocimiento matemático y que los niños de su estado se ven perjudicados en este proceso. También sienten que tales reducciones dejarán a sus niños mal preparados para los diversos exámenes competitivos que rendirán al final de la escolaridad.”

⁴⁵Véase, p. ej., Rampal and Subramaniam (2012) para un ejemplo concreto: “La matemática en el nivel primario superior presupone la capacidad de leer y escribir números, y de dar sentido a expresiones aritméticas, como punto de partida hacia el álgebra. Como los niños no están preparados para afrontarlo, la actividad en el aula se reduce a que los niños copien símbolos sin sentido del pizarrón, o de guías disponibles comercialmente en las que los problemas aparecen resueltos. Estas aulas en las que los estudiantes no pueden dar sentido a las expresiones aritméticas no son excepcionales, sino bastante típicas de las aulas que atienden a estudiantes de sectores socioeconómicamente marginados o de contextos rurales. Estos constituyen una parte significativa de la población estudiantil.”

B.2.2 La falta de enseñanza diferenciada

El segundo conjunto de problemas se relaciona con la capacidad y la voluntad de los docentes para abordar por iniciativa propia el logro bajo y disperso en sus aulas. Si bien, en teoría, los docentes podrían ofrecer enseñanza diferenciada para atender una heterogeneidad generalizada, no hay evidencia de que lo hagan. Sinha, Banerji and Wadhwa (2016) informan, por ejemplo, que el 88 % de los docentes de escuelas primarias y primarias superiores en Bihar creía que su objetivo principal era “completar el programa de estudios”, aun cuando casi la mitad de ellos coincidía con la afirmación, o no la cuestionaba, de que “los libros de texto son demasiado difíciles para los niños” (p. 24). Las observaciones de aula tanto en el nivel primario como en el posprimario encuentran sistemáticamente poca evidencia de enseñanza diferenciada o en grupos pequeños, con una dependencia abrumadora de la enseñanza en el pizarrón y la clase expositiva (Bhattacharjea, Wadhwa and Banerji, 2011; Sankar and Linden, 2014; World Bank, 2016; Sinha, Banerji and Wadhwa, 2016). La enseñanza de nivelación también es poco común, y agrupar a los estudiantes en secciones según su nivel dentro de la escuela resulta impracticable en la mayoría de las escuelas públicas de la India, porque las escuelas son pequeñas y rara vez tienen más de una sección por grado.⁴⁶

Además de reflejar la orientación general del sistema educativo, determinada por el programa de estudios, la falta de enseñanza de nivelación o diferenciada probablemente también refleja las creencias de algunos docentes sobre la capacidad de aprender de los estudiantes. Como señalan Kumar, Dewan and K.Subramaniam (2012): “Es bastante común que los educadores y administradores crean que los niños de contextos socioeconómicos desfavorecidos son incapaces de aprender matemática, ya sea por una falta inherente de capacidad o porque no tienen la preparación cultural y la actitud hacia el aprendizaje.” Por último, no está claro que, aun si lo desearan, los docentes puedan diagnosticar eficazmente los errores de los estudiantes y brindar el apoyo adecuado. En un estudio de 150 escuelas secundarias en dos estados (Madhya Pradesh y Tamil Nadu) en el ciclo lectivo 2014-2015, se encontró que los docentes de lengua solo lograban identificar los errores de los estudiantes el 50 % de las veces y los docentes de matemática solo lo lograban el 40 % de las veces (Banco Mundial, 2016, p. 47). Estos desafíos no son exclusivos de la India, y hallazgos similares sobre el bajo capital humano docente y la escasa capacidad para apoyar a los estudiantes más rezagados también están documentados en otros lugares; Bold et al. (2017), por ejemplo, usan datos primarios de siete países de África subsahariana para documentar que “el conocimiento pedagógico general y la capacidad de evaluar el aprendizaje de los estudiantes y responder a esa evaluación son deficientes en

⁴⁶En todo caso, es más típica la situación opuesta, en la que un mismo docente enseña simultáneamente a varios grados. Esto se debe a que el gobierno indio ha priorizado el acceso universal a la escuela, lo que dio lugar a numerosas escuelas muy pequeñas en toda la India rural. La matrícula promedio de las escuelas públicas de la India rural es inferior a 100 estudiantes en los cinco grados de primaria, y la mayoría tiene enseñanza multigrado (Muralidharan et al., 2017).

los siete países: aproximadamente solo 1 de cada 10 docentes se clasifica como poseedor de un conocimiento mínimo de pedagogía general y ninguno posee un conocimiento mínimo de evaluación de estudiantes.”

En suma, el desafío central del desajuste curricular es generalizado en todo el sistema educativo indio. Si bien la evidencia directa es escasa para otros contextos, es probable que este desafío también se extienda a otros países en desarrollo afectados por bajos niveles de logro y currículos potencialmente demasiado ambiciosos (véase Pritchett and Beatty (2015)). La enseñanza personalizada también podría tener un potencial significativo para mejorar los resultados de aprendizaje en estos contextos.⁴⁷

⁴⁷Para evidencia experimental, véase Duflo, Dupas and Kremer (2011), que encuentra efectos positivos del agrupamiento por nivel en toda la distribución inicial de habilidades y los atribuye a la posibilidad de ajustar la enseñanza más de cerca a los niveles de habilidad de los estudiantes dentro de un aula.

Apéndice C Investigaciones previas sobre hardware y software

Las Tablas C.1 y C.2 ofrecen un panorama de las evaluaciones de impacto experimentales y cuasiexperimentales de intervenciones que proveen hardware y software para mejorar el aprendizaje de los niños. Las tablas solo incluyen estudios centrados en estudiantes de escuela primaria y secundaria (no de nivel inicial ni de educación superior) y solo informan efectos en matemática y lenguaje (no en otros resultados evaluados en estos estudios, p. ej., la familiaridad con las computadoras o las habilidades socioemocionales).

C.1 Selección de estudios

Esta no pretende ser una revisión exhaustiva de la literatura. En concreto, excluimos varias evaluaciones de impacto de programas (en su mayoría, dentro de la educación) debido a fallas de diseño importantes (p. ej., tamaños muestrales extremadamente pequeños, ausencia de grupo de control o exclusión del análisis de quienes abandonaron la muestra). Estas fallas están ampliamente documentadas en metaanálisis de esta literatura (véanse, por ejemplo, Murphy et al., 2001; Pearson et al., 2005; Waxman, Lin and Michko, 2003).

Aplicamos exclusiones adicionales para cada tabla. En la Tabla C.1, excluimos los DID cuya identificación es cuestionable y los estudios que evalúan el impacto de subsidios para Internet (por ejemplo, Goolsbee and Guryan, 2006). En la Tabla C.2, excluimos las evaluaciones de impacto de productos de software para materias distintas de matemática y lenguaje o diseñados para abordar dificultades específicas de aprendizaje (p. ej., dislexia, trastornos del habla).

C.2 Informe de los efectos

Para informar los tamaños del efecto, seguimos el siguiente procedimiento: (a) informamos la diferencia entre los grupos de tratamiento y de control ajustada por el desempeño en la línea de base siempre que estuviera disponible; (b) si esta diferencia no estaba disponible, informamos la diferencia simple entre los grupos de tratamiento y de control (sin otras covariables más que los bloques de aleatorización, si correspondía); y (c) si ninguna de las dos diferencias estaba disponible, informamos la diferencia entre los grupos de tratamiento y de control ajustada por el desempeño en la línea de base y/o por cualquier otra covariable que incluyeran los autores.

En todos los RCT, informamos el efecto de intención de tratar (ITT); en todos los RDD e IV, informamos el efecto local promedio del tratamiento (LATE). En todos los casos, solo

informamos la magnitud de los tamaños del efecto que eran estadísticamente significativos al nivel del 5 %. Estas decisiones no son triviales, ya que las especificaciones preferidas por los autores de algunos estudios (e informadas en los resúmenes) solo son significativas al nivel del 10 % o solo pasan a ser significativas al nivel del 5 % tras la inclusión de múltiples covariables. En caso contrario, indicamos que un programa “no tuvo efecto” en la materia respectiva. Nuevamente, esta decisión no es trivial, porque algunos de estos estudios carecían de potencia estadística suficiente para detectar efectos pequeños a moderados.

C.3 Categorías de cada tabla

En ambas tablas, documentamos el estudio, el método de evaluación de impacto empleado por los autores, la muestra, el programa, la materia a la que apuntaba el software/hardware y su intensidad. Además, en la Tabla C.1, documentamos: (a) si el hardware provisto incluía software preinstalado; (b) si el hardware requería alguna participación del instructor; y (c) si el hardware iba acompañado de capacitación docente. En la Tabla C.2, documentamos: (a) si el software estaba vinculado a un currículo oficial (y, en ese caso, cómo); (b) si el software era adaptativo (es decir, si podía ajustar *dinámicamente* la dificultad de las preguntas y/o actividades en función del desempeño de los estudiantes); y (c) si el software brindaba retroalimentación *diferenciada* (es decir, si los estudiantes veían mensajes distintos según la respuesta incorrecta que seleccionaran).

Tabla C.1: Evaluaciones de impacto de hardware

Estudio	Método	Muestra	Programa	Materia	Intensidad	¿Incluye software?	¿Rol del instructor?	¿Capacitación docente?	Efecto	Costo
Angrist and Lavy (2002)	IV	Grados 4 y 8, 122 escuelas judías en Israel	Tomorrow-98	Matemática y lenguaje (hebreo)	Relación objetivo estudiantes-computadora de 1:10 en cada escuela	Sí, incluía software educativo de una empresa privada	No especificado	Sí, capacitación docente para integrar las computadoras en la enseñanza	Grado 4: -0.4 a -0.3 σ en matemática y sin efecto en lenguaje	USD 3,000 por máquina, incluidos hardware, software e instalación; con 40 computadoras por escuela, USD 120,000 por escuela
Barrera-Osorio and Linden (2009)	RCT	Grados 3-9, 97 escuelas públicas en seis distritos escolares, Colombia	Computers for Education	Matemática y lenguaje (español)	15 computadoras por escuela	No especificado	Usar las computadoras para apoyar a los niños en habilidades básicas (esp. español)	Sí, capacitación docente de 20 meses, a cargo de una universidad local	Sin efecto en lenguaje ni en matemática	No especificado
Malamud and Pop-Eleches (2011)	RDD	Grados 1-12, en seis regiones, Rumania	Programa Euro 200	Matemática y lenguaje (inglés y rumano)	Un vale (por valor de USD 300) para la compra de una computadora de uso en el hogar	Software preinstalado, pero el software educativo se proveía por separado y no siempre se instalaba	No especificado	Sí, 530 lecciones multimedia para estudiantes sobre el uso de computadoras con fines educativos	-0.44 σ en el promedio de calificaciones de matemática, -0.56 σ en el promedio de calificaciones de rumano y -0.63 σ en inglés	Costo del vale más costos de gestión no especificados

Cristia et al. (2012)	RCT	319 escuelas en ocho zonas rurales, Perú	One Laptop per Child	Matemática y lenguaje (español)	Una laptop por estudiante y docente para uso en la escuela y el hogar	Sí, 39 aplicaciones, entre ellas: aplicaciones estándar, juegos educativos, edición de música, entornos de programación, grabación de sonido y video, enciclopedia; también 200 libros electrónicos adecuados a la edad	No especificado	Sí, capacitación de 40 horas orientada a facilitar el uso de las laptops con fines pedagógicos	Sin efecto en matemática ni en lenguaje	USD 200 por laptop
Mo et al. (2013)	RCT	Grado 3, 13 escuelas para migrantes en Beijing, China	One Laptop per Child	Matemática y lenguaje (chino)	Una laptop por estudiante para uso en el hogar	Sí, tres conjuntos de software: un programa comercial de aprendizaje de matemática basado en juegos; un programa similar para chino; un tercer programa desarrollado por el equipo de investigación	No especificado	No, pero una sesión de capacitación con los niños y sus padres	Sin efecto en matemática ni en lenguaje	No especificado

Beuermann et al. (2015)	RCT	Grado 2, 28 escuelas públicas en Lima, Perú	One Laptop per Child	Matemática y lenguaje (español)	Cuatro laptops (una por estudiante) en cada clase/sección para uso en la escuela	Sí, 32 aplicaciones, entre ellas: aplicaciones estándar, juegos educativos, edición de música, entornos de programación, grabación de sonido y video, enciclopedia	No especificado	No, pero sesiones semanales de capacitación durante siete semanas para los estudiantes	Sin efecto en matemática ni en lenguaje	USD 188 por laptop
Leuven et al. (2007)	RDD	Grado 8, 150 escuelas en los Países Bajos	No especificado	Matemática y lenguaje (neerlandés)	No especificado	No especificado	No especificado	No especificado	-0.08 DE en lenguaje y sin efecto en matemática	Este estudio estima el efecto de USD 90 por alumno para hardware y software
Machin, McNally and Silva (2007)	IV	Grado 6, 627 (1999-2001) y 810 (2001-2002) escuelas primarias y 616 (1999-2000) y 714 (2001-2002) escuelas secundarias en Inglaterra	No especificado	Matemática y lenguaje (inglés)	Relación objetivo estudiantes-computadora de 1:8 en cada escuela primaria y de 1:5 en cada escuela secundaria	Algunas escuelas destinaron fondos para TIC a software	No especificado	Sí, capacitación en servicio para docentes y bibliotecarios escolares	Aumento de 2.2 pp. en el porcentaje de niños que alcanzan estándares mínimos aceptables en los exámenes de fin de año	Este estudio estima el efecto de duplicar el financiamiento para TIC (hardware y software) de una Autoridad Educativa Local
Fairlie and Robinson (2013)	RCT	Grados 6-10, 15 escuelas públicas medias y secundarias en cinco distritos escolares de California, Estados Unidos	No especificado	Matemática y lenguaje (inglés)	Una computadora por niño para uso en el hogar	Sí, Microsoft Windows y Office	No	No	Sin efecto en lenguaje ni en matemática	No especificado

Tabla C.2: Evaluaciones de impacto de software

Estudio	Método	Muestra	Programa	Materia	Intensidad	¿Vinculado al currículo?	¿Adaptativo dinámicamente?	¿Retroalimentación diferenciada?	Efecto	Costo
Banerjee et al. (2007)	RCT	Grado 4, 100 escuelas municipales en Gujarat, India	Año 1: programa estándar desarrollado por Pratham; Año 2: programa desarrollado por Media-Pro	Matemática	120 min./semana durante la jornada escolar o antes/después de ella; 2 niños por computadora	Curriculo de Gujarat, énfasis en habilidades básicas	Sí, la dificultad de las preguntas responde a la habilidad	No especificado	Año 1: 0.35σ en matemática y sin efecto en lenguaje; Año 2: 0.48σ en matemática y sin efecto en lenguaje	INR 722 (USD 15.18) por estudiante por año
Linden (2008)	RCT	Grados 2-3, 60 escuelas Gyan Shala en Gujarat, India	Programa de aprendizaje asistido por computadora (CAL) de Gyan Shala	Matemática	Versión 1: 60 min./día durante la jornada escolar; Versión 2: 60 min./día después de la escuela; Ambas: 2 niños por computadora (pantalla dividida)	Curriculo de Gujarat, refuerza el material enseñado ese día	No especificado	No especificado	Versión 1: sin efecto en matemática ni en lenguaje; Versión 2: sin efecto en matemática ni en lenguaje	USD 5 por estudiante por año
Carrillo, Onofa and Ponce (2010)	RCT	Grados 3-5, 16 escuelas públicas en Guayaquil, Ecuador	Programa Aprendizaje Personalizado Complementario Interconectado (APCI)	Matemática y lenguaje (español)	180 min./semana durante la jornada escolar	Curriculo personalizado basado en una prueba diagnóstica	No, pero las preguntas dependen de la prueba diagnóstica	No especificado	Sin efecto en matemática ni en lenguaje	No especificado

Lai et al. (2012)	RCT	Grado 3, 57 escuelas públicas rurales, Qinghai, China	No especificado	Lenguaje (mandarín)	Dos sesiones obligatorias de 40 min./semana durante el almuerzo o después de la escuela; equipos de 2 niños	Currículo nacional, refuerza el material enseñado esa semana	No, las mismas preguntas para todos los estudiantes	No, si los estudiantes tenían una pregunta, podían discutirla con su compañero de equipo, pero no con el docente	Sin efecto en lenguaje y 0.23σ en matemática	No especificado
Lai et al. (2013)	RCT	Grados 3 y 5, 72 escuelas rurales con internado, Shaanxi, China	No especificado	Matemática	Dos sesiones obligatorias de 40 min./semana después de la escuela; equipos de 2 niños	Currículo nacional, refuerza el material enseñado esa semana	No, las mismas preguntas para todos los estudiantes	No, si los estudiantes tenían una pregunta, podían discutirla con su compañero de equipo, pero no con el docente	0.12 σ en lenguaje, en ambos grados	No especificado
Mo et al. (2014a)	RCT	Grados 3 y 5, 72 escuelas rurales, Shaanxi, China	No especificado	Matemática	Dos sesiones obligatorias de 40 min./semana durante las clases de computación; equipos de 2 niños	Currículo nacional, refuerza el material enseñado esa semana	No, las mismas preguntas para todos los estudiantes	No, si los estudiantes tenían una pregunta, podían discutirla con su compañero de equipo, pero no con el docente	0.18 σ en matemática	USD 9439 en total por 1 año
Mo et al. (2014b)	RCT	Grados 3 y 5, 72 escuelas rurales, Shaanxi, China	No especificado	Matemática	Dos sesiones obligatorias de 40 min./semana durante las clases de computación; equipos de 2 niños	Currículo nacional, refuerza el material enseñado esa semana	No, las mismas preguntas para todos los estudiantes	No, si los estudiantes tenían una pregunta, podían discutirla con su compañero de equipo, pero no con el docente	Fase 1: sin efecto en matemática; Fase 2: 0.3 σ en matemática	USD 9439 en total por 1 año

Lai et al. (2015)	RCT	Grado 3, 43 escuelas para migrantes, Beijing, China	No especificado	Matemá- tica	Dos sesiones obligatorias de 40 min./semana durante el almuerzo o después de la escuela	Curriculo nacional, refuerza el material enseñado esa semana	No, las mismas preguntas para todos los estudiantes	No, si los estudiantes tenían una pregunta, podían discutirla con su compañero de equipo, pero no con el docente	0.15 σ en matemática y sin efecto en lenguaje	USD 7.9-8.8 por niño por 6 meses
Mo et al. (2016)	RCT	Grado 5, 120 escuelas, Qinghai, China	No especificado	Lenguaje (inglés)	Versión 1: Dos sesiones obligatorias de 40 min./semana durante las clases regulares de computación; Versión 2: clases de inglés (también opcional durante el almuerzo u otros recreos); Ambas: equipos de 2 niños	Curriculo nacional, refuerza el material enseñado esa semana	Versión 1: Sin retroalimenta- ción durante las clases regulares de computación; Versión 2: retroalimenta- ción de los docentes durante las clases de inglés	Versión 1: si los estudiantes tenían una pregunta, podían discutirla con su compañero de equipo, pero no con el docente; Versión 2: retroalimenta- ción del docente de inglés	Versión 1: 0.16 σ en lenguaje; Versión 2: sin efecto en lenguaje	Versión 1: RMB 32.09 (USD 5.09) por año; Versión 2: RMB 24.42 (USD 3.87) por año
Wise and Olson (1995)	RCT	Grados 2-5, 4 escuelas públicas en Boulder, Colorado, Estados Unidos	Programas Reading with Orthographic and Segmented Speech (ROSS)	Lenguaje y lectura (inglés)	Ambas versiones: 420 min. en total, en sesiones de 30 y 15 min.; equipos de 3 niños	No especificado	No, pero los problemas más difíciles se presentaban solo una vez resueltos correctamente los más fáciles; además, en la Versión 2, los docentes explicaban las preguntas respondidas in- correctamente	No, pero los estudiantes pueden pedir ayuda cuando no entienden una palabra	Efecto positivo en el Lindamond Test of Auditory Con- ceptualization (LAC), la prueba Phoneme Deletion y la Deletion y la de Nonword Reading (TE no informados); sin efecto en otros dominios de lenguaje y lectura	No especificado

Morgan and Ritter (2002)	RCT	Grado 9, 4 escuelas públicas en el Moore Independent School District, Oklahoma, Estados Unidos	Cognitive Tutor - Algebra I	Matemática	No especificado	No especificado	No especificado	Effecto positivo (TE no informado) en matemática	No especificado
Rouse and Krueger (2004)	RCT	Grados 4-6, 4 escuelas públicas en un distrito urbano del noreste de Estados Unidos	Programas Fast For Word (FFW)	Lenguaje y lectura (inglés)	90-100 min./día durante las clases ("pull-out", fuera del aula) o antes/después de la escuela, 5 días por semana, durante 6-8 semanas	No especificado	No, pero los problemas más difíciles se presentaban solo una vez resueltos correctamente los más fáciles	Sin efecto en la prueba Reading Edge, la Clinical Evaluation of Language Fundamentals 3rd Edition (CELF-3-RP), la prueba Success For All (SFA) ni la State Reading Test	USD 30,000 por una licencia de 1 año para 30 computadoras, más USD 100 por sitio para capacitación profesional
Dynarski et al. (2007)	RCT	Grados 4-6, 4 escuelas públicas en un distrito urbano del noreste de Estados Unidos	Programas Fast For Word (FFW)	Lenguaje y lectura (inglés)	90-100 min./día durante las clases ("pull-out", fuera del aula) o antes/después de la escuela, 5 días por semana, durante 6-8 semanas	No especificado	No, pero los problemas más difíciles se presentaban solo una vez resueltos correctamente los más fáciles	Sin efecto en la prueba Reading Edge, la Clinical Evaluation of Language Fundamentals 3rd Edition (CELF-3-RP), la prueba Success For All (SFA) ni la State Reading Test	USD 30,000 por una licencia de 1 año para 30 computadoras, más USD 100 por sitio para capacitación profesional

Grado 4, 43 escuelas públicas en 11 distritos escolares, Estados Unidos	Leapfrog, Read 180, Academy of Reading, Knowledgebox	Lectura (inglés)	Varía según el producto, pero el 70 % los usó durante el horario de clase; el 25 % los usó antes de la escuela, durante el almuerzo o en tiempo asignado a otras materias; y el 6 % de los docentes los usó en ambos	No especificado	No especificado, pero los cuatro productos creaban auto- máticamente "trayectorias de aprendizaje" individuales para cada estudiante	No especificado, pero los cuatro productos brindaban retroalimenta- ción inmediata a los estudiantes; uno brindaba retroalimenta- ción sobre el dominio; dos brindaban retroalimenta- ción diagnóstica	Sin efecto en lectura	USD 18 a USD 184 por estudiante por año (según el producto)
Grado 6, 28 escuelas públicas en 10 distritos escolares, Estados Unidos	Larson Pre-Algebra, Achieve Now, iLearn Math	Matemá- tica	Varía según el producto, pero el 76 % los usó durante el horario de clase; el 11 % los usó antes de la escuela, durante el almuerzo o en tiempo asignado a otras materias; y el 13 % de los docentes los usó en ambos	No especificado	No especificado, pero los tres productos creaban auto- máticamente "trayectorias de aprendizaje" individuales para cada estudiante	No especificado, pero los tres productos brindaban retroalimenta- ción inmediata a los estudiantes; uno brindaba retroalimenta- ción sobre el dominio; dos brindaban retroalimenta- ción diagnóstica	Sin efecto en matemática	USD 9 a USD 30 por estudiante por año (según el producto)

Barrow, Markman and Rouse (2009)	RCT	Grados 8, 10	I Can Learn	Matemática	Varía según el producto, pero el 94 % los usó durante el horario de clase; y el 6 % de los docentes los usó en ambos	No especificado	No especificado, pero los tres productos creaban automáticamente "trayectorias de aprendizaje" individuales para cada estudiante	No especificado, pero los tres brindaban retroalimentación inmediata a los estudiantes; dos brindaban retroalimentación sobre el dominio; dos brindaban retroalimentación diagnóstica	Sin efecto en matemática	USD 7 a USD 30 por estudiante por año (según el producto)
		Grados 2 y 7, 8	Fast For Word (FFW) Language	Lenguaje y lectura (inglés)	100 min./día, cinco días por semana, durante cuatro a ocho semanas, durante las clases ("pull-out", fuera del aula)	No especificado	No, pero los estudiantes que no aprueban las pruebas integrales repiten las lecciones hasta aprobarlas	No especificado	0.17σ en matemática	Un laboratorio de 30 puestos cuesta USD 100,000, con USD 150,000 adicionales para software de preálgebra, álgebra y gestión del aula
Borman, Benson and Overman (2009)	RCT	Grados 2 y 7, 8 escuelas públicas en Baltimore, Maryland, Estados Unidos	Fast For Word (FFW) Language	Lenguaje y lectura (inglés)	100 min./día, cinco días por semana, durante cuatro a ocho semanas, durante las clases ("pull-out", fuera del aula)	No especificado	No, todos los niños comienzan en el mismo nivel básico y avanzan solo tras alcanzar un nivel de dominio predefinido	No especificado	Grado 2: sin efecto en lenguaje ni en lectura; Grado 7: sin efecto en lenguaje ni en lectura	No especificado
Campuzano et al. (2009)	RCT	Grado 1, 12 escuelas públicas en 2 distritos escolares, Estados Unidos	Destination Reading - Course 1	Lectura (inglés)	20 min./día, dos veces por semana, durante la jornada escolar	No especificado	No especificado	No especificado	Sin efecto en lectura	USD 78 por estudiante por año

Grado 1, 12 escuelas públicas en 3 distritos escolares, Estados Unidos	Headsprout	Lectura (inglés)	30 min./día, tres veces por semana, durante la jornada escolar	No especificado	No especificado	No especificado	0.01 DE en lectura ($p>0.05$)	USD 146 por estudiante por año
Grado 1, 8 escuelas públicas en 3 distritos escolares, Estados Unidos	PLATO Focus	Lectura (inglés)	15-30 min./día (frecuencia semanal no especificada)	No especificado	No, pero los docentes pueden elegir el orden y el nivel de dificultad de las actividades	No especificado	Sin efecto en lectura	USD 351 por estudiante por año
Grado 1, 13 escuelas públicas en 3 distritos escolares, Estados Unidos	Waterford Early Reading Program - Levels 1-3	Lectura (inglés)	17-30 min./día, tres veces por semana, durante la jornada escolar	No especificado	No especificado	No especificado	Sin efecto en lectura	USD 223 por estudiante por año
Grado 4, 15 escuelas públicas en 4 distritos escolares, Estados Unidos	Academy of Reading	Lectura (inglés)	25 min./día, tres o más días por semana, durante la jornada escolar	No especificado	No especificado	No especificado	Sin efecto en lectura	USD 217 por estudiante por año
Grado 4, 19 escuelas públicas en 4 distritos escolares, Estados Unidos	LeapTrack	Lectura (inglés)	15 min./día, de tres a cinco días por semana, durante la jornada escolar	No especificado	No, pero evaluaciones diagnósticas determinan la "trayectoria de aprendizaje" de cada estudiante	No especificado	0.09 σ en lectura	USD 154 por estudiante por año
Grado 6, 13 escuelas públicas en 3 distritos escolares, Estados Unidos	PLATO Achieve Now - Mathematics Series 3	Matemá- tica	30 min./día, cuatro días por semana, durante al menos 10 semanas, durante la jornada escolar	No especificado	No, pero una evaluación diagnóstica determina qué actividades deben intentar los estudiantes	No especificado	Sin efecto en matemática	USD 36 por estudiante por año

Grado 6, 13 escuelas públicas en 5 distritos escolares, Estados Unidos	Larson Pre-Algebra	Matemática	Varía según la cantidad de temas/semanas del curso, pero se recomendaba al menos uno por semana	No especificado	No especificado	Sin efecto en matemática	USD 15 por estudiante por año	
Álgebra I, 11 escuelas públicas en 4 distritos escolares, Estados Unidos	Cognitive Tutor - Algebra I	Matemática	Dos días por semana (más libro de texto tres días por semana)	No especificado	No especificado	Sin efecto en matemática	USD 69 por estudiante por año	
Álgebra I, 12 escuelas públicas en 5 distritos escolares, Estados Unidos	Larson Algebra I	Matemática	Varía según la cantidad de temas/semanas del curso, pero se recomendaba al menos uno por semana	No especificado	No especificado	Sin efecto en matemática	USD 13 por estudiante por año	
Grados 6-8, 8 escuelas públicas medias en Nueva York, NY, Estados Unidos	School of One (So1)	Matemática	No especificado	No, actividades obtenidas de editoriales, proveedores de software y otros grupos educativos	Sí, un "algoritmo de aprendizaje" se basa en el desempeño de los estudiantes en cada lección y recomienda una "lista de actividades" para cada estudiante; al final del día, los estudiantes realizan una "actualización de la lista"	No, pero existe la posibilidad de obtener retroalimentación mediante el refuerzo presencial de lecciones previas, tutoría presencial, colaboración en grupos pequeños, enseñanza virtual en vivo y tutoría virtual en vivo	Sin efecto en la New York State Math Test ni en la prueba de la Northwest Evaluation Association (NWEA)	No especificado

Apéndice D Software Mindspark

Este apéndice ofrece una descripción más detallada del funcionamiento del software de aprendizaje asistido por computadora (CAL) Mindspark, así como detalles específicos sobre cómo se implementó en los centros Mindspark extraescolares evaluados en nuestro estudio.

D.1 Capacitación en el uso de la computadora

La primera vez que los estudiantes ingresan al software Mindspark, se les presenta una rutina optativa (que lleva 10-15 minutos) diseñada para familiarizarlos con la interfaz de usuario y con ejercicios de matemática o de lengua.

D.2 Prueba diagnóstica

Después de la rutina de familiarización, se presentan a los estudiantes pruebas diagnósticas de matemática y de hindi, que la plataforma Mindspark utiliza para determinar algorítmicamente su nivel inicial de logro (al cual se orientará la instrucción). Las pruebas contienen de cuatro a cinco preguntas por nivel de grado en cada materia. A todos los estudiantes se les muestran preguntas desde 1.º grado hasta su nivel de grado. Sin embargo, si los estudiantes responden correctamente al menos el 75 % de las preguntas correspondientes a su nivel de grado, se les pueden mostrar preguntas de hasta dos niveles de grado por encima del propio.⁴⁸ Si responden correctamente el 25 % o menos de las preguntas de un nivel de grado por encima de su grado real, la prueba diagnóstica no muestra más preguntas. Los niveles iniciales de logro que el sistema Mindspark determina a partir de estas pruebas solo se utilizan para personalizar el primer conjunto de contenidos que se ofrece a los estudiantes. La personalización posterior se basa en el desempeño de los estudiantes en estos módulos de contenido y no depende de su desempeño en la prueba diagnóstica inicial (que solo se utiliza para la calibración inicial del nivel de aprendizaje de cada estudiante).

D.3 Contenidos de matemática y de hindi

Mindspark contiene una serie de actividades asignadas a niveles de grado específicos, sobre la base de análisis de los currículos estatales. Todos los ítems son elaborados por los especialistas en educación de EI. Los centros Mindspark se concentran en una materia específica por día: hay dos días asignados a matemática, dos días asignados a hindi, un día asignado a inglés y un día “libre”, en el que los estudiantes pueden elegir una materia.

Los ítems de matemática y de hindi se organizan de manera diferente. En matemática, los “temas” (p. ej., operaciones con números enteros) se dividen en “temas docentes” (p. ej., la suma), que se dividen en “grupos” (p. ej., la suma en una recta numérica), que se dividen

⁴⁸Por ejemplo, un estudiante de 4.º grado siempre verá preguntas desde 1.º grado hasta 4.º grado. Sin embargo, si responde correctamente más del 75 % de las preguntas de 4.º grado, se le mostrarán preguntas de 5.º grado; y si responde correctamente más del 75 % de las preguntas de 5.º grado, se le mostrarán preguntas de 6.º grado.

en “niveles de dificultad del estudiante” (SDL) (p. ej., desplazarse de un lugar a otro en la recta numérica), que a su vez se dividen en preguntas (p. ej., el mismo ejercicio con números levemente diferentes). El software Mindspark tiene actualmente 21 temas, 105 temas docentes y 550 grupos. La organización de los contenidos de matemática refleja la naturaleza mayormente lineal del aprendizaje de la matemática (p. ej., no se puede aprender la multiplicación sin comprender la suma). Por este motivo, además, los estudiantes deben aprobar un SDL para pasar al siguiente, y los SDL siempre aumentan en dificultad.

En hindi, hay dos tipos de preguntas: “pasajes” (es decir, preguntas de comprensión lectora) y “no pasajes” (es decir, preguntas no vinculadas a ninguna lectura). Las preguntas de pasajes se agrupan por grado (1 a 8), que a su vez se dividen en niveles (bajo, medio o alto). Las preguntas que no son de pasajes se agrupan en “habilidades” (p. ej., gramática), que se dividen en “subhabilidades” (p. ej., sustantivos), que a su vez se dividen en preguntas (p. ej., el mismo ejercicio con palabras levemente diferentes). El software Mindspark tiene actualmente alrededor de 330 pasajes (es decir, de 20 a 50 por grado) vinculados a casi 6,000 preguntas y, para las preguntas que no son de pasajes, 13 habilidades y 50 subhabilidades, vinculadas a aproximadamente 8,200 preguntas. Los contenidos de hindi se organizan de este modo porque el aprendizaje de una lengua no es tan lineal como el de la matemática (p. ej., un estudiante puede leer y comprender parte de un texto aunque no domine la gramática o todo el vocabulario que contiene). En consecuencia, no hay SDL en hindi, y los contenidos no son necesariamente tan lineales ni están tan claramente asociados a la dificultad del grado como en matemática.

La eficacia pedagógica de los contenidos de aprendizaje de la lengua se potencia mediante el uso de videos con subtítulo en el mismo idioma (SLS). El enfoque SLS se basa en un estilo “karaoke” y promueve el aprendizaje de la lengua mediante un texto en pantalla que acompaña un audio, con el resaltado en pantalla de cada sílaba en el mismo momento en que se escucha; se ha demostrado que es sumamente eficaz para promover la alfabetización de adultos en la India (Kothari et al., 2002; Kothari, Pandey and Chudgar, 2004). En Mindspark, el enfoque SLS se implementa mostrando a los estudiantes historias animadas con audio en hindi junto con subtítulos en hindi, para ayudar al estudiante a seguir la lectura y mejorar el reconocimiento fonético, así como la pronunciación.

D.4 Personalización

D.4.1 Adaptación dinámica a los niveles de logro de los estudiantes

En matemática, las preguntas dentro de un tema docente aumentan progresivamente en dificultad, sobre la base de los análisis de datos de EI y de la clasificación que realizan sus especialistas en educación. Cuando un niño no aprueba una unidad de aprendizaje, se identifica la brecha de aprendizaje y se toma la medida de apoyo correspondiente. Esta puede consistir

en guiar al niño a través de una explicación paso a paso de un concepto, en un repaso de los fundamentos de ese concepto o simplemente en más preguntas sobre el concepto.

La Figura D.1 ilustra cómo funciona la adaptabilidad. Por ejemplo, un niño podría ser asignado a la “prueba de comparación de decimales”, un ejercicio en el que debe comparar dos números decimales e indicar cuál es mayor. Si responde correctamente la mayoría de las preguntas de esa prueba, se le asigna el “juego de los números ocultos”, un ejercicio levemente más difícil en el que también debe comparar dos números decimales, pero con la menor información posible (es decir, para que los niños comprendan que la cifra a la izquierda de la coma decimal es la más importante y que las que están a la derecha de la coma decimal tienen una importancia decreciente). Sin embargo, si responde incorrectamente la mayoría de las preguntas de la prueba de comparación de decimales, se le asigna una serie de actividades de apoyo que buscan reforzar los conceptos fundamentales sobre los decimales.

En hindi, en la primera parte, los estudiantes comienzan con pasajes de baja dificultad y avanzan hacia pasajes de mayor dificultad. Si un niño tiene un desempeño deficiente en un pasaje, se le asigna un pasaje de menor dificultad. En la segunda parte, los estudiantes comienzan con preguntas de baja dificultad en cada habilidad y avanzan hacia preguntas de mayor dificultad. Así, un estudiante podría estar viendo preguntas de baja dificultad en una habilidad determinada y preguntas de dificultad media en otra.

D.4.2 Análisis de errores

Además de adaptar el nivel de dificultad de los contenidos al del estudiante, Mindspark también busca identificar las fuentes específicas de incomprensión conceptual de estudiantes que, de otro modo, podrían tener un nivel general de aprendizaje similar. Así, aunque dos estudiantes tengan el mismo puntaje en un tema determinado (digamos, un 60 % en fracciones), las razones por las que no respondieron bien las preguntas restantes pueden ser muy diferentes, y esto puede no ser fácil de identificar para un docente. Un rasgo distintivo del sistema Mindspark es el uso de datos detallados sobre las respuestas de los estudiantes a cada pregunta para analizar e identificar *patrones* de errores en sus respuestas, lo que permite identificar la incomprensión o concepción errónea precisa que un estudiante puede tener sobre un tema determinado y orientar los contenidos posteriores en consecuencia.

La idea de que los educadores pueden aprender tanto (o quizás más) del análisis de los patrones de errores de los estudiantes como de sus respuestas correctas tiene una larga tradición en la investigación educativa (véanse, por ejemplo, Buswell and Judd (1925) y Radatz (1979) para discusiones sobre el uso del “análisis de errores” en la enseñanza de la matemática). Sin embargo, llevar esta idea a la práctica dista mucho de ser trivial para un docente individual en un aula típica. El potencial de los ‘macrodatos’ para mejorar el diseño y la entrega de contenidos educativos es especialmente prometedor en el área del análisis de errores, como se observa en el ejemplo que sigue.

La Figura D.2 muestra tres ejemplos de errores de los estudiantes en preguntas de “comparación de decimales”. El software Mindspark identificó estos patrones de errores y, posteriormente, el personal de EI entrevistó a una muestra de estudiantes que cometieron estos errores para comprender las concepciones erróneas subyacentes. En el primer ejemplo, los estudiantes se equivocan en la comparación porque exhiben lo que EI clasifica como “pensamiento de números enteros”. Específicamente, los estudiantes creían que 3.27 era mayor que 3.3 porque, dado que la parte entera era la misma en ambos casos (es decir, 3), compararon los números a la izquierda de la coma decimal (es decir, 27 y 3) y concluyeron (incorrectamente) que, como 27 es mayor que 3, 3.27 era mayor que 3.3.

En el segundo ejemplo, el error no puede deberse a la razón anterior (ya que 27 es mayor que 18). En este caso, EI diagnosticó la naturaleza de la concepción errónea como “pensamiento de orden inverso”. En este caso, los estudiantes saben que el valor posicional de las ‘centenas’ es mayor que el de las ‘decenas’, pero, como consecuencia, también creen que el valor posicional de los ‘centésimos’ es mayor que el de los ‘décimos’. Por lo tanto, compararon 81 con 27 y concluyeron (incorrectamente) que 3.18 era mayor que 3.27.

Por último, el error del último ejemplo no puede deberse a ninguno de los dos patrones anteriores (ya que 27 es menor que 39, y 7 es menor que 9). En este caso, EI diagnosticó la naturaleza de la concepción errónea como “pensamiento recíproco”. Específicamente, los estudiantes en este caso comprendían que el componente del número a la derecha de la coma decimal es una fracción, pero luego tomaban el recíproco del número a la derecha de la coma decimal, del modo en que se escriben las fracciones comunes. Así, comparaban $\frac{1}{27}$ con $\frac{1}{39}$ en lugar de 0.27 con 0.39 y, en consecuencia, clasificaban (incorrectamente) el primero como mayor.

Es importante señalar que la proporción de estudiantes que cometen cada tipo de error es bastante pequeña (5 %, 4 % y 3 %, respectivamente), lo que haría mucho más difícil que un docente detectara estos patrones en un aula típica (ya que la muestra de estudiantes de un aula sería pequeña). La ventaja comparativa del sistema basado en computadora resulta claramente evidente en un caso como este, ya que puede analizar patrones de miles de estudiantes, cada uno de los cuales intenta un gran conjunto de comparaciones de este tipo. Esto permite tanto el reconocimiento de patrones a nivel agregado como el diagnóstico, a nivel de cada estudiante, de si un estudiante determinado exhibe ese patrón. En línea con este enfoque, Mindspark orienta luego los contenidos de seguimiento según la clasificación que hace el sistema de los patrones de errores de los estudiantes, como se observa en la Figura D.1 (que también muestra cómo cada estudiante haría 30 comparaciones en el conjunto inicial de ejercicios para permitir un diagnóstico preciso de las concepciones erróneas).

D.5 Retroalimentación

El enfoque pedagógico que privilegia el sistema Mindspark prioriza la participación activa de los estudiantes en todo momento. Se busca que el aprendizaje se construya a partir de la retroalimentación a los estudiantes sobre las preguntas respondidas incorrectamente. Además, la mayoría de las preguntas están precedidas por un ejemplo y por contenidos interactivos que brindan instrucciones paso a paso sobre cómo deberían abordar los estudiantes la resolución de la pregunta.

En matemática, la retroalimentación consiste en devoluciones sobre las respuestas incorrectas, mediante animaciones o texto con locución. En hindi, los estudiantes reciben explicaciones de las palabras difíciles y se les muestra cómo usarlas en una oración. El grado de personalización de la retroalimentación varía según la pregunta: (a) en algunas preguntas, no hay retroalimentación ante las respuestas incorrectas; (b) en otras, todos los estudiantes reciben la misma retroalimentación ante una respuesta incorrecta; y (c) en otras, los estudiantes reciben distintos tipos de retroalimentación según la respuesta incorrecta que hayan seleccionado.

Los algoritmos que determinan la retroalimentación adecuada y la instrucción posterior que siguen a un patrón determinado de errores se basan en análisis de datos de los errores de los estudiantes, en entrevistas a estudiantes realizadas por los especialistas en educación de EI para comprender las concepciones erróneas y en investigaciones publicadas sobre pedagogía. Todas las decisiones del software respecto de qué contenidos ofrecer tras la clasificación de los errores están, por ahora, ‘programadas de forma fija’. Mindspark no emplea actualmente ningún algoritmo de aprendizaje automático (aunque la base de datos ofrece un potencial significativo para el desarrollo de este tipo de herramientas).

Además de su naturaleza adaptativa, el software Mindspark permite que el personal del centro brinde a los estudiantes una ‘inyección’ de ítems sobre un tema determinado si considera que un estudiante necesita repasar ese tema. Sin embargo, una vez que el estudiante completa esta inyección, el software vuelve al ítem que se estaba completando cuando se aplicó la inyección y retoma su naturaleza adaptativa.

Figura D.1: Adaptabilidad de Mindspark en matemática

Ejemplo de tecnología que posibilita el aprendizaje personalizado de decimales





Figura D.2: Errores de los estudiantes en matemática

¿Por qué algunos estudiantes pensarían...?



Apéndice E Diseño de las pruebas

E.1 Panorama general

Medimos el logro de los estudiantes, que es el principal resultado de nuestra evaluación, mediante evaluaciones independientes de matemática y de hindi. Estas pruebas se administraron bajo la supervisión del equipo de investigación tanto en la línea de base como en la línea final. Aquí presentamos detalles sobre el contenido y la elaboración de las pruebas, su administración y su puntuación.

E.2 Objetivos del diseño de las pruebas

El diseño de nuestras pruebas se guio por tres objetivos principales. El primero fue elaborar una prueba que fuera informativa en un amplio rango de logro. Dado que los estudiantes podían estar muy por debajo de los niveles de logro adecuados para su grado, los cuadernillos de prueba incluyeron ítems que iban desde competencias muy básicas propias de la escuela primaria hasta ítems más difíciles, más cercanos a los estándares adecuados para el grado.

Nuestro objetivo secundario fue asegurar que midiéramos un constructo amplio de logro que incluyera tanto habilidades curriculares como la capacidad de aplicarlas en problemas sencillos.

Nuestro tercer objetivo, relacionado con el anterior, fue asegurar que la prueba constituyera una referencia justa para juzgar la adquisición real de habilidades de los estudiantes. En respuesta a esta necesidad, las pruebas se administraron en papel y lápiz y no en computadoras, para no confundir los aumentos en el logro real con una mayor familiaridad con las computadoras en el grupo de tratamiento. Además, los ítems se tomaron de una amplia variedad de evaluaciones independientes que se detallan más abajo, y el equipo de investigación los seleccionó sin consultar a Education Initiatives, para asegurar que la selección de ítems no fuera susceptible de “enseñar para la prueba” en la intervención.

E.3 Contenido de las pruebas

Buscamos evaluar una amplia gama de habilidades. Las pruebas de matemática van desde cálculos aritméticos simples hasta la interpretación más compleja de datos de gráficos y de ejemplos contextualizados, como en las evaluaciones PISA. Las evaluaciones de hindi incluyeron algunos ítems “fáciles”, como relacionar imágenes con palabras, o ítems de tipo Cloze, que requieren que los estudiantes completen una oración con la palabra faltante. La mayor parte de la evaluación se concentró en la comprensión lectora, que se evaluó mediante la lectura de pasajes de dificultad variable y la respuesta a preguntas que podían pedir a los estudiantes recuperar información explícita o realizar inferencias más complejas a partir de lo que habían leído. En consonancia con nuestro énfasis en medir habilidades funcionales, muchos de los pasajes se plantearon como tareas de la vida real (p. ej., un artículo periodístico,

un afiche de vacunación o un aviso escolar) para medir la capacidad de los estudiantes de completar tareas habituales.

En ambas materias, armamos las pruebas con ítems de acceso público provenientes de una amplia variedad de evaluaciones de investigación. En matemática, las pruebas se basaron en ítems de las evaluaciones de 4.^o y 8.^o grado del Trends in Mathematics and Science Study (TIMSS), del Programme for International Student Assessment (PISA) de la OCDE, de las evaluaciones de estudiantes de Young Lives administradas en cuatro países, entre ellos la India, del Andhra Pradesh Randomized Studies in Education (APRESt), y de los estudios con sede en la India Student Learning Survey (SLS) y Quality Education Study (QES); en conjunto, estas se cuentan entre las pruebas más validadas a nivel internacional y en el contexto indio.

En hindi, las pruebas utilizaron ítems administrados por el Progress in International Reading Literacy Study (PIRLS) y de Young Lives, SLS y PISA. Estos ítems, disponibles públicamente solo en inglés, se tradujeron y adaptaron al hindi.

E.4 Cuadernillos de prueba

Elaboramos múltiples cuadernillos tanto en la línea de base como en la línea final para ambas materias. En la evaluación de línea de base, se elaboraron cuadernillos separados para los estudiantes de los grados 4-5, de los grados 6-7 y de los grados 8-9. En la evaluación de línea final, dado el número muy bajo de estudiantes de los grados 4-5 en la muestra del estudio, se administró un único cuadernillo a los estudiantes de los grados 4-7 y un cuadernillo separado a los estudiantes de los grados 8-9. Es importante señalar que se mantuvo una superposición sustancial entre los cuadernillos de los distintos grados y entre las evaluaciones de línea de base y de línea final. Esta superposición se mantuvo en ítems de todos los niveles de dificultad para permitir una vinculación robusta mediante la teoría de respuesta al ítem (IRT). La Tabla E.1 presenta un desglose de las preguntas por nivel de dificultad según el grado en cada uno de los cuadernillos de la línea de base y de la línea final.

Los cuadernillos de prueba se pusieron a prueba antes de la línea de base y los ítems se seleccionaron según su capacidad para discriminar el logro entre los estudiantes en este contexto. Además, antes de finalizar la prueba de línea final se realizó un análisis detallado de todos los ítems administrados en la línea de base, para asegurar que el subconjunto de ítems seleccionados para repetirse en la línea final tuviera un buen desempeño en términos de discriminación y estuviera distribuido a lo largo del rango de habilidad de nuestra muestra. La Tabla E.2 presenta el número de ítems comunes que se mantuvieron entre los cuadernillos de prueba administrados.

E.5 Puntuación de las pruebas

Todos los ítems administrados fueron preguntas de opción múltiple, cuyas respuestas se calificaron de forma dicotómica como correctas o incorrectas. Las pruebas se puntuaron mediante modelos de teoría de respuesta al ítem (IRT).

Los modelos IRT especifican una relación entre una única variable latente subyacente de logro (“habilidad”) y la probabilidad de responder correctamente una pregunta determinada de la prueba (“ítem”). Si bien son estándar en la literatura sobre evaluaciones internacionales para generar puntajes comparables, el uso de modelos IRT es mucho menos frecuente en la literatura sobre economía de la educación en países en desarrollo (para excepciones notables, véanse Das and Zajonc (2010), Andrabi et al. (2011), Singh (2015)). Para una introducción detallada a los modelos IRT, véanse van der Linden and Hambleton (2013) y Das and Zajonc (2010).

El uso de modelos IRT ofrece ventajas importantes en una aplicación como la nuestra, especialmente en comparación con la práctica habitual de presentar puntajes de porcentaje de respuestas correctas o puntajes brutos normalizados. En primer lugar, permite que los ítems contribuyan de manera diferenciada a la medida de habilidad subyacente; esto es particularmente importante en pruebas como las nuestras, en las que los ítems más difíciles son significativamente más complejos que los más fáciles de la prueba.

En segundo lugar, nos permite vincular de manera robusta todos los puntajes en una métrica común, incluso con un conjunto de preguntas solo parcialmente superpuesto, utilizando un conjunto de ítems comunes entre dos evaluaciones cualesquiera como ítems “ancla”. Esto resulta especialmente ventajoso al aplicar pruebas en muestras con diferencias posiblemente grandes en el logro medio (pero con un soporte común sustancial en el logro), ya que permite adaptar las pruebas al nivel de dificultad de cada muestra y, aun así, expresar el puntaje de cada individuo en una única métrica continua. Esto es particularmente importante en nuestra aplicación, pues nos permite calcular el valor agregado en condiciones habituales en el grupo de control.⁴⁹

En tercer lugar, los modelos IRT también ofrecen un marco para evaluar el desempeño de cada ítem de la prueba de forma individual, lo que resulta ventajoso para diseñar pruebas que incluyan una combinación adecuada de ítems de dificultad variable pero de alta discriminación.

Utilizamos el modelo logístico de 3 parámetros para puntuar las pruebas. Este modelo plantea la relación entre el logro subyacente y la probabilidad de responder correctamente una pregunta determinada como una función de tres características del ítem: la dificultad del ítem, la discriminación del ítem y el parámetro de pseudoadivinación. Esta relación está dada por:

$$P_g(\theta_i) = c_g + \frac{1 - c_g}{1 + \exp(-1.7 \cdot a_g \cdot (\theta_i - b_g))} \quad (3)$$

⁴⁹Los puntajes IRT solo están identificados hasta una transformación lineal. Sin vincular explícitamente los puntajes de la línea de base y de la línea final, el término constante de nuestras regresiones de valor agregado (que interpretamos como el valor agregado en el grupo de control) confundiría la transformación lineal arbitraria con el valor agregado en el grupo de control.

donde i indexa a los estudiantes y g indexa las preguntas de la prueba. θ_i es el logro latente (habilidad) del estudiante, P es la probabilidad de responder correctamente la pregunta g , b_g es el parámetro de dificultad y a_g es el parámetro de discriminación (pendiente de la ICC en b). c_g es el parámetro de pseudoadivinación, que tiene en cuenta que, con preguntas de opción múltiple, incluso quienes tienen la menor habilidad pueden responder correctamente algunas preguntas.

Dada esta relación paramétrica entre la habilidad (latente) y las características de los ítems, esta relación puede formularse como un problema de máxima verosimilitud conjunta que utiliza la matriz de $N \times M$ respuestas de los estudiantes para estimar $N + 3M$ parámetros desconocidos. Los puntajes se generaron con el software OpenIRT para Stata, desarrollado por Tristan Zajonc. En el análisis utilizamos estimaciones de máxima verosimilitud del logro de los estudiantes, que son medidas individuales insesgadas de la habilidad (los resultados son similares si, en cambio, se utilizan puntajes bayesianos de esperanza a posteriori).

E.6 Distribución empírica de los puntajes

La Figura E.1 presenta el porcentaje de respuestas correctas en matemática y en hindi en la línea de base y en la línea final. Muestra que las pruebas ofrecen una medida del logro bien distribuida, con pocos estudiantes que no pueden responder ninguna pregunta o que responden correctamente todas las preguntas. Esto confirma que nuestras medidas de logro son informativas a lo largo de todo el rango de logro de los estudiantes en este contexto.

La Figura E.2 presenta gráficos similares para la distribución de los puntajes IRT. Cabe señalar que los puntajes brutos de porcentaje de respuestas correctas de la Figura E.1 no son comparables entre rondas ni entre cuadernillos debido a la distinta composición de las preguntas de la prueba, pero los puntajes IRT utilizados en el análisis sí lo son.

E.7 Ajuste de los ítems

En los modelos IRT, se supone que la relación paramétrica entre la habilidad subyacente y las características de los ítems es invariante entre individuos (lo que en la literatura psicométrica se denomina ausencia de funcionamiento diferencial de los ítems). Una verificación intuitiva del desempeño del modelo IRT consiste en evaluar el ajuste empírico de los datos a las características estimadas de los ítems.

La Figura E.3 grafica la curva característica del ítem (ICC) estimada para cada ítem de las evaluaciones de línea final de matemática y de hindi, junto con el ajuste empírico para los grupos de tratamiento y de control por separado. El ajuste de los ítems es en general bastante bueno y no hay indicios de funcionamiento diferencial de los ítems (DIF) entre los grupos de tratamiento y de control. Esto indica que los efectos estimados del tratamiento no reflejan

una relación (espuria) inducida por un desempeño diferencial del modelo de medición en los grupos de tratamiento y de control.

Figura E.1: Distribución de los puntajes brutos de porcentaje de respuestas correctas




Figura E.2: Distribución de los puntajes IRT, por ronda y condición de tratamiento







Figura E.3: Curvas características de los ítems: Hindi



Curvas características de los ítems

Hindi




Todos los grados combinados

Figura E.4: Curvas características de los ítems: Matemática

Curvas características de los ítems


Matemática



Todos los grados combinados

Curvas características de los ítems


Matemática



Todos los grados combinados

Curvas características de los ítems

Matemática



Todos los grados combinados

Tabla E.1: Distribución de las preguntas por dificultad según el nivel de grado en los cuadernillos de prueba

Cuadernillos						
		Línea de base			Línea final	
Matemática						
		G4-5	G6-7	G8-9	G4-7	G8-9
Número de preguntas	G2	2	0	0	2	0
por nivel de grado	G3	14	6	4	6	6
	G4	13	7	4	9	8
	G5	4	10	3	10	10
	G6	1	10	10	5	6
	G7	1	2	11	2	3
	G8	0	0	3	0	2
Hindi						
		G4-5	G6-7	G8-9	G4-7	G8-9
Número de preguntas	G2	5	2	1	1	0
por nivel de grado	G3	3	4	2	1	1
	G4	7	3	3	8	8
	G5	8	7	2	5	6
	G6	0	2	3	11	11
	G7	0	5	9	0	4
	G8	7	7	7	4	0
	G9	0	0	3	0	0

Nota: Cada celda presenta el número de preguntas por nivel de grado del contenido en los cuadernillos de prueba. Las pruebas se diseñaron para captar un amplio rango de logro de los estudiantes y, por lo tanto, no se limitaron a ítems adecuados para el grado. El nivel de grado de las preguntas se estableció ex post con la ayuda de un experto en currículo.

Tabla E.2: Distribución de las preguntas comunes entre los cuadernillos de prueba

Matemática				
	LB G6-7	LB G8-9	LF G4-7	LF G8-9
LB G4-5	16	10	14	14
LB G6-7		15	10	10
LB G8-9			7	7
LF G4-7				31

Hindi				
	LB G6-7	LB G8-9	LF G4-7	LF G8-9
LB G4-5	18	10	11	9
LB G6-7		17	13	13
LB G8-9			9	8
LF G4-7				24

Nota: Cada celda presenta el número de preguntas en común entre los cuadernillos de prueba. Los ítems comunes entre cuadernillos se utilizan para anclar las estimaciones IRT del logro de los estudiantes en una métrica común.