

¿Qué estudiantes se benefician de la enseñanza individualizada por computadora?

Evidencia experimental de un software de matemáticas en escuelas públicas de la India *

Andreas de Barros[†]
Massachusetts Institute of Technology

Alejandro J. Ganimian[‡]
New York University

Resumen

Este es uno de los primeros estudios que evalúa el impacto de la enseñanza individualizada por computadora en un país en desarrollo. Asignamos aleatoriamente a 1,528 estudiantes de los grados 6-8 de 15 escuelas públicas “modelo” de Rajasthan, India, que usaban un software de aprendizaje adaptativo por computadora, a: un grupo de control, en el que solo podían acceder a las actividades correspondientes al grado en el que estaban matriculados; o un grupo de tratamiento, en el que podían acceder a ejercicios adecuados a su nivel de desempeño. Después de nueve meses, la enseñanza individualizada por computadora tuvo un efecto promedio nulo sobre el desempeño en matemáticas. Sin embargo, los estudiantes del grupo de tratamiento con bajo desempeño inicial superaron a sus pares del grupo de control por 0.22 desviaciones estándar. Nuestros resultados sugieren que la enseñanza individualizada por computadora es más beneficiosa para los estudiantes de bajo desempeño.

Códigos JEL: C93, I21, I22, I25

* Agradecemos el financiamiento que la Douglas B. Marshall, Jr. Family Foundation otorgó a este proyecto. Agradecemos especialmente a Karthik Muralidharan por su participación como colaborador en las primeras etapas de este proyecto y por las discusiones posteriores. Agradecemos a Pranav Kothari, Aarthi Muralidharan, Sridhar Rajagopalan, Maulik Shah, Nishchal Shukla y Gayatri Vaidya por hacer posible este estudio. También agradecemos a Anuja Venkatachalam por su excelente asistencia de investigación y apoyo en el trabajo de campo. Este estudio se registró en el AEA Trial Registry (RCT ID: AEARCTR-0002459). Se aplican los descargos de responsabilidad habituales. Los autores declaran no tener conflictos de interés.

^{††} Investigador posdoctoral, Departamento de Economía, Massachusetts Institute of Technology. Correo electrónico: debarros@mit.edu.

^{‡‡} Profesor adjunto de Psicología Aplicada y Economía, New York University Steinhardt School of Culture, Education, and Human Development. Correo electrónico: alejandroganimian@nyu.edu.

Palabras clave: aprendizaje asistido por computadora, India, enseñanza individualizada por computadora, enseñanza de las matemáticas

Existe cada vez más evidencia de que, en muchos países en desarrollo, los escolares están rezagados respecto del desempeño esperado para su nivel de grado, de que la brecha entre el desempeño esperado y el real se amplía durante la educación primaria y de que existe una variación considerable en la preparación de los estudiantes para la escuela dentro de cada grado (véase, por ejemplo, Andrabi et al., 2007; Das & Zajonc, 2010; Duflo et al., 2011; Pritchett & Beatty, 2015; Muralidharan et al., 2019). Se espera que este patrón se agrave por los recientes cierres de escuelas debidos a la pandemia en curso (Azevedo et al., 2020; Kaffenberger, 2020; Kaffenberger & Pritchett, 2020; Angrist et al., 2021).

Los sistemas educativos han buscado abordar la heterogeneidad en la preparación de los estudiantes para la escolarización de dos maneras principales: pidiendo a los docentes que ofrezcan enseñanza diferenciada (es decir, que dividan a los estudiantes en grupos según su desempeño dentro del aula y les asignen actividades adaptadas a cada grupo) o mediante el aprendizaje adaptativo por computadora (es decir, dando a los estudiantes acceso a un software que se ajusta dinámicamente a su nivel y ritmo de aprendizaje). La enseñanza individualizada—conocida en algunos círculos como “enseñanza al nivel adecuado”—ha mejorado el aprendizaje de los estudiantes cuando se implementa según lo previsto, pero los docentes a menudo se han mostrado reacios a integrar esta modalidad en sus clases habituales (presumiblemente, porque compite con las presiones que enfrentan para completar currículos ambiciosos y preparar a los estudiantes para exámenes de alto impacto; véase, p. ej., Banerjee et al., 2007; Banerjee et al., 2010; Banerjee et al., 2017). El aprendizaje adaptativo por computadora (CAL) también ha arrojado resultados prometedores, pero los múltiples componentes que suelen combinar los

productos de software CAL dificultan entender el papel que desempeña la enseñanza individualizada en su efectividad (véase, p. ej., Banerjee et al., 2007; Muralidharan et al., 2019; Muralidharan & Singh, 2020).

Para avanzar el conocimiento existente sobre cómo abordar la heterogeneidad en la preparación de los estudiantes para el aprendizaje, realizamos una evaluación aleatorizada para investigar si la enseñanza individualizada, cuando se ofrece mediante un software CAL, mejora el desempeño. En concreto, en el presente artículo, presentamos una de las primeras estimaciones experimentales del efecto de la enseñanza individualizada por computadora sobre el desempeño en matemáticas en un país en desarrollo, usando un producto de software (llamado “Mindspark”) que, según estudios previos, mejora los puntajes en pruebas estandarizadas tanto cuando se ofrece antes o después del horario escolar como durante este (Muralidharan et al., 2019; Muralidharan & Singh, 2020). A diferencia de esas evaluaciones previas, que estimaron el efecto del software Mindspark en su conjunto—incluida, aunque no exclusivamente, la función de enseñanza individualizada—, la nuestra aísla esta función. Se centra en si el hecho de que a los estudiantes diagnosticados como rezagados respecto de las expectativas curriculares se les presente material que debían haber aprendido en grados anteriores mejora su desempeño en pruebas de matemáticas. Asignamos aleatoriamente a estudiantes de los grados 6 a 8 de escuelas públicas “modelo” (que atienden zonas desfavorecidas pero seleccionan a los estudiantes mediante exámenes de ingreso) que tenían acceso a un software CAL para aprender matemáticas a: (a) un grupo de control, en el que solo podían acceder a las actividades correspondientes al grado en el que estaban *matriculados*; o (b) un grupo de tratamiento, en el que se les asignaron ejercicios adecuados a su nivel de preparación individual.

Presentamos tres conjuntos principales de resultados. Primero, como se ha mostrado en otros contextos, los niveles de aprendizaje de la mayoría de los estudiantes estaban varios niveles por debajo de las expectativas para su grado (según una prueba diagnóstica que todos los estudiantes debían rendir al ingresar por primera vez al software). Así, los estudiantes de nuestro contexto, al igual que los de muchos países de ingresos bajos y medios, podían beneficiarse considerablemente de la enseñanza individualizada.

Segundo, la enseñanza individualizada por computadora tuvo un efecto positivo, pero estadísticamente no significativo, sobre el desempeño en matemáticas del estudiante *promedio* de nuestra muestra. En relación con el grupo de control, el grupo de tratamiento obtuvo 0.05 desviaciones estándar (DE) más en evaluaciones independientes de matemáticas, pero esta diferencia no fue estadísticamente significativa. De hecho, según el intervalo de confianza del 95%, podemos descartar efectos inferiores a -0.02 DE y superiores a 0.13 DE. Además, encontramos que los efectos se mantienen cercanos a cero incluso con niveles muy altos de exposición a la intervención. Para poner estos efectos en contexto, el primer ensayo de eficacia del software CAL que usamos para evaluar el efecto de la enseñanza individualizada por computadora encontró que el programa completo (incluido, aunque no exclusivamente, el componente de enseñanza individualizada) mejoró los puntajes en pruebas de matemáticas en 0.59 DE en matemáticas y 0.36 DE en hindi después de solo 4.5 meses (Muralidharan et al., 2019). Si la enseñanza individualizada realmente impulsara estas mejoras, parece razonable esperar efectos muy superiores a 0.13 DE después de 9 meses de interacción con el software, incluso considerando las diferencias en el muestreo y la dosis.

Tercero, la enseñanza individualizada por computadora tuvo un efecto positivo para los estudiantes de bajo desempeño (es decir, los del cuartil inferior de la distribución del desempeño

en matemáticas en la línea de base dentro del grado) del grupo de tratamiento, quienes superaron a sus pares del grupo de control por 0.22 DE en la evaluación de matemáticas que desarrollamos. Este efecto sigue siendo estadísticamente significativo al nivel del 10% después de tener en cuenta las pruebas de hipótesis múltiples. También estimamos el efecto de la intervención sobre su rango percentil en la prueba diagnóstica que los estudiantes completan al ingresar por primera vez a la plataforma CAL y encontramos evidencia adicional de un efecto de interacción entre la intervención y el desempeño en la línea de base. Estos efectos no son estadísticamente significativos una vez que tenemos en cuenta las pruebas de hipótesis múltiples, pero son consistentes con los efectos que observamos en la prueba que diseñamos.

El resto del artículo se estructura de la siguiente manera. La sección 1 revisa la literatura sobre el CAL en general y sobre la enseñanza individualizada mediada por tecnología en particular. La sección 2 presenta el contexto, el diseño del estudio y la intervención. La sección 3 describe los datos. La sección 4 discute la estrategia empírica. La sección 5 presenta los resultados. La sección 6 discute las implicaciones para la investigación y las políticas.

1. Investigación previa

Las evaluaciones experimentales y cuasiexperimentales previas de intervenciones de tecnología educativa en países desarrollados y en desarrollo indican que, si bien proporcionar a los estudiantes hardware gratuito (p. ej., computadoras portátiles) en general ha tenido efectos nulos—y en algunos casos, *negativos*—sobre su desempeño (véase, p. ej., Angrist & Lavy, 2002; Leuven et al., 2007; Barrera-Orsorio & Linden, 2009; Malamud & Pop-Eleches, 2011; Fairlie & Robinson, 2013; Beuermann et al., 2015; Cristia et al., 2017), ofrecerles oportunidades de interactuar con software educativo—a menudo, como complemento de la enseñanza dirigida por el docente—por lo general ha tenido resultados más alentadores. En concreto, el software que se

centra en que los estudiantes repasen el material enseñado por su docente en una semana determinada tradicionalmente ha producido mejoras de pequeñas a moderadas en los puntajes de las pruebas y/o las calificaciones escolares (véase, p. ej., Lai et al., 2012; Lai et al., 2013; Mo et al., 2014; Lai et al., 2015; Mo et al., 2015; Mo et al., 2016), mientras que el software que ofrece cierto grado de diferenciación o enseñanza individualizada ha producido mejoras de moderadas a grandes en el desempeño (véase Banerjee et al., 2007; Muralidharan et al., 2019; Muralidharan & Singh, 2020). Esta investigación sugiere que las innovaciones tecnológicas que abordan deliberadamente una restricción determinante para el aprendizaje de los estudiantes (p. ej., la heterogeneidad en la preparación de los estudiantes para la escolarización) tienen muchas más probabilidades de éxito.

Sin embargo, las evaluaciones de productos de software no pueden identificar causalmente el efecto de ninguna función individual. Cada producto que incluye una función de enseñanza individualizada también incluye muchas otras funciones, como contenido de alta calidad revisado por expertos pedagógicos, retroalimentación sobre respuestas incorrectas, oportunidades de práctica independiente y elementos tanto “basados en juegos” (p. ej., laberintos) como “gamificados” (p. ej., tablas de clasificación). Cada función puede afectar el desempeño de manera positiva (p. ej., la práctica independiente puede reforzar el conocimiento procedimental de los estudiantes; véase de Barros et al., 2022) o negativa (p. ej., la gamificación puede aumentar la ansiedad de los estudiantes; véase Araya et al., 2019) e interactuar con otra función de maneras que refuercen o contrarresten sus efectos. Una evaluación de un producto de software capta la suma de todos esos efectos principales y de interacción.

Hasta donde sabemos, nuestro estudio es el primero en evaluar experimentalmente el efecto de la enseñanza individualizada mediada por tecnología en un país en desarrollo (es decir,

en asignar aleatoriamente a los estudiantes a una versión del software en la que se incluye esta función o a otra en la que se excluye). Solo otro estudio adoptó un diseño similar, pero se realizó en un país desarrollado (véase Van Klaveren et al., 2017). Evaluar experimentalmente el impacto de la enseñanza individualizada en países de ingresos bajos y medios es particularmente importante porque los estudiantes de esos contextos tienen muchas más probabilidades que sus pares de países de ingresos altos de estar rezagados respecto de los estándares curriculares y de presentar variación en su desempeño (véase, p. ej., MIA, 2015; Uwezo, 2019; ASER Pakistan, 2020; ASER, 2021). Así, la enseñanza individualizada por computadora aborda una restricción al aprendizaje que es más determinante en el mundo en desarrollo.

En teoría, la enseñanza individualizada por computadora debería beneficiar a todos los estudiantes por igual. Si un software ajusta la dificultad del material presentado a cada estudiante de manera *dinámica* (es decir, en función del desempeño de ese estudiante en cada conjunto de actividades), podría mejorar su desempeño al presentarle actividades que se basen en lo que comprende y subsanen sus lagunas. De hecho, esto es lo que sugieren las evaluaciones previas de productos de software que incluyen enseñanza individualizada. Tanto Banerjee et al. (2007) como Muralidharan et al. (2019) encuentran que dos productos con distintos niveles de diferenciación tuvieron efectos comparables para estudiantes de bajo y alto desempeño en la India.

Sin embargo, la evidencia existente también indica que la calidad de la enseñanza contrafactual importa. Muralidharan et al. (2019) señalan que, si bien el software que evaluaron en Delhi, India, produjo mejoras *absolutas* similares para los estudiantes a lo largo de la distribución del desempeño, los estudiantes del tercio inferior de la distribución obtuvieron mejoras *relativas* mayores que los del tercio superior, ya que los estudiantes del grupo de control

en este grupo no mejoraron en absoluto durante los 4.5 meses de la evaluación. Del mismo modo, Linden (2008) encontró que el mismo software que había producido mejoras de moderadas a grandes cuando fue evaluado por Banerjee et al. (2007) en escuelas públicas de Gujarat, India, tuvo efectos nulos cuando se implementó en una red de escuelas que funcionaba bien, administrada por una organización sin fines de lucro en el mismo estado. Este patrón de resultados sugiere que la enseñanza individualizada tiene un mayor margen de impacto para los estudiantes de bajo desempeño cuando la enseñanza dirigida por el docente no logra atender las necesidades de estos estudiantes. En este estudio, investigamos dicha individualización en el contexto del aprendizaje adaptativo por computadora y prestamos especial atención a los estudiantes más rezagados.

2. Experimento

Contexto

La escolarización en la India es obligatoria y gratuita desde los 6 hasta los 14 años (MLJ, 2009). La educación primaria abarca de los grados 1 a 5 y la primaria superior, de los grados 6 a 8. En el año escolar 2016-2017, el sistema educativo indio incluía 840,241 escuelas primarias, 287,265 escuelas de primaria superior y 48,543 escuelas primarias con grados de secundaria (NIEPA, 2018). Ese mismo año, las escuelas del gobierno (es decir, públicas) atendían a casi un tercio de los estudiantes de los grados de educación elemental (111,310,953 estudiantes, o el 59% de la matrícula total).

Realizamos este estudio en colaboración con Educational Initiatives (EI), una empresa de evaluación líder en el país que desarrolló el software CAL que usamos para asignar aleatoriamente a los estudiantes a la enseñanza individualizada (descrito con mayor detalle en la subsección Intervención). Establecimos esta colaboración como un proyecto plurianual para

aprovechar tanto el amplio banco de ítems del software CAL en matemáticas y otras materias como su alto grado de penetración en todo el país, con el fin de usar experimentos aleatorizados para responder preguntas de importancia para los educadores. La colaboración, denominada Learning Lab, fue dirigida por Karthik Muralidharan, de la Universidad de California en San Diego, y Sridhar Rajagopalan, de EI, y financiada por la Douglas B. Marshall, Jr. Family Foundation. Fuimos coinvestigadores principales de este proyecto.

Realizamos este estudio en el estado de Rajasthan, que es un contexto ideal para comprender el efecto de intervenciones que podrían ampliarse al resto de la India. Primero, representa una proporción considerable del territorio y la población del país: es el estado más grande en superficie y el séptimo más grande en población (MHA, 2012). Segundo, es un estado mayormente rural, al igual que el resto del país: tres cuartas partes de sus habitantes viven en zonas rurales. Tercero, su nivel educativo es muy similar al del resto de la India rural: en 2018, solo el 25% de los estudiantes de sexto grado podía restar un número de dos dígitos de otro número de dos dígitos y apenas el 29% podía dividir un número de tres dígitos entre un número de dos dígitos, frente al 24% y el 35% de los estudiantes de sexto grado en toda la India rural (ASER, 2018).

En concreto, realizamos nuestro estudio en escuelas públicas “modelo”, creadas en 2009 por el Ministry of Human Resource Development del gobierno central para promover la educación en zonas rurales. Se diferencian de las escuelas públicas regulares en cinco aspectos principales: se centran en zonas desfavorecidas del estado (en lugar de todo el estado), solo abarcan los grados 6 a 12 (en lugar de los grados 1 a 12), su lengua de instrucción es el inglés (en lugar de la lengua local), siguen un currículo establecido por el gobierno nacional (en lugar del definido por el gobierno estatal) y exigen que los estudiantes aprueben un examen de ingreso

para ser admitidos (Kumar, 2020). En 2017, el año de nuestro estudio, había 134 escuelas modelo en Rajasthan; de hecho, 303 (64%) de todos los “bloques” (es decir, subdivisiones de los distritos) del estado tenían al menos una escuela modelo. Estas escuelas eran adecuadas para nuestro estudio porque deben cumplir requisitos de infraestructura (p. ej., suministro eléctrico, conectividad a Internet y laboratorios de computación) y de enseñanza (p. ej., docentes de informática de tiempo completo y horarios semanales para clases de informática) que facilitan la implementación de un software educativo.

Sin embargo, las mismas características que hacen que las escuelas modelo sean propicias para nuestra intervención también limitan la generalización de nuestros hallazgos. Debido a que se centran en estudiantes que han completado la primaria, que hablan y escriben en inglés y que pueden aprobar un examen de ingreso, estas escuelas probablemente atienden a estudiantes no solo con un desempeño promedio más alto, sino también con menos variabilidad en su desempeño que las escuelas públicas tradicionales. Por lo tanto, la contribución potencial de la enseñanza individualizada por computadora para el *estudiante promedio* en estas escuelas probablemente sea menor, dado que la enseñanza individualizada busca abordar la heterogeneidad en la preparación de los estudiantes. Además, debido en parte a sus estándares curriculares y de infraestructura, estas escuelas pueden ofrecer a los estudiantes más oportunidades de aprender que las escuelas públicas tradicionales. Así, el potencial de la enseñanza individualizada mediada por tecnología para mejorar el aprendizaje de los estudiantes probablemente sea más limitado, dado que busca compensar la ausencia de estrategias de enseñanza diferenciada por parte de los docentes. Dicho de otro modo, el impacto promedio de la enseñanza individualizada mediada por tecnología podría ser mayor en las escuelas públicas tradicionales.

Muestra

La muestra del estudio incluyó a 1,528 estudiantes de los grados 6 a 8 de 15 escuelas públicas modelo en siete distritos de Rajasthan: Alwar, Bhilwara, Bundi, Dungarpur, Jodhpur, Rajsamand y Udaipur (véase la Figura A.1 en el Anexo A). Seleccionamos las escuelas según tres criterios: (a) debían tener edificios completamente construidos; (b) debían tener espacio para un laboratorio de computación; y (c) debían tener suministro eléctrico. En teoría, el gobierno estatal exige que todas las escuelas modelo cumplan estos tres requisitos (véase la subsección anterior), pero en la práctica no siempre es así. Las 15 escuelas aceptaron participar. Solicitamos el consentimiento informado de los directores y docentes de esas escuelas.

La deserción de la muestra del estudio no fue desdeñable: 1,078 (o el 71%) de los 1,528 estudiantes que participaron en las evaluaciones de línea de base también rindieron las evaluaciones de medición final. Sin embargo, no encontramos evidencia de deserción diferencial por grupo experimental: el 28% de los estudiantes del grupo de control y el 31% de los estudiantes del grupo de tratamiento que estuvieron presentes en la línea de base no rindieron la medición final, y la diferencia entre los grupos no es estadísticamente significativa. Para verificar que nuestro patrón de resultados no se vea afectado por la deserción de la muestra, incluimos tanto estimaciones ponderadas por probabilidad inversa (IPW) como cotas de Lee (2009).

Aleatorización

Asignamos aleatoriamente a los 1,528 estudiantes de nuestra muestra a: (a) un grupo de control, en el que los estudiantes solo podían acceder a las actividades de un software de aprendizaje asistido por computadora (CAL) correspondientes a su nivel de grado de *matrícula* (762 estudiantes); o (b) un grupo de tratamiento, en el que a los estudiantes se les asignaron ejercicios adecuados a su nivel de preparación individual, en una amplia gama de niveles de

grado, con base en una prueba diagnóstica (766 estudiantes).¹ Describimos las diferencias entre los grupos en la sección de Intervención. Para maximizar la comparabilidad entre los grupos experimentales, asignamos aleatoriamente a los participantes a los grupos experimentales a nivel del estudiante (en lugar de a nivel de la escuela o del aula) y estratificamos la aleatorización dentro de cada combinación de escuela, grado y sección (p. ej., un sorteo incluyó a los estudiantes de la escuela 1, grado 6 y sección “A”). Los directores, los docentes y los estudiantes desconocían la condición experimental de cada estudiante.

Es posible, aunque muy poco probable, que con esta estrategia de aleatorización los docentes noten que los estudiantes del grupo de tratamiento están mejorando gracias a esta intervención y adopten un comportamiento compensatorio reforzando su enseñanza a los estudiantes del grupo de control. En primer lugar, para que esto ocurra, los docentes tendrían que saber cómo evolucionaron los niveles de aprendizaje de sus estudiantes durante el año escolar. Sin embargo, los docentes en la India estiman erróneamente las habilidades de los estudiantes de su aula por un amplio margen: según un estudio reciente en el estado de Maharashtra, el 84% de los docentes de los grados 5 y 6 sobreestimó el desempeño de sus estudiantes en una evaluación independiente de matemáticas; de hecho, el docente promedio estimó erróneamente el puntaje de sus estudiantes en 24 puntos porcentuales, o el 126% de la desviación estándar dentro del aula en el desempeño en matemáticas (Djaker et al., 2022). En segundo lugar, para que esto ocurra, los docentes tendrían que adoptar estrategias de enseñanza diferentes para los estudiantes de bajo desempeño. Sin embargo, es ampliamente sabido que los docentes en la India rara vez atienden las necesidades de sus estudiantes. Las observaciones de aula han mostrado sistemáticamente que estos docentes usan los mismos materiales para todos los estudiantes y dedican la mayor parte de sus clases a enfoques dirigidos a toda el aula (Bhattacharjea et al., 2011; Sankar &

Linden, 2014; Ganimian et al., 2022). Esto es precisamente lo que hace necesaria la enseñanza diferenciada o individualizada en este contexto (Ganimian & Djaker, 2022). En tercer lugar, para que esto ocurra, los docentes tendrían que identificar a los estudiantes de los grupos de tratamiento y de control. Sin embargo, los docentes desconocen los grupos experimentales y todos los estudiantes interactúan con el software.

La aleatorización de los estudiantes dentro de la misma aula maximiza el poder estadístico, pero su principal desventaja es que permite efectos indirectos entre los estudiantes de la misma aula. En teoría, si los estudiantes del grupo de tratamiento (que tuvieron acceso a la intervención) trabajan junto con los estudiantes del grupo de control (que no tuvieron acceso a la intervención) en ejercicios de matemáticas, las comparaciones entre tratamiento y control podrían subestimar el efecto de la intervención sobre el desempeño en matemáticas de los primeros (si transfirieran parte de su conocimiento a los segundos).

Creemos que estos efectos indirectos son posibles, pero es poco probable que constituyan una preocupación importante. La función de enseñanza individualizada del software educativo beneficia a cada estudiante al presentarle material que aborda las brechas en su conocimiento y los errores conceptuales subyacentes (véase el Anexo D de Muralidharan et al., 2019). Por lo tanto, para que los efectos indirectos compensen las diferencias entre los estudiantes de los grupos de tratamiento y de control, tendrían que cumplirse tres condiciones. En primer lugar, los estudiantes de los grupos de tratamiento y de control tendrían que trabajar juntos con regularidad—algo que rara vez ocurre en las observaciones de aula en la India (véase, p. ej., Bhattacharjea et al., 2011; Sankar & Linden, 2014; Sinha et al., 2016; World Bank, 2016a). En segundo lugar, el estudiante del grupo de tratamiento y el estudiante del grupo de control tendrían que tener brechas de conocimiento y/o errores conceptuales similares—algo que contradice la amplia

dispersión de los niveles de grado de las actividades que presenta la plataforma en cualquier día dado (que mostramos en la Figura 3 y discutimos en la sección de Resultados). En tercer lugar, los estudiantes del grupo de tratamiento tendrían que ser (aproximadamente) tan eficaces para abordar los errores conceptuales de sus compañeros del grupo de control como lo es la función de enseñanza individualizada del software con los estudiantes del grupo de tratamiento—algo que desmienten no solo la experiencia y los 10 años de iteración invertidos en el diseño del software, sino también la evidencia sobre el aprendizaje entre pares en los países en desarrollo (véase, p. ej., Beuermann et al., 2013; Berlinski & Busso, 2017).

Los estudiantes de los grupos de control y de tratamiento eran comparables en su desempeño en la línea de base y en su sexo, ya sea que consideremos a todos los estudiantes presentes en la línea de base o solo a quienes también rindieron la evaluación de medición final (es decir, quienes permanecieron en la muestra; véase la Tabla 1). De hecho, no solo las medias, sino también la distribución del desempeño en la línea de base fue similar entre los grupos experimentales (véase la Figura A.2).

Intervención

Proporcionamos a todos los estudiantes de nuestro estudio un software CAL llamado “Mindspark”, centrado en la enseñanza de matemáticas. El software también puede ofrecer enseñanza de lengua, pero esta función se desactivó en nuestro estudio. Fue desarrollado por Educational Initiatives (EI), una empresa líder en evaluación en la India, a lo largo de un período de 10 años. Lo han usado más de 500,000 estudiantes, cuenta con una base de datos de más de 45,000 preguntas y administra más de 2 millones de preguntas entre sus usuarios cada día. Puede implementarse durante la jornada escolar, antes o después de la escuela en centros independientes, y a través de una plataforma en línea autoguiada. La versión extraescolar se

evaluó recientemente mediante un experimento aleatorizado, que encontró que mejora enormemente el desempeño en matemáticas y lectura de estudiantes de primaria y secundaria básica en Delhi (Muralidharan et al., 2019). La versión escolar, que es la que usamos en el presente estudio, se está evaluando actualmente en Rajasthan. Sus impactos son menores que los de la versión extraescolar, pero son proporcionales a la menor dosis que reciben los estudiantes en este modelo, que además se logra a menores costos (Muralidharan & Singh, 2020).

En el presente estudio, no nos interesa evaluar el impacto del software; en cambio, lo usamos para estimar el efecto de su función de enseñanza individualizada sobre el desempeño en matemáticas de los estudiantes. El software funciona de la siguiente manera. Cuando los estudiantes inician sesión por primera vez, se les pide que rindan una breve prueba diagnóstica, que identifica lo que saben y son capaces de hacer, así como las áreas en las que pueden mejorar. Esta prueba también determina el nivel de grado en el que el estudiante puede responder la mayoría de las preguntas, que puede coincidir o no con su grado de matrícula (p. ej., un estudiante puede estar *matriculado* en el grado 6, pero *desempeñarse* al nivel del grado 4). Luego, el software presenta al estudiante una serie de ejercicios sobre temas adecuados para su nivel de preparación, con base en la prueba diagnóstica. La dificultad y el tema de los ejercicios posteriores se ajustan dinámicamente al progreso de cada estudiante (p. ej., a un estudiante que responde correctamente la mayoría de los ejercicios se le pueden presentar ejercicios más difíciles, mientras que a un estudiante que responde los ejercicios incorrectamente se le pueden presentar ejercicios más fáciles, e incluso se le puede redirigir a ejercicios de nivelación). En este estudio, restringimos temporalmente los ejercicios a los que podían acceder los estudiantes del grupo de control a aquellos asociados con su nivel de grado de matrícula. Los estudiantes interactuaron con el software en sus laboratorios de computación, con la ayuda de un “encargado

del laboratorio”, que abría y mantenía los laboratorios de computación (es decir, no su docente de matemáticas). Este diseño nos permite estimar el efecto de que los estudiantes puedan acceder a ejercicios más alineados con su preparación.

Es importante señalar que la versión del software CAL que se ofreció a los estudiantes del grupo de control se asemeja a la mayoría de los productos de software educativo que se han evaluado en países en desarrollo, que se usan para que los estudiantes practiquen lo que aprenden en la escuela en una semana determinada y, por lo tanto, se centran en el contenido prescrito para su nivel de grado de matrícula (véase, p. ej., Carrillo et al., 2011; Lai et al., 2012; Lai et al., 2013; Mo et al., 2014; Lai et al., 2015; Mo et al., 2015; Mo et al., 2020). De hecho, esta versión del software también se asemejaba a la enseñanza habitual dirigida por docentes en la India, donde las observaciones de aula han encontrado que los docentes usan los mismos materiales y enfoques pedagógicos para todos los estudiantes, independientemente de su nivel de preparación (Bhattacharjea et al., 2011; Sankar & Linden, 2014; Sinha et al., 2016; World Bank, 2016b). Esta versión permite cierto grado de enseñanza individualizada dentro de materiales adecuados para el grado, pero a los estudiantes no se les presenta material de grados inferiores, sin importar cuán atrasado esté su desempeño. Por ejemplo, si a un estudiante del grupo de control se le introducen las fracciones y tiene dificultades, se le puede pedir que avance más despacio y repase materiales adicionales del nivel de su grado. Sin embargo, no estaría expuesto a materiales de nivelación de grados inferiores, como unidades de aprendizaje centradas en el sentido numérico básico (un posible prerequisite para aprender fracciones). Esta característica de nuestro estudio nos permite arrojar luz sobre la posible contribución de la función de enseñanza individualizada al aprendizaje asistido por computadora.

Algunos de los productos de software educativo que se han evaluado en países en desarrollo incluyen cierto grado de enseñanza individualizada (p. ej., Banerjee et al., 2007; Linden, 2008). Sin embargo, el amplio banco de ítems y las trayectorias de aprendizaje del software CAL que usamos en este estudio ofrecen un mayor grado de individualización de la enseñanza, tanto del contenido como de la dificultad del material.

3. Datos

Recolectamos dos tipos principales de datos: (a) el desempeño de los estudiantes, antes y después de la intervención, para verificar la equivalencia en la línea de base y estimar el impacto; y (b) el uso del software CAL por parte de los estudiantes y su interacción con la intervención, para verificar la fidelidad de la implementación. Complementamos estos datos con información administrativa sobre el grado y el sexo de los estudiantes (sin embargo, no aplicamos una encuesta a los estudiantes).

Desempeño de los estudiantes

Aplicamos evaluaciones de matemáticas a los estudiantes en la línea de base (antes de la intervención) y en la medición final (aproximadamente nueve meses después del inicio de la intervención). Estas evaluaciones midieron lo que los estudiantes deberían saber y ser capaces de hacer según estándares internacionales, e incluyeron tres dominios de contenido (números, figuras geométricas y medición, y visualización de datos) y tres dominios cognitivos (conocer, aplicar y razonar). La distribución de los ítems entre los dominios de contenido y cognitivos se basó en el marco de evaluación del Estudio de las Tendencias en Matemáticas y Ciencias (TIMSS) de 2019 para el grado 4 (IEA, 2017).

Cada prueba tenía 35 ítems de opción múltiple. Recurrimos a ítems de evaluaciones internacionales (p. ej., TIMSS, PISA, Young Lives), evaluaciones nacionales (p. ej., Quality

Education Study, Student Learning Survey) y evaluaciones de impacto previas en la India (p. ej., los Andhra Pradesh Randomized Studies in Education o APRESt). Incluimos ítems de una amplia gama de dificultad para reducir la posibilidad de que hubiera estudiantes que no respondieran correctamente ninguna pregunta y estudiantes que respondieran correctamente todas las preguntas. Diseñamos una única evaluación para todos los grados del estudio (es decir, los grados 6 a 8) en cada ronda (es decir, línea de base y medición final), que incluía ítems de una amplia variedad de niveles de grado (es decir, de los grados 3 al grado 8), para asegurarnos de poder captar impactos sobre los resultados de aprendizaje en habilidades fundamentales. Creamos tres versiones de la evaluación en la línea de base y cuatro versiones en la medición final para evitar que los estudiantes se copiaran.²

Para ubicar las evaluaciones de línea de base y de medición final en la misma escala, usamos un diseño de prueba de anclaje no equivalente (NEAT) (véase Kolen & Brennan, 2004). Incluimos 11 ítems en común entre ambas rondas de evaluación (lo que se conoce como “prueba de anclaje”) y luego ajustamos un modelo logístico de dos parámetros de la Teoría de Respuesta al Ítem (TRI), que tiene en cuenta las diferencias de dificultad y de “discriminación” (la capacidad de distinguir entre examinados con un desempeño por lo demás similar) entre los ítems (Yen & Fitzpatrick, 2006), combinando los datos de ambas rondas de evaluación. Este proceso ubica los resultados de la línea de base y de la medición final en una escala común.

Es importante señalar que las evaluaciones de línea de base se aplicaron aproximadamente dos semanas *después* de que se activara el software en las escuelas del estudio, por lo que, en teoría, los puntajes de línea de base de los estudiantes podrían reflejar lo que aprendieron al usar Mindspark durante esas dos semanas iniciales. En la práctica, sin embargo, el estudiante promedio estuvo expuesto al software solo 21 minutos durante este período, por lo

que consideramos poco probable que haya producido cambios significativos en el desempeño de los estudiantes en matemáticas. (Discutimos con mayor detalle la exposición de los estudiantes al programa durante el estudio en la sección de Resultados). Además, como mostramos más adelante, nuestras estimaciones de impacto permanecen prácticamente sin cambios cuando no controlamos por el desempeño en la línea de base, lo que sugiere que es poco probable que esto sea una preocupación importante.

Interacción de los estudiantes con el software

También obtuvimos datos sobre la interacción de los estudiantes con el software CAL. Estos incluyen: (a) la preparación inicial de los estudiantes (a partir de la prueba diagnóstica, descrita en la subsección de Intervención); (b) el tiempo que los estudiantes dedicaron a interactuar con el software en cada sesión (a partir de la plataforma CAL, donde podemos vincular a los estudiantes con las sesiones mediante sus credenciales de acceso únicas); (c) el nivel de dificultad de los ejercicios que se les presentaron (comparado por los desarrolladores del software con el desempeño esperado en cada grado); (d) el tiempo que cada estudiante tardó en intentar cada ejercicio; y (e) si respondió correctamente cada ejercicio.

4. Estrategia empírica

Estimamos el efecto de la oferta de enseñanza individualizada por computadora (es decir, el efecto de la “intención de tratar” o ITT) ajustando el siguiente modelo:

$$Y_{igs}^t = \alpha_{r(gs)} + \beta T_{igs} + \theta Y_{igs}^{t-1} + \epsilon_{igs}^t, \quad (1)$$

donde Y_{igs}^t es el desempeño en matemáticas del estudiante i en el grado y sección g y la escuela s en el momento t (medición final), $r(gs)$ es el estrato de aleatorización del grado y sección g y la escuela s y $\alpha_{r(gs)}$ es un efecto fijo de estrato, T_{igs} es una variable indicadora de la asignación aleatoria al tratamiento, y Y_{igs}^{t-1} es el desempeño en matemáticas en el momento $t - 1$ (línea de

base). El parámetro de interés es β , que capta el efecto causal de la intervención. Ajustamos variantes de este modelo en las que interactuamos la variable dicotómica de tratamiento con el grado, el sexo y el desempeño en la línea de base de los estudiantes (continuo o por cuartil dentro del grado) para comprender si la intervención fue más útil para algunos subgrupos de estudiantes. También interactuamos la variable dicotómica de tratamiento con las tres características de los estudiantes que observamos en la línea de base (es decir, sexo, grado y desempeño inicial) para probar la existencia de efectos heterogéneos. Especificamos previamente estos análisis en el American Economics Association's Trial Registry (RCT ID: AEARCTR-0002459). Por último, como se mencionó en la sección anterior, también usamos estimaciones IPW y cotas de Lee (2009) para mostrar que la deserción de la muestra no altera nuestro patrón general de resultados.

5. Resultados

Fidelidad de la implementación

La intervención se implementó en gran medida según lo previsto. En primer lugar, prácticamente todos los estudiantes de ambos grupos experimentales (1,069 de 1,078 estudiantes, o el 99.2%) iniciaron sesión al menos una vez en la plataforma CAL durante la evaluación. Sin embargo, el tiempo total que los estudiantes dedicaron a interactuar con el software fue relativamente bajo: el estudiante típico (es decir, en el percentil 50 de la distribución de uso) interactuó con el software CAL durante 329 minutos a lo largo de los nueve meses de la intervención (Figura 1). Este nivel de exposición es considerablemente menor que el de la versión extraescolar del programa evaluada en Delhi (Muralidharan et al., 2019), pero refleja las limitaciones que enfrentan las escuelas para integrar este software en su enseñanza regular (p. ej., disponibilidad de aulas y computadoras, coordinación entre los horarios de los docentes, tiempo

perdido al llevar a los estudiantes al laboratorio de computación) (véase, p. ej., Ferman et al., 2019; Rodríguez-Segura, 2021).

La exposición al software varió ampliamente entre los estudiantes: los usuarios menos frecuentes (es decir, los del percentil 25 de la distribución de uso) interactuaron con el software menos de 250 minutos durante el estudio, mientras que los usuarios más frecuentes (es decir, los del percentil 75 de la distribución) tuvieron el doble de exposición, con un total de casi 500 minutos en el mismo período. La exposición también varió a lo largo del tiempo: en algunas semanas, ningún estudiante interactuó con el software, mientras que en otras el uso llegó a 30 minutos. Esta variación sugiere que nuestros resultados deben interpretarse como estimaciones de cota inferior de los efectos de la enseñanza individualizada por computadora sobre el desempeño en matemáticas, que podrían mejorarse si las escuelas aumentaran y sostuvieran el uso del software.

En el caso de los estudiantes que estuvieron expuestos al software, la evaluación diagnóstica confirmó que tenían una clara necesidad de enseñanza individualizada. Observamos dos patrones documentados en estudios previos. En primer lugar, el estudiante promedio estaba muy por debajo de las expectativas curriculares para su grado: por ejemplo, el estudiante promedio matriculado en el grado 6 se desempeñaba al nivel del grado 4 en matemáticas (Figura 2). En segundo lugar, había una amplia variabilidad en el desempeño de los estudiantes dentro de cada grado: por ejemplo, mientras que algunos estudiantes del grado 6 se desempeñaban al nivel del grado 2, otros lo hacían al nivel del grado 7 (Figura 2). Ningún docente, por eficaz que sea, podría brindar enseñanza individualizada a estudiantes con niveles de preparación tan dispares, por lo que el software CAL estaba, en teoría, bien posicionado para complementar la enseñanza dirigida por docentes.

La aleatorización de la función de enseñanza individualizada del software funcionó exactamente como se esperaba. A los estudiantes del grupo de control se les presentaron ejercicios que correspondían a su grado *de matrícula* (p. ej., los estudiantes de grado 6 solo vieron ejercicios de grado 6), mientras que a los estudiantes del grupo de tratamiento se les ofrecieron ejercicios que correspondían a su grado *diagnosticado* (p. ej., los estudiantes de grado 6 diagnosticados con un nivel de grado 3 vieron ejercicios de grado 3, véase la Figura 3).⁴ Además, mientras que a los estudiantes del grupo de control se les siguieron presentando ejercicios acordes con el nivel del grado en el que estaban matriculados, sus pares del grupo de tratamiento vieron ejercicios cada vez más difíciles durante el período de estudio (p. ej., los estudiantes de grado 7 comenzaron intentando ejercicios de nivel de grado 4; al final del experimento, completaban ejercicios de entre los grados 5 y 6, véase la Figura 4). De manera similar, mientras que los estudiantes del grupo de control intentaron ejercicios acordes con el nivel del grado en el que estaban matriculados, independientemente de su diagnóstico inicial, sus pares del grupo de tratamiento comenzaron en su nivel diagnosticado y “se graduaron” a niveles superiores (p. ej., los estudiantes diagnosticados en el grado 7 comenzaron intentando ejercicios de nivel de grado 5; al final del experimento, completaban ejercicios de nivel de grado 7, véase la Figura 5). En otras palabras, como se señaló anteriormente, el software no solo se ajustó al *nivel* inicial de preparación de los estudiantes, sino también a su *ritmo de progreso* (es decir, aumentó la dificultad más rápidamente para los estudiantes que respondieron correctamente más preguntas).

Los ejercicios que intentaron los participantes del estudio durante la evaluación se centraron en números (95% del total de ejercicios intentados), y mucho menos en geometría (4.5%) o datos (0.5%, Tabla A.1).⁴ En concreto, los temas más frecuentes fueron: conceptos de

números enteros no negativos (alrededor del 28% del total), operaciones con números enteros no negativos (19%), números reales (15%), números enteros (9%), teoría de números (8%) y álgebra básica (7%, véase la Tabla A.1). Como argumentamos más adelante, esta distribución de ejercicios ayuda a entender por qué el desempeño de los estudiantes mejoró en algunos temas y no en otros.

Efectos promedio en el desempeño en matemáticas

La oferta de la intervención tuvo un efecto nulo (de alrededor de 0.05 DE) en el desempeño en matemáticas del estudiante promedio, independientemente de si tomamos en cuenta el desempeño de los estudiantes en la línea de base en las evaluaciones que desarrollamos y aplicamos o en la propia prueba diagnóstica del software (Tabla 2). De hecho, con base en el intervalo de confianza del 95%, podemos descartar efectos inferiores a -0.02 DE y superiores a 0.13 DE. Cuando estimamos los efectos por separado según el dominio de contenido y el dominio cognitivo, observamos efectos en los ítems relacionados con datos y en los ítems en los que se pedía a los estudiantes aplicar sus conocimientos (de alrededor de 2 p.p. en ambos casos; Tabla 3, panel A). Sin embargo, ambos efectos son pequeños (inferiores a 2.3 p.p. en ambos casos), y ninguno es estadísticamente significativo una vez que tomamos en cuenta las pruebas de hipótesis múltiples con un ajuste del valor p por la tasa de error por familia (FWER) (siguiendo a List et al., 2019). Por último, aunque el efecto de la enseñanza individualizada por computadora varió entre escuelas, las diferencias entre escuelas no fueron estadísticamente significativas en ningún caso (Figura A.3). En conjunto, estos resultados sugieren que el estudiante promedio se benefició poco de la enseñanza individualizada por computadora.⁵

No encontramos evidencia de que los efectos promedio de la intervención se vieran afectados por la deserción de la muestra entre la línea de base y la medición final. En la Tabla 2,

la columna 2 muestra que nuestra estimación del efecto promedio de la intención de tratar (ITT) se mantuvo prácticamente sin cambios cuando ponderamos los resultados por el inverso de la probabilidad de que cada estudiante participara en la medición final. Además, cuando estimamos las cotas de Lee (2009), las cotas inferior y superior de los efectos del tratamiento fueron ambas positivas, pero no pudimos rechazar la hipótesis nula de que la cota inferior fuera igual a cero (véase la Tabla A.2).

Efectos heterogéneos en el desempeño en matemáticas

Los efectos promedio nulos, sin embargo, ocultaron impactos heterogéneos importantes. Investigamos si el efecto de la enseñanza individualizada por computadora difería según tres características de los estudiantes, especificadas previamente y registradas en nuestros datos: sexo, grado de matrícula y desempeño inicial. En particular, encontramos que la intervención tuvo un efecto positivo de magnitud media a grande, de 0.22 DE, en los estudiantes con un desempeño inicial bajo en matemáticas (es decir, aquellos en el cuartil inferior de la distribución del desempeño en matemáticas en la línea de base dentro del grado). Primero lo mostramos gráficamente, al graficar los efectos del tratamiento según el cuartil de los estudiantes en la línea de base (Figura 6), y luego lo demostramos analíticamente de dos maneras: tomando en cuenta el desempeño de los estudiantes en la línea de base e interactuándolo con el indicador de tratamiento, e interactuando este indicador con variables indicadoras del cuartil de desempeño en la línea de base de cada estudiante dentro del grado (Tabla 4, columnas 1 y 2, donde la primera fila refleja los efectos en el percentil inferior y en el cuartil inferior, respectivamente).⁶ Estos resultados mantienen su significancia estadística al nivel del 10%, después de tomar en cuenta las pruebas de hipótesis múltiples. También observamos este patrón cuando graficamos los efectos según el desempeño de los estudiantes en la línea de base (Figura A.4).

Para investigar si los estudiantes a quienes se diagnosticó como rezagados mejoraron más, examinamos los efectos heterogéneos según el desempeño de los estudiantes en la evaluación diagnóstica que aplicaba el software cuando los estudiantes ingresaban por primera vez (véase la subsección Intervención). Interactuamos el tratamiento con el percentil de los estudiantes dentro del grado en la prueba diagnóstica (Tabla 4, columna 3, donde la primera fila refleja los efectos en el percentil inferior), y con la diferencia entre el nivel del grado de matrícula y el nivel de grado diagnosticado de cada estudiante (Tabla 4, columna 4, donde la primera fila refleja los efectos en los estudiantes que estaban más de tres niveles de grado atrasados). Ambas especificaciones indicaron que los estudiantes con menor desempeño en matemáticas en la línea de base tuvieron efectos del tratamiento mayores que sus pares (como sugieren los coeficientes negativos del indicador de tratamiento y de los respectivos términos de interacción). Sin embargo, ni los efectos del tratamiento en los estudiantes de más bajo desempeño ni las interacciones siguieron siendo estadísticamente significativos al nivel del 10% después de tomar en cuenta las pruebas de hipótesis múltiples.

Las mejoras de los estudiantes de bajo desempeño se concentraron en un dominio de contenido (números) y en un dominio cognitivo (aplicar conocimientos; véase la Tabla 3, panel B). Este patrón no es sorprendente, dado que (como señalamos en la subsección sobre la fidelidad de la implementación), la mayoría de los ejercicios que intentaron los participantes del estudio se centraron en números (véase la Tabla A.1). Sin embargo, una vez que tomamos en cuenta las pruebas de hipótesis múltiples, solo el impacto en aplicar conocimientos conserva su significancia estadística.

Cabe destacar que los efectos en los estudiantes de bajo desempeño no fueron simplemente el resultado de “enseñar para la prueba”. Estos estudiantes mejoraron su desempeño

tanto en los ítems aplicados en la línea de base y en la medición final, en 2.8 p.p. (que llamamos “ítems repetidos”), como en los ítems que se introdujeron por primera vez en la medición final, en 6.8 p.p. (que llamamos “ítems no repetidos”; véase la Tabla A.3).

No encontramos evidencia de efectos heterogéneos según el sexo de los estudiantes: las estudiantes mujeres tuvieron un desempeño ligeramente inferior al de los estudiantes hombres (en 0.03 DE), pero la diferencia no fue estadísticamente significativa, como tampoco lo fue la interacción entre el tratamiento y el indicador de mujer (Tabla A.4). No encontramos evidencia de heterogeneidad en los efectos del tratamiento según el grado de matrícula de los estudiantes.

Efectos promedio en la interacción con el software CAL

Dado que la función de enseñanza individualizada del software puede asignar a los estudiantes ejercicios de grados inferiores o de nivelación, es posible que los lleve a completar potencialmente menos unidades en la plataforma CAL que los estudiantes del grupo de control. Esto sería problemático porque, si bien esperamos que la enseñanza individualizada por computadora tenga un impacto *positivo* en el desempeño en matemáticas de los estudiantes del grupo de tratamiento, también esperaríamos que completar menos unidades tuviera un impacto *negativo* en su desempeño, y el efecto promedio que estimamos podría confundir estas influencias contrapuestas.

Abordamos esta posibilidad de tres maneras en la Tabla A.5. Primero, estimamos el efecto de la intervención en el número de sesiones completadas en la plataforma CAL. Los estudiantes del grupo de tratamiento realizaron menos de 1% más sesiones que los estudiantes del grupo de control, pero la diferencia entre ambos no es estadísticamente significativa. Segundo, estimamos el efecto de la intervención en el tiempo total dedicado a la plataforma. Los estudiantes del grupo de tratamiento dedicaron 2.8% más minutos que los estudiantes del grupo

de control, pero, de nuevo, la diferencia no fue estadísticamente significativa. Tercero, estimamos el efecto de la intervención en el tiempo total dedicado a la plataforma, manteniendo constante el número de sesiones completadas (para estimar el efecto de la intervención en el tiempo dedicado por sesión). Por sesión, los estudiantes del grupo de tratamiento dedicaron 2.3% más minutos a la plataforma, pero la diferencia no fue estadísticamente significativa. En resumen, no vimos evidencia convincente de que la función de enseñanza individualizada del software haya frenado a los estudiantes del grupo de tratamiento.

6. Conclusión

Este artículo presenta uno de los primeros estudios que aíslan el efecto de la enseñanza individualizada por computadora en el contexto de un país en desarrollo. Después de unos nueve meses, encontramos que los estudiantes que podían acceder a ejercicios por debajo o por encima del nivel del grado en el que estaban matriculados no tuvieron, en promedio, un desempeño distinto al de quienes solo podían acceder a ejercicios del nivel del grado en el que estaban matriculados. Sin embargo, los estudiantes de bajo desempeño (es decir, aquellos que se ubicaron en el cuartil inferior de la distribución del desempeño en matemáticas de su grado en la línea de base) del grupo de tratamiento superaron a sus pares del grupo de control por 0.22 DE. Afortunadamente, estas mejoras se concentraron en los temas y las habilidades que aparecían con más frecuencia en el software. Aun así, no reflejaron “enseñar para la prueba”, dado que abarcaron tanto ítems aplicados en la línea de base y en la medición final como ítems nuevos. Estos resultados sugieren que la enseñanza individualizada mediada por tecnología importa más para los estudiantes de bajo desempeño, quienes posiblemente obtienen muy poco de ejercicios centrados en contenidos de su grado de matrícula, dado que su desempeño está varios niveles de grado por debajo de las expectativas curriculares.

Nuestro estudio hace varias contribuciones importantes. Primero, amplía nuestra comprensión, aún en desarrollo, de por qué los productos de software de aprendizaje adaptativo por computadora (CAL) podrían estar entre las intervenciones de tecnología educativa más eficaces evaluadas hasta la fecha en países en desarrollo (véase Ganimian et al., 2020). En concreto, nuestro estudio sugiere que la función de enseñanza individualizada del software Mindspark, que resultó eficaz tanto en su formato extraescolar (Muralidharan et al., 2019) como en su formato dentro de la escuela (Muralidharan & Singh, 2019), podría desempeñar un papel importante en la mejora del aprendizaje de los estudiantes de bajo desempeño. Este hallazgo es intuitivo, pero, hasta donde sabemos, no hay estudios experimentales en países en desarrollo diseñados para aislar los efectos de la enseñanza individualizada de otras características de los productos de software CAL. La gran mayoría de las evaluaciones de impacto de intervenciones de tecnología educativa en países en desarrollo se centran en estimar el efecto de productos de software multifacéticos, que incluyen la enseñanza individualizada además de muchas otras características (para revisiones, véase Bulman & Fairlie, 2016; Tauson & Stannard, 2018; Escueta et al., 2020; Rodríguez-Segura, 2021). El presente estudio es un paso muy necesario para identificar las *características* que hacen que algunos productos sean eficaces—especialmente, para los estudiantes de bajo desempeño.

Segundo, nuestro estudio también contribuye a la creciente evidencia sobre el aprendizaje diferenciado en términos más amplios, incluso cuando no se imparte mediante tecnología. En las últimas dos décadas, varias evaluaciones de impacto han encontrado que, cuando los docentes pueden enseñar a un grupo de estudiantes más homogéneo—p. ej., mediante la agrupación por nivel de habilidad (Duflo et al., 2011) o la enseñanza diferenciada dentro del aula (Banerjee et al., 2007; Banerjee et al., 2010)—, mejoran el desempeño de sus estudiantes en mayor medida

que cuando enseñan a todos sus estudiantes a la vez. En los círculos de política de desarrollo hay un consenso creciente de que esto podría deberse a que, como encontramos en nuestro estudio, muchos estudiantes en países en desarrollo tienen un desempeño muy por debajo de las expectativas curriculares de su grado y, por lo tanto, podrían beneficiarse de repasar habilidades de grados inferiores. Nuestro estudio no solo aporta evidencia que respalda esa hipótesis, sino que también arroja luz sobre la ventaja comparativa de la tecnología para ofrecer ese tipo de enseñanza individualizada.

Tercero, nuestro estudio destaca la importancia de las condiciones contrafactuales (es decir, la enseñanza habitual) en las evaluaciones de intervenciones mediadas por tecnología. En concreto, sugiere que estas intervenciones tienen un margen relativamente estrecho para impactar al estudiante promedio en contextos donde los estudiantes ya tienen un desempeño promedio más alto y una menor variabilidad en ese desempeño, y donde las escuelas tienen más recursos para ofrecer a los estudiantes más oportunidades de mejorar, como puede ser el caso de las escuelas públicas “modelo” de nuestro estudio. Sin embargo, e igual de importante, estas intervenciones pueden mejorar el desempeño de los estudiantes de bajo desempeño en estos contextos, quienes quizá no hayan alcanzado un nivel de desempeño que les permita aprovechar los beneficios de mejores pares y recursos.

Por último, nuestro estudio demuestra cómo aprovechar la creciente difusión de los productos de software educativo para realizar evaluaciones aleatorizadas de ciclo rápido que arrojen luz sobre los méritos de estrategias educativas intuitivamente atractivas, pero en gran medida no probadas. Ante todo, mostramos que es posible entender las contribuciones relativas de los componentes individuales de intervenciones de software eficaces “agrupadas” (véase Muralidharan, 2017) desactivándolos temporalmente para evaluar su contribución. Cabe destacar

que este enfoque no requiere reclutar usuarios adicionales y produce una estimación del impacto de cada componente en un período breve, lo que reduce los costos de experimentación para los desarrolladores de software. Consideramos que esta es una contribución crucial a la investigación sobre tecnología educativa, dado que muchas intervenciones evaluadas en este ámbito han arrojado resultados decepcionantes y se beneficiarían de retroalimentación para mejorar su eficacia (Ganimian et al., 2020). En términos más generales, también ilustramos cómo estas evaluaciones pueden ofrecer lecciones más amplias para la pedagogía, al documentar la necesidad y el impacto de estrategias pedagógicas específicas (en este caso, la enseñanza individualizada). En particular, evaluar estrategias mediante la tecnología puede ofrecer información valiosa sobre mecanismos importantes (en este caso, cómo el material con el que interactúan los estudiantes se acerca más a su nivel de habilidad) y sobre los efectos en subgrupos objetivo (en este caso, los estudiantes con bajo desempeño inicial), algo que es más difícil de hacer en evaluaciones de intervenciones pedagógicas presenciales.

Creemos que investigaciones adicionales sobre la enseñanza individualizada mediada por tecnología pueden complementar el presente estudio en múltiples frentes. Primero, es importante que el campo entienda si formas más rudimentarias de enseñanza individualizada por computadora, que son mucho más comunes que la función única del software Mindspark, son igual de eficaces para mejorar el aprendizaje de los estudiantes. Si bien muchos estudios afirman evaluar productos de software que incluyen algún tipo de enseñanza individualizada, la mayor parte de estos productos o bien exigen que los estudiantes alcancen cierto nivel de dominio antes de pasar a la siguiente unidad, o bien simplemente reducen la dificultad de las actividades, con poca atención a las brechas específicas en los conocimientos de los estudiantes, y mucho menos a sus concepciones erróneas subyacentes (para una revisión de las características de los

productos, véase el Anexo C de Muralidharan et al., 2019). Sospechamos que esta distinción, que a menudo se pasa por alto en las discusiones sobre la eficacia de los productos de software educativo, puede marcar una diferencia significativa en la mejora de los resultados de aprendizaje de los estudiantes. Dado que no todos los desarrolladores de software pueden contar con los recursos o los años de iteración de Educational Initiatives, el desarrollador de Mindspark, sería útil entender si funciones de enseñanza individualizada más asequibles pueden conferir beneficios similares.

Segundo, nuestro estudio ilustra la importancia de probar la eficacia de la enseñanza individualizada mediada por tecnología en distintos sistemas educativos y en distintos tipos de escuelas dentro de ellos. En concreto, esperamos que la contribución potencial de la enseñanza individualizada por computadora sea mayor en países como la India, donde existe una enorme heterogeneidad en la preparación escolar de los estudiantes (ASER, 2021). Esta heterogeneidad también está presente en otros países del sur de Asia y en naciones de África subsahariana (véase, p. ej., Uwezo, 2015, 2016, 2019; ASER Pakistan, 2020), donde la enseñanza individualizada probablemente sea igual de prometedora, pero en menor medida en otros países de ingresos bajos y medios, y parece crucial entender en qué medida el impacto de la enseñanza individualizada depende de este grado de variabilidad en el desempeño. También esperamos que el margen de impacto de la enseñanza individualizada por computadora sea mayor en las escuelas públicas tradicionales, que suelen tener estudiantes con un desempeño más bajo y más variable que las escuelas públicas “modelo” en las que realizamos nuestro estudio. En resumen, entender si la enseñanza individualizada mediada por tecnología es una medida provisional para enfrentar niveles muy altos de heterogeneidad en la preparación de los estudiantes, o un enfoque

pedagógico de utilidad más general, parece una prioridad de primer orden para la investigación en curso sobre tecnología educativa en el mundo en desarrollo.

Referencias

- Andrabi, T., Das, J., Khwaja, A. I., Vishwanath, T., & Zajonc, T. (2007). *Learning and Educational Achievements in Punjab Schools (LEAPS): Insights to inform the education policy debate*. World Bank, Washington, DC.
- Angrist, J., & Lavy, V. (2002). New evidence on classroom computers and pupil learning. *The Economic Journal*, 112(482), 735-765. doi:10.1111/1468-0297.00068
- Angrist, N., de Barros, A., Bhula, R., Chakera, S., Cummiskey, C., DeStefano, J., Floretta, J., Kaffenberger, M., Piper, B., & Stern, J. (2021). Building back better to avert a learning catastrophe: Estimating learning loss from COVID-19 school shutdowns in Africa and facilitating short-term and long-term learning recovery. *International Journal of Educational Development*, 84, 102397. Retrieved from <https://shared.rti.org/content/calculating-educational-impact-covid-19-part-ii-using-data-successive-grades-estimate>
- Araya, R., Arias Ortiz, E., Bottan, N. L., & Cristia, J. P. (2019). *Does gamification in education work?: Experimental evidence from Chile*. (IDB Working Paper No. IDB-WP-982). Inter-American Development Bank. Washington, DC.
- ASER. (2018). *Annual status of education report (ASER) 2018: Provisional*. ASER Centre. New Delhi, India.
- ASER. (2021). *Annual status of education report (ASER) 2021: Provisional*. ASER Centre. New Delhi, India.
- ASER Pakistan. (2020). *Annual Status of Education Report (ASER) Pakistan 2019: Provisional*. ASER Pakistan Secretariat. Lahore, Pakistan.
- Azevedo, J. P., Hasan, A., Goldemberg, D., Geven, K., & Iqbal, S. A. (2020). Simulating the potential impacts of Covid-19 school closures on schooling and learning outcomes: A set of global estimates. *The World Bank Research Observer*, 36(1), 1-40.
- Banerjee, A. V., Banerji, R., Berry, J., Duflo, E., Kannan, H., Mukerji, S., Shotland, M., & Walton, M. (2017). From proof to concept to scalable policies: Challenges and solutions, with an application *Journal of Economic Perspectives*, 31(4), 73-102.
- Banerjee, A. V., Banerji, R., Duflo, E., Glennerster, R., & Khemani, S. (2010). Pitfalls of participatory programs: Evidence from a randomized evaluation in education in India. *American Economic Journal: Economic Policy*, 2, 1-30. doi:10.1257/pol.2.1.1
- Banerjee, A. V., Cole, S., Duflo, E., & Linden, L. L. (2007). Remedying education: Evidence from two randomized experiments in India. *The Quarterly Journal of Economics*, 122, 1235-1264. doi:10.1162/qjec.122.3.1235
- Barrera-Orsorio, F., & Linden, L. L. (2009). *The use and misuse of computers in education: Evidence from a randomized experiment in Colombia*. (Impact Evaluation Series No. 29). The World Bank. Washington, DC.
- Berlinski, S., & Busso, M. (2017). Challenges in educational reform: An experiment on active learning in mathematics. *Economics Letters*, 156, 172-175.
- Beuermann, D. W., Cristia, J., Cruz-Aguayo, Y., Cueto, S., & Malamud, O. (2015). Home computers and child outcomes: Short-term impacts from a randomized experiment in Peru. *American Economic Journal: Applied Economics*, 7(2), 53-80.
- Beuermann, D. W., Naslund-Hadley, E., Ruprah, I. J., & Thompson, J. (2013). The pedagogy of science and environment: Experimental evidence from Peru. *The Journal of Development Studies*, 49(5), 719-736. doi:10.1080/00220388.2012.754432

- Bhattacharjea, S., Wadhwa, W., & Banerji, R. (2011). *Inside primary schools: A study of teaching and learning in rural India*. ASER. Delhi, India.
- Bulman, G., & Fairlie, R. W. (2016). *Technology and education: Computers, software, and the Internet*. (NBER Working Paper No. 22237). National Bureau of Economic Research (NBER). Cambridge, MA.
- Carrillo, P., Onofa, M., & Ponce, J. (2011). *Information technology and student achievement: Evidence from a randomized experiment in Ecuador*. (IDB Working Paper No. IDB-WP-223). Inter-American Development Bank. Washington, DC.
- Cristia, J., Ibararán, P., Cueto, S., Santiago, A., & Severín, E. (2017). Technology and child development: Evidence from the One Laptop per Child program. *American Economic Journal: Applied Economics*, 9(3), 295-320.
- Das, J., & Zajonc, T. (2010). India shining and Bharat drowning: Comparing two Indian states to the worldwide distribution in mathematics achievement. *Journal of Development Economics*, 92(2), 175-187.
- de Barros, A., Ganimian, A. J., & Venkatachalam, A. (2022). Which students benefit from independent practice? Experimental evidence from a math software in private schools in India. *Journal of Research on Educational Effectiveness*, 15(2), 279-301.
- Djaker, S., Ganimian, A. J., & Sabarwal, S. (2022). *Out of sight, out of mind? The gap between students' performance and teachers' estimations in Bangladesh and its implications for instruction*. Unpublished manuscript. Steinhardt School of Culture, Education, and Human Development, New York University. New York, NY.
- Duflo, E., Dupas, P., & Kremer, M. (2011). Peer effects, teacher incentives, and the impact of tracking: Evidence from a randomized evaluation in Kenya. *American Economic Review*, 101(5), 1739-1774. doi:10.1257/aer.101.5.1739
- Escueta, M., Nickow, A. J., Oreopoulos, P., & Quan, V. (2020). Upgrading education with technology: Insights from experimental research. *Journal of Economic Literature*, 58(4), 897-996.
- Fairlie, R. W., & Robinson, J. (2013). Experimental evidence on the effects of home computers on academic achievement among schoolchildren. *American Economic Journal: Applied Economics*, 5(3), 211-240.
- Ferman, B., Finamor, L., & Lima, L. (2019). *Are public schools ready to integrate ed-tech classes with Khan Academy?* (MPRA Paper No. 94736). Munich Personal RePEc Archive (MPRA). Munich, Bavaria.
- Ganimian, A. J., & Djaker, S. (2022). *How can developing countries address heterogeneity in students' preparation for school? A review of the challenge and potential solutions*. Unpublished manuscript. Steinhardt School of Culture, Education, and Human Development, New York University. New York, NY.
- Ganimian, A. J., Hess, F. M., & Vegas, E. (2020). *Realizing the promise: How can education technology improve learning for all?* Brookings Institution. Washington, DC.
- Ganimian, A. J., Muralidharan, K., & Walters, C. R. (2022). *Augmenting state capacity for child development: Experimental evidence from India*. (NBER Working Paper No. 28780). National Bureau of Economic Research (NBER). Cambridge, MA.
- IEA. (2017). *TIMSS 2019: Assessment frameworks*. Boston, MA: TIMSS & PIRLS International Study Center. Lynch School of Education, Boston College & International Association for the Evaluation of Educational Achievement (IEA).

- Kaffenberger, M. (2020). *Modeling the long-run learning impact of the COVID-19 learning shock: Actions to (more than) mitigate loss*. RISE Insights. Research on Improving Systems of Education (RISE).
- Kaffenberger, M., & Pritchett, L. (2020). *Failing to plan? Estimating the impact of achieving schooling goals on cohort learning*. (RISE Working Paper No. RISE-WP-20/038). Research on Improving Systems of Education (RISE). London, UK.
- Kolen, M. J., & Brennan, R. L. (2004). *Test equating, scaling, and linking*. New York, NY: Springer.
- Kumar, N. (2020). *Public school quality and student outcomes: Evidence from model schools in India*. Unpublished manuscript. University of California, San Diego. San Diego, CA.
- Lai, F., Luo, R., Zhang, L., Huang, X., & Rozelle, S. (2015). Does computer-assisted learning improve learning outcomes? Evidence from a randomized experiment in migrant schools in Beijing. *Economics of Education Review*, 47, 34-48. doi:10.1016/j.econedurev.2015.03.005
- Lai, F., Zhang, L., Hu, X., Qu, Q., Shi, Y., Qiao, Y., Boswell, M., & Rozelle, S. (2013). Computer assisted learning as extracurricular tutor? Evidence from a randomised experiment in rural boarding schools in Shaanxi. *Journal of development effectiveness*, 5(2), 208-231. doi:10.1080/19439342.2013.780089
- Lai, F., Zhang, L., Qu, Q., Hu, X., Shi, Y., Boswell, M., & Rozelle, S. (2012). *Does computer-assisted learning improve learning outcomes? Evidence from a randomized experiment in public schools in rural minority areas in Qinghai, China*. (REAP working paper No. 237). Rural Education Action Program (REAP). Stanford, CA.
- Lee, D. (2009). Training, wages, and sample selection: Estimating sharp bounds on treatment effects. *The Review of Economic Studies*, 76, 1071-1101.
- Leuven, E., Lindahl, M., Oosterbeek, H., & Webbink, D. (2007). The effect of extra funding for disadvantaged pupils on achievement. *The Review of Economics and Statistics*, 89(4), 721-736.
- Linden, L. L. (2008). *Complement or substitute? The effect of technology on student achievement in India*. Unpublished manuscript. Abdul Latif Jameel Poverty Action Lab (J-PAL). Cambridge, MA.
- List, J. A., Shaikh, A. M., & Xu, Y. (2019). Multiple hypothesis testing in experimental economics. *Experimental Economics*, 22(4), 773-793.
- Malamud, O., & Pop-Eleches, C. (2011). Home computer use and the development of human capital. *The Quarterly Journal of Economics*, 126, 987-1027. doi:10.1093/qje/qjr008
- MHA. (2012). *15th Census of India*. URL: <http://www.censusindia.gov.in/> (last accessed: February 15, 2016). Office of the Registrar General & Census Commissioner, Ministry of Home Affairs, Government of India. New Delhi, Delhi.
- MIA. (2015). *Medición independiente de aprendizajes: Porque la educación es de todos, la responsabilidad es mía*. Medición Independiente de Aprendizajes (MIA). Ciudad de México, México.
- MLJ. (2009). *The right of children to free and compulsory education act, 2009*. Ministry of Law and Justice, Government of India. New Delhi, Delhi.
- Mo, D., Bai, Y., Boswell, M., & Rozelle, S. (2016). *Evaluating the effectiveness of computers as tutors in China*. (3ie Impact Evaluation Report No. 41). International Initiative for Impact Evaluation (3ie). New Delhi, India.

- Mo, D., Bai, Y., Shi, Y., Abbey, C., Zhang, L., Rozelle, S., & Loyalka, P. (2020). Institutions, implementation, and program effectiveness: Evidence from a randomized evaluation of computer-assisted learning in rural China. *Journal of Development Economics*.
- Mo, D., Zhang, L., Luo, R., Qu, Q., Huang, W., Wang, J., Qiao, Y., Boswell, M., & Rozelle, S. (2014). Integrating computer-assisted learning into a regular curriculum: Evidence from a randomised experiment in rural schools in Shaanxi. *Journal of development effectiveness*, 6, 300-323. doi:10.1080/19439342.2014.911770
- Mo, D., Zhang, L., Wang, J., Huang, W., Shi, Y., Boswell, M., & Rozelle, S. (2015). Persistence of learning gains from computer assisted learning: Experimental evidence from China. *Journal of Computer Assisted Learning*, 31, 562-581.
- Muralidharan, K. (2017). Field experiments in education in developing countries. In A. V. Banerjee & E. Duflo (Eds.), *Handbook of field experiments (Vol. 1)*: North Holland.
- Muralidharan, K., & Singh, A. (2019). *Improving schooling productivity through computer-aided personalization: Experimental evidence from Rajasthan*. Unpublished manuscript. University of California, San Diego. San Diego, CA.
- Muralidharan, K., & Singh, A. (2020). *Improving school productivity through computer-aided instruction: Experimental evidence from Rajasthan*. Unpublished manuscript. University of California, San Diego. San Diego, CA.
- Muralidharan, K., Singh, A., & Ganimian, A. J. (2019). Disrupting education? Experimental evidence on technology-aided instruction in India. *American Economic Review*, 109(4), 1426-1460.
- NIEPA. (2018). *U-DISE flash statistics 2016-17*. National Institute of Educational Planning and Administration (NIEPA). New Delhi, India.
- Pritchett, L., & Beatty, A. (2015). Slow down, you're going too fast: Matching curricula to student skill levels. *International Journal of Educational Development*, 40, 276-288.
- Rodriguez-Segura, D. (2021). Educational technology in developing countries: A review of the evidence. *The World Bank Research Observer*.
- Sankar, D., & Linden, T. (2014). *How much and what kind of teaching is there in elementary education in India? Evidence from three states*. (South Asia Human Development Sector Report No. 67). The World Bank. Washington, DC.
- Sinha, S., Banerji, R., & Wadhwa, W. (2016). *Teacher performance in Bihar, India: Implications for education*. Washington, DC: The World Bank.
- Tauson, M., & Stannard, L. (2018). *Edtech for learning in emergencies and displaced settings*. Save the Children UK. London, UK.
- Uwezo. (2015). *2014 Tanzania annual assessment report*. Uwezo East Africa Regional Office. Nairobi, Kenya.
- Uwezo. (2016). *2015 Kenya annual assessment report*. Uwezo East Africa Regional Office. Nairobi, Kenya.
- Uwezo. (2019). *Are our children learning? Uwezo Uganda eighth learning assessment report*. Twaweza East Africa. Kampala, Uganda.
- Van Klaveren, C., Vonk, S., & Cornelisz, I. (2017). The effect of adaptive versus static practicing on student learning-evidence from a randomized field experiment. *Economics of Education Review*, 58, 175-187.
- World Bank. (2016a). *Time on task study in secondary schools: Madhya Pradesh & Tamil Nadu, 2015-2016*. Unpublished manuscript. The World Bank and Educational Initiatives. New Delhi, India.

World Bank. (2016b). *What is happening inside classrooms in Indian secondary schools? A time on task study in Madhya Pradesh and Tamil Nadu*. The World Bank. Washington, DC.

Yen, W. M., & Fitzpatrick, A. R. (2006). Item response theory. In R. L. Brennan (Ed.), *Educational measurement (4th ed.)*. Westport, CT: American Council on Education and Praeger Publishers.

Notas finales

¹ Inicialmente planeamos introducir dos grupos de tratamiento más. Sin embargo, debido a dificultades técnicas, los abandonamos poco después de la línea de base y excluimos del presente estudio a los estudiantes de esos grupos experimentales. Estas intervenciones se describen en nuestro plan de prerregistro: <https://www.socialscienceregistry.org/trials/2459>.

² Las pruebas pueden consultarse en: <https://bit.ly/3knzgaj> (línea de base) y <https://bit.ly/2E8U0mF> (medición final).


³ No tenemos forma de saber por qué el material para los estudiantes del grupo de tratamiento matriculados en algunos grados (p. ej., grado 6) se concentró en un grado inferior específico (p. ej., grado 4), mientras que el material para otros grados (p. ej., grado 8) se distribuyó entre varios grados inferiores (p. ej., grados 4 a 8). Es posible que la mayoría de los estudiantes matriculados en grados inferiores necesitaran reforzar contenidos básicos, mientras que los matriculados en grados superiores tuvieran necesidades más diversas.

⁴ La asignación de ejercicios a temas la realizó Educational Initiatives, el desarrollador del software CAL, antes del inicio del estudio. La agrupación de temas en dominios de contenido la realizamos nosotros en la etapa de análisis.

⁵ Sí encontramos un efecto estadísticamente significativo de la enseñanza individualizada por computadora en los ítems que se introdujeron por primera vez en la medición final (Tabla A.3, panel A). Sin embargo, dados todos los demás resultados, creemos que esto probablemente ocurrió por azar.


⁶ Reportamos los impactos por cuartil dentro del grado. El efecto de la intención de tratar para la *mitad* inferior de los estudiantes dentro del grado es de 0.18 DE ($p < 0.01$). El efecto respectivo para la mitad superior de los estudiantes es de -0.05 DE ($p > 0.1$).

Figura 1: Tiempo semanal y acumulado dedicado al software CAL durante el estudio




Notas: Esta figura muestra el uso semanal (panel A) y acumulado (panel B) de la plataforma CAL para el estudiante mediano, por grupo experimental. La figura incluye a todos los estudiantes observados en la línea de base y en la medición final, independientemente de si usaron el software (el 99.2% de los estudiantes lo hizo). El uso se agrupa por semanas transcurridas desde el inicio del estudio (el 6 de agosto de 2017).

Figura 2: Niveles de grado en que están matriculados los estudiantes vs. sus niveles de grado diagnosticados




Notas: Esta figura muestra el nivel estimado de desempeño de los estudiantes (determinado por el programa CAL Mindspark) frente al grado en el que están matriculados. Estos datos provienen de la prueba diagnóstica inicial y no reflejan ninguna enseñanza impartida por Mindspark. Encontramos un déficit general entre el nivel promedio alcanzado y las normas esperadas para el grado. También encontramos una amplia dispersión del desempeño de los estudiantes dentro de cada grado.

Figura 3: Personalización de la enseñanza por el software CAL, según condición de tratamiento




Notas: Esta figura muestra, por grupo de tratamiento, el nivel de grado de las actividades de aprendizaje que el sistema adaptativo por computadora asignó a los estudiantes en un solo día (poco después de activar el estudio, el 30 de agosto de 2017). Para simplificar, la figura omite los ejercicios que también están asignados a otro nivel de grado adyacente. En cada grado de matrícula, el nivel real alcanzado por los estudiantes, según la estimación del software CAL, varía ampliamente. En el grupo de tratamiento, este amplio rango se cubre mediante la personalización del contenido de enseñanza por parte del software CAL. En el grupo de control, los estudiantes solo reciben materiales acordes con el nivel de grado en el que están matriculados.

Figura 4: Actualización dinámica e individualización del contenido por computadora, por grado de matrícula y grupo experimental




Notas: Esta figura muestra, por grupo experimental, líneas suavizadas de medias locales ponderadas por kernel que relacionan el nivel de dificultad de los ejercicios que intentaron los estudiantes con la fecha de administración. Las distintas líneas reflejan el grado real de matrícula. El software se activó el 6 de agosto de 2017, pero su primer uso se registró el 10 de agosto de 2017. Para simplificar, la figura omite las actividades de aprendizaje que también están asignadas a otro nivel de grado adyacente. Nótese que también se grafican los intervalos de confianza del 95%, pero, dada la gran cantidad de datos a nuestra disposición, las estimaciones son muy precisas y los intervalos de confianza pueden ser demasiado estrechos para distinguirse visualmente.

Figura 5: Actualización dinámica e individualización del contenido por computadora, por grado diagnosticado y grupo experimental



Notas: Esta figura muestra, por grupo experimental, líneas suavizadas de medias locales ponderadas por kernel que relacionan el nivel de dificultad de los ejercicios que intentaron los estudiantes con la fecha de administración. Las distintas líneas reflejan el nivel de grado según la evaluación diagnóstica del software. Para simplificar, la figura omite las actividades de aprendizaje que también están asignadas a otro nivel de grado adyacente. Nótese que también se grafican los intervalos de confianza del 95%, pero, dada la gran cantidad de datos a nuestra disposición, las estimaciones son muy precisas y los intervalos de confianza pueden ser demasiado estrechos para distinguirse visualmente.

Figura 6: Efectos ITT heterogéneos sobre el desempeño en matemáticas en la medición final, por cuartil de desempeño en la línea de base



Notas: Esta figura muestra la heterogeneidad del efecto de la intención de tratar (ITT) de la enseñanza individualizada por computadora sobre el desempeño de los estudiantes en matemáticas en la medición final (tras 37 semanas), por cuartil dentro del grado de desempeño en la línea de base. Ambos paneles incluyen efectos fijos de estrato de aleatorización. Las barras y los bigotes muestran intervalos de confianza del 90 y del 95 por ciento, respectivamente.

Tabla 1: Pruebas de equilibrio entre grupos experimentales

	(1) Control	(2) Tratamiento	(3) Diferencia
<i>A. Distribución por grado (muestra completa)</i>			
Grado 6	0.34 [0.47]	0.33 [0.47]	
Grado 7	0.34 [0.47]	0.34 [0.48]	
Grado 8	0.32 [0.47]	0.32 [0.47]	
<i>B. Pruebas de equilibrio (muestra completa)</i>			
Puntaje en matemáticas (escalado con TRI)	0.02 [0.99]	-0.02 [1.01]	0.05 (0.04)
Puntaje en matemáticas (porcentaje de respuestas correctas)	0.58 [0.17]	0.57 [0.17]	0.01 (0.01)
Mujer	0.47 [0.50]	0.49 [0.50]	-0.02 (0.03)
Abandonó la muestra entre línea de base y medición final	0.28 [0.45]	0.31 [0.46]	-0.02 (0.02)
N (estudiantes)	762	766	1,528
<i>C. Pruebas de equilibrio (quienes permanecieron en la muestra)</i>			
Puntaje en matemáticas (escalado con TRI)	0.08 [0.99]	0.05 [1.00]	0.03 (0.05)
Puntaje en matemáticas (porcentaje de respuestas correctas)	0.59 [0.17]	0.58 [0.17]	0.01 (0.01)
Mujer	0.44 [0.50]	0.49 [0.50]	-0.05 (0.03)
N (estudiantes)	547	531	1,078

Notas: Esta tabla compara a los estudiantes de los grupos experimentales de control y de tratamiento en cuanto a su matrícula por grado y sus características: muestra la media y las desviaciones estándar correspondientes de cada variable (entre corchetes) y compara ambos grupos incluyendo efectos fijos de estrato de aleatorización, mostrando su diferencia de medias y los errores estándar correspondientes (entre paréntesis). El panel A no compara la matrícula por grado porque, debido a la estrategia de estratificación, esta es comparable entre grupos experimentales por diseño. El panel B compara el puntaje en la línea de base y el sexo de los estudiantes (las dos únicas variables recolectadas en la línea de base) para todos los estudiantes presentes en la línea de base. El panel C hace lo mismo solo para los estudiantes que estuvieron presentes en la línea de base y en la medición final (el 71% del total). * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla 2: Efecto ITT de la enseñanza individualizada por computadora sobre el desempeño en matemáticas en la medición final

	(1)	(2)	(3)	(4)	(5)
	Puntaje en matemáticas (escalado con TRI)				
Tratamiento	0.050 (0.054)	0.053 (0.055)	0.062 (0.040)	0.033 (0.045)	0.056 (0.038)
Puntaje en línea de base (est.)			0.72*** (0.024)		0.56*** (0.029)
Puntaje diagnóstico (est.)				0.61*** (0.028)	0.27*** (0.030)
¿Ajustado por IPW?	No	Sí	No	No	No
N (estudiantes)	1,078	1,078	1,078	1,068	1,068
R cuadrado	0.264	0.277	0.609	0.501	0.639
Puntaje en línea de base (C)	0.080 [0.986]	0.039 [0.995]	0.080 [0.986]	0.087 [0.984]	0.087 [0.984]
Puntaje en línea de base (T)	0.051 [0.997]	-0.024 [1.110]	0.051 [0.997]	0.053 [0.998]	0.053 [0.998]
Puntaje en medición final (C)	0.228 [0.993]	0.191 [1.021]	0.228 [0.993]	0.232 [0.995]	0.232 [0.995]
Puntaje en medición final (T)	0.255 [0.967]	0.210 [1.081]	0.255 [0.967]	0.259 [0.966]	0.259 [0.966]
Crecimiento (C)	0.148*** (0.029)	0.153*** (0.030)	0.148*** (0.029)	0.145*** (0.029)	0.145*** (0.029)

Notas: Esta tabla muestra el efecto de la intención de tratar (ITT) de la enseñanza individualizada por computadora sobre el desempeño de los estudiantes en matemáticas en la medición final (tras 37 semanas). La columna 1 muestra la diferencia simple de medias; la columna 2 pondera la estimación por la probabilidad inversa de cada estudiante de participar en la medición final; la columna 3 controla por el desempeño de los estudiantes en las evaluaciones independientes de línea de base; la columna 4 controla por el desempeño de los estudiantes en las evaluaciones diagnósticas que el software administró cuando ingresaron por primera vez; y la columna 5 controla por el desempeño de los estudiantes en la línea de base en ambas evaluaciones. La tabla también muestra el puntaje medio en matemáticas (escalado con TRI) del grupo de control (C) y del grupo de tratamiento (T), respectivamente, en la línea de base y en la medición final. La última fila muestra el crecimiento medio en el grupo de control (la diferencia entre los puntajes de la medición final y de la línea de base). Los errores estándar se muestran entre paréntesis; las desviaciones estándar, entre corchetes. Todas las estimaciones de los efectos del tratamiento incluyen efectos fijos de estrato de aleatorización. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla 3: Efecto ITT de la enseñanza individualizada por computadora sobre el desempeño en matemáticas en la medición final, por dominio de contenido y dominio cognitivo

	(1) Números	(2) Geometría	(3) Medición	(4) Conocer	(5) Aplicar	(6) Razonar
<i>A. Todos los estudiantes</i>						
Tratamiento	0.009 (0.008)	0.014 (0.010)	0.023* (0.012)	0.009 (0.008)	0.018** (0.008)	0.012 (0.014)
Puntaje en línea de base (est.)	0.122*** (0.005)	0.133*** (0.006)	0.134*** (0.007)	0.118*** (0.005)	0.124*** (0.005)	0.168*** (0.009)
N (estudiantes)	1,078	1,078	1,078	1,078	1,078	1,078
R cuadrado	0.503	0.465	0.411	0.471	0.534	0.418
Valor p ajustado por FWER	0.592	0.43	0.239	0.51	0.182	0.38
<i>B. Estudiantes de bajo desempeño</i>						
Tratamiento	0.048*** (0.018)	0.025 (0.022)	0.046* (0.026)	0.032* (0.019)	0.051*** (0.018)	0.030 (0.032)
Puntaje en línea de base (est.)	0.127*** (0.013)	0.136*** (0.016)	0.119*** (0.019)	0.121*** (0.013)	0.133*** (0.013)	0.130*** (0.023)
N (estudiantes)	1,078	1,078	1,078	1,078	1,078	1,078
R cuadrado	0.515	0.476	0.422	0.480	0.541	0.424
Valor p ajustado por FWER	0.298	0.85	0.459	0.744	0.068	0.858

Notas: Esta tabla muestra el efecto de la intención de tratar (ITT) de la enseñanza individualizada por computadora sobre el desempeño de los estudiantes en cada dominio de contenido (columnas 1-3) y cognitivo (columnas 4-6) en la medición final (tras 37 semanas). Todas las estimaciones incluyen efectos fijos de estrato de aleatorización. El panel A presenta los efectos ITT promedio entre todos los estudiantes. El panel B usa interacciones (no se muestran) para reportar los efectos ITT entre los estudiantes del cuartil inferior de su nivel de grado, según su desempeño en la evaluación de línea de base. La última fila de cada panel muestra los valores p del coeficiente de tratamiento, ajustados por pruebas de hipótesis múltiples que controlan asintóticamente la tasa de error por familia (FWER), siguiendo a List et al. (2019). Los ajustes consideran los efectos del tratamiento en todos los cuartiles, incluidos los que no se reportan en la tabla (es decir, para 24 pruebas). * significativo al 10%; ** significativo al 5%; *** significativo al 1%.


Tabla 4: Efectos ITT heterogéneos sobre el desempeño en matemáticas en la medición final, según el desempeño de los estudiantes en la línea de base

	(1)	(2)	(3)	(4)
	Puntaje en matemáticas (escalado con TRI)			
Tratamiento	0.278*** (0.085) [0.026]	0.215** (0.088) [0.081]	0.229** (0.097) [0.12]	0.192* (0.112) [0.344]
Línea de base (percentil)	0.024*** (0.001)	0.032*** (0.003)		
Tratamiento X Línea de base	-0.004*** (0.001) [0.062]			
Cuartil 2		-0.287** (0.111)		
Cuartil 3		-0.514*** (0.169)		
Cuartil 4		-0.638*** (0.235)		
Tratamiento X Cuartil 2		-0.057 (0.122) [0.943]		
Tratamiento X Cuartil 3		-0.182 (0.119) [0.548]		
Tratamiento X Cuartil 4		-0.338*** (0.118) [0.076]		
Diagnóstico (percentil)			0.021*** (0.001)	0.014*** (0.002)
Tratamiento X Diagnóstico			-0.004** (0.002) [0.184]	
Atraso de 2-3 niveles				0.359*** (0.109)
Atraso de 0-1 niveles				0.685*** (0.160)
Tratamiento X atraso de 2-3 niveles				-0.167 (0.128) [0.638]
Tratamiento X atraso de 0-1 niveles				-0.268* (0.150) [0.41]
N (estudiantes)	1,078	1,078	1,068	1,068
R cuadrado	0.599	0.606	0.491	0.498

Notas: Esta tabla muestra el efecto de la intención de tratar (ITT) de la enseñanza individualizada por computadora sobre el desempeño en matemáticas en la medición final (tras 37 semanas), según el desempeño inicial en las pruebas independientes del estudio y en la prueba diagnóstica del software. El desempeño en la línea de base se expresa dentro de cada grado, como percentiles (columna 1) y como indicadores de cuartil (columna 2). El desempeño en la prueba diagnóstica se expresa dentro de cada grado, como percentiles (columna 3) y como indicadores del número de niveles de grado de atraso (columna 4). En la columna 4, la categoría de referencia son los estudiantes con más de tres niveles de atraso. Todas las estimaciones incluyen efectos fijos de estrato de aleatorización. * significativo al 10%; ** significativo al 5%; *** significativo al 1%. Errores estándar entre paréntesis; valores p entre corchetes, ajustados por pruebas múltiples que controlan asintóticamente la tasa de error por familia (FWER), siguiendo a List et al. (2019). Los ajustes consideran de forma conservadora *todas* las pruebas (preespecificadas) de efectos heterogéneos, incluidas las de la Tabla A.5 (es decir, 16 pruebas).


Anexo A: Gráficos y tablas adicionales

Figura A.1: Mapa de los distritos y las escuelas del estudio




Notas: Esta figura muestra el estado de Rajasthan (en marrón) y la ubicación de las escuelas del estudio (en rojo).

Figura A.2: Distribución de los puntajes en matemáticas (escalados con TRI) por grupo experimental en la línea de base




Notas: Esta figura muestra la distribución de los puntajes en la evaluación de matemáticas de línea de base de los estudiantes de los grupos de control y de tratamiento. Los puntajes se escalaron con un modelo logístico de dos parámetros de la Teoría de Respuesta al Ítem (TRI). La figura incluye a todos los estudiantes presentes en la línea de base y en la medición final.

Figura A.3: Efectos ITT heterogéneos sobre el desempeño en matemáticas en la medición final, por escuela




Notas: Esta figura presenta un “gráfico de oruga” de los efectos ITT por escuela (cf. von Hippel & Bellows, 2018). Cada punto negro corresponde a la estimación puntual de una escuela determinada. Los intervalos de confianza de Bonferroni ajustan los errores estándar por pruebas de hipótesis múltiples. La línea negra continua muestra la distribución nula de los “efectos” que cabe esperar debido al error. τ es la desviación estándar de la heterogeneidad. Q se refiere al estadístico Q de Cochran, que sigue una distribución χ^2 , y p reporta el valor p correspondiente a una prueba de la hipótesis nula de ausencia de heterogeneidad. ρ estima la confiabilidad; es decir, la proporción de la varianza de las estimaciones atribuible a la heterogeneidad (y no al error). La estimación controla por el desempeño de los estudiantes en la línea de base y por efectos fijos de estrato de aleatorización.

Figura A.4: Análisis no paramétrico de los efectos del tratamiento por percentiles (dentro del grado) en la prueba de línea de base



Notas: La figura presenta gráficos suavizados de medias locales ponderadas por kernel que relacionan los puntajes de la prueba de medición final con los percentiles dentro del nivel de grado del desempeño en la línea de base, por separado para los grupos de tratamiento y de control, junto con intervalos de confianza del 95%. En aproximadamente los dos cuartiles inferiores del desempeño en la línea de base, los estudiantes del grupo de tratamiento obtienen puntajes más altos en la prueba de medición final que el grupo de control; no hay diferencias discernibles en la mitad superior de la distribución.

Figura A.5: Relación dosis-respuesta



Notas: Esta figura muestra la heterogeneidad del efecto de la intención de tratar (ITT) de la enseñanza individualizada sobre el desempeño de los estudiantes en matemáticas en la medición final (tras nueve meses) por estrato de aleatorización, para todos los estudiantes (panel A) y para los estudiantes del cuartil inferior de desempeño en la línea de base dentro de su nivel de grado (panel B). Las barras y los bigotes muestran intervalos de confianza del 90 y del 95 por ciento, respectivamente.

Tabla A.1: Número y porcentaje de ejercicios intentados por dominio de contenido y tema

Tema	(1) Número de ejercicios	(2) Porcentaje de ejercicios (del total)
<i>Panel A. Números</i>	<i>39,023</i>	<i>95.01%</i>
Conceptos de números enteros	11,414	27.79%
Operaciones con números enteros	7,964	19.39%
Números reales	6,126	14.91%
Enteros	3,700	9.01%
Teoría de números	3,322	8.09%
Álgebra básica	2,977	7.25%
Fracciones	1,769	4.31%
Decimales	1,725	4.2%
Razones y proporciones	15	0.04%
Porcentajes y matemática comercial	6	0.01%
Exponentes	5	0.01%
<i>Panel B. Geometría</i>	<i>1,863</i>	<i>4.53%</i>
Medición	1,021	2.49%
Geometría	732	1.78%
Área	104	0.25%
Volumen y área de superficie	6	0.01%
<i>Panel C. Datos</i>	<i>188</i>	<i>0.46%</i>
Probabilidad y análisis de datos	188	0.46%

Notas: La tabla muestra el número de ejercicios que los participantes del estudio de ambos grupos experimentales intentaron en el software CAL, así como el porcentaje del total que representa ese número. El panel A muestra los temas relacionados con números, el panel B los temas relacionados con geometría y el panel C los temas relacionados con datos.

Tabla A.2: Estimaciones de cotas de Lee del efecto ITT de la enseñanza individualizada sobre el desempeño en matemáticas en la medición final

	(1) Puntaje en matemáticas (escalado con TRI)
Inferior	0.023 (0.077)
Superior	0.104 (0.077)
IC 95% inferior	-0.107
IC 95% superior	0.238

Notas: Esta tabla muestra las cotas de Lee (2009) para el efecto de la intención de tratar (ITT) de la enseñanza individualizada sobre el desempeño de los estudiantes en matemáticas en la medición final (tras 37 semanas). Como variable dependiente, usamos los residuos de una regresión de los puntajes de la prueba de medición final sobre los puntajes de la prueba de línea de base y los efectos fijos de aleatorización, para que nuestro análisis de cotas sea análogo a los efectos ITT principales. Las cotas se ajustan dentro de celdas de escuela por grado. Los errores estándar analíticos se muestran entre paréntesis.

Tabla A.3: Efecto ITT de la enseñanza individualizada sobre el desempeño en matemáticas en la medición final, por ítems repetidos y no repetidos

	(1) Ítems repetidos Puntaje (proporción de respuestas correctas)	(2) Ítems no repetidos Puntaje (proporción de respuestas correctas)
<i>A. Todos los estudiantes</i>		
Tratamiento	0.008 (0.007)	0.025*** (0.009)
Puntaje en línea de base (est.)	0.125*** (0.005)	0.134*** (0.006)
N (estudiantes)	1,078	1,078
R cuadrado	0.571	0.495
<i>B. Estudiantes de bajo desempeño</i>		
Tratamiento	0.028* (0.016)	0.068*** (0.021)
Puntaje en línea de base (est.)	0.129*** (0.012)	0.126*** (0.015)
N (estudiantes)	1,078	1,078
R cuadrado	0.576	0.505

Notas: Esta tabla muestra el efecto de la intención de tratar (ITT) de la enseñanza individualizada sobre el desempeño de los estudiantes en los ítems administrados tanto en la línea de base como en la medición final (que llamamos “ítems repetidos” en la columna 1) y en los ítems que se introdujeron por primera vez en la medición final (que llamamos “ítems no repetidos” en la columna 2) tras 37 semanas. Todas las estimaciones incluyen efectos fijos de estrato de aleatorización. El panel A presenta los efectos ITT promedio entre todos los estudiantes. El panel B usa interacciones (no se muestran) para reportar los efectos ITT entre los estudiantes del cuartil inferior de su nivel de grado, según su desempeño en la evaluación de línea de base. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.4: Efectos ITT heterogéneos de la enseñanza individualizada sobre el desempeño en matemáticas en la medición final, por sexo y grado de matrícula de los estudiantes

	(1)	(2)
	Puntaje en matemáticas (escalado con TRI)	
Tratamiento	0.054	0.017
	(0.055)	(0.065)
	[0.88]	[0.937]
Puntaje en línea de base (est.)	0.72***	0.72***
	(0.025)	(0.024)
Estudiante mujer	-0.031	
	(0.058)	
Tratamiento X Mujer	0.021	
	(0.082)	
	[0.81]	
Tratamiento X Grado 7		0.078
		(0.093)
		[0.918]
Tratamiento X Grado 8		0.064
		(0.10)
		[0.936]
N (estudiantes)	1,078	1,078
R cuadrado	0.609	0.609

Notas: Esta tabla muestra el efecto de la intención de tratar (ITT) de la enseñanza individualizada sobre el desempeño de los estudiantes en matemáticas en la medición final (tras 37 semanas) para las estudiantes mujeres (columna 1) y para los estudiantes matriculados en distintos grados (columna 2). Todas las estimaciones incluyen el desempeño en la línea de base y efectos fijos de estrato de aleatorización (es decir, de grado) (no se muestran los coeficientes). Errores estándar entre paréntesis; valores p entre corchetes, ajustados por pruebas de hipótesis múltiples que controlan asintóticamente la tasa de error por familia (FWER), siguiendo a List et al. (2019). Los ajustes consideran de forma conservadora *todas* las pruebas (preespecificadas) de efectos heterogéneos, incluidas las documentadas en la Tabla 4 (es decir, para 16 pruebas). * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.5: Efecto ITT de los ejercicios de práctica sobre el uso de la plataforma CAL

	(1) Número de sesiones completadas (log)	(2) Total de minutos dedicados a la plataforma CAL (log)	(3)
Tratamiento	0.008 (0.026)	0.028 (0.025)	0.023 (0.017)
Puntaje en línea de base	0.062*** (0.016)	0.055*** (0.015)	0.012 (0.011)
Número de sesiones completadas (log)	-	-	0.695*** (0.021)
N (estudiantes)	1,069	1,069	1,069
R cuadrado	0.695	0.798	0.905

Notas: Esta tabla muestra el efecto de la intención de tratar (ITT) de los ejercicios de práctica sobre el (logaritmo natural del) número de sesiones que completaron los estudiantes (columna 1), sobre el (logaritmo natural de los) minutos que dedicaron a la plataforma CAL (columna 2) y sobre ese mismo número manteniendo constante el número de sesiones completadas (columna 3). Todas las estimaciones incluyen efectos fijos de estrato de aleatorización. Las estimaciones excluyen a nueve estudiantes que no dedicaron tiempo alguno al software. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Lee, D. (2009). Training, wages, and sample selection: Estimating sharp bounds on treatment effects. *The Review of Economic Studies*, 76, 1071-1101.

List, J. A., Shaikh, A. M., & Xu, Y. (2019). Multiple hypothesis testing in experimental economics. *Experimental Economics*, 22(4), 773-793.

von Hippel, P. T., & Bellows, L. (2018). How much does teacher quality vary across teacher preparation programs? Reanalyses from six states. *Economics of Education Review*, 64, 298-312.