

¿Qué estudiantes se benefician de la práctica independiente?

Evidencia experimental de un software de matemática en escuelas privadas de la India*

Andreas de Barros[†]
Alejandro Ganimian[‡]
Anuja Venkatachalam[§]

23 de mayo de 2021

Resumen

Este estudio es una de las primeras evaluaciones de la práctica independiente (es decir, autoguiada) en matemática en un país en desarrollo. Asignamos aleatoriamente a 4,461 estudiantes de 4.º a 7.º grado de escuelas privadas “no subvencionadas” de siete ciudades de la India, que usaban un software de aprendizaje asistido por computadora, a: (a) un grupo de control, en el que pasaban de una unidad a la siguiente al completarla; o (b) un grupo de tratamiento, en el que debían completar ejercicios de práctica antes de avanzar al siguiente tema. Después de seis meses, la práctica adicional tuvo un efecto nulo, estimado con precisión, sobre el rendimiento en matemática del estudiante promedio. Sin embargo, los estudiantes del grupo de tratamiento con bajo rendimiento inicial superaron a sus pares del grupo de control por 0.14 desviaciones estándar (DE). Nuestros resultados sugieren que la práctica independiente puede ayudar a estudiantes de escuelas privadas de familias relativamente acomodadas que necesitan ponerse al día con sus pares.

Palabras clave: aprendizaje asistido por computadora, India, enseñanza de la matemática, ejercicios de práctica, escuelas privadas

Clasificación JEL: C93, I21, I22, I25

Preinscripción del estudio: Preinscrito en el AEA RCT Trial Registry (AEARCTR-0002455)

*Agradecemos el financiamiento otorgado por la Douglas B. Marshall, Jr. Family Foundation para este proyecto. Agradecemos especialmente a Karthik Muralidharan por su participación como colaborador en las primeras etapas de este proyecto y por las conversaciones posteriores. Agradecemos a Pranav Kothari, Aarthi Muralidharan, Sridhar Rajagopalan, Maulik Shah, Nishchal Shukla y Gayatri Vaidya por hacer posible este estudio. Se aplican las salvedades habituales. Los autores declaran no tener conflictos de interés.

[†]Investigador posdoctoral asociado, Departamento de Economía, Massachusetts Institute of Technology. Correo electrónico: debarros@mit.edu.

[‡]Profesor asistente de Psicología Aplicada y Economía, New York University Steinhardt School of Culture, Education, and Human Development. Correo electrónico: alejandro.ganimian@nyu.edu

[§]Periodista de datos, DataLEADS. Correo electrónico: anujav04@gmail.com

Existe un amplio consenso entre los educadores de matemática sobre la importancia de la práctica para los estudiantes de primaria y secundaria básica (véase Woodward y col. 2012). Sin embargo, el tipo de práctica que ha demostrado ser eficaz suele estar precedido por un grado considerable de andamiaje por parte de los docentes, ya sea mediante “listas de tareas” con pasos específicos (véase, p. ej., Hohn y Frey 2002; Verschaffel y col. 1999), listas de verificación de “autocuestionamiento” (p. ej., A. K. Jitendra y col. 1998; Asha K. Jitendra y col. 2011) o procesos (Cardelle-Elawar 1990, 1995; King 1991; Kramarski y Mevarech 2003; Mevarech y Kramarski 2003). Se sabe mucho menos sobre la práctica “independiente” (es decir, autoguiada), que no necesariamente se vincula con estrategias metacognitivas específicas que les brindan a los estudiantes una estructura para pensar cómo abordar un tipo de problema. Este tipo de práctica cobra cada vez más importancia con la llegada del coronavirus, que de repente exigió que los estudiantes asumieran un papel más independiente en su educación.

Más específicamente, todavía sabemos muy poco sobre si la práctica independiente (y, de ser así, cómo) afecta de manera distinta a estudiantes con diferentes niveles de preparación para la escolaridad. La mayoría de las evaluaciones de intervenciones basadas en la práctica citadas arriba no estiman efectos heterogéneos según el rendimiento en la línea de base, y muchas de las que sí lo hacen carecen de poder estadístico suficiente para detectarlos, por lo que ha sido difícil interpretar los efectos nulos de las interacciones entre las intervenciones y el rendimiento inicial de los estudiantes. Ex ante, no está claro qué esperar. Por un lado, los niños de bajo rendimiento podrían beneficiarse de aprender a su propio ritmo, y la práctica independiente podría permitirles hacerlo. En consonancia con esto, múltiples evaluaciones de impacto de la práctica mediada por software en estos contextos han encontrado sistemáticamente efectos positivos pequeños a moderados sobre el rendimiento de los estudiantes (véase, p. ej., Bettinger y col. 2020; Lai y col. 2013; Lai y col. 2015; Lai y col. 2016; Mo y col. 2015; Pitchford 2015). Por otro lado, estos niños suelen estar varios grados por detrás de las expectativas curriculares, por lo que la práctica adicional podría no ser tan útil como el trabajo remedial centrado en desarrollar habilidades fundamentales y corregir concepciones erróneas. Esa podría ser la razón por la cual el software que se ajusta dinámicamente al desempeño de cada estudiante ha producido efectos sobre el rendimiento aún mayores que el software que repasa el material cubierto en la escuela durante una semana determinada (p. ej., A. V. Banerjee y col. 2007a; Muralidharan, Singh y Ganimian 2019).

Este artículo presenta uno de los primeros estudios sobre los efectos de la práctica independiente mediada por tecnología en un país en desarrollo. Durante el año escolar 2017-2018, nos asociamos con una empresa de evaluación educativa en India para asignar aleatoriamente a 4,461 estudiantes de 4.º a 7.º grado de escuelas privadas “no subvencionadas” (es decir, financiadas de manera independiente) en siete ciudades indias que usaban un software de aprendizaje asistido por computadora (CAL) a: (a) un grupo de control, en el que los estudiantes completan un conjunto de “ejercicios de aprendizaje” (que presentan conceptos nuevos) sobre un tema determinado de matemática (p. ej.,

operaciones con fracciones) y luego pasan al tema siguiente; o (b) un grupo de tratamiento, en el que los estudiantes también completan los ejercicios de aprendizaje, pero luego deben completar un conjunto de “ejercicios de práctica” (que buscan desarrollar el conocimiento procedimental) antes de pasar al tema siguiente. En concreto, dado que los ejercicios de práctica eran una funcionalidad del software, los desactivamos para los estudiantes del grupo de control durante el período del estudio, siguiendo estudios previos que infieren el efecto de una política o programa examinando las consecuencias de su discontinuación (Argys y col. 2020; Chyn 2018; Dynarski 2003; Fishman y col. 2017; Nakajima 2020). Más adelante discutimos en mayor detalle las implicancias de este enfoque para nuestra pregunta de investigación.

Podemos verificar que la intervención se implementó mayormente según lo previsto: durante los seis meses del estudio, el estudiante mediano de ambos grupos experimentales interactuó con el software CAL durante más de 700 minutos, y los estudiantes del grupo de tratamiento interactuaron con los ejercicios de práctica durante más de 60 minutos. Los estudiantes podían usar el software durante o después del horario escolar, pero la mayor parte del uso ocurrió en el hogar (66% en promedio durante el estudio), lo que lo hace especialmente relevante para el contexto actual de la pandemia. Los tres temas en los que los estudiantes intentaron más ejercicios de práctica fueron: medición (14% de todos los ejercicios intentados), fracciones (10%) y números (9.1%). Además, la interacción con el software se mantuvo relativamente constante durante el estudio—por lo general, los estudiantes usaron el software entre 20 y 40 minutos por semana. En conjunto, los estudiantes del grupo de tratamiento intentaron casi medio millón de ejercicios de práctica.

Reportamos dos conjuntos principales de resultados. Primero, tras seis meses, encontramos que los ejercicios de práctica tuvieron un efecto nulo, estimado con precisión, sobre el rendimiento en matemática, medido mediante una prueba independiente diseñada por el equipo de investigación (no por los desarrolladores del software): el estudiante promedio del grupo de tratamiento obtuvo un desempeño 0.01 desviaciones estándar (DE) superior al de su par del grupo de control, y la diferencia no fue estadísticamente significativa. Podemos descartar efectos positivos mayores a 0.06 DE (según el límite superior del intervalo de confianza del 95% de la estimación). De hecho, observamos efectos estimados sistemáticamente en torno a cero en todos los temas y habilidades de la evaluación. Además, no observamos ninguna relación entre la cantidad de ejercicios de práctica completados por el estudiante promedio y su rendimiento en matemática.

Sin embargo, estos impactos promedio ocultan efectos heterogéneos no triviales. Los estudiantes con bajo rendimiento inicial (es decir, aquellos en el cuartil inferior de la distribución del rendimiento en matemática en la línea de base dentro de cada grado) superaron a sus pares del grupo de control por 0.14 DE ($p < 0.01$). De hecho, mejoraron en dos de los tres dominios de contenido (números y geometría) y en los tres dominios cognitivos (conocer, aplicar y razonar) evaluados en la prueba de línea final. Examinamos si los estudiantes de bajo rendimiento que pasan más tiempo en el software y hacen más ejercicios de práctica obtienen mejores resultados, pero, para nuestra sorpresa, no

encontramos que sea así. No encontramos efectos heterogéneos estadísticamente significativos según la escuela, el grado o el sexo de los estudiantes.

Este estudio hace varias contribuciones clave a la investigación sobre el aprendizaje de los estudiantes en países en desarrollo. Primero, llama la atención sobre la heterogeneidad en los beneficios de la práctica independiente. Estudios previos de didáctica de la matemática han buscado reclutar estudiantes de contextos desfavorecidos para comprender el impacto de la práctica independiente en un segmento de la población estudiantil que puede beneficiarse de una exposición adicional al material. Sin embargo, en su mayor parte, esta literatura se basa en muestras pequeñas, lo que impide a los investigadores comparar el efecto de la práctica independiente entre distintos tipos de estudiantes. La repentina disrupción que impuso el coronavirus a los sistemas educativos hace que esta pregunta sea especialmente oportuna.

Segundo, este estudio también contribuye a la creciente literatura sobre las escuelas privadas en India. Estudios previos han establecido que estas escuelas, que atienden a alrededor de uno de cada dos niños del país (Central Square Foundation 2020), superan a las escuelas públicas (Muralidharan y Kremer 2008), que su ventaja se debe principalmente a la selección de estudiantes más que a una mejor enseñanza ((Singh 2015), pero que sus menores salarios docentes las hacen más eficientes (Muralidharan y Sundararaman 2015). Nuestro estudio contribuye a esta creciente literatura al identificar una intervención que podría mejorar el rendimiento de este segmento amplio (y en expansión) del sistema escolar indio.

De manera más general, nuestro estudio ilustra el potencial de aprovechar el software CAL para realizar experimentos aleatorizados de ciclo rápido que permitan identificar los enfoques pedagógicos que mejor funcionan. A menudo, las decisiones sobre las funcionalidades del software las toman especialistas en educación que trabajan junto con los desarrolladores, a partir de investigaciones basadas en muestras pequeñas y de conveniencia en Estados Unidos. En algunos casos, también se guían por las llamadas “pruebas A/B”, en las que una funcionalidad específica del software se ofrece a un subconjunto aleatorio de sus usuarios. Sin embargo, como demuestra nuestro artículo, las alianzas entre investigadores y desarrolladores de software pueden producir estudios que aborden preguntas de interés más amplio para el campo de la educación, que aseguren que se cumplan las condiciones mínimas para la inferencia causal (p. ej., equivalencia en la línea de base y después de la deserción) y que los resultados sean compartidos (y examinados) por la comunidad científica pertinente.

El resto del artículo se estructura de la siguiente manera. La Sección 1 presenta el contexto, el diseño del estudio y la intervención. La Sección 2 describe los datos. La Sección 3 discute la estrategia empírica. La Sección 4 reporta los resultados. La Sección 5 discute las implicancias para la investigación y las políticas.

1 Experimento

1.1 Contexto

Nuestro estudio se centra en las escuelas privadas de India, que han sido considerablemente poco estudiadas en relación con su participación en la matrícula nacional y mundial de educación elemental. Atienden a 120 millones de estudiantes indios (es decir, casi uno de cada dos) (Central Square Foundation 2020). Si se las considerara por separado, constituirían el tercer sistema escolar más grande del mundo, después de los sistemas de escuelas públicas de China e India (UIS-UNESCO 2019). La matrícula en escuelas privadas se multiplicó 33 veces entre 1973 y 2017, y las escuelas privadas no subvencionadas, donde realizamos nuestro estudio, explicaron la mayor parte de este aumento, al pasar del 3.4% al 34.8% de la matrícula total (Central Square Foundation 2020). Según los datos más recientes disponibles, estas escuelas matriculan al 36% y al 31% de los estudiantes de primaria (es decir, de 1.º a 5.º grado) y de primaria superior (de 6.º a 8.º grado), respectivamente (NIEPA 2019). Si bien la mayoría cobra aranceles relativamente bajos (el arancel mensual mediano en una escuela elemental privada no subvencionada es de INR 958 o USD 13 en zonas urbanas y de INR 500 o USD 7 en zonas rurales), educan a uno de cada tres y a uno de cada dos estudiantes de los dos quintiles de ingreso más altos, respectivamente, por lo que ocupan un lugar privilegiado en la formación de las élites del país (Central Square Foundation 2020).

Las nueve escuelas privadas no subvencionadas de nuestro estudio abarcaban siete ciudades indias: Ahmedabad y Rajkot (en el estado de Gujarat), Faridabad (Haryana), Ghaziabad (Uttar Pradesh), Kolkata (Bengala Occidental), Nueva Delhi (Delhi) y Tiruchirappalli (Tamil Nadu). En el año escolar 2016-2017, estas ciudades tenían 13,025 escuelas y más de 2.9 millones de estudiantes (NIEPA 2018a, 2018b), aproximadamente la misma cantidad de estudiantes que los seis distritos escolares más grandes de Estados Unidos (NCES 2019). Como muestra la Tabla A1 del Anexo A, en todos los estados del estudio salvo Bengala Occidental, las escuelas privadas no subvencionadas concentran más de un tercio de la matrícula del nivel elemental, y en todos los estados esta participación aumentó entre 35 y 156% solo en la última década.

Los datos sobre resultados de aprendizaje de las escuelas privadas en India no se recopilan de manera sistemática. Sin embargo, los datos existentes sugieren que estas escuelas tienen un rendimiento similar o superior al de las escuelas estatales (es decir, públicas). Según la ronda más reciente (previa al COVID-19) de una evaluación representativa de escuelas rurales, solo el 44% de los estudiantes de 5.º grado de escuelas estatales podía leer un texto de 2.º grado, frente al 65% de sus pares de escuelas privadas, y solo el 23% de los estudiantes de quinto grado del sector público podía resolver la división de un número de tres cifras por uno de una cifra, frente al 40% de sus pares del sector privado (ASER 2019). De manera similar, en la edición más reciente de la Encuesta Nacional de Rendimiento (NAS, por sus siglas en inglés), que incluye escuelas privadas afiliadas

a juntas estatales, los estudiantes de escuelas privadas no subvencionadas superaron levemente a los de escuelas privadas subvencionadas en todas las asignaturas (matemática, ciencias naturales y sociales, lenguas indias modernas e inglés) (NCERT 2017). Estas diferencias se explican, al menos en parte, por la autoselección en cada sector (véase, p. ej., Muralidharan y Kremer 2008; Muralidharan y Sundararaman 2011; Singh 2015).

Realizamos este estudio en alianza con Educational Initiatives (EI), una empresa de evaluación líder en el país que desarrolló el software CAL que usamos para asignar aleatoriamente a los estudiantes a los ejercicios de práctica (descrito con mayor detalle en la subsección de Intervención). Establecimos esta alianza como un proyecto plurianual para aprovechar tanto el vasto banco de ítems del software en matemática y otras asignaturas como su alto grado de penetración en el país, con el fin de usar experimentos aleatorizados para responder preguntas de relevancia para los educadores. La alianza, denominada Learning Lab, fue liderada por Karthik Muralidharan, de la Universidad de California, San Diego, y Sridhar Rajagopalan, de EI, y financiada por la Douglas B. Marshall Foundation. Fuimos coinvestigadores principales y asociados de investigación en este proyecto.

1.2 Muestra

La muestra del estudio incluyó a 4,461 estudiantes de 4.º a 7.º grado de nueve escuelas privadas en las ciudades mencionadas. Seleccionamos una muestra de conveniencia de escuelas porque este era el primer estudio del Learning Lab y necesitábamos un grupo de escuelas que cumpliera con todos los requisitos de hardware y software para implementar el software CAL durante el período del estudio sin mayores interrupciones. Invitamos a participar a 12 escuelas privadas. Nueve de ellas aceptaron. Solicitamos el consentimiento informado de los directores y docentes de esas escuelas.

Se consideró que los estudiantes abandonaron el estudio si estuvieron ausentes de la escuela el día en que se administró la evaluación de línea final o si abandonaron la escuela. La deserción del estudio fue baja: 4,001 de los 4,461 estudiantes que rindieron la evaluación de línea de base (90%) también rindieron la evaluación de línea final. No conocemos la proporción de desertores que abandonaron la escuela, pero podemos estimarla aprovechando que el acceso al software CAL se brindaba a través de la escuela. En concreto, para cualquier semana dada, podemos calcular el porcentaje de estudiantes que dejaron de usar el software entre los desertores y los no desertores. Este enfoque sugiere que solo una pequeña proporción de estudiantes abandonó la escuela, pero que era más probable que fueran desertores: en la semana 20 (es decir, aproximadamente un mes antes de la línea final), el 5.2% de los desertores había dejado de usar el software, frente al 0.6% de los no desertores. Encontramos una diferencia marginalmente significativa en la deserción según el grupo experimental: el 11% de los estudiantes del grupo de control y el 9.4% de los estudiantes del grupo de tratamiento abandonaron el estudio, y la diferencia fue significativa al nivel del 10% ($p = 0.052$). En

la sección de Resultados discutimos si esta pequeña diferencia afectó nuestros resultados, reportando estimaciones ponderadas por la probabilidad inversa (IPW) y cotas de Lee (2009).

1.3 Aleatorización

Asignamos aleatoriamente a los 4,461 estudiantes de nuestra muestra a: (a) un grupo de control, en el que primero completaban un conjunto de “ejercicios de aprendizaje” (que presentaban conceptos nuevos) sobre un tema determinado de matemática (p. ej., operaciones con fracciones) y luego pasaban al tema siguiente; o (b) un grupo de tratamiento, en el que los estudiantes también completaban los ejercicios de aprendizaje, pero luego debían completar un conjunto de “ejercicios de práctica” (que buscan desarrollar el conocimiento procedimental y la fluidez) antes de pasar al tema siguiente. Para maximizar la comparabilidad entre los grupos experimentales, asignamos aleatoriamente a los participantes a nivel de estudiante (en lugar de a nivel de escuela o de aula) y estratificamos la aleatorización dentro de cada combinación de escuela, grado y sección, y según el desempeño de los estudiantes dentro de su clase en la plataforma CAL antes del inicio del estudio (p. ej., un sorteo incluyó a estudiantes de la escuela 1, de 4.º grado y de la sección “A”, que se ubicaban en la mitad superior de esa sección según su interacción previa con la plataforma).

La aleatorización de estudiantes dentro de la misma aula maximiza el poder estadístico, pero su principal desventaja es que permite “efectos de derrame”. En teoría, si los estudiantes del grupo de tratamiento (que tenían acceso a la intervención) trabajan junto con estudiantes del grupo de control (que no tenían acceso a la intervención) en ejercicios de matemática, las comparaciones entre ambos grupos podrían subestimar el efecto de la intervención sobre el rendimiento en matemática de los primeros (si transfirieran parte de sus conocimientos a los segundos). En la práctica, creemos que tales efectos de derrame son poco probables por tres razones. Primero, para que la práctica tenga un impacto significativo en el aprendizaje, suele requerir más apoyo del que un estudiante de cuarto a séptimo grado podría brindar a sus compañeros (véase, p. ej., Palinscar y Brown 1984; Scardamalia, Bereiter y Steinbach 1984). Por eso, como señalamos en la Introducción, los estudios previos sobre la práctica se han centrado en iniciativas en las que los docentes brindan modelado, acompañamiento y andamiaje (véase también National Research Council 2000) (véase también National Research Council, 2000). Segundo, como mencionamos en la Introducción y discutimos con mayor detalle en la sección de Resultados, el estudiante promedio pasó dos tercios de su tiempo de interacción con el software CAL en el hogar (y no en la escuela), donde presumiblemente tenía menos oportunidades de trabajar con sus compañeros. Tercero, como también reportamos en la sección de Resultados, encontramos que la intervención tuvo un efecto de 0.14 DE sobre los estudiantes con bajo rendimiento inicial—precisamente, el subconjunto que más se beneficiaría del trabajo en grupo (y, por lo tanto, el más propenso a los efectos de derrame). Aun si hubiera habido efectos de derrame, tendrían que ser de una magnitud similar a la de los beneficios individuales de la práctica para producir efectos

nulos estimados con precisión. Hasta donde sabemos, no hay estudios que sugieran que los efectos de derrame puedan contrarrestar las ganancias individuales.

Los estudiantes del grupo de control y del grupo de tratamiento eran comparables en su rendimiento en la línea de base y en su sexo, ya sea que comparemos a todos los estudiantes presentes en la línea de base o solo a quienes también rindieron la evaluación de línea final (es decir, los no desertores; véase la Tabla A4). De hecho, no solo las medias, sino también la distribución del rendimiento en la línea de base eran bastante similares entre los grupos experimentales (véase la Figura A1 del Anexo A).

1.4 Intervención

El software CAL en el que se insertó nuestro experimento, llamado “Mindspark”, fue desarrollado por Educational Initiatives (EI), una empresa de evaluación líder en India, a lo largo de un período de 10 años. Lo han usado más de 500,000 estudiantes, cuenta con una base de datos de más de 45,000 preguntas y administra más de 2 millones de preguntas a sus usuarios cada día. Puede implementarse durante la jornada escolar, antes o después de la escuela en centros independientes, y a través de una plataforma en línea autoguiada. La versión extraescolar fue evaluada recientemente mediante un experimento aleatorizado, que encontró que mejora enormemente el rendimiento en matemática y lectura de estudiantes de primaria y secundaria básica en Delhi (Muralidharan, Singh y Ganimian 2019). En nuestro estudio, los estudiantes tuvieron acceso a la versión escolar, que actualmente usan más de 100,000 estudiantes en 300 escuelas privadas de India y del extranjero (incluidos algunos estados árabes del golfo Pérsico). Todos los estudiantes siguieron recibiendo la enseñanza regular (es decir, a cargo de los docentes) durante el período del estudio.

Hay dos diferencias importantes entre la versión del software para escuelas privadas (que usamos en este estudio) y la versión extraescolar (que fue evaluada previamente) que conviene destacar para interpretar nuestras estimaciones de impacto. Primero, la versión para escuelas privadas presenta principalmente ejercicios de aprendizaje y de práctica del nivel del grado o superiores: entre los estudiantes del grupo de tratamiento, el 58% de todos los ejercicios de práctica que completaron durante el estudio correspondía al nivel de su grado, y el 20% estaba *por encima* del grado en que estaban matriculados (véase la Tabla A2). La versión extraescolar atiende a niños de escuelas desfavorecidas y, en consecuencia, enfatiza material por debajo del nivel del grado. Segundo, los temas y habilidades que cubre la versión para escuelas privadas los determina el docente de cada estudiante, según el currículo y cualquier práctica adicional que considere apropiada. Los dominios de contenido y cognitivos del material que presenta la versión extraescolar se determinan en gran medida mediante una prueba diagnóstica que los estudiantes rinden cuando interactúan por primera vez con el software. Por lo tanto, nuestras estimaciones de impacto no confunden el efecto de la práctica con el de la adaptación dinámica del material, que en gran medida está desactivada en la

versión del software para escuelas privadas.¹ Ni los directores ni los docentes recibieron diagnósticos sobre el aprendizaje de los estudiantes hasta *después* del estudio, por lo que nuestras estimaciones no confunden los efectos de la práctica con los de la provisión de información. De hecho, los directores y docentes desconocían la condición de tratamiento de los estudiantes (estudio “ciego”), por lo que es sumamente improbable que hayan adoptado algún comportamiento compensatorio para apoyar solo el aprendizaje de los estudiantes del grupo de tratamiento.

No nos interesa evaluar el impacto del software; en cambio, lo usamos para asignar aleatoriamente a los estudiantes a distintos niveles de práctica independiente en matemática. En concreto, los estudiantes del grupo de control y del grupo de tratamiento interactuaron con el software de manera similar (Figura 1). Primero, el software les pedía a los estudiantes que seleccionaran un tema de matemática (p. ej., fracciones); cada tema incluye entre ocho y diez unidades (p. ej., resta de fracciones). Luego, intentaban un conjunto de ejercicios de aprendizaje que buscaban introducir esa unidad (en promedio, los estudiantes completan 16 preguntas de completar espacios en blanco y de opción múltiple por unidad). A continuación, la experiencia de los estudiantes de ambos grupos se diferenciaba: los estudiantes del grupo de control pasaban a la unidad siguiente después de completar los ejercicios de aprendizaje, mientras que los del grupo de tratamiento debían completar ejercicios de práctica para consolidar su comprensión de los conceptos y procedimientos enseñados mediante los ejercicios de aprendizaje.²

Los ejercicios de aprendizaje que completaron todos los estudiantes se diferencian de los ejercicios de práctica que solo debían completar los estudiantes del grupo de tratamiento en cuatro aspectos. Primero, como se mencionó arriba, los ejercicios de aprendizaje introducían conceptos y procedimientos nuevos, mientras que los ejercicios de práctica se centraban en ayudar a los estudiantes a desarrollar su conocimiento procedimental (es decir, el conocimiento de los algoritmos que deben seguirse para resolver un problema específico) y su fluidez (es decir, la capacidad de resolver problemas con rapidez). Segundo, los ejercicios de aprendizaje no tenían límite de tiempo, pero los estudiantes disponían de ocho a diez minutos (según el tema) para intentar cada ejercicio de práctica. Quienes no lograban completar un ejercicio de práctica en el tiempo asignado podían intentarlo nuevamente (con el temporizador reiniciado) en su siguiente sesión (para no retrasar su avance de una unidad a la siguiente). Tercero, los ejercicios de aprendizaje eran los mismos para los estudiantes de todos los niveles de rendimiento inicial, pero los ejercicios de práctica se clasificaban

1. Como muestra la Tabla A2, existe *cierto* grado de adaptación dinámica, pero dentro de un rango de grados mucho más acotado que en la versión extraescolar evaluada por Muralidharan, Singh y Ganimian (2019).

2. Las escuelas diferían en cómo usaban el software CAL: algunas pueden haberlo usado como parte de tareas calificadas, mientras que otras pueden haberlo usado como un recurso de aprendizaje adicional. Sin embargo, estas diferencias no deberían sesgar nuestra estimación de impacto, dado que estratificamos la aleatorización por combinación de escuela, grado y sección, y por el desempeño en la plataforma antes del estudio (véase la subsección de Aleatorización). Los ejercicios de práctica no pudieron haberse usado con fines de alto impacto, ya que no estaban disponibles para los estudiantes del grupo de control y los docentes desconocían (“ciegos”) la asignación de los estudiantes a la condición de tratamiento.

en tres niveles de dificultad (baja, media o alta), que se presentaban de manera secuencial (los estudiantes que intentaban ejercicios de dificultad baja pasaban a ejercicios de dificultad media, y así sucesivamente, independientemente de si respondían correctamente los ejercicios).³ Por último, si bien todas las unidades incluían ejercicios de aprendizaje, no todas incluían ejercicios de práctica.⁴

Es importante destacar que todas las escuelas de nuestro estudio ya tenían acceso al software, que incluía los ejercicios de práctica. De hecho, el estudiante mediano de nuestro estudio (de ambos grupos experimentales) había intentado 683 ejercicios de práctica.⁵ Desactivamos esta funcionalidad para los estudiantes del grupo de control durante la evaluación para estimar su efecto. Como señalamos en la Introducción, no somos los primeros en inferir los efectos de una intervención examinando las consecuencias de su discontinuación, pero conviene discutir las implicancias de este diseño para nuestra pregunta de investigación. Si los ejercicios de práctica benefician a los estudiantes principalmente al enseñarles habilidades generales (p. ej., de resolución de problemas), y la relación entre dichos beneficios y la cantidad de ejercicios intentados es cóncava (es decir, hay rendimientos decrecientes), nuestras comparaciones entre los grupos de control y de tratamiento no captarán esos efectos (porque los ejercicios de práctica habrán impactado a ambos grupos experimentales antes de nuestro estudio), y subestimaremos los efectos de la práctica. Sin embargo, si dichos ejercicios mejoran el rendimiento en matemática al exponer a los estudiantes a problemas de dominios específicos (p. ej., sumas de fracciones de dos cifras), permitiéndoles probar distintas estrategias y observar cuáles funcionan mejor (es decir, mediante ensayo y error específico del contenido), nuestras estimaciones de impacto sí captarán esos efectos (porque los estudiantes cubrían temas distintos, y por lo tanto completaban ejercicios distintos, antes y después del período de evaluación).

La evidencia de la psicología del desarrollo sugiere que el tipo de transferencia de conocimientos y habilidades que nos llevaría a subestimar el efecto de la práctica independiente es bastante infrecuente (véase National Research Council 2000). Si bien los especialistas de este campo creían inicialmente que la práctica con tareas difíciles contribuía al desarrollo de habilidades generales de aprendizaje y atención (Woodworth y Thorndike 1901), la investigación experimental descubrió que, incluso cuando las personas parecen exhibir transferencia, a menudo se apoyan en conocimientos previos que sirven de poco para resolver tareas similares (p. ej., Ericsson, Chase y Faloon 1980). Estudios posteriores demostraron que la transferencia depende no solo del grado en que las tareas comparten

3. Lamentablemente, no tenemos datos sobre los ejercicios de aprendizaje; solo sobre los ejercicios de práctica (para los estudiantes del grupo de tratamiento).

4. No podemos calcular la proporción de unidades con ejercicios de práctica a partir de nuestros datos, pero sí el porcentaje de todos los días en que los estudiantes interactuaron con la plataforma CAL en los que también completaron ejercicios de práctica. El estudiante promedio del grupo de tratamiento vio al menos un ejercicio de práctica en el 75% de todos los días en que usó la plataforma. Dicho de otro modo, tres de cada cuatro días en que un estudiante del grupo de tratamiento usó el software incluyeron ejercicios de práctica.

5. No conocemos la fecha en que cada escuela comenzó a usar el software, pero, suponiendo que todos los estudiantes intentaron ejercicios antes del inicio de la evaluación al mismo ritmo que los estudiantes del grupo de tratamiento durante el período de evaluación, estimamos que habían estado expuestos al software durante 92 semanas (es decir, aproximadamente dos años).

elementos comunes (Klausmeier 1985; Thorndike 1913), sino también de las características de quienes aprenden (Singley y Anderson 1989), como su dominio de la materia original (p. ej., Klahr y Carver 1988; Littlefield y col. 1988), la medida en que la aprendieron con comprensión (en lugar de memorizar datos, p. ej., Hendrickson y Schroeder 1941; Judd 1908), el tiempo dedicado a aprenderla (para desarrollar habilidades de reconocimiento de patrones, p. ej., Chase y Simon 1973; Ericsson, Krampe y Tesch-Römer 1993; Simon y Chase 1973) y su motivación para aprender (White 1959). La transferencia también se ve afectada por el contexto en el que se aprendió la tarea original (p. ej., Carraher, Carraher y Schliemann 1985; Nunes y col. 1993) y por el nivel de abstracción con el que se presentó (p. ej., Singley y Anderson 1989; Spiro y col. 1991). De hecho, la transferencia puede incluso ser negativa (es decir, la experiencia con un conjunto de eventos puede de hecho perjudicar el desempeño en tareas relacionadas) al llevar a las personas a adoptar estrategias de resolución de problemas menos eficientes (Luchins y Luchins 1970). Por lo tanto, parece poco probable que nuestro diseño experimental subestime los efectos de la práctica.

Dado que administramos los instrumentos de línea de base en fechas ligeramente distintas (véase la sección de Datos), algunos estudiantes del grupo de control tuvieron acceso a los ejercicios de práctica después de la línea de base. Sin embargo, su exposición a esta funcionalidad fue mínima: el estudiante promedio dedicó solo 3.4 minutos a intentar ejercicios de práctica durante este período, y el estudiante mediano, 1.7 minutos. Por lo tanto, es sumamente improbable que esta breve exposición haya generado una diferencia significativa en su rendimiento.

2 Datos

Recopilamos dos tipos principales de datos: (a) el rendimiento de los estudiantes, antes y después de la intervención, para verificar la equivalencia en la línea de base y estimar el impacto; (b) el uso del software CAL por parte de los estudiantes y su interacción con la intervención, para verificar la fidelidad de la implementación y estimar la relación entre la cantidad de ejercicios de práctica completados y el rendimiento. Complementamos estos datos con información administrativa sobre el grado y el sexo de los estudiantes (no aplicamos una encuesta a los estudiantes).

2.1 Rendimiento de los estudiantes

Administramos evaluaciones de aprendizaje en matemática a los estudiantes en la línea de base (antes de la intervención) y en la línea final (seis meses después del inicio de la intervención).⁶ Estas evaluaciones medían lo que los estudiantes deberían saber y ser capaces de hacer según estándares

6. Las distintas escuelas aplicaron la evaluación de línea de base y comenzaron a usar el software en fechas ligeramente distintas (véase la Tabla A3). Sin embargo, a lo largo de este artículo, limitamos nuestro análisis a un período común de seis meses, que comienza el 11 de septiembre de 2017 y termina el 11 de marzo de 2018.

internacionales, e incluían tres dominios de contenido (números, figuras geométricas y medición) y tres dominios cognitivos (conocer, aplicar y razonar). La distribución de los ítems entre los dominios de contenido y cognitivos se basó en el marco de evaluación del Estudio de las Tendencias en Matemática y Ciencias (TIMSS, por sus siglas en inglés) de 2019 para 4.º grado (Mullis y Martin 2017).

Cada prueba tenía 35 ítems de opción múltiple. Utilizamos ítems de evaluaciones internacionales (p. ej., TIMSS, PISA, Young Lives), de evaluaciones nacionales (p. ej., Quality Education Study, Student Learning Survey) y de evaluaciones de impacto previas en India (p. ej., los Andhra Pradesh Randomized Studies in Education o APRESt). Incluimos ítems de un amplio rango de dificultad para reducir la posibilidad de efectos “piso” (es decir, estudiantes que no responden correctamente ninguna pregunta) y efectos “techo” (es decir, estudiantes que responden correctamente todas las preguntas). Tanto en la línea de base como en la línea final, administramos una evaluación para los estudiantes de 4.º y 5.º grado y otra para los de 6.º y 7.º grado, y elaboramos cuatro versiones de cada evaluación para evitar la copia.⁷

Utilizamos un diseño de prueba ancla no equivalente (NEAT, por sus siglas en inglés) para vincular los resultados entre las aplicaciones (para una discusión de este diseño, véase Kolen y Brennan 2004). Incluimos una “prueba ancla” con ítems comunes entre las rondas de recolección de datos y escalamos los resultados de ambas rondas de manera concurrente mediante un modelo logístico de dos parámetros de teoría de respuesta al ítem (IRT).

2.2 Tiempo de los estudiantes en la plataforma CAL y respuestas a los ejercicios

También obtuvimos acceso a datos sobre el tiempo que los estudiantes interactuaron con la plataforma CAL y con los ejercicios de aprendizaje y de práctica, así como sobre si sus respuestas a estos ejercicios eran correctas, para verificar que el ensayo y la intervención se implementaran según lo previsto y para investigar la relación dosis-respuesta entre la práctica y el rendimiento. A cada estudiante se le asignó un usuario y una contraseña únicos, lo que nos permitió hacer un seguimiento de su uso y sus respuestas durante el estudio. A partir de la dirección de Protocolo de Internet (IP) de cada estudiante y de la hora de inicio de sesión, también pudimos determinar si usaba el software en la escuela o en el hogar.

7. Las pruebas de línea de base pueden consultarse en: <https://bit.ly/2MLWKqL> (4.º-5.º grado), <https://bit.ly/3dSusXw> (6.º-7.º grado). Las pruebas de línea final pueden consultarse en: <https://bit.ly/2UtCSx6> (4.º-5.º grado), <https://bit.ly/30v0jcU> (6.º-7.º grado).

3 Estrategia empírica

Estimamos el efecto de la oferta de ejercicios de práctica (es decir, el efecto de intención de tratar o ITT) mediante el siguiente modelo:

$$Y_{igs}^t = \alpha_{r(gs)} + \beta T_{igs} + \theta Y_{igs}^{(t-1)} + \epsilon_{igs}^t \quad (1)$$

donde Y_{igs}^t es el rendimiento en matemática del estudiante i en el grado g y la escuela s en el momento t (línea final), $r(gs)$ es el estrato de aleatorización del grado g y la escuela s , y $\alpha_{r(gs)}$ es un efecto fijo por estrato, T_{igs} es una variable indicadora de la asignación aleatoria al tratamiento, y $Y_{igs}^{(t-1)}$ es el rendimiento en matemática en el momento $t - 1$ (línea de base). El parámetro de interés es β , que capta el efecto causal de la intervención. Estimamos variantes de este modelo que interactúan la variable indicadora de tratamiento con el grado, el sexo y el rendimiento en la línea de base de los estudiantes (continuo o por cuartil dentro de cada grado) para comprender si la intervención resulta más útil para algunos subgrupos de estudiantes.

No ajustamos nuestros errores estándar por las correlaciones a nivel de aula en los resultados de los estudiantes, porque un estudio reciente demostró que dicho ajuste no se justifica cuando la asignación aleatoria se realiza a nivel individual (Abadie y col. 2017). Algunos autores han argumentado que este ajuste debería realizarse cuando los estratos de aleatorización incluyen muy pocas observaciones (Chaisemartin y Ramirez-Cuellar 2020). Nuestros estratos son relativamente grandes, pero en la Tabla A9 demostramos que nuestras estimaciones son robustas a dicho ajuste.

Calculamos valores p ajustados por la tasa de error por familia de hipótesis en nuestra estimación de los efectos ITT heterogéneos. En concreto, seguimos a List, Shaikh y Xu (2019) y tomamos en cuenta los análisis de subgrupos preregistrados por sexo, grado de matrícula y rendimiento inicial en matemática.

4 Resultados

4.1 Fidelidad de la implementación

La intervención se implementó en gran medida según lo previsto. Primero, prácticamente todos los estudiantes de ambos grupos experimentales (3,999 de 4,001 estudiantes, o 99.9%) iniciaron sesión al menos una vez en la plataforma CAL durante la evaluación. De hecho, el estudiante promedio interactuó con el software durante 952 minutos a lo largo de los seis meses del estudio (es decir, unos 38 minutos por semana; véase la Figura 2), mayormente en el hogar (es decir, en lugar de en la escuela; véase la Figura A2). El uso varió entre escuelas, por lo general entre unos 500 y 1,000

minutos; solo una escuela registró más de 2,500 minutos (Figura A3, panel A). La variación en la adopción no es infrecuente, y puede deberse a diferencias en la infraestructura escolar (p. ej., disponibilidad de computadoras), en el compromiso de los docentes y/o en la alineación entre el software y el currículo de matemática de la escuela, entre otros factores.

Segundo, todos los estudiantes del grupo de tratamiento intentaron al menos un ejercicio de práctica durante el estudio. El estudiante promedio del grupo de tratamiento dedicó 76 minutos a intentar ejercicios de práctica durante el período del estudio (es decir, unos 3 minutos por semana; véase la Figura 3). La interacción con los ejercicios de práctica también difirió entre escuelas, siguiendo un patrón similar al del uso del software (Figura A3, panel B).

Por último, los ejercicios de práctica que intentaron los estudiantes del grupo de tratamiento abarcaron 18 temas (p. ej., “geometría”), 59 subtemas (p. ej., “triángulos y propiedades de los triángulos”) y 151 unidades dentro de esos temas (p. ej., “clasificación de triángulos según sus lados y ángulos”). Los tres temas en los que los estudiantes intentaron la mayor cantidad de ejercicios de práctica fueron medición (14% del total de ejercicios), fracciones (10%) y teoría de números (9.1%).

4.2 Efectos promedio sobre el rendimiento en matemática

La oferta de la intervención tuvo un efecto nulo, estimado con precisión (de 0.01 desviaciones estándar o DE), sobre el rendimiento en matemática del estudiante promedio, independientemente de si controlamos o no por el desempeño de los estudiantes en la línea de base (Tabla 2). De hecho, a partir del intervalo de confianza del 95%, podemos descartar efectos inferiores a -0.04 DE y superiores a 0.06 DE. Este efecto promedio nulo es consistente entre los dominios de contenido, con estimaciones puntuales que van de 0.002 a 0.01, y entre los dominios cognitivos, con estimaciones puntuales que van de 0.002 a 0.01 (Tabla 3).⁸ También es consistente entre los ítems “repetidos” en la línea de base y la línea final y los ítems “no repetidos” (introducidos en la línea final; Tabla A5).

4.3 Efectos heterogéneos sobre el rendimiento en matemática

Exploramos si el efecto de la intervención difería según las únicas tres características de los estudiantes registradas en nuestros datos—sexo, grado de matrícula y rendimiento inicial—tal como lo habíamos especificado en nuestro plan de preanálisis. Encontramos que la intervención tuvo un efecto positivo de moderado a grande, de 0.14 DE, para los estudiantes con bajo rendimiento inicial en matemática. Primero, lo mostramos gráficamente. Graficamos los efectos de la intervención para cada cuartil dentro de cada grado del rendimiento en matemática en la línea de base (Figura 4). Luego, lo mostramos analíticamente. Examinamos esta heterogeneidad de dos maneras: primero,

8. En el dominio cognitivo de razonar, encontramos un efecto marginalmente significativo desde el punto de vista estadístico, que probablemente se deba a la cantidad de pruebas de hipótesis que estamos realizando (véase la Tabla 3).

interactuando la variable indicadora de tratamiento con el puntaje (continuo) de cada estudiante en la línea de base y, luego, interactuando esa variable con indicadoras del cuartil dentro de cada grado del rendimiento de cada estudiante en la línea de base (Tabla 4). Incluso después de ajustar los valores p por pruebas de hipótesis múltiples, nuestra estimación del efecto causal de los ejercicios de práctica sobre los estudiantes con bajo rendimiento inicial siguió siendo estadísticamente significativa al nivel del 1% ($p = 0.001$, no se muestra en la tabla).

Exploramos, pero finalmente descartamos, la posibilidad de que los efectos de la intervención sobre los estudiantes con bajo rendimiento inicial pudieran explicarse por impactos en el dominio del idioma inglés. En concreto, dado que la enseñanza en las escuelas privadas no subvencionadas de India se imparte en inglés (véase Singh y Sarkar 2015), y que nuestras evaluaciones de línea de base y de línea final también estaban en inglés (y no en lenguas vernáculas indias), parece al menos posible que los ejercicios de práctica hayan mejorado el rendimiento en matemática de los estudiantes de bajo rendimiento al enseñarles palabras (de matemática) en inglés. Examinamos esta posibilidad de tres maneras. Primero, calculamos la proporción de respuestas correctas de los estudiantes en la evaluación de línea final para los ítems que no requerían leer palabras (más allá de una consigna breve, como “resuelve”) y para los ítems sin palabras de “vocabulario matemático” (p. ej., “rectángulo”), y estimamos el impacto de la intervención sobre cada uno de ellos por separado. Luego, usamos un modelo confirmatorio de teoría de respuesta al ítem (IRT) bidimensional para escalar los puntajes de línea final de los estudiantes, permitiendo que los ítems que no requerían lectura y los que sí la requerían cargaran en factores correlacionados distintos, y estimamos el efecto de la intervención sobre este último. A continuación, usamos un modelo IRT similar en el que todos los ítems cargaban en el primer factor, pero los que requerían lectura también podían cargar en un factor correlacionado, y estimamos el efecto de la intervención sobre el primero. Si los estudiantes con bajo rendimiento inicial solo hubieran mejorado porque se les “enseñó” inglés mediante los ejercicios de práctica, no deberían haber mejorado (o deberían haber mejorado menos) en las seis variables de resultado mencionadas. Sin embargo, no fue así. De hecho, los impactos sobre estos resultados fueron indistinguibles de nuestras estimaciones principales de las Tablas 2 y 4 (véase la Tabla A6).

Sin embargo, no encontramos evidencia convincente de efectos heterogéneos según otros factores (véase la Tabla A7). Las estudiantes mujeres obtuvieron un desempeño levemente inferior al de los varones, pero la diferencia no fue estadísticamente significativa, como tampoco lo fue la interacción entre el tratamiento y la indicadora de sexo femenino. El efecto de la intervención tampoco varió según el grado en que estaban matriculados los estudiantes. Si bien observamos cierta variación en el efecto de la intervención entre escuelas, no teníamos poder estadístico suficiente para detectar diferencias estadísticamente significativas (véase la Figura A4).

4.4 Efectos promedio sobre la interacción con el software CAL

Por último, consideramos si los ejercicios de práctica afectaron la medida en que los estudiantes interactuaron con el software CAL. Primero, dado que los estudiantes del grupo de tratamiento debían intentar ejercicios de práctica al final de cada unidad pero los del grupo de control no (véase la sección de Intervención), es posible que la intervención haya llevado a los primeros a completar menos unidades en la plataforma CAL que los segundos. Esto habría sido problemático porque, si bien esperábamos que los ejercicios de práctica afectaran *positivamente* el rendimiento en matemática de los estudiantes del grupo de tratamiento, esperaríamos que completar menos unidades afectara *negativamente* su rendimiento, de modo que el efecto global de la intervención habría confundido estas influencias contrapuestas. Abordamos esta posibilidad en la primera columna de la Tabla A8, donde estimamos el efecto de la intervención sobre la cantidad de sesiones completadas en la plataforma CAL. Los estudiantes del grupo de tratamiento completaron solo alrededor de un 1% más de sesiones que los del grupo de control, y la diferencia entre ambos no fue estadísticamente significativa. Segundo, dado que evaluamos el efecto de los ejercicios de práctica desactivándolos para los estudiantes del grupo de control durante el período del estudio (véase la sección de Intervención), es posible que estos hayan compensado este cambio pasando más tiempo en la plataforma que sus pares del grupo de tratamiento. Esto también habría sido problemático, porque nos habría llevado a confundir el efecto de la exposición a los ejercicios de práctica con el efecto de pasar tiempo en la plataforma CAL. Abordamos esta posibilidad en la segunda columna de la Tabla A8, donde estimamos el efecto de la intervención sobre el *tiempo total* en la plataforma. Los estudiantes del grupo de tratamiento pasaron aproximadamente un 2.3% más de minutos que los del grupo de control, pero, nuevamente, la diferencia no fue estadísticamente significativa. En la tercera columna de la tabla, también consideramos la posibilidad de que la intervención afectara el tiempo que los estudiantes del grupo de control pasaban en la plataforma en *cada* sesión, estimando el efecto de la intervención sobre el tiempo total en la plataforma, manteniendo constante la cantidad de sesiones. Por sesión, los estudiantes del grupo de tratamiento pasaron aproximadamente un 1.5% más de minutos en la plataforma, pero la diferencia fue solo marginalmente significativa desde el punto de vista estadístico. En resumen, no encontramos mucha evidencia de que la intervención haya afectado la medida en que los estudiantes interactuaron con el software CAL, lo que sugiere que no estábamos confundiendo los efectos de la práctica con los de otros factores.

5 Conclusión

Este artículo presenta uno de los primeros estudios con poder estadístico suficiente para, a la vez, descartar efectos relevantes de la práctica independiente para el estudiante promedio y detectar efectos positivos no triviales para los estudiantes de menor rendimiento. Tras solo seis meses de un

promedio de tres minutos de práctica por día, encontramos que los estudiantes de menor rendimiento que asisten a escuelas privadas orientadas a familias relativamente acomodadas superaron a sus pares del grupo de control por 0.14 DE.⁹ Sin embargo, esta práctica adicional no tuvo ningún efecto sobre sus pares de rendimiento promedio. Estos resultados son robustos en los análisis de subgrupos y entre distintas escuelas y ciudades.

Nuestro estudio hace una contribución importante a tres literaturas distintas pero relacionadas. Primero y principal, identifica un enfoque para abordar la heterogeneidad en la preparación de los estudiantes para la escolaridad, un desafío de frontera en los países en desarrollo (véase Ganimian y Murnane 2016; Glewwe y Muralidharan 2016). Este enfoque exige mucho menos tiempo a estudiantes y docentes que las intervenciones remediales con efectos similares (p. ej., A. V. Banerjee y col. 2007b). Puede llevarse a cabo (mayormente) fuera del horario escolar, sin exigir que los docentes se aparten del currículo ni que resten tiempo a las asignaturas centrales para llevar a los estudiantes al laboratorio de computación—dos factores que han frustrado los esfuerzos por escalar intervenciones igualmente eficaces (véase, p. ej., Muralidharan y Singh 2019; A. Banerjee y col. 2017). Y, siempre que se disponga del hardware y el software necesarios para la plataforma CAL en la que se inserta (en este caso, Mindspark) no requiere costos adicionales de instalación ni capacitación. Dado el amplio alcance del software Mindspark en India y en el extranjero, y la necesidad actual de educar a los estudiantes mientras están fuera de la escuela debido al coronavirus, nuestros resultados sugieren que podríamos estar ayudando a muchos más estudiantes a alcanzar a sus pares si fomentáramos la práctica independiente.

Segundo, nuestro estudio también contribuye al cuerpo de investigación, en rápida evolución, sobre las escuelas privadas en India y, de manera más general, en los países en desarrollo. Si bien nuestro estudio no es en absoluto representativo de todas las escuelas privadas no subvencionadas, arroja luz sobre un sector que ha recibido considerablemente menos atención de la que merece en vista de su participación en la matrícula nacional y mundial de educación elemental. Nuestro estudio identifica un enfoque mediante el cual al menos las escuelas privadas no subvencionadas podrían mejorar el aprendizaje de los estudiantes de bajo rendimiento. Dados los bajos costos de la plataforma subyacente (véase Muralidharan, Singh y Ganimian 2019), somos optimistas respecto de que un enfoque similar podría adoptarse en las escuelas privadas subvencionadas, que constituyen la mayor parte del sector en el sur de Asia (véase Andrabi y col. 2007).

Por último, nuestro estudio ofrece una demostración importante de cómo aprovechar la creciente penetración de los productos de software educativo para realizar evaluaciones aleatorizadas de ciclo rápido que arrojen luz sobre los méritos de estrategias educativas intuitivamente atractivas pero en gran medida no evaluadas, a la vez que reducen el tiempo y el costo que requiere la

9. Usamos el término “práctica adicional” para referirnos a los ejercicios de práctica que se esperaba que completaran los estudiantes del grupo de tratamiento, pero no los del grupo de control, durante el período del estudio (esta fue la intervención). Sin embargo, como explicamos en la sección de Resultados, los estudiantes del grupo de control y del grupo de tratamiento pasaron la misma cantidad de tiempo con el software CAL.

recolección independiente de datos. Quizás más importante aún, lo hace de un modo que permite a los investigadores monitorear de cerca la interacción de los estudiantes con la intervención evaluada (en este caso, la práctica independiente) y estimar su efecto con precisión, no solo para el estudiante promedio, sino también para subgrupos relevantes. Consideramos que esta es una contribución crucial a la investigación sobre tecnología educativa, dado que muchas intervenciones evaluadas en este ámbito han arrojado resultados decepcionantes y se beneficiarían de retroalimentación sobre su eficacia (Ganimian, Hess y Vegas 2020).

Referencias

- Abadie, Alberto, Susan Athey, Guido Imbens y Jeffrey Wooldridge. 2017. *When Should You Adjust Standard Errors for Clustering?* Informe técnico w24003. Cambridge, MA: National Bureau of Economic Research.
- Andrabi, T., J. Das, A. I. Khwaja, T. Vishwanath y T. Zajonc. 2007. *Learning and Educational Achievements in Punjab Schools (LEAPS): Insights to inform the education policy debate*. Washington, DC: World Bank.
- Argys, Laura M., Andrew I. Friedson, M. Melinda Pitts y D. Sebastian Tello-Trillo. 2020. «Losing public health insurance: TennCare reform and personal financial distress». *Journal of Public Economics* 187 (julio): 104202.
- ASER. 2019. *Annual Status of Education Report 2018 (Rural)*. Provisional Report. New Delhi: Pratham.
- Banerjee, Abhijit, Rukmini Banerji, James Berry, Esther Duflo, Harini Kannan, Shobhini Mukerji, Marc Shotland y Michael Walton. 2017. «From Proof of Concept to Scalable Policies: Challenges and Solutions, with an Application». *Journal of Economic Perspectives* 31, n.º 4 (noviembre): 73-102.
- Banerjee, Abhijit V, Shawn Cole, Esther Duflo y Leigh Linden. 2007a. «Remedying Education: Evidence from Two Randomized Experiments in India». *The Quarterly Journal of Economics* 122 (3): 1235-1264.
- . 2007b. «Remedying Education: Evidence from Two Randomized Experiments in India». *The Quarterly Journal of Economics* 122 (3): 1235-1264.
- Bettinger, Eric, Robert W Fairlie, Anastasia Kapuza, Elena Kardanova, Prashant Loyalka y Andrey Zakharov. 2020. *Does EdTech Substitute for Traditional Learning? Experimental Estimates of the Educational Production Function*. Working Paper 26967. Cambridge, MA: National Bureau of Economic Research, abril.
- Cardelle-Elawar, Maria. 1990. «Effects of Feedback Tailored to Bilingual Students' Mathematics Needs on Verbal Problem Solving». *The Elementary School Journal* 91, n.º 2 (noviembre): 165-175.
- . 1995. «Effects of metacognitive instruction on low achievers in mathematics problems». *Teaching and Teacher Education* 11, n.º 1 (enero): 81-95.
- Carraher, Terezinha Nunes, David William Carraher y Analúcia Dias Schliemann. 1985. «Mathematics in the streets and in schools». *British Journal of Developmental Psychology* 3 (1): 21-29.
- Central Square Foundation. 2020. *State of the Sector Report on Private Schools in India*. Report. New Delhi: Central Square Foundation.

- Chaisemartin, Clément de, y Jaime Ramirez-Cuellar. 2020. *At What Level Should One Cluster Standard Errors in Paired Experiments, and in Stratified Experiments with Small Strata?* Working Paper 27609. Cambridge, MA: National Bureau of Economic Research, agosto.
- Chase, William G., y Herbert A. Simon. 1973. «Perception in chess». *Cognitive Psychology* 4 (1): 55-81.
- Chyn, Eric. 2018. «Moved to Opportunity: The Long-Run Effects of Public Housing Demolition on Children». *American Economic Review* 108, n.º 10 (octubre): 3028-3056.
- Dynarski, Susan M. 2003. «Does Aid Matter? Measuring the Effect of Student Aid on College Attendance and Completion». *American Economic Review* 93, n.º 1 (marzo): 279-288.
- Ericsson, K. Anders, William G. Chase y Steve Faloon. 1980. «Acquisition of a Memory Skill». *Science* 208, n.º 4448 (junio): 1181-1182.
- Ericsson, K. Anders, Ralf T. Krampe y Clemens Tesch-Römer. 1993. «The role of deliberate practice in the acquisition of expert performance». *Psychological Review* 100, n.º 3 (julio): 363-406.
- Fishman, Ram, Stephen C Smith, Vida Bobić y Munshi Sulaiman. 2017. *How Sustainable Are Benefits from Extension for Smallholder Farmers? Evidence from a Randomized Phase-Out of the BRAC Program in Uganda*. Working Paper. Bonn, Germany: IZA Institute of Labor Economics.
- Ganimian, A. J., F. M. Hess y E. Vegas. 2020. *Realizing the promise: How can education technology improve learning for all?* Informe técnico. Washington, D.C.: Brookings Institution.
- Ganimian, Alejandro J., y Richard J. Murnane. 2016. «Improving Education in Developing Countries: Lessons From Rigorous Impact Evaluations». *Review of Educational Research* 86 (3): 719-755.
- Glewwe, Paul, y Karthik Muralidharan. 2016. «Improving School Education Outcomes in Developing Countries: Evidence, Knowledge Gaps, and Policy Implications». En *Handbook of the Economics of Education*, editado por Eric Hanushek, Stephen Machin y Ludger Woessmann, 653-744. Elsevier.
- Hendrickson, G., y W. H. Schroeder. 1941. «Transfer of training in learning to hit a submerged target». *Journal of Educational Psychology* 32 (3): 205-213.
- Hippel, Paul T. von, y Laura Bellows. 2018. «How much does teacher quality vary across teacher preparation programs? Reanalyses from six states». *Economics of Education Review* 64 (junio): 298-312.
- Hohn, Robert L., y Bruce Frey. 2002. «Heuristic Training and Performance in Elementary Mathematical Problem Solving». *The Journal of Educational Research* 95, n.º 6 (julio): 374-380.
- Jitendra, A. K., C. C. Griffin, K. McGoey, M. C. Gardill, P. Bhat y T. Riley. 1998. «Effects of mathematical word problem solving by students at risk or with mild disabilities». *The Journal of Educational Research* 91 (6): 345-355.

- Jitendra, Asha K., Jon R. Star, Michael Rodriguez, Mary Lindell y Fumio Someki. 2011. «Improving students' proportional thinking using schema-based instruction». *Learning and Instruction* 21, n.º 6 (diciembre): 731-745.
- Judd, C. H. 1908. «The relation of special training and general intelligence». *Educational Review* 36:28-42.
- King, Alison. 1991. «Effects of training in strategic questioning on children's problem-solving performance.» *Journal of Educational Psychology* 83 (3): 307-317.
- Klahr, David, y Sharon McCoy Carver. 1988. «Cognitive objectives in a LOGO debugging curriculum: Instruction, learning, and transfer». *Cognitive Psychology* 20, n.º 3 (julio): 362-404.
- Klausmeier, Herbert J. 1985. *Educational psychology*. 5. ed. New York: Harper & Row.
- Kolen, Michael J, y Robert L Brennan. 2004. *Test Equating, Scaling, and Linking*. 3rd. New York, NY: Springer.
- Kramarski, Bracha, y Zemira R. Mevarech. 2003. «Enhancing Mathematical Reasoning in the Classroom: The Effects of Cooperative Learning and Metacognitive Training». *American Educational Research Journal* 40, n.º 1 (enero): 281-310.
- Lai, Fang, Renfu Luo, Linxiu Zhang, Xinzhe Huang y Scott Rozelle. 2015. «Does computer-assisted learning improve learning outcomes? Evidence from a randomized experiment in migrant schools in Beijing». *Economics of Education Review* 47 (agosto): 34-48.
- Lai, Fang, Linxiu Zhang, Xiao Hu, Qinghe Qu, Yaojiang Shi, Yajie Qiao, Matthew Boswell y Scott Rozelle. 2013. «Computer assisted learning as extracurricular tutor? Evidence from a randomised experiment in rural boarding schools in Shaanxi». *Journal of Development Effectiveness* 52 (2): 208-231.
- Lai, Fang, Linxiu Zhang, Qinghe Qu, Xiao Hu, Yaojiang Shi, Matthew Boswell y Scott Rozelle. 2016. *Does computer-assisted learning improve learning outcomes? Evidence from a randomized experiment in public schools in rural minority areas in Qinghai, China*. Working Paper 237. Stanford, CA: Stanford University, Freeman Spogli Institute for International Studies, agosto.
- Lee, David S. 2009. «Training, Wages, and Sample Selection: Estimating Sharp Bounds on Treatment Effects». *The Review of Economic Studies* 76, n.º 3 (julio): 1071-1102.
- List, John A., Azeem M. Shaikh y Yang Xu. 2019. «Multiple hypothesis testing in experimental economics». *Experimental Economics* 22, n.º 4 (diciembre): 773-793.
- Littlefield, Joan, Victor R. Delclos, Sharon Lever, Keith N. Clayton, John D. Bransford y Jeffery J. Franks. 1988. «Learning LOGO: Method of teaching, transfer of general skills, and attitudes toward school and computers». En *Teaching and learning computer programming: Multiple research perspectives*, editado por Richard E. Mayer, 111-135. Lawrence Erlbaum Associates, Inc.

- Luchins, Abraham S., y Edith H. Luchins. 1970. *Wertheimer's Seminars Revisited: Problem Solving and Thinking, Volume I*. 1st edition. Albany, NY: State University of New York at Albany, enero.
- Mevarech, Zemira R., y Bracha Kramarski. 2003. «The effects of metacognitive training versus worked-out examples on students' mathematical reasoning». *British Journal of Educational Psychology* 73 (4): 449-471.
- Mo, D., L. Zhang, J. Wang, W. Huang, Y. Shi, M. Boswell y S. Rozelle. 2015. «Persistence of learning gains from computer assisted learning: Experimental evidence from China». *Journal of Computer Assisted Learning* 31 (6): 562-581.
- Mullis, Ina V. S, y Michael O. Martin. 2017. *TIMSS 2019 Assessment Frameworks*. Chestnut Hill, MA: International Association for the Evaluation of Educational Achievement (IEA).
- Muralidharan, Karthik, y Michael Kremer. 2008. «Public-Private Schools in Rural India». En *School Choice International: Exploring Public-Private Partnerships*, editado por Rajashri Chakrabarti y Paul E. Peterson, 91-110. Cambridge, MA: MIT Press.
- Muralidharan, Karthik, y Abhijeet Singh. 2019. «Improving Schooling Productivity through Computer-Aided Personalization: Experimental Evidence from Rajasthan». Washington, D.C.: RISE Annual Conference 2019, junio.
- Muralidharan, Karthik, Abhijeet Singh y Alejandro J. Ganimian. 2019. «Disrupting Education? Experimental Evidence on Technology-Aided Instruction in India». *American Economic Review* 109, n.º 4 (abril): 1426-1460.
- Muralidharan, Karthik, y Venkatesh Sundararaman. 2011. «Teacher performance pay: Experimental evidence from India». *Journal of Political Economy* 119 (1): 39-77.
- . 2015. «The Aggregate Effect of School Choice: Evidence from a Two-Stage Experiment in India». *The Quarterly Journal of Economics* 130, n.º 3 (agosto): 1011-1066.
- Nakajima, Nozomi. 2020. «Long-run effects of short-term grants in early childhood education». Cambridge, MA, diciembre.
- National Research Council. 2000. *How People Learn: Brain, Mind, Experience, and School: Expanded Edition*. Washington, D.C.: National Academies Press, agosto.
- NCERT. 2017. *National Achievement Survey (NAS) dashboard: 2017*.
- NCES. 2019. *Digest of education statistics: 2019*.
- NIEPA. 2018a. *Elementary Education in India: Where Do We Stand? District Report Cards 2016-17*. Vol. 1. New Delhi, India: National Institute of Educational Planning / Administration.

- NIEPA. 2018b. *Elementary Education in India: Where Do We Stand? District Report Cards 2016-17*. Vol. 2. New Delhi, India: National Institute of Educational Planning / Administration.
- . 2019. *U-DISE Flash Statistics 2017-18*. New Delhi, India: National Institute of Educational Planning / Administration.
- Nunes, Terezinha, Terezinha Nunes Carraher, Analucia Dias Schliemann y David William Carraher. 1993. *Street Mathematics and School Mathematics*. Cambridge University Press, abril.
- Palinscar, Aannemarie Sullivan, y Ann L. Brown. 1984. «Reciprocal Teaching of Comprehension-Fostering and Comprehension-Monitoring Activities». *Cognition and Instruction* 1, n.º 2 (marzo): 117-175.
- Pitchford, Nicola J. 2015. «Development of early mathematical skills with a tablet intervention: a randomized control trial in Malawi». *Frontiers in Psychology* 6 (abril).
- Scardamalia, Marlene, Carl Bereiter y Rosanne Steinbach. 1984. «Teachability of Reflective Processes in Written Composition». *Cognitive Science* 8, n.º 2 (abril): 173-190.
- Simon, Herbert A., y William G. Chase. 1973. «Skill in chess». *American Scientist* 61 (4): 394-403.
- Singh, Abhijeet. 2015. «Private school effects in urban and rural India: Panel estimates at primary and secondary school ages». *Journal of Development Economics* 113 (marzo): 16-32.
- Singh, Renu, y Sudipa Sarkar. 2015. «Does teaching quality matter? Students learning outcome related to teaching quality in public and private primary schools in India». *International Journal of Educational Development* 41 (marzo): 153-163.
- Singley, Mark K., y John Robert Anderson. 1989. *The Transfer of Cognitive Skill*. Harvard University Press.
- Spiro, Rand J., Paul J. Feltovich, Paul L. Feltovich, Michael J. Jacobson y Richard L. Coulson. 1991. «Cognitive Flexibility, Constructivism, and Hypertext: Random Access Instruction for Advanced Knowledge Acquisition in Ill-Structured Domains». *Educational Technology* 31 (5): 24-33.
- Thorndike, Edward L. 1913. *Educational psychology*. New York: Teachers College, Columbia University.
- UIS-UNESCO. 2019. *UIS statistics*.
- Verschaffel, Lieven, Erik De Corte, Sabien Lasure, Griet Van Vaerenbergh, Hedwig Bogaerts y Elie Ratinckx. 1999. «Learning to Solve Mathematical Application Problems: A Design Experiment With Fifth Graders». *Mathematical Thinking and Learning* 1, n.º 3 (septiembre): 195-229.
- White, Robert W. 1959. «Motivation reconsidered: The concept of competence». *Psychological Review* 66 (5): 297-333.


Woodward, John, Sybilla Beckmann, Mark Driscoll, Megan Franke, Patricia Herzig, Asha Jitendra, Kenneth R. Koedinger y Philip Ogbuehi. 2012. *Improving mathematical problem solving in grades 4 through 8: A practice guide*. Practice Guide NCEE 2012-4055. Washington, D.C.: National Center for Education Evaluation y Regional Assistance, Institute of Education Sciences, U.S. Department of Education.

Woodworth, R. S., y E. L. Thorndike. 1901. «The influence of improvement in one mental function upon the efficiency of other functions. (I)». *Psychological Review* 8 (3): 247-261.

6 Figuras y tablas


Figuras

Figura 1: Diferencias en la secuencia de ejercicios completados por los estudiantes del estudio




Nota: Esta figura describe la secuencia de ejercicios completados por los estudiantes de ambos grupos experimentales del estudio.

Figura 2: Tiempo semanal y acumulado dedicado a la plataforma CAL durante el estudio




Notas: (1) Esta figura muestra el uso semanal (panel A) y acumulado (panel B) de la plataforma CAL para el estudiante mediano, por grupo experimental. (2) Esta figura incluye a todos los estudiantes observados en la línea de base y en la línea final, independientemente de si usaron el software (el 99.9% de los estudiantes lo hizo). (3) El uso se agrupa por semanas transcurridas desde el inicio del estudio (el 11 de septiembre de 2017).

Figura 3: Tiempo semanal y acumulado dedicado a los ejercicios de práctica durante el estudio entre los estudiantes de tratamiento



Notas: (1) Esta figura muestra el tiempo semanal (panel A) y acumulado (panel B) dedicado a los ejercicios de práctica de la plataforma para tres grupos de estudiantes de tratamiento: el estudiante mediano (es decir, el percentil 50), el percentil 25 y el percentil 75, para dar una idea de la variación en el uso dentro de la muestra. (2) Esta figura incluye a todos los estudiantes de tratamiento observados en la línea de base y en la línea final, independientemente de si usaron el software (el 99.9% de los estudiantes lo hizo). (3) El uso se agrupa por semanas transcurridas desde el inicio del estudio (el 11 de septiembre de 2017).

Figura 4: Efectos ITT heterogéneos en el rendimiento en matemática en la línea final, por cuartil de desempeño en la línea de base



Notas: ((1) Esta figura muestra la heterogeneidad del efecto de intención de tratar (ITT) de los ejercicios de práctica en el rendimiento de los estudiantes en matemática en la línea final (tras seis meses), por cuartil de desempeño en la línea de base dentro de cada grado. (2) Ambos paneles incluyen efectos fijos por estrato de aleatorización. (3) Las barras y los bigotes muestran intervalos de confianza del 90 por ciento y del 95 por ciento, respectivamente.

Tablas

Tabla 1: Pruebas de balance entre grupos experimentales

	(1) Control	(2) Tratamiento	(3) Diferencia
<i>A. Distribución por grado (muestra completa)</i>			
Grado 4	0.24 [0.43]	0.25 [0.43]	-0.00
Grado 5	0.29 [0.45]	0.28 [0.45]	0.01
Grado 6	0.25 [0.43]	0.26 [0.44]	-0.01
Grado 7	0.22 [0.41]	0.22 [0.41]	0.00
<i>B. Pruebas de balance (muestra completa)</i>			
Puntaje de línea de base	0.00 [1.00]	-0.03 [1.01]	0.03 (0.02)
Mujer	0.53 [0.50]	0.51 [0.50]	0.02 (0.01)
N (estudiantes)	2234	2227	
<i>C. Pruebas de balance (no desertores)</i>			
Puntaje de línea de base	0.02 [1.00]	-0.01 [1.00]	0.04 (0.02)
Mujer	0.53 [0.50]	0.52 [0.50]	0.01 (0.01)
N (estudiantes)	1984	2017	

Notas: (1) Esta tabla compara a los estudiantes de los grupos experimentales de control y de tratamiento en su matrícula por grado y sus características: muestra la media y la desviación estándar correspondiente de cada variable (entre corchetes) y compara ambos grupos incluyendo efectos fijos por estrato de aleatorización, con su diferencia de medias y el error estándar correspondiente (entre paréntesis). El panel A compara la matrícula por grado. No realiza pruebas de significancia porque, debido a la estrategia de estratificación, la matrícula por grado es comparable entre grupos por diseño. El panel B compara el puntaje de línea de base y el sexo de los estudiantes (las únicas dos variables recolectadas en la línea de base) para todos los estudiantes presentes en la línea de base. El panel C hace lo mismo solo para los estudiantes presentes tanto en la línea de base como en la línea final (el 90% del total). (2) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla 2: *Efecto ITT de los ejercicios de práctica en el rendimiento en matemática en la línea final*

	Puntaje en matemática (escalado con IRT)	
	(1)	(2)
Tratamiento	0.014 (0.027)	0.014 (0.025)
Puntaje de línea de base		0.645*** (0.025)
N (estudiantes)	4001	4001
R cuadrado	0.512	0.588

Notas: (1) Esta tabla muestra el efecto de intención de tratar (ITT) de los ejercicios de práctica en el rendimiento de los estudiantes en matemática en la línea final (tras seis meses). La columna 1 muestra la diferencia simple de medias (incluyendo efectos fijos por estrato de aleatorización); la columna 2, además, controla por el puntaje de línea de base. (2) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla 3: Efecto ITT de los ejercicios de práctica en el rendimiento en matemática en la línea final, por dominio de contenido y dominio cognitivo

A. Todos los estudiantes						
	(1) Números	(2) Geometría	(3) Datos	(4) Conocer	(5) Aplicar	(6) Razonar
Tratamiento	0.002 (0.004)	0.008 (0.005)	0.002 (0.006)	0.004 (0.005)	0.002 (0.004)	0.011* (0.006)
Puntaje de línea de base	0.077*** (0.004)	0.117*** (0.005)	0.114*** (0.006)	0.065*** (0.005)	0.102*** (0.004)	0.132*** (0.006)
N (estudiantes)	4001	4001	4001	4001	4001	4001
R cuadrado	0.513	0.495	0.405	0.475	0.533	0.501
B. Estudiantes de bajo rendimiento						
	(1) Números	(2) Geometría	(3) Datos	(4) Conocer	(5) Aplicar	(6) Razonar
Tratamiento	0.020** (0.009)	0.051*** (0.011)	0.013 (0.012)	0.027*** (0.009)	0.022** (0.009)	0.042*** (0.013)
Puntaje de línea de base	0.088*** (0.007)	0.125*** (0.009)	0.115*** (0.010)	0.076*** (0.008)	0.110*** (0.007)	0.141*** (0.011)
N (estudiantes)	4001	4001	4001	4001	4001	4001
R cuadrado	0.517	0.503	0.408	0.478	0.538	0.506

Notas: (1) Esta tabla muestra el efecto de intención de tratar (ITT) de los ejercicios de práctica en el rendimiento de los estudiantes en cada dominio de contenido (columnas 1-3) y cognitivo (columnas 4-6) en la línea final (tras seis meses). Todas las estimaciones incluyen efectos fijos por estrato de aleatorización. El panel A presenta los efectos ITT promedio entre todos los estudiantes. El panel B usa interacciones (no se muestran) para reportar los efectos ITT entre los estudiantes del cuartil inferior de su grado, según su desempeño en la evaluación de línea de base. (2) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla 4: Efectos ITT heterogéneos en el rendimiento en matemática en la línea final, por desempeño de los estudiantes en la línea de base


	Puntaje en matemática (escalado con IRT)	
	(1)	(2)
Tratamiento	0.014 (0.025)	0.136*** (0.050)
Puntaje de línea de base	0.672*** (0.028)	0.647*** (0.042)
Tratamiento X Línea de base	-0.054** (0.025)	
Cuartil 2		0.182*** (0.065)
Cuartil 3		0.198** (0.085)
Cuartil 4		0.144 (0.110)
Tratamiento X Cuartil 2		-0.160** (0.071)
Tratamiento X Cuartil 3		-0.131* (0.071)
Tratamiento X Cuartil 4		-0.193*** (0.070)
N (estudiantes)	4001	4001
R cuadrado	0.588	0.590

Notas: (1) Esta tabla muestra el efecto de intención de tratar (ITT) de los ejercicios de práctica en el rendimiento de los estudiantes en matemática en la línea final (tras seis meses) según su desempeño en la línea de base, ya sea como puntaje continuo (columna 1) o como un conjunto de variables indicadoras de cuartil (columna 2). Todas las estimaciones incluyen efectos fijos por estrato de aleatorización. (2) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Anexo A Figuras y tablas adicionales


Figuras adicionales

Figura A1: Distribución de los puntajes en matemática (escalados con IRT) por grupo experimental en la línea de base




Notas: (1) Esta figura muestra la distribución de los puntajes en la evaluación de matemática de línea de base para los estudiantes de control y de tratamiento. (2) Los puntajes se escalaron con un modelo logístico de dos parámetros de teoría de respuesta al ítem (IRT, por sus siglas en inglés). (3) Esta figura incluye a todos los estudiantes presentes en la línea de base y en la línea final.

Figura A2: Porcentaje del tiempo dedicado a la plataforma CAL en casa (en lugar de en la escuela)




Notas: (1) Esta figura muestra un gráfico suavizado por polinomios locales, con intervalos de confianza, del número de minutos que el estudiante promedio dedicó al software CAL en casa (en lugar de durante el horario escolar) en cada día del estudio. (2) Los intervalos de confianza del 95 por ciento se muestran con líneas discontinuas. (3) Esta figura incluye a todos los estudiantes que usaron el software en un día determinado.

Figura A3: Adopción entre los estudiantes del grupo de tratamiento, por escuela




Notas: (1) Para cada escuela del estudio, esta figura muestra el número promedio de minutos que los estudiantes del grupo de tratamiento dedicaron al software (panel A) y a los ejercicios de práctica (panel B). (2) Los errores estándar se muestran con bigotes grises. (3) Las escuelas están numeradas según el orden alfabético de sus localidades, de la siguiente manera. 1: Ahmedabad, Gujarat; 2: Faridabad, Haryana; 3: Ghaziabad, Uttar Pradesh; 4-5: Kolkata, West Bengal; 6-7: New Delhi, Delhi; 8: Rajkot, Gujarat; 9: Tiruchirappalli, Tamil Nadu.

Figura A4: Efectos ITT heterogéneos en el rendimiento en matemática en la línea final, por escuela



Notas: (1) Esta figura presenta un “gráfico de oruga” (“caterpillar plot”) de los efectos ITT por escuela (cf. Hippel y Bellows 2018). Cada punto negro corresponde a la estimación puntual para una escuela determinada. (2) Los intervalos de confianza de Bonferroni ajustan los errores estándar por pruebas de hipótesis múltiples. La línea negra continua muestra la distribución nula de los “efectos” que cabría esperar debido al error. τ es la desviación estándar de la heterogeneidad. Q se refiere al estadístico Q de Cochran, que sigue una distribución χ^2 , y p reporta el valor p correspondiente a una prueba de la hipótesis nula de ausencia de heterogeneidad. ρ estima la confiabilidad; es decir, la proporción de la varianza de las estimaciones que es atribuible a la heterogeneidad (y no al error). (3) La estimación controla por el rendimiento de los estudiantes en la línea de base y por efectos fijos por estrato de aleatorización.

Figura A5: *Relación dosis-respuesta*



Notas: (1) Esta figura muestra la heterogeneidad del efecto de intención de tratar (ITT) de los ejercicios de práctica en el rendimiento de los estudiantes en matemática en la línea final (tras seis meses) por estrato de aleatorización, para todos los estudiantes (panel A) y para los estudiantes del cuartil inferior de rendimiento en la línea de base dentro de su grado (panel B). (2) Las barras y los bigotes muestran intervalos de confianza del 90 por ciento y del 95 por ciento, respectivamente.

Tablas adicionales

Tabla A1: Distribución de la matrícula de educación elemental por tipo de escuela en los estados de India representados en este estudio, 2006-2007 y 2017-2018

	(1)	(2)	(3)	(4)	(5)	(6)
	Proporción de la matrícula en los grados 1 a 8 (educación elemental)					
	Estatad		Privada no subvencionada		Privada subvencionada	
Estado	2007-08	2017-18	2007-08	2017-18	2007-08	2017-18
Delhi	66%	53%	28%	44%	5.40%	3.40%
Gujarat	79%	62%	19%	36%	2.80%	2.10%
Haryana	74%	39%	23%	59%	3.20%	1.50%
Tamil Nadu	50%	37%	25%	46%	25%	17%
Uttar Pradesh	70%	46%	30%	42%	5.40%	5.60%
West Bengal	87%	86%	8.10%	11%	4.90%	0.30%

Fuentes: Central Square Foundation (2020).

Notas: (1) Los porcentajes indican la proporción de estudiantes inscritos en escuelas estatales, privadas no subvencionadas y privadas subvencionadas en todos los estados representados en nuestro estudio.

Tabla A2: *Proporción de ejercicios de práctica por debajo, en o por encima del nivel de grado*

Grado en que está inscrito	Proporción de ejercicios de práctica...				
	...dos o más grados por debajo	...un grado por debajo	...en el nivel de grado	...un grado por encima	...dos o más grados por encima
Grado 4	0.001	0.070	0.422	0.330	0.177
Grado 5	0.019	0.065	0.407	0.315	0.194
Grado 6	0.010	0.066	0.881	0.042	0.000
Grado 7	0.010	0.281	0.632	0.078	0.000
Todos los grados	0.010	0.113	0.579	0.198	0.099

Notas: (1) Esta tabla muestra la proporción de ejercicios de práctica completados por los estudiantes de tratamiento durante el estudio, según el grado en que estaban inscritos y el nivel de grado en que se clasificó cada ejercicio. Específicamente, muestra la proporción de ejercicios uno o dos (o más) grados por debajo, en el nivel de grado, o uno o dos (o más) grados por encima del grado en que estaba inscrito cada estudiante. (2) Los ejercicios de práctica pueden corresponder a varios niveles. En esta tabla, si un ejercicio incluye al menos el grado en que está inscrito el estudiante, se clasifica como en el nivel de grado.

Tabla A3: Ciudades, escuelas y fechas de evaluación y de activación del software

	(1) Escuela	(2) Fecha de línea de base (2017)	(3) Fecha de activación (2017)	(4) Fecha de línea final (2018)
Ahmedabad, Gujarat	1	25-26 sep	6-oct	3-5 abr
Faridabad, Haryana	2	26-sep	6-oct	27-28 mar
Ghaziabad, Uttar Pradesh	3	26-sep	6-oct	13-14 abr
Kolkata, West Bengal	4	15-sep	15-sep	7-9 mar
	5	14-sep	17-oct	5-7 mar
New Delhi, Delhi	6	21-22 sep	17-oct	16-abr
	7	25-sep	6-oct	9, 11, 12 abr
Rajkot, Gujarat	8	20-sep	22-sep	15-mar
Tiruchirappalli, Tamil Nadu	9	7-oct	9-oct	9, 11-13 abr

Notas: (1) Esta tabla muestra la lista de sitios, escuelas y fechas de evaluación y de activación del software para la muestra del estudio. (2) La fecha de activación del software se refiere a la fecha en que los ejercicios de práctica dejaron de estar disponibles para los estudiantes de control. (3) Las escuelas con varias fechas de línea de base y de línea final tenían varios grados en el estudio, cuyas fechas de evaluación diferían.

Tabla A4: Pruebas de balance entre grupos experimentales (solo entre estudiantes de bajo rendimiento)

	(1) Control Media/DE	(2) Tratamiento Media/DE	Diferencia (1)-(2)
<i>A. Distribución por grado (muestra completa)</i>			
Grado 4	0.25 [0.43]	0.24 [0.43]	0.01
Grado 5	0.29 [0.45]	0.28 [0.45]	0.01
Grado 6	0.25 [0.43]	0.26 [0.44]	-0.01
Grado 7	0.21 [0.41]	0.22 [0.42]	-0.02
<i>B. Pruebas de balance (muestra completa)</i>			
Puntaje de línea de base	-1.18 [0.63]	-1.15 [0.63]	-0.03 (0.03)
Mujer	0.49 [0.50]	0.49 [0.50]	-0.00 (0.03)
N (estudiantes)	533	584	
<i>C. Pruebas de balance (no desertores)</i>			
Puntaje de línea de base	-1.16 [0.62]	-1.15 [0.62]	-0.01 (0.03)
Mujer	0.50 [0.50]	0.50 [0.50]	-0.00 (0.03)
N (estudiantes)	462	519	

Notas: (1) Esta tabla compara a los estudiantes de bajo rendimiento de los grupos experimentales de control y de tratamiento en su matrícula por grado y sus características: muestra la media y la desviación estándar correspondiente de cada variable (entre corchetes) y compara ambos grupos incluyendo efectos fijos por estrato de aleatorización, con su diferencia de medias y el error estándar correspondiente (entre paréntesis). “Bajo rendimiento” se refiere a los estudiantes del cuartil inferior de su grado, según su desempeño en la evaluación de línea de base. El panel A compara la matrícula por grado. No realiza pruebas de significancia porque, debido a la estrategia de estratificación, la matrícula por grado es comparable entre grupos por diseño. El panel B compara el puntaje de línea de base y el sexo de los estudiantes (las únicas dos variables recolectadas en la línea de base) para todos los estudiantes presentes en la línea de base. El panel C hace lo mismo solo para los estudiantes presentes tanto en la línea de base como en la línea final (el 90% del total). (2) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A5: Efecto ITT de los ejercicios de práctica en el rendimiento en matemática en la línea final, por ítems repetidos y no repetidos

	(1) Puntaje en ítems repetidos (proporción correcta)	(2) Puntaje en ítems no repetidos (proporción correcta)
Tratamiento	0.005 (0.004)	0.002 (0.005)
Puntaje de línea de base	0.089*** (0.004)	0.110*** (0.005)
N (estudiantes)	4001	4001
R cuadrado	0.527	0.491

Notas: (1) Esta tabla muestra el efecto de intención de tratar (ITT) de los ejercicios de práctica en el rendimiento de los estudiantes en los ítems repetidos entre la línea de base y la línea final (columna 2) y en los ítems no repetidos (columna 3) en la línea final (tras 6 meses). Ambas estimaciones incluyen efectos fijos por estrato de aleatorización. (2) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A6: Efecto ITT de los ejercicios de práctica en el rendimiento en matemática en la línea final, según si las preguntas incluían palabras / lenguaje académico

	A. Todos los estudiantes					
	Proporción correcta		IRT (separado)		IRT (adicional)	
	(1)	(2)	(3)	(4)	(5)	(6)
	Sin palabras	Sin leng. acad.	Sin palabras	Sin leng. acad.	Sin palabras	Sin leng. acad.
Tratamiento	0.000 (0.004)	0.004 (0.004)	0.009 (0.025)	0.013 (0.025)	0.011 (0.025)	0.013 (0.025)
Puntaje de línea de base	0.059*** (0.004)	0.090*** (0.004)	0.610*** (0.025)	0.644*** (0.025)	0.597*** (0.025)	0.645*** (0.025)
N (estudiantes)	4001	4001	4001	4001	4001	4001
R cuadrado	0.434	0.550	0.575	0.588	0.564	0.589
	B. Estudiantes de bajo rendimiento					
	Proporción correcta		IRT (separado)		IRT (adicional)	
	(1)	(2)	(3)	(4)	(5)	(6)
	Sin palabras	Sin leng. acad.	Sin palabras	Sin leng. acad.	Sin palabras	Sin leng. acad.
Tratamiento	0.017** (0.009)	0.023*** (0.008)	0.126** (0.051)	0.132*** (0.050)	0.117** (0.052)	0.134*** (0.050)
Puntaje de línea de base	0.073*** (0.007)	0.099*** (0.007)	0.622*** (0.043)	0.646*** (0.042)	0.610*** (0.043)	0.647*** (0.041)
N (estudiantes)	4001	4001	4001	4001	4001	4001
R cuadrado	0.436	0.555	0.577	0.590	0.566	0.591

Notas: (1) Esta tabla muestra el efecto de intención de tratar (ITT) de los ejercicios de práctica en el rendimiento en matemática en la línea final (tras seis meses), según si las preguntas incluían palabras (columnas 1, 3 y 5) o lenguaje académico (columnas 2, 4 y 6). En las columnas 1 y 2, la variable de resultado es la proporción de respuestas correctas de los estudiantes en las preguntas que no requieren leer palabras (más allá de la instrucción “resuelve”) o leer términos académicos (p. ej., “rectángulo”). En las columnas 3 y 4, la variable de resultado es un puntaje factorial (estandarizado) de un modelo confirmatorio bidimensional 2PL de teoría de respuesta al ítem, en el que los ítems que no requieren saber leer cargan en este factor (y los ítems que sí lo requieren cargan en otro factor, separado, que se correlaciona con el primero). En las columnas 5 y 6, la variable de resultado es un puntaje factorial (estandarizado) de un modelo confirmatorio bidimensional 2PL de teoría de respuesta al ítem, en el que todos los ítems de matemática cargan en este factor (y los ítems que requieren saber leer también pueden cargar en otro factor, adicional, que se correlaciona con el primero). Todas las estimaciones incluyen efectos fijos por estrato de aleatorización. El panel A presenta los efectos ITT promedio entre todos los estudiantes. El panel B usa interacciones (no se muestran) para reportar los efectos ITT entre los estudiantes del cuartil inferior de su grado, según su desempeño en la evaluación de línea de base. (2) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A7: Efectos ITT heterogéneos en el rendimiento en matemática en la línea final, por sexo y grado en que están inscritos los estudiantes

	Puntaje en matemática (escalado con IRT)	
	(1)	(2)
Tratamiento	-0.015 (0.036)	0.021 (0.050)
Mujer	-0.050 (0.038)	-0.022 (0.029)
Tratamiento X Mujer	0.054 (0.050)	
Tratamiento X Grado 5		-0.011 (0.068)
Tratamiento X Grado 6		0.042 (0.071)
Tratamiento X Grado 7		-0.067 (0.073)
Puntaje de línea de base	0.646*** (0.025)	0.645*** (0.025)
N (estudiantes)	4001	4001
R cuadrado	0.588	0.588

Notas: (1) Esta tabla muestra el efecto de intención de tratar (ITT) de los ejercicios de práctica en el rendimiento de los estudiantes en matemática en la línea final (tras 25 semanas) para las estudiantes mujeres (columna 1) y para los estudiantes inscritos en distintos grados (columna 2). Ambas estimaciones incluyen efectos fijos por estrato de aleatorización de la línea de base. (2) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A8: Efecto ITT de los ejercicios de práctica en el uso de la plataforma CAL

	Número de sesiones completadas (log)	Minutos totales en la plataforma CAL (log)	
	(1)	(2)	(3)
<i>A. Todos los estudiantes</i>			
Tratamiento	0.010 (0.016)	0.023 (0.015)	0.015* (0.008)
Puntaje de línea de base	0.068*** (0.016)	0.101*** (0.015)	0.050*** (0.008)
Número de sesiones completadas (log)			0.760*** (0.008)
N (estudiantes)	3999	3999	3999
R cuadrado	0.477	0.504	0.845
<i>B. Estudiantes de bajo rendimiento</i>			
Tratamiento	0.087** (0.036)	0.082** (0.033)	0.016 (0.018)
Puntaje de línea de base	0.095** (0.044)	0.147*** (0.040)	0.075*** (0.022)
Número de sesiones completadas (log)			0.756*** (0.018)
N (estudiantes)	979	979	979
R cuadrado	0.409	0.429	0.824

Notas: (1) Esta tabla muestra el efecto de intención de tratar (ITT) de los ejercicios de práctica en el (logaritmo natural del) número de sesiones que completaron los estudiantes (columna 1), en el (logaritmo natural de los) minutos que dedicaron a la plataforma CAL (columna 2) y en esa misma cifra manteniendo constante el número de sesiones completadas (columna 3). Todas las estimaciones incluyen efectos fijos por estrato de aleatorización. (2) Las estimaciones excluyen a 2 (de 4,001) estudiantes que no dedicaron tiempo alguno al software. (3) El panel A presenta los resultados para todos los estudiantes. El panel B presenta los resultados para la submuestra de estudiantes del cuartil inferior de su grado, según su desempeño en la evaluación de línea de base. (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A9: Robustez de los resultados de la estimación al ajuste de los errores estándar para tener en cuenta las correlaciones en los resultados de los estudiantes a nivel de aula

	Efecto principal		Interacc. continua		Por cuartil	
	(1)	(2)	(3)	(4)	(5)	(6)
Tratamiento	0.014 (0.025)	0.014 (0.026)	0.014 (0.025)	0.014 (0.025)	0.136*** (0.050)	0.136*** (0.043)
Puntaje de línea de base	0.645*** (0.025)	0.645*** (0.027)	0.672*** (0.028)	0.672*** (0.031)	0.647*** (0.042)	0.647*** (0.056)
Tratamiento X Línea de base			-0.054** (0.025)	-0.054** (0.026)		
Cuartil 2					0.182*** (0.065)	0.182*** (0.064)
Cuartil 3					0.198** (0.085)	0.198** (0.091)
Cuartil 4					0.144 (0.110)	0.144 (0.134)
Tratamiento X Cuartil 2					-0.160** (0.071)	-0.160** (0.065)
Tratamiento X Cuartil 3					-0.131* (0.071)	-0.131* (0.067)
Tratamiento X Cuartil 4					-0.193*** (0.070)	-0.193*** (0.067)
N (estudiantes)	4001	4001	4001	4001	4001	4001
R cuadrado	0.588	0.588	0.588	0.588	0.590	0.590
Errores estándar agrupados	No	Sí	No	Sí	No	Sí

Notas: (1) Esta tabla muestra las estimaciones de las tablas 2 y 4 (efectos ITT promedio y heterogéneos de los ejercicios de práctica, respectivamente) con y sin ajuste de los errores estándar para tener en cuenta la correlación en los resultados de los estudiantes a nivel de aula. (2) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A10: Robustez de los resultados ante la deserción sistemática

	Efecto promedio			Cuartil más bajo		
	(1) IPW	(2) Lee (inferior)	(3) Lee (superior)	(4) IPW	(5) Lee (inferior)	(6) Lee (superior)
Tratamiento	0.015 (0.025)	-0.034 (0.024)	0.060** (0.024)	0.135*** (0.041)	0.114** (0.048)	0.134*** (0.048)
N (estudiantes)	4001	3965	3966	4001	3965	3966
R cuadrado	0.589	0.624	0.609	0.591	0.627	0.610

Notas: (1) Esta tabla muestra el efecto de intención de tratar (ITT) de los ejercicios de práctica en el rendimiento de los estudiantes en matemática en la línea final (tras 6 meses). Las columnas 1-3 muestran efectos promedio; las columnas 4-6 muestran efectos entre los estudiantes del cuartil inferior de rendimiento en la línea de base dentro de su grado. (2) Las columnas 1 y 4 muestran estimaciones ponderadas por la inversa de la probabilidad (IPW, por sus siglas en inglés); las columnas 2-3 y 5-6 muestran las cotas de Lee (2009). (3) Todas las estimaciones incluyen efectos fijos por estrato de aleatorización y los puntajes de línea de base (resultados no mostrados). Las columnas 4-6 incluyen, aunque no reportan, efectos fijos por cuartil y sus interacciones con el indicador de tratamiento. (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.