

Enseñar *con* la prueba: Evidencia experimental sobre retroalimentación diagnóstica y fortalecimiento de capacidades para escuelas públicas en Argentina*

Rafael de Hoyos[†]
Banco Mundial

Alejandro J. Ganimian[‡]
New York University

Peter A. Holland[§]
Banco Mundial

8 de julio de 2019

Resumen

Examinamos el impacto de dos estrategias para usar los resultados de evaluaciones a gran escala con el fin de mejorar la gestión escolar y la enseñanza en el aula en la provincia de La Rioja, Argentina. Asignamos aleatoriamente 104 escuelas primarias públicas a: un grupo de retroalimentación diagnóstica, en el que administramos pruebas estandarizadas en la línea de base y en dos seguimientos y pusimos los resultados a disposición de las escuelas; un grupo de fortalecimiento de capacidades, en el que además realizamos talleres y visitas a las escuelas; o un grupo de control, en el que administramos las pruebas en el segundo seguimiento. Después de dos años, las escuelas de retroalimentación diagnóstica superaron a las escuelas de control por $.33\sigma$ en matemática y $.36\sigma$ en lectura. De hecho, las escuelas de retroalimentación todavía obtuvieron resultados $.26\sigma$ mejores en matemática y $.22\sigma$ en lectura en la evaluación nacional un año después de finalizada la intervención. Además, los directores de estas escuelas fueron más propensos a usar los resultados de las evaluaciones para tomar decisiones de gestión, y los estudiantes fueron más propensos a informar que sus docentes usaban más estrategias de enseñanza y los calificaron de manera más favorable. Combinar la retroalimentación con el fortalecimiento de capacidades no parece generar mejoras adicionales, pero esto podría deberse a que las escuelas asignadas a recibir ambos componentes partieron de niveles de aprendizaje más bajos y participaron en menos talleres y visitas de lo previsto.

Códigos JEL: C93, I21, I22, I25.

Palabras clave: Retroalimentación diagnóstica, fortalecimiento de capacidades, evaluaciones a gran escala, Argentina.

*Agradecemos el financiamiento otorgado por el Banco Mundial para este estudio. Agradecemos a Rita Abdala, Walter Flores, Silvia Romero y Juan Vegas, del Ministerio de Educación de La Rioja, y a Eduardo Cascallar, Jorge Fasce y Gustavo Iaies, del Centro de Estudios en Políticas Públicas, por hacer posible este estudio. María Cortelezzi, Alvina Erman, Bárbara Funtowicz, Andrés Felipe Pérez, Melissa Rofman, María José Vargas y Guillermo Toral colaboraron en la gestión del proyecto. Por último, agradecemos a Larry Aber, Felipe Barrera-Ororio, Elise Cappella, Joe Cimpian, Sean Corcoran, Andy de Barros, Emmerich Davies, Andrew Ho, Jimmy Kim, Dan Koretz, Isaac Mbiti, Dick Murnane, Jeff Puryear, Jonah Rockoff, Jennifer Steele, Hiro Yoshikawa y a los participantes de seminarios en APPAM, FRA, HGSE, NEUDC, NYU y el Banco Mundial por sus valiosos comentarios. Todas las opiniones expresadas son de los autores y no de ninguna de las instituciones a las que están afiliados.

[†]Economista principal, Educación, Banco Mundial. Correo electrónico: rdehoyos@worldbank.org.

[‡]Profesor adjunto de Psicología Aplicada y Economía, Steinhardt School of Culture, Education, and Human Development, New York University. Correo electrónico: alejandros.ganimian@nyu.edu.

[§]Especialista sénior, Educación, Banco Mundial. Correo electrónico: pholland@worldbank.org.

1 Introducción

Durante la última década, los países en desarrollo han desplazado su atención de ampliar el acceso a la escolarización a asegurar que los niños adquieran habilidades básicas en la escuela.¹ Este consenso emergente ha llevado a un número creciente de países de ingresos bajos y medianos a administrar evaluaciones de estudiantes a gran escala y a participar en evaluaciones internacionales. Según un relevamiento, 85 sistemas escolares nacionales han realizado 306 evaluaciones de matemática, lectura y ciencias desde 2004 (Cheng and Gale 2014). Un esfuerzo similar encontró que 328 sistemas escolares nacionales y subnacionales participaron en 37 evaluaciones internacionales de las mismas materias entre 1963 y 2015; casi la mitad de ellos comenzó a participar a partir de 1995 (Ganimian and Koretz 2017).²

Sin embargo, a pesar del crecimiento exponencial de las evaluaciones de estudiantes en el mundo en desarrollo, todavía sabemos sorprendentemente poco sobre si los gobiernos de estos contextos pueden aprovechar los resultados de estas pruebas para mejorar la gestión escolar y la enseñanza en el aula (y, de ser así, cómo). La mayoría de los estudios previos se han centrado en cómo usar las evaluaciones nacionales con fines de rendición de cuentas, como incentivar a los padres a enviar a sus hijos a escuelas con mejor desempeño (véase, por ejemplo, Andrabi et al. 2017; Camargo et al. 2018; Mizala and Urquiola 2013), o en cómo usar las evaluaciones en el aula para orientar la implementación de enseñanza diferenciada o estructurada (véase Banerjee et al. 2011; Bassi et al. 2016; Duflo et al. 2015; Piper and Korda 2011). Los pocos estudios que evalúan el impacto de usar evaluaciones a gran escala con fines formativos llegan a conclusiones contradictorias (véase de Hoyos et al. 2017; Muralidharan and Sundararaman 2010).³

Este artículo presenta evidencia experimental sobre dos estrategias para usar los resultados de evaluaciones a gran escala con fines de mejora en un país en desarrollo: la retroalimentación diagnóstica y el fortalecimiento de capacidades. Asignamos aleatoriamente 104 escuelas primarias públicas de la provincia de La Rioja, Argentina, a: (a) un grupo de retroalimentación

¹En los Objetivos de Desarrollo del Milenio, adoptados por la Asamblea General de las Naciones Unidas en 2000, 191 países se comprometieron a asegurar que “para 2015, los niños y niñas de todo el mundo puedan terminar un ciclo completo de enseñanza primaria” (UNGA 2000). En los Objetivos de Desarrollo Sostenible, adoptados en 2015, 194 países fijaron una nueva meta: “para 2030... todas las niñas y todos los niños [deberán] terminar una educación primaria y secundaria gratuita, equitativa y de *calidad* que produzca *resultados de aprendizaje* pertinentes y efectivos” (UNGA 2015, énfasis agregado).

²Es probable que estas cifras aumenten a medida que los organismos de evaluación desarrollen evaluaciones para países de ingresos bajos, que han sido reacios a sumarse a las pruebas globales existentes (p. ej., el Programa para la Evaluación Internacional de Alumnos para el Desarrollo, de la Organización para la Cooperación y el Desarrollo Económicos, y la Evaluación de Lectoescritura y Aritmética, de la Asociación Internacional para la Evaluación del Rendimiento Educativo).

³Esta pregunta ha recibido más atención en los países desarrollados (véase, por ejemplo, Betts et al. 2017). Sin embargo, no está claro que las lecciones de estos estudios se apliquen a los países en desarrollo, que tienen evaluaciones técnicamente menos sólidas y menor capacidad para analizar y difundir sus resultados.

diagnóstica (T1), en el que administramos pruebas estandarizadas de matemática y comprensión lectora en la línea de base y en dos seguimientos y pusimos los resultados a disposición de las escuelas mediante informes fáciles de usar; (b) un grupo de fortalecimiento de capacidades (T2), en el que además realizamos talleres de desarrollo profesional y visitas a las escuelas para supervisores, directores y docentes; o (c) un grupo de control, en el que solo administramos las pruebas en el segundo seguimiento. Este diseño nos permite entender si difundir los resultados de las evaluaciones entre las escuelas basta para impulsar mejoras en la gestión y la enseñanza, o si los directores y docentes necesitan apoyo adicional para comprender esta información y actuar en consecuencia.

Presentamos tres conjuntos de resultados basados en este experimento. Primero, encontramos que simplemente brindar a las escuelas información sobre el desempeño de sus estudiantes en relación con el resto de la provincia, con un fortalecimiento de capacidades mínimo, generó grandes mejoras en el aprendizaje de los estudiantes después de dos años: las escuelas T1 superaron a las escuelas de control por $.33\sigma$ en matemática y $.36\sigma$ en lectura. Es importante destacar que esta intervención generó mejoras en casi todos los dominios de contenido y dominios cognitivos evaluados en ambas materias, no solo en aquellos más fáciles de mejorar en el corto plazo, lo que sugiere que no provocó un estrechamiento del currículo, o lo que se conoce como “enseñar para la prueba”. Además, la intervención generó mejoras tanto en los ítems comunes a todas las rondas como en los ítems nuevos, lo que indica que las mejoras en los puntajes no se deben a la familiaridad con la prueba. Las cotas de los efectos van desde efectos moderadamente negativos hasta efectos positivos muy grandes. Sin embargo, también encontramos que los estudiantes expuestos a la intervención durante dos años todavía superaban a sus pares del grupo de control por $.26\sigma$ en matemática y $.22\sigma$ en lectura en la evaluación nacional de estudiantes un año después de finalizado el experimento, lo que indica que las mejoras no dependen de la prueba ni son de corta duración.

Segundo, en línea con estos efectos, encontramos que la retroalimentación diagnóstica también generó cambios en la gestión escolar y en la enseñanza en el aula. Los directores de las escuelas T1 fueron más propensos que sus pares de las escuelas de control a informar que usaban los resultados de las evaluaciones para orientar decisiones de gestión (p. ej., hacer cambios en el currículo, evaluar la efectividad de los docentes, informar a los padres sobre los resultados de sus hijos y hacer públicos los resultados).⁴ Los estudiantes de las escuelas T1 fueron más propensos que sus pares del grupo de control a informar que sus docentes usaban más estrategias de enseñanza (p. ej., usar libros de texto, asignar tareas, escribir en el pizarrón

⁴Curiosamente, sin embargo, estos directores no fueron más propensos a usar los puntajes de las pruebas para asignar estudiantes a secciones, lo que sugiere que la intervención no aumentó la segregación de las oportunidades educativas dentro de las escuelas.

y explicar los temas).⁵ También calificaron a sus docentes de manera más positiva en todos los dominios de una encuesta a estudiantes de uso extendido (p. ej., mostrar interés por los estudiantes, manejar el aula, aclarar conceptos y tareas difíciles, desafiar a los estudiantes a dar lo mejor de sí, dar clases atractivas, involucrar a los estudiantes en discusiones y resumir el material al final de cada clase). Sin embargo, la retroalimentación diagnóstica no mejoró la asistencia ni la puntualidad de los docentes.

Por último, no encontramos evidencia de que combinar la provisión de información con talleres y visitas a las escuelas genere mejoras adicionales en la gestión escolar, la enseñanza o el aprendizaje. De hecho, para la mayoría de los resultados y mecanismos potenciales, no encontramos un impacto estadísticamente significativo de T2 y no podemos descartar la posibilidad de que T1 y T2 hayan tenido el mismo efecto. Sin embargo, estos resultados deben interpretarse con cautela. Primero, es posible que las escuelas asignadas aleatoriamente a T2 ya estuvieran en desventaja respecto de las asignadas a T1 en la línea de base. T1 y T2 tenían una eficiencia interna y características de los estudiantes similares, pero las escuelas T2 obtuvieron resultados levemente inferiores a los de las escuelas T1 en las evaluaciones. La brecha era pequeña y no estadísticamente significativa, pero podría explicar por qué T2 no tuvo un efecto al menos tan grande como el de T1.⁶ Segundo, la participación en talleres y visitas entre las escuelas T2 fue menor de lo previsto, y algunas escuelas T1 participaron en estas actividades aunque no debían hacerlo. La baja participación y la contaminación pueden haber hecho que la mayoría de las escuelas T2 no recibiera mucho más apoyo que las escuelas T1, lo que habría preservado el desequilibrio inicial entre ambos grupos.⁷

Nuestros resultados contribuyen a la literatura de evaluación de impacto sobre el uso de evaluaciones a gran escala en países en desarrollo en al menos dos sentidos. Primero, demuestran que es posible usar los resultados de las evaluaciones para mejorar el aprendizaje de los estudiantes sin necesidad de asociarles consecuencias. Esto es importante porque, incluso cuando el uso de evaluaciones con altas consecuencias ha funcionado (p. ej., Muralidharan 2012; Muralidharan and Sundararaman 2011), ha enfrentado oposición política. Segundo, ofrecen una posible explicación para los resultados mixtos de intervenciones de retroalimentación previas. Una posibilidad es que la retroalimentación tenga menos margen de impacto en contextos donde la restricción principal es el margen extensivo del esfuerzo de

⁵Sin embargo, estos estudiantes no fueron más propensos a informar que sus docentes les hacían completar pruebas de práctica, lo que aporta más evidencia de que la intervención no derivó en un “entrenamiento” para la prueba.

⁶Presentamos dos resultados consistentes con esta posibilidad. Primero, solo encontramos un efecto estadísticamente significativo de T2 en 5.^o grado, donde la diferencia inicial entre las escuelas T1 y T2 era menor. Segundo, los coeficientes de T2 aumentan cuando controlamos por covariables de línea de base en 3.er grado, donde la diferencia inicial era mayor.

⁷Presentamos datos de encuestas a directores y del monitoreo de la intervención que verifican que las escuelas T1 y T2 recibieron niveles de apoyo similares.

directores y docentes (es decir, mejorar la asistencia) (Muralidharan and Sundararaman 2010), pero resulte prometedora donde la restricción es el margen intensivo del esfuerzo (aumentar la productividad, condicional a la asistencia) (de Hoyos et al. 2017).

El resto del artículo se estructura de la siguiente manera. La sección 2 describe el contexto, las intervenciones, el muestreo y la aleatorización. La sección 3 presenta los datos. La sección 4 discute la estrategia empírica. La sección 5 informa los resultados. La sección 6 discute las implicancias para la política y la investigación.

2 Experimento

2.1 Contexto

En Argentina, la escolaridad es obligatoria desde los 4 años hasta el final de la escuela secundaria. En 12 de las 24 provincias del país, incluida la provincia de La Rioja, la escuela primaria abarca de 1.^o a 7.^o grado y la secundaria de 8.^o a 12.^o grado (DiNIECE 2013).⁸ Según las cifras oficiales más recientes, el sistema escolar argentino atiende a 11.1 millones de estudiantes: 1.7 millones en el nivel inicial, 4.5 millones en primaria y 3.9 millones en secundaria (DiNIEE 2015).

Argentina logró un acceso casi universal a la educación primaria antes que la mayor parte de América Latina (véase Bassi et al. 2013). Sin embargo, el desempeño relativo de los estudiantes argentinos de primaria en la región se ha deteriorado. En 1997, en la primera evaluación regional de estudiantes de primaria, los estudiantes argentinos de 3.er grado habían ocupado el segundo lugar en matemática, después de sus pares cubanos. En 2013, en la tercera evaluación regional, ocuparon el séptimo lugar—a la par de sus pares de Perú y Ecuador, que se habían ubicado cerca del último lugar en 1997 y 2006 (Ganimian 2014).⁹

En Argentina, la política educativa está a cargo tanto del gobierno nacional como de los gobiernos subnacionales (provinciales). Según la Ley de Educación Nacional de 2006, el gobierno federal es responsable de la educación superior y de brindar asistencia técnica y financiera a las provincias, y los gobiernos provinciales, de la educación inicial, primaria y secundaria. El Ministerio de Educación, Cultura, Ciencia y Tecnología de la Nación también tiene a su cargo coordinar la evaluación nacional de estudiantes (antes denominada *Operativo Nacional de Evaluación* y actualmente *Aprender*), vigente desde 1993, en conjunto con sus

⁸En las otras 12 provincias, la primaria abarca de 1.^o a 6.^o grado y la secundaria de 7.^o a 12.^o grado.

⁹Las evaluaciones de 1997 y 2006 no son estrictamente comparables, pero ningún otro país que participó en ambas evaluaciones cambió su posición de manera tan radical. Además, la posición relativa de los estudiantes argentinos de secundaria también se deterioró durante el mismo período (de Hoyos et al. 2015; Ganimian 2013).

pares de cada provincia. Hasta donde sabemos, solo la Ciudad Autónoma de Buenos Aires realiza regularmente su propia evaluación subnacional de estudiantes.

Argentina es un contexto interesante para evaluar el impacto de aprovechar las evaluaciones de estudiantes para la retroalimentación diagnóstica y el fortalecimiento de capacidades de las escuelas. Durante las últimas dos décadas, el país tomó varias medidas que limitaron la generación, difusión y uso de datos sobre el logro de los estudiantes: (a) redujo la frecuencia de su evaluación nacional de anual (en 1999-2000) a bienal (en 2002-2007) y luego a trienal (en 2008-2013); (b) prohibió por ley la publicación de resultados de aprendizaje desagregados a nivel de estudiante, docente o escuela; y (c) en 2013, dejó de publicar los resultados de las evaluaciones a nivel provincial y pasó a publicarlos a nivel regional (Ganimian 2015). Estas políticas han contrastado marcadamente con las de otros países de América Latina (p. ej., Brasil, Chile, Colombia, México y Perú), que cuentan con evaluaciones técnicamente sólidas y de larga trayectoria y las utilizan con múltiples fines (Ferrer 2006; Ferrer and Fiszbein 2015).

En los últimos años, un nuevo gobierno revirtió algunas de estas políticas: (a) adoptó una nueva evaluación nacional, que se administraría anualmente, abarcaría a todos los estudiantes al final de la primaria y la secundaria (7.^o y 12.^o grado) y a una muestra a mitad de cada nivel (3.^{er} y 8.^o grado), y evaluaría matemática, lectura y ciencias naturales y sociales (SEE-MEDN 2016);¹⁰ y (b) comenzó a compartir con todos los directores los resultados de las evaluaciones a nivel escolar mediante informes similares a los evaluados en este artículo.¹¹ Por lo tanto, las preguntas que examinamos en este artículo no solo son de interés general para los países en desarrollo, sino también de interés específico para Argentina.

Realizamos nuestro estudio en La Rioja por tres razones. Primero, es una de las provincias con peor desempeño de Argentina. En la última evaluación nacional, el 41% de sus estudiantes de 6.^o grado se ubicó en los dos niveles más bajos en matemática y el 53% en lectura (SEE-MEDN 2018). Segundo, es uno de los sistemas escolares subnacionales más pequeños del país, por lo que está mejor posicionado para implementar un mecanismo de aseguramiento de la calidad. Es el séptimo sistema más pequeño en cantidad de escuelas (377 escuelas primarias) y el cuarto más pequeño en cantidad de estudiantes (41,571 estudiantes de primaria) (DiNIEE 2015). Tercero, fue una de las pocas provincias con la voluntad política de experimentar con una evaluación subnacional. La evaluación contó con el respaldo del gobernador y del ministro de educación.

¹⁰En 2017, el gobierno nacional comenzó a alternar cada año los grados y las asignaturas evaluados.

¹¹Una versión en español del informe puede consultarse en: <https://bit.ly/2MfSpLu>.

2.2 Muestra

El marco muestral del estudio incluyó las 126 escuelas primarias públicas de zonas urbanas y semiurbanas de La Rioja.¹² Llegamos a este marco de la siguiente manera. Primero, de las 394 escuelas primarias de la provincia, excluimos las 29 escuelas privadas porque nos interesaba el efecto de las intervenciones en las escuelas públicas. Luego, descartamos las 239 escuelas de zonas rurales porque están dispersas por toda la provincia, lo que habría limitado nuestra capacidad para implementar las intervenciones.¹³ De este marco, extrajimos una muestra aleatoria de 104 escuelas primarias públicas urbanas y semiurbanas, estratificada por tercil de matrícula en el ciclo lectivo 2013.

Las escuelas de nuestra muestra son comparables con todas las escuelas primarias públicas de la provincia, y aún más con las demás escuelas primarias públicas urbanas y semiurbanas (Tabla A.1, Apéndice A). La escuela promedio de nuestra muestra tiene más estudiantes matriculados, pero esto se debe principalmente a que excluimos las escuelas rurales, que suelen ser más pequeñas. No encontramos ninguna diferencia estadísticamente significativa entre las escuelas en la muestra y fuera de la muestra en los indicadores de eficiencia interna que recopila el sistema escolar, entre ellos: las tasas de promoción, reprobación, abandono y repitencia.

Muestreamos estudiantes y docentes para obtener información *transversal* en 3.er y 5.º grado cada año, así como información *longitudinal* sobre los estudiantes que comenzaron 3.er grado en 2013. Así, en 2013 participaron todos los estudiantes y docentes de 3.er y 5.º grado; en 2014, todos los estudiantes y docentes de 3.er a 5.º grado; y en 2015, todos los estudiantes y docentes de 3.er y 5.º grado. Todos los directores de las escuelas seleccionadas participaron en el estudio.

2.3 Aleatorización

Asignamos aleatoriamente las 104 escuelas primarias públicas de nuestra muestra a: (a) un grupo de “retroalimentación diagnóstica” (T1), en el que administramos evaluaciones de estudiantes en la línea de base y en dos seguimientos y pusimos los resultados a disposición de las escuelas mediante informes de fácil lectura; (b) un grupo de “fortalecimiento de capacidades” (T2), en el que además ofrecimos a las escuelas talleres de desarrollo profesional y visitas a las escuelas para supervisores, directores y docentes; o (c) un grupo de control, en

¹²A lo largo de este artículo, usamos el término “semiurbanas” para referirnos a las zonas conocidas localmente como *rurales aglomeradas* y “rurales” para las zonas conocidas como *rurales dispersas*.

¹³Cabe señalar, sin embargo, que si bien las escuelas rurales representan una gran proporción del total de escuelas públicas de La Rioja (65% del total), atienden a una pequeña proporción de los estudiantes (menos del 10%).

el que solo administramos las evaluaciones en la línea final.¹⁴ Estratificamos la aleatorización por terciles de matrícula en la escuela primaria para aumentar el poder estadístico.¹⁵

Este diseño nos permite estimar el efecto de: (a) la retroalimentación diagnóstica (comparando las escuelas T1 con las de control en 2015); (b) la combinación de retroalimentación diagnóstica y fortalecimiento de capacidades (comparando las escuelas T2 con las de control en 2015); y (c) el valor agregado del fortalecimiento de capacidades, más allá de la retroalimentación diagnóstica (comparando las escuelas T1 con las T2 en 2014 y 2015).

2.4 Intervenciones

La Tabla 1 muestra el cronograma de las intervenciones y de las rondas de recolección de datos del estudio. En Argentina, el ciclo lectivo comienza en febrero y termina en diciembre. Como muestra la tabla, administramos las evaluaciones de estudiantes al final de cada año (solo en las escuelas T1 y T2 en 2013 y 2014, y en todas las escuelas en 2015). Entregamos a las escuelas T1 y T2 informes escolares basados en las evaluaciones del año anterior al comienzo de cada año (en 2014 y 2015). Realizamos talleres y visitas a las escuelas T2 durante cada ciclo lectivo (en 2014 y 2015).

2.4.1 Grupo de retroalimentación diagnóstica (T1)

La intervención de retroalimentación diagnóstica brindó a las escuelas datos confiables, oportunos y útiles para la acción sobre los resultados de aprendizaje de los estudiantes, con el fin de orientar la gestión escolar y la enseñanza en el aula. Al comienzo de cada año, y durante dos años consecutivos (2014 y 2015), las escuelas asignadas aleatoriamente al grupo T1 recibieron informes que resumían los resultados de las evaluaciones de estudiantes de matemática y lectura administradas al final del año anterior.¹⁶

Los informes eran breves (10 páginas) y tenían cuatro secciones: (a) una introducción, que describía las evaluaciones e informaba el porcentaje de estudiantes de la escuela que las completaron; (b) un panorama del desempeño promedio de la escuela, que incluía el puntaje promedio de la escuela en cada grado y asignatura, el cambio en cada puntaje respecto del año anterior y comparaciones entre los puntajes de la escuela y los de la escuela promedio

¹⁴Explicamos los motivos de esta decisión en la sección siguiente.

¹⁵Realizamos la aleatorización en junio de 2013. Se informó a las escuelas T1 y T2 que formarían parte del estudio en agosto de ese año, pero las escuelas de control no se dieron a conocer hasta justo antes de la línea final, para minimizar los efectos John Henry (es decir, que las escuelas intentaran compensar el hecho de no recibir una intervención).

¹⁶En la Tabla 1 especificamos los grados evaluados cada año.

de la zona y de la provincia;¹⁷ (c) un análisis de la distribución del desempeño de la escuela, que incluía un diagrama de caja y bigotes para la escuela y la provincia en cada grado y asignatura; y (d) una presentación tipo “semáforo” del desempeño de la escuela en cada ítem de las evaluaciones para cada grado y asignatura.¹⁸

Como revela la Tabla 1, algunas escuelas T1 participaron en los talleres y visitas diseñados para las escuelas T2 (descritos más abajo). Por lo tanto, nuestra estimación del efecto causal de la intervención T1 debe interpretarse como el efecto de la retroalimentación diagnóstica con un fortalecimiento de capacidades mínimo.

2.4.2 Grupo de fortalecimiento de capacidades (T2)

La intervención de fortalecimiento de capacidades brindó a supervisores, directores y docentes apoyo para comprender los resultados de aprendizaje de los estudiantes presentados en los informes escolares y tomar decisiones basadas en ellos. Durante el ciclo lectivo, y durante dos años consecutivos (2014 y 2015), a las escuelas asignadas aleatoriamente al grupo T2 se les ofrecieron los mismos informes que al grupo T1, cinco talleres (tres en 2014 y dos en 2015) y dos visitas a las escuelas (una por año).

Dos de los talleres explicaron los resultados de las evaluaciones después de cada ronda de entrega de los informes, uno se centró en cómo elaborar planes de mejora escolar, otro en cómo instituir mecanismos de aseguramiento de la calidad a nivel escolar y otro en la enseñanza de la geometría. Los primeros cuatro talleres se ofrecieron a supervisores y directores, y el último, a docentes. Cada visita a la escuela incluyó una reunión con el director y su equipo directivo, una observación de clase y una reunión con el personal docente. Los talleres y las visitas estuvieron a cargo del ministerio de educación de la provincia, en colaboración con un centro de estudios local. Después de cada visita, el ministerio elaboró y compartió con la escuela un informe que incluía un diagnóstico y algunas recomendaciones de mejora.¹⁹

Como muestra la Tabla 1, la participación en los talleres y las visitas a las escuelas fue menor que la esperada. En la sección 5.2, usamos los datos de la línea final para analizar la variación en la dosis entre las escuelas T2.

¹⁷Todos los puntajes se escalaron y vincularon mediante un modelo de teoría de respuesta al ítem de dos parámetros.

¹⁸Una versión en inglés del informe puede consultarse en: <http://bit.ly/2xrRaoc>.

¹⁹Los talleres y las visitas a las escuelas se basaron en las recomendaciones de Boudett et al. (2005).

2.4.3 Grupo de control

Las escuelas de control solo fueron evaluadas en 2015, al final del último año del estudio. Las evaluaciones de estudiantes eran poco frecuentes en La Rioja,²⁰ por lo que administrar evaluaciones en 2013 y 2014 podría haber provocado en directores, docentes y estudiantes respuestas conductuales que no habrían representado con precisión la gestión escolar y la enseñanza en el aula habituales. Así, siguiendo a Muralidharan and Sundararaman (2010), solo administramos las evaluaciones de línea final en estas escuelas para estimar el impacto de las intervenciones después de dos años.

3 Datos

Como indica la Tabla 1, administramos evaluaciones de estudiantes de matemática y lectura, y encuestas a estudiantes y docentes, en las escuelas T1 y T2 en cada año del estudio (de 2013 a 2015). También realizamos encuestas a directores al final de cada año de intervención (en 2014 y 2015). Solo administramos las evaluaciones en las escuelas de control al final del estudio (en 2015).²¹ Además, obtuvimos datos de eficiencia interna de todas las escuelas de nuestro estudio (de 2013 a 2017) y datos sobre resultados de aprendizaje de la evaluación nacional de estudiantes (de 2016).

3.1 Evaluaciones de estudiantes

Administramos evaluaciones de estudiantes de matemática y lectura antes de las intervenciones (en 2013) y después de uno y dos años de intervención (en 2014 y 2015) en las escuelas T1 y T2. Solo administramos las evaluaciones en las escuelas de control al final del segundo año (en 2015).²²

Las evaluaciones midieron lo que los estudiantes deberían saber y saber hacer según: (a) el currículo nacional (*Contenidos Básicos Comunes*); (b) los temas del currículo que el

²⁰La última evaluación nacional de estudiantes se había realizado en una muestra de escuelas primarias en 2010. No se había realizado ninguna evaluación nacional censal en las escuelas primarias de la provincia desde 2000. La provincia nunca había administrado evaluaciones subnacionales (Ganimian 2015).

²¹Los grados evaluados cada año se presentan en la Tabla 1.

²²Es posible que a algunos estudiantes les falten puntajes de las pruebas porque estuvieron ausentes el día de las evaluaciones, estuvieron presentes pero fueron eximidos de las pruebas, abandonaron la escuela o se cambiaron a otra escuela. Sin embargo, no encontramos evidencia de que las escuelas de tratamiento tuvieran más estudiantes que las escuelas de control en esos días; de hecho, en 2015 observamos lo contrario y todas las diferencias son inferiores a 5 puntos porcentuales (véase la Tabla A.2). La tasa de abandono en nuestra muestra es extremadamente baja y varía poco entre los grupos experimentales (Tablas A.3 y A.15). No contamos con datos a nivel escolar sobre los pases ni sobre los estudiantes que estuvieron presentes y fueron excluidos el día de la prueba, pero no tenemos motivos para creer que alguno de estos casos haya ocurrido con frecuencia o de manera diferencial entre los grupos.

gobierno nacional identificó como prioritarios (*Núcleos de Aprendizaje Prioritario*); y (c) el currículo de la provincia (*Diseño Curricular de La Rioja*).²³ Específicamente, la evaluación de matemática abarcó tres dominios de contenido (números, geometría, medida, y probabilidad y estadística) y cuatro dominios cognitivos (identificar conceptos matemáticos, comprender y usar la matemática simbólica, realizar cálculos y resolver problemas abstractos y aplicados). La evaluación de lectura abarcó tres dominios de contenido (textos narrativos, informativos y breves) y cuatro dominios cognitivos (localizar información en los textos, comprender las relaciones entre partes de los textos, identificar la idea principal de los textos e interpretar el significado de las palabras a partir del contexto). Cada evaluación incluyó entre 30 y 35 ítems de opción múltiple.

Usamos un modelo de teoría de respuesta al ítem de dos parámetros para escalar los resultados de las evaluaciones de manera que se tengan en cuenta las diferencias entre los ítems (su dificultad, su capacidad para distinguir entre estudiantes de habilidad similar y su propensión a ser respondidos correctamente al azar) y para aprovechar los ítems comunes entre las rondas de recolección de datos a fin de vincular los resultados a lo largo del tiempo.

El Apéndice B ofrece más detalles sobre el diseño, el escalamiento y la vinculación de las evaluaciones, así como sobre la distribución de los puntajes en todas las asignaturas, grados y años del estudio.²⁴

3.2 Encuestas a estudiantes

También administramos encuestas a estudiantes en los mismos años y a los mismos grupos que las evaluaciones de estudiantes. En 2013 (es decir, el año anterior a las intervenciones), las encuestas indagaron sobre las características demográficas de los estudiantes, los bienes del hogar, la trayectoria escolar y los apoyos para el estudio, lo que nos permitió describir la muestra del estudio. En 2015 (es decir, el segundo año de las intervenciones), se preguntó a los estudiantes sobre el esfuerzo de sus docentes, medido por la frecuencia de asistencia, la puntualidad y un conjunto de actividades en el aula, y sobre la efectividad de sus docentes, medida mediante una versión abreviada de la encuesta Tripod desarrollada por Ron Ferguson en Harvard (véase, por ejemplo, Ferguson 2010, 2012; Ferguson and Danielson 2014).²⁵

²³Por lo tanto, los informes escolares, que se basaron en estas evaluaciones, estaban alineados con los requisitos curriculares nacionales y subnacionales.

²⁴Las evaluaciones están disponibles en <https://bit.ly/2MRudPZ> (2013), <https://bit.ly/2Gf6it4> (2014) y <https://bit.ly/2DXnhxD> (2015).

²⁵Las encuestas están disponibles en <http://bit.ly/1qZeYHC> (2013) y <http://bit.ly/1VrPBek> (2014-2015).

3.3 Encuestas a docentes

Realizamos encuestas a docentes en los mismos años y grupos que las evaluaciones de estudiantes. En 2013, preguntamos sobre las características demográficas de los docentes, su formación y experiencia, su desarrollo profesional y sus prácticas de enseñanza, para describir la muestra del estudio. En 2014 y 2015, preguntamos a los docentes sobre aspectos que plausiblemente podrían verse influidos por las intervenciones (p. ej., las prácticas de monitoreo y evaluación en sus escuelas y la satisfacción laboral).²⁶

3.4 Encuestas a directores

Administramos encuestas a directores en las escuelas T1 y T2 en 2014 y en todas las escuelas en 2015. En ambos años, preguntamos a los directores sobre aspectos que podrían verse afectados por las intervenciones (p. ej., las prácticas de gestión y los recursos y materiales de sus escuelas).²⁷

3.5 Evaluaciones nacionales

Obtuvimos del ministerio de educación de la Nación los resultados de la evaluación nacional de estudiantes (denominada *Aprender*) de los estudiantes de 6.^o grado un año después de las intervenciones (2016). Este es el único grado de la escuela primaria en el que las evaluaciones son censales (es decir, abarcan a todas las escuelas y estudiantes). Esta es también la cohorte de estudiantes que cursaba 3.er grado (uno de los grados destinatarios de las intervenciones) en 2013, el primer año de nuestro estudio, y que recibió dos años de intervención. Usamos estos datos para verificar si encontramos evidencia de desvanecimiento (fade-out).

3.6 Eficiencia interna

Por último, también obtuvimos del ministerio de educación de la Nación datos sobre la eficiencia interna de las escuelas (incluidas la matrícula y las tasas de promoción, reprobación, repitencia y abandono) correspondientes al año anterior a las intervenciones (2013), a los dos años de las intervenciones (2014 y 2015) y a los dos años posteriores a las intervenciones. Usamos los datos de 2013 para verificar el balance entre los grupos experimentales, los datos de 2014 y 2015 para estimar el impacto de las intervenciones en la eficiencia interna, y los

²⁶Las encuestas están disponibles en: <http://bit.ly/20R1ni3> (2013) y <http://bit.ly/1THNgr0> (2014-2015).

²⁷La encuesta está disponible en: <http://bit.ly/1TUkwy0> (2014-2015).

datos de 2016 y 2017 para verificar si encontramos evidencia de desvanecimiento y/o de efectos latentes.

4 Estrategia empírica

Estimamos el efecto de la oferta (es decir, el efecto de intención de tratar o efecto ITT) de la retroalimentación diagnóstica y del fortalecimiento de capacidades después de dos años mediante el siguiente modelo:

$$Y_{igs} = \alpha_{r(s)} + X_{gs}\gamma + T'_s\beta + \epsilon_{igs} \quad (1)$$

donde Y_{igs} es el resultado de interés para el estudiante i en el grado g y la escuela s después de dos años de intervención, $r(s)$ es el estrato de aleatorización de la escuela s y $\alpha_{r(s)}$ es un efecto fijo de estrato, X_{gs} es el primer componente principal de un análisis de componentes principales de los indicadores de eficiencia interna para el grado g y la escuela s antes de la intervención,²⁸ y T_s es un vector de indicadores de intervención.²⁹ El parámetro de interés es β , que mide los efectos de cada intervención en relación con el grupo de control. Las hipótesis nulas son que los elementos de β son iguales a cero. Usamos errores estándar robustos por conglomerado para tener en cuenta las correlaciones en los resultados entre estudiantes de una misma escuela. También evaluamos la sensibilidad de nuestras estimaciones a la inclusión de X_{gs} .

También estimamos varias variantes de este modelo, entre ellas: (a) dos modelos casi idénticos, en los que los resultados se miden a nivel del director o del docente (para estimar el impacto de las intervenciones en la gestión escolar y en la enseñanza en el aula, respectivamente); (b) modelos que interactúan los indicadores de intervención con covariables a nivel de estudiante, como el sexo de los estudiantes (para estimar los efectos heterogéneos de las intervenciones en estos subgrupos de estudiantes); y (c) modelos en los que los resultados se miden a nivel de estudiante y de escuela en las escuelas T1 y T2 después del primer año de las intervenciones (para estimar el impacto del fortalecimiento de capacidades, más allá de la retroalimentación diagnóstica, después de un año).³⁰

²⁸Estos indicadores incluyen la matrícula, así como las tasas de promoción, reprobación, abandono y repitencia.

²⁹No podemos controlar por los resultados de los estudiantes antes de la intervención porque, como se explica en las secciones 2.3, 2.4 y 3, las escuelas de control solo participaron en la última ronda de recolección de datos del estudio.

³⁰En estos modelos, no podemos controlar por los resultados de los estudiantes antes de la intervención porque no se asignaron identificadores únicos ni a los estudiantes ni a los docentes que nos permitieran seguirlos a lo largo del tiempo.

5 Resultados

5.1 Pruebas de balance

Las escuelas de control, de retroalimentación diagnóstica (T1) y de fortalecimiento de capacidades (T2) eran comparables en todos los indicadores de eficiencia interna que el sistema escolar registraba en 2013 (Tabla A.3). Esto es así tanto cuando comparamos las escuelas en función de todos sus estudiantes de primaria como cuando las comparamos en función de los estudiantes de los grados a los que apuntaba la intervención (3.er y 5.º grado en 2013). El sentido de las diferencias no favorece sistemáticamente a ningún grupo.³¹ La magnitud de estas diferencias es pequeña (menos de 3.2 puntos porcentuales en todos los indicadores de eficiencia interna). Solo una de estas diferencias es (marginamente) estadísticamente significativa, lo cual es menos de lo que esperaríamos dado el número de hipótesis que estamos contrastando.

Si comparamos los grupos con datos de línea de base (de 2013), a las escuelas T1 les va mejor que a las escuelas T2. Los estudiantes de las escuelas T1 obtienen puntajes más altos en las evaluaciones de matemática y lectura, y la diferencia es mayor en 3.er grado ($.15\sigma$ en matemática, $.16\sigma$ en lectura) que en 5.º grado ($.1\sigma$ y $.12\sigma$, respectivamente) (Tabla A.4). Los estudiantes de las escuelas T1 también tienen padres marginalmente más educados, más bienes en el hogar y más apoyos para el estudio que sus pares de las escuelas T2 (Tabla A.5). Ninguna de estas diferencias es estadísticamente significativa, pero, como discutimos más adelante, podrían explicar por qué no encontramos un efecto estadísticamente significativo de la intervención de fortalecimiento de capacidades en la mayoría de los resultados.

5.2 Fidelidad de la implementación

Las intervenciones se implementaron mayormente según lo previsto (Tabla 2). En encuestas administradas justo antes de la línea final (en 2015), los directores de casi todas las escuelas de retroalimentación diagnóstica (T1) y de fortalecimiento de capacidades (T2) informan haber administrado evaluaciones de estudiantes en sus escuelas ese año (Panel A, cols. 2-3).³² Algunos directores de control también informaron haber administrado evaluaciones, pero dado que en 2015 no hubo evaluaciones nacionales ni ninguna otra evaluación subnacional, creemos que estos directores o bien pensaron que se esperaba que administraran evaluaciones y afirmaron haberlo hecho aunque no fuera así, o bien consideraron otros tipos de evaluaciones (por

³¹Por ejemplo, las escuelas T1 tienen tasas de promoción más bajas que las escuelas de control (lo que sugiere que les va peor), pero también tienen tasas de abandono más bajas (lo que sugiere que les va mejor).

³²La encuesta preguntaba a los directores si sus estudiantes habían rendido evaluaciones nacionales o subnacionales. No hacía referencia específica a la intervención para reducir el sesgo de deseabilidad social (es decir, que los directores informaran haber administrado las evaluaciones porque creían que eso era lo que se esperaba de ellos).

ejemplo, pruebas de aula) (col. 1).³³ Los directores de las escuelas T1 y T2 también tenían más probabilidades que sus pares de control de comparar los resultados de aprendizaje de su escuela, tanto a lo largo del tiempo como con los de la provincia y otras escuelas. Dado que estas comparaciones estaban incluidas en los informes distribuidos durante el estudio, estos resultados sugieren que la mayoría de los directores de las escuelas T1 y T2 usaron los informes según lo previsto.³⁴

Según los datos de monitoreo de la intervención, la distribución de los informes escolares se realizó según lo planeado, pero la participación en los talleres y las visitas a las escuelas no. Todas las escuelas de tratamiento recibieron tres informes (dos durante el estudio y uno después de la línea final) y todas las escuelas de control recibieron un informe después de la línea final (Panel B, cols. 1-3). Hubo dos problemas en la implementación de la intervención de fortalecimiento de capacidades. Primero, la participación en los talleres y las visitas a las escuelas fue menor de lo esperado entre las escuelas T2 (col. 3). Los directores de estas escuelas debían asistir a cinco talleres y dos visitas, pero el director promedio de este grupo asistió a tres talleres y una visita. Segundo, algunos directores de escuelas T1 asistieron a talleres y visitas, aunque no les correspondía hacerlo (col. 2). Por lo tanto, el efecto de T1 debe interpretarse como el de la retroalimentación diagnóstica con un fortalecimiento de capacidades mínimo.

5.3 Efectos ITT promedio

5.3.1 Logro de los estudiantes

Encontramos que la retroalimentación diagnóstica tuvo un efecto positivo, grande y estadísticamente significativo sobre el logro de los estudiantes, pero vemos evidencia menos clara de un efecto positivo del fortalecimiento de capacidades. Después del primer año de las intervenciones (en 2014), las escuelas de retroalimentación diagnóstica (T1) tuvieron un mejor desempeño en matemática y lectura que las escuelas de fortalecimiento de capacidades (T2), pero las diferencias son pequeñas (menos de $.07\sigma$ o 2 p.p.) y estadísticamente no significativas (Tabla 3, cols. 1-3). Después de dos años (en 2015), las escuelas T1 y T2 superaron a las escuelas de control (cols. 4-8). Solo las diferencias entre las escuelas de control y las escuelas T1 son estadísticamente significativas, y son grandes en ambas materias ($.33\sigma$ o 6.3 p.p. en

³³Una desventaja clave de depender únicamente de datos autoinformados, y la razón por la cual también recolectamos datos de monitoreo de la intervención, es que los directores a veces informan realizar prácticas que es sumamente improbable que hayan ocurrido en realidad (por ejemplo, porque están prohibidas por ley). Por ejemplo, muchos directores de escuelas públicas afirman tomar decisiones sobre la contratación y el despido de docentes en la encuesta escolar del Programa para la Evaluación Internacional de Alumnos (PISA) en países donde las escuelas públicas no tienen tal discrecionalidad (véase OECD 2016).

³⁴Creemos que las respuestas de los directores de las escuelas de control a estas tres preguntas están sujetas a los mismos problemas potenciales que las respuestas a la pregunta anterior.

matemática y $.36\sigma$ o 7.7 p.p. en lectura), pero no podemos descartar la posibilidad de que T1 y T2 hayan tenido el mismo impacto sobre el logro de los estudiantes (col. 9).³⁵

Los resultados anteriores son robustos a pruebas de atrición de estudiantes y de pruebas de hipótesis múltiples. Observamos un patrón similar cuando calculamos cotas de Lee (2009) para tener en cuenta la posible influencia de la atrición de estudiantes en 2015.³⁶ Las cotas son muy amplias: para las escuelas T1, van de $-.18$ a $.89\sigma$ en matemática y de $-.17$ a $.92\sigma$ en lectura; para las escuelas T2, van de $.31$ a $.76\sigma$ en matemática y de $-.36$ a $.7\sigma$ en lectura. Aun así, son mayormente positivas (Tabla A.13).³⁷ Además, la significancia estadística de los coeficientes de T1 y T2 se mantiene sin cambios cuando calculamos valores q de la tasa de falsos descubrimientos (FDR) para 2014 y 2015 (Tabla A.14).

El efecto positivo de la retroalimentación diagnóstica no se limita solo a algunos temas o habilidades. De hecho, las escuelas T1 superaron a las escuelas de control en casi todos los dominios de contenido y dominios cognitivos en ambos grados y materias (Tabla A.7 y A.8). Este hallazgo es importante porque sugiere que la intervención no llevó a las escuelas a concentrarse en habilidades más maleables para aumentar los puntajes en las pruebas.³⁸

El efecto positivo de la retroalimentación diagnóstica no se explica por la familiaridad de los estudiantes con la prueba. Todo lo contrario: las escuelas T1 superaron a las escuelas de control tanto en los ítems que se repitieron de rondas de evaluación anteriores (a los que llamamos ítems “conocidos”) como en los ítems que se introdujeron por primera vez en cada ronda de evaluación (a los que llamamos ítems “nuevos”) (Tabla A.9). De hecho, la magnitud del coeficiente de T1 es notablemente similar en ambos tipos de ítems.

El efecto estadísticamente no significativo de T2 resulta desconcertante porque combina los informes de T1 con talleres y visitas a las escuelas, por lo que su efecto debería ser al menos

³⁵No encontramos efectos ITT heterogéneos estadísticamente significativos sobre el aprendizaje según el tamaño o la ubicación de la escuela. Hemos omitido estas estimaciones del manuscrito, pero están disponibles a pedido.

³⁶Todas las cotas de Lee (2009) estimadas en este artículo reportan errores estándar analíticos porque el comando de Stata `leebounds` no admite errores estándar por conglomerado. Por lo tanto, deben interpretarse con cautela, ya que ignoran el componente del error a nivel de escuela.

³⁷También encontramos que nuestras estimaciones ITT cambian poco cuando tenemos en cuenta las ausencias el día de la prueba (Tabla A.11). Además, no vemos evidencia de que los efectos positivos y estadísticamente significativos de la retroalimentación diagnóstica en 2015 sean predichos por el ausentismo estudiantil en 2013. Los coeficientes de correlación para las escuelas T1 están por debajo de $.1$ para todos los grados y materias. Los coeficientes para las escuelas T2 son levemente mayores, pero esto podría deberse al desbalance en la línea de base que ya discutimos. De hecho, las diferencias en las magnitudes de los coeficientes entre grados son consistentes con estas hipótesis: los coeficientes son mayores en 3.er grado (donde vemos un mayor desbalance entre las escuelas T1 y T2 en la línea de base) y menores en 5.º grado (donde observamos menos desbalance).

³⁸El fortalecimiento de capacidades no tuvo un efecto mayor en geometría. Esto podría deberse a que solo el 20% de las escuelas T2 participó en el taller sobre ese tema o a que las evaluaciones tuvieron lugar un mes más tarde (ver Tabla 1).

tan grande como el de T1.³⁹ Aun así, cierta evidencia sugiere que podría deberse al desbalance inicial entre T1 y T2.⁴⁰ Primero, el efecto de T2 es proporcional a ese desbalance: es pequeño ($.14\sigma$ en matemática y $.11\sigma$ en lectura) y estadísticamente no significativo en 3.er grado, donde el desbalance era mayor, y es grande ($.29\sigma$ y $.22\sigma$) y estadísticamente significativo en 5.º grado, donde era menor (Tabla A.6). Segundo, el efecto de T2 es levemente mayor en 3.er grado si usamos covariables (de $.14$ a $.15\sigma$ en matemática y de $.11$ a $.12\sigma$ en lectura), pero no cambia en 5.º grado (Tabla A.10, col. 8). Hay que admitir, sin embargo, que estos patrones son sugerentes más que concluyentes.

El efecto estadísticamente no significativo de T2 también podría deberse a los problemas de cumplimiento.⁴¹ Si las escuelas T2 estaban en desventaja con respecto a las escuelas T1 en el primer año del estudio (en 2013), la baja participación de los directores T2 en los talleres y las visitas a las escuelas, y la participación de algunos directores T1 en esas actividades, podrían haber preservado esa desventaja.⁴² Sin embargo, no podemos determinar el papel del incumplimiento en el efecto del fortalecimiento de capacidades.

5.3.2 Evaluaciones nacionales

Encontramos evidencia de que los efectos de las intervenciones persistieron después del fin del experimento. Un año después de las intervenciones (en 2016), las escuelas T1 y T2 superaron a las escuelas de control en matemática y lectura, aun cuando las escuelas de control habían recibido un informe al final del experimento (ver sección 5.2) (Tabla 5, cols. 4-5).⁴³ Los efectos son de pequeños a moderados ($.26\sigma$ en matemática y $.22\sigma$ en lectura entre las escuelas T1 y $.17\sigma$ en matemática y $.18\sigma$ en lectura entre las escuelas T2). Los coeficientes de T1 son mayores que los de T2, pero, en línea con los resultados de nuestras evaluaciones, no podemos descartar que ambas intervenciones hayan tenido el mismo efecto (col. 6).

5.3.3 Eficiencia interna

No encontramos evidencia clara de que las intervenciones hayan mejorado la eficiencia interna de las escuelas (Tabla 4), ni mientras se implementaban (en 2014-2015, columnas 1-6), ni hasta

³⁹Es posible que los componentes adicionales hayan contradicho los informes y/o desviado recursos de actividades que mejoran el logro de los estudiantes, pero esto es poco probable dado el poco tiempo que demandaban estos componentes (ver sección 2.4) y su implementación desigual (ver sección 5.2).

⁴⁰Ver sección 5.1 para la discusión de este desbalance.

⁴¹Ver sección 5.2 para la discusión de estos problemas.

⁴²Esta posibilidad es consistente con análisis en los que aprovechamos la asignación aleatoria a T2 para estimar el efecto de la participación en el fortalecimiento de capacidades y encontramos que tuvo un impacto positivo sobre el logro de los estudiantes. Estos análisis están disponibles a pedido de los autores.

⁴³Como se mencionó en la sección 3, las evaluaciones nacionales evaluaron a estudiantes de 6.º grado, que estaban en 3.er grado al inicio del estudio y recibieron dos años de las intervenciones.

dos años después de que concluyeron (en 2016-2017, columnas 7-12). En algunos indicadores y años, el signo de la diferencia entre las escuelas de control y de tratamiento es el esperado (por ejemplo, en 2014, las escuelas T1 y T2 tuvieron tasas de abandono levemente más bajas). En otros indicadores y años, el signo parece contraintuitivo (por ejemplo, en 2014, las escuelas T1 y T2 tuvieron tasas de promoción *más bajas*). Y en otros indicadores y años, el signo difiere entre las escuelas T1 y T2 (por ejemplo, en 2014, las escuelas T1 tuvieron tasas de abandono más altas, pero las escuelas T2 tuvieron tasas de abandono más bajas que las escuelas de control). Además, solo un puñado de estas diferencias son (marginamente) estadísticamente significativas. Observamos un patrón similar cuando estimamos estos efectos por separado para cada grado (Tabla A.15).

Es importante señalar, sin embargo, que los indicadores de eficiencia interna se recolectan a nivel de escuela (y no a nivel de estudiante). Con este nivel de agregación, es posible que no tengamos suficiente poder estadístico para detectar efectos pequeños o moderados, aun si ocurrieron.

5.4 Posibles mecanismos

5.4.1 Gestión escolar

Una vía por la cual las intervenciones podrían haber mejorado el logro de los estudiantes es llevando a los directores a usar los resultados de las evaluaciones para fundamentar decisiones de gestión.⁴⁴ En línea con esta expectativa, las encuestas a directores administradas después de dos años (en 2015) indican que los directores de las escuelas T1 y T2 usaron los resultados de las evaluaciones para varios aspectos relacionados con la gestión.⁴⁵

Primero, los directores de las escuelas de intervención usaron los resultados de las evaluaciones con fines de planificación. Los directores de las escuelas T1 y T2 informaron tener 48 p.p. y 28 p.p. más probabilidades de fijar metas para sus escuelas sobre la base de los resultados de las evaluaciones y 30 p.p. y 23 p.p. más probabilidades de modificar el currículo sobre la base de los resultados que sus pares de control (Tabla 6, cols. 4-5). Todas estas diferencias son estadísticamente significativas y no podemos descartar la posibilidad de que T1 y T2 hayan tenido el mismo efecto sobre cualquiera de los dos indicadores (col. 6).

Segundo, los directores de estas escuelas también usaron los resultados de las evaluaciones para tomar decisiones sobre el personal. Los directores de las escuelas T1 y T2 informaron tener

⁴⁴Como se discutió en una nota al pie anterior, preguntamos a los directores si usaron resultados de evaluaciones de estudiantes nacionales o subnacionales en 2015 para los fines discutidos en esta sección. Dado que en 2015 no hubo evaluación nacional en Argentina, ni ninguna otra evaluación subnacional en La Rioja ese año, las únicas evaluaciones a las que podían referirse los directores serían las asociadas a las intervenciones.

⁴⁵Como se mencionó en una nota al pie anterior, los resultados de esta sección deben interpretarse con cautela, ya que los informes de los directores no siempre se corresponden con las prácticas escolares.

28 p.p. y 37 p.p. más probabilidades de usar los resultados de las evaluaciones para evaluar a los directores que sus pares de control. Los directores de las escuelas T1 también afirmaron tener 23 p.p. más probabilidades de usar estos resultados para evaluar a los docentes, pero esta diferencia es solo marginalmente estadísticamente significativa, no es significativa en el caso de las escuelas T2, y no podemos rechazar la hipótesis nula de que T1 y T2 hayan tenido el mismo efecto sobre este indicador.⁴⁶

Por último, los directores pusieron los resultados de las evaluaciones a disposición de otros. Los directores de las escuelas T1 y T2 informaron tener 42 y 49 p.p. más probabilidades de informar a los padres sobre los resultados de las evaluaciones, y 32 p.p. y 31 p.p. más probabilidades de hacer públicos estos resultados, que los de las escuelas de control. Todas estas diferencias son estadísticamente significativas y no podemos descartar la posibilidad de que T1 y T2 hayan tenido el mismo efecto. Este hallazgo sugiere que las mejoras en el aprendizaje podrían haberse producido en parte debido a cambios en la asignación de inversiones educativas por parte de los padres.⁴⁷ Todos los resultados de esta sección son robustos a pruebas de hipótesis múltiples (Tabla A.16).

5.4.2 Enseñanza en el aula

Otra vía por la cual la retroalimentación podría haber mejorado el aprendizaje es la enseñanza en el aula. Las encuestas a estudiantes administradas después de dos años (en 2015) indican que los docentes de las escuelas T1 dedicaron más tiempo a la enseñanza, emplearon más actividades durante las clases y fueron mejor calificados por sus estudiantes que los de las escuelas de control.

Primero, los docentes de las escuelas T1 no tenían más probabilidades de ir a la escuela o de llegar a tiempo, ni de dedicar más tiempo a la enseñanza condicional a la asistencia. Los estudiantes de las escuelas T1 informaron que sus docentes tenían menos probabilidades de empezar la clase tarde, menos probabilidades de terminar la clase temprano y menos probabilidades de retirarse temprano de la escuela que los de las escuelas de control (Tabla 7, col. 4). Sin embargo, ninguno de estos resultados es estadísticamente significativo una vez que tenemos en cuenta las pruebas de hipótesis múltiples (Tabla A.18).

Segundo, los docentes de las escuelas T1 también usaron más actividades durante las clases. Los estudiantes de las escuelas T1 informaron que sus docentes tenían 6 p.p. más

⁴⁶Nótese que en La Rioja, como en el resto de Argentina, las escuelas públicas tienen una autoridad limitada sobre la contratación y el despido de directores y docentes. Por lo tanto, es improbable que hayan asociado consecuencias a estos resultados. Es más probable, en cambio, que hayan incorporado los resultados de aprendizaje al proceso de evaluación del desempeño de directores y docentes.

⁴⁷Como se discutió en la sección 2.1, la Ley de Educación Nacional prohíbe al gobierno difundir resultados de las evaluaciones a nivel de escuela, docente o estudiante. Sin embargo, la ley no prohíbe que las escuelas pongan sus propios resultados a disposición de los padres o de los miembros de la comunidad.

probabilidades de usar un libro de texto, 2 p.p. más probabilidades de asignar tareas, 3 p.p. más probabilidades de escribir en el pizarrón, 2 p.p. más probabilidades de explicar temas y 2 p.p. más probabilidades de corregir las tareas que los de las escuelas de control (Tabla 8, col. 4). La significancia estadística de estos coeficientes se mantiene sin cambios una vez que tenemos en cuenta las pruebas de hipótesis múltiples (Tabla A.19). Aun así, los docentes no tenían más probabilidades de asignar pruebas de práctica, lo que sugiere que la intervención no llevó a “enseñar para la prueba”. En la mayoría de estos resultados, no podemos descartar la posibilidad de que T1 y T2 hayan tenido un efecto similar (col. 6).

Por último, los docentes de las escuelas T1 fueron mejor calificados. Los estudiantes de las escuelas T1 informaron que sus docentes tenían más probabilidades de demostrar interés en los estudiantes ($.19\sigma$), manejar el aula ($.13\sigma$), aclarar conceptos o tareas difíciles ($.17\sigma$), motivar a los estudiantes a dar lo mejor de sí ($.18\sigma$), dar clases cautivantes ($.16\sigma$), hacer participar a los estudiantes en discusiones ($.14\sigma$) y resumir el material al final de la clase ($.18\sigma$) que los docentes de control (Tabla 9, col. 4). La significancia estadística de todos los coeficientes se mantiene sin cambios una vez que tenemos en cuenta las pruebas de hipótesis múltiples (Tabla A.20). De hecho, las escuelas T1 superaron a las escuelas T2 (col. 6).

6 Conclusión

Presentamos evidencia experimental sobre el impacto de la retroalimentación diagnóstica y el fortalecimiento de capacidades en escuelas primarias públicas de La Rioja, Argentina, y encontramos que brindar a las escuelas información sobre su desempeño relativo generó grandes ganancias en los puntajes de las pruebas de matemática y lectura. Los resultados presentados en las Tablas 6 a 9 indican que esta mejora se debió a que los directores usaron los resultados de las evaluaciones para fundamentar decisiones de gestión escolar, a que los docentes recurrieron a más estrategias de enseñanza y a una mejora en las interacciones entre docentes y estudiantes.

El impacto de la retroalimentación diagnóstica demuestra el potencial de las evaluaciones a gran escala para mejorar el desempeño de los sistemas en los países en desarrollo. Específicamente, sugiere que, al menos en contextos donde la restricción principal no es el margen extensivo sino el margen intensivo del esfuerzo de directores y docentes, informar a las escuelas sobre su posición relativa puede impulsar mejoras en la gestión escolar y la enseñanza en el aula, que a su vez pueden elevar los resultados de aprendizaje. Dado que muchos países en desarrollo comenzaron recientemente a administrar evaluaciones a gran escala (véase Cheng and Gale 2014; Ganimian and Koretz 2017), que estas evaluaciones representan solo una pequeña parte de sus presupuestos educativos (véase Wolff 2007), y que los informes escolares

pueden automatizarse y distribuirse a un costo bajo o nulo (por ejemplo, si son en línea), la retroalimentación diagnóstica promete ser una forma costo-efectiva de mejorar el aprendizaje de los estudiantes en estos contextos (véase World Bank 2018).

No podemos distinguir las contribuciones relativas de cada componente de la retroalimentación diagnóstica, pero es importante señalar que la intervención que evaluamos se basó en evaluaciones que eran informativas en un amplio rango de logro y comparables a lo largo del tiempo. Hay buenas razones para creer que estos aspectos son fundamentales a los fines de la retroalimentación. Las evaluaciones que solo cubren el material que los estudiantes deberían saber en un grado dado (es decir, sin evaluar material de grados inferiores), que son bastante frecuentes en algunos contextos (por ejemplo, el sur de Asia), a menudo hacen que la mayoría de los estudiantes tenga un desempeño bajo y no brindan suficiente información para establecer distinciones significativas entre escuelas (véase Muralidharan et al. 2019). De manera similar, las evaluaciones que no son comparables a lo largo del tiempo (por ejemplo, porque incluyen muy pocos ítems comunes entre rondas y/o no usan la teoría de respuesta al ítem con fines de equiparación) pueden transmitir información inconsistente sobre el desempeño relativo y absoluto de las escuelas, lo que lleva a sus usuarios a tomar decisiones incorrectas (véase Barrera-Orsorio and Ganimian 2016).

En la misma línea, parece igualmente importante destacar que los informes que evaluamos presentaban distintos tipos de información que pueden resultar útiles para directores y docentes, incluidas no solo comparaciones entre el desempeño promedio de una escuela y el de la escuela promedio del sistema escolar, sino también entre secciones dentro de una escuela, así como el desempeño general de la escuela en cada dominio de contenido y dominio cognitivo de cada materia evaluada. No podemos determinar cuál de estos distintos tipos de información fue más útil para las escuelas, pero advertiríamos contra la expectativa de que informes que simplemente comparan una escuela con el resto del sistema generen las grandes ganancias en los puntajes de las pruebas que hemos observado en este contexto. Consideramos que la experimentación con los tipos de información presentados en los informes escolares, y con el formato en que se presenta esa información, es un área prometedora para futuras investigaciones.

Por último, nuestros resultados sobre la participación menor de lo esperado en el fortalecimiento de capacidades ilustran los desafíos de implementar un desarrollo profesional significativo en el mundo en desarrollo. Son consistentes con los de evaluaciones de programas tradicionales de formación docente en otros países en desarrollo, que también han encontrado una baja participación y efectos limitados sobre el aprendizaje (véase Angrist and Lavy 2001; Yoshikawa et al. 2015; Yue et al. 2014; Zhang et al. 2013). Consideramos que la experimentación con modelos más innovadores de desarrollo profesional (por ejemplo,

el acompañamiento pedagógico (coaching)) es un área más prometedora para futuras investigaciones (véase, por ejemplo, Cilliers et al. 2019).

Referencias

- Andrabi, T., J. Das, and A. I. Khwaja (2017). Report cards: The impact of providing school and child test scores on educational markets. *American Economic Review* 107(6), 1535–1563.
- Angrist, J. D. and V. Lavy (2001). Does teacher training affect pupil learning? Evidence from matched comparisons in Jerusalem public schools. *Journal of Labor Economics* 19(2).
- Banerjee, A. V., R. Banerji, E. Duflo, and M. Walton (2011). Effective pedagogies and a resistant education system: Experimental evidence on interventions to improve basic skills in rural India. *Unpublished manuscript*. New Delhi, India: Abdul Latif Jameel Poverty Action Lab (J-PAL).
- Barrera-Osorio, F. and A. J. Ganimian (2016). The barking dog that bites: Test score volatility and school rankings in Punjab, Pakistan. *International Journal of Educational Development* 49, 31–54.
- Bassi, M., M. Busso, and J. S. Muñoz (2013). Is the glass half empty or half full? School enrollment, graduation, and dropout rates in Latin America. (IDB Working Paper No. 462). Washington, DC: Inter-American Development Bank.
- Bassi, M., C. Meghir, and A. Reynoso (2016). Education quality and teaching practices. Technical report, National Bureau of Economic Research.
- Betts, J. R., Y. Hahn, and A. C. Zau (2017). Can testing improve student learning? An evaluation of the mathematics diagnostic testing project. *Journal of Urban Economics* 100, 54–64.
- Boudett, K. P., E. A. City, and R. J. Murnane (2005). *Data wise: A step-by-step guide to using assessment results to improve teaching and learning*. Cambridge, MA: Harvard Education Press.
- Camargo, B., R. Camelo, S. Firpo, and V. Ponczek (2018). Information, market incentives, and student performance: Evidence from a regression discontinuity design in Brazil. *The Journal of Human Resources* 53(2), 414–444.
- Cheng, X. and C. Gale (2014). National assessments mapping metadata. Washington, DC: FHI 360. Retrieved from: <http://bit.ly/2yxBeBd>.
- Cilliers, J., B. Fleisch, C. Prinsloo, and S. Taylor (2019). How to improve teaching practice? an experimental comparison of centralized training and in-classroom coaching. *Journal of Human Resources*, 0618–9538R1.

- de Hoyos, R., V. A. García-Moreno, and H. A. Patrinos (2017). The impact of an accountability intervention with diagnostic feedback: Evidence from Mexico. *Economics of Education Review* 58, 123–140.
- de Hoyos, R., P. A. Holland, and S. Troiano (2015). Understanding the trends in learning outcomes in Argentina, 2000 to 2012. (Policy Research Working Paper No. 7518). The World Bank. Washington.
- DiNIECE (2009). Estudio nacional de evaluación y consideraciones conceptuales: Educación primaria. Educación secundaria. Ciudad Autónoma de Buenos Aires, Argentina: Subsecretaría de Planeamiento Educativo, Secretaría de Educación, Ministerio de Educación.
- DiNIECE (2012). Operativo Nacional de Evaluación 2010: 3er y 6to año de la educación primaria. Informe de resultados. Ciudad Autónoma de Buenos Aires, Argentina: Subsecretaría de Planeamiento Educativo, Secretaría de Educación, Ministerio de Educación.
- DiNIECE (2013). Anuario Estadístico 2013. Buenos Aires, Argentina: Dirección Nacional de Información de la Calidad Educativa (DiNIECE).
- DiNIECE (2015). Anuario Estadístico 2015. Buenos Aires, Argentina: Dirección Nacional de Información de la Calidad Educativa (DiNIECE).
- Duflo, E., J. Berry, S. Mukerji, and M. Shotland (2015). A wide angle view of learning: Evaluation of the CCE and LEP programmes in Haryana, India. (Impact Evaluation Report No. 22). International Initiative for Impact Evaluation (3ie). New Delhi, India.
- Ferguson, R. F. (2010). Student perceptions of teaching effectiveness. Boston, MA: The National Center for Teacher Effectiveness and the Achievement Gap Initiative.
- Ferguson, R. F. (2012). Can student surveys measure teaching quality? *Phi Delta Kappan* 94(3), 24–28.
- Ferguson, R. F. and C. Danielson (2014). How Framework for Teaching and Tripod 7Cs evidence distinguish key components of effective teaching. T. J. Kane, K. A. Kerr & R. C. Pianta, *Designing teacher evaluation systems: New guidance from the Measures of Effective Teaching project*. San Francisco, CA: Jossey-Bass.
- Ferrer, G. (2006). *Educational assessment systems in Latin America: Current practice and future challenges*. Partnership for Educational Revitalization in the Americas (PREAL).

- Ferrer, G. and A. Fiszbein (2015). What has happened with learning assessment systems in Latin America? Lessons from the last decade of experience. Washington, DC: The World Bank.
- Ganimian, A. J. (2013). No logramos mejorar: Informe sobre el desempeño de Argentina en el Programa para la Evaluación Internacional de Alumnos (PISA) 2012. Buenos Aires, Argentina: Proyecto Educar 2050.
- Ganimian, A. J. (2014). Avances y desafíos pendientes: Informe sobre el desempeño de Argentina en el Tercer Estudio Regional Comparativo y Explicativo (TERCE) del 2013. Buenos Aires, Argentina: Proyecto Educar 2050.
- Ganimian, A. J. (2015). El termómetro educativo: Informe sobre el desempeño de Argentina en los Operativos Nacionales de Evaluación (ONE) 2005-2013. Buenos Aires, Argentina: Proyecto Educar 2050.
- Ganimian, A. J. and D. M. Koretz (2017). Dataset of international large-scale assessments. Last updated: February 8, 2017. Cambridge, MA: Harvard Graduate School of Education.
- Harris, D. (2005). Comparison of 1-, 2-, and 3-parameter IRT models. *Educational Measurement: Issues and Practice* 8(1), 35–41.
- IEA (2015). PIRLS 2016: Assessment framework. TIMSS & PIRLS International Study Center. Lynch School of Education, Boston College & International Association for the Evaluation of Educational Achievement (IEA).
- IEA (2017). TIMSS 2019: Assessment frameworks. Edited by Mullis, I. V. S. & Martin, M. O. TIMSS & PIRLS International Study Center. Lynch School of Education, Boston College & International Association for the Evaluation of Educational Achievement (IEA).
- Lee, D. S. (2009). Training, wages, and sample selection: Estimating sharp bounds on treatment effects. *The Review of Economic Studies* 76(3), 1071–1102.
- Mizala, A. and M. Urquiola (2013). School markets: The impact of information approximating schools’ effectiveness. *Journal of Development Economics* 103, 313–335.
- Muralidharan, K. (2012). Long-term effects of teacher performance pay: Experimental evidence from India. *Unpublished manuscript*. San Diego, CA: University of California, San Diego.
- Muralidharan, K., A. Singh, and A. J. Ganimian (2019). Disrupting education? Experimental evidence on technology-aided instruction in India. *American Economic Review* 109(4), 1–35.

- Muralidharan, K. and V. Sundararaman (2010). The impact of diagnostic feedback to teachers on student learning: Experimental evidence from India. *The Economic Journal* 120(F187-F203).
- Muralidharan, K. and V. Sundararaman (2011). Teacher performance pay: Experimental evidence from India. *Journal of Political Economy* 119(1), 39–77.
- OECD (2016). PISA 2015 results: Excellence and equity in education. Volume I. Paris, France: Organization for Economic Cooperation and Development (OECD).
- Piper, B. and M. Korda (2011). EGRA plus: Liberia. Program evaluation report. *Unpublished manuscript*. RTI International. Research Triangle Park, NC.
- SEE-MEDN (2016). Aprender 2016: Informe de resultados. Ciudad Autónoma de Buenos Aires: Secretaría de Evaluación Educativa. Ministerio de Educación y Deportes de la Nación.
- SEE-MEDN (2018). Aprender 2017: Informe de resultados, secundaria. Ciudad Autónoma de Buenos Aires: Secretaría de Evaluación Educativa. Ministerio de Educación y Deportes de la Nación.
- Stata (2017). *Stata item response theory reference manual: Release 15*. College Station, TX: StataCorp LLC.
- UNGA (2000). A/RES/55/2. Resolution adopted by the General Assembly on 18 September 2000. New York, NY: United Nations General Assembly.
- UNGA (2015). A/RES/70/1. Resolution adopted by the General Assembly on 25 September 2015. New York, NY: United Nations General Assembly.
- Wolff, L. (2007). The costs of student assessments in Latin America. (PREAL Working Paper No. 38). Washington, DC: Partnership for Educational Revitalization in the Americas (PREAL).
- World Bank (2018). World Development Report 2018: Learning to realize education’s promise. Washington, DC: The World Bank.
- Yen, W. M. and A. R. Fitzpatrick (2006). Item response theory. In Brennan, R. (Ed.) *Educational measurement* (4th ed.). Westport, CT: American Council on Education and Praeger Publishers.
- Yoshikawa, H., D. Leyva, C. E. Snow, E. Treviño, M. C. Arbour, M. C. Barata, C. Weiland, C. Gómez, L. Moreno, A. Rolla, and N. D’Sa (2015). Experimental impacts of a teacher professional development program in Chile on preschool classroom quality and child outcomes. *Journal of Developmental Psychology* 51, 309–322.

- Yue, A., Y. Shi, F. Chang, C. Yang, H. Wang, H. Yi, R. Luo, C. Liu, L. Zhang, J. Yanjey Chu, et al. (2014). Dormitory management and boarding students in china's rural primary schools. *China Agricultural Economic Review* 6(3), 523–550.
- Zhang, L., F. Lai, X. Pang, H. Yi, and S. Rozelle (2013). The impact of teacher training on teacher and student outcomes: Evidence from a randomised experiment in Beijing migrant schools. *Journal of Development Effectiveness* 5(3), 339–358.

Tabla 1: Cronograma del estudio

(1) Mes	(2) Evento	(3)	(4)	(5)
		Tasas de participación de las escuelas		
		Escuelas de control	Escuelas T1	Escuelas T2
<i>Panel A. 2013</i>				
febrero	Comienza el ciclo lectivo			
abril	Datos administrativos (3.er y 5.º grado)	-	100%	100%
octubre	Evaluaciones de estudiantes (3.er y 5.º grado)	-	100%	100%
	Encuestas a estudiantes (3.er y 5.º grado)	-	100%	100%
	Encuestas a docentes (3.er y 5.º grado)	-	100%	100%
		-	100%	100%
diciembre	Termina el ciclo lectivo			
<i>Panel B. 2014</i>				
febrero	Comienza el ciclo lectivo			
marzo	Se entregan los informes a las escuelas	-	100%	100%
	Taller 1: Resultados de las evaluaciones	-	-	53%
abril	Visita a las escuelas 1	-	40%	60%
mayo	Taller 2: Planes de mejora escolar	-	-	90%
septiembre	Taller 3: Aseguramiento de la calidad	-	-	87%
noviembre	Evaluaciones de estudiantes (3.er, 4.º y 5.º grado)	-	100%	100%
	Encuestas a estudiantes (3.er, 4.º y 5.º grado)	-	100%	100%
	Encuestas a docentes (3.er, 4.º y 5.º grado)	-	100%	93%
	Encuestas a directores	-	100%	93%
diciembre	Termina el ciclo lectivo			
<i>Panel C. 2015</i>				
febrero	Comienza el ciclo lectivo			
abril	Se entregan los informes a las escuelas	-	100%	100%
	Taller 4: Resultados de las evaluaciones	-	-	97%
junio	Visita a las escuelas 2	-	33%	87%
septiembre	Taller 5: Enseñanza de la geometría	-	23%	20%
octubre	Evaluaciones de estudiantes (3.er y 5.º grado)	100%	100%	100%
	Encuestas a estudiantes (3.er y 5.º grado)	-	100%	100%
	Encuestas a docentes (3.er y 5.º grado)	-	100%	100%
	Encuestas a directores	-	100%	100%
diciembre	Termina el ciclo lectivo			

Notas: (1) La tabla muestra el cronograma de las intervenciones y de las rondas de recolección de datos del estudio, incluido el mes en que ocurrió cada evento (columna 1), una breve descripción del evento (columna 2) y el porcentaje de escuelas que participó en cada evento por grupo experimental (columnas 3-5).

Tabla 2: Administración y uso de las evaluaciones de estudiantes (2015)

	(1) Escuelas de control	(2) Escuelas T1	(3) Escuelas T2	(4) Col. (5)- Col. (4)	(5) Col. (6)- Col. (4)	(6) Prueba F $\beta_1 = \beta_2$
<i>Panel A. Encuesta a directores</i>						
En mi escuela se rindieron evaluaciones nacionales o subnacionales	.4 (.497)	.962 (.196)	.931 (.258)	.562*** (.093)	.529*** (.098)	.291 (.591)
Comparé los resultados de mi escuela con los de la provincia	.25 (.441)	.679 (.476)	.75 (.441)	.426*** (.123)	.501*** (.119)	.391 (.533)
Comparé los resultados de mi escuela con los de otras escuelas	.25 (.441)	.741 (.447)	.519 (.509)	.47*** (.122)	.276** (.129)	2.215 (.141)
Comparé los resultados de mi escuela a lo largo del tiempo	.677 (.475)	1 (0)	.966 (.186)	.323*** (.086)	.29*** (.095)	.706 (.403)
<i>Panel B. Monitoreo de la implementación</i>						
Número de informes recibidos	1 (0)	3 (0)	3 (0)	2 (0)	2 (0)	. (.)
Número de talleres a los que asistió	0 (0)	.233 (.43)	3.4 (.855)	.22*** (.075)	3.401*** (.156)	334.158 (0)
Número de visitas recibidas	0 (0)	.733 (.583)	1.467 (.571)	.758*** (.1)	1.462*** (.105)	24.782 (0)

Notas: (1) La tabla muestra, para el ciclo lectivo 2015, las medias y desviaciones estándar del grupo de control (columna 1), del grupo de retroalimentación diagnóstica o T1 (columna 2) y del grupo de fortalecimiento de capacidades o T2 (columna 3). También estima el efecto ITT de T1 y T2 con respecto a las escuelas de control, usando efectos fijos de aleatorización (columnas 4-5). Por último, muestra el estadístico F y el valor p asociado para la hipótesis nula de que los coeficientes de T1 y T2 son iguales en 2015 (columna 6). El Panel A usa datos de las encuestas a directores de 2015 y el Panel B usa datos del monitoreo de la implementación de 2013-2015. (2) En las encuestas, se pidió a los directores que indicaran si sus escuelas usaban los resultados de las evaluaciones de estudiantes para los fines enumerados arriba. Las cifras indican la proporción de directores que reportaron que sus escuelas usaban las evaluaciones para cada fin, con referencia al ciclo lectivo de la recolección de datos. (3) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla 3: Efecto ITT de las intervenciones sobre el logro de los estudiantes (2014-2015)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
	2014					2015			
	Escuelas T1	Escuelas T2	Col. (2)- Col. (1)	Escuelas de control	Escuelas T1	Escuelas T2	Col. (5)- Col. (4)	Col. (6)- Col. (4)	Prueba F $\beta_1 = \beta_2$
Matemática (% de aciertos)	55.779 (18.059)	54.941 (19.614)	-.635 (2.432)	51.552 (19.417)	57.69 (19.599)	55.46 (20.761)	6.275** (2.422)	3.939 (2.757)	.538 (.465)
Matemática (puntaje TRI)	.278 (.992)	.243 (1.075)	-.023 (.139)	0 (1)	.324 (1.036)	.216 (1.104)	.333** (.131)	.216 (.145)	.481 (.489)
Lectura (% de aciertos)	63.181 (19.666)	61.043 (20.092)	-1.431 (2.167)	58.319 (22.371)	66.048 (21.625)	61.674 (22.921)	7.713*** (2.13)	3.627 (2.518)	1.981 (.162)
Lectura (puntaje TRI)	.312 (.969)	.212 (.966)	-.066 (.105)	0 (1)	.357 (1.018)	.153 (1.035)	.356*** (.102)	.166 (.111)	1.987 (.162)
N (estudiantes)	3950	3588	7538	3446	3950	3588	10984	10984	10984

Notas: (1) La tabla muestra, para 2014 y 2015, las medias y desviaciones estándar de todas las escuelas de control (columna 4), de las escuelas de retroalimentación diagnóstica o T1 (columnas 1 y 5) y de las escuelas de fortalecimiento de capacidades o T2 (columnas 2 y 6). También estima el efecto ITT de T2 con respecto a T1 en 2014 (columna 3) y de T1 y T2 con respecto a las escuelas de control en 2015, usando efectos fijos de aleatorización (columnas 7-8). Por último, muestra el estadístico F y el valor p asociado para la hipótesis nula de que los coeficientes de T1 y T2 son iguales en 2015 (columna 9). (2) Todos los puntajes se presentan como puntajes de porcentaje de respuestas correctas y como puntajes escalados con TRI, estandarizados con respecto al grupo de control en 2015. (3) Las escuelas de control solo fueron evaluadas en 2015 (ver secciones 2.3 y 2.4 del manuscrito). (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla 4: Efecto ITT de las intervenciones sobre la eficiencia interna (2014-2017)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)	(10)	(11)	(12)
		2014			2015			2016			2017	
		Diferencia			Diferencia			Diferencia			Diferencia	
	Control	T1	T2	Control	T1	T2	Control	T1	T2	Control	T1	T2
Número de estudiantes matriculados	326.567 (272.272)	-9.443 (41.564)	20.38 (41.351)	319.481 (271.878)	-14.888 (41.103)	26.339 (40.893)	311.462 (263.714)	-13.086 (38.986)	32.386 (38.787)	306.692 (259.112)	-5.397 (37.872)	33.576 (37.679)
Porcentaje de estudiantes que aprobaron el grado	96.28 (4.31)	-.626 (1.018)	-1.69* (1.014)	97.155 (3.497)	-.167 (.842)	.556 (.838)	98.416 (2.662)	.147 (.644)	.009 (.641)	98.774 (1.904)	-.358 (.452)	-.116 (.45)
Porcentaje de estudiantes que reprobaron el grado	3.682 (4.32)	.694 (1.02)	1.718* (1.016)	2.571 (3.412)	-.067 (.824)	-.67 (.82)	1.432 (2.516)	-.188 (.606)	-.202 (.603)	1.175 (1.869)	.313 (.444)	.017 (.441)
Porcentaje de estudiantes que abandonaron la escuela	.038 (.153)	-.067* (.037)	-.028 (.036)	.274 (.929)	.234 (.22)	.115 (.219)	.152 (.75)	.041 (.18)	.193 (.18)	.051 (.214)	.045 (.051)	.099* (.05)
Porcentaje de estudiantes que repitieron el grado	2.649 (3.191)	.581 (.771)	-.076 (.767)	1.922 (2.567)	.436 (.615)	-.107 (.612)	1.453 (2.279)	-.711 (.536)	-1.09** (.533)	2.535 (3.593)	-.025 (.851)	-1.552* (.847)
N (escuelas)	44	104	104	44	104	104	44	104	104	44	104	104

Notas: (1) La tabla muestra, para cada año del período 2014-2017, las medias y desviaciones estándar de todas las escuelas de control (columnas 1, 4, 7 y 10) y el efecto ITT de la retroalimentación diagnóstica o T1 (columnas 2, 5, 8, 11) y del fortalecimiento de capacidades o T2 (columnas 3, 6, 9, 12), con respecto a las escuelas de control, usando efectos fijos de aleatorización. (2) Las tasas de abandono deben interpretarse como una estimación de cota superior, ya que en realidad se refieren al porcentaje de estudiantes que dejan su escuela sin solicitar el pase a otra escuela. (3) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla 5: Efecto ITT de las intervenciones sobre la evaluación nacional de estudiantes (2016)

	(1) Escuelas de control	(2) Escuelas T1	(3) Escuelas T2	(4) Col. (2)- Col. (1)	(5) Col. (3)- Col. (1)	(6) Prueba F $\beta_1 = \beta_2$
Matemática (puntaje TRI)	0 (1)	.259 (1.082)	.164 (1.038)	.257** (.107)	.173** (.079)	.503 (.48)
Lectura (puntaje TRI)	0 (1)	.226 (1.034)	.164 (1.04)	.221** (.099)	.177* (.102)	.139 (.71)
N (estudiantes)	1661	1291	1217	3538	3538	3538

Notas: (1) La tabla muestra, para 2016, las medias y desviaciones estándar de todas las escuelas de control (columna 1), de las escuelas de retroalimentación diagnóstica o T1 (columna 2) y de las escuelas de fortalecimiento de capacidades o T2 (columna 3). También estima el efecto ITT de T1 y T2 con respecto a las escuelas de control en 2015, usando efectos fijos de aleatorización (columnas 4-5). Por último, muestra el estadístico F y el valor p asociado para la hipótesis nula de que los coeficientes de T1 y T2 son iguales (columna 6). (2) Todos los puntajes se presentan como puntajes escalados con TRI, estandarizados con respecto al grupo de control en 2016. (3) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla 6: Efecto ITT de las intervenciones sobre la gestión escolar reportada por los directores (2015)

	(1) Escuelas de control	(2) Escuelas T1	(3) Escuelas T2	(4) Col. (2)- Col. (1)	(5) Col. (3)- Col. (1)	(6) Prueba F $\beta_1 = \beta_2$
Mi escuela fijó metas según los resultados de las evaluaciones	.483 (.509)	.964 (.189)	.963 (.192)	.475*** (.103)	.484*** (.103)	.021 (.885)
Hice cambios al currículo según los resultados de las evaluaciones	.7 (.466)	1 (0)	.931 (.258)	.295*** (.086)	.233** (.099)	1.665 (.2)
Me evalúan en parte según los resultados de las evaluaciones	.333 (.479)	.615 (.496)	.704 (.465)	.284** (.135)	.37*** (.127)	.405 (.526)
Mis docentes son evaluados en parte según los resultados de las evaluaciones	.452 (.506)	.69 (.471)	.654 (.485)	.233* (.128)	.208 (.133)	.035 (.853)
Asigno estudiantes a secciones según los resultados de las evaluaciones	.107 (.315)	.231 (.43)	.107 (.315)	.11 (.099)	0 (.086)	1.226 (.271)
Informé a los padres sobre los resultados de sus hijos	.452 (.506)	.857 (.356)	.931 (.258)	.423*** (.11)	.485*** (.104)	.542 (.464)
Hice públicos los resultados de las evaluaciones de mi escuela	.207 (.412)	.519 (.509)	.519 (.509)	.318** (.126)	.309** (.126)	.004 (.952)
N (escuelas)	42	29	30	101	101	101

Notas: (1) La tabla muestra, para el ciclo lectivo 2015, las medias y desviaciones estándar del grupo de control (columna 1), del grupo de retroalimentación diagnóstica o T1 (columna 2) y del grupo de fortalecimiento de capacidades o T2 (columna 3). También estima el efecto ITT de T1 y T2 con respecto a las escuelas de control, usando efectos fijos de aleatorización (columnas 4-5). Por último, muestra el estadístico F y el valor p asociado para la hipótesis nula de que los coeficientes de T1 y T2 son iguales en 2015 (columna 6). (2) Se pidió a los directores que indicaran si sus escuelas usaban los resultados de las evaluaciones de estudiantes para los fines enumerados arriba. Las cifras indican la proporción de directores que reportaron que sus escuelas usaban las evaluaciones para cada fin, con referencia al ciclo lectivo de la recolección de datos. (3) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla 7: Efecto ITT de las intervenciones sobre el uso del tiempo de los docentes reportado por los estudiantes (2015)

	(1) Escuelas de control	(2) Escuelas T1	(3) Escuelas T2	(4) Col. (2)- Col. (1)	(5) Col. (3)- Col. (1)	(6) Prueba F $\beta_1 = \beta_2$
Mi docente faltó a la escuela	.578 (.494)	.554 (.497)	.6 (.49)	-.025 (.031)	.026 (.03)	2.206 (.141)
Mi docente llegó tarde a la escuela	.394 (.489)	.364 (.481)	.413 (.492)	-.032 (.033)	.021 (.04)	1.411 (.238)
Mi docente empezó la clase tarde	.443 (.497)	.394 (.489)	.446 (.497)	-.05* (.029)	.005 (.036)	1.763 (.187)
Mi docente terminó la clase temprano	.5 (.5)	.441 (.497)	.492 (.5)	-.06** (.03)	-.006 (.035)	1.699 (.195)
Mi docente se retiró temprano de la escuela	.449 (.497)	.389 (.488)	.433 (.496)	-.06* (.035)	-.014 (.039)	.982 (.324)
N (estudiantes)	4034	3014	2854	9902	9902	9902

Notas: (1) La tabla muestra, para el ciclo lectivo 2015, las medias y desviaciones estándar del grupo de control (columna 1), del grupo de retroalimentación diagnóstica o T1 (columna 2) y del grupo de fortalecimiento de capacidades o T2 (columna 3). También estima el efecto ITT de T1 y T2 con respecto a las escuelas de control, usando efectos fijos de aleatorización (columnas 4-5). (2) Se pidió a los estudiantes que indicaran con qué frecuencia ellos o sus docentes realizaron las actividades anteriores. Las cifras indican la proporción de estudiantes que reportaron que estas actividades ocurrieron dos o más veces por semana, con referencia a las dos semanas previas a la ronda de recolección de datos.

(3) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla 8: Efecto ITT de las intervenciones sobre las actividades de los docentes reportadas por los estudiantes (2015)

	(1) Escuelas de control	(2) Escuelas T1	(3) Escuelas T2	(4) Col. (2)- Col. (1)	(5) Col. (3)- Col. (1)	(6) Prueba F $\beta_1 = \beta_2$
Usé un libro de texto	.814 (.389)	.872 (.334)	.85 (.357)	.058*** (.016)	.036** (.016)	1.869 (.175)
Mi docente me dio tarea	.936 (.245)	.958 (.2)	.949 (.22)	.022*** (.008)	.014 (.009)	.888 (.348)
Copié del pizarrón	.912 (.283)	.938 (.241)	.913 (.281)	.026** (.012)	.001 (.01)	4.186 (.043)
Trabajé en grupo	.916 (.278)	.936 (.245)	.921 (.27)	.021 (.014)	.004 (.013)	1.506 (.223)
Mi docente explicó un tema	.96 (.196)	.977 (.149)	.969 (.174)	.018*** (.006)	.009 (.006)	1.992 (.161)
Mi docente me tomó una prueba de práctica	.892 (.311)	.911 (.285)	.9 (.299)	.02 (.014)	.008 (.011)	.758 (.386)
Mi docente corrigió mi tarea	.958 (.2)	.975 (.156)	.956 (.206)	.018*** (.006)	-.004 (.007)	9.084 (.003)
N (estudiantes)	4034	3014	2854	9902	9902	9902

Notas: (1) La tabla muestra, para el ciclo lectivo 2015, las medias y desviaciones estándar del grupo de control (columna 1), del grupo de retroalimentación diagnóstica o T1 (columna 2) y del grupo de fortalecimiento de capacidades o T2 (columna 3). También estima el efecto ITT de T1 y T2 con respecto a las escuelas de control, usando efectos fijos de aleatorización (columnas 4-5). (2) Se pidió a los estudiantes que indicaran con qué frecuencia ellos o sus docentes realizaron las actividades anteriores. Las cifras indican la proporción de estudiantes que reportaron que estas actividades ocurrieron dos o más veces por semana, con referencia a las dos semanas previas a la ronda de recolección de datos.

(3) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla 9: Efecto ITT de las intervenciones sobre la efectividad de los docentes reportada por los estudiantes (2015)

	(1) Escuelas de control	(2) Escuelas T1	(3) Escuelas T2	(4) Col. (2)- Col. (1)	(5) Col. (3)- Col. (1)	(6) Prueba F $\beta_1 = \beta_2$
Cuidado (puntaje estandarizado)	0 (1)	.186 (.854)	.003 (.967)	.191*** (.05)	-.006 (.052)	17.419 (0)
Control (puntaje estandarizado)	0 (1)	.128 (.9)	.029 (.949)	.133*** (.05)	.02 (.053)	4.108 (.045)
Claridad (puntaje estandarizado)	0 (1)	.163 (.865)	.053 (.951)	.168*** (.056)	.048 (.053)	4.386 (.039)
Desafío (puntaje estandarizado)	0 (1)	.171 (.887)	.017 (1.01)	.176*** (.06)	.01 (.057)	7.21 (.008)
Cautivación (puntaje estandarizado)	0 (1)	.152 (.822)	.022 (.943)	.157*** (.042)	.017 (.049)	8.523 (.004)
Diálogo (puntaje estandarizado)	0 (1)	.129 (.874)	-.001 (.995)	.137** (.055)	-.009 (.056)	6.244 (.014)
Consolidación (puntaje estandarizado)	0 (1)	.168 (.881)	-.004 (.983)	.177*** (.054)	-.017 (.054)	11.054 (.001)
N (estudiantes)	4034	3014	2854	9902	9902	9902

Notas: (1) La tabla muestra, para el ciclo lectivo 2015, las medias y desviaciones estándar del grupo de control (columna 1), del grupo de retroalimentación diagnóstica o T1 (columna 2) y del grupo de fortalecimiento de capacidades o T2 (columna 3). También estima el efecto ITT de T1 y T2 con respecto a las escuelas de control, usando efectos fijos de aleatorización (columnas 4-5). (2) Se pidió a los estudiantes que indicaran con qué frecuencia su docente mostraba ciertas conductas (p. ej., tratarlos con amabilidad cuando hacen preguntas) en una escala tipo Likert, de 1 (nunca) a 5 (siempre). Luego, sus respuestas se usaron para calcular un puntaje para cada docente en siete dominios: (a) demostrar interés por sus estudiantes; (b) manejar el aula; (c) aclarar conceptos y tareas difíciles; (d) desafiar a los estudiantes a dar lo mejor de sí; (e) captar la atención de los estudiantes con sus clases; (f) involucrar a los estudiantes en discusiones; y (g) resumir el material aprendido al final de cada clase. Los puntajes de los estudiantes se estandarizaron con respecto al grupo de control en 2015. Los puntajes de cada dominio se expresan en desviaciones estándar a nivel de estudiante. (3) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Apéndice A Tablas adicionales

Tabla A.1: Comparación entre escuelas dentro y fuera de la muestra en eficiencia interna (2013)

	(1) Todas las escuelas	(2) Escuelas fuera de la muestra Todas	(3) Escuelas fuera de la muestra No rurales	(4) Escuelas en la muestra	(5) Col.(4)- Col.(2)	(6) Col.(4)- Col.(3)
<i>Panel A. Escuela primaria</i>						
Número de estudiantes matriculados	122.753 (212.564)	38.019 (92.519)	310.684 (176.837)	332.144 (272.879)	294.125*** (19.261)	24.539 (64.993)
Porcentaje de estudiantes que aprobaron el grado	95.503 (9.296)	95.59 (10.648)	95.946 (3.413)	95.292 (4.61)	-.298 (1.084)	-.7 (1.111)
Porcentaje de estudiantes que reprobaron el grado	3.703 (7.161)	3.385 (7.981)	3.882 (3.459)	4.477 (4.533)	1.092 (.833)	.638 (1.096)
Porcentaje de estudiantes que abandonaron la escuela	.794 (6.198)	1.026 (7.332)	.173 (.545)	.232 (.906)	-.794 (.722)	.061 (.216)
Porcentaje de estudiantes que repitieron el grado	3.816 (6.557)	3.752 (7.223)	4.26 (3.827)	3.975 (4.536)	.223 (.763)	-.247 (1.109)
N (escuelas)	361	257	19	104	361	122
<i>Panel B. 3.er grado</i>						
Número de estudiantes matriculados	21.565 (33.602)	7.193 (15.909)	47.895 (28.075)	49.481 (40.714)	42.288*** (3.259)	2.028 (9.746)
Porcentaje de estudiantes que aprobaron el grado	95.593 (14.461)	95.755 (17.179)	96.869 (3.996)	95.283 (6.758)	-.473 (1.752)	-1.632 (1.607)
Porcentaje de estudiantes que reprobaron el grado	3.899 (13.306)	3.729 (15.767)	2.992 (3.915)	4.225 (6.406)	.496 (1.612)	1.274 (1.526)
Porcentaje de estudiantes que abandonaron la escuela	.508 (5.912)	.516 (7.09)	.138 (.603)	.492 (2.414)	-.024 (.716)	.358 (.561)
Porcentaje de estudiantes que repitieron el grado	4.807 (14.975)	5.284 (18.01)	2.885 (3.345)	3.882 (5.454)	-1.402 (1.808)	1.035 (1.299)
N (escuelas)	306	202	19	104	306	122
<i>Panel C. 5.º grado</i>						
Número de estudiantes matriculados	21.01 (33.015)	7.059 (14.384)	43.316 (25.699)	48.24 (41.235)	41.181*** (3.216)	5.383 (9.797)
Porcentaje de estudiantes que aprobaron el grado	96.267 (11.532)	96.36 (13.658)	97.931 (3.548)	96.093 (5.823)	-.267 (1.404)	-1.876 (1.387)
Porcentaje de estudiantes que reprobaron el grado	3.153 (10.659)	2.775 (12.501)	1.919 (3.573)	3.859 (5.835)	1.085 (1.296)	1.978 (1.39)
Porcentaje de estudiantes que abandonaron la escuela	.58 (4.801)	.865 (5.925)	.151 (.656)	.048 (.49)	-.817 (.583)	-.102 (.13)
Porcentaje de estudiantes que repitieron el grado	2.567 (9.078)	2.243 (10.245)	2.218 (4.528)	3.201 (6.194)	.959 (1.095)	1.014 (1.496)
N (escuelas)	307	203	19	104	307	122

Notas: (1) La tabla muestra las medias y desviaciones estándar de todas las escuelas primarias públicas de La Rioja (columna 1), de las escuelas fuera del experimento (columnas 2-3) y de las escuelas del experimento (columna 4). También prueba las diferencias entre todas las escuelas fuera y dentro del experimento (columna 5), y entre las escuelas no rurales fuera del experimento y las escuelas del experimento (columna 6). El Panel A muestra resultados para todos los estudiantes de primaria, el Panel B para estudiantes de 3.er grado y el Panel C para estudiantes de 5.º grado. (2) Las tasas de abandono deben interpretarse como una estimación de cota superior, ya que en realidad se refieren al porcentaje de estudiantes que dejan su escuela sin solicitar el pase a otra escuela. (3) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.2: Diferencias en el ausentismo estudiantil entre grupos experimentales (2013-2015)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)	(10)	(11)
	2013			2014				2015			
	Escuelas T1	Escuelas T2	Col. (2)- Col. (1)	Escuelas T1	Escuelas T2	Col. (5)- Col. (4)	Escuelas de control	Escuelas T1	Escuelas T2	Col. (8)- Col. (7)	Col. (9)- Col. (7)
<i>Panel A. 3.er grado</i>											
Porcentaje de estudiantes ausentes en matemática	17.43 (19.86)	18.27 (12.92)	.847 (4.378)	11.37 (9.75)	12.26 (10.62)	.891 (2.652)	20.61 (14.82)	19.51 (14.48)	15.89 (11.45)	-1.102 (3.46)	-4.717 (3.062)
Porcentaje de estudiantes ausentes en lectura	20.48 (19.76)	20.5 (11.66)	.025 (4.242)	7.64 (20.06)	11.67 (7.59)	4.023 (3.974)	17.2 (10.39)	15.24 (12.12)	15.14 (10.34)	-1.967 (2.711)	-2.069 (2.453)
N (escuelas)	30	30	60	30	30	60	44	30	30	74	74
<i>Panel B. 5.º grado</i>											
Porcentaje de estudiantes ausentes en matemática	12.58 (20.37)	8.79 (39.6)	-3.787 (8.161)	12.64 (12.05)	11.74 (9.02)	-.901 (2.747)	15.83 (10.54)	11.36 (11.62)	15.72 (6.72)	-4.474* (2.65)	-.108 (2.01)
Porcentaje de estudiantes ausentes en lectura	15.64 (18.04)	12.69 (42.13)	-2.945 (8.391)	13.46 (14.44)	11.22 (8.51)	-2.238 (3.06)	14.52 (11.02)	9.99 (8.93)	13.89 (8.08)	-4.538* (2.328)	-.639 (2.223)
N (escuelas)	30	30	60	30	30	60	44	30	30	74	74

Notas: (1) La tabla muestra la tasa media de ausentismo el día de la prueba por asignatura, año y grupo experimental, y su desviación estándar correspondiente (columnas 1-2, 4-5 y 7-9). También estima la diferencia en las tasas de ausentismo entre todos los grupos experimentales evaluados en un año determinado (columnas 3, 6 y 10-11). (2) Las escuelas de control solo fueron evaluadas en 2015 (ver secciones 2.3 y 2.4 del manuscrito). (3) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.3: Pruebas de balance entre grupos experimentales en eficiencia interna (2013)

	(1) Escuelas en la muestra	(2) Escuelas de control	(3) Escuelas T1	(4) Escuelas T2	(5) Col.(4)- Col.(2)	(6) Col.(4)- Col.(3)
<i>Panel A. Escuela primaria</i>						
Número de estudiantes matriculados	332.144 (272.879)	324.205 (334.744)	356.4 (210.542)	319.533 (230.495)	-17.335 (48.034)	11.59 (48.296)
Porcentaje de estudiantes que aprobaron el grado	95.292 (4.61)	95.281 (5.274)	95.118 (4.465)	95.482 (3.772)	-.103 (1.2)	.222 (1.134)
Porcentaje de estudiantes que reprobaron el grado	4.477 (4.533)	4.329 (5.098)	4.668 (4.492)	4.501 (3.769)	.29 (1.176)	.141 (1.104)
Porcentaje de estudiantes que abandonaron la escuela	.232 (.906)	.39 (1.186)	.214 (.86)	.016 (.052)	-.187 (.258)	-.362 (.218)
Porcentaje de estudiantes que repitieron el grado	3.975 (4.536)	3.487 (4.264)	3.543 (3.381)	5.121 (5.725)	.009 (.951)	1.589 (1.162)
N (escuelas)	104	44	30	30	74	74
<i>Panel B. 3.er grado</i>						
Número de estudiantes matriculados	49.481 (40.714)	48.114 (49.116)	52.9 (32.648)	48.067 (35.039)	-2.732 (6.797)	2.424 (6.887)
Porcentaje de estudiantes que aprobaron el grado	95.283 (6.758)	95.883 (5.743)	93.211 (9.064)	96.474 (4.968)	-2.596 (1.757)	.555 (1.302)
Porcentaje de estudiantes que reprobaron el grado	4.225 (6.406)	3.295 (4.581)	6.313 (9.139)	3.501 (4.977)	2.95* (1.643)	.218 (1.134)
Porcentaje de estudiantes que abandonaron la escuela	.492 (2.414)	.822 (3.499)	.476 (1.461)	.024 (.133)	-.354 (.692)	-.772 (.646)
Porcentaje de estudiantes que repitieron el grado	3.882 (5.454)	3.646 (5.416)	3.718 (4.57)	4.393 (6.393)	.137 (1.231)	.692 (1.391)
N (escuelas)	104	44	30	30	74	74
<i>Panel C. 5.º grado</i>						
Número de estudiantes matriculados	48.24 (41.235)	47.591 (52.049)	54.067 (30.773)	43.367 (31.856)	-.916 (7.654)	-1.841 (7.644)
Porcentaje de estudiantes que aprobaron el grado	96.093 (5.823)	95.142 (7.094)	96.08 (5.16)	97.499 (3.973)	1.043 (1.542)	2.309 (1.443)
Porcentaje de estudiantes que reprobaron el grado	3.859 (5.835)	4.858 (7.094)	3.753 (5.205)	2.501 (3.973)	-1.206 (1.544)	-2.309 (1.443)
Porcentaje de estudiantes que abandonaron la escuela	.048 (.49)	0 (0)	.167 (.913)	0 (0)	.163 (.138)	0 (0)
Porcentaje de estudiantes que repitieron el grado	3.201 (6.194)	3.077 (6.207)	2.471 (3.646)	4.114 (8.025)	-.673 (1.286)	1.02 (1.663)
N (escuelas)	104	44	30	30	74	74

Notas: (1) La tabla muestra las medias y desviaciones estándar de todas las escuelas de nuestra muestra (columna 1), de las escuelas de control (columna 2), de las escuelas de retroalimentación diagnóstica o T1 (columna 3) y de las escuelas de fortalecimiento de capacidades o T2 (columna 4). También prueba las diferencias entre las escuelas de control y de tratamiento, con efectos fijos de aleatorización (columnas 5-6). El Panel A muestra resultados para todos los estudiantes de primaria, el Panel B para estudiantes de 3.er grado y el Panel C para estudiantes de 5.º grado. (2) Las tasas de abandono deben interpretarse como una estimación de cota superior, ya que en realidad se refieren al porcentaje de estudiantes que dejan su escuela sin solicitar el pase a otra escuela. (3) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.4: Pruebas de balance entre grupos de tratamiento en el logro de los estudiantes (2013)

	(1) Escuelas de tratamiento	(2) Escuelas T1	(3) Escuelas T2	(4) Col. (3)- Col. (2)
<i>Panel A. Escuela primaria</i>				
Matemática (% de aciertos)	55.459 (19.502)	56.513 (18.823)	54.193 (20.219)	-2.224 (2.397)
Matemática (puntaje TRI)	.038 (1.027)	.096 (.994)	-.032 (1.062)	-.123 (.135)
Lectura (% de aciertos)	57.012 (20.378)	58.541 (19.97)	55.155 (20.717)	-2.918 (2.68)
Lectura (puntaje TRI)	.072 (.968)	.145 (.961)	-.016 (.969)	-.139 (.125)
N (estudiantes)	4903	2689	2214	4903
<i>Panel B. 3.er grado</i>				
Matemática (% de aciertos)	59.86 (20.694)	61.405 (19.375)	58.075 (21.994)	-3.152 (2.907)
Matemática (puntaje TRI)	.095 (.985)	.172 (.926)	.007 (1.044)	-.155 (.139)
Lectura (% de aciertos)	56.443 (21.718)	58.394 (21.176)	54.178 (22.125)	-3.825 (3.14)
Lectura (puntaje TRI)	.041 (.943)	.124 (.926)	-.054 (.953)	-.16 (.134)
N (estudiantes)	2457	1320	1137	2457
<i>Panel C. 5.º grado</i>				
Matemática (% de aciertos)	50.977 (17.073)	51.714 (16.936)	50.054 (17.206)	-1.718 (2.45)
Matemática (puntaje TRI)	-.02 (1.065)	.023 (1.051)	-.074 (1.08)	-.098 (.157)
Lectura (% de aciertos)	57.584 (18.925)	58.683 (18.74)	56.187 (19.075)	-1.977 (2.493)
Lectura (puntaje TRI)	.104 (.992)	.166 (.994)	.024 (.985)	-.117 (.131)
N (estudiantes)	2446	1369	1077	2446

Notas: (1) La tabla muestra las medias y desviaciones estándar de todas las escuelas de tratamiento (columna 1), de las escuelas de retroalimentación diagnóstica o T1 (columna 2) y de las escuelas de fortalecimiento de capacidades o T2 (columna 3). También prueba las diferencias entre las escuelas T1 y T2, con efectos fijos de aleatorización (columna 4). El Panel A muestra resultados para estudiantes de 3.er y 5.º grado, el Panel B para estudiantes de 3.er grado y el Panel C para estudiantes de 5.º grado. (2) Todos los puntajes se presentan como puntajes de porcentaje de respuestas correctas y como puntajes escalados con TRI, estandarizados respecto del grupo de control en 2015. (3) Las escuelas de control no fueron evaluadas en 2013 (ver secciones 2.3 y 2.4 del manuscrito). (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.5: Pruebas de balance entre grupos de tratamiento en la encuesta a estudiantes (2013)

	(1) Escuelas de tratamiento	(2) Escuelas T1	(3) Escuelas T2	(4) Col. (3)- Col. (2)
<i>Panel A. Escuela primaria</i>				
Mujer	.498 (.5)	.494 (.5)	.502 (.5)	.008 (.013)
Índice de educación de los padres	0 (2.195)	.061 (2.173)	-.066 (2.279)	-.27 (.196)
Índice de bienes del hogar	0 (1.424)	.014 (1.415)	-.016 (1.415)	.005 (.146)
Índice de apoyos al estudio	0 (1.1)	.009 (1.115)	-.01 (1.077)	-.064 (.057)
N (estudiantes)	4212	3278	3018	4212
<i>Panel B. 3.er grado</i>				
Mujer	.498 (.5)	.502 (.5)	.493 (.5)	-.008 (.019)
Índice de educación de los padres	0 (2.288)	.106 (2.199)	-.129 (2.387)	-.195 (.187)
Índice de bienes del hogar	0 (1.397)	.018 (1.387)	-.022 (1.409)	.015 (.129)
Índice de apoyos al estudio	0 (1.092)	.049 (1.114)	-.055 (1.064)	-.084 (.063)
N (estudiantes)	2084	1103	981	2084
<i>Panel C. 5.º grado</i>				
Mujer	.499 (.5)	.487 (.5)	.513 (.5)	.024 (.022)
Índice de educación de los padres	0 (2.11)	.157 (1.974)	-.201 (2.257)	-.336 (.255)
Índice de bienes del hogar	0 (1.447)	.037 (1.443)	-.048 (1.453)	-.003 (.179)
Índice de apoyos al estudio	0 (1.108)	.026 (1.155)	-.033 (1.045)	-.046 (.073)
N (estudiantes)	2128	1194	934	2128

Notas: (1) La tabla muestra la media y la desviación estándar de todas las escuelas de tratamiento (columna 1), de las escuelas de retroalimentación diagnóstica o T1 (columna 2) y de las escuelas de fortalecimiento de capacidades o T2 (columna 3). También prueba las diferencias entre las escuelas T1 y T2, con efectos fijos de aleatorización (columna 4). El Panel A muestra resultados para estudiantes de 3.er y 5.º grado, el Panel B para estudiantes de 3.er grado y el Panel C para estudiantes de 5.º grado. (2) El índice de educación de los padres es el primer componente principal de un análisis de componentes principales (ACP) del máximo nivel educativo alcanzado por la madre y el padre de cada estudiante y de su nivel de alfabetización, según lo informado por el estudiante. (3) El índice de bienes del hogar es el primer componente principal de un ACP de variables que indican si cada estudiante tenía en su hogar heladera, microondas, ventilador, televisor, baño, computadora e internet. (4) El índice de apoyos al estudio es el primer componente principal de un ACP de variables que indican si a cada estudiante se le asignaba tarea todos los días, si tomaba clases particulares, si hacía la tarea solo, y la cantidad de libros en su hogar. (5) Todos los índices están estandarizados respecto del conjunto de escuelas de tratamiento dentro de cada grado en 2013. (6) Las escuelas de control no fueron evaluadas en 2013 (ver secciones 2.3 y 2.4 del manuscrito). (7) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.6: Efecto ITT de las intervenciones sobre el logro de los estudiantes, por grado (2014-2015)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
	2014					2015			
	Escuelas T1	Escuelas T2	Col. (2)- Col. (1)	Escuelas de control	Escuelas T1	Escuelas T2	Col. (5)- Col. (4)	Col. (6)- Col. (4)	Prueba F $\beta_1 = \beta_2$
<i>Panel A. Ambos grados</i>									
Matemática (% de aciertos)	55.779 (18.059)	54.941 (19.614)	-.635 (2.432)	51.552 (19.417)	57.69 (57.69)	55.46 (55.46)	6.275** (2.422)	3.939 (2.757)	.538 (.465)
Matemática (puntaje TRI)	.278 (.992)	.243 (1.075)	-.023 (.139)	0 (1)	.324 (.324)	.216 (.216)	.333** (.131)	.216 (.145)	.481 (.489)
Lectura (% de aciertos)	63.181 (19.666)	61.043 (20.092)	-1.431 (2.167)	58.319 (22.371)	66.048 (66.048)	61.674 (61.674)	7.713*** (2.13)	3.627 (2.518)	1.981 (.162)
Lectura (puntaje TRI)	.312 (.969)	.212 (.966)	-.066 (.105)	0 (1)	.357 (.357)	.153 (.153)	.356*** (.102)	.166 (.111)	1.987 (.162)
N (estudiantes)	3950	3588	7538	3446	3950	3588	10984	10984	10984
<i>Panel B. 3.er grado</i>									
Matemática (% de aciertos)	59.92 (18.839)	58.481 (21.014)	-1.418 (2.801)	55.334 (21.629)	61.955 (61.955)	58.084 (58.084)	6.776** (2.603)	2.853 (3.468)	1.064 (.305)
Matemática (puntaje TRI)	.322 (.944)	.262 (1.043)	-.062 (.137)	0 (1)	.31 (.31)	.14 (.14)	.321*** (.119)	.143 (.158)	1.034 (.312)
Lectura (% de aciertos)	61.91 (21.274)	58.74 (21.919)	-2.511 (2.621)	56.779 (24.029)	64.6 (64.6)	59.238 (59.238)	7.714*** (2.413)	2.781 (2.98)	2.275 (.135)
Lectura (puntaje TRI)	.332 (.948)	.192 (.96)	-.112 (.112)	0 (1)	.327 (.327)	.098 (.098)	.322*** (.104)	.112 (.122)	2.279 (.134)
N (estudiantes)	1951	1769	3720	1650	1951	1769	5370	5370	5370
<i>Panel C. 5.º grado</i>									
Matemática (% de aciertos)	51.484 (16.133)	51.366 (17.382)	.269 (2.586)	48.094 (16.407)	53.704 (53.704)	52.907 (52.907)	5.746** (2.537)	4.754* (2.556)	.106 (.746)
Matemática (puntaje TRI)	.233 (1.037)	.223 (1.105)	.015 (.166)	0 (1)	.336 (.336)	.29 (.29)	.344** (.155)	.288* (.155)	.093 (.761)
Lectura (% de aciertos)	64.497 (17.762)	63.358 (17.781)	-.412 (2.069)	59.734 (20.636)	67.418 (67.418)	64.032 (64.032)	7.727*** (2.264)	4.518* (2.407)	1.223 (.271)
Lectura (puntaje TRI)	.291 (.99)	.233 (.973)	-.019 (.118)	0 (1)	.385 (.385)	.207 (.207)	.387*** (.118)	.218* (.118)	1.324 (.253)
N (estudiantes)	1999	1819	3818	1796	1999	1819	5614	5614	5614

Notas: (1) La tabla muestra, para 2014 y 2015, las medias y desviaciones estándar de todas las escuelas de control (columna 4), de las escuelas de retroalimentación diagnóstica o T1 (columnas 1 y 5) y de las escuelas de fortalecimiento de capacidades o T2 (columnas 2 y 6). También estima el efecto ITT de T2 respecto de T1 en 2014 (columna 3) y de T1 y T2 respecto de las escuelas de control en 2015, con efectos fijos de aleatorización (columnas 7-8). Por último, muestra el estadístico F y el valor p asociado para la hipótesis nula de que los coeficientes de T1 y T2 son iguales en 2015 (columna 9). El Panel A muestra resultados para estudiantes de 3.er y 5.º grado, el Panel B para estudiantes de 3.er grado y el Panel C para estudiantes de 5.º grado. (2) Todos los puntajes se presentan como puntajes de porcentaje de respuestas correctas y como puntajes escalados con TRI, estandarizados respecto del grupo de control en 2015. (3) Las escuelas de control no fueron evaluadas en 2013 (ver secciones 2.3 y 2.4 del manuscrito). (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.7: Efecto ITT de las intervenciones sobre el logro de los estudiantes, por grado y dominio de contenido (2014-2015)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
	2014					2015			
	Escuelas T1	Escuelas T2	Col. (2)- Col. (1)	Escuelas de control	Escuelas T1	Escuelas T2	Col. (5)- Col. (4)	Col. (6)- Col. (4)	Prueba F $\beta_1 = \beta_2$
<i>Panel A. Ambos grados</i>									
Matemática - Números	54.261 (19.536)	54.047 (20.62)	-.106 (2.423)	52.094 (21.783)	57.154 (57.154)	56.276 (56.276)	5.202** (2.594)	4.22 (3.035)	.08 (.777)
Matemática - Geometría	58.993 (25.062)	58.047 (26.88)	-.406 (2.538)	53.732 (26.413)	60.471 (60.471)	57.115 (57.115)	6.771*** (2.297)	3.525 (2.558)	1.239 (.268)
Matemática - Medición	50.143 (25.102)	48.87 (26.211)	-1.349 (2.734)	43.419 (24.801)	51.303 (51.303)	47.836 (47.836)	8.142*** (2.516)	4.297 (2.744)	1.461 (.23)
Lectura - Textos informativos	60.669 (22.679)	59.457 (22.862)	-.406 (2.161)	58.52 (25.26)	66.107 (66.107)	62.657 (62.657)	7.569*** (2.068)	4.441* (2.544)	1.119 (.293)
Lectura - Textos narrativos	64.319 (23.133)	61.822 (23.503)	-1.909 (2.165)	58.418 (25.878)	66.298 (66.298)	61.578 (61.578)	7.87*** (2.104)	3.35 (2.48)	2.471 (.119)
Lectura - Textos breves	65.459 (28.321)	61.498 (29.204)	-3.183 (2.455)	60.818 (32.493)	68.811 (68.811)	62.482 (62.482)	7.963*** (2.269)	1.974 (2.819)	3.855 (.052)
N (estudiantes)	3950	3588	7538	3446	3950	3588	10984	10984	10984
<i>Panel B. 3.er grado</i>									
Matemática - Números	60.782 (18.503)	59.427 (19.811)	-1.292 (2.55)	58.324 (22.391)	64.411 (64.411)	60.855 (60.855)	6.166** (2.704)	2.678 (3.566)	.799 (.374)
Matemática - Geometría	65.265 (26.797)	64.002 (29.273)	-.976 (3.292)	58.043 (29.317)	64.172 (64.172)	60.199 (60.199)	6.343** (2.654)	2.241 (3.185)	1.41 (.238)
Matemática - Medición	53.648 (27.679)	51.859 (29.741)	-2.078 (3.434)	45.454 (28.701)	53.845 (53.845)	49.223 (49.223)	8.701*** (2.754)	3.772 (3.844)	1.391 (.241)
Lectura - Textos informativos	59.269 (22.405)	57.885 (22.501)	-.687 (2.324)	58.141 (26.011)	65.101 (65.101)	61.116 (61.116)	6.877*** (2.299)	3.252 (2.917)	1.24 (.268)
Lectura - Textos narrativos	62.068 (25.392)	58.467 (25.558)	-2.999 (2.872)	56.929 (28.702)	65.108 (65.108)	59.083 (59.083)	8.023*** (2.56)	2.507 (3.034)	2.776 (.099)
Lectura - Textos breves	69.396 (31.301)	62.683 (33.492)	-5.994* (3.283)	56.582 (34.2)	66.027 (66.027)	57.813 (57.813)	9.363*** (2.847)	1.553 (3.759)	3.854 (.052)
N (estudiantes)	1951	1769	3720	1650	1951	1769	5370	5370	5370
<i>Panel C. 5.º grado</i>									
Matemática - Números	47.497 (18.241)	48.614 (19.995)	1.279 (2.916)	46.397 (19.551)	50.372 (50.372)	51.821 (51.821)	4.182 (2.854)	5.323* (3.13)	.101 (.751)
Matemática - Geometría	52.487 (21.263)	52.035 (22.703)	.35 (2.428)	49.789 (22.749)	57.011 (57.011)	54.115 (54.115)	7.138*** (2.435)	4.499* (2.4)	.828 (.365)
Matemática - Medición	46.508 (21.529)	45.852 (21.68)	-.52 (2.944)	41.559 (20.431)	48.928 (48.928)	46.486 (46.486)	7.594*** (2.637)	4.677* (2.366)	1 (.32)
Lectura - Textos informativos	62.118 (22.878)	61.037 (23.12)	-.184 (2.478)	58.867 (24.552)	67.057 (67.057)	64.149 (64.149)	8.229*** (2.192)	5.61** (2.453)	.785 (.378)
Lectura - Textos narrativos	66.648 (20.284)	65.194 (20.707)	-.928 (1.775)	59.786 (22.903)	67.423 (67.423)	63.993 (63.993)	7.702*** (2.264)	4.226* (2.411)	1.444 (.232)
Lectura - Textos breves	61.385 (24.211)	60.307 (24.094)	-.23 (2.273)	64.71 (30.335)	71.444 (71.444)	67.003 (67.003)	6.741*** (2.305)	2.593 (2.456)	2.266 (.135)
N (estudiantes)	1999	1819	3818	1796	1999	1819	5614	5614	5614

Notas: (1) La tabla muestra, para 2014 y 2015, las medias y desviaciones estándar de todas las escuelas de control (columna 4), de las escuelas de retroalimentación diagnóstica o T1 (columnas 1 y 5) y de las escuelas de fortalecimiento de capacidades o T2 (columnas 2 y 6). También estima el efecto ITT de T2 respecto de T1 en 2014 (columna 3) y de T1 y T2 respecto de las escuelas de control en 2015, con efectos fijos de aleatorización (columnas 7-8). Por último, muestra el estadístico F y el valor p asociado para la hipótesis nula de que los coeficientes de T1 y T2 son iguales en 2015 (columna 9). El Panel A muestra resultados para estudiantes de 3.er y 5.º grado, el Panel B para estudiantes de 3.er grado y el Panel C para estudiantes de 5.º grado. (2) Todos los puntajes se presentan como puntajes de porcentaje de respuestas correctas y como puntajes escalados con TRI, estandarizados respecto del grupo de control en 2015. (3) Las escuelas de control no fueron evaluadas en 2013 (ver secciones 2.3 y 2.4 del manuscrito). (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.8: Efecto ITT de las intervenciones sobre el logro de los estudiantes,
por grado y dominio cognitivo (2014-2015)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
	2014					2015			
	Escuelas T1	Escuelas T2	Col. (2)- Col. (1)	Escuelas de control	Escuelas T1	Escuelas T2	Col. (5)- Col. (4)	Col. (6)- Col. (4)	Prueba F $\beta_1 = \beta_2$
<i>Panel A. Ambos grados</i>									
Matemática - Conocer	62.023 (21.479)	60.537 (23.395)	-1.091 (2.491)	55.958 (22.558)	63.023 (63.023)	59.554 (59.554)	7.172*** (2.226)	3.672 (2.69)	1.364 (.246)
Matemática - Algoritmos	59.915 (24.136)	60.1 (25.175)	.53 (3.237)	56.313 (26.94)	60.798 (60.798)	59.899 (59.899)	4.661 (2.894)	3.648 (3.552)	.067 (.796)
Matemática - Razonar	39.818 (22.82)	39.856 (24.074)	-.102 (2.288)	38.032 (23.21)	44.527 (44.527)	42.592 (42.592)	6.688** (2.719)	4.492 (2.79)	.423 (.517)
Lectura - Localizar información explícita	70.121 (22.562)	67.983 (23.47)	-1.502 (2.065)	64.359 (25.632)	71.919 (71.919)	67.6 (67.6)	7.573*** (1.832)	3.375 (2.381)	2.543 (.114)
Lectura - Realizar inferencias directas	59.524 (23.827)	56.723 (23.637)	-2.214 (2.24)	57.295 (26.46)	64.483 (64.483)	59.988 (59.988)	7.207*** (2.161)	2.978 (2.606)	1.999 (.16)
Lectura - Interpretar e integrar información	58.967 (22.883)	57.309 (23.329)	-.728 (2.27)	54.533 (25.585)	63.209 (63.209)	58.594 (58.594)	8.586*** (2.371)	4.426* (2.664)	1.698 (.195)
Lectura - Evaluar y criticar elementos textuales	64.032 (27.296)	62.279 (27.492)	-1.066 (2.538)	55.639 (28.087)	63.131 (63.131)	59.226 (59.226)	7.481*** (2.643)	3.929 (2.693)	1.264 (.264)
N (estudiantes)	3950	3588	7538	3446	3950	3588	10984	10984	10984
<i>Panel B. 3.er grado</i>									
Matemática - Conocer	63.867 (23.613)	61.84 (26.272)	-1.922 (3.134)	56.065 (25.441)	63.354 (63.354)	58.881 (58.881)	7.483*** (2.538)	2.93 (3.537)	1.418 (.236)
Matemática - Algoritmos	61.722 (21.842)	59.766 (23.065)	-1.712 (2.919)	61.108 (26.138)	67.526 (67.526)	63.792 (63.792)	6.464** (2.883)	2.88 (3.842)	.732 (.394)
Matemática - Razonar	48.49 (23.223)	48.501 (24.331)	-.197 (2.785)	44.853 (25.972)	51.521 (51.521)	47.394 (47.394)	6.939** (2.891)	2.538 (3.67)	1.169 (.282)
Lectura - Localizar información explícita	70.122 (24.736)	67.149 (25.821)	-2.294 (2.749)	61.364 (26.367)	68.985 (68.985)	63.911 (63.911)	7.591*** (2.299)	2.686 (2.949)	2.369 (.127)
Lectura - Realizar inferencias directas	61.691 (25.872)	57.084 (26.194)	-3.95 (2.878)	59.012 (28.484)	66.707 (66.707)	60.908 (60.908)	7.619*** (2.508)	2.247 (3.113)	2.505 (.117)
Lectura - Interpretar e integrar información	53.877 (22.631)	51.923 (22.62)	-1.305 (2.328)	51.111 (26.896)	59.526 (59.526)	53.696 (53.696)	8.168*** (2.621)	3.061 (3.135)	2.069 (.153)
Lectura - Evaluar y criticar elementos textuales	60.635 (28.554)	57.711 (28.819)	-2.284 (3.137)	53.919 (29.169)	61.391 (61.391)	56.981 (56.981)	7.397*** (2.799)	3.406 (3.079)	1.391 (.241)
N (estudiantes)	1951	1769	3720	1650	1951	1769	5370	5370	5370
<i>Panel C. 5.º grado</i>									
Matemática - Conocer	60.111 (18.834)	59.221 (20.001)	-.226 (2.312)	55.861 (19.561)	62.715 (62.715)	60.21 (60.21)	6.898*** (2.238)	4.385* (2.262)	.898 (.345)
Matemática - Algoritmos	58.041 (26.182)	60.439 (27.145)	2.825 (4.064)	51.928 (26.922)	54.509 (54.509)	56.112 (56.112)	2.866 (3.353)	4.089 (3.925)	.08 (.778)
Matemática - Razonar	30.823 (18.517)	31.127 (20.389)	.259 (2.827)	31.796 (18.257)	37.99 (37.99)	37.921 (37.921)	6.354** (2.918)	5.958** (2.644)	.014 (.906)
Lectura - Localizar información explícita	70.119 (20.074)	68.822 (20.821)	-.715 (1.838)	67.11 (24.625)	74.694 (74.694)	71.173 (71.173)	7.624*** (2.042)	4.192* (2.175)	1.799 (.183)
Lectura - Realizar inferencias directas	57.282 (21.285)	56.36 (20.759)	-.405 (2.063)	55.718 (24.355)	62.381 (62.381)	59.096 (59.096)	6.748*** (2.276)	3.588 (2.48)	1.132 (.29)
Lectura - Interpretar e integrar información	64.234 (21.938)	62.721 (22.78)	-.366 (2.442)	57.678 (23.898)	66.692 (66.692)	63.337 (63.337)	9.017*** (2.537)	5.91** (2.636)	.917 (.34)
Lectura - Evaluar y criticar elementos textuales	67.548 (25.467)	66.868 (25.283)	.013 (2.554)	57.22 (26.966)	64.777 (64.777)	61.401 (61.401)	7.597** (2.961)	4.521 (2.85)	.786 (.377)
N (estudiantes)	1999	1819	3818	1796	1999	1819	5614	5614	5614

Notas: (1) La tabla muestra, para 2014 y 2015, las medias y desviaciones estándar de todas las escuelas de control (columna 4), de las escuelas de retroalimentación diagnóstica o T1 (columnas 1 y 5) y de las escuelas de fortalecimiento de capacidades o T2 (columnas 2 y 6). También estima el efecto ITT de T2 respecto de T1 en 2014 (columna 3) y de T1 y T2 respecto de las escuelas de control en 2015, con efectos fijos de aleatorización (columnas 7-8). Por último, muestra el estadístico F y el valor p asociado para la hipótesis nula de que los coeficientes de T1 y T2 son iguales en 2015 (columna 9). El Panel A muestra resultados para estudiantes de 3.er y 5.º grado, el Panel B para estudiantes de 3.er grado y el Panel C para estudiantes de 5.º grado. (2) Todos los puntajes se presentan como puntajes de porcentaje de respuestas correctas y como puntajes escalados con TRI, estandarizados respecto del grupo de control en 2015. (3) Las escuelas de control no fueron evaluadas en 2013 (ver secciones 2.3 y 2.4 del manuscrito). (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.9: Efecto ITT de las intervenciones sobre el logro de los estudiantes, por grado y familiaridad (2015)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
	2014					2015			
	Escuelas T1	Escuelas T2	Col. (2)- Col. (1)	Escuelas de control	Escuelas T1	Escuelas T2	Col. (5)- Col. (4)	Col. (6)- Col. (4)	Prueba F $\beta_1 = \beta_2$
<i>Panel A. Ambos grados</i>									
Matemática - Ítems conocidos	51.407 (17.985)	50.958 (19.365)	-.253 (1.767)	53.595 (22.79)	59.091 (59.091)	56.953 (56.953)	5.555** (2.405)	3.49 (2.666)	.462 (.498)
Matemática - Ítems nuevos	57.224 (20.042)	56.259 (21.467)	-.771 (2.696)	50.777 (20.085)	57.16 (57.16)	54.925 (54.925)	6.549*** (2.461)	4.142 (2.812)	.543 (.463)
Lectura - Ítems conocidos	61.933 (21.764)	58.803 (21.987)	-2.417 (2.176)	61.191 (26.093)	68.519 (68.519)	63.456 (63.456)	7.329*** (2.034)	2.534 (2.514)	3.046 (.084)
Lectura - Ítems nuevos	64.453 (21.097)	62.585 (21.525)	-1.165 (2.217)	58.247 (23.084)	66.22 (66.22)	62.093 (62.093)	7.965*** (2.221)	4.106 (2.57)	1.646 (.202)
N (estudiantes)	3950	3588	7538	3446	3950	3588	10984	10984	10984
<i>Panel B. 3.er grado</i>									
Matemática - Ítems conocidos	57.096 (18.26)	55.843 (20.238)	-1.002 (2.234)	58.76 (23.901)	64.243 (64.243)	59.889 (59.889)	5.512** (2.468)	1.375 (3.318)	1.398 (.24)
Matemática - Ítems nuevos	61.05 (20.856)	59.536 (22.897)	-1.584 (3.06)	53.963 (22.504)	61.039 (61.039)	57.362 (57.362)	7.281*** (2.726)	3.445 (3.573)	.936 (.336)
Lectura - Ítems conocidos	60.957 (24.86)	56.394 (25.132)	-3.864 (2.913)	58.133 (27.992)	66.667 (66.667)	60.261 (60.261)	8.429*** (2.511)	2.463 (3.294)	2.927 (.09)
Lectura - Ítems nuevos	62.291 (21.673)	59.679 (22.439)	-1.97 (2.557)	56.238 (24.037)	63.773 (63.773)	58.829 (58.829)	7.428*** (2.416)	2.908 (2.891)	1.964 (.164)
N (estudiantes)	1951	1769	3720	1650	1951	1769	5370	5370	5370
<i>Panel C. 5.º grado</i>									
Matemática - Ítems conocidos	45.507 (15.651)	46.025 (17.085)	.673 (1.88)	48.872 (20.628)	54.276 (54.276)	54.098 (54.098)	5.502** (2.734)	5.222** (2.591)	.008 (.929)
Matemática - Ítems nuevos	53.255 (18.344)	52.949 (19.374)	.149 (2.88)	47.863 (17.077)	53.534 (53.534)	52.554 (52.554)	5.818** (2.52)	4.616* (2.587)	.153 (.696)
Lectura - Ítems conocidos	62.944 (17.962)	61.223 (17.98)	-1.018 (1.795)	64 (23.883)	70.27 (70.27)	66.549 (66.549)	6.337*** (2.015)	2.745 (2.208)	2.013 (.159)
Lectura - Ítems nuevos	66.691 (20.251)	65.506 (20.156)	-.453 (2.253)	60.093 (22.017)	68.533 (68.533)	65.253 (65.253)	8.494*** (2.476)	5.363** (2.599)	.986 (.323)
N (estudiantes)	1999	1819	3818	1796	1999	1819	5614	5614	5614

Notas: (1) La tabla muestra, para 2014 y 2015, las medias y desviaciones estándar de todas las escuelas de control (columna 4), de las escuelas de retroalimentación diagnóstica o T1 (columnas 1 y 5) y de las escuelas de fortalecimiento de capacidades o T2 (columnas 2 y 6). También estima el efecto ITT de T2 respecto de T1 en 2014 (columna 3) y de T1 y T2 respecto de las escuelas de control en 2015, con efectos fijos de aleatorización (columnas 7-8). Por último, muestra el estadístico F y el valor p asociado para la hipótesis nula de que los coeficientes de T1 y T2 son iguales en 2015 (columna 9). El Panel A muestra resultados para estudiantes de 3.er y 5.º grado, el Panel B para estudiantes de 3.er grado y el Panel C para estudiantes de 5.º grado. (2) Todos los puntajes se presentan como puntajes de porcentaje de respuestas correctas y como puntajes escalados con TRI, estandarizados respecto del grupo de control en 2015. (3) Las escuelas de control no fueron evaluadas en 2013 (ver secciones 2.3 y 2.4 del manuscrito). (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.10: Efecto ITT de las intervenciones sobre el logro de los estudiantes, por grado con covariables (2014-2015)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
	2014					2015			
	Escuelas T1	Escuelas T2	Col. (2)- Col. (1)	Escuelas de control	Escuelas T1	Escuelas T2	Col. (5)- Col. (4)	Col. (6)- Col. (4)	Prueba F $\beta_1 = \beta_2$
<i>Panel A. Ambos grados</i>									
Matemática (% de aciertos)	55.779 (18.059)	54.941 (19.614)	-.51 (2.321)	51.552 (19.417)	57.69 (57.69)	55.46 (55.46)	6.395*** (2.431)	3.988 (2.799)	.585 (.446)
Matemática (puntaje TRI)	.278 (.992)	.243 (1.075)	-.016 (.131)	0 (1)	.324 (.324)	.216 (.216)	.338** (.132)	.218 (.147)	.516 (.474)
Lectura (% de aciertos)	63.181 (19.666)	61.043 (20.092)	-1.581 (2.121)	58.319 (22.371)	66.048 (66.048)	61.674 (61.674)	8.174*** (2.105)	3.748 (2.509)	2.447 (.121)
Lectura (puntaje TRI)	.312 (.969)	.212 (.966)	-.073 (.102)	0 (1)	.357 (.357)	.153 (.153)	.375*** (.101)	.171 (.111)	2.412 (.123)
N (estudiantes)	3950	3588	7538	3446	3950	3588	10984	10984	10984
<i>Panel B. 3.er grado</i>									
Matemática (% de aciertos)	59.92 (18.839)	58.481 (21.014)	-1.498 (2.768)	55.334 (21.629)	61.955 (61.955)	58.084 (58.084)	7.257*** (2.651)	2.995 (3.502)	1.283 (.26)
Matemática (puntaje TRI)	.322 (.944)	.262 (1.043)	-.065 (.136)	0 (1)	.31 (.31)	.14 (.14)	.341*** (.122)	.149 (.16)	1.238 (.268)
Lectura (% de aciertos)	61.91 (21.274)	58.74 (21.919)	-2.665 (2.579)	56.779 (24.029)	64.6 (64.6)	59.238 (59.238)	8.505*** (2.351)	2.893 (2.879)	3.245 (.075)
Lectura (puntaje TRI)	.332 (.948)	.192 (.96)	-.118 (.11)	0 (1)	.327 (.327)	.098 (.098)	.353*** (.101)	.117 (.118)	3.202 (.076)
N (estudiantes)	1951	1769	3720	1650	1951	1769	5370	5370	5370
<i>Panel C. 5.º grado</i>									
Matemática (% de aciertos)	51.484 (16.133)	51.366 (17.382)	.608 (2.391)	48.094 (16.407)	53.704 (53.704)	52.907 (52.907)	5.609** (2.514)	4.682* (2.57)	.095 (.758)
Matemática (puntaje TRI)	.233 (1.037)	.223 (1.105)	.037 (.153)	0 (1)	.336 (.336)	.29 (.29)	.338** (.155)	.284* (.155)	.085 (.771)
Lectura (% de aciertos)	64.497 (17.762)	63.358 (17.781)	-.506 (2.05)	59.734 (20.636)	67.418 (67.418)	64.032 (64.032)	7.875*** (2.297)	4.577* (2.441)	1.309 (.255)
Lectura (puntaje TRI)	.291 (.99)	.233 (.973)	-.026 (.116)	0 (1)	.385 (.385)	.207 (.207)	.395*** (.12)	.222* (.119)	1.417 (.237)
N (estudiantes)	1999	1819	3818	1796	1999	1819	5614	5614	5614

Notas: (1) La tabla muestra, para 2014 y 2015, las medias y desviaciones estándar de todas las escuelas de control (columna 4), de las escuelas de retroalimentación diagnóstica o T1 (columnas 1 y 5) y de las escuelas de fortalecimiento de capacidades o T2 (columnas 2 y 6). También estima el efecto ITT de T2 respecto de T1 en 2014 (columna 3) y de T1 y T2 respecto de las escuelas de control en 2015, con efectos fijos de aleatorización y controlando por la eficiencia interna en la línea de base (columnas 7-8). Por último, muestra el estadístico F y el valor p asociado para la hipótesis nula de que los coeficientes de T1 y T2 son iguales en 2015 (columna 9). El Panel A muestra resultados para estudiantes de 3.er y 5.º grado, el Panel B para estudiantes de 3.er grado y el Panel C para estudiantes de 5.º grado. (3) Las escuelas de control no fueron evaluadas en 2013 (ver secciones 2.3 y 2.4 del manuscrito). (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.11: Efecto ITT de las intervenciones sobre el logro de los estudiantes, por grado considerando el ausentismo estudiantil (2014-2015)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
	2014					2015			
	Escuelas T1	Escuelas T2	Col. (2)- Col. (1)	Escuelas de control	Escuelas T1	Escuelas T2	Col. (5)- Col. (4)	Col. (6)- Col. (4)	Prueba F $\beta_1 = \beta_2$
<i>Panel A. 3.er grado</i>									
Matemática (% de aciertos)	59.92 (18.839)	58.481 (21.014)	-1.421 (2.724)	55.334 (21.629)	61.955 (61.955)	58.084 (58.084)	6.236** (2.454)	2.198 (3.359)	1.284 (.26)
Matemática (puntaje TRI)	.322 (.944)	.262 (1.043)	-.062 (.134)	0 (1)	.31 (.31)	.14 (.14)	.297*** (.113)	.114 (.154)	1.23 (.27)
Lectura (% de aciertos)	61.91 (21.274)	58.74 (21.919)	-2.29 (2.439)	56.779 (24.029)	64.6 (64.6)	59.238 (59.238)	6.82*** (1.999)	2.412 (2.457)	2.648 (.107)
Lectura (puntaje TRI)	.332 (.948)	.192 (.96)	-.102 (.104)	0 (1)	.327 (.327)	.098 (.098)	.285*** (.086)	.097 (.101)	2.665 (.106)
N (estudiantes)	1951	1769	3720	1650	1951	1769	5370	5370	5370
<i>Panel B. 5.º grado</i>									
Matemática (% de aciertos)	51.484 (16.133)	51.366 (17.382)	.206 (2.55)	48.094 (16.407)	53.704 (53.704)	52.907 (52.907)	4.692** (2.263)	4.91** (2.465)	.006 (.936)
Matemática (puntaje TRI)	.233 (1.037)	.223 (1.105)	.011 (.164)	0 (1)	.336 (.336)	.29 (.29)	.277** (.136)	.298** (.149)	.017 (.896)
Lectura (% de aciertos)	64.497 (17.762)	63.358 (17.781)	-.422 (2.05)	59.734 (20.636)	67.418 (67.418)	64.032 (64.032)	7.422*** (2.184)	5.17** (2.1)	.799 (.373)
Lectura (puntaje TRI)	.291 (.99)	.233 (.973)	-.02 (.116)	0 (1)	.385 (.385)	.207 (.207)	.372*** (.114)	.251** (.102)	.9 (.345)
N (estudiantes)	1999	1819	3818	1796	1999	1819	5614	5614	5614

Notas: (1) La tabla muestra, para 2014 y 2015, las medias y desviaciones estándar de todas las escuelas de control (columna 4), de las escuelas de retroalimentación diagnóstica o T1 (columnas 1 y 5) y de las escuelas de fortalecimiento de capacidades o T2 (columnas 2 y 6). También estima el efecto ITT de T2 respecto de T1 en 2014 (columna 3) y de T1 y T2 respecto de las escuelas de control en 2015, con efectos fijos de aleatorización y controlando por el ausentismo el día de la prueba, según la ecuación 1 (columnas 7-8). Por último, muestra el estadístico F y el valor p asociado para la hipótesis nula de que los coeficientes de T1 y T2 son iguales en 2015 (columna 9). El Panel A muestra resultados para estudiantes de 3.er y 5.º grado, el Panel B para estudiantes de 3.er grado y el Panel C para estudiantes de 5.º grado. (2) Todos los puntajes se presentan como puntajes de porcentaje de respuestas correctas y como puntajes escalados con TRI, estandarizados respecto del grupo de control en 2015. (3) Las escuelas de control solo fueron evaluadas en 2015 (ver secciones 2.3 y 2.4 del manuscrito). (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.12: Correlación entre el ausentismo en 2013 y el logro en 2015, por grado

(1)	(2) Escuelas T1	(3) Escuelas T2
<i>Panel A. 3.er grado</i>		
Matemática (% de aciertos)	.014	-.141***
Matemática (puntaje TRI)	.009	-.139***
Lectura (% de aciertos)	-.077***	-.132***
Lectura (puntaje TRI)	-.08***	-.138***
<i>Panel B. 5.º grado</i>		
Matemática (% de aciertos)	-.077***	.062**
Matemática (puntaje TRI)	-.079***	.069**
Lectura (% de aciertos)	-.075***	.107***
Lectura (puntaje TRI)	-.084***	.096***

Notas: (1) La tabla muestra las correlaciones de a pares entre el ausentismo estudiantil en 2013 y el logro de los estudiantes en 2015 por grado y grupo experimental. El primero se mide a nivel de escuela y el segundo, a nivel de estudiante. (2) Las escuelas de control solo fueron evaluadas en 2015 (ver secciones 2.3 y 2.4). (3) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.13: Cotas de Lee del efecto ITT de las intervenciones sobre el logro de los estudiantes (2015)

	(1) Escuelas de control	(2) Inferior	(3) Superior	(4) Efecto de T1 IC 95%	(5) Inferior	(6) Superior	(7) Efecto de T2 IC 95%
Matemática (% de aciertos)	51.552 (19.417)	-4.006*** (.607)	17.329*** (.568)	[-5.005, 18.264]	-6.542*** (.638)	14.723*** (.607)	[-7.591, 15.722]
Matemática (puntaje TRI)	0 (1)	-.183*** (.031)	.892*** (.029)	[-.234, .94]	-.306*** (.033)	.76*** (.031)	[-.36, .812]
Lectura (% de aciertos)	58.319 (22.371)	-4.687*** (.662)	20.03*** (.693)	[-5.776, 21.17]	-8.738*** (.696)	15.147*** (.714)	[-9.882, 16.32]
Lectura (puntaje TRI)	0 (1)	-.167*** (.031)	.917*** (.029)	[-.218, .965]	-.356*** (.032)	.697*** (.03)	[-.408, .747]
N (estudiantes)	3446		7396			7034	

Notas: (1) La tabla muestra, para 2015, las medias y desviaciones estándar de todas las escuelas de control (columna 1), y las cotas de Lee (2009) de los efectos ITT sobre el logro de los estudiantes en ese año. Muestra las cotas inferiores (columnas 2 y 5) y superiores (columnas 3 y 6), con sus errores estándar analíticos asociados, y el intervalo de confianza del 95% (columnas 4 y 7). (2) Calculamos estas cotas mediante una regresión con los puntajes de las pruebas de la línea final como variable dependiente, para que el análisis de las cotas sea análogo al de los efectos ITT principales. Ajustamos las cotas usando los efectos fijos de aleatorización por tamaño de escuela. (3) Todos los puntajes se presentan como puntajes de porcentaje de respuestas correctas y como puntajes escalados con TRI, estandarizados con respecto al grupo de control en 2015. (4) Las escuelas de control solo fueron evaluadas en 2015 (ver secciones 2.3 y 2.4 del manuscrito). (5) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.14: Efecto ITT de las intervenciones sobre el logro de los estudiantes con valores q de FDR (2014-2015)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
	2014					2015			
	Escuelas T1	Escuelas T2	Col. (2)- Col. (1)	Escuelas de control	Escuelas T1	Escuelas T2	Col. (5)- Col. (4)	Col. (6)- Col. (4)	Prueba F $\beta_1 = \beta_2$
Matemática (% de aciertos)	55.779 (18.059)	54.941 (19.614)	-.635 (2.432) [.8659]	51.552 (19.417)	57.69 (19.599)	55.46 (20.761)	6.275** (2.422) [.0373]	3.939 (2.757) [.2341]	.538 (.465)
Matemática (puntaje TRI)	.278 (.992)	.243 (1.075)	-.023 (.139) [.8659]	0 (1)	.324 (1.036)	.216 (1.104)	.333** (.131) [.0373]	.216 (.145) [.2341]	.481 (.489)
Lectura (% de aciertos)	63.184 (19.665)	61.043 (20.092)	-1.436 (2.167) [.6386]	58.319 (22.371)	66.048 (21.625)	61.674 (22.921)	7.713*** (2.13) [.0043]	3.627 (2.518) [.2341]	1.981 (.162)
Lectura (puntaje TRI)	.312 (.969)	.213 (.966)	-.066 (.105) [.6386]	0 (1)	.357 (1.018)	.153 (1.035)	.356*** (.102) [.0043]	.166 (.111) [.2341]	1.987 (.162)
N (estudiantes)	3950	3588	7538	3446	3950	3588	10984	10984	10984

Notas: (1) La tabla muestra, para 2014 y 2015, las medias y desviaciones estándar de todas las escuelas de control (columna 4), de las escuelas de retroalimentación diagnóstica o T1 (columnas 1 y 5) y de las escuelas de fortalecimiento de capacidades o T2 (columnas 2 y 6). También estima el efecto ITT de T2 con respecto a T1 en 2014 (columna 3) y de T1 y T2 con respecto a las escuelas de control en 2015, usando efectos fijos de aleatorización (columnas 7-8). Por último, muestra el estadístico F y el valor p asociado para la hipótesis nula de que los coeficientes de T1 y T2 son iguales en 2015 (columna 9). (2) Todos los puntajes se presentan como puntajes de porcentaje de respuestas correctas y como puntajes escalados con TRI, estandarizados con respecto al grupo de control en 2015. (3) Las escuelas de control solo fueron evaluadas en 2015 (ver secciones 2.3 y 2.4 del manuscrito). (4) Los valores q de la tasa de falsos descubrimientos (FDR) (entre corchetes) se calcularon con el procedimiento escalonado ascendente de Benjamini-Hochberg. (5) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.15: Efecto ITT de las intervenciones sobre la eficiencia interna (2014-2017)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)	(10)	(11)	(12)
		2014			2015			2016			2017	
		Diferencia			Diferencia			Diferencia			Diferencia	
	Control	T1	T2	Control	T1	T2	Control	T1	T2	Control	T1	T2
<i>Panel A. Escuela primaria</i>												
Número de estudiantes matriculados	326.567 (272.272)	-9.443 (41.564)	20.38 (41.351)	319.481 (271.878)	-14.888 (41.103)	26.339 (40.893)	311.462 (263.714)	-13.086 (38.986)	32.386 (38.787)	306.692 (259.112)	-5.397 (37.872)	33.576 (37.679)
Porcentaje de estudiantes que aprobaron el grado	96.28 (4.31)	-.626 (1.018)	-1.69* (1.014)	97.155 (3.497)	-.167 (.842)	.556 (.838)	98.416 (2.662)	.147 (.644)	.009 (.641)	98.774 (1.904)	-.358 (.452)	-.116 (.45)
Porcentaje de estudiantes que reprobaron el grado	3.682 (4.32)	.694 (1.02)	1.718* (1.016)	2.571 (3.412)	-.067 (.824)	-.67 (.82)	1.432 (2.516)	-.188 (.606)	-.202 (.603)	1.175 (1.869)	.313 (.444)	.017 (.441)
Porcentaje de estudiantes que abandonaron la escuela	.038 (.153)	-.067* (.037)	-.028 (.036)	.274 (.929)	.234 (.22)	.115 (.219)	.152 (.75)	.041 (.18)	.193 (.18)	.051 (.214)	.045 (.051)	.099* (.05)
Porcentaje de estudiantes que repitieron el grado	2.649 (3.191)	.581 (.771)	-.076 (.767)	1.922 (2.567)	.436 (.615)	-.107 (.612)	1.453 (2.279)	-.711 (.536)	-1.09** (.533)	2.535 (3.593)	-.025 (.851)	-1.552* (.847)
N (escuelas)	44	104	104	44	104	104	44	104	104	44	104	104
<i>Panel B. 3.er grado</i>												
Número de estudiantes matriculados	47.779 (40.522)	-.946 (6.184)	4.03 (6.152)	46.058 (40.237)	-2.634 (6.278)	3.268 (6.246)	45.462 (39.21)	-1.84 (5.872)	5.741 (5.842)	46 (39.06)	0 (5.698)	6.281 (5.597)
Porcentaje de estudiantes que aprobaron el grado	96.66 (5.528)	.085 (1.291)	-1.697 (1.286)	97.233 (4.331)	1.188 (1.001)	1.231 (.996)	97.83 (4.064)	-.884 (.97)	-1.052 (.965)	97.667 (5.085)	-1.022 (1.24)	-.078 (1.218)
Porcentaje de estudiantes que reprobaron el grado	3.31 (5.53)	-.022 (1.291)	1.727 (1.286)	2.684 (4.282)	-1.306 (.99)	-1.39 (.985)	2.108 (4.071)	.671 (.976)	1.058 (.971)	2.333 (5.085)	1.022 (1.24)	.078 (1.218)
Porcentaje de estudiantes que abandonaron la escuela	.029 (.175)	-.063 (.041)	-.03 (.041)	.083 (.597)	.118 (.141)	.159 (.141)	.062 (.455)	.213** (.105)	-.007 (.105)	0 (0)	0 (0)	0 (0)
Porcentaje de estudiantes que repitieron el grado	2.809 (4.493)	-.401 (1.09)	-.354 (1.085)	2.261 (4.082)	-.562 (.985)	-.514 (.98)	1.645 (3.532)	.175 (.861)	-.561 (.846)	2.473 (4.21)	.71 (1.015)	-.216 (.998)
N (escuelas)	44	104	104	44	104	104	44	104	104	44	104	104
<i>Panel C. 5.º grado</i>												
Número de estudiantes matriculados	46.904 (39.868)	-1.726 (6.163)	3.082 (6.131)	47.048 (39.796)	-3.682 (5.843)	4.225 (5.814)	45.942 (38.984)	-.633 (6.022)	5.882 (5.992)	44.231 (39.094)	-.799 (6.045)	4.437 (6.014)
Porcentaje de estudiantes que aprobaron el grado	96.601 (5.781)	-.664 (1.4)	-.069 (1.395)	97.472 (5.141)	.734 (1.245)	.649 (1.239)	98.218 (4.022)	.755 (.969)	.874 (.964)	98.619 (2.947)	-.315 (.691)	.668 (.688)
Porcentaje de estudiantes que reprobaron el grado	3.384 (5.766)	.701 (1.397)	.102 (1.391)	2.517 (5.145)	-.705 (1.246)	-.624 (1.24)	1.65 (3.951)	-.735 (.951)	-.77 (.946)	1.305 (2.877)	.267 (.676)	-.572 (.673)
Porcentaje de estudiantes que abandonaron la escuela	.014 (.145)	-.038 (.035)	-.032 (.035)	.011 (.112)	-.029 (.027)	-.025 (.027)	.132 (.773)	-.021 (.186)	-.103 (.185)	.075 (.541)	.048 (.13)	-.096 (.129)
Porcentaje de estudiantes que repitieron el grado	2.452 (4.466)	.687 (1.074)	-.853 (1.069)	1.91 (4.427)	-.616 (1.063)	-1.046 (1.058)	1.556 (4.362)	-.104 (1.065)	.025 (1.046)	3.402 (6.452)	.285 (1.535)	-2.662* (1.527)
N (escuelas)	44	104	104	44	104	104	44	104	104	44	104	104

Notas: (1) La tabla muestra, para cada año del período 2014-2017, las medias y desviaciones estándar de todas las escuelas de control (columnas 1, 4, 7 y 10) y el efecto ITT de la retroalimentación diagnóstica o T1 (columnas 2, 5, 8, 11) y del fortalecimiento de capacidades o T2 (columnas 3, 6, 9, 12), con respecto a las escuelas de control, usando efectos fijos de aleatorización. El Panel A muestra los resultados para todos los estudiantes de primaria, el Panel B para los de 3.er grado y el Panel C para los de 5.º grado. (2) Las tasas de abandono deben interpretarse como una estimación de cota superior, ya que en realidad se refieren al porcentaje de estudiantes que dejan su escuela sin solicitar el pase a otra escuela. (3) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.16: Efecto ITT de las intervenciones sobre la gestión escolar reportada por los directores con valores q de FDR (2015)

	(1) Escuelas de control	(2) Escuelas T1	(3) Escuelas T2	(4) Col. (2)- Col. (1)	(5) Col. (3)- Col. (1)	(6) Prueba F $\beta_1 = \beta_2$
Mi escuela fijó metas según los resultados de las evaluaciones	.483 (.509)	.964 (.189)	.963 (.192)	.475*** (.103) [.0001]	.484*** (.103) [.0001]	.021 (.885)
Hice cambios al currículo según los resultados de las evaluaciones	.7 (.466)	1 (0)	.931 (.258)	.295*** (.086) [.0026]	.233** (.099) [.0321]	1.665 (.2)
Me evalúan en parte según los resultados de las evaluaciones	.333 (.479)	.615 (.496)	.704 (.465)	.284* (.135) [.0532]	.37** (.127) [.0106]	.405 (.526)
Mis docentes son evaluados en parte según los resultados de las evaluaciones	.452 (.506)	.69 (.471)	.654 (.485)	.233* (.128) [.0912]	.208 (.133) [.1418]	.035 (.853)
Asigno estudiantes a secciones según los resultados de las evaluaciones	.107 (.315)	.231 (.43)	.107 (.315)	.11 (.099) [.2912]	0 (.086) [1]	1.226 (.271)
Informé a los padres sobre los resultados de sus hijos	.452 (.506)	.857 (.356)	.931 (.258)	.423*** (.11) [.0008]	.485*** (.104) [.0001]	.542 (.464)
Hice públicos los resultados de las evaluaciones de mi escuela	.207 (.412)	.519 (.509)	.519 (.509)	.318** (.126) [.0273]	.309** (.126) [.0288]	.004 (.952)
N (escuelas)	42	29	30	101	101	101

Notas: (1) La tabla muestra, para el ciclo lectivo 2015, las medias y desviaciones estándar del grupo de control (columna 1), del grupo de retroalimentación diagnóstica o T1 (columna 2) y del grupo de fortalecimiento de capacidades o T2 (columna 3). También estima el efecto ITT de T1 y T2 con respecto a las escuelas de control, usando efectos fijos de aleatorización (columnas 4-5). Por último, muestra el estadístico F y el valor p asociado para la hipótesis nula de que los coeficientes de T1 y T2 son iguales en 2015 (columna 6). (2) Se pidió a los directores que indicaran si sus escuelas usaban los resultados de las evaluaciones de estudiantes para los fines enumerados arriba. Las cifras indican la proporción de directores que reportaron que sus escuelas usaban las evaluaciones para cada fin, con referencia al ciclo lectivo de la recolección de datos. (3) Los valores q de la tasa de falsos descubrimientos (FDR) (entre corchetes) se calcularon con el procedimiento escalonado ascendente de Benjamini-Hochberg. (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.17: Cotas de Lee del efecto ITT de las intervenciones sobre la gestión escolar reportada por los directores (2015)

	(1) Escuelas de control	(2) Inferior	(3) Efecto de T1 Superior	(4) IC 95%	(5) Inferior	(6) Efecto de T2 Superior	(7) IC 95%
Mi escuela fijó metas según los resultados de las evaluaciones	.483 (.509)	.444*** (.121)	.517*** (.094)	[.233, .682]	.467*** (.108)	.517*** (.094)	[.276, .685]
Hice cambios al currículo según los resultados de las evaluaciones	.7 (.466)	.3*** (.085)	.3*** (.085)	[.133, .467]	.208* (.108)	.3*** (.085)	[.025, .445]
Me evalúan en parte según los resultados de las evaluaciones	.333 (.479)	.229 (.168)	.417** (.177)	[-.053, .713]	.292* (.148)	.556*** (.174)	[.047, .844]
Mis docentes son evaluados en parte según los resultados de las evaluaciones	.452 (.506)	.109 (.163)	.464*** (.175)	[-.16, .752]	.14 (.154)	.305* (.157)	[-.118, .568]
Asigno estudiantes a secciones según los resultados de las evaluaciones	.107 (.315)	-.048 (.137)	.161 (.142)	[-.274, .396]	-.107* (.06)	.046 (.109)	[-.206, .226]
Informé a los padres sobre los resultados de sus hijos	.452 (.506)	.375*** (.131)	.548*** (.091)	[.157, .699]	.459*** (.112)	.527*** (.113)	[.264, .724]
Hice públicos los resultados de las evaluaciones de mi escuela	.207 (.412)	.193 (.17)	.522*** (.186)	[-.088, .829]	.166 (.165)	.469*** (.17)	[-.107, .75]
N (escuelas)	42		71			72	

Notas: (1) La tabla muestra, para 2015, las medias y desviaciones estándar de todas las escuelas de control (columna 1), y las cotas de Lee (2009) de los efectos ITT sobre el logro de los estudiantes en ese año. Muestra las cotas inferiores (columnas 2 y 5) y superiores (columnas 3 y 6), con sus errores estándar analíticos asociados, y el intervalo de confianza del 95% (columnas 4 y 7). (2) Calculamos estas cotas mediante una regresión con los puntajes de las pruebas de la línea final como variable dependiente, para que el análisis de las cotas sea análogo al de los efectos ITT principales. Ajustamos las cotas usando los efectos fijos de aleatorización por tamaño de escuela. (3) Se pidió a los directores que indicaran si sus escuelas usaban los resultados de las evaluaciones de estudiantes para los fines enumerados arriba. Las cifras indican la proporción de directores que reportaron que sus escuelas usaban las evaluaciones para cada fin, con referencia al ciclo lectivo de la recolección de datos. (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.18: Efecto ITT de las intervenciones sobre el uso del tiempo de los docentes reportado por los estudiantes con valores q de FDR (2015)

	(1) Escuelas de control	(2) Escuelas T1	(3) Escuelas T2	(4) Col. (2)- Col. (1)	(5) Col. (3)- Col. (1)	(6) Prueba F $\beta_1 = \beta_2$
Mi docente faltó a la escuela	.578 (.494)	.554 (.497)	.6 (.49)	-.025 (.031) [.699]	.026 (.03) [.699]	2.206 (.141)
Mi docente llegó tarde a la escuela	.394 (.489)	.364 (.481)	.413 (.492)	-.032 (.033) [.699]	.021 (.04) [.865]	1.411 (.238)
Mi docente empezó la clase tarde	.443 (.497)	.394 (.489)	.446 (.497)	-.05 (.029) [.3131]	.005 (.036) [.8817]	1.763 (.187)
Mi docente terminó la clase temprano	.5 (.5)	.441 (.497)	.492 (.5)	-.06 (.03) [.3131]	-.006 (.035) [.8817]	1.699 (.195)
Mi docente se retiró temprano de la escuela	.449 (.497)	.389 (.488)	.433 (.496)	-.06 (.035) [.3131]	-.014 (.039) [.8817]	.982 (.324)
N (estudiantes)	4034	3014	2854	9902	9902	9902

Notas: (1) La tabla muestra, para el ciclo lectivo 2015, las medias y desviaciones estándar del grupo de control (columna 1), del grupo de retroalimentación diagnóstica o T1 (columna 2) y del grupo de fortalecimiento de capacidades o T2 (columna 3). También estima el efecto ITT de T1 y T2 con respecto a las escuelas de control, usando efectos fijos de aleatorización (columnas 4-5). (2) Se pidió a los estudiantes que indicaran con qué frecuencia ellos o sus docentes realizaron las actividades anteriores. Las cifras indican la proporción de estudiantes que reportaron que estas actividades ocurrieron dos o más veces por semana, con referencia a las dos semanas previas a la ronda de recolección de datos. (3) Los valores q de la tasa de falsos descubrimientos (FDR) (entre corchetes) se calcularon con el procedimiento escalonado ascendente de Benjamini-Hochberg. (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.19: Efecto ITT de las intervenciones sobre las actividades de los docentes reportadas por los estudiantes con valores q de FDR (2015)

	(1) Escuelas de control	(2) Escuelas T1	(3) Escuelas T2	(4) Col. (2)- Col. (1)	(5) Col. (3)- Col. (1)	(6) Prueba F $\beta_1 = \beta_2$
Usé un libro de texto	.814 (.389)	.872 (.334)	.85 (.357)	.058*** (.016) [.0044]	.036* (.016) [.0612]	1.869 (.175)
Mi docente me dio tarea	.936 (.245)	.958 (.2)	.949 (.22)	.022** (.008) [.0308]	.014 (.009) [.2196]	.888 (.348)
Copie del pizarrón	.912 (.283)	.938 (.241)	.913 (.281)	.026* (.012) [.0612]	.001 (.01) [.9491]	4.186 (.043)
Trabajé en grupo	.916 (.278)	.936 (.245)	.921 (.27)	.021 (.014) [.2196]	.004 (.013) [.8498]	1.506 (.223)
Mi docente explicó un tema	.96 (.196)	.977 (.149)	.969 (.174)	.018** (.006) [.0185]	.009 (.006) [.2334]	1.992 (.161)
Mi docente me tomó una prueba de práctica	.892 (.311)	.911 (.285)	.9 (.299)	.02 (.014) [.2334]	.008 (.011) [.6202]	.758 (.386)
Mi docente corrigió mi tarea	.958 (.2)	.975 (.156)	.956 (.206)	.018** (.006) [.0185]	-.004 (.007) [.6496]	9.084 (.003)
N (estudiantes)	4034	3014	2854	9902	9902	9902

Notas: (1) La tabla muestra, para el ciclo lectivo 2015, las medias y desviaciones estándar del grupo de control (columna 1), del grupo de retroalimentación diagnóstica o T1 (columna 2) y del grupo de fortalecimiento de capacidades o T2 (columna 3). También estima el efecto ITT de T1 y T2 con respecto a las escuelas de control, usando efectos fijos de aleatorización (columnas 4-5). (2) Se pidió a los estudiantes que indicaran con qué frecuencia ellos o sus docentes realizaron las actividades anteriores. Las cifras indican la proporción de estudiantes que reportaron que estas actividades ocurrieron dos o más veces por semana, con referencia a las dos semanas previas a la ronda de recolección de datos.

(3) Los valores q de la tasa de falsos descubrimientos (FDR) (entre corchetes) se calcularon con el procedimiento escalonado ascendente de Benjamini-Hochberg. (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.20: Efecto ITT de las intervenciones sobre la efectividad de los docentes reportada por los estudiantes con valores q de FDR (2015)

	(1) Escuelas de control	(2) Escuelas T1	(3) Escuelas T2	(4) Col. (2)- Col. (1)	(5) Col. (3)- Col. (1)	(6) Prueba F $\beta_1 = \beta_2$
Cuidado (puntaje estandarizado)	0 (1)	.186 (.854)	.003 (.967)	.191*** (.05) [.0019]	-.006 (.052) [.9022]	17.419 (0)
Control (puntaje estandarizado)	0 (1)	.128 (.9)	.029 (.949)	.133** (.05) [.0213]	.02 (.053) [.9022]	4.108 (.045)
Claridad (puntaje estandarizado)	0 (1)	.163 (.865)	.053 (.951)	.168** (.056) [.0111]	.048 (.053) [.645]	4.386 (.039)
Desafío (puntaje estandarizado)	0 (1)	.171 (.887)	.017 (1.01)	.176** (.06) [.0111]	.01 (.057) [.9022]	7.21 (.008)
Cautivación (puntaje estandarizado)	0 (1)	.152 (.822)	.022 (.943)	.157*** (.042) [.0019]	.017 (.049) [.9022]	8.523 (.004)
Consolidación (puntaje estandarizado)	0 (1)	.168 (.881)	-.004 (.983)	.177*** (.054) [.0069]	-.017 (.054) [.9022]	11.054 (.001)
N (estudiantes)	4034	3014	2854	9902	9902	9902

Notas: (1) La tabla muestra, para el ciclo lectivo 2015, las medias y desviaciones estándar del grupo de control (columna 1), del grupo de retroalimentación diagnóstica o T1 (columna 2) y del grupo de fortalecimiento de capacidades o T2 (columna 3). También estima el efecto ITT de T1 y T2 con respecto a las escuelas de control, usando efectos fijos de aleatorización (columnas 4-5). (2) Se pidió a los estudiantes que indicaran con qué frecuencia su docente mostraba ciertas conductas (p. ej., tratarlos con amabilidad cuando hacen preguntas) en una escala tipo Likert, de 1 (nunca) a 5 (siempre). Luego, sus respuestas se usaron para calcular un puntaje para cada docente en siete dominios: (a) demostrar interés por sus estudiantes; (b) manejar el aula; (c) aclarar conceptos y tareas difíciles; (d) desafiar a los estudiantes a dar lo mejor de sí; (e) captar la atención de los estudiantes con sus clases; (f) involucrar a los estudiantes en discusiones; y (g) resumir el material aprendido al final de cada clase. Los puntajes de los estudiantes se estandarizaron con respecto al grupo de control en 2015. Los puntajes de cada dominio se expresan en desviaciones estándar a nivel de estudiante. (3) Los valores q de la tasa de falsos descubrimientos (FDR) (entre corchetes) se calcularon con el procedimiento escalonado ascendente de Benjamini-Hochberg. (4) * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Apéndice B Información adicional sobre los instrumentos

B.1 Evaluaciones de estudiantes

B.1.1 Diseño

Las evaluaciones de estudiantes que usamos en este estudio fueron desarrolladas por un centro de estudios nacional (el *Centro de Estudios en Políticas Públicas*). El centro de estudios creó sus propios ítems y recurrió a ítems liberados de la evaluación nacional de estudiantes (denominada *Operativo Nacional de Evaluación* en el momento del estudio) (véase, por ejemplo, DiNIECE 2009, 2012).

Los contenidos y las habilidades que miden las evaluaciones de este estudio son similares a los de las evaluaciones nacionales e internacionales. Como explicamos en la sección 3, nuestras evaluaciones se basaron en estándares nacionales y provinciales (los *Contenidos Básicos Comunes*, los *Núcleos de Aprendizaje Prioritarios* y el *Diseño Curricular de La Rioja*). Además, la distribución de los ítems entre dominios de contenido y dominios cognitivos en nuestras evaluaciones es coherente con la de la evaluación nacional actual (*Aprender*) y con la de evaluaciones internacionales de estudiantes de primaria, como el Estudio de las Tendencias en Matemáticas y Ciencias (TIMSS) y el Estudio Internacional del Progreso en Comprensión Lectora (PIRLS) (ver Tabla B.1).

B.1.2 Escalamiento y equiparación


El centro de estudios que diseñó las evaluaciones calificó todos los ítems de forma dicotómica. Usamos un modelo logístico de dos parámetros (2PL) de la teoría de respuesta al ítem (TRI) para escalar y equiparar los resultados (Harris 2005).⁴⁸ Este modelo nos permite tener en cuenta las diferencias entre ítems (en concreto, las diferencias en su dificultad y en su capacidad para distinguir entre estudiantes de habilidad similar). También nos permite aprovechar los ítems comunes entre rondas de recolección de datos (dentro de cada asignatura y grado) para ubicar en una misma escala los resultados de las evaluaciones de los tres años del estudio (2013 a 2015). Estandarizamos todos los puntajes escalados con TRI para que tuvieran una media de 0 y una desviación estándar de 1 respecto del grupo de control en 2015.

⁴⁸Usamos el módulo de TRI de Stata 15 (véase Stata 2017). Elegimos un modelo 2PL en lugar de uno 3PL en parte por los requisitos muestrales de los modelos 3PL que se discuten en Yen and Fitzpatrick (2006).

B.1.3 Distribuciones de los puntajes de porcentaje de respuestas correctas y de los puntajes escalados con TRI


Los procesos de diseño, escalamiento y equiparación descritos arriba produjeron distribuciones con buen comportamiento en todos los grados, asignaturas y años del estudio, con poca evidencia de efectos “piso” (es decir, una alta concentración de estudiantes sin respuestas correctas) o efectos “techo” (es decir, una alta concentración de estudiantes con puntajes perfectos) (Figuras B.1 y B.2).

Figura B.1: Distribución de los puntajes de porcentaje de respuestas correctas en las evaluaciones de estudiantes (2013-2015)



Notas: (1) Esta figura muestra la distribución de los puntajes de porcentaje de respuestas correctas en las evaluaciones de estudiantes de esta evaluación por asignatura y grado. (2) Cada gráfico incluye a todos los estudiantes evaluados en un año determinado (es decir, los estudiantes de los grupos de retroalimentación diagnóstica o T1 y de fortalecimiento de capacidades o T2 en 2013 y 2014, y los estudiantes de esos dos grupos y del grupo de control en 2015) (ver Tabla 1).

Figura B.2: Distribución de los puntajes escalados con TRI en las evaluaciones de estudiantes (2013-2015)



Notas: (1) Esta figura muestra la distribución de los puntajes escalados con TRI en las evaluaciones de estudiantes de esta evaluación por asignatura y grado. (2) Cada gráfico incluye a todos los estudiantes evaluados en un año determinado (es decir, los estudiantes de los grupos de retroalimentación diagnóstica o T1 y de fortalecimiento de capacidades o T2 en 2013 y 2014, y los estudiantes de esos dos grupos y del grupo de control en 2015) (ver Tabla 1).

Tabla B.1: Comparación de la distribución de los ítems entre dominios de contenido y cognitivos en las evaluaciones usadas en este estudio con la de las evaluaciones nacionales e internacionales

	(1)	(2)	(3)	(4)	(5)	(6)	(7)
	Evaluación usada en este estudio (La Rioja)		Evaluación nacional (Aprender)		Evaluaciones internacionales (TIMSS) (PIRLS)		
	3.er grado	4.º grado	5.º grado	3.er grado	6.º grado	4.º grado	4.º grado
<i>Panel A. Matemática</i>							
Dominios de contenido							
Números	60%	51%	43%	76%	50%	50%	
Geometría	17%	23%	20%	24%	36%	30%	
Medición	23%	17%	26%				
Probabilidad y estadística		9%	11%		14%	20%	
Dominios cognitivos							
Conocer	37%	43%	34%	26%	26%	40%	
Comunicar	14%	14%	14%	19%	18%	40%	
Algoritmos	26%	14%	17%	11%	7%		
Razonar	23%	29%	34%	43%	49%	20%	
<i>Panel B. Lectura</i>							
Dominios de contenido							
Textos narrativos	41%	41%	41%				
Textos informativos	41%	41%	41%				
Textos breves	18%	18%	18%				
Dominios cognitivos							
Localizar información explícita	29%	29%	29%	38%	23%		20%
Realizar inferencias directas	29%	29%	29%				30%
Interpretar e integrar información	26%	26%	26%	49%	39%		30%
Evaluar y criticar elementos textuales	17%	17%	17%	13%	38%		20%

Notas: (1) Esta tabla compara el porcentaje de ítems asignados a cada dominio de contenido y dominio cognitivo en la evaluación usada en este estudio (columnas 1-2) con el de la evaluación nacional *Aprender*, que evalúa 3.er y 6.º grado (columnas 3-4), y el de las evaluaciones internacionales Estudio de las Tendencias en Matemáticas y Ciencias (TIMSS) y Estudio Internacional del Progreso en Comprensión Lectora (PIRLS), que evalúan 4.º grado (columnas 5-6). (2) Las cifras de la evaluación nacional se obtuvieron de SEE-MEDN (2018). Las cifras de las evaluaciones internacionales se obtuvieron de IEA (2015, 2017). (3) La distribución de los ítems entre distintos tipos de textos no se informa para las evaluaciones nacionales e internacionales. (4) En algunos casos, los términos usados para describir los dominios de contenido y cognitivos varían entre evaluaciones (por ejemplo, “probabilidad y estadística” se clasifica como “datos” en TIMSS). (5) Las cifras que abarcan varias filas se informan como una sola categoría para esa evaluación (por ejemplo, “comunicar” y “algoritmos” se clasifican como “analizar” en TIMSS).