

¿Ojos que no ven, corazón que no siente? La brecha entre el desempeño de los estudiantes en las pruebas y las estimaciones de los docentes en la India y Bangladesh*

Sharnic Djaker[†]

Alejandro J. Ganimian[‡]

Shwetlena Sabarwal[§]

Resumen

Este es uno de los primeros estudios sobre el desajuste entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes sobre esos puntajes en los países de ingresos bajos y medios. Estudios previos en países de ingresos altos han encontrado correlaciones fuertes entre estas métricas. Aprovechamos datos sobre los puntajes reales y estimados en matemáticas y lengua de la India y Bangladesh y encontramos que los docentes estiman erróneamente los puntajes de sus estudiantes y que sus estimaciones revelan concepciones erróneas sobre los estudiantes que más necesitan apoyo y sobre la variabilidad dentro de su aula. Este patrón se explica en parte por la propensión de los docentes a sobreestimar los puntajes de los estudiantes de bajo desempeño y a sobrevalorar la importancia de la inteligencia. Los docentes parecen no ser conscientes de sus errores: expresan seguridad en sus estimaciones y sorpresa ante el desempeño de sus estudiantes una vez que este se les revela.

Códigos JEL: C93, I21, I22, I25

Palabras clave: estimaciones de los docentes, enseñanza diferenciada, India, Bangladesh

* Agradecemos a Noam Angrist y T. M. Asaduzzaman por sus aportes al diseño y el análisis de los resultados de Bangladesh; a Larry Aber, Minahil Asim, Felipe Barrera-Orsorio, Rezarta Bilali, Andy de Barros, Emmerich Davies, Anne Fitzpatrick, Erin Godfrey, Diane Hughes, Isaac Mbiti, Abhiroop Mukhopadhyay, Mauricio Romero, Hiro Yoshikawa y a los participantes de seminarios por sus comentarios; y a Rashmi Menon por su excelente asistencia de investigación en el estudio original de la India. El estudio en la India fue financiado por el Post-Primary Education fund del Abdul Latif Jameel Poverty Action Lab. El estudio en Bangladesh fue financiado por la Foreign, Commonwealth & Development Office del Gobierno del Reino Unido, el Banco Mundial y la China-World Bank Group Partnership Facility. Los estudios fueron revisados y aprobados por los comités de ética institucionales (Institutional Review Boards) del Institute for Financial Management and Research (en el caso de la India) y del Institute of Health Economics de la University of Dhaka (en el de Bangladesh).

^{††} Estudiante de doctorado en psicología e intervención social, Steinhardt School of Culture, Education, and Human Development, New York University. Correo electrónico: sharnic.djaker@nyu.edu.

^{‡‡} Profesor asistente de psicología aplicada y economía, Steinhardt School of Culture, Education, and Human Development, New York University. Correo electrónico: alejandroganimian@nyu.edu.

^{§§} Economista sénior, Banco Mundial. Correo electrónico: ssabarwal@worldbank.org.

La evidencia existente de los países de ingresos bajos y medios (PIBM) sugiere que los docentes rara vez atienden las necesidades de los estudiantes con distintos niveles de desempeño, y que esta falta de diferenciación perjudica de manera desproporcionada a los estudiantes de bajo desempeño, que son los más desfasados respecto de las expectativas curriculares y, por lo tanto, respecto de los materiales y la enseñanza basados en el grado. Los estudios transversales han encontrado que muchos niños no pueden responder preguntas básicas de aritmética o lectura al final de la educación primaria, lo que sugiere que la escolarización es insuficiente para que adquieran habilidades fundamentales (ASER, 2023; Banerjee et al., 2023; World Bank, 2018). Los estudios longitudinales han mostrado que el aprendizaje mejora mucho más lentamente de lo esperado, lo que sugiere que las brechas tempranas de conocimiento rara vez se subsanan a medida que los niños pasan de la educación primaria a la secundaria (Andrabi et al., 2007; Muralidharan et al., 2019; Singh, 2019). Las observaciones de aula han revelado que los docentes tienden a usar enfoques de enseñanza dirigidos a toda la clase (en lugar de la enseñanza en grupos pequeños o individualizada) y los mismos materiales para todos los estudiantes (Bhattacharjea et al., 2011; Sankar & Linden, 2014).

Las explicaciones predominantes de por qué los docentes no diferencian la enseñanza se centran en los incentivos que enfrentan. En muchos PIBM, los currículos nacionales se desarrollaron originalmente para preparar a las élites para la educación postsecundaria y los empleos públicos, y en consecuencia son excesivamente ambiciosos, lo que alienta a los docentes a privilegiar la amplitud sobre la profundidad y les deja poco tiempo para verificar la comprensión de los estudiantes (Pritchett & Beatty, 2015). Los padres de bajos ingresos a menudo subestiman los retornos de cada año adicional de escolaridad y retiran a sus hijos de la escuela antes de que se gradúen, lo que lleva a los docentes a anticipar este patrón y a invertir poco en la nivelación (Banerjee & Duflo, 2011; Sabarwal et al., 2022). Los funcionarios, los directores de escuela y los

padres otorgan demasiada importancia al desempeño de los estudiantes en los exámenes de alto impacto durante la educación primaria y secundaria, lo que alienta a los docentes a concentrarse en maximizar las tasas de aprobación y, por lo tanto, en los estudiantes con más probabilidades de rendir y aprobar estas pruebas, en detrimento de sus compañeros (Duflo et al., 2011).

En este artículo, destacamos otro factor que puede contribuir a este patrón: la mayoría de los docentes en los PIBM no tienen una comprensión precisa del desempeño de sus estudiantes.

Aprovechamos dos bases de datos sobre el desempeño de los estudiantes (es decir, sus puntajes en pruebas estandarizadas de matemáticas y lengua) y las estimaciones de los docentes sobre su desempeño (es decir, los puntajes que los docentes esperaban que obtuvieran los estudiantes) de escuelas primarias y de secundaria básica (grados 5 y 6) en una ciudad de la India y tres divisiones de Bangladesh para documentar la magnitud de este error de estimación y considerar qué factores podrían explicarlo.

Presentamos seis conjuntos principales de resultados. Primero, los docentes estiman erróneamente los puntajes de sus estudiantes en las pruebas. Tienden a sobreestimar el desempeño en matemáticas y a subestimarlos en lengua. Si calculamos la diferencia entre el puntaje de cada estudiante en la prueba y la estimación de su docente sobre ese puntaje, el 84% de esas diferencias en la India y el 60% de las de Bangladesh son positivas en matemáticas (lo que indica que las estimaciones de los docentes están por encima de los puntajes de los estudiantes) y el 66% de las diferencias en Bangladesh son negativas en lengua (lo que refleja estimaciones por debajo de los puntajes). La magnitud de estos errores es grande en términos absolutos (la diferencia media entre los porcentajes de respuestas correctas reales y estimados va de 7 a 24 puntos porcentuales [p.p.], según el país y la materia) y en términos relativos (la diferencia media equivale a entre el 151% y el 218% de la desviación estándar [DE] dentro del aula en los puntajes de las pruebas).

Segundo, las estimaciones de los docentes revelan concepciones erróneas subyacentes sobre qué estudiantes necesitan más apoyo y cuánto varía el desempeño de los estudiantes de una misma aula. Si ordenamos a los estudiantes dentro de una clase primero según sus puntajes en las pruebas y luego según las estimaciones de sus docentes sobre esos puntajes, la correlación entre estos ordenamientos va de 0.07 a 0.35 según el país y la materia, lo que implica que solo entre el 1 y el 12% de la variación en las posiciones reales de los estudiantes se explica por las posiciones estimadas por los docentes. Si comparamos las DE dentro del aula de los puntajes de los estudiantes con las DE dentro del aula implícitas en los puntajes estimados por los docentes, más de la mitad de los docentes en la India y tres cuartas partes de los de Bangladesh subestiman la variabilidad en ambas materias.

Tercero, los docentes cometen errores distintos a lo largo de la distribución del desempeño dentro del aula. Son particularmente propensos a sobreestimar los resultados de los estudiantes de bajo desempeño. En la India, los docentes sobreestiman los puntajes de los estudiantes de todos los terciles en matemáticas, pero lo hacen por un margen mayor en el tercil inferior (30.3 p.p.) que en el tercil superior (15.9 p.p.) En Bangladesh, los docentes sobreestiman los puntajes del tercil inferior (por 18.6 p.p. en matemáticas y 5.02 p.p. en lengua) y los subestiman en el tercil superior (por 6.05 p.p. en matemáticas y 17.9 p.p. en lengua). En Bangladesh, observamos un patrón similar si agrupamos a los estudiantes según la distribución nacional del desempeño.

Cuarto, los patrones anteriores se explican en gran medida porque los docentes sobrevaloran la importancia de la inteligencia de los estudiantes para su desempeño. En la India, donde observamos el desempeño de los estudiantes en una evaluación de “inteligencia fluida” (es decir, razonamiento abstracto no verbal), la diferencia en los puntajes de matemáticas entre los estudiantes de los terciles inferior y superior es mucho menor que la estimada por los docentes. De hecho, la inteligencia predice mejor los puntajes estimados por los docentes que los puntajes reales de los

estudiantes. Otras características de los estudiantes (p. ej., ser mujer, de bajos ingresos o de una casta o tribu registrada) desempeñan un papel comparativamente menor para explicar los errores de estimación de los docentes. Las métricas que los sistemas educativos usan para determinar el salario docente (p. ej., tener una maestría, haber completado la formación inicial o tener más años de experiencia) explican poco la variabilidad en la precisión de las estimaciones.

Quinto, los errores de estimación no son atribuibles a factores de confusión. En Bangladesh, donde validamos los patrones que encontramos inicialmente en la India, podemos descartar varias amenazas potenciales, como que los docentes se centren en habilidades no evaluadas en sus estimaciones (la mayoría de los docentes coincide en que las pruebas miden lo que enseñan), que no reconozcan a sus estudiantes (la mayoría de los docentes puede verificar los nombres de sus estudiantes), que no sepan cómo estimar los puntajes de las pruebas (la mayoría de los docentes también subestima el porcentaje de estudiantes de bajo desempeño en su clase) o que no puedan agregar sus juicios en puntajes totales (las estimaciones de los docentes no son más precisas para temas o ítems específicos de las pruebas).

Por último, los docentes no son conscientes, en gran medida, de sus evaluaciones incorrectas de las habilidades de los estudiantes. La gran mayoría de los docentes de Bangladesh expresa altos niveles de seguridad en sus estimaciones, y la mayoría admite sentirse sorprendida al conocer cómo se ubican sus estudiantes en la distribución nacional. Las estimaciones de los docentes con el mayor nivel de seguridad son las que mejor predicen los puntajes reales, pero incluso entre estos docentes las estimaciones son bastante imprecisas.

Hacemos cuatro contribuciones principales. Primero, ampliamos el conocimiento global sobre la importante cuestión de si los docentes tienen creencias precisas sobre las habilidades de sus estudiantes. Existe una amplia literatura en psicología educativa sobre esta cuestión, pero se basa

casi por completo en estudios de países de ingresos altos (PIA),¹ donde la correlación entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes es fuerte, y va de 0.62 (Südkamp et al., 2012) a 0.65 (Hoge & Coladarci, 1989; Kaufmann, 2020).² Estamos entre los primeros en documentar que estas correlaciones son mucho más débiles en los PIBM, en examinar la importancia de predictores relevantes a nivel local (p. ej., la casta/tribu de los estudiantes) y en destacar diferencias en los patrones entre contextos (p. ej., en los PIA, la inteligencia fluida de los estudiantes predice sus puntajes en las pruebas con más fuerza que las estimaciones de los docentes; en los PIBM, encontramos el patrón opuesto).³

Segundo, contribuimos a los debates en curso en la economía del desarrollo sobre la efectividad de la enseñanza diferenciada (también conocida como “enseñanza al nivel adecuado”).

¹ Según una revisión reciente de esta literatura, el 70% de los estudios se realizaron en los Estados Unidos, el 16% en Europa, el 4% en Canadá, el 6% en Australia y solo el 4% en otros países (Südkamp et al., 2012).

² Urhahne and Wijnia (2021) actualizaron recientemente estas revisiones, pero no reportaron correlaciones. En cambio, reportaron una diferencia media cercana a cero entre los puntajes de los estudiantes y las estimaciones de los docentes, lo cual es coherente con correlaciones altas.

³ Wadmare et al. (2022) compararon el desempeño de los estudiantes con las estimaciones de los docentes usando datos de la India y encontraron que el 40% de los docentes percibía erróneamente que sus estudiantes de bajo desempeño habían alcanzado la alfabetización básica. Sin embargo, su muestra solo incluyó a estudiantes de bajo desempeño, lo que les impide evaluar si las estimaciones son *diferencialmente* imprecisas para este grupo y, por lo tanto, identificar posibles implicaciones sobre cómo los docentes distribuyen su atención entre grupos. Además, su prueba solo evaluó habilidades básicas (p. ej., en matemáticas, solo reconocimiento de números, resta y división), que subestiman la medida en que los niños se rezagan respecto de las expectativas curriculares (de Barros & Ganimian, 2023) y, en consecuencia, pueden subestimar la medida en que los docentes realmente son conscientes de las brechas en los conocimientos y habilidades de los estudiantes. Por último, su prueba solo clasificó a los estudiantes en cinco niveles de desempeño (en lugar de producir un puntaje) y, por lo tanto, solo puede indicar un nivel relativamente grueso de correspondencia entre las habilidades de los estudiantes y las estimaciones de los docentes sobre esas habilidades.

Durante la última década, varias evaluaciones aleatorizadas han encontrado que las intervenciones que alientan a los docentes a aplicar pruebas diagnósticas, agrupar a los estudiantes según su desempeño y asignar actividades distintas a cada grupo mejoran los puntajes en las pruebas en los PIBM (Banerjee et al., 2017; Banerjee et al., 2010; Banerjee et al., 2011; Banerjee et al., 2007; Duflo et al., 2020), pero la contribución relativa de cada uno de sus componentes sigue sin explorarse. Nuestro estudio ofrece evidencia indicativa de que uno de los mecanismos por los que funcionan estas intervenciones es la actualización de las creencias previas de los docentes sobre el desempeño de sus estudiantes. Creemos que esta hipótesis es consistente con la evidencia prometedora sobre las intervenciones de evaluación formativa en estos contextos (de Hoyos et al., 2023; de Hoyos et al., 2021; de Hoyos et al., 2017).

Tercero, contribuimos a la creciente evidencia en educación internacional sobre la capacidad docente en los PIBM. Los primeros estudios de esta línea de investigación documentaron bajos niveles de esfuerzo docente en estos contextos, medido a través de las ausencias (Bruns et al., 2011; Chaudhury et al., 2006; Muralidharan et al., 2017). Una ola posterior de estudios destacó los bajos niveles de tiempo de clase dedicado a actividades de enseñanza (Bruns & Luque, 2014; Stallings et al., 2014). Luego, varios estudios llamaron la atención sobre las brechas en el dominio de la materia y en la pericia pedagógica de los docentes (Bold et al., 2017; Metzler & Woessmann, 2012; Santibañez, 2006). Nos basamos en estudios recientes sobre las creencias de los docentes (Sabarwal et al., 2022), que encuentran que muchos docentes no creen que sea su trabajo subsanar el aprendizaje de grados anteriores, para destacar la importancia de que los docentes comprendan las habilidades de los estudiantes ante el desafío de vanguardia de atender a grupos de estudiantes cada vez más numerosos y heterogéneos, cuya magnitud ha sido documentada en varios estudios recientes en los PIBM (Ganimian & Djaker, 2022). Aunque nuestro estudio no está diseñado para estimar el efecto causal de las estimaciones de los docentes sobre su esfuerzo y, posteriormente, sobre el

desempeño de los estudiantes, identificamos este como un mecanismo potencial que debe examinarse.

Por último, nuestros resultados dialogan con la literatura sobre la discriminación de los docentes contra los estudiantes en los PIBM. Varios estudios han documentado la prevalencia de creencias y conductas discriminatorias mediante métodos novedosos (Farfan Bertran et al., 2021; Hanna & Linden, 2012). Aportamos algunos matices a esta discusión, al comparar el papel crucial que algunos atributos desempeñan en la formación de las estimaciones de los docentes (p. ej., la inteligencia fluida de los estudiantes) con la influencia relativamente menos central de los factores que se han destacado previamente (p. ej., el sexo, los ingresos y la casta/tribu de los estudiantes).

El resto del artículo se estructura de la siguiente manera. La sección 2 ofrece una visión general de los métodos de los estudios en la India y Bangladesh y destaca varios aspectos de su diseño que se basan en lecciones de investigaciones previas para maximizar la precisión de las estimaciones de los docentes. La sección 3 presenta los principales resultados de estos estudios. La sección 4 concluye extrayendo lecciones generales de nuestros hallazgos, situando nuestros estudios en la literatura más amplia y discutiendo direcciones prometedoras para investigaciones futuras.

2. Métodos

En este artículo, nos basamos en datos de dos estudios en la India y Bangladesh. El estudio en la India, en el que volvimos a analizar datos de una evaluación aleatorizada, nos permitió primero identificar el desajuste entre los puntajes de los estudiantes en las pruebas y las expectativas de los docentes. El de Bangladesh, que diseñamos y ejecutamos, nos permitió luego examinar este patrón, descartar factores de confusión e identificar mecanismos potenciales. Los presentamos juntos porque, dadas las estructuras de incentivos y las capacidades similares de estos dos sistemas educativos, consideramos que sus resultados consistentes sugieren desafíos comunes.

Muestra

En el estudio 1, usamos datos de una evaluación aleatorizada de un programa de residencia docente en el estado de Maharashtra, en la India (Ganimian et al., 2024). Esta evaluación se realizó en los grados 5 y 6, en una muestra de conveniencia de 48 escuelas primarias públicas con enseñanza en inglés en la ciudad de Pune, en el estado indio de Maharashtra. El marco muestral incluía las 286 escuelas primarias administradas por el Pune School Board.⁴ Solo usamos datos del grupo de control (para eliminar la posibilidad de que la intervención influya en los patrones que observamos) correspondientes a los docentes regulares en la ronda de recolección de datos de la medición final.⁵ Nuestra muestra analítica incluye 46 docentes y 457 estudiantes de los grados 5 y 6.

⁴ Los autores excluyeron 118 escuelas en zonas rurales remotas (porque habría sido difícil supervisar la intervención en esos contextos), 30 escuelas con enseñanza en urdu (porque la mayoría de los residentes docentes no hablaban urdu), 46 escuelas con enseñanza en inglés y 13 escuelas que estaban implementando otras intervenciones (para evitar confundir los efectos de la intervención con los de estos otros programas), 20 escuelas con baja matrícula (para minimizar el error muestral) y 9 escuelas que ya habían implementado la intervención. Después de la medición inicial, se retiraron dos escuelas debido a la escasez de residentes.

⁵ Al grupo de tratamiento le enseñaron estudiantes universitarios durante una beca de un año (en lugar de docentes de escuelas públicas). Nos interesa explicar el comportamiento de los docentes de escuelas públicas, por lo que excluimos al grupo de tratamiento.

En el estudio 2, usamos datos de un estudio que realizamos en Bangladesh para entender en qué medida los patrones que observamos en la India estaban presentes en un sistema educativo con características institucionales similares. Este estudio se realizó en el grado 6, en una muestra aleatoria estratificada de 403 docentes de matemáticas y/o lengua (bengalí) y sus 1,306 estudiantes en 273 escuelas secundarias de asociación público-privada (es decir, financiadas con fondos públicos y administradas de forma privada, o APP), que representan más del 95% de la matrícula en la educación secundaria. Llegamos a esta muestra de la siguiente manera. Primero, obtuvimos acceso a los resultados de la National Assessment of Secondary Students (NASS) de 2019—una evaluación a gran escala de bajo impacto aplicada a una muestra representativa a nivel nacional de estudiantes en matemáticas, bengalí e inglés. Esta base de datos incluía 28,238 estudiantes, a quienes vinculamos con sus 6,373 docentes en las tres materias evaluadas. Luego, extrajimos una muestra aleatoria simple de tres de las ocho divisiones del país (Chittagong, Dhaka y Mymensingh) y conservamos a los 2,724 docentes de esas divisiones. Por último, excluimos a 1,034 docentes que no enseñaban matemáticas ni bengalí, a 83 docentes de quienes no teníamos números de teléfono celular y a 84 docentes de quienes no teníamos información sobre el tamaño de la clase (que necesitábamos para la estratificación). De los 1,523 docentes restantes, seleccionamos aleatoriamente a 825, estratificando la selección por terciles de matrícula estudiantil. De los docentes seleccionados, incluimos a 573 en nuestra muestra y asignamos los 252 restantes a una lista de reserva. Llamamos a 726 docentes (573 de la muestra y 153 de la lista de reserva), contactamos a 607 de ellos, obtuvimos el consentimiento de 597, excluimos a 194 (porque informaron que no enseñaban en las escuelas, grados o materias objetivo) y nos quedamos con 403. Ofrecimos a cada docente BDT 100 taka (~USD 1.17) en saldo de telefonía celular por participar. Vinculamos a estos docentes con 3,259 estudiantes, de los cuales reconocieron a 2,445. Seleccionamos aleatoriamente a 1,128 de estos estudiantes para obtener las estimaciones de los docentes sobre sus puntajes en las pruebas.

Datos

En el estudio 1, usamos principalmente datos de dos instrumentos aplicados en la medición final de la evaluación de impacto: una prueba de matemáticas y una encuesta a docentes. La prueba de matemáticas usó 35 ítems de opción múltiple para evaluar a los estudiantes en tres dominios de contenido (números, geometría y medidas, y representación de datos) y dominios cognitivos (conocer, aplicar y razonar) en una amplia gama de niveles de dificultad.⁶ El puntaje de cada estudiante está dado por el porcentaje de ítems que respondió correctamente, de 0 a 100. La encuesta pedía a los docentes que estimaran los puntajes de 10 estudiantes seleccionados aleatoriamente en su aula. Cada estimación también se expresa como un porcentaje de respuestas correctas de 0 a 100. También aprovechamos datos de la línea de base para explorar si la precisión de las estimaciones variaba según las características de los estudiantes (ser mujer, provenir de una familia de bajos ingresos o pertenecer a una casta o tribu registrada) o las características de los docentes (p. ej., tener una maestría, formación inicial o más experiencia).

En el estudio 2, usamos principalmente datos de dos fuentes: la NASS de 2019 para el grado 6, que evaluó las habilidades de los estudiantes en matemáticas y lengua (bengalí), y una encuesta telefónica a docentes que recogió sus estimaciones del desempeño de sus estudiantes en la NASS. La NASS de 2019 usó 40 ítems (de los cuales 29 eran de opción múltiple) en cinco dominios de contenido en matemáticas (números y operaciones, medición, datos, geometría y álgebra) y 42 ítems (de los cuales 36 eran de opción múltiple) en tres dominios de contenido en lengua (lectura,

⁶ La distribución de los ítems entre dominios de contenido y cognitivos se basó en el marco de evaluación del Trends in International Math and Science Study de 2019 (TIMSS; IEA, 2017). Los ítems de la prueba se tomaron de evaluaciones nacionales e internacionales, así como de evaluaciones de impacto realizadas en la India. La evaluación de impacto para la cual se diseñó esta prueba encontró efectos de moderados a grandes en esta prueba en la medición final y en el seguimiento (Ganimian et al., 2024).

vocabulario y gramática). La distribución de los ítems se basó en el currículo nacional. La encuesta pedía a los docentes que estimaran los puntajes de tres estudiantes seleccionados aleatoriamente en su aula en la prueba de la materia que enseñaban (matemáticas o lengua).⁷ También incluía preguntas sobre las características de los docentes (p. ej., educación), sus creencias (p. ej., mentalidad de crecimiento) y sus prácticas de enseñanza, que usamos para explorar la heterogeneidad en la precisión de las estimaciones.

Hay tres aspectos comunes a ambos estudios que se basan en lecciones de investigaciones previas y maximizan nuestras posibilidades de encontrar una relación entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes. En primer lugar, pedimos a los docentes que estimaran los puntajes de sus estudiantes en una *prueba específica*, en lugar de pedirles una valoración holística, para evitar que los puntajes y las estimaciones difirieran simplemente porque estas últimas se basaran en información no captada por la prueba. En segundo lugar, pedimos a los docentes que expresaran sus estimaciones en la *misma escala* en la que se calificaron las pruebas, en lugar de pedirles que usaran una escala Likert, para prevenir discrepancias entre los puntajes y las estimaciones debidas únicamente a diferencias entre escalas. En tercer lugar, pedimos a los docentes que estimaran el *puntaje de cada estudiante individual*, en lugar de ordenar a sus estudiantes, para descartar la posibilidad de que las diferencias entre los puntajes y las estimaciones fueran atribuibles a juicios erróneos sobre la posición relativa de los estudiantes (para revisiones que discuten la importancia de estos factores, véase Hoge & Coladarci, 1989; Südkamp et al., 2012; Urhahne & Wijnia, 2021). Por último, pedimos a los docentes que hicieran sus estimaciones después de haber enseñado a los estudiantes durante un año escolar completo, para evitar la posibilidad de

⁷ 212 docentes enseñaban matemáticas, 181 enseñaban bengalí y 10 enseñaban ambas y fueron asignados aleatoriamente a una de ellas para la encuesta.

que las estimaciones fueran inexactas porque los docentes no hubieran llegado a conocer a los estudiantes.

Cada estudio tiene además algunas características específicas que nos permiten descartar posibles factores de confusión en la relación entre los puntajes de los estudiantes y las estimaciones de los docentes. En la India, medimos el desempeño de los estudiantes y las estimaciones de los docentes al *mismo tiempo* (es decir, dentro de la misma ronda de recolección de datos, a menudo el mismo día) para evitar discrepancias debidas al “sesgo de recuerdo” (es decir, que los docentes recordaran mal el desempeño de sus estudiantes en la prueba) o a la “reversión a la media” (es decir, que los docentes anticiparan cambios en los puntajes de sus estudiantes a lo largo del tiempo).⁸ Dado que la prueba fue desarrollada por un equipo de investigación para los fines de una evaluación de impacto, también mostramos a los docentes la prueba que usamos para evaluar a los estudiantes antes de recabar sus estimaciones, para evitar que cometieran errores simplemente por no estar familiarizados con la prueba.⁹ En Bangladesh, medimos los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes en dos materias para descartar discrepancias atribuibles a la estimación del desempeño en una materia específica.¹⁰ También pedimos a los docentes que estimaran el desempeño de los estudiantes no solo en la prueba en su conjunto, sino también en

⁸ En Bangladesh, el desempeño de los estudiantes se midió con la NASS 2019 en febrero-marzo de 2020 y las estimaciones de los docentes se recogieron con nuestra encuesta en septiembre de 2020, por lo que transcurrieron cinco meses entre ambas mediciones.

⁹ En Bangladesh, pedimos a los docentes que estimaran los puntajes de sus estudiantes en la evaluación nacional, que se administra desde 2011 y con la que los docentes ya estaban familiarizados. La prueba evalúa los contenidos del currículo de 6.º grado y, por lo tanto, debería estar alineada con los contenidos que los docentes cubren en clase (MEW-DSHE, 2019).

¹⁰ En la India, la base de datos solo incluye las estimaciones de los docentes sobre el desempeño de los estudiantes en las pruebas de matemáticas.

temas e ítems específicos, para prevenir la posibilidad de que las discrepancias se originaran en que los docentes no supieran cómo estimar el desempeño general en la prueba.¹¹ Por último, pedimos a los docentes que corroboraran los nombres de sus estudiantes, usando tanto nombres reales como falsos, para descartar la posibilidad de que no conocieran a los estudiantes cuyos puntajes se les pedía estimar.¹²

3. Resultados

En esta sección, presentamos los hallazgos de los estudios en la India y Bangladesh. Documentamos la brecha promedio entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes, exploramos cómo difiere esta brecha entre subgrupos de estudiantes y docentes, y descartamos posibles factores de confusión.

A. Brechas promedio entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes

Los docentes estiman erróneamente los puntajes de sus estudiantes en las pruebas

Todos los docentes de nuestros datos estiman erróneamente el desempeño de sus estudiantes en pruebas estandarizadas. Si calculamos la diferencia entre el porcentaje de respuestas correctas de cada estudiante y la estimación de ese puntaje hecha por su docente, solo 2 (de 438 estimaciones por docente y estudiante) son exactamente 0 (lo que indica que el docente adivinó perfectamente el puntaje de un estudiante) en la India en matemáticas, 22 (de 605 estimaciones) en Bangladesh en matemáticas y 2 (de 509 estimaciones) en lengua. Ninguno de los docentes de ninguno de los dos países estimó perfectamente los puntajes de todos sus estudiantes (como se explica en la sección de Métodos, en la India pedimos a los docentes que estimaran los puntajes de 10 estudiantes, y en

¹¹ En la India, los datos solo incluyen las estimaciones de los docentes sobre los puntajes globales de los estudiantes.

¹² En la India, tanto los estudiantes como los docentes habían participado en un estudio de un año de duración, por lo que dicha verificación no fue necesaria.

Bangladesh, de tres estudiantes, por lo que este hecho es menos sorprendente en la India que en Bangladesh).

La dirección (es decir, el signo) de los errores de los docentes varía según la materia. En matemáticas, los docentes tienden a sobreestimar el desempeño de los estudiantes en las pruebas. Si contabilizamos las diferencias entre los puntajes de los estudiantes y las estimaciones de los docentes en esta materia, el 84% de esas diferencias son positivas (lo que indica que el docente adivinó un puntaje superior al puntaje real del estudiante) en la India y el 60% son positivas en Bangladesh. En lengua, ocurre lo contrario: solo el 33% de las diferencias en esa materia son positivas en Bangladesh. Mostramos este patrón gráficamente en la Figura 1, que presenta la distribución de las diferencias entre puntajes y estimaciones a nivel de estudiante-docente (díada) (en histogramas) y la distribución de los promedios de esas diferencias a nivel de docente (en gráficos de densidad) por país y materia. Las distribuciones están centradas a la derecha de 0 en matemáticas y a la izquierda de 0 en lengua, lo cual es consistente con la dirección de los errores de los docentes descrita arriba (véase también la Figura A.1 del anexo).¹³

La magnitud de los errores de los docentes es grande

La forma más sencilla de cuantificar las discrepancias entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes es calcular la diferencia promedio en puntos porcentuales entre estas medidas, dado que ambas se expresan como porcentaje de respuestas correctas (es decir, de 0 a 100). En la India, el puntaje real promedio en matemáticas fue de 39, pero el puntaje estimado promedio es de 63—24 p.p. más alto. En Bangladesh, los puntajes reales promedio son de 56 en matemáticas y de 70 en lengua, pero los puntajes estimados promedio son de

¹³ Las diferencias en la dirección y la magnitud de los errores de estimación entre materias podrían deberse a varios factores, incluidas diferencias en la dificultad de estimar el desempeño en cada materia, en la dificultad de las pruebas o en la alineación entre los contenidos enseñados en clase y los evaluados por la prueba.

65 y 63—8.4 p.p. más altos en el primer caso y 7 p.p. más bajos en el segundo (Tabla A.1 del anexo).

Una forma de interpretar estas diferencias es calcular la posición percentil del puntaje estimado promedio en la distribución de los puntajes reales. Una diferencia de 0 indicaría que el puntaje estimado promedio se ubica en el 50° percentil de la distribución de los puntajes reales. La diferencia promedio en la India indica que el puntaje estimado promedio se ubica en el percentil 88 de la distribución de los puntajes reales; las diferencias promedio en Bangladesh indican que los puntajes estimados promedio se ubican en los percentiles 58 y 57 de las distribuciones de los puntajes reales en matemáticas y lengua, respectivamente.

Sin embargo, los enfoques anteriores no tienen en cuenta que algunos docentes tienen estudiantes cuyo desempeño en las pruebas varía más que el de otros. Esta es una limitación importante porque, si dos docentes estiman erróneamente los puntajes de sus estudiantes por la misma cantidad de puntos porcentuales, pero uno de ellos tiene estudiantes cuyos puntajes varían más, ese docente será menos capaz de distinguir entre los puntajes de dos estudiantes cualesquiera. Un enfoque alternativo que ilustra las implicaciones de las estimaciones erróneas para la enseñanza consiste en dividir la diferencia promedio de cada docente entre los puntajes estimados y reales de los estudiantes de su clase por la DE dentro del aula de los puntajes reales de ese docente, y calcular el cociente promedio entre todos los docentes. Si lo hacemos, la diferencia promedio entre los puntajes estimados y reales equivale a 1.51 DE dentro del aula en la India en matemáticas, y a 2.18 y 1.87 DE dentro del aula en Bangladesh en matemáticas y lengua, respectivamente (Tabla A.1).

La métrica usada con mayor frecuencia en estudios previos (que, como se explica en la Introducción, se realizaron principalmente en países de ingresos altos) es la correlación entre los puntajes reales y los estimados. El coeficiente de correlación de Pearson entre estos puntajes es de 0.36 en la India en matemáticas (lo que equivale a un R cuadrado de 0.13, e implica que solo el 13%

de la variación en los puntajes reales se explica por la variación en los puntajes estimados), y de 0.07 y 0.11 en Bangladesh en matemáticas y lengua, respectivamente (lo que equivale a valores de R^2 de aproximadamente 0.01, o al 1% de la variación en los puntajes reales explicada por la variación en los puntajes estimados). Mostramos estas relaciones gráficamente en la Figura 2. En todos los casos, la recta de mejor ajuste es plana, lo que indica una asociación positiva pero débil entre los puntajes reales y los estimados.

Un enfoque similar consiste en estimar en qué medida los puntajes estimados predicen los puntajes reales. Si ajustamos una regresión de mínimos cuadrados ordinarios (MCO) de los puntajes reales sobre los estimados, podemos obtener el cambio promedio en los puntajes estimados por cada cambio de un punto en los puntajes reales. En la India, un aumento de un punto en los puntajes reales corresponde a un aumento de 0.31 puntos en los puntajes estimados en matemáticas ($p < 0.01$); en Bangladesh, corresponde a aumentos de 0.10 ($p = 0.09$) y 0.13 puntos ($p = 0.02$) en los puntajes estimados en matemáticas y lengua, respectivamente (Tabla A.2, columna 1). Si incluimos efectos fijos de docente (para tener en cuenta las diferencias en las distribuciones de los puntajes reales y estimados entre docentes), las estimaciones puntuales aumentan a 0.45 ($p < 0.01$) en la India en matemáticas, y a 0.32 ($p < 0.01$) y 0.44 ($p < 0.01$) en Bangladesh en matemáticas y lengua, respectivamente (Tabla A.2, columna 2). Los efectos fijos también aumentan la proporción de la variación en los puntajes reales debida a la variación en los puntajes estimados, en parte debido a la asignación no aleatoria de estudiantes a docentes (p. ej., a algunos docentes se les asignan estudiantes de menor desempeño).

Los docentes no saben que están cometiendo errores

Los docentes no solo desconocen que están haciendo estimaciones incorrectas de los puntajes de los estudiantes en las pruebas; de hecho, se sienten abrumadoramente seguros de sus juicios erróneos. En Bangladesh, les pedimos que indicaran su nivel de seguridad en sus estimaciones de los

puntajes individuales de los estudiantes, usando una escala de cuatro puntos que iba desde “Totalmente seguro (espero que todos mis puntajes sean correctos con un margen de unos pocos puntos porcentuales)” hasta “No estoy seguro (en su mayoría estoy adivinando con base en mi experiencia)”. La gran mayoría de los docentes tanto de matemáticas (91%) como de lengua (83%) seleccionó los dos niveles superiores de la escala, lo que indica que estaban totalmente seguros o muy seguros de sus estimaciones. De hecho, ninguno de los 403 docentes encuestados en ninguna de las dos materias indicó que no estuviera seguro de sus estimaciones.

Los docentes más seguros estiman los puntajes de los estudiantes con mayor precisión que el resto, pero solo por un pequeño margen, y los demás niveles de seguridad son menos útiles para predecir la precisión de las estimaciones. Si hacemos una regresión de los puntajes reales sobre los estimados por separado para cada nivel de seguridad seleccionado por al menos un docente en Bangladesh (en orden descendente: totalmente seguro, muy seguro y algo seguro), las estimaciones de los docentes con el nivel más alto de seguridad son las que mejor predicen los puntajes reales. Sin embargo, incluso entre estos docentes, las estimaciones son bastante inexactas: en matemáticas, un aumento de un punto en los puntajes reales corresponde a un aumento de 0.32 puntos en los puntajes estimados ($p < 0.01$); en lengua, corresponde a un aumento de 0.25 puntos ($p < 0.01$; Tabla A.3). Dicho de otro modo, solo alrededor del 5% de la variación en los puntajes reales se explica por la variación en los puntajes estimados tanto en matemáticas como en lengua. Los niveles más bajos de seguridad corresponden a niveles más bajos de precisión en matemáticas (entre los docentes que están muy seguros, un aumento de un punto en los puntajes reales corresponde a un aumento de 0.07 puntos en los puntajes estimados [$p = 0.346$], y entre quienes están algo seguros, a una *disminución* de 0.12 puntos [$p = 0.544$], lo que sugiere que los puntajes estimados están inversamente relacionados con los puntajes reales), pero menos claramente en lengua (las cifras correspondientes son aumentos

de 0.04 [$p=0.687$] y 0.14 puntos [$p=0.274$], respectivamente)—en parte, porque una proporción muy pequeña de docentes seleccionó el nivel más bajo de seguridad.

Los docentes no saben cómo se comparan sus estudiantes entre sí

Es posible que los docentes no necesiten conocer el puntaje exacto de cada uno de sus estudiantes para entender que algunos tienen más dificultades que otros con el contenido y, por lo tanto, necesitan más apoyo. Sin embargo, parecen desconocer la posición relativa dentro del aula (es decir, el ordenamiento) de los estudiantes de sus clases. La forma más sencilla de mostrarlo es calcular la correlación de Spearman (es decir, la correlación entre posiciones) entre los puntajes reales y los estimados.¹⁴ Estas correlaciones son muy similares a las correlaciones de Pearson anteriores: 0.35 en la India en matemáticas (lo que equivale a un R cuadrado de 0.12, e implica que solo el 12% de la variación en las posiciones reales se explica por la variación en las posiciones estimadas), y 0.07 y 0.11 en Bangladesh en matemáticas y lengua, respectivamente (lo que equivale a valores de R cuadrado de 0.01 y 0.02, o al 1% y 1.5% de la variación en las posiciones reales explicada por la variación en las posiciones estimadas, respectivamente). En la Figura 3, graficamos la relación entre las posiciones reales de los estudiantes dentro del aula (según la posición relativa de su puntaje en la distribución de la clase) y las posiciones estimadas por los docentes dentro del aula (según la posición relativa implícita en cada puntaje estimado). Nuevamente, las rectas de mejor ajuste son planas, lo que indica asociaciones positivas pero débiles.

¹⁴ Comparamos los ordenamientos de los puntajes de los estudiantes y de las estimaciones de los docentes para los estudiantes que tienen ambos. Como se explica en la sección de Métodos, en la India pedimos a los docentes que estimaran los puntajes de 10 estudiantes y, en Bangladesh, los de tres estudiantes. No esperamos que el número de estudiantes seleccionados en cada país importe para los ordenamientos, porque no pedimos a los docentes que ordenaran solo a los estudiantes seleccionados. Más bien, somos nosotros quienes ordenamos a esos estudiantes según sus puntajes reales y estimados.

Confirmamos este patrón con un marco de regresión. Si ajustamos una regresión de MCO de las posiciones reales sobre las posiciones estimadas dentro del aula (según se definieron arriba), podemos obtener el cambio promedio en las posiciones estimadas por cada cambio de un punto en las posiciones reales. En la India, un aumento de un punto en las posiciones reales corresponde a un aumento de 0.51 puntos en las posiciones estimadas en matemáticas ($p < 0.01$); en Bangladesh, corresponde a una *disminución* de 0.17 puntos ($p < 0.01$) (lo que indica una relación inversa entre las posiciones reales y las estimadas) en matemáticas y a un aumento de 0.14 puntos ($p = 0.02$) en lengua (Tabla A.4). Los valores de R cuadrado son más altos que los de las regresiones de los puntajes (0.25 en la India en matemáticas, y 0.03 y 0.02 en Bangladesh en matemáticas y lengua, lo que implica que el 6% y menos del 1% de la variación en las posiciones reales es atribuible a la variación en las posiciones estimadas, respectivamente) debido a la naturaleza gruesa de los ordenamientos (aunque un docente estime erróneamente el puntaje de un estudiante, aún puede estimar correctamente la posición de ese estudiante).¹⁵

De hecho, una proporción no trivial de docentes *invierte* los ordenamientos de sus estudiantes (es decir, supone que el estudiante con el puntaje más alto es el de puntaje más bajo, o viceversa). En Bangladesh, donde solo recabamos los puntajes estimados por los docentes para tres estudiantes, calculamos el porcentaje de docentes que caen en esta categoría: el 11% de los docentes de matemáticas y el 12% de los de lengua invirtieron la posición relativa de sus propios estudiantes.

Los docentes subestiman cuánto varían sus estudiantes

Aunque los docentes no conozcan el desempeño absoluto o relativo de sus estudiantes en las pruebas, aún podrían tener una idea de cuánto varían sus estudiantes en su comprensión del

¹⁵ Incluir efectos fijos por docente casi no cambia nuestros resultados, dado que la distribución de los ordenamientos no varía dentro de cada país (recuérdese que obtuvimos estimaciones para 10 estudiantes en la India y tres estudiantes en Bangladesh).

contenido.¹⁶ Sin embargo, si comparamos la variabilidad real dentro del aula (la DE dentro del aula de los puntajes de los estudiantes en las pruebas) con la variabilidad estimada dentro del aula (la DE dentro del aula de las estimaciones de los docentes), la mayoría de los docentes subestima la variabilidad en sus aulas. En la India, el 54% de los docentes subestima la variabilidad dentro del aula en matemáticas; en Bangladesh, el 77% de los docentes lo hace en matemáticas y el 78% en lengua.

Las creencias de los docentes sobre la variabilidad de los puntajes en su aula son un mal predictor de la variabilidad real de los puntajes de los estudiantes dentro del aula. El coeficiente de correlación de Pearson entre la variabilidad real y la estimada dentro del aula (según se definieron arriba) es de 0.08 en la India en matemáticas (lo que implica que alrededor del 1% de la variabilidad real se explica por la variabilidad estimada), y de 0.08 y -0.03 en Bangladesh en matemáticas y lengua (lo que implica que menos del 1% de la variabilidad real se explica por la variabilidad estimada). Presentamos estas relaciones gráficamente en la Figura 4. En todos los casos, la recta de mejor ajuste es plana, lo que indica una asociación cercana a cero entre la variabilidad real y la estimada dentro del aula. Confirmamos este patrón analíticamente: cuando ajustamos una regresión de MCO de las DE reales sobre las DE estimadas dentro del aula, los coeficientes se mantienen sistemáticamente en torno a cero y no son estadísticamente significativos (Tabla A.5).

B. Brechas según las características de los estudiantes y los docentes

Los docentes sobreestiman los puntajes de los estudiantes de bajo desempeño

¹⁶ Por ejemplo, si en un aula de dos estudiantes un estudiante obtiene un 0 en una prueba y el otro obtiene un 100, y su docente estima que el primer estudiante obtendrá un 100 y el segundo un 0, ese docente se equivocaría en sus estimaciones de los puntajes de sus estudiantes, pero acertaría en su estimación de la variabilidad de los puntajes en su clase.

El patrón presentado arriba se explica en parte porque los docentes son particularmente propensos a sobreestimar los puntajes de los estudiantes de bajo desempeño. Clasificamos a los estudiantes en grupos de puntaje bajo, medio y alto de dos maneras. En primer lugar, agrupamos a los estudiantes según su tercil *dentro del aula* (es decir, su posición relativa en su clase).¹⁷ En la India, los docentes sobreestiman los puntajes de los estudiantes de todos los terciles en matemáticas, pero lo hacen por un margen mayor en el caso de los estudiantes del tercil más bajo (30.3 p.p., $p<0.01$) que en el de los terciles medio y más alto (23.6 y 15.9 p.p., respectivamente, $p<0.01$; Figura 5 y Tabla A.6). En Bangladesh, los docentes sobreestiman los puntajes de los estudiantes del tercil más bajo (en 18.5 p.p. en matemáticas y 4.84 p.p. en lengua, $p<0.01$) y subestiman los puntajes de los del tercil más alto (en 6.17 p.p. en matemáticas y 17.9 p.p. en lengua, $p<0.01$).

En Bangladesh, también agrupamos a los estudiantes según su tercil *nacional* (es decir, su posición entre todos los evaluados). Al hacerlo, encontramos el mismo patrón que arriba: los docentes sobreestiman los puntajes de los estudiantes del tercil más bajo (en 30.4 p.p. en matemáticas y 14.0 p.p. en lengua, $p<0.01$) y subestiman los de los estudiantes del tercil más alto (en 13.0 p.p. en matemáticas y 20.1 p.p. en lengua, $p<0.01$; Tabla A.7), lo que sugiere que los docentes subestiman el bajo desempeño en su clase.

Los docentes sobrevaloran la importancia de la inteligencia para los puntajes en las pruebas

La brecha entre los puntajes en las pruebas y las estimaciones también se explica en parte porque los docentes sobrevaloran la importancia de la inteligencia de los estudiantes al estimar su desempeño. En la India, tenemos datos sobre la “inteligencia fluida” de los estudiantes (es decir, el

¹⁷ En la India, asignamos a los estudiantes a terciles dentro del aula según los puntajes de los 10 estudiantes para los que los docentes proporcionaron estimaciones. En Bangladesh, lo hacemos según *todos* los estudiantes de la misma aula que rindieron la evaluación nacional, pero solo observamos tanto los puntajes reales como los estimados para los tres estudiantes para los que los docentes proporcionaron estimaciones.

razonamiento abstracto no verbal) a partir de una versión abreviada de las Matrices Progresivas de Raven (Raven & Summers, 1986). Si calculamos el puntaje promedio en la prueba de matemáticas por cuartil de inteligencia de los estudiantes, los del cuartil 1 (el más bajo) obtienen un puntaje menor (30.7) que los del cuartil 4 (el más alto; 44.8)—una diferencia de 14.1 p.p. Sin embargo, los docentes estiman que la diferencia entre estos cuartiles es mucho mayor—de unos 23.4 p.p.—porque, aunque sobreestiman los puntajes de los estudiantes en las pruebas a lo largo de toda la distribución de inteligencia, sobreestiman los puntajes de los estudiantes del cuartil 4 por un margen mayor (30.3 p.p., $p < 0.01$) que los de los estudiantes del cuartil 1 (21.0, Tabla A.8). De hecho, la inteligencia de los estudiantes predice mejor las estimaciones de los docentes que los puntajes de los estudiantes en las pruebas: el coeficiente de correlación de Pearson entre la inteligencia y los puntajes en las pruebas es de 0.29 (lo que implica un R cuadrado de 0.09) y el coeficiente entre la inteligencia y las estimaciones es de 0.36 (lo que implica un R cuadrado de 0.13). Estos resultados sugieren que los docentes usan la inteligencia como un indicador indirecto del desempeño.

Los docentes sobreestiman los puntajes de las niñas en las pruebas en mayor medida que los de los niños

Varios estudios en países de ingresos bajos y medios (PIBM) han encontrado que los docentes suelen tener expectativas distintas para distintos grupos de estudiantes (p. ej., Farfan Bertran et al., 2021; Hanna & Linden, 2012). Por lo tanto, investigamos si las estimaciones de los docentes diferían en nivel o en precisión para los estudiantes tradicionalmente desfavorecidos. Solo podemos hacerlo en la India, donde observamos las características demográficas de los estudiantes.

En la India, los estudiantes varones y mujeres tienen un desempeño similar en matemáticas (con porcentajes promedio de respuestas correctas de 39.4 y 38.7, respectivamente; Tabla A.9). Los docentes no estiman que los puntajes de las estudiantes mujeres sean más bajos que los de los varones. De hecho, sobreestiman los puntajes tanto de los varones como de las mujeres, pero lo

hacen por un margen más amplio en el caso de las mujeres (26.8 p.p., $p<0.01$) que en el de los varones (22.1 p.p., $p<0.01$). Los docentes varones sobreestiman los puntajes tanto de los estudiantes varones (28.5, $p<0.01$) como de las mujeres (30.6, $p=0.01$) por un margen más amplio que las docentes mujeres (20.7 y 25.9 p.p., respectivamente, $p<0.01$), pero la diferencia entre las estimaciones para estudiantes varones y mujeres es mayor en el caso de las docentes mujeres (5.2 p.p., a favor de las mujeres) que en el de los docentes varones (2.1 p.p., también a favor de las mujeres).

Los docentes sobreestiman en medida similar los puntajes de los estudiantes de ingresos bajos y altos

En la India, los estudiantes tienen un desempeño similar en matemáticas en todo el espectro socioeconómico. Si agrupamos a los estudiantes según su cuartil en un índice de bienes del hogar,¹⁸ los estudiantes del cuartil 1 (los más pobres) tienen un desempeño comparable (con un porcentaje promedio de respuestas correctas de 38.6) al de los del cuartil 2 (39.3), el cuartil 3 (39.3) y el cuartil 4 (los más ricos, 39.2). Los docentes no estiman que los puntajes de los estudiantes de familias de bajos ingresos sean más bajos que los de familias de altos ingresos. De hecho, sobreestiman los puntajes de los estudiantes de todos los cuartiles por un margen similar (entre 22.7 y 28.3 p.p., Tabla A.10).

Los docentes sobreestiman en medida similar los puntajes de los estudiantes de distintas castas/tribus

En la India, los estudiantes tienen un desempeño similar en matemáticas en las distintas castas y tribus. Si clasificamos a los estudiantes según la casta o tribu registrada en los expedientes

¹⁸ El índice indica si los estudiantes reportaron tener los siguientes bienes en sus hogares: un escritorio para estudiar, libros de cuentos, una habitación propia, un diccionario, una computadora, un televisor, conexión a internet y un reproductor de DVD.

de su escuela, los de tribus registradas obtienen el mejor desempeño (con un porcentaje promedio de respuestas correctas de 48), seguidos por los de otras castas atrasadas (41.9), otras categorías generales (39.6) y los de castas registradas (36.7).¹⁹ El ordenamiento de las estimaciones de los docentes refleja el de los puntajes de los estudiantes: son más altas para los estudiantes de tribus registradas (con un puntaje estimado promedio de 71.6), seguidos por los de otras castas atrasadas (70.0), otras categorías generales (64.1) y castas registradas (61.9). Sin embargo, las estimaciones superan los puntajes de todos los grupos por entre 23.6 y 28.1 p.p. ($p < 0.01$ excepto en el caso de las tribus registradas; Tabla A.11).

Los docentes con más educación, formación y experiencia no son más precisos

Dada la débil asociación entre los criterios que los sistemas educativos de los PIBM usaban con frecuencia para determinar los salarios docentes—tener una maestría, haber completado la formación inicial o tener más años de experiencia docente que el docente mediano—y las mejoras en el desempeño de los estudiantes (Araujo et al., 2016; Azam & Kingdon, 2015; Bau & Das, 2017; Buhl-Wiggers et al., 2019), quizás no sorprenda que estos factores no expliquen las diferencias en la precisión de las estimaciones. Si estimamos una regresión por MCO de los puntajes reales sobre los puntajes estimados, una variable indicadora de una característica (p. ej., tener una maestría) y su interacción con los puntajes estimados, encontramos que los docentes con más educación, formación y experiencia no hacen predicciones más precisas.²⁰ De hecho, los coeficientes de las interacciones en estas regresiones (que capturan las diferencias en el poder predictivo de las estimaciones entre los docentes con y sin una característica) se estiman sistemáticamente en cero (lo que indica que no hay

¹⁹ La categoría “general” incluye todas las clases no desfavorecidas según el sistema de castas de la India.

²⁰ También analizamos la importancia de la experiencia de los docentes en su escuela, en su grado y en su materia. Todos estos resultados fueron coherentes con los de la experiencia total, por lo que solo conservamos estos últimos por brevedad.

diferencia en el poder predictivo con y sin la característica) o por debajo de cero (lo que indica que los docentes sin la característica estiman los puntajes con *mayor* precisión; Tabla A.12).

C. Descarte de posibles factores de confusión

Los errores no se deben a un enfoque en habilidades no evaluadas

Los errores de los docentes no pueden deberse a que basen sus estimaciones en información sobre habilidades de los estudiantes en una materia que las pruebas no miden. No pedimos a los docentes que ofrecieran una evaluación integral de las habilidades de sus estudiantes; les pedimos que estimaran sus puntajes en las pruebas. De hecho, la mayoría de los docentes cree que las pruebas miden precisamente lo que ellos enseñan. En Bangladesh, preguntamos a los docentes “¿en qué medida cree que [la prueba] abarca lo que usted enseña?”²¹ En matemáticas, el 96% de ellos afirmó que coincidía con lo que enseñaban en una medida “alta” o “moderada”; solo el 4.2% seleccionó un nivel “bajo” de alineación. En lengua, las cifras correspondientes fueron 96% y 3.8%, respectivamente.

Los errores no se deben a que los docentes no reconozcan a sus estudiantes

Los errores de los docentes no se deben a que no conozcan a sus estudiantes o los recuerden mal. En Bangladesh, presentamos a cada docente los nombres de 12 estudiantes y le pedimos que verificara si enseñaba a cada uno de ellos. Dos de esos nombres eran falsos, para comprobar si los docentes afirmaban reconocer a estudiantes que no estaban en su aula. Los docentes tuvieron una probabilidad mucho mayor de reconocer los nombres reales (el docente promedio reconoció el 75% de ellos) que los nombres falsos (el docente promedio reconoció solo el 30% de estos nombres y apenas el 14% de los docentes indicó conocer *ambos* nombres falsos; Tabla A.13). Además, los docentes tuvieron la misma probabilidad de reconocer a los estudiantes de los terciles superior,

²¹ El estudio de la India no incluyó esta pregunta.

medio e inferior de puntaje en las pruebas, tanto en la distribución de desempeño dentro del aula como en la nacional.

Los errores no se deben a la dificultad de estimar puntajes en las pruebas

La subestimación, por parte de los docentes, de la magnitud del bajo desempeño en su aula no puede explicarse por la dificultad de estimar puntajes en las pruebas. En Bangladesh, también les pedimos que estimaran el porcentaje de sus estudiantes en los terciles superior, medio e inferior de la distribución nacional de desempeño. Dado que observamos los puntajes de todos los estudiantes que rindieron la evaluación nacional de estudiantes, podemos comparar las estimaciones de los docentes con los porcentajes reales. En línea con la propensión de los docentes a sobreestimar los puntajes en las pruebas de los estudiantes de bajo desempeño (véase la Figura 5 y la Tabla A.7), los docentes tienden a subestimar el porcentaje de estos estudiantes en su aula. El docente promedio subestima la proporción de estudiantes en el tercil más bajo en 19.2 p.p. ($p<0.01$) en matemáticas y en 14.5 p.p. ($p<0.01$) en lengua (Tabla A.14). Los docentes también subestiman la proporción de estudiantes en el tercil medio, pero por un margen menor: 4.26 p.p. ($p=0.05$) en matemáticas y 3.53 p.p. ($p=0.13$) en lengua. Y si bien los docentes subestiman la proporción de estudiantes en el tercil superior en matemáticas en 3.86 p.p. ($p=0.17$), la sobreestiman en lengua en 5.43 p.p. ($p=0.08$).

De hecho, la mayoría de los docentes admitió haberse sorprendido al conocer el porcentaje real de estudiantes de su aula en los terciles inferior, medio y superior de la distribución nacional. Cuando les revelamos esta información, el 63% de los docentes de matemáticas y el 60% de los docentes de lengua indicaron estar “muy” o “algo sorprendidos”. Si los encuestados son reacios a admitir que cometen errores, estos porcentajes podrían subestimar la sorpresa de los docentes.

Los errores no se deben a la dificultad de agregar el desempeño por ítem

Los errores de los docentes no pueden atribuirse al nivel de agregación de sus estimaciones. Para explorar si los docentes cometieron errores debido a la dificultad de estimar puntajes totales, en

Bangladesh también les pedimos que estimaran el porcentaje de estudiantes de su aula que son competentes en los temas evaluados en matemáticas (números y operaciones, medición, datos, geometría, álgebra) y lengua (lectura, vocabulario y gramática).²² En línea con nuestros resultados para los puntajes totales (véase la Figura 1 y las Tablas A.1-A.2), los docentes sobreestiman las tasas de competencia en todos los temas (Figura 6). Las diferencias entre los porcentajes estimados y reales de estudiantes competentes por tema son grandes. En matemáticas, van de 43.7 p.p. en medición a 56.1 en álgebra (ambas $p < 0.01$). En lengua, van de 19.5 p.p. en gramática a 57.7 p.p. en lectura (ambas $p < 0.01$), lo que indica que el nivel de agregación de las estimaciones no explica su imprecisión (Tabla A.15).

Las estimaciones de los docentes no son más precisas cuando se centran en ítems específicos. En Bangladesh, pedimos a los docentes que estimaran el porcentaje de estudiantes de su aula que podrían responder *ítems específicos* de la evaluación nacional de estudiantes (p. ej., en matemáticas, calcular el área de un rectángulo). Los docentes no sobreestiman el desempeño en todos los ítems de matemáticas ni lo subestiman en todos los ítems de lengua, como cabría esperar dados los resultados anteriores. En cambio, la dirección (es decir, el signo) de sus errores está relacionada con la dificultad de los ítems. Identificamos este patrón aprovechando la base de datos de la evaluación nacional de estudiantes, que incluye el desempeño por ítem no solo de los estudiantes de nuestro estudio, sino de *todos* los examinados, y usamos un modelo logístico de dos parámetros de la teoría de respuesta al ítem (TRI 2PL) para estimar el parámetro de dificultad (b) de cada ítem (es decir, el nivel de habilidad latente necesario para responder cada ítem con una probabilidad del 50%; véase Yen & Fitzpatrick, 2006). En ambas materias, los docentes tienden a subestimar los ítems muy fáciles (es decir, aquellos con parámetros b bajos en los modelos TRI), sobreestimar los ítems muy

²² Pedimos a los docentes que clasificaran a un estudiante como competente en un tema si era “capaz de responder *todos* los ítems de ese tema”. El estudio de la India no incluyó esta pregunta.

difíciles (es decir, aquellos con parámetros b altos; Figura 7). De hecho, la magnitud de los errores de los docentes se correlaciona con la magnitud de la dificultad de los ítems (es decir, los errores son mayores en los ítems más fáciles y más difíciles, y menores en los de dificultad promedio; Tabla A.16).

Las estimaciones de los docentes no son más precisas cuando se centran en ítems y estudiantes específicos. En Bangladesh, pedimos a los docentes que indicaran si tres estudiantes a quienes habían reconocido previamente podían responder correctamente ítems específicos de las pruebas de matemáticas y lengua. En línea con nuestros resultados anteriores sobre la propensión de los docentes a sobreestimar los puntajes en las pruebas de los estudiantes de bajo desempeño (véase la Figura 5 y las Tablas A.6-A.7), subestimar el porcentaje de estos estudiantes en su aula (véase la Tabla A.14) y sobreestimar el desempeño en los ítems más fáciles (véase la Tabla A.16), los docentes sobreestiman el desempeño de los estudiantes de bajo desempeño y subestiman el de los de alto desempeño en ambos ítems presentados para matemáticas y para lengua, independientemente de si los estudiantes se clasifican en terciles según la distribución de desempeño dentro del aula o la nacional (Tabla A.17).²³

Los errores no se deben a una dependencia excesiva de heurísticas

Los docentes—como todos—recurren a heurísticas al hacer estimaciones. Muchos docentes estiman que el porcentaje de respuestas correctas de los estudiantes está en o cerca del 60%, una nota de aprobación muy utilizada: el 11% de las estimaciones de matemáticas en la India y el 21% y el 19% de las estimaciones de matemáticas y lengua en Bangladesh, respectivamente, son exactamente del 60%; y el 17% de las de la India y el 29% y el 32% de las de Bangladesh se encuentran a 5 p.p. o

²³ Dado que la mayoría de los ítems presentados a los docentes en esta pregunta eran fáciles, no podemos responder la importante pregunta de si los docentes son más propensos a sobreestimar el desempeño de los estudiantes de bajo desempeño en los ítems más fáciles. Sin embargo, los resultados del ítem de vocabulario ($b=2.28$) sugieren lo contrario.

menos del 60% (véase la Figura 2). Sin embargo, como muestra la Tabla A.18, incluso si omitimos a los docentes con estimaciones en o cerca del 60%, observamos el mismo patrón que antes (véase la Tabla A.2).

4. Conclusión

En los PIBM, los docentes rara vez diferencian su enseñanza. Estudios previos han destacado los *incentivos* que enfrentan los docentes, que los desalientan de apoyar a estos estudiantes. El presente estudio complementa esas investigaciones al destacar el posible papel de la *capacidad*—específicamente, el desajuste entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes de esos puntajes.

El estudio se distingue de esfuerzos similares por documentar patrones comunes en dos contextos (la India y Bangladesh), materias (matemáticas y lengua) y tipos de pruebas (una desarrollada por un equipo de investigación independiente y otra administrada como parte de una evaluación nacional); examinar la heterogeneidad en la precisión de las estimaciones de los docentes según las características de los estudiantes y de los docentes; y descartar posibles factores de confusión (p. ej., al recoger las estimaciones de los docentes a nivel de materia y de ítem; véanse las Tablas A.19 y A.18 para un resumen de los resultados principales y de las pruebas de robustez, respectivamente).

Extraemos tres lecciones principales de esta investigación. Primero, los docentes de los PIBM difieren considerablemente de sus pares de los países de ingresos altos (PIA) en su capacidad para estimar el desempeño de sus estudiantes. Las correlaciones entre los puntajes reales y estimados que documentamos en la India y Bangladesh son dos y nueve veces más débiles que las de los PIA, respectivamente (Hoge & Coladarci, 1989; Kaufmann, 2020; Südkamp et al., 2012; Urhahne & Wijnia, 2021). Segundo, los docentes de los PIBM son particularmente propensos a sobreestimar el desempeño en el extremo inferior de la distribución de desempeño. Este patrón se manifiesta con

mayor claridad en su sobreestimación de los puntajes de los estudiantes en los terciles más bajos de desempeño dentro del aula y nacional, algo que también se ha encontrado en los PIA (Begeny et al., 2008; Begeny et al., 2011), pero también se manifiesta en la propensión de los docentes a sobreestimar las tasas de competencia en los temas e ítems más fáciles. Por último, los errores de estimación de los docentes parecen estar más estrechamente relacionados con la inteligencia de los estudiantes que con sus actitudes hacia subgrupos de estudiantes (p. ej., mujeres o de bajos ingresos). Los estudios en los PIA no suelen encontrar una relación entre las estimaciones de los docentes y la inteligencia de los estudiantes (Hoge & Butcher, 1984), pero sí han encontrado que las estimaciones rara vez se predicen a partir de las características de los estudiantes (Doherty & Conolly, 1985; Hoge & Butcher, 1984; Leinhardt, 1983).

Vemos tres limitaciones principales en nuestro estudio. Estas también son limitaciones de la literatura en general, por lo que las discutimos con cierto detalle con la esperanza de orientar investigaciones futuras. Primero, parece posible que los docentes hayan malinterpretado lo que se les pidió de maneras que no son inmediatamente evidentes. Como ya señalamos, los docentes conocían la prueba sobre la cual se les pidió estimar el desempeño o se les mostró, estuvieron de acuerdo en que la prueba evaluaba lo que enseñaban y no fueron más precisos al estimar porcentajes de estudiantes competentes o tasas de competencia en temas e ítems específicos. Sin embargo, incorporar ejercicios de práctica con respuestas contribuiría aún más a asegurar la comprensión.

Segundo, los docentes podrían haber hecho un esfuerzo insuficiente al estimar los puntajes de sus estudiantes en las pruebas. Como demostramos, las estimaciones de los docentes no son puro “ruido”; pueden explicarse en parte por las diferencias entre sus estimaciones para los estudiantes de bajo y alto desempeño y por el desempeño de los estudiantes en una prueba de inteligencia fluida. Sin embargo, sigue siendo posible que ofrecer a los docentes incentivos para que den sus estimaciones más meditadas de los puntajes de los estudiantes mejore su precisión. Como

mencionamos, en Bangladesh ofrecimos a los docentes un incentivo por participar en la encuesta, pero podrían dar estimaciones más meditadas si se les recompensara según su precisión.

Por último, a pesar de que nuestras instrucciones eran sumamente claras, los docentes podrían haber declarado los puntajes que *esperaban* que obtuvieran los estudiantes—ya sea por “razonamiento motivado” (Bénabou & Tirole, 2016) o por ilusiones—o los puntajes que creían que serían *aceptables*—por “deseabilidad social” (Reisinger, 2022). Sin embargo, si estos mecanismos fueran un determinante importante de las estimaciones, sería difícil explicar por qué los docentes no esperan que *todos* los estudiantes obtengan puntajes más altos (es decir, por qué no sobreestiman los puntajes de todos los estudiantes por un margen similar). Ni siquiera sus estudiantes de mayor desempeño obtienen puntajes perfectos, por lo que todavía hay un margen considerable para que los docentes esperen que les vaya aún mejor de lo que realmente les va. También es difícil explicar por qué la inteligencia de los estudiantes predeciría las estimaciones. No obstante, proporcionar a los docentes anclas basadas en estudiantes similares, o bien recoger por separado los puntajes que desearían que obtuvieran sus estudiantes y los que esperan que obtengan, podría ayudar a obtener estimaciones más precisas.

En última instancia, la pregunta de frontera para esta literatura en los PIBM es si (y, de ser así, cómo) los errores de estimación de los docentes sobre los puntajes de los estudiantes en las pruebas afectan la enseñanza en el aula. Específicamente, planteamos la hipótesis de que los docentes podrían interactuar menos, o tener distintos tipos de interacciones, con los estudiantes para quienes sus estimaciones son menos precisas. Consideramos que los estudios que vinculen las (malas) estimaciones de los docentes con la frecuencia y el tipo de interacciones entre estudiantes y docentes son un siguiente paso natural de esta agenda de investigación.


Referencias

- Andrabi, T., Das, J., Khwaja, A. I., Vishwanath, T., & Zajonc, T. (2007). *Learning and Educational Achievements in Punjab Schools (LEAPS): Insights to inform the education policy debate*.
- Araujo, M. C., Carneiro, P., Cruz-Aguayo, Y., & Schady, N. (2016). Teacher quality and learning outcomes in kindergarten. *The Quarterly Journal of Economics*, 131(3), 1415-1453.
- ASER. (2023). *Annual status of education report (ASER) 2022: Provisional*.
- Azam, M., & Kingdon, G. G. (2015). Assessing teacher quality in India. *Journal of Development Economics*, 117, 74-83. <https://doi.org/10.1016/j.jdeveco.2015.07.001>
- Banerjee, A. V., Banerji, R., Berry, J., Duflo, E., Kannan, H., Mukerji, S., Shotland, M., & Walton, M. (2017). From proof to concept to scalable policies: Challenges and solutions, with an application. *Journal of Economic Perspectives*, 31(4), 73-102.
- Banerjee, A. V., Banerji, R., Duflo, E., Glennerster, R., & Khemani, S. (2010). Pitfalls of participatory programs: Evidence from a randomized evaluation in education in India. *American Economic Journal: Economic Policy*, 2, 1-30. <https://doi.org/10.1257/pol.2.1.1>
- Banerjee, A. V., Banerji, R., Duflo, E., & Walton, M. (2011). *Effective pedagogies and a resistant education system: Experimental evidence on interventions to improve basic skills in rural India*.
- Banerjee, A. V., Bhattacharjee, S., Chattopadhyay, R., Ganimian, A. J., Duflo, E., & Spelke, E. (2023). *Street smart or school smart? The arithmetic skills of working children in two Indian cities*. Abdul Latif Jameel Poverty Action Lab (J-PAL).
- Banerjee, A. V., Cole, S., Duflo, E., & Linden, L. (2007). Remedying education: Evidence from two randomized experiments in India. *The Quarterly Journal of Economics*, 122, 1235-1264. <https://doi.org/10.1162/qjec.122.3.1235>
- Banerjee, A. V., & Duflo, E. (2011). Top of the Class. In *Poor Economics: A Radical Rethinking of the Way to Fight Global Poverty*. Public Affairs.
- Bau, N., & Das, J. (2017). *The misallocation of pay and productivity in the public sector: Evidence from the labor market for teachers*. The World Bank.
- Begeny, J. C., Eckert, T. L., Montarello, S. A., & Storie, M. S. (2008). Teachers' perceptions of students' reading abilities: An examination of the relationship between teachers' judgments and students' performance across a continuum of rating methods. *School Psychology Quarterly*, 23(1), 43-55.
- Begeny, J. C., Krouse, H. E., Brown, K. G., & Mann, C. M. (2011). Teacher judgments of students' reading abilities across a continuum of rating methods and achievement measures. *School Psychology Review*, 40(1), 23-38.
- Bénabou, R., & Tirole, J. (2016). Mindful economics: The production, consumption, and value of beliefs. *Journal of Economic Perspectives*, 30(3), 141-164.
- Bhattacharjea, S., Wadhwa, W., & Banerji, R. (2011). *Inside primary schools: A study of teaching and learning in rural India*. ASER.
- Bold, T., Filmer, D. P., Martin, G., Molina, E., Stacy, B., Rockmore, C., Svensson, J., & Wane, W. (2017). Enrollment without learning: Teacher effort, knowledge, and skill in primary schools in Africa. *Journal of Economic Perspectives*, 31(4), 185-204.
- Bruns, B., Filmer, D. P., & Patrinos, H. A. (2011). *Making schools work: New evidence on accountability reforms*. World Bank Publications.
- Bruns, B., & Luque, J. (2014). *Great teachers: How to raise student learning in Latin America and the Caribbean*. The World Bank.

- Buhl-Wiggers, J., Kerwin, J. T., Smith, J. A., & Thornton, R. (2019). *Teacher effectiveness in Africa: Longitudinal and causal estimates*. Department of Economics, Copenhagen Business School.
- Chaudhury, N., Hammer, J., Kremer, M., Muralidharan, K., & Rogers, F. H. (2006). Missing in action: Teacher and health worker absence in developing countries. *The Journal of Economic Perspectives*, 20(1), 91-116.
- de Barros, A., & Ganimian, A. J. (2023). The foundational math skills of Indian children. *Economics of Education Review*, 92, 102336.
- de Hoyos, R., Djaker, S., Ganimian, A. J., & Holland, P. (2023). *Can performance-management tools and training complement diagnostic feedback? Experimental evidence from public schools in Argentina*. New York University.
- de Hoyos, R., Ganimian, A. J., & Holland, P. (2021). Teaching with the test: Experimental evidence on diagnostic feedback and capacity-building for schools in Argentina. *World Bank Economic Review*, 35(2), 499-520.
- de Hoyos, R., García-Moreno, V. A., & Patrinos, H. A. (2017). The impact of an accountability intervention with diagnostic feedback: Evidence from Mexico. *Economics of Education Review*, 58, 123-140.
- Doherty, J., & Conolly, M. (1985). How accurately can primary school teachers predict the scores of their pupils in standardised tests of attainment? A study of some non-cognitive factors that influence specific judgements. *Educational Studies*, 11(1), 41-60.
- Duflo, A., Kiessel, J., & Lucas, A. M. (2020). *Experimental evidence on alternative policies to increase learning at scale*. National Bureau of Economic Research (NBER).
- Duflo, E., Dupas, P., & Kremer, M. (2011). Peer effects, teacher incentives, and the impact of tracking: Evidence from a randomized evaluation in Kenya. *American Economic Review*, 101(5), 1739-1774. <https://doi.org/10.1257/aer.101.5.1739>
- Farfan Bertran, M. G., Holla, A., & Vakis, R. (2021). *Poor expectations: Experimental evidence on teachers' stereotypes and student assessment*. The World Bank.
- Ganimian, A. J., & Djaker, S. (2022). *How can developing countries address heterogeneity in students' preparation for school? A review of the challenge and potential solutions*. Steinhardt School of Culture, Education, and Human Development, New York University.
- Ganimian, A. J., Mbiti, I. M., & Mishra, A. (2024). *Teach for science: Experimental evidence on a STEM teaching fellowship in India*. Steinhardt School of Culture, Education, and Human Development, New York University.
- Hanna, R. N., & Linden, L. L. (2012). Discrimination in grading. *American Economic Journal: Economic Policy*, 4(4), 146-168.
- Hoge, R. D., & Butcher, R. (1984). Analysis of teacher judgments of pupil achievement levels. *Journal of Educational Psychology*, 76(5), 777.
- Hoge, R. D., & Coladarci, T. (1989). Teacher-based judgments of academic achievement: A review of literature. *Review of Educational Research*, 59(3), 297-313.
- IEA. (2017). *TIMSS 2019: Assessment frameworks*. TIMSS & PIRLS International Study Center. Lynch School of Education, Boston College & International Association for the Evaluation of Educational Achievement (IEA).
- Kaufmann, E. (2020). How accurately do teachers' judge students? Re-analysis of Hoge and Coladarci (1989) meta-analysis. *Contemporary Educational Psychology*, 63, 101902.
- Leinhardt, G. (1983). Novice and expert knowledge of individual student's achievement. *Educational Psychologist*, 18(3), 165-179.


- Metzler, J., & Woessmann, L. (2012). The impact of teacher subject knowledge on student achievement: Evidence from within-teacher within-student variation. *Journal of Development Economics*, 99(2), 486-496.
- MEW-DSHE. (2019). *Frameworks for National Assessment of Secondary Students 2019. Subject: Bangla, English, and mathematics. Grades: 6, 8, and 10* Monitoring and Evaluation Wing, Directorate of Secondary and Higher Education (MEW-DSHE).
- Muralidharan, K., Das, J., Holla, A., & Mohpal, A. (2017). The fiscal cost of weak governance: Evidence from teacher absence in India. *Journal of Public Economics*, 145(C), 116-135.
- Muralidharan, K., Singh, A., & Ganimian, A. J. (2019). Disrupting education? Experimental evidence on technology-aided instruction in India. *American Economic Review*, 109(4), 1426-1460.
- Pritchett, L., & Beatty, A. (2015). Slow down, you're going too fast: Matching curricula to student skill levels. *International Journal of Educational Development*, 40, 276-288.
- Raven, J., & Summers, W. A. (1986). Research Supplement No. 3.: A Compendium of North American Normative and Validity Studies. In J. C. Raven, J. H. Court, & J. Raven (Eds.), *Manual for Raven's Progressive Matrices and Vocabulary Tests*. Psychological Corporation.
- Reisinger, J. (2022). Subjective well-being and social desirability. *Journal of Public Economics*, 214, 104745.
- Sabarwal, S., Abu-Jawdeh, M., & Kapoor, R. (2022). Teacher beliefs: Why they matter and what they are. *The World Bank Research Observer*, 37(1), 73-106.
- Sankar, D., & Linden, T. (2014). *How much and what kind of teaching is there in elementary education in India? Evidence from three states*. The World Bank.
- Santibañez, L. (2006). Why we should care if teachers get A's: Teacher test scores and student achievement in Mexico. *Economics of Education Review*, 25(5), 510-520.
- Singh, A. (2019). Learning more with every year: School year productivity and international learning divergence. *Journal of the European Economic Association*, 1-44.
- Stallings, J. A., Knight, S. L., & Markham, D. (2014). *Using the Stallings observation system to investigate time on task in four countries*. The World Bank.
- Südkamp, A., Kaiser, J., & Möller, J. (2012). Accuracy of teachers' judgments of students' academic achievement: A meta-analysis. *Journal of Educational Psychology*, 104(3), 743.
- Urhahne, D., & Wijnia, L. (2021). A review on the accuracy of teacher judgments. *Educational Research Review*, 32, 100374.
- Wadmare, P., Nanda, M., Sabates, R., Sunder, N., & Wadhwa, W. (2022). Understanding the accuracy of teachers' perceptions about low achieving learners in primary schools in rural India: An empirical analysis of alignments and misalignments. *International Journal of Educational Research Open*, 3, 100198.
- World Bank. (2018). *World development report 2018: Learning to realize education's promise*. The World Bank.
- Yen, W. M., & Fitzpatrick, A. R. (2006). Item response theory. In R. L. Brennan (Ed.), *Educational measurement (4th ed.)*. American Council on Education and Praeger Publishers.

Figura 1: Distribución de las diferencias entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes, por país y materia




Notas: Este gráfico muestra la distribución de las diferencias entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes de esos puntajes a nivel de díada estudiante-docente (histograma, eje y izquierdo) y la distribución de las diferencias promedio a nivel de docente (gráfico de densidad, eje y derecho). El Panel A muestra estas distribuciones para la India (donde solo se evaluó matemáticas) y el Panel B las muestra para Bangladesh (donde se evaluaron tanto matemáticas como lengua). En la India, pedimos a los docentes que estimaran los puntajes de 10 estudiantes, y en Bangladesh, de tres estudiantes.

Figura 2: Relación entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes de esos puntajes, por país y materia




Notas: Este gráfico muestra la relación entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes de esos puntajes a nivel de díada estudiante-docente. El Panel A muestra el diagrama de dispersión para la India (donde solo se evaluó matemáticas) y el Panel B los diagramas de dispersión para Bangladesh (donde se evaluaron tanto matemáticas como lengua). En la India, pedimos a cada docente que estimara los puntajes de 10 estudiantes, y en Bangladesh, de tres estudiantes. La línea continua de 45 grados indica dónde se ubicarían los puntos si los puntajes estimados predijeran perfectamente los puntajes reales. La línea discontinua es la línea de mejor ajuste, con el intervalo de confianza del 95% en gris. Agregamos ruido aleatorio esférico a los datos para mostrar la densidad dentro de cada punto.

Figura 3: Relación entre las posiciones de los estudiantes dentro del aula y sus posiciones implícitas dentro del aula según las estimaciones de los docentes, por país y materia




Notas: Este gráfico muestra la relación entre las posiciones de los estudiantes dentro del aula (basadas en sus puntajes reales en las pruebas) y sus posiciones implícitas dentro del aula (basadas en las estimaciones de los docentes sobre sus puntajes) a nivel de diada estudiante-docente. El panel A muestra el diagrama de dispersión para la India (donde solo se evaluó matemáticas) y el panel B, los diagramas de dispersión para Bangladesh (donde se evaluaron tanto matemáticas como lengua). En la India, pedimos a cada docente que estimara los puntajes de 10 estudiantes y, en Bangladesh, los de tres estudiantes. La línea continua de 45 grados indica dónde caerían los puntos si las posiciones estimadas predijeran perfectamente las posiciones reales. La línea discontinua es la recta de mejor ajuste, con el intervalo de confianza del 95% en gris. Añadimos ruido aleatorio esférico a los datos para mostrar la densidad dentro de cada punto.

Figura 4: Relación entre las desviaciones estándar reales de los estudiantes dentro del aula y y sus desviaciones estándar implícitas dentro del aula según las estimaciones de los docentes, por país y materia




Notas: Este gráfico muestra la relación entre las desviaciones estándar de los estudiantes dentro del aula (basadas en sus puntajes reales en las pruebas) y sus desviaciones estándar implícitas dentro del aula (basadas en las estimaciones de los docentes sobre sus puntajes) a nivel de docente. El panel A muestra el diagrama de dispersión para la India (donde solo se evaluó matemáticas) y el panel B, los diagramas de dispersión para Bangladesh (donde se evaluaron tanto matemáticas como lengua). En la India, pedimos a cada docente que estimara los puntajes de 10 estudiantes y, en Bangladesh, los de tres estudiantes. La línea continua de 45 grados indica dónde caerían los puntos si las desviaciones estándar estimadas predijeran perfectamente las desviaciones estándar reales. La línea discontinua es la recta de mejor ajuste, con el intervalo de confianza del 95% en gris. Añadimos ruido aleatorio esférico a los datos para mostrar la densidad dentro de cada punto.

Figura 5: Puntajes de los estudiantes en las pruebas y estimaciones de los docentes sobre esos puntajes, por país, materia y tercil de desempeño dentro del aula




Notas: Este gráfico muestra los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes sobre esos puntajes a nivel de díada estudiante-docente, por tercil de desempeño de los estudiantes dentro del aula. El panel A muestra el diagrama de dispersión para la India (donde solo se evaluó matemáticas) y el panel B, los diagramas de dispersión para Bangladesh (donde se evaluaron tanto matemáticas como lengua). En la India, pedimos a cada docente que estimara los puntajes de 10 estudiantes y, en Bangladesh, los de tres estudiantes.

Figura 6: Porcentaje estimado y real de estudiantes competentes en cada tema en Bangladesh, por materia




Notas: Este gráfico muestra el porcentaje real y estimado de estudiantes “competentes” en cada tema (es decir, estudiantes que responden correctamente todas las preguntas de ese tema) según los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes, respectivamente, a nivel de docente. Solo pedimos a los docentes que proporcionaran estas estimaciones en Bangladesh. El gráfico de la izquierda muestra los resultados de matemáticas y el de la derecha, los de lengua.

Figura 7: Porcentaje estimado y real de estudiantes competentes en ítems seleccionados en Bangladesh, por materia



Notas: Este gráfico muestra el porcentaje real y estimado de estudiantes que pueden responder ítems específicos de cada tema según los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes, respectivamente, a nivel de docente. Solo pedimos a los docentes que proporcionaran estas estimaciones en Bangladesh. El gráfico de la izquierda muestra los resultados de matemáticas y el de la derecha, los de lengua. En matemáticas, los ítems incluyeron: ordenar cuatro números según su valor (números), calcular el área de un rectángulo (medición), hallar la media y la mediana de cinco números (datos), identificar el número de lados de un libro (geometría), identificar el coeficiente de una expresión algebraica (álgebra). En lengua, incluyeron: identificar la causa de un suceso en un párrafo (lectura), encontrar un antónimo (vocabulario) e identificar los componentes de una palabra (gramática). Los parámetros b indican el nivel de habilidad latente necesario para responder un ítem con un 50% de probabilidad: los valores negativos indican ítems más fáciles y los valores positivos, ítems más difíciles.

Figura A.1: Distribución de los puntajes de los estudiantes en las pruebas y de las estimaciones de los docentes, por país y materia



Notas: Este gráfico muestra la distribución de los puntajes de los estudiantes en las pruebas y de las estimaciones de los docentes sobre esos puntajes a nivel de díada estudiante-docente. El panel A muestra estas distribuciones para la India (donde solo se evaluó matemáticas) y el panel B las muestra para Bangladesh (donde se evaluaron tanto matemáticas como lengua). En la India, pedimos a los docentes que estimaran los puntajes de 10 estudiantes y, en Bangladesh, los de tres estudiantes.

por país y

Tabla A.1: Estadísticas descriptivas para la India y Bangladesh

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
	Media	DE	Mín.	Máx.	Pctil. 25	Pctil. 50	Pctil. 75	N (díadas)
<i>A. India</i>								
<u>Matemáticas</u>								
Puntajes reales de los estudiantes	38.9	20.4	0	86	29	43	57	438
Puntajes estimados por los docentes	63.2	23.7	0	100	50	70	80	438
Estimado-real (en p.p.)	24.3	25.1	-47	100	9	24	40	438
Estimado-real (como prop. de la DE dentro del aula)	1.51	1.06	0	5.90	0.75	1.31	2.04	438
<i>B. Bangladesh</i>								
<u>Matemáticas</u>								
Puntajes reales de los estudiantes	56.4	19.9	5	100	42.5	57.5	72.5	605
Puntajes estimados por los docentes	64.8	14.0	20	100	55	65	75	605
Estimado-real (en p.p.)	8.44	23.4	-52.5	82.5	-10	7.5	25	605
Estimado-real (como prop. de la DE dentro del aula)	2.18	2.29	0	17.5	0.68	1.55	2.87	601
<u>Lengua</u>								
Puntajes reales de los estudiantes	69.6	16.7	16.7	100	59.5	73.8	80.9	509
Puntajes estimados por los docentes	62.6	13.9	20	100	50	60	70	509
Estimado-real (en p.p.)	-7.02	20.6	-68.1	56.7	-21.0	-8.81	6.19	509
Estimado-real (como prop. de la DE dentro del aula)	1.87	2.29	0	20.5	0.59	1.25	2.26	506

Notas: Esta tabla muestra estadísticas descriptivas de las principales variables utilizadas en ambos estudios, incluidas: los puntajes reales de los estudiantes en las pruebas, las estimaciones de los docentes sobre esos puntajes (ambos como porcentaje de respuestas correctas, de 0 a 100) y las diferencias entre ambos, expresadas en puntos porcentuales y como proporción de la desviación estándar dentro del aula de los puntajes reales, a nivel de díada estudiante-docente. En la India, calculamos la diferencia promedio entre los puntajes y las estimaciones como proporción de la desviación estándar dentro del aula respecto de los 10 estudiantes sobre los que se pidió a los docentes que proporcionaran estimaciones. En Bangladesh, lo hacemos respecto de todos los estudiantes que rindieron la evaluación nacional (no solo de los tres estudiantes sobre los que se pidió a los docentes que proporcionaran estimaciones).

Tabla A.2: Relación entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes sobre esos puntajes, por país y materia

	(1)	(2)
Puntajes reales de los estudiantes		
<i>A. India</i>		
<u>Matemáticas</u>		
Puntajes estimados por los docentes	0.31*** (0.04)	0.45*** (0.04)
N (díadas)	438	438
R cuadrado	0.130	0.349
<i>B. Bangladesh</i>		
<u>Matemáticas</u>		
Puntajes estimados por los docentes	0.10* (0.06)	0.32*** (0.12)
N (díadas)	605	605
R cuadrado	0.005	0.568
<u>Lengua</u>		
Puntajes estimados por los docentes	0.13** (0.05)	0.44*** (0.11)
N (díadas)	509	509
R cuadrado	0.012	0.379
¿Efectos fijos por docente?	N	Y

Notas: Esta tabla muestra los resultados de regresiones de mínimos cuadrados ordinarios de los puntajes de los estudiantes en las pruebas sobre las estimaciones de los docentes sobre esos puntajes a nivel de díada estudiante-docente, sin (columna 1) y con (columna 2) efectos fijos por docente. El panel A muestra los resultados para la India (donde solo se evaluó matemáticas) y el panel B, para Bangladesh (donde se evaluaron tanto matemáticas como lengua). En la India, pedimos a cada docente que estimara los puntajes de 10 estudiantes y, en Bangladesh, los de tres estudiantes. Los errores estándar (agrupados por docente) aparecen entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.3: Relación entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes sobre esos puntajes, por materia y confianza de los docentes en sus estimaciones, Bangladesh

	(1)	(2)	(3)
	Puntajes reales de los estudiantes		
El docente está...	...totalmente seguro	...muy seguro	...algo seguro
<u>Matemáticas</u>			
Puntajes estimados por los docentes	0.32*** (0.12)	0.07 (0.08)	-0.12 (0.20)
N (díadas)	137	417	51
R cuadrado	0.051	0.003	0.005
<u>Lengua</u>			
Puntajes estimados por los docentes	0.25*** (0.08)	0.04 (0.09)	0.14 (0.12)
N (díadas)	159	266	84
R cuadrado	0.056	0.001	0.011
¿Efectos fijos por docente?	N	N	N

Notas: Esta tabla muestra los resultados de regresiones de mínimos cuadrados ordinarios de los puntajes de los estudiantes en las pruebas sobre las estimaciones de los docentes sobre esos puntajes a nivel de díada estudiante-docente, según el nivel de confianza de los docentes en su estimación, del más alto (totalmente seguro, columna 1) al más bajo (algo seguro, columna 2). Todos los resultados corresponden a Bangladesh, el único país en el que pedimos a los docentes que reportaran su nivel de confianza en sus estimaciones. Los errores estándar (agrupados por docente) aparecen entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.4: Relación entre las posiciones de los estudiantes dentro del aula y sus posiciones implícitas dentro del aula según las estimaciones de los docentes, por país y materia

	(1)	(2)
	Posiciones reales de los estudiantes	
<i>A. India</i>		
<u>Matemáticas</u>		
Posiciones estimadas por los docentes	0.51*** (0.04)	0.51*** (0.04)
N (díadas)	438	438
R cuadrado	0.250	0.253
<i>B. Bangladesh</i>		
<u>Matemáticas</u>		
Posiciones estimadas por los docentes	-0.17*** (0.05)	0.13* (0.07)
N (díadas)	605	605
R cuadrado	0.025	0.059
<u>Lengua</u>		
Posiciones estimadas por los docentes	0.14** (0.06)	0.13* (0.08)
N (díadas)	509	509
R cuadrado	0.016	0.044
¿Efectos fijos por docente?	N	Y

Notas: Esta tabla muestra los resultados de regresiones de mínimos cuadrados ordinarios de las posiciones de los estudiantes dentro del aula (basadas en sus puntajes reales en las pruebas) sobre sus posiciones implícitas dentro del aula (basadas en las estimaciones de los docentes sobre sus puntajes) a nivel de díada estudiante-docente, sin (columna 1) y con (columna 2) efectos fijos por docente. El panel A muestra los resultados para la India (donde solo se evaluó matemáticas) y el panel B, para Bangladesh (donde se evaluaron tanto matemáticas como lengua). En la India, pedimos a cada docente que estimara los puntajes de 10 estudiantes y, en Bangladesh, los de tres estudiantes. Los errores estándar (agrupados por docente) aparecen entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.5: Relación entre las desviaciones estándar reales de los estudiantes dentro del aula y sus desviaciones estándar implícitas dentro del aula según las estimaciones de los docentes, por país y materia

	(1) DE real de los estudiantes dentro del aula
<i>A. India</i>	
<u>Matemáticas</u>	
DE estimada por los docentes dentro del aula	0.05 (0.08)
N (docentes)	46
R cuadrado	0.011
<i>B. Bangladesh</i>	
<u>Matemáticas</u>	
DE estimada por los docentes dentro del aula	0.12 (0.09)
N (docentes)	202
R cuadrado	0.007
<u>Lengua</u>	
DE estimada por los docentes dentro del aula	-0.05 (0.10)
N (docentes)	173
R cuadrado	0.001

Notas: Esta tabla muestra los resultados de regresiones de mínimos cuadrados ordinarios de las desviaciones estándar de los estudiantes dentro del aula (basadas en sus puntajes reales en las pruebas) sobre sus desviaciones estándar implícitas dentro del aula (basadas en las estimaciones de los docentes sobre sus puntajes) a nivel de docente. El panel A muestra los resultados para la India (donde solo se evaluó matemáticas) y el panel B, para Bangladesh (donde se evaluaron tanto matemáticas como lengua). En la India, pedimos a cada docente que estimara los puntajes de 10 estudiantes y, en Bangladesh, los de tres estudiantes. Los errores estándar (agrupados por docente) aparecen entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.6: Puntajes de los estudiantes en las pruebas y estimaciones de los docentes sobre esos puntajes, por país, materia y tercil de desempeño dentro del aula

	(1) Puntajes reales de los estudiantes	(2) Puntajes estimados por los docentes	(3) Col. (2)-(1)	(4)
<i>A. India</i>				
<u>Matemáticas</u>				
Estudiantes en el tercil más bajo dentro del aula	21.2	51.5	30.3***	30.3***
	[16.2]	[24.6]	(3.08)	(3.30)
Estudiantes en el tercil medio dentro del aula	44.7	68.3	23.6***	23.6***
	[9.78]	[19.7]	(2.37)	(2.59)
Estudiantes en el tercil más alto dentro del aula	59.5	75.4	15.9***	15.9***
	[9.69]	[18.1]	(2.37)	(2.65)
N (díadas)	438	438	438	438
<i>B. Bangladesh</i>				
<u>Matemáticas</u>				
Estudiantes en el tercil más bajo dentro del aula	44.8	64.3	18.5***	18.6***
	[19.4]	[13.7]	(1.86)	(2.29)
Estudiantes en el tercil medio dentro del aula	59.6	64.6	5.01***	5.18**
	[13.6]	[14.7]	(1.65)	(2.15)
Estudiantes en el tercil más alto dentro del aula	72.8	66.6	-6.17***	-6.05***
	[12.9]	[13.6]	(1.66)	(2.26)
N (díadas)	567	567	567	567
<u>Lengua</u>				
Estudiantes en el tercil más bajo dentro del aula	55.5	60.3	4.84***	5.02**
	[15.5]	[13.0]	(1.77)	(2.29)
Estudiantes en el tercil medio dentro del aula	74.1	63.0	-11.1***	-11.0***
	[10.5]	[14.6]	(1.49)	(1.96)
Estudiantes en el tercil más alto dentro del aula	82.8	64.9	-17.9***	-17.9***
	[6.72]	[12.8]	(1.15)	(1.53)
N (díadas)	477	477	477	477
¿Efectos fijos por docente?			N	Y

Notas: Esta tabla muestra la media y la desviación estándar de los puntajes de los estudiantes en las pruebas (columna 1) y de las estimaciones de los docentes sobre esos puntajes (columna 2) y luego estima la diferencia entre

ambos según el tercil de desempeño de los estudiantes dentro del aula a nivel de díada estudiante-docente, sin (columna 3) y con (columna 4) efectos fijos por docente. El panel A muestra los resultados para la India (donde solo se evaluó matemáticas) y el panel B, para Bangladesh (donde se evaluaron tanto matemáticas como lengua). En la India, pedimos a cada docente que estimara los puntajes de 10 estudiantes y, en Bangladesh, los de tres estudiantes. Las desviaciones estándar aparecen entre corchetes y los errores estándar (agrupados por docente), entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.7: Puntajes de los estudiantes en las pruebas y estimaciones de los docentes sobre esos puntajes en Bangladesh, por materia y tercil de desempeño nacional

	(1) Puntajes reales de los estudiantes	(2) Puntajes estimados por los docentes	(3) Col. (2)-(1)	(4)
<u>Matemáticas</u>				
Estudiantes en el tercil nacional más bajo	33.7	64.0	30.4***	30.4***
	[9.37]	[14.2]	(1.43)	(1.79)
Estudiantes en el tercil nacional medio	57.7	64.2	6.52***	6.52***
	[7.03]	[14.8]	(1.25)	(1.64)
Estudiantes en el tercil nacional más alto	79.1	66.0	-13.0***	-13.0***
	[7.69]	[12.7]	(1.22)	(1.57)
N (díadas)	567	567	567	567
<u>Lengua</u>				
Estudiantes en el tercil nacional más bajo	48.1	62.1	14.0***	14.0***
	[11.4]	[12.5]	(1.59)	(2.11)
Estudiantes en el tercil nacional medio	72.3	61.4	-10.9***	-10.9***
	[4.53]	[13.8]	(1.23)	(1.61)
Estudiantes en el tercil nacional más alto	85.3	65.2	-20.1***	-20.1***
	[4.13]	[13.9]	(1.18)	(1.57)
N (díadas)	477	477	477	477
¿Efectos fijos por docente?			N	Y

Notas: Esta tabla muestra la media y la desviación estándar de los puntajes de los estudiantes en las pruebas (columna 1) y de las estimaciones de los docentes sobre esos puntajes (columna 2) y luego estima la diferencia entre ambos según el tercil de desempeño nacional de los estudiantes a nivel de díada estudiante-docente, sin (columna 3) y con (columna 4) efectos fijos por docente. Solo muestra resultados para Bangladesh, donde observamos el desempeño de los estudiantes respecto de todos los que rindieron la prueba en el país. En Bangladesh, pedimos a cada docente que estimara los puntajes de tres estudiantes. Las desviaciones estándar aparecen entre corchetes y los errores estándar (agrupados por docente), entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.8: Puntajes de los estudiantes en las pruebas de matemáticas y estimaciones de los docentes de esos puntajes en la India, por cuartil de inteligencia fluida de los estudiantes

	(1)	(2)	(3)	(4)
	Puntajes reales de los estudiantes	Puntajes estimados por los docentes	Col. (2)-(1)	
Estudiantes del cuartil 1 (más bajo)	30.7	51.7	21.0***	21.0***
	[19.3]	[26.0]	(3.72)	(4.09)
Estudiantes del cuartil 2	38.6	63.2	24.6***	24.6***
	[20.1]	[21.3]	(2.68)	(2.88)
Estudiantes del cuartil 3	48.9	69.5	20.6***	20.6***
	[16.1]	[22.8]	(3.85)	(4.47)
Estudiantes del cuartil 4 (más alto)	44.8	75.1	30.3***	30.3***
	[20.5]	[17.9]	(2.86)	(3.17)
N (díadas)	438	438	438	438
¿Efectos fijos por docente?			N	Y

Notas: Esta tabla muestra la media y la desviación estándar de los puntajes de los estudiantes en las pruebas (columna 1) y de las estimaciones de los docentes de esos puntajes (columna 2) y luego estima la diferencia entre ellos según el cuartil de inteligencia fluida de los estudiantes a nivel de díada estudiante-docente, sin (columna 3) y con (columna 4) efectos fijos por docente. Solo muestra resultados para la India, donde observamos la inteligencia fluida de los estudiantes. En la India, los docentes solo estimaron los puntajes de los estudiantes en matemáticas. Las desviaciones estándar aparecen entre corchetes y los errores estándar (agrupados por docente) aparecen entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.9: Puntajes de los estudiantes en las pruebas de matemáticas y estimaciones de los docentes de esos puntajes en la India, por sexo del estudiante y del docente

	(1) Puntajes reales de los estudiantes	(2) Puntajes estimados por los docentes	(3) Col. (2)-(1)	(4)
<u>Todos los docentes</u>				
Estudiantes varones	39.4 [20.1]	61.5 [24.8]	22.1*** (2.89)	22.1*** (3.04)
Estudiantes mujeres	38.7 [20.3]	65.52 [22.37]	26.8*** (2.77)	26.8*** (2.91)
N (díadas)	430	430	430	430
<u>Docentes varones</u>				
Estudiantes varones	36.0 [15.8]	64.5 [19.4]	28.5*** (3.80)	28.5*** (3.99)
Estudiantes mujeres	36.9 [16.8]	67.6 [18.0]	30.6** (8.79)	30.6** (9.17)
N (díadas)	82	82	82	82
<u>Docentes mujeres</u>				
Estudiantes varones	40.1 [20.9]	60.8 [25.7]	20.7*** (3.36)	20.7*** (3.53)
Estudiantes mujeres	39.1 [21.1]	65.0 [23.4]	25.9*** (2.69)	25.9*** (2.82)
N (díadas)	348	348	348	348
¿Efectos fijos por docente?			N	Y

Notas: Esta tabla muestra la media y la desviación estándar de los puntajes de los estudiantes en las pruebas (columna 1) y de las estimaciones de los docentes de esos puntajes (columna 2) y luego estima la diferencia entre ellos según el sexo del estudiante y del docente a nivel de díada estudiante-docente, sin (columna 3) y con (columna 4) efectos fijos por docente. Solo muestra resultados para la India, donde observamos tanto el sexo del estudiante como el del docente. En la India, los docentes solo estimaron los puntajes de los estudiantes en matemáticas. Las desviaciones estándar aparecen entre corchetes y los errores estándar (agrupados por docente) aparecen entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.10: Puntajes de los estudiantes en las pruebas de matemáticas y estimaciones de los docentes de esos puntajes en la India, por nivel socioeconómico del estudiante

	(1)	(2)	(3)	(4)
	Puntajes reales de los estudiantes	Puntajes estimados por los docentes	Col. (2)-(1)	
Estudiantes del cuartil 1 (más pobres)	38.6	62.5	23.9***	23.9***
	[21.3]	[25.1]	(3.19)	(3.43)
Estudiantes del cuartil 2	39.3	67.6	28.3***	28.3***
	[20.5]	[21.5]	(3.14)	(3.56)
Estudiantes del cuartil 3	39.3	62.1	22.7***	22.7***
	[18.8]	[24.4]	(2.94)	(3.19)
Estudiantes del cuartil 4 (más ricos)	39.2	62.8	23.6***	23.6***
	[20.3]	[21.0]	(3.41)	(3.94)
N (díadas)	430	430	430	430
¿Efectos fijos por docente?			N	Y

Notas: Esta tabla muestra la media y la desviación estándar de los puntajes de los estudiantes en las pruebas (columna 1) y de las estimaciones de los docentes de esos puntajes (columna 2) y luego estima la diferencia entre ellos según el cuartil de un índice de bienes del hogar de los estudiantes a nivel de díada estudiante-docente, sin (columna 3) y con (columna 4) efectos fijos por docente. Solo muestra resultados para la India, donde observamos el nivel socioeconómico de los estudiantes a través de los bienes de su hogar. En la India, los docentes solo estimaron los puntajes de los estudiantes en matemáticas. Las desviaciones estándar aparecen entre corchetes y los errores estándar (agrupados por docente) aparecen entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.11: Puntajes de los estudiantes en las pruebas de matemáticas y estimaciones de los docentes de esos puntajes en la India, por casta o tribu del estudiante

	(1) Puntajes reales de los estudiantes	(2) Puntajes estimados por los docentes	(3) Col. (2)-(1)	(4)
Estudiantes de casta registrada	36.7 [20.4]	61.9 [23.8]	25.2*** (2.55)	25.2*** (2.69)
Estudiantes de tribu registrada	48.0 [26.6]	71.6 [14.6]	23.6* (10.4)	23.6 (14.7)
Estudiantes de otras castas atrasadas	41.9 [22.4]	70.0 [23.4]	28.1*** (5.39)	28.1 (6.41)
Estudiantes de otras categorías generales	39.6 [19.6]	64.1 [23.4]	24.5*** (2.60)	24.5*** (2.80)
N (díadas)	421	421	421	421
¿Efectos fijos por docente?			N	Y

Notas: Esta tabla muestra la media y la desviación estándar de los puntajes de los estudiantes en las pruebas (columna 1) y de las estimaciones de los docentes de esos puntajes (columna 2) y luego estima la diferencia entre ellos según la casta o tribu de los estudiantes a nivel de díada estudiante-docente, sin (columna 3) y con (columna 4) efectos fijos por docente. Solo muestra resultados para la India, donde observamos el nivel socioeconómico de los estudiantes a través de los bienes de su hogar. En la India, los docentes solo estimaron los puntajes de los estudiantes en matemáticas. Las desviaciones estándar aparecen entre corchetes y los errores estándar (agrupados por docente) aparecen entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.12: Relación entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes de esos puntajes por país, materia y características de los docentes

	(1)	(2)	(3)
	Puntajes reales de los estudiantes		
	Docentes con maestría	Docentes con certificación	Docentes con experiencia superior a la mediana
<i>A. India</i>			
<u>Matemáticas</u>			
Puntajes estimados por los docentes	0.38*** (0.05)	0.37*** (0.07)	0.29*** (0.05)
Covariable	7.60 (6.65)	6.83 (4.20)	-3.41 (6.30)
Interacción	-0.17* (0.09)	-0.03 (0.02)	0.04 (0.09)
N (díadas)	438	438	438
R cuadrado	0.146	0.139	0.131
<i>B. Bangladesh</i>			
<u>Matemáticas</u>			
Puntajes estimados por los docentes	0.10 (0.11)	0.07 (0.12)	0.22*** (0.08)
Covariable	-0.09 (8.82)	-1.74 (9.68)	14.9* (7.81)
Interacción	<0.01 (0.13)	0.04 (0.14)	-0.22* (0.12)
N (díadas)	605	605	605
R cuadrado	0.005	0.006	0.012
<u>Lengua</u>			
Puntajes estimados por los docentes	0.12 (0.08)	0.10 (0.08)	0.11 (0.07)
Covariable	2.27 (6.79)	-1.27 (6.80)	-3.57 (6.82)
Interacción	0.01 (0.11)	0.05 (0.11)	0.04 (0.11)
N (díadas)	509	509	509
R cuadrado	0.019	0.014	0.013

Notas: Esta tabla muestra los resultados de regresiones por mínimos cuadrados ordinarios de los puntajes de los estudiantes en las pruebas sobre las estimaciones de los docentes de esos puntajes, una covariable a nivel de docente (tener una maestría, un certificado docente o una experiencia docente superior a la mediana) y su interacción con las estimaciones a nivel de díada estudiante-docente. El panel A muestra los resultados para la India (donde solo se evaluó matemáticas) y el panel B para Bangladesh (donde se evaluaron tanto matemáticas como lengua). En la India, pedimos a cada docente que estimara los puntajes de 10 estudiantes, y en Bangladesh, de tres estudiantes. Los errores estándar (agrupados por docente) aparecen entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.13: Porcentaje de estudiantes reconocidos por los docentes en Bangladesh, según si son reales o ficticios, materia y tercil de desempeño

	(1) General	(2) Distribución dentro del aula	(3) Distribución nacional
<u>Matemáticas</u>			
Todos los estudiantes ficticios	28.5 [45.2]		
Todos los estudiantes reales	73.6 [44.1]		
Estudiantes del tercil inferior		74.2 [43.8]	75.2 [43.2]
Estudiantes del tercil medio		71.9 [45.0]	72.6 [44.6]
Estudiantes del tercil superior		74.8 [43.5]	73.2 [44.3]
N (díadas)	1,689	1,689	1,689
<u>Lengua</u>			
Todos los estudiantes ficticios	31.1 [46.4]		
Todos los estudiantes reales	76.3 [42.5]		
Estudiantes del tercil inferior		74.5 [43.6]	76.6 [42.4]
Estudiantes del tercil medio		77.6 [41.8]	75.4 [43.1]
Estudiantes del tercil superior		77.4 [41.9]	77.3 [41.9]
N (díadas)	1,528	1,528	1,528

Notas: Esta tabla muestra el porcentaje de estudiantes que fueron reconocidos por los docentes de matemáticas y lengua, según si eran reales o ficticios (columna 1) y—entre los estudiantes reales—su tercil de desempeño en la distribución dentro del aula (columna 2) o nacional (columna 3), en Bangladesh. Las desviaciones estándar aparecen entre corchetes.

Tabla A.14: Porcentaje estimado y real de estudiantes en cada tercil de la distribución nacional de desempeño en Bangladesh, por materia

	(1) Porcentaje real de estudiantes	(2) Porcentaje estimado por los docentes	(3) Col. (2)-(1)
<u>Matemáticas</u>			
Estudiantes en el tercil nacional más bajo	47.0 [30.2]	27.8 [18.7]	-19.2*** (2.95)
Estudiantes en el tercil nacional medio	41.6 [23.1]	37.3 [13.9]	-4.26** (2.13)
Estudiantes en el tercil nacional más alto	38.7 [32.0]	34.8 [20.1]	-3.86 (2.80)
N (docentes)	222	222	222
<u>Lengua</u>			
Estudiantes en el tercil nacional más bajo	40.9 [25.6]	26.4 [19.1]	-14.5*** (2.89)
Estudiantes en el tercil nacional medio	38.9 [19.3]	35.3 [15.4]	-3.53 (2.30)
Estudiantes en el tercil nacional más alto	32.9 [26.9]	38.3 [23.4]	5.43* (3.08)
N (docentes)	191	191	191

Notas: Esta tabla muestra el porcentaje real de estudiantes en cada tercil de la distribución nacional de desempeño (columna 1) y las estimaciones de los docentes de esos porcentajes (columna 2) y luego estima la diferencia entre ellos a nivel de docente (columna 3). Solo muestra resultados para Bangladesh, donde observamos los porcentajes reales y estimados de estudiantes en cada tercil. Las desviaciones estándar aparecen entre corchetes y los errores estándar (agrupados por docente) aparecen entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.15: Porcentaje estimado y real de estudiantes competentes en cada tema en Bangladesh, por materia

	(1)	(2)	(3)
	Porcentaje real de estudiantes	Porcentaje estimado por los docentes	Col. (2)-(1)
<u>Matemáticas</u>			
Números	1.68 [6.15]	55.7 [19.6]	54.0*** (1.37)
Medición	9.57 [19.0]	53.3 [21.0]	43.7*** (1.87)
Datos	16.4 [25.0]	62.8 [21.6]	46.4*** (2.24)
Geometría	3.01 [12.7]	53.0 [20.2]	50.0*** (1.63)
Álgebra	8.16 [21.1]	64.3 [18.9]	56.1*** (1.94)
N (docentes)	222	222	222
<u>Lengua</u>			
Lectura	0.19 [1.45]	57.8 [20.4]	57.7*** (1.50)
Vocabulario	34.3 [25.9]	51.7 [20.4]	17.4*** (2.49)
Gramática	32.8 [26.8]	52.2 [20.6]	19.5*** (2.36)
N (docentes)	191	191	191

Notas: Esta tabla muestra el porcentaje real de estudiantes que son competentes en cada materia (columna 1) y las estimaciones de los docentes de esos porcentajes (columna 2) y luego estima la diferencia entre ellos a nivel de docente (columna 3). Solo muestra resultados para Bangladesh, donde observamos los porcentajes reales y estimados por tema. Pedimos a los docentes que clasificaran a un estudiante como competente en un tema si era “capaz de responder *todos* los ítems de ese tema”. Las desviaciones estándar aparecen entre corchetes y los errores estándar (agrupados por docente) aparecen entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.16: Porcentaje estimado y real de estudiantes que responden correctamente ítems seleccionados en Bangladesh, por materia

	(1)	(2)	(3)
	Porcentaje real de estudiantes	Porcentaje estimado por los docentes	Col. (2)-(1)
<u>Matemáticas</u>			
Números ($b=1.97$)	14.7 [21.0]	67.9 [21.3]	53.3*** (2.02)
Medición ($b=-1.19$)	82.7 [20.8]	69.1 [21.6]	-13.7*** (2.02)
Datos ($b=0.79$)	61.9 [28.0]	68.9 [19.7]	6.92*** (2.48)
Geometría ($b=-0.64$)	60.3 [31.5]	55.7 [25.3]	-4.63 (2.83)
Álgebra ($b=-1.63$)	82.1 [16.4]	56.3 [21.3]	-25.8*** (1.86)
N (docentes)	222	222	222
<u>Lengua</u>			
Lectura ($b=-1.22$)	74.9 [20.0]	59.3 [23.2]	-15.7*** (2.16)
Vocabulario ($b=-1.70$)	82.7 [16.8]	53.6 [20.8]	-29.1*** (1.94)
Gramática ($b=-1.08$)	69.8 [22.4]	49.3 [23.5]	-20.5*** (2.21)
N (docentes)	191	191	191

Notas: Esta tabla muestra los porcentajes reales de estudiantes que pueden responder ítems específicos de cada tema (columna 1) y las estimaciones de los docentes de esos porcentajes (columna 2) y luego estima la diferencia entre ellos a nivel de docente (columna 3). Solo muestra resultados para Bangladesh, donde observamos los porcentajes reales y estimados por ítem. En matemáticas, los ítems incluyeron: ordenar cuatro números según su valor (números), calcular el área de un rectángulo (medición), hallar la media y la mediana de cinco números (datos), identificar el coeficiente en una expresión algebraica (álgebra) e identificar el número de lados de un libro (geometría). En lengua, incluyeron: rastrear la causa de un suceso en un párrafo (lectura), hallar un antónimo (vocabulario) e identificar los componentes de una palabra (gramática). Las desviaciones estándar aparecen entre corchetes y los errores estándar (agrupados por docente) aparecen entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.17: Porcentaje estimado y real de estudiantes que pueden responder correctamente ítems seleccionados en Bangladesh, por materia y tercil de la distribución de desempeño

	(1)	(2)	(3)	(4)	(5)	(6)
	Porcentaje real de estudiantes	Porcentaje estimado por los docentes	Col. (2)- (1)	Porcentaje real de estudiantes	Porcentaje estimado por los docentes	Col. (5)- (4)
<i>A. Matemáticas</i>	Medición ($b=-1.47$)			Álgebra ($b=-1.41$)		
<u>Distribución dentro del aula</u>						
Estudiantes del tercil inferior	69.5	84.9	15.4***	72.9	77.4	4.46
	[46.1]	[35.9]	(3.96)	[44.5]	[41.9]	(3.95)
Estudiantes del tercil medio	89.5	85.6	-3.99	89.5	80.4	-9.19**
	[30.7]	[32.3]	(3.33)	[30.7]	[39.9]	(4.23)
Estudiantes del tercil superior	96.4	90.6	-5.77*	95.6	85.5	-10.1***
	[18.8]	[29.3]	(3.06)	[20.5]	[35.3]	(3.47)
N (días)	567	567	567	567	567	567
<u>Distribución nacional</u>						
Estudiantes del tercil inferior	56.2	84.5	28.4***	65.5	75.8	10.3***
	[49.7]	[36.3]	(4.76)	[47.7]	[43.0]	(4.80)
Estudiantes del tercil medio	91.0	84.5	-6.50**	88.5	80.5	-8.00**
	[28.7]	[36.3]	(3.26)	[32.0]	[39.7]	(4.02)
Estudiantes del tercil superior	100	90.8	-9.25***	97.1	86.1	-11.0***
	[0.00]	[29.1]	(2.15)	[16.8]	[34.7]	(2.98)
N (días)	567	567	567	567	567	567
<i>B. Lengua</i>	Lectura ($b=-1.29$)			Vocabulario ($b=2.28$)		
<u>Distribución dentro del aula</u>						
Estudiantes del tercil inferior	57.4	86.5	29.2***	62.6	91.2	28.6***
	[49.6]	[34.2]	(4.50)	[48.5]	[28.4]	(4.37)
Estudiantes del tercil medio	81.3	87.7	6.48	80.6	88.3	7.72*
	[39.2]	[32.9]	(4.21)	[39.7]	[32.2]	(4.17)
Estudiantes del tercil superior	94.1	87.5	-6.57*	95.6	94.9	-0.70
	[23.7]	[33.2]	(3.49)	[20.7]	[22.2]	(2.22)
N (días)	492	492	492	492	492	492
<u>Distribución nacional</u>						

Estudiantes del tercil inferior	46.85	86.0	39.2***	52.5	90.2	37.8***
	[50.1]	[34.8]	(5.21)	[50.1]	[29.8]	(5.35)
Estudiantes del tercil medio	81.9	88.1	6.21	81.9	89.3	7.34*
	[38.6]	[32.4]	(4.03)	[38.6]	[31.0]	(3.77)
Estudiantes del tercil superior	95.5	87.3	-8.28***	97.5	93.6	-3.82
	[20.7]	[33.5]	(3.16)	[15.8]	[24.5]	(2.38)
N (díadas)	477	477	477	477	477	477

Notas: Esta tabla muestra los porcentajes reales de estudiantes específicos que pueden responder ítems específicos (columnas 1 y 4) y las estimaciones de los docentes de esos porcentajes (columnas 2 y 5) y luego estima la diferencia entre ellos a nivel de díada estudiante-docente (columnas 3 y 6). Solo muestra resultados para Bangladesh, donde observamos los porcentajes reales y estimados por ítem. En matemáticas, los ítems incluyeron: calcular el área de un rectángulo (medición) e identificar el coeficiente en una expresión algebraica (álgebra). En lengua, incluyeron: identificar el tema principal de un pasaje (lectura) y hallar la palabra para un animal que puede vivir en la tierra y en el agua (vocabulario). Las desviaciones estándar aparecen entre corchetes y los errores estándar (agrupados por docente) aparecen entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.18: Relación entre los puntajes de los estudiantes en las pruebas y las estimaciones de los docentes de esos puntajes omitiendo las estimaciones en o alrededor del 60%, por país y materia

	(1)	(2)	(3)	(4)
	Puntajes reales de los estudiantes			
	Omitiendo estimaciones exactamente en 60%		Omitiendo estimaciones a menos de 5 p.p. de 60%	
<i>A. India</i>				
<u>Matemáticas</u>				
Puntajes estimados por los docentes	0.31***	0.44***	0.31***	0.45***
	(0.04)	(0.04)	(0.04)	(0.04)
N (díadas)	388	388	362	362
R cuadrado	0.146	0.363	0.153	0.379
<i>B. Bangladesh</i>				
<u>Matemáticas</u>				
Puntajes estimados por los docentes	0.09	0.36***	0.09	0.38***
	(0.06)	(0.14)	(0.06)	(0.14)
N (díadas)	477	477	429	429
R cuadrado	0.005	0.647	0.006	0.671
<u>Lengua</u>				
Puntajes estimados por los docentes	0.12**	0.49***	0.11**	0.51***
	(0.05)	(0.13)	(0.05)	(0.16)
N (díadas)	412	412	348	348
R cuadrado	0.012	0.455	0.013	0.517
¿Efectos fijos por docente?	N	Y	N	Y

Notas: Esta tabla muestra los resultados de regresiones por mínimos cuadrados ordinarios de los puntajes de los estudiantes en las pruebas sobre las estimaciones de los docentes de esos puntajes a nivel de díada estudiante-docente, omitiendo las estimaciones exactamente en o a menos de 5 p.p. de 60%, sin (columnas 1 y 3) y con (columnas 2 y 4) efectos fijos por docente. El panel A muestra los resultados para la India (donde solo se evaluó matemáticas) y el panel B para Bangladesh (donde se evaluaron tanto matemáticas como lengua). En la India, pedimos a cada docente que estimara los puntajes de 10 estudiantes, y en Bangladesh, de tres estudiantes. Los errores estándar (agrupados por docente) aparecen entre paréntesis. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.19: Resumen de los resultados principales, por país y materia

	(1) Matem.	(2) Matem.	(3) Lengua
<i>A. La magnitud de los errores de los docentes es grande</i>			
Puntajes estimados-reales (en p.p.)	24.3	8.44	-7.02
Puntajes estimados-reales (como prop. de la DE dentro del aula)	1.51	2.18	1.87
Correlación de Pearson entre puntajes estimados y reales	0.36	0.07	0.11
Coef. MCO de puntajes reales sobre estimados	0.31	0.10	0.13
Coef. MCO de puntajes reales sobre estimados (con EF por docente)	0.45	0.32	0.44
<i>B. Los docentes no saben que están cometiendo errores</i>			
Porc. de docentes “totalmente seguros” o “muy seguros” de sus estimaciones	-	91	83
Coef. MCO de puntajes reales sobre estimados (solo “totalmente seguro”)	-	0.32	0.25
Coef. MCO de puntajes reales sobre estimados (solo “muy seguro”)	-	0.07	0.04
Coef. MCO de puntajes reales sobre estimados (solo “algo seguro”)	-	-0.12	0.14
<i>C. Los docentes no saben cómo se comparan sus estudiantes entre sí</i>			
Correlación de Spearman entre puntajes estimados y reales	0.35	0.07	0.11
Coef. MCO de posiciones reales sobre estimadas	0.51	-0.17	0.14
Coef. MCO de posiciones reales sobre estimadas (con EF por docente)	0.51	0.13	0.13
Porc. de docentes con ordenamientos “invertidos”	-	11	12
<i>D. Los docentes subestiman cuánto varían sus estudiantes</i>			
Porc. de docentes que subestiman la DE dentro del aula	54	77	78
Correlación de Pearson entre las DE dentro del aula estimadas y reales	0.08	0.08	-0.03
Coef. MCO de la DE dentro del aula real sobre la estimada	0.05	0.12	-0.05
<i>E. Los docentes sobreestiman los puntajes de los estudiantes de bajo desempeño</i>			
Coef. MCO de puntajes reales sobre estimados (tercil inferior dentro del aula)	30.3	18.5	4.84
Coef. MCO de puntajes reales sobre estimados (tercil medio dentro del aula)	23.6	5.01	-11.1
Coef. MCO de puntajes reales sobre estimados (tercil superior dentro del aula)	15.9	-6.17	-17.9
Coef. MCO de puntajes reales sobre estimados (tercil inferior nacional)	-	30.4	14.0
Coef. MCO de puntajes reales sobre estimados (tercil medio nacional)	-	6.52	-10.9
Coef. MCO de puntajes reales sobre estimados (tercil superior nacional)	-	-13.0	-20.1
<i>F. Los docentes sobrevaloran la importancia de la inteligencia para los puntajes en las pruebas</i>			
Coef. MCO de puntajes reales sobre estimados (cuartil inferior, inteligencia fluida)	21.0	-	-
Coef. MCO de puntajes reales sobre estimados (segundo cuartil, inteligencia fluida)	24.6	-	-
Coef. MCO de puntajes reales sobre estimados (tercer cuartil, inteligencia fluida)	20.6	-	-
Coef. MCO de puntajes reales sobre estimados (tercil superior, inteligencia fluida)	30.3	-	-
<i>G. Los docentes sobreestiman los puntajes de las niñas en mayor medida que los de los niños</i>			
Coef. MCO de puntajes reales sobre estimados (todos los docentes, estudiantes varones)	22.1	-	-
Coef. MCO de puntajes reales sobre estimados (todos los docentes, estudiantes mujeres)	26.8	-	-
Coef. MCO de puntajes reales sobre estimados (docentes varones, estudiantes varones)	28.5	-	-
Coef. MCO de puntajes reales sobre estimados (docentes varones, estudiantes mujeres)	30.6	-	-
Coef. MCO de puntajes reales sobre estimados (docentes mujeres, estudiantes varones)	20.7	-	-
Coef. MCO de puntajes reales sobre estimados (docentes mujeres, estudiantes mujeres)	25.9	-	-
<i>H. Los docentes sobreestiman de forma similar los puntajes de estudiantes de ingresos bajos y altos</i>			
Coef. MCO de puntajes reales sobre estimados (cuartil inferior, NSE)	23.9	-	-
Coef. MCO de puntajes reales sobre estimados (segundo cuartil, NSE)	28.3	-	-
Coef. MCO de puntajes reales sobre estimados (tercer cuartil, NSE)	22.7	-	-
Coef. MCO de puntajes reales sobre estimados (tercil superior, NSE)	23.6	-	-
<i>I. Los docentes sobreestiman de forma similar los puntajes de estudiantes de ingresos bajos y altos</i>			
Coef. MCO de puntajes reales sobre estimados (casta registrada)	25.2	-	-
Coef. MCO de puntajes reales sobre estimados (tribu registrada)	23.6	-	-
Coef. MCO de puntajes reales sobre estimados (otras castas atrasadas)	28.1	-	-
Coef. MCO de puntajes reales sobre estimados (otras categorías generales)	24.5	-	-
<i>J. Los docentes con más educación, formación y experiencia no son más precisos</i>			
Media de la interacción en MCO de puntajes reales sobre estimados (docentes con maestría)	0.21	0.10	0.13
Media de la interacción en MCO de puntajes reales sobre estimados (docentes con	0.34	0.11	0.15

certificación)			
Media de la interacción en MCO de puntajes reales sobre estimados (docentes con maestría)	0.33	0	0.15

Notas: Esta tabla ofrece un resumen de todos los resultados principales presentados en el artículo. Para los paneles E-I, omitimos las estimaciones con efectos fijos por docente porque son muy similares a las estimaciones sin ellos (véanse las tablas A.6-A.11 para los resultados completos). DE se refiere a desviación estándar. EF se refiere a efectos fijos. NSE se refiere a nivel socioeconómico. Media de la interacción se refiere a la suma del primer y el tercer coeficiente en cada regresión de la tabla A.12.

Tabla A.20: Resumen de las pruebas de robustez, Bangladesh, por materia

	(1) Matem	(2) Lengua
<i>A. Los errores no se deben a un enfoque en habilidades no evaluadas</i>		
Porc. de docentes que creen que la prueba evalúa lo que enseñan (en medida “alta” o “moderada”)	96	96
<i>B. Los errores no se deben a que los docentes no reconozcan a los estudiantes</i>		
Porc. de estudiantes reconocidos (todos los estudiantes ficticios)	28.5	31.1
Porc. de estudiantes reconocidos (todos los estudiantes reales)	73.6	76.3
Porc. de estudiantes reconocidos (tercil inferior dentro del aula)	74.2	74.5
Porc. de estudiantes reconocidos (tercil medio dentro del aula)	71.9	77.6
Porc. de estudiantes reconocidos (tercil superior dentro del aula)	74.8	77.4
Porc. de estudiantes reconocidos (tercil inferior nacional)	75.2	76.6
Porc. de estudiantes reconocidos (tercil medio nacional)	72.6	75.4
Porc. de estudiantes reconocidos (tercil superior nacional)	73.2	77.3
<i>C. Los errores no se deben a la dificultad de estimar puntajes en las pruebas</i>		
Coef. MCO del porc. real sobre el estimado de estudiantes en el tercil inferior nacional	-19.2	-14.5
Coef. MCO del porc. real sobre el estimado de estudiantes en el tercil inferior nacional	-4.26	-3.53
Coef. MCO del porc. real sobre el estimado de estudiantes en el tercil inferior nacional	-3.86	5.43
Porc. de docentes “sorprendidos” o “muy sorprendidos” por el porc. de estudiantes en cada tercil nacional	63	60
<i>D. Los errores no se deben a la dificultad de agregar el desempeño por ítem</i>		
Coef. MCO del porc. real sobre el estimado de estudiantes competentes en números	54.0	-
Coef. MCO del porc. real sobre el estimado de estudiantes competentes en medición	43.7	-
Coef. MCO del porc. real sobre el estimado de estudiantes competentes en datos	46.4	-
Coef. MCO del porc. real sobre el estimado de estudiantes competentes en geometría	50.0	-
Coef. MCO del porc. real sobre el estimado de estudiantes competentes en álgebra	56.1	-
Coef. MCO del porc. real sobre el estimado de estudiantes competentes en lectura	-	57.7
Coef. MCO del porc. real sobre el estimado de estudiantes competentes en vocabulario	-	17.4
Coef. MCO del porc. real sobre el estimado de estudiantes competentes en gramática	-	19.5
Coef. MCO del porc. real sobre estimado que acierta el ítem de números	53.5	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de medición	-13.7	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de datos	6.92	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de geometría	-4.63	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de álgebra	-25.8	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de lectura	-	-15.7
Coef. MCO del porc. real sobre estimado que acierta el ítem de vocabulario	-	-29.1
Coef. MCO del porc. real sobre estimado que acierta el ítem de gramática	-	-20.5
Coef. MCO del porc. real sobre estimado que acierta el ítem de medición (tercil inferior dentro del aula)	15.4	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de medición (tercil medio dentro del aula)	-3.99	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de medición (tercil superior dentro del aula)	-5.77	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de medición (tercil inferior nacional)	28.4	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de medición (tercil medio nacional)	-6.50	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de medición (tercil superior nacional)	-9.25	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de álgebra (tercil inferior dentro del aula)	4.46	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de álgebra (tercil medio dentro del aula)	-9.19	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de álgebra (tercil superior dentro del aula)	-10.1	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de álgebra (tercil inferior nacional)	10.3	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de álgebra (tercil medio nacional)	-8.00	-
Coef. MCO del porc. real sobre estimado que acierta el ítem de álgebra (tercil superior nacional)	-11.0	-
<i>E. Los errores no se deben a una dependencia excesiva de heurísticas</i>		
Porc. de estimaciones de porcentajes de respuestas correctas de los estudiantes exactamente en 60%	21	19
Porc. de estimaciones de porcentajes de respuestas correctas de los estudiantes a menos de 5 p.p. de 60%	29	32
Coef. MCO de puntajes reales sobre estimados (omitiendo estimaciones exactamente en 60%)	0.09	0.09
Coef. MCO de puntajes reales sobre estimados (omitiendo estimaciones exactamente en 60%, con EF por docente)	0.36	0.38
Coef. MCO de puntajes reales sobre estimados (omitiendo estimaciones a menos de 5 p.p. de 60%)	0.12	0.11

Coef. MCO de puntajes reales sobre estimados (omitiendo estimaciones a menos de 5 p.p. de 60%, con EF por docente)	0.49	0.51
--	------	------

Notas: Esta tabla ofrece un resumen de todas las pruebas de robustez presentadas en el artículo. Omitimos los resultados por ítem y tercil de estudiantes para lengua de la tabla A.17, que coherentes con los de matemáticas, pero son demasiados para incluirlos aquí. También omitimos los resultados de las tablas A.18 para la India, que son el único conjunto de pruebas de robustez del artículo para ese país. EF se refiere a efectos fijos.