

**La confiabilidad de las observaciones de clase y las encuestas a estudiantes en contextos
ajenos a la investigación:**

Evidencia de un país de ingresos medios¹

Alejandro J. Ganimian²

Andrew D. Ho³

Alejandra Campos

Harvard University/
New York University

Harvard University

Quintero⁴

Columbia University

Resumen: Presentamos uno de los primeros estudios de generalizabilidad de medidas no basadas en pruebas de la efectividad docente administradas por profesionales de la práctica educativa en un país de ingresos medios. La confiabilidad de las observaciones varía ampliamente (de 0 a 0.75 en una escala de 0-1) y depende de su contexto (si se realizan durante la formación o en el ejercicio de la docencia) y de las configuraciones de asignación de evaluadores. La confiabilidad de las encuestas varía sustancialmente, en coincidencia con un cambio en los estudiantes muestreados entre ocasiones. Nuestras estimaciones son comparables a la confiabilidad reportada por investigaciones en países de ingresos altos, pero la variación dentro de nuestras estimaciones y entre estas y las de estudios individuales sugiere que los profesionales deberían realizar sus propios análisis de confiabilidad. Ofrecemos orientaciones para aprovechar dichos análisis a fin de mejorar la confiabilidad de sus medidas.

¹ Agradecemos los fondos aportados por el Banco Interamericano de Desarrollo para este estudio. Agradecemos a Emiliana Vegas, Mariana Alfonso y al equipo de *Enseña por Argentina*—especialmente a Oscar Ghillione, Fernando Viola, Mariana Albarracín y Laura de Jorge—por hacer posible este estudio. También agradecemos a Samuel Hansen Freel por su excelente asistencia de investigación.

² Profesor asociado visitante de educación, Harvard Graduate School of Education. Profesor asociado de psicología aplicada y economía, Steinhardt School of Culture, Education, and Human Development, New York University. alejandro_ganimian@gse.harvard.edu.

³ Profesor Charles William Eliot de educación, Harvard Graduate School of Education. andrew_ho@gse.harvard.edu.

⁴ Estudiante de doctorado, Teachers College de Columbia University. aac2271@tc.columbia.edu.

1. Introducción

Existe un consenso creciente sobre la necesidad de medir la efectividad docente mediante múltiples instrumentos (Baker et al., 2010; Goe et al., 2008; Kane et al., 2014). Sin embargo, salvo notables excepciones (Glazerman et al., 2011; Whitehurst et al., 2014), las orientaciones sobre cómo lograr calificaciones confiables a partir de medidas no basadas en pruebas provienen en gran medida de estudios en los que las observaciones de clase y las encuestas a estudiantes se administraron con fines de investigación en países de ingresos altos. La aplicabilidad de dichas orientaciones fuera de esos contextos sigue estando poco examinada. Cuando los investigadores recogen estas medidas, existen múltiples mecanismos (p. ej., capacitación de evaluadores, certificación, codificación maestra, motores de validación) para garantizar la integridad de la información recopilada. Además, casi todos los estudios de esta literatura se realizaron en Estados Unidos, donde los docentes pueden estar más acostumbrados a ser evaluados que los de otros países (Commission/EACEA/Eurydice, 2021; Isoré, 2009; Martinez et al., 2016; OECD, 2015, 2025; Pouezevara et al., 2016). Ambos factores podrían hacer que estas métricas sean más confiables que las administradas por profesionales de la práctica educativa en países de ingresos bajos y medios (PIBM). Si así fuera, los profesionales que toman decisiones basándose en contextos de investigación (Manzi et al., 2011; Quezada & Salcedo, 2019) podrían diseñar sistemas de retroalimentación docente que produzcan resultados menos confiables de lo que pretenden y perciben.

En este artículo, aprovechamos observaciones de clase y encuestas a estudiantes sobre 100 docentes, recogidas por una vía alternativa de acceso a la docencia en Argentina (llamada *Enseñá por Argentina* o ExA), para entender cómo se compara su confiabilidad con la de contextos de investigación en Estados Unidos. Nuestro estudio se diferencia de análisis previos

de la confiabilidad de medidas no basadas en pruebas en cuatro aspectos principales. En primer lugar, nuestros datos fueron recogidos por profesionales en un país de ingresos medios, lo que complementa esfuerzos previos liderados por investigadores en países de ingresos altos. En segundo lugar, los instrumentos que examinamos fueron adaptados de protocolos ampliamente utilizados en Estados Unidos con fines formativos (no tenían consecuencias asociadas), lo que reduce la preocupación de que cualquier diferencia en la confiabilidad respecto de estudios previos se deba a cómo se desarrollaron los instrumentos o a cómo se usaron sus resultados. En tercer lugar, observamos las mismas medidas a lo largo de dos años y dos contextos (las medidas se recogieron durante las prácticas docentes y una vez que los docentes comenzaron a enseñar en escuelas de difícil cobertura) y en múltiples condiciones de evaluación (mentores y pares, solos o combinados, fijos o rotativos), lo que nos permite determinar si la confiabilidad de nuestras medidas es estable o varía entre administraciones. Por último, dado que la organización sin fines de lucro que proporcionó los datos forma parte de una red global de 60 organizaciones que utilizan procedimientos y medidas similares (Teach for All), consideramos que nuestros resultados podrían ser relevantes más allá del contexto específico de nuestro estudio.

Nuestro análisis va más allá de las métricas tradicionales de confiabilidad, que cuantifican la consistencia de los puntajes respecto de una sola fuente de error a la vez (p. ej., ítems o evaluadores). Estimamos simultáneamente la contribución de distintas facetas del error de medición (p. ej., la dificultad de los ítems y la severidad de los evaluadores) y de las interacciones entre estas facetas (p. ej., que algunos evaluadores sean más severos en algunos ítems). La principal ventaja de este enfoque es que, al ser más precisos sobre las fuentes de error, también podemos ser más estratégicos para reducirlo (p. ej., si la severidad de los evaluadores contribuye más al error de medición que la dificultad de los ítems, podemos reducir el error de

manera más eficiente aumentando el número de evaluadores en lugar del de ítems). Este enfoque, la “teoría G(eneralizabilidad)” (Brennan, 2001; Cronbach et al., 1972; Shavelson & Webb, 1991), se utiliza cada vez más en los sistemas de retroalimentación docente de Estados Unidos (Bell et al., 2012; Hill et al., 2012a; Ho & Kane, 2013; Kane & Staiger, 2012; Meyer et al., 2011). Hasta donde sabemos, no se ha aplicado ampliamente en países de ingresos bajos o medios.

Presentamos cinco hallazgos principales. En primer lugar, las observaciones de clase realizadas por profesionales varían ampliamente en su confiabilidad tanto para establecer distinciones *relativas* (decidir qué docentes son más efectivos) como para emitir juicios *absolutos* sobre los docentes (obtener puntajes consistentes para niveles de desempeño similares) con los números actuales de ítems, evaluadores y ocasiones. En los dos contextos en que se observó a los docentes—la práctica clínica y el ciclo lectivo—el coeficiente de generalizabilidad para el error relativo—una medida de confiabilidad para distinciones relativas que va de 0 (totalmente no confiable) a 1 (perfectamente confiable)—osciló entre 0 y 0.75, y el coeficiente para el error absoluto—una métrica para juicios absolutos que también va de 0 a 1—osciló entre 0 y 0.71. El alto grado de variabilidad indica que las observaciones en estos contextos pueden ir desde puro ruido (es decir, 0% de la variación en los puntajes de observación refleja diferencias reales en la efectividad docente medida, en lugar de error de medición) hasta mecanismos útiles para asignar a intervenciones a los docentes que necesitan apoyo (es decir, 75% de la variación refleja diferencias reales). Los coeficientes de generalizabilidad para el error relativo de una sola observación oscilan entre 0 y 0.61 según la condición, con una media de 0.39, notablemente cercana a la media de 0.39 y a la mediana de 0.38 de las 44 estimaciones de estudios de generalizabilidad realizados por investigadores en países de ingresos altos.

En segundo lugar, el nivel y la variación de la confiabilidad de estas observaciones parecen explicarse en parte por el contexto en que se administraron y por las formas en que se asignaron los evaluadores a los docentes. Los coeficientes de generalizabilidad fueron más bajos durante la práctica clínica que durante el ciclo lectivo: el coeficiente medio para el error relativo (absoluto) en la práctica clínica fue de 0.48 (0.42) y el del error relativo (absoluto) en el ciclo lectivo fue de 0.64 (0.52). Estos coeficientes también variaron más durante la práctica clínica: el coeficiente para el error relativo (absoluto) varió de 0 a 0.71 (de 0 a 0.75), frente a un rango de 0.63 a 0.66 (de 0.44 a 0.59) durante el ciclo lectivo. Dentro de la práctica clínica, la confiabilidad varió ampliamente entre los distintos tipos de asignación de evaluadores: ambos coeficientes fueron más altos y menos variables cuando el mismo par calificó ambas clases, más bajos y ligeramente más variables cuando el mismo mentor calificó ambas clases, y los más bajos y más variables cuando un par distinto calificó cada clase. Estas cifras sugieren que el tipo de consideraciones que influyen en la asignación de evaluadores entre los profesionales puede tener impactos no triviales en la confiabilidad.

En tercer lugar, con una excepción, parece posible mejorar la confiabilidad de las observaciones aumentando el número de veces que se califica a los docentes. Durante la práctica clínica, observar a cada docente tres veces en lugar de dos mejoraría los coeficientes de generalizabilidad para el error relativo en 6-9 puntos porcentuales (p.p.) y los del error absoluto en 4-7 p.p., según el tipo de evaluador (mentores o pares) y según si todas las clases de cada docente son observadas por el mismo evaluador o por uno distinto. Agregar una observación durante el ciclo lectivo mejoraría los coeficientes para el error relativo y absoluto en 8 p.p. en los dos años para los que tenemos datos. Aumentos adicionales en el número de observaciones mejorarían la confiabilidad en un margen menor.

En cuarto lugar, las encuestas a estudiantes administradas por profesionales también varían en su confiabilidad. Durante la práctica clínica, el coeficiente de generalizabilidad para el error relativo osciló entre 0.33 y 0.58, y el del error absoluto, entre 0.29 y 0.57. En el ciclo lectivo, las cifras correspondientes fueron de 0.59 a 0.85 y de 0.36 a 0.70, respectivamente. Estos resultados indican que entre el 33 y el 85% de la variación en los puntajes observados refleja diferencias reales en la efectividad docente medida. Los coeficientes de generalizabilidad para el error relativo con un solo evaluador oscilan entre 0.03 y 0.25, en términos generales consistentes con la única estimación que encontramos en investigaciones previas en Estados Unidos, de 0.16.

En quinto lugar, es posible mejorar la confiabilidad de las encuestas a estudiantes aumentando el número de encuestados mediante extensiones razonables de las condiciones de administración existentes. Durante la práctica clínica, encuestar a 15 estudiantes en lugar de 10 mejoraría los coeficientes de generalizabilidad para el error relativo en 7 a 10 p.p. y los del error absoluto en 6 a 10 p.p. Agregar cinco estudiantes durante el ciclo lectivo mejoraría los coeficientes para el error relativo y absoluto en 6-9 p.p. y 4 p.p., respectivamente. Aumentos adicionales en el número de estudiantes encuestados mejorarían la confiabilidad en márgenes menores.

El resto del artículo se estructura de la siguiente manera. La sección 2 revisa investigaciones previas sobre la confiabilidad de las observaciones de clase y las encuestas a estudiantes, y muestra que las medidas recogidas con fines de investigación presentan niveles de confiabilidad relativamente altos. La sección 3 describe los datos utilizados en este estudio, que se basan en observaciones de clase y encuestas a estudiantes administradas en dos contextos distintos a lo largo de dos años de una vía alternativa de acceso a la docencia en Argentina. La sección 4 explica cómo usamos la teoría de la generalizabilidad para ser más precisos sobre las

fuentes de error de medición en las observaciones y las encuestas, y más estratégicos sobre cómo reducirlas. La sección 5 presenta nuestras estimaciones de confiabilidad para ambas métricas y cómo podrían mejorarse aumentando el número de las facetas de error pertinentes (p. ej., aumentando los evaluadores y/o las clases).

2. Investigaciones previas

En las últimas dos décadas, los responsables de políticas públicas y los profesionales de la práctica educativa se interesaron cada vez más en medir la efectividad docente. Inicialmente, este interés estuvo motivado en gran medida por investigaciones que sugerían que los docentes varían ampliamente en su capacidad para mejorar el rendimiento de sus estudiantes. Varios estudios encontraron que los estudiantes de algunos docentes obtienen sistemáticamente puntajes más altos en pruebas estandarizadas que los de otros, incluso cuando ambos grupos tienen características demográficas similares y parten de niveles de rendimiento comparables (Aaronson et al., 2007; Chetty et al., 2014; Kane et al., 2008; Koedel et al., 2015; Nye et al., 2004; Rivkin et al., 2005; Rockoff, 2004). Esta evidencia impulsó esfuerzos para identificar a los docentes efectivos a fin de orientar la contratación, la retención, la formación y la remuneración (Dee & Wyckoff, 2013; Goldhaber et al., 2017; Rockoff et al., 2011).

Los métodos estadísticos utilizados para estimar la influencia de los docentes en el rendimiento de los estudiantes (“modelos de valor agregado”) han sido criticados por conducir a veces a resultados imposibles (p. ej., que un docente afecte los puntajes de sus estudiantes en las pruebas del año anterior; Rothstein, 2010), por arrojar resultados contradictorios entre pruebas (Papay, 2011), por ignorar otras formas en que los docentes contribuyen al bienestar de los estudiantes (Blazar, 2018; Jackson, 2020; Kraft, 2019) y por desatender cómo los factores a nivel

de escuela (p. ej., directores, orientadores y pares) median la capacidad de los docentes para ayudar a los estudiantes (Jackson, 2013; Jackson & Bruegmann, 2009; Johnson et al., 2012; Mulhern, 2023; Papay et al., 2020).

Las limitaciones de los modelos de valor agregado, sumadas al reconocimiento de que el impacto de los docentes en la vida de los estudiantes va más allá de mejorar sus puntajes en las pruebas, llevaron a muchos a abogar por combinar las ganancias en el rendimiento estudiantil con otras medidas de la calidad docente. Varios estudios ilustraron las ventajas de este enfoque, al mostrar que otras medidas de la calidad de la enseñanza (p. ej., las observaciones de clase y las encuestas a estudiantes) aportan información valiosa que las pruebas no captan (Baker et al., 2010; Darling-Hammond et al., 2012; Goe et al., 2008; Kane et al., 2014; Kane & Staiger, 2011, 2012; Kane et al., 2011). Algunos han ofrecido consejos prácticos sobre cómo administrar dichos instrumentos (p. ej., el número de veces que se debe observar a un docente para obtener calificaciones consistentes de su desempeño; Ho & Kane, 2013).

Sin embargo, la confiabilidad de las medidas no basadas en pruebas administradas por profesionales ha sido relativamente poco examinada—especialmente en los PIBM. En este estudio, intentamos abordar esta brecha centrándonos en la confiabilidad de las observaciones de clase y las encuestas a estudiantes de una organización sin fines de lucro que forma parte de una red global con prácticas similares de retroalimentación docente. En esta sección, revisamos estudios previos que analizaron la confiabilidad de estos dos instrumentos con un enfoque común (descrito más adelante) para entender cómo se comparan con los de nuestro estudio. Nos centramos en la confiabilidad de cada medida porque así es como la organización que nos proporcionó los datos para nuestro estudio utiliza la información. Para investigaciones sobre la

confiabilidad de compuestos que combinan múltiples medidas, véase Douglas y Mislevy (2010); Martínez y Fernández (2021).

El estudio de la confiabilidad de las medidas de efectividad docente en general, y de las observaciones de clase y las encuestas a estudiantes en particular, ha evolucionado considerablemente en las últimas décadas. Convencionalmente, los especialistas en medición educativa conciben el puntaje que un docente recibe en un procedimiento como debido en parte a la efectividad de ese docente y en parte a errores de medición. Distinguen entre estas partes tomando múltiples mediciones e interpretando las similitudes entre mediciones como indicativas de lo primero y las diferencias como indicativas de lo segundo. Esta idea se plasma en la “teoría clásica de los tests” (TCT) y su ecuación $X_i = \tau + \varepsilon_i$, que indica que cualquier puntaje observado X_i es igual a un puntaje verdadero τ más el error de ese procedimiento ε_i (Allen & Yen, 2001; Lord & Novick, 2008; Nunnally, 1978). El puntaje verdadero es el promedio a largo plazo de los puntajes a lo largo de las replicaciones, los errores de medición son desviaciones de ese promedio específicas de cada replicación, y la confiabilidad es la correlación entre los puntajes de distintas replicaciones (el cociente entre la varianza del puntaje verdadero y la del puntaje total).

Este marco se usa a menudo para cuantificar el error de medición proveniente de las preguntas (ítems) de una prueba. Si todos los ítems miden el mismo constructo, podemos interpretar la esperanza de los puntajes de los ítems como el puntaje verdadero y cualquier desviación respecto de ella como error. Por ejemplo, el alfa de Cronbach mide la confiabilidad de consistencia interna como la proporción de la varianza del puntaje total atribuible a la variación compartida entre ítems (Cronbach, 1951). En las observaciones de clase y las encuestas a estudiantes, los “ítems” son los indicadores con los que se pide a los evaluadores (en las

observaciones, mentores o pares; en las encuestas, estudiantes) que califiquen a los docentes (para ejemplos de los ítems de los instrumentos utilizados en este estudio, véanse las secciones 3.2.1 y 3.2.2). Esta idea también se aplica al error proveniente de los evaluadores o de las ocasiones. Si consideramos el puntaje de cada evaluador (u ocasión) como una replicación, podemos interpretar la correlación de los puntajes entre evaluadores (u ocasiones) como confiabilidad interevaluador (o test-retest).

Una limitación clave de los análisis clásicos de confiabilidad es que no distinguen entre distintas fuentes de error de medición. Descomponen la varianza del puntaje observado en varianza verdadera y varianza de error indiferenciada. Una alternativa es usar modelos de efectos aleatorios para separar la contribución de cada faceta (p. ej., ítems o evaluadores) y de las interacciones entre ellas (p. ej., que los evaluadores sean más severos en algunos ítems). Este enfoque, la “teoría G(eneralizabilidad)” (Brennan, 2001; Cronbach et al., 1972; Shavelson & Webb, 1991), nos permite describir la varianza de error con mayor precisión y ser más estratégicos para reducirla, aumentando las replicaciones en las facetas que agregan más ruido. Por ejemplo, si la severidad de los evaluadores contribuye más al error que la dificultad de los ítems, aumentar el número de evaluadores reducirá el error en mayor medida que aumentar el número de ítems. En las observaciones de clase y las encuestas a estudiantes, cada ítem se califica en una escala de 1 (nivel de desempeño más bajo) a 5 (nivel más alto). La dificultad de los ítems refleja diferencias sistemáticas entre ítems (p. ej., los ítems que reciben sistemáticamente calificaciones más bajas que otros se consideran más “difíciles”).

En las últimas décadas, los estudios de generalizabilidad (estudios G) se convirtieron en un método cada vez más destacado para examinar la confiabilidad de las medidas no basadas en pruebas de la efectividad docente en la educación K-12. Estos estudios ofrecieron orientaciones

prácticas sobre cómo diseñar sistemas de retroalimentación docente que produzcan resultados confiables. Quizás el caso más conocido sea el estudio Measures of Effective Teaching (MET), que comparó la confiabilidad de cuatro protocolos de observación de clase ampliamente utilizados en cinco distritos escolares de Estados Unidos y concluyó que “para lograr una confiabilidad cercana a 0.65... tuvimos que calificar cuatro clases distintas, cada una con un evaluador distinto” (Kane & Staiger, 2012), y posteriormente identificó múltiples enfoques para lograr observaciones confiables (MET Project, 2013). Esta evidencia se ha citado en el diseño de sistemas de retroalimentación docente en Estados Unidos y en otros países (Manzi et al., 2011; Quezada & Salcedo, 2019).

Sin embargo, gran parte de lo que sabemos sobre la confiabilidad de las métricas alternativas de efectividad docente proviene de un conjunto relativamente reducido de contextos y medidas. La Tabla A.1 del Anexo A resume los hallazgos de 15 estudios de generalizabilidad de observaciones de clase y encuestas a estudiantes. Todos los estudios se realizaron en países de ingresos altos—principalmente, en Estados Unidos (87%)—y solo dos estudios en Europa, uno en Alemania y Suiza (Praetorius et al., 2014) y otro en los Países Bajos (van der Lans et al., 2016). El instrumento más estudiado es el Classroom Assessment Scoring System (CLASS, Hamre et al., 2013; Mashburn et al., 2008; Pianta et al., 2008a), que aparece en siete estudios de los niveles inicial, primario y secundario; le siguen el Framework for Teaching (FfT, Danielson, 2011), en cinco estudios, y el Mathematics Quality of Instruction (MQI, Hill et al., 2012a; Hill et al., 2011), en tres. Cada uno de los demás instrumentos aparece en un solo estudio.

Los tamaños de muestra varían ampliamente, desde 8 docentes (Hill et al., 2012a) hasta 1,333 (Kane & Staiger, 2012), con una mediana de 48. Sin embargo, la mayoría de los estudios son pequeños: el 73% incluye menos de 100 docentes. El número de observaciones por docente

suele oscilar entre 3 y 8, con una mediana de aproximadamente 5. Los extremos incluyen a Hill et al. (2012a), con solo 1 observación por docente, y a Ho and Kane (2013), con un promedio de 46—aunque este último es excepcional.

Los puntajes promedio en las observaciones de clase aportan evidencia de posibles efectos piso y techo. En el CLASS (calificado de 1 a 7), los promedios de Classroom Organization son sistemáticamente altos (5.18-5.75), se acercan al límite superior y sugieren una compresión en el techo que puede limitar la capacidad del instrumento para distinguir entre los docentes del extremo superior de la distribución. Los promedios de Instructional Support son considerablemente más bajos (1.93-3.58), y el dominio Cognitive Activation de Praetorius et al. (2014), con 1.93, sugiere un posible efecto piso. Los promedios de Emotional Support se ubican en el rango intermedio (3.64-5.37). En el FfT (calificado de 1 a 4), los promedios se concentran cerca del centro de la escala (1.87-2.58), sin evidencia sólida de efectos piso o techo.

La desviación estándar (DE) del efecto docente y el error estándar de medición (EEM) de una sola observación revelan que el error de medición con frecuencia iguala o supera la variación verdadera entre docentes. En los dominios del CLASS, las DE van de 0.22 a 0.73, mientras que los EEM van de 0.39 a 0.97. En muchos casos—sobre todo en Instructional Support—el EEM supera a la DE, lo que significa que la varianza del error de una sola observación es mayor que la varianza atribuible a diferencias genuinas entre docentes. Se observa un patrón similar en el FfT, donde las DE van de 0.19 a 0.37 y los EEM, de 0.24 a 0.44. El instrumento RESET muestra EEM especialmente grandes (0.82-2.11) en relación con su escala de 0-3.

La confiabilidad de una sola observación (es decir, la proporción de la varianza del puntaje observado atribuible a diferencias persistentes en la práctica docente) es baja en todos los estudios e instrumentos. En las 45 estimaciones de confiabilidad de la Tabla A.1, los valores van

de 0.00 a 0.81, con una mediana de 0.38 y una media de 0.39. Más de tres cuartas partes (76%) se ubican por debajo de 0.50, y solo tres estimaciones (7%) alcanzan o superan el umbral convencional de 0.70: dos subescalas del MQI en el nivel inicial (Mantzicopoulos et al., 2018) y el FfT para la enseñanza de la lectura (Patrick et al., 2020). En las clasificaciones de nivel secundario y de múltiples niveles, ninguna confiabilidad de una sola observación alcanza 0.70. La única estimación de encuestas a estudiantes (Schweig, 2014) arroja una confiabilidad de apenas 0.16. Estos hallazgos indican que una sola observación realizada por un solo evaluador suele ser insuficiente para medir de manera confiable la calidad de la enseñanza, independientemente del instrumento utilizado.

Las observaciones de clase de estos estudios se realizaron con fines de investigación e incorporaron varios mecanismos de aseguramiento de la calidad que probablemente mejoran su confiabilidad, como: la capacitación, evaluación y certificación de evaluadores, y la práctica adicional (p. ej., capacitación en profundidad, acompañamiento individual, observaciones en parejas y calibración grupal, Jerald, 2012); la codificación maestra (en la que expertos discuten y acuerdan los puntajes correctos y su justificación, McClellan, 2013), y un motor de validación (que incluye una videoteca en línea, una rúbrica de calificación, comparaciones con otras métricas e informes automatizados, MET Project, 2010), entre otros (p. ej., la prueba piloto del protocolo de observación, Joe et al., 2013). Sigue siendo una pregunta abierta si las observaciones realizadas por profesionales de la práctica educativa, con menos de estos mecanismos, pueden alcanzar niveles similares de confiabilidad.

3. Datos

3.1 Contexto

Realizamos nuestro estudio en Argentina, un país de ingresos medios altos con altos niveles de matriculación en la escuela primaria y secundaria, pero con resultados de aprendizaje inferiores a los de sus vecinos. El ingreso per cápita de Argentina (USD 13,730) es comparable al de China, México, Rusia y Turquía (World Bank 2024a), pero el país ha atravesado recientemente varias crisis económicas y políticas que lo distinguen tanto de esos países como de la mayoría de sus vecinos sudamericanos. Según los datos más recientes, 4 de cada 10 personas viven por debajo de la línea de pobreza (World Bank 2024c). Más del 99% de los niños y jóvenes se matricula en la escuela primaria y en el primer ciclo de la secundaria, pero solo el 90% lo hace en el ciclo superior de la secundaria y apenas el 70% termina la escuela secundaria (World Bank 2024b). Incluso entre quienes llegan al último año de la secundaria, el 43% obtiene puntajes en los niveles más bajos de la evaluación nacional en lengua y el 82% en matemática (Ganimian 2025). La proporción de jóvenes de 15 años en los niveles más bajos de las pruebas internacionales es mayor: 55% en lengua y 73% en matemática (OECD 2023). Además, los estudiantes más pobres tienen 21 y 42 puntos porcentuales más de probabilidad de ubicarse en estos niveles en lectura y matemática, respectivamente, que sus pares más ricos.

Nos enfocamos en la Provincia de Buenos Aires (PBA), el sistema educativo subnacional más grande del país. En Argentina, las provincias (similares a los estados de Estados Unidos) son responsables de proveer la educación desde el nivel inicial hasta el nivel terciario, y el gobierno federal, de proveer la educación superior, así como asistencia técnica y financiera a las provincias (Ley de Educación Nacional 2006). La PBA atiende a 4.3 millones de estudiantes: 654,958 en el nivel inicial, 1.7 millones en el nivel primario, 1.7 millones en el nivel secundario

y 260,082 en el nivel terciario (MdCH 2024). La PBA es representativa del país en su conjunto, con un ingreso familiar mediano de ARS 117,278 (USD 121) por mes, casi idéntico al promedio nacional. También es comparable en desigualdad de ingresos, con un coeficiente de Gini levemente inferior a la media nacional (INDEC 2024). Sus resultados de aprendizaje reflejan esta realidad económica: sus puntajes en la evaluación nacional se asemejan mucho a los de la provincia promedio del país (Ganimian 2025).

Obtuvimos los datos para nuestro estudio de *Enseñá por Argentina* (ExA), una organización sin fines de lucro que recluta graduados universitarios para enseñar durante dos años en escuelas con dificultades para cubrir sus cargos docentes. Para 2024, 15 años después de su fundación, ExA había incorporado a 400 docentes que atendían a 130,000 estudiantes en siete provincias (la Provincia y la Ciudad de Buenos Aires, Chaco, Mendoza, Neuquén, Salta y Santa Fé). Además, sigue procesos similares para formar y desarrollar a sus docentes a los de otras 60 organizaciones de todo el mundo que integran la red Teach for All. Consideramos que nuestro estudio es relevante para este grupo más amplio y para otras organizaciones que usan instrumentos y procedimientos comparables.

3.2 Procedimiento

En este estudio, examinamos la confiabilidad de dos medidas de efectividad docente (observaciones de clase y encuestas a estudiantes) desarrolladas y administradas por ExA con fines de retroalimentación. Como muchos miembros de la red Teach for All, ExA usa tanto observaciones de clase como encuestas a estudiantes para decidir qué docentes deben recibir apoyo adicional y qué tipo de apoyo necesitan (p. ej., manejo del aula frente a conocimiento disciplinar). Estos usos de los datos sobre efectividad docente probablemente son más comunes en contextos ajenos a la investigación que las decisiones de contratación, remuneración y

despido, que rara vez se basan en el desempeño (Bruns et al., 2011; Kraft & Gilmour, 2017; Weisberg et al., 2009). Esto es particularmente cierto en América Latina, donde los directores tienen poca discrecionalidad sobre estas decisiones (Adelman & Lemos, 2018; Anand et al., 2023). Que las medidas se usen con fines formativos en este contexto no implica que no tengan consecuencias. De hecho, en organizaciones sin fines de lucro con recursos limitados, la asignación de apoyo entre los docentes es quizás la decisión más trascendente tanto para la organización como para sus docentes.

En 2014 y 2015, ExA administró estas medidas inmediatamente después de la contratación de los docentes, durante su instituto de formación de verano (una formación inicial de cuatro semanas que concluye con dos semanas de práctica docente), y durante el ciclo lectivo, cuando los docentes ya estaban en el aula. Denominamos al primer proceso “práctica clínica” y al segundo, “ciclo lectivo.” Todos los docentes nuevos participaron en la práctica clínica solo en el año en que fueron contratados (p. ej., si un docente fue contratado en 2014, solo participó en la práctica clínica en 2014), y tanto los docentes nuevos como los existentes enseñaron durante el ciclo lectivo por dos años (p. ej., la base de datos del ciclo lectivo 2014 incluye tanto a docentes contratados en 2013 [segundo año] como en 2014 [primer año]).

Todos los participantes del instituto de formación de verano, incluidos los mentores y los docentes, asistieron a una sesión de capacitación de una hora sobre las observaciones de clase y las encuestas a estudiantes, organizada por el equipo de Formación y Acompañamiento de ExA. La sesión presentó ambos instrumentos, sus usos previstos y su frecuencia de administración durante la práctica clínica y el ciclo lectivo, así como los instrumentos en los que se basaban. Luego, describió cada uno de los dominios y los ítems de cada dominio, y ofreció ejemplos de la escala de calificación de algunos ítems a modo de ilustración. A lo largo de la sesión, los

mentores y los docentes tuvieron la oportunidad de hacer preguntas aclaratorias. Después de esta sesión, revisaron los instrumentos en grupos, mientras miembros del personal de ExA recorrían los grupos para responder cualquier pregunta que surgiera. Por último, los mentores y los docentes tuvieron la oportunidad de practicar la calificación de una clase de demostración y discutir sus resultados.

3.2.1 Práctica clínica

Durante la práctica clínica, cada docente enseñó a un grupo de estudiantes voluntarios durante dos semanas y fue observado en dos clases, con un evaluador que calificó cada clase en seis dominios (un dominio es el puntaje promedio de varios ítems; véase el Anexo B). En los estudios G, esta configuración de docentes, clases, evaluadores y dominios se denomina diseño de dominio por clase anidada en docente, o $d \times (l:t)$. En este diseño, los dominios están cruzados con los docentes y las clases (como indica el signo $\times$) porque todos los docentes fueron calificados con el mismo protocolo de observación de clase (véase la sección 3.4.1) en todas las clases. Las clases están anidadas en los docentes (como indica el signo $:$) porque cada docente enseñó clases distintas (p. ej., el docente A enseñó matemática de 5.º grado; el docente B, lengua de 6.º grado).

El efecto de la severidad de los evaluadores sobre la confiabilidad no puede estimarse porque hubo un solo evaluador por clase, por lo que no podemos saber cómo habría calificado otro evaluador las mismas clases. Algunos docentes fueron calificados por el mismo mentor en ambas clases, otros por el mismo par y otros por un par distinto. Los mentores (pero no los pares) observaron a varios docentes, por lo que realizamos estudios separados para cada mentor (7 en 2014 y 8 en 2015) y reportamos el resultado promedio entre mentores para cada año. Esta configuración nos permite comparar la confiabilidad de estos tres enfoques de asignación de

evaluadores, lo que puede interesar a los profesionales que buscan equilibrar la experiencia y la disponibilidad de los evaluadores. Los docentes no fueron asignados aleatoriamente a estas condiciones de evaluación, pero los profesionales no informaron ninguna atención sistemática al emparejamiento. Su asignación dependió de factores logísticos, como la disponibilidad de mentores y pares durante cada clase.

Los estudiantes de cada docente también fueron encuestados en la última clase de la práctica clínica sobre siete dominios. En este caso, los estudiantes actúan como evaluadores. En la notación de la teoría G, esta disposición se representa como un diseño de dominio por evaluador anidado en docente, o $d \times (r:t)$. Los dominios están cruzados con los evaluadores y los docentes porque todos los docentes fueron calificados con la misma encuesta (véase la sección 3.4.2). Los evaluadores están anidados porque cada docente enseñó a un grupo distinto de estudiantes (p. ej., el docente A fue evaluado por los estudiantes 1-10, mientras que el docente B, por los estudiantes 11-20). En cada análisis, incluimos a todos los encuestados por clase. El efecto de la dificultad de la clase sobre la confiabilidad no puede estimarse porque los estudiantes fueron encuestados una sola vez, por lo que no podemos saber cómo habrían evaluado los mismos estudiantes a su docente en otra clase. Cabe destacar que este diseño trata a los estudiantes como evaluadores intercambiables, a pesar de que pueden tener experiencias distintas y no pueden concebirse como intercambiables (Seidel, 2006). Sin embargo, como indican los estudios G de la sección de investigaciones previas, otros estudios también adoptan este supuesto simplificador.

3.2.2 Ciclo lectivo

Durante el ciclo lectivo, los docentes enseñaron en varias escuelas, grados y materias durante 11 meses. Cada docente fue calificado en dos ocasiones por un evaluador en los mismos dominios

que en la práctica clínica. Aquí hablamos de ocasiones porque estas observaciones se realizaron en distintos momentos, a diferencia de las clases de la práctica clínica, que tuvieron lugar en rápida sucesión. Se trata de un diseño de docente por dominio por ocasión, o $t \times d \times o$. Los dominios están cruzados con todo lo demás por las mismas razones expuestas más arriba. Las ocasiones también están cruzadas porque todos los docentes fueron observados a mitad y a fin de año. En 2014, ambas observaciones tuvieron lugar en la misma escuela, grado, sección y materia para mantenerlas comparables; en 2015 se realizaron en clases distintas para que fueran más abarcativas. El efecto de la severidad de los evaluadores sobre la confiabilidad no puede estimarse porque hubo un solo evaluador por ocasión. Cada evaluador observó a varios docentes, por lo que realizamos un estudio separado para cada evaluador (3 en 2014 y 4 en 2015) y reportamos el resultado promedio entre evaluadores. Como en la práctica clínica, la asignación de docentes a evaluadores no fue aleatoria, sino que respondió a restricciones logísticas.

Los estudiantes de cada docente fueron encuestados dos veces con el mismo instrumento de la práctica clínica. Se trata de diseños separados de dominio por evaluador anidado en docente, o $d \times (r:t)$, para cada ocasión. Los dominios están cruzados con todo lo demás por las mismas razones expuestas más arriba. Los evaluadores están anidados en los docentes porque cada docente tiene un conjunto distinto de estudiantes. Como en la práctica clínica, incluimos a todos los encuestados por ocasión. Realizamos un análisis separado por ocasión—en lugar de cruzar las ocasiones con todo lo demás—porque las encuestas eran anónimas, por lo que no podemos asegurar que los estudiantes de ambas ocasiones sean los mismos. Además, en 2014, ExA encuestó al mismo grupo de estudiantes en ambas ocasiones, pero en 2015 encuestó a clases distintas. Por lo tanto, es poco probable que los evaluadores estén cruzados con las ocasiones en 2014, y definitivamente no lo están en 2015.

3.3 Muestreo

Nuestro marco muestral incluye 100 docentes únicos que participaron en ExA en 2014 y 2015: 23 comenzaron el programa antes de 2014 y permanecieron, 32 comenzaron en 2014 y 45 comenzaron en 2015. Tenemos datos de las dos últimas cohortes para la práctica clínica y el ciclo lectivo, pero solo observamos a la primera cohorte durante el ciclo lectivo porque completó la práctica clínica antes de nuestro estudio.

Nuestras muestras para cada análisis no incluyen a todos los docentes de una cohorte determinada. Algunos docentes fueron observados menos veces que el resto, por lo que los excluimos para asegurar que todos los docentes tengan datos suficientes para estimar los componentes de varianza relevantes. Durante la práctica clínica, algunos docentes fueron observados por el mismo mentor o par en ambas clases y otros por un par distinto en cada clase (véase la sección 3.2.1). Analizamos cada grupo por separado. Algunos docentes se incluyen en varios análisis, pero ninguno contribuye más de una vez al mismo análisis. La Tabla 1 muestra el número de docentes, clases u ocasiones, evaluadores y dominios, así como el diseño de cada análisis.

3.4 Medidas

Las observaciones de clase y las encuestas a estudiantes que usó ExA fueron adaptadas de protocolos estadounidenses. Esto es bastante común en los PIBM, donde los investigadores simplifican, combinan y/o traducen instrumentos desarrollados en Estados Unidos y a menudo realizan estudios de validación (Araujo et al., 2016; Bruns et al., 2018; Bruns et al., 2016; Bruns & Luque, 2014; Filmer et al., 2022; Molina et al., 2018). Esta característica de nuestro estudio reduce la preocupación de que cualquier diferencia en la confiabilidad entre nuestro estudio y las investigaciones previas se deba puramente a la construcción de los instrumentos. Por lo tanto,

nuestra evidencia informa sobre la “portabilidad” de la confiabilidad cuando se implementan familias de instrumentos similares en un contexto de ingresos medios y bajo una administración operativa a cargo de profesionales. No pretendemos separar estas influencias; en cambio, tratamos el estudio como una “prueba de estrés” conjunta de si la evidencia sobre confiabilidad proveniente de contextos de investigación es una guía razonable en la realidad de las políticas y de los profesionales.

La confiabilidad es una propiedad importante, pero no suficiente, cuando se utilizan puntajes de observaciones y encuestas para respaldar inferencias sobre la enseñanza. La validez es el grado de evidencia que respalda la interpretación y el uso de los puntajes en un contexto particular y se sustenta en múltiples fuentes de evidencia (AERA/APA/NCME, 2018). Nuestra contribución no es una validación exhaustiva de estas medidas en Argentina, sino un examen de si una administración operativa, a cargo de profesionales, puede producir puntajes suficientemente confiables bajo restricciones realistas. Citamos investigaciones previas de validación sobre instrumentos relacionados (en gran medida realizadas en Estados Unidos), aunque subrayamos que dicha evidencia puede no trasladarse plenamente a este contexto. A modo de referencia, reportamos correlaciones descriptivas entre estas medidas en el Anexo A (Tablas A.3–A.5). Estas asociaciones no pretenden ser pruebas confirmatorias de validez y pueden estar atenuadas por el error de medición y verse afectadas por diferencias contextuales en la implementación y la interpretación.

3.4.1 Observaciones de clase

ExA desarrolló su protocolo de observación de clase a partir de cinco medidas creadas y administradas en Estados Unidos: el Classroom Assessment Scoring System (CLASS, Allen et al., 2013; Bell et al., 2012; Hafen et al., 2014; Hamre et al., 2013; Mashburn et al., 2008; Pianta

et al., 2020; Pianta et al., 2008b; Sandilos & DiPerna, 2014); el Framework for Teaching (FfT, Danielson, 2011; Kane et al., 2011; Kimball et al., 2009; Milanowski, 2009; Patrick et al., 2019); Teaching As Leadership (TAL, Farr 2010); el Protocol for Language Arts Teaching Observation (PLATO, Grossman et al., 2015; Grossman et al., 2014; Grossman et al., 2013; Lockwood et al., 2015); y el Mathematical Quality of Instruction (MQI, Blazar, 2015; Blazar et al., 2017; Blazar & Kraft, 2017; Hill et al., 2008; Hill et al., 2012a; Hill et al., 2011; Hill et al., 2012b; Learning Mathematics for Teaching Project, 2011).

El proceso de traducción y combinación de estos instrumentos fue el siguiente. El director del equipo de Formación y Acompañamiento de ExA tradujo al español la versión en inglés de los instrumentos. Luego, el equipo discutió qué aspectos de cada instrumento valoraba la organización y podían ser evaluados de manera factible por un mentor o un par durante la práctica clínica y el ciclo lectivo. A continuación, el director redactó un instrumento que combinaba aspectos de todos los instrumentos, organizándolos en torno a seis dominios (p. ej., “presentar contenidos con claridad”), redactando ítems para cada uno de ellos (p. ej., “¿el docente anuncia con claridad lo que los estudiantes van a aprender al inicio de la clase?”) y descriptores para cada nivel de desempeño de cada indicador (p. ej., desde 1 “no, el docente nunca menciona lo que los estudiantes van a aprender” hasta 5 “sí, el docente menciona lo que los estudiantes van a aprender al inicio de la clase mediante un esquema”). El director y los miembros del equipo participaron en múltiples rondas de discusión para decidir los cambios. La implementación inicial del protocolo en 2013 orientó cambios adicionales para 2014 en adelante. No hubo retrotraducción ni pilotaje, como puede ocurrir cuando los instrumentos se utilizan con fines de investigación.

El protocolo abarcaba seis dominios: presentar contenidos con claridad, verificar la comprensión, gestionar la conducta de los estudiantes, aplicar los procedimientos de clase, crear un ambiente propicio para el aprendizaje y desarrollar un sentido de posibilidad. Cada dominio se calificaba a partir de entre cinco y siete ítems en una escala de 1 (preprincipiante) a 5 (ejemplar). Cada ítem incluía una breve descripción de cada puntaje posible para ayudar a los evaluadores en su elección. En el Anexo A incluimos histogramas de los puntajes a nivel de clase y de docente (Figura A.1), gráficos de barras de las calificaciones a nivel de dominio (Figura A.3) y tablas con las correlaciones entre ellos (Tablas A.2-A.3). En el Anexo B describimos los dominios, presentamos ítems de ejemplo traducidos del protocolo y ofrecemos un enlace al protocolo completo. El director del equipo de Formación y Acompañamiento de ExA tradujo al español la versión en inglés de la encuesta, solicitó comentarios a los miembros de su equipo y la implementó por primera vez en 2013. Esta implementación inicial dio lugar a cambios menores en la versión utilizada a partir de 2014.

3.4.2 Encuestas a estudiantes

ExA tradujo la encuesta Tripod (Ferguson 2010, 2012). La encuesta abarca siete dominios: cuidar (atender las necesidades de los estudiantes), consultar (involucrar a los estudiantes en conversaciones), cautivar (motivar a los estudiantes a aprender), clarificar (verificar la comprensión de los estudiantes), consolidar (ayudar a los estudiantes a integrar conceptos), desafiar (tener altas expectativas para los estudiantes) y controlar (gestionar la conducta de los estudiantes). Cada dominio se calificaba a partir de entre dos y siete ítems en una escala de 1 (“nunca”) a 5 (“siempre”). Las distribuciones de los puntajes a nivel de evaluador, de docente y de dominio se encuentran en el Anexo A (Figuras A.2 y A.4), y las descripciones de los dominios y los ítems de ejemplo, en el Anexo B.

Las distribuciones de los puntajes están sesgadas hacia el extremo superior de la escala, lo que puede afectar nuestras estimaciones de confiabilidad de dos maneras. En primer lugar, los efectos techo a nivel de ítem podrían atenuar la confiabilidad, aunque esta preocupación se mitiga cuando los puntajes se promedian entre múltiples ítems, ya que los puntajes compuestos tienden a estar menos sesgados que los puntajes de los ítems individuales (Ho & Kane, 2013). En segundo lugar, si la población de docentes de nuestro estudio presenta una menor varianza de puntaje verdadero que las poblaciones para las que se desarrollaron estos instrumentos—una restricción de rango—, los coeficientes de confiabilidad observados serán menores independientemente de los efectos techo.

4. Análisis

4.1 Estudios de generalizabilidad

Estimamos la confiabilidad de las observaciones de clase y las encuestas a estudiantes durante la práctica clínica y el ciclo lectivo mediante estudios G. En todos los estudios, concebimos el puntaje observado X_i que recibe un docente en la réplica i como compuesto por un puntaje universo τ (es decir, el promedio a largo plazo entre réplicas) y *múltiples* facetas de error (p. ej., desviaciones respecto de τ debidas a diferencias en la dificultad de los dominios o en la severidad de los evaluadores). En cada estudio, descomponemos la varianza del puntaje observado en varianza del puntaje universo (es decir, diferencias reales en efectividad) y distintos tipos de varianza de error (es decir, diferencias debidas a las facetas de error y a las interacciones entre ellas).

Como se analizó en la sección 3.2, el diseño del estudio, es decir, la forma en que los docentes fueron asignados a dominios, clases u ocasiones y evaluadores, difirió tanto entre

contextos como entre años. Cada uno de estos diseños nos permite distinguir entre distintas fuentes de varianza de error. A continuación, explicamos cómo analizamos los datos de cada diseño mediante modelos de efectos aleatorios. Los errores estándar se calculan mediante el método delta. Dado que los componentes de varianza están acotados inferiormente por cero (y los coeficientes de generalizabilidad están acotados entre 0 y 1), los intervalos de confianza simétricos de tipo Wald basados en aproximadamente dos errores estándar pueden extenderse más allá del espacio paramétrico, especialmente en muestras pequeñas o en componentes cercanos a cero. Reportamos los errores estándar para transmitir la incertidumbre de la estimación y evitamos afirmaciones formales de “significancia” para los componentes de varianza individuales.

Como también se indicó en la sección 3.2, ExA utiliza los puntajes de cada dominio para decidir qué tipo de apoyo necesitan los docentes. Nuestros análisis, sin embargo, tratan los dominios como una faceta aleatoria, de manera análoga a los ítems en los estudios G convencionales. Descomponemos la varianza a nivel de dominio y reportamos la confiabilidad del puntaje promedio de todos los dominios, ya que promediar entre dominios aumenta la precisión del puntaje compuesto, como reflejan las ecuaciones del estudio D que se presentan más adelante.

4.1.1 Los diseños $d \times (l:t)$ y $d \times (r:t)$

Como se explicó en las secciones 3.2.1- 3.2.2, las observaciones de clase durante la práctica clínica siguen un diseño $d \times (l:t)$ y las encuestas a estudiantes durante la práctica clínica y el ciclo lectivo siguen un diseño $d \times (r:t)$. En ambos, todos los docentes son calificados en los mismos dominios, pero cada docente enfrenta clases o evaluadores distintos. Estos diseños nos permiten distinguir entre cinco fuentes de varianza:

$$X_{dl:t} = \mu + v_t + v_d + v_{l:t} + v_{dt} + v_{dl:t,e} \quad (1)$$

o

$$X_{dr:t} = \mu + v_t + v_d + v_{r:t} + v_{dt} + v_{dr:t,e}, \quad (2)$$

donde $X_{dl:t}$ o $X_{dr:t}$ es el puntaje observado del docente t en el dominio d , evaluado en la clase l o por el evaluador r ; μ es la media general (es decir, el puntaje promedio de todos los docentes, dominios y clases o evaluadores); v_t es el efecto docente (es decir, cuánto difiere el docente t en su desempeño); v_d es el efecto dominio (es decir, cuánto difiere el dominio d en su dificultad); $v_{l:t}$ o $v_{r:t}$ son el efecto clase o el efecto evaluador (es decir, cuánto difiere la clase l en su dificultad o el evaluador r en su severidad), anidados en los docentes; v_{dt} es el efecto dominio por docente (es decir, cuánto difiere el dominio d en su dificultad para el docente t); y $v_{dl:t,e}$ o $v_{dr:t,e}$ es el efecto dominio por clase o dominio por evaluador (es decir, cuánto difiere el dominio d en su dificultad para la clase l o el evaluador r), anidado en los docentes y confundido con la variación residual. Los parámetros de interés no son estos efectos aleatorios, sino sus varianzas, que se estiman directamente mediante máxima verosimilitud restringida.

En estos diseños, podemos estimar la varianza de error relativo $\hat{\sigma}_\delta^2$ (es decir, la variación en los puntajes proveniente de las facetas de error que afectan la posición relativa u ordenamiento de los docentes) mediante las fórmulas:

$$\hat{\sigma}_\delta^2 = \frac{\hat{\sigma}_{l:t}^2}{n_l} + \frac{\hat{\sigma}_{dt}^2}{n_d} + \frac{\hat{\sigma}_{dl:t,e}^2}{n_d n_l}, \quad (3)$$

o

$$\hat{\sigma}_\delta^2 = \frac{\hat{\sigma}_{r:t}^2}{n_r} + \frac{\hat{\sigma}_{dt}^2}{n_d} + \frac{\hat{\sigma}_{dr:t,e}^2}{n_d n_r}, \quad (4)$$

donde $\hat{\sigma}_{l:t}^2$ y $\hat{\sigma}_{r:t}^2$ son las varianzas estimadas de las clases y de los evaluadores, anidados en los docentes; $\hat{\sigma}_{dt}^2$ es la varianza de la interacción dominio por docente; $\hat{\sigma}_{dl:t,e}^2$ o $\hat{\sigma}_{dr:t,e}^2$ es la varianza de la interacción entre dominios y clases o evaluadores, anidada en los docentes y confundida con el error residual; y n_d , n_l y n_r son los números de dominios, clases y evaluadores.

También podemos estimar la varianza de error absoluto $\hat{\sigma}_\Delta^2$ (es decir, la variación en los puntajes proveniente de las facetas de error que afectan no solo el ordenamiento, sino también la ubicación de los docentes en la escala de puntajes) como:

$$\hat{\sigma}_\Delta^2 = \frac{\hat{\sigma}_d^2}{n_d} + \hat{\sigma}_\delta^2, \quad (5)$$

donde $\hat{\sigma}_d^2$ es la varianza estimada de los dominios y todo lo demás es como se indicó arriba.

Podemos usar nuestras estimaciones de la varianza de error relativo y absoluto para obtener los coeficientes de generalizabilidad para el error relativo y absoluto, $E\hat{\rho}^2$ y Φ . Estos son similares a los coeficientes de confiabilidad de la TCT, como el alfa de Cronbach, pero son más generales porque toman en cuenta la varianza de error proveniente de múltiples facetas de error y de las interacciones entre ellas. Definen la confiabilidad como la proporción de la varianza total explicada por la varianza del puntaje universo:

$$E\hat{\rho}^2 = \frac{\hat{\sigma}_t^2}{\hat{\sigma}_t^2 + \hat{\sigma}_\delta^2} \quad (6)$$

y

$$\hat{\Phi} = \frac{\hat{\sigma}_t^2}{\hat{\sigma}_t^2 + \hat{\sigma}_\Delta^2} \quad (7)$$

donde $\hat{\sigma}_t^2$ es la varianza estimada del puntaje universo y todo lo demás es como se indicó arriba.

Estas fórmulas son siempre las mismas, independientemente del diseño del estudio, por lo que no las repetimos más adelante.

4.1.2 El diseño $t \times d \times o$

Como se explicó en la sección 3.2.2, durante el ciclo lectivo las observaciones de clase siguen un diseño $t \times d \times o$. En este diseño, todos los docentes son calificados en los mismos dominios y ocasiones. Este diseño nos permite descomponer los puntajes observados en siete fuentes de varianza:

$$X_{tdo} = \mu + v_t + v_d + v_o + v_{dt} + v_{to} + v_{do} + v_{tdo,e}, \quad (8)$$

donde X_{tdo} es el puntaje observado del docente t en el dominio d y la ocasión o ; μ es la media general; v_t es el efecto docente; v_d es el efecto dominio; v_o es el efecto ocasión (es decir, cuánto difiere la ocasión o en su dificultad); v_{dt} es el efecto dominio por docente; v_{to} es el efecto docente por ocasión (es decir, cuánto difiere el docente t en su desempeño en la ocasión r); v_{do} es el efecto dominio por ocasión (es decir, cuánto difiere el dominio d en su dificultad en la ocasión o); y $v_{tdo,e}$ es el efecto docente por dominio por ocasión (es decir, cuánto difiere el docente t en su desempeño en el dominio d y la ocasión o), confundido con el error residual.

Podemos estimar la varianza de error relativo como:

$$\hat{\sigma}_\delta^2 = \frac{\hat{\sigma}_{dt}^2}{n_d} + \frac{\hat{\sigma}_{to}^2}{n_o} + \frac{\hat{\sigma}_{tdo,e}^2}{n_d n_o}, \quad (9)$$

donde $\hat{\sigma}_{to}^2$ y $\hat{\sigma}_{tdo,e}^2$ son las varianzas estimadas de las interacciones docente por ocasión y docente por dominio por ocasión; n_d y n_o son los números de dominios y ocasiones; y todo lo demás es como se indicó arriba. También podemos estimar la varianza de error absoluto como:

$$\hat{\sigma}_\Delta^2 = \frac{\hat{\sigma}_d^2}{n_d} + \frac{\hat{\sigma}_o^2}{n_o} + \frac{\hat{\sigma}_{do}^2}{n_d n_o} + \hat{\sigma}_\delta^2, \quad (10)$$

donde $\hat{\sigma}_d^2$, $\hat{\sigma}_o^2$ y $\hat{\sigma}_{do}^2$ son las varianzas estimadas de los dominios, las ocasiones y la interacción dominio por ocasión; y todo lo demás es como se indicó arriba.

4.2 Estudios de decisión

Luego identificamos el enfoque óptimo para aumentar la confiabilidad de las observaciones de clase y las encuestas a estudiantes mediante estudios D (de decisión). En cada estudio D, tomamos los coeficientes de generalizabilidad para el error relativo y absoluto de un diseño de estudio, que capturan la confiabilidad de estos instrumentos en las condiciones actuales, y calculamos cómo cambiarían si promediáramos entre más evaluadores y clases u ocasiones en cada procedimiento de medición. Como se explicó en la sección 4.1, estos coeficientes se derivan de las estimaciones de la varianza de error relativo y absoluto basadas en los componentes de varianza de cada estudio G. El cálculo de estas varianzas incluye el número de réplicas de cada faceta de error en cada diseño. Al permitir que algunos de estos números varíen, podemos anticipar su impacto esperado en la confiabilidad.

4.2.1 Los diseños $d \times (l:t)$ y $d \times (r:t)$

Como muestran las ecuaciones (5)-(7), en estos diseños, la varianza de error relativo y absoluto y sus coeficientes de generalizabilidad dependen en parte del número de dominios y de clases o evaluadores. Por lo tanto, si aumentáramos cualquiera de ellos, la varianza de error disminuiría y la confiabilidad aumentaría. Esto tiene sentido intuitivamente: si los docentes son calificados en más dominios o clases o por más evaluadores, sus puntajes deberían ser más confiables (porque estamos aumentando el número de réplicas). Supondremos que el protocolo de observación y la encuesta tienen sólidas justificaciones teóricas y estimaremos cómo aumentar el número de clases o evaluadores afectaría su confiabilidad. Permitiremos que el número de clases o evaluadores varíe en el cálculo de la varianza de error relativo:

$$\hat{\sigma}_{\delta}^2 = \frac{\hat{\sigma}_{l:t}^2}{n_l} + \frac{\hat{\sigma}_{dt}^2}{n_d} + \frac{\hat{\sigma}_{dl:t,e}^2}{n_d n_l}, \quad (11)$$

o

$$\hat{\sigma}_{\delta}^2 = \frac{\hat{\sigma}_{r:t}^2}{n_r} + \frac{\hat{\sigma}_{dt}^2}{n_d} + \frac{\hat{\sigma}_{dr:t,e}^2}{n_d n_r}, \quad (12)$$

y también en el cálculo de la varianza de error absoluto:

$$\hat{\sigma}_{\Delta}^2 = \frac{\hat{\sigma}_d^2}{n_d} + \hat{\sigma}_{\delta}^2, \quad (13)$$

donde n'_l y n'_r son el número de clases y de evaluadores que se permite variar y todo lo demás es como se indicó arriba. Si aumentáramos estos números, la varianza de error disminuiría (porque se encuentran en el denominador de ambos conjuntos de expresiones) y los coeficientes de generalizabilidad aumentarían (porque la varianza de error está en sus denominadores; véanse las ecuaciones (6) y (7)).

4.2.2 El diseño $t \times d \times o$

Como muestran las ecuaciones (9)-(10), en este diseño, la varianza de error relativo y absoluto y sus coeficientes de generalizabilidad dependen en parte del número de dominios y de ocasiones.

Si nuevamente mantenemos constante el número de dominios en las observaciones y las encuestas, podemos permitir que el número de ocasiones varíe para estimar cómo aumentarlo afectaría la varianza de error relativo:

$$\hat{\sigma}_{\delta}^2 = \frac{\hat{\sigma}_{dt}^2}{n_d} + \frac{\hat{\sigma}_{to}^2}{n_o} + \frac{\hat{\sigma}_{tdo,e}^2}{n_d n_o}, \quad (14)$$

y la varianza de error absoluto:

$$\hat{\sigma}_{\Delta}^2 = \frac{\hat{\sigma}_d^2}{n_d} + \frac{\hat{\sigma}_o^2}{n_o} + \frac{\hat{\sigma}_{do}^2}{n_d n_o} + \hat{\sigma}_{\delta}^2, \quad (15)$$

donde n'_o es el número variable de ocasiones y todo lo demás es como se indicó arriba.

5. Resultados

5.1 Observaciones de clase

En este contexto, las observaciones de clase varían ampliamente en su confiabilidad tanto para hacer distinciones relativas como para emitir juicios absolutos sobre los docentes. Como muestra la Tabla 2, los coeficientes para el error relativo (en la tercera fila desde abajo) oscilaron entre 0 y 0.75, y los coeficientes para el error absoluto (en la penúltima fila) oscilaron entre 0 y 0.71. Para ilustrar qué implican estos coeficientes en la práctica, consideremos a un docente que recibe un puntaje promedio de observación de 3 en una escala de 1 a 5 (cercano a la media de la Tabla 1). El error estándar de medición (EEM) de una sola observación oscila entre 0.184 y 0.340 según las condiciones. En el mejor caso, esto produce un intervalo de confianza del 95% de [2.65, 3.35], que abarca solo 0.70 puntos de la escala. En el peor caso, produce un intervalo de [2.33, 3.67], es decir, 1.34 puntos—alrededor de un tercio de la escala. El enorme grado de variabilidad indica que, en estos contextos, las observaciones pueden ir desde puro ruido hasta mecanismos útiles para asignar a los docentes que necesitan apoyo a recursos, formación y/o acompañamiento. Como indican los errores estándar de los componentes de varianza, tanto las estimaciones puntuales como las diferencias entre ellas deben interpretarse con cautela, dada la imprecisión conocida derivada de los tamaños muestrales pequeños.

Para situar estos resultados en la literatura previa, calculamos la confiabilidad de una sola observación (es decir, una clase calificada por un evaluador, promediada entre los seis dominios) a partir de los componentes de varianza de la Tabla 2, fijando n_l o n_o en 1 y n_d en 6. Estos coeficientes de generalizabilidad de una sola observación para el error relativo oscilan entre 0 y 0.61 según las condiciones, con una media de 0.39. Esto es notablemente cercano a la media de 0.39 y la mediana de 0.38 de las 44 estimaciones de la Tabla A.1, aun cuando nuestras

observaciones fueron realizadas por profesionales y no por evaluadores de investigación capacitados, y en un país de ingresos medios.

En promedio, las observaciones realizadas durante la práctica clínica tuvieron niveles de confiabilidad más bajos que las realizadas durante el ciclo lectivo. El coeficiente de generalizabilidad medio para el error relativo, considerando todas las asignaciones de evaluadores y todos los años, fue de 0.48 en la práctica clínica y de 0.64 en el ciclo lectivo. El coeficiente medio para el error absoluto fue de 0.42 y el del ciclo lectivo, de 0.52. La confiabilidad de las observaciones también varió más durante la práctica clínica. Los coeficientes para el error relativo y absoluto en la práctica clínica oscilaron entre 0 y 0.75 y entre 0 y 0.71, respectivamente. Los del ciclo lectivo oscilaron entre 0.63 y 0.66 y entre 0.44 y 0.59.

Un factor que podría explicar las diferencias en el nivel y la variabilidad de la confiabilidad entre la práctica clínica y el ciclo lectivo es el contexto en el que se realizaron las observaciones. Si comparamos las observaciones en las que el mismo mentor calificó ambas clases en la práctica clínica y en el ciclo lectivo, las primeras tuvieron menor confiabilidad que las segundas. Los coeficientes de generalizabilidad para el error relativo oscilaron entre 0.34 y 0.52 durante la práctica clínica y entre 0.63 y 0.66 durante el ciclo lectivo, y los coeficientes para el error absoluto oscilaron entre 0.29 y 0.33 durante la práctica clínica y entre 0.44 y 0.59 durante el ciclo lectivo.

Otro factor que podría explicar estas diferencias son las distintas formas en que se asignaron los evaluadores pares a los docentes durante la práctica clínica. Si comparamos las observaciones en las que el mismo par calificó ambas clases con aquellas en las que un par distinto calificó cada clase, las primeras tienen una confiabilidad más alta y menos variable que las segundas. Los coeficientes para el error relativo y absoluto rondaron 0.75 y 0.71 en ambos

años cuando el mismo par calificó ambas clases, y oscilaron entre 0 y 0.51 y entre 0 y 0.48 cuando un par distinto calificó cada clase. Las observaciones en las que el mismo mentor calificó ambas clases tuvieron una confiabilidad más baja y más variable que aquellas en las que el mismo par calificó ambas clases. Los coeficientes para el error relativo y absoluto oscilaron entre 0.34 y 0.52 y entre 0.29 y 0.33 cuando el mismo mentor calificó ambas clases, y rondaron 0.75 y 0.71 en ambos años cuando el mismo par calificó ambas clases. En la discusión consideramos varios mecanismos que podrían explicar esta diferencia.

Sin embargo, como señalamos en las secciones 3.2.1 y 3.2.2, la asignación de evaluadores no fue aleatoria. En la medida en que los docentes hayan sido asignados sistemáticamente a determinados tipos de evaluadores o a evaluadores más o menos severos, nuestros componentes de varianza y, por lo tanto, nuestros coeficientes de generalizabilidad pueden reflejar en parte la selección y el emparejamiento, y no solo las propiedades de medición. Por ejemplo, dado que los coeficientes de generalizabilidad dependen de la varianza entre docentes, una restricción de rango en el subconjunto de docentes observados bajo una configuración determinada podría reducir mecánicamente la confiabilidad. Por ello, interpretamos con cautela las diferencias entre tipos de evaluadores y configuraciones.

Salvo en las observaciones de práctica clínica en las que un par distinto calificó cada clase, los coeficientes para el error relativo y absoluto variaron poco de un año a otro. Esto es coherente con nuestras conversaciones con los profesionales, quienes no señalaron ningún cambio en la capacitación de los pares que pudiera explicar las fluctuaciones en la confiabilidad de las observaciones realizadas por un par distinto en cada clase. En las observaciones de práctica clínica con un par distinto en cada clase, la variabilidad interanual podría deberse a la composición de la cohorte de docentes en cada año o a otros factores que no observamos. Sin

embargo, como señalamos en otras secciones, los componentes de varianza se estiman con error, y las diferencias en la confiabilidad entre años deben interpretarse con cautela.

Las tablas que presentan los resultados de las descomposiciones de la varianza de los puntajes suelen incluir también columnas que indican el porcentaje de la varianza total que representa cada componente de varianza. Sin embargo, es importante recordar que los componentes de varianza son varianzas estimadas de distribuciones de los puntajes más elementales (p. ej., en el diseño $t \times d \times o$, X_{tdo} o el puntaje observado del docente t en el dominio d y la ocasión o), y no de los puntajes promedio que solemos utilizar (p. ej., en el mismo diseño, $\bar{X}_t$ o el puntaje promedio del docente t entre dominios y ocasiones). Para describir la importancia de una fuente de error en función de su impacto en la confiabilidad de los puntajes que utilizamos con mayor frecuencia, presentamos los resultados de nuestros estudios D.

Es factible aumentar la confiabilidad de las observaciones en todos los escenarios que consideramos, salvo uno. Como muestra la Figura 1, el coeficiente de generalizabilidad para el error relativo en las observaciones de práctica clínica se ubica entre 0.2 y 0.6 cuando cada docente es evaluado dos veces, independientemente del tipo de evaluador (véase la coordenada y de las líneas azules en 2 clases en los paneles A–F), salvo en las observaciones de práctica clínica en las que un par distinto calificó cada clase en 2014. Agregar una clase mejoraría este coeficiente en 6-9 p.p. (véase la coordenada y de las mismas líneas en 3 clases). Aumentos adicionales en el número de clases solo mejorarían la confiabilidad en 3-6 p.p., a pesar de que harían que estas observaciones fueran logísticamente más complejas (véanse las pendientes cada vez más planas de estas líneas a partir de 3 clases). El coeficiente para el error relativo en las observaciones del ciclo lectivo se ubica entre 0.4 y 0.5 cuando cada docente es evaluado dos

veces (véanse los paneles G-H). Agregar una ocasión mejoraría este coeficiente en 8 p.p., pero aumentos adicionales solo lo mejorarían en otros 5 p.p.

Agregar clases u ocasiones tendría un impacto menor en la confiabilidad de los juicios absolutos. Como muestra la Figura 1, el coeficiente de generalizabilidad para el error absoluto se ubica entre 0.3 y 0.7 durante la práctica clínica cuando un docente es evaluado dos veces por el mismo mentor o por un par distinto en cada clase (véanse las coordenadas y de las líneas rojas en 2 clases en los paneles A-B y E-F). Agregar una clase elevaría este coeficiente en 4-7 p.p. (véanse las coordenadas y de las mismas líneas en 4 clases en los paneles A, E-F). Aumentos adicionales en el número de clases mejorarían la confiabilidad en 2-5 p.p. El patrón es similar para el ciclo lectivo. El coeficiente para el error absoluto se ubica entre 0.4 y 0.6 cuando cada docente es evaluado dos veces (véanse los paneles G-H). Agregar una ocasión mejoraría este coeficiente en 8 p.p., pero aumentos adicionales solo lo mejorarían en 5 p.p.

Sin embargo, para decidir si vale la pena buscar estas mejoras, es importante considerar los costos prácticos (p. ej., tiempo, dinero, logística) de agregar observaciones. Durante la práctica clínica, cuando todos los docentes y mentores están en el mismo lugar durante varias semanas consecutivas, agregar una clase parece menos costoso que durante el ciclo lectivo, cuando implica un viaje adicional del mentor a la escuela del docente (y, potencialmente, menos atención a los demás docentes que acompaña). Dentro de la práctica clínica, agregar una clase calificada por pares es más sencillo (suponiendo que haya más docentes disponibles que observando una clase en un momento dado) que agregar una clase calificada por mentores (suponiendo que sigan siendo empleados remunerados de ExA y que probablemente estén observando una clase en cada franja horaria durante la práctica clínica).

5.2 Encuestas a estudiantes

La confiabilidad de las encuestas a estudiantes también varía ampliamente. Como muestra la Tabla 3, los coeficientes para el error relativo oscilaron entre 0.33 y 0.85, y los del error absoluto, entre 0.29 y 0.70. Para ilustrar lo que estos coeficientes implican en la práctica, consideremos a un docente que recibe un puntaje promedio de 3.9 en una escala de 1 a 5 (cercano a la media de la Tabla 1). El EEM de una sola encuesta oscila entre 0.119 y 0.173 según las condiciones. En el mejor de los casos, esto produce un intervalo de confianza del 95% de [3.67, 4.13], que abarca 0.47 puntos de la escala. En el peor de los casos, produce un intervalo de [3.56, 4.24], o 0.68 puntos—menos de una quinta parte de la escala. Estos intervalos sugieren que las encuestas a estudiantes, si bien suelen ser más precisas que las observaciones de clase, siguen conllevando una incertidumbre considerable cuando se administran una sola vez.

Para comparar con la literatura previa, calculamos la confiabilidad de la respuesta de un solo estudiante (fijando n_r en 1 y n_d en 7) a partir de los componentes de varianza de la Tabla 3. Estos coeficientes de generalizabilidad para el error relativo con un solo evaluador oscilan entre 0.02 y 0.35, en términos generales coherentes con la estimación de 0.16 de Schweig (2014) para una sola administración de Tripod (Tabla A.1). Al igual que con las observaciones de clase, estas comparaciones sugieren que los desafíos de medición documentados en contextos de investigación de Estados Unidos se extienden a implementaciones lideradas por profesionales en otros países.

Al igual que en el caso de las observaciones, las encuestas administradas durante la práctica clínica tuvieron una confiabilidad más baja y más variable que las del ciclo lectivo. El coeficiente de generalizabilidad promedio para el error relativo fue de 0.46 en la práctica clínica y de 0.72 en el ciclo lectivo. El coeficiente promedio para el error absoluto fue de 0.43 en la

práctica clínica y de 0.53 en el ciclo lectivo. Los coeficientes para el error relativo y absoluto en la práctica clínica oscilaron entre 0.33 y 0.58 y entre 0.29 y 0.57, respectivamente. Los del ciclo lectivo oscilaron entre 0.59 y 0.85 y entre 0.36 y 0.70. Durante el ciclo lectivo, la confiabilidad fue más baja en 2015, cuando ExA pasó de encuestar dos veces a los mismos estudiantes a encuestar a grupos distintos de estudiantes (véase la sección 3.2.2). En términos más generales, ExA introdujo pocos cambios en los diseños de estudio de las encuestas a estudiantes, por lo que la aparente estabilidad de las estimaciones de confiabilidad puede deberse en parte a que solo se comparan dos diseños.

Aumentar el número de evaluadores mejoraría la confiabilidad de los juicios relativos en todos los escenarios considerados, salvo uno. Como muestra la Figura 2, el coeficiente de generalizabilidad para el error relativo en las encuestas de práctica clínica se ubica entre 0.15 y 0.55 con 10 estudiantes (véanse las coordenadas y de las líneas azules en 10 estudiantes en los paneles A-B). Agregar 5 estudiantes de la misma clase mejoraría la confiabilidad en 9 p.p. en 2015 (véanse las coordenadas y de estas líneas en 15 estudiantes); agregar 5 más solo la mejoraría en 6 p.p. (véanse las coordenadas y en 20 estudiantes). El impacto de agregar evaluadores en el ciclo lectivo es ligeramente menor. El coeficiente para el error relativo se ubica entre 0.39 y 0.77 con 10 estudiantes. Agregar 5 estudiantes lo aumentaría en 5-8 p.p., y agregar 5 más solo lo haría en 3-6 p.p.

Agregar evaluadores tendría un impacto similar en la confiabilidad de los juicios absolutos. Como muestra la Figura 2, el coeficiente de generalizabilidad para el error absoluto se ubica entre 0.14 y 0.54 en las encuestas de práctica clínica con 10 estudiantes (véanse las coordenadas y de las líneas rojas en 10 estudiantes en los paneles A-B). Agregar 5 estudiantes mejoraría la confiabilidad en 9 p.p. en 2015 (véanse las coordenadas y en 15 estudiantes), pero

agregar 5 más solo lo haría en 6 p.p. (véanse las coordenadas y en 20 estudiantes). Una vez más, agregar evaluadores tendría un impacto menor en la confiabilidad durante el ciclo lectivo. El coeficiente para el error absoluto se ubica entre 0.28 y 0.67 con 10 estudiantes. Agregar 5 estudiantes lo aumentaría en 4 p.p., pero 5 más solo lo harían en 2-3 p.p.

Una vez más, estas mejoras en la confiabilidad deben sopesarse frente a sus costos. Dado que ExA encuestó a todos los estudiantes presentes, algunos de los aumentos considerados aquí (p. ej., agregar cinco estudiantes más) mejorarían la confiabilidad sin costos adicionales. Incluso encuestar a 20 estudiantes debería ser factible, dado el número promedio de encuestados durante la práctica clínica y el ciclo lectivo (véase la Tabla 3).

6. Discusión

En este artículo, presentamos uno de los primeros estudios G de dos medidas no basadas en pruebas de la efectividad docente en un país de ingresos medios: las observaciones de clase y las encuestas a estudiantes. Nuestra motivación fue doble. En primer lugar, los estudios G previos se basaron en datos recolectados con fines de investigación, con varios mecanismos de control de calidad, por lo que evaluamos si sus resultados reflejan la confiabilidad de instrumentos administrados en la práctica. En segundo lugar, los estudios G anteriores se han centrado en países de ingresos altos (principalmente, Estados Unidos), por lo que evaluamos si son representativos de la realidad de instrumentos menos consolidados administrados en PIBM. Obtuvimos datos de una organización educativa sin fines de lucro que forma parte de una red global y examinamos la confiabilidad de sus métricas.

Nuestros resultados sugieren que las medidas de efectividad docente administradas por profesionales en un país de ingresos medios varían ampliamente. Consideramos que este

hallazgo es importante porque demuestra que los profesionales no pueden basarse en las estimaciones de confiabilidad de estudios realizados en contextos de investigación en países de ingresos altos para diseñar sus propios sistemas de retroalimentación docente. A pesar de la creciente adopción de estos instrumentos en los PIBM (Araujo et al., 2016; Bruns et al., 2018; Bruns et al., 2016; Bruns & Luque, 2014; Filmer et al., 2022; Molina et al., 2018), no se había examinado empíricamente esta cuestión, que tiene implicaciones para el desarrollo docente. Sin embargo, cabe destacar que nuestro estudio difiere de los estudios G previos en múltiples aspectos a la vez—entre ellos, el país, los instrumentos, los evaluadores y los mecanismos de control de calidad—, por lo que no podemos aislar cuál de estos factores explica las similitudes o diferencias de nuestros hallazgos con respecto a trabajos anteriores.

También encontramos que la confiabilidad de las observaciones de clase varió según el contexto en el que se administraron: práctica clínica o ciclo lectivo. En concreto, encontramos que las observaciones son menos confiables y más variables durante la práctica clínica. Esto tiene sentido intuitivamente: parece plausible que los docentes nuevos varíen más en sus primeras oportunidades de enseñar, con estudiantes que no son los suyos, que una vez que se asientan en su puesto docente; también parece posible que los pares y los mentores nuevos todavía se estén familiarizando con el uso del protocolo de observación durante este período. Ambos factores podrían dar lugar a una confiabilidad más baja y más variable.

La confiabilidad de las observaciones también varió según la forma en que se asignó a los docentes a los evaluadores: si el mismo mentor o par calificó ambas clases, o si un par distinto calificó cada clase. Las observaciones calificadas por el mismo mentor son más confiables durante el ciclo lectivo que durante la práctica clínica, lo cual tiene sentido por las mismas razones expuestas antes. Las observaciones calificadas por el mismo par son más confiables que

las calificadas por un par distinto, lo cual también tiene sentido: es probable que el acuerdo entre docentes nuevos sea menos frecuente que la consistencia en las calificaciones de un mismo docente entre clases. Varios mecanismos podrían explicar esta diferencia, entre ellos la restricción de rango en cuanto a qué docentes fueron observados bajo cada tipo de evaluador, el emparejamiento sistemático de docentes con evaluadores o tipos de evaluadores, y que los mentores estrechen y eleven los puntajes para alentar a los docentes. Sin embargo, no encontramos evidencia clara de ninguno de estos mecanismos. Ante la ausencia de una asignación aleatoria de evaluadores a docentes, interpretamos las diferencias entre asignaciones de evaluadores como evidencia adicional de que la confiabilidad es sensible a las características del diseño, y no como una propiedad de los tipos de evaluadores.

Trabajamos con este programa alternativo de acceso a la docencia porque es miembro de una red internacional que utiliza prácticas similares para formar a sus docentes y brindarles retroalimentación. Informamos sobre los contextos, las configuraciones de evaluadores, los tipos de evaluadores y los parámetros (coeficientes de generalizabilidad para el error relativo v. absoluto) que maximizan la confiabilidad en nuestro contexto. Mostramos que los estudios G pueden ser útiles no solo para comprender la confiabilidad de un procedimiento de medición, sino también para mejorarla. Demostramos cómo los aumentos en el número de clases u ocasiones en las observaciones de clase, o de evaluadores en las encuestas a estudiantes, pueden mejorar de manera significativa la confiabilidad, a la vez que llamamos la atención sobre los rendimientos marginales decrecientes de ampliaciones adicionales. Esperamos que los procesos y aprendizajes de nuestro estudio sean relevantes para estos programas similares, lo que podría tener un impacto en miles de docentes cada año y en los estudiantes a quienes atienden.

Sin embargo, para responder a la pregunta de si las observaciones de clase y las encuestas a estudiantes administradas por profesionales pueden producir resultados confiables, se necesitan más análisis de datos recolectados por gobiernos y organizaciones sin fines de lucro, especialmente en los PIBM. Esto es particularmente importante dada la evidencia de que las medidas no basadas en pruebas de la efectividad docente están asociadas con características de los estudiantes y factores del entorno (Cohen & Goldhaber, 2016; Whitehurst et al., 2014), lo que puede limitar la validez externa de los hallazgos entre contextos. Esperamos que futuros estudios se basen en nuestro trabajo y realicen análisis similares de instrumentos desarrollados localmente.

El alto grado de variabilidad de nuestras estimaciones de confiabilidad indica que los profesionales deberían utilizar nuestro estudio como guía para realizar sus propios análisis, en lugar de tratar nuestras estimaciones como puntos de referencia para sus contextos específicos. Aun así, alentamos a los profesionales a estimar la confiabilidad bajo su diseño operativo y su mecanismo de asignación reales y, cuando sea factible, a incorporar una aleatorización limitada y una doble calificación para separar adecuadamente los componentes de varianza y estimar y predecir la confiabilidad. Para apoyarlos en este proceso, hemos explicado cómo comprender el diseño de cada procedimiento de medición y cómo analizar los datos que cada uno produce. También hemos puesto a disposición, junto con este artículo, las bases de datos y el código de nuestros análisis.

Al utilizar estudios G para diseñar sus sistemas de retroalimentación docente, los profesionales deben tener en cuenta que las recomendaciones de los estudios D se estiman con una imprecisión considerable. Un estudio reciente utilizó estimación bayesiana para reanalizar datos de un estudio G en el campo de la medicina y encontró que el número mínimo de

evaluadores necesario para alcanzar niveles adecuados de confiabilidad era mayor y más variable de lo que el estudio había sugerido (Himmelsbach 2025). Por lo tanto, no recomendamos que los profesionales realicen un único estudio G y D y supongan que sus confiabilidades son precisas ni que se aplican a todas las administraciones posteriores de sus instrumentos. Como ilustra nuestro análisis, puede haber una variación interanual significativa en la confiabilidad de las medidas no basadas en pruebas de la efectividad docente administradas por profesionales. En cambio, alentamos a los profesionales a examinar periódicamente la confiabilidad de sus medidas y a realizar ajustes según sea necesario. Nuestros resultados sugieren que este enfoque sería preferible a suponer que las recomendaciones de contextos formales de investigación se generalizan a los suyos.

Por último, cabe señalar que, como todos los estudios G, el nuestro solo estima la varianza de las facetas incluidas explícitamente en cada diseño. Las facetas que no se modelan (p. ej., el momento de las observaciones dentro del ciclo lectivo, la asignatura que se enseña o la composición del alumnado) quedan absorbidas en la varianza residual. En la medida en que estas facetas omitidas introduzcan un error sistemático y no aleatorio, nuestros coeficientes de generalizabilidad podrían sobrestimar la confiabilidad de estos instrumentos en la práctica (Bell et al., 2012).

Aun con esta limitación, la teoría G es útil precisamente porque aclara qué fuentes de error consideramos. Esta claridad permite a los profesionales tratar la confiabilidad como una propiedad empírica de su diseño local, a la vez que se benefician de una teoría que les permite anticipar cómo cambiará la confiabilidad cuando cambien características como la asignación de evaluadores, el momento de aplicación o el tamaño de las muestras.

7. Referencias

- Aaronson, D., Barrow, L., & Sander, W. (2007). Teachers and student achievement in the Chicago public high schools. *Journal of Labor Economics*, 25(1), 95-135.
- Adelman, M., & Lemos, R. (2018). *Managing for learning: Measuring and strengthening education management in Latin America and the Caribbean*. The World Bank.
- AERA/APA/NCME. (2018). *Standards for educational and psychological testing*. American Educational Research Association (AERA), American Psychological Association (APA), and National Council on Measurement in Education (NCME).
- Allen, J. P., Gregory, A., Mikami, A., Lun, J., Hamre, B. K., & Pianta, R. C. (2013). Observations of effective teacher-student interactions in secondary school classrooms: Predicting student achievement with the Classroom Assessment Scoring System--Secondary. *School Psychology Review*, 42(1), 76-98.
- Allen, M. J., & Yen, W. M. (2001). *Introduction to measurement theory*. Waveland Press.
- Anand, G., Atluri, A., Crawford, L., Pugatch, T., & Sheth, K. (2023). Improving school management in low and middle income countries: A systematic review. *Economics of Education Review*, 97, 102464.
- Araujo, M. C., Carneiro, P., Cruz-Aguayo, Y., & Schady, N. (2016). Teacher quality and learning outcomes in kindergarten. *Quarterly Journal of Economics*, 131(3), 1415-1453.
- Baker, E. L., Barton, P. E., Darling-Hammond, L., Haertel, E. H., Ladd, H. F., Linn, R. L., Ravitch, D., Rothstein, R., Shavelson, R. J., & Shepard. (2010). *Problems with the use of student test scores to evaluate teachers*. Economic Policy Institute (EPI).

- Bell, C. A., Gitomer, D. H., McCaffrey, D. F., Hamre, B. K., Pianta, R. C., & Qi, Y. (2012). An argument approach to observation protocol validity. *Educational Assessment*, 17(2-3), 62-87.
- Blazar, D. (2015). Effective teaching in elementary mathematics: Identifying classroom practices that support student achievement. *Economics of Education Review*, 48, 16-29.
- Blazar, D. (2018). Validating teacher effects on students' attitudes and behaviors: Evidence from random assignment of teachers to students. *Education Finance and Policy*, 13(3), 281-309.
- Blazar, D., Braslow, D., Charalambous, C. Y., & Hill, H. C. (2017). Attending to general and mathematics-specific dimensions of teaching: Exploring factors across two observation instruments. *Educational Assessment*, 22(2), 71-94.
- Blazar, D., & Kraft, M. A. (2017). Teacher and teaching effects on students' attitudes and behaviors. *Educational Evaluation and Policy Analysis*, 39(1), 146-170.
- Brennan, R. L. (2001). *Generalizability theory*. Springer-Verlag.
- Bruns, B., Costa, L., & Cunha, N. (2018). Through the looking glass: Can classroom observation and coaching improve teacher performance in Brazil? *Economics of Education Review*, 64, 214-250.
- Bruns, B., De Gregorio, S., & Taut, S. (2016). *Measures of effective teaching in developing countries*. Research on Improving Systems of Education (RISE).
- Bruns, B., Filmer, D., & Patrinos, H. A. (2011). *Making schools work: New evidence on accountability reforms*. World Bank Publications.
- Bruns, B., & Luque, J. (2014). *Great teachers: How to raise student learning in Latin America and the Caribbean*. The World Bank.

- Chetty, R., Friedman, J., & Rockoff, J. E. (2014). Measuring the impacts of teachers I: Evaluating bias in teacher value-added estimates. *American Economic Review*, 104(9), 2593-2632.
- Cohen, J., & Goldhaber, D. (2016). Building a more complete understanding of teacher evaluation using classroom observations. *Educational Researcher*, 45(6), 378-387.
- Commission/EACEA/Eurydice, E. (2021). In *Teachers in Europe: Careers, development, and well-being*. Publications Office of the European Union.
- Cronbach, L. J. (1951). Coefficient alpha and the internal structure of tests. *Psychometrika*, 16(3), 297-334.
- Cronbach, L. J., Gleser, G. C., Nanda, H., & Rajaratnam, N. (1972). *The dependability of behavioral measurements: Theory of generalizability for scores and profiles*. John Wiley & Sons. <https://doi.org/10.2307/1162145>
- Danielson, C. (2011). *Enhancing Professional Practice: A Framework for Teaching*. Association for Supervision; Curriculum Development (ASCD).
- Darling-Hammond, L., Amrein-Beardsley, A., Haertel, E., & Rothstein, J. (2012). Evaluating teacher evaluation. *Phi Delta Kappan*, 93(6), 8-15.
<https://doi.org/10.1177/003172171209300603>
- Dee, T. S., & Wyckoff, J. (2013). Incentives, selection, and teacher performance: Evidence from IMPACT. *Journal of Policy Analysis and Management*, 34, 267-297.
- Douglas, K. M., & Mislevy, R. J. (2010). Estimating classification accuracy for complex decision rules based on multiple scores. *Journal of Educational and Behavioral Statistics*, 35(3), 280-306.

- Filmer, D., Molina, E., & Wane, W. (2022). *Identifying effective teachers: Lessons from four classroom observation tools*. Research on Improving Systems of Education (RISE).
- Glazerman, S., Goldhaber, D., Loeb, S., Raudenbush, S. W., Staiger, D. O., & Whitehurst, G. J. (2011). *Passing muster: Evaluating teacher evaluation systems*. Brown Center on Education Policy, Brookings Institute.
- Goe, L., Bell, C., & Little, O. (2008). *Approaches to evaluating teacher effectiveness: A research synthesis*.
- Goldhaber, D., Grout, C., & Huntington-Klein, N. (2017). Screen twice, cut once: Assessing the predictive validity of applicant selection tools. *Education Finance and Policy*, 12(2), 197-223.
- Grossman, P., Cohen, J., & Brown, L. (2015). Understanding instructional quality in English language arts: Variations in PLATO scores by content and context. In T. J. Kane, K. A. Kerr, & R. C. Pianta (Eds.), *Designing teacher evaluation systems: New guidance from the Measures of Effective Teaching project*. Wiley Online Library.
- Grossman, P., Cohen, J., Ronfeldt, M., & Brown, L. (2014). The test matters: The relationship between classroom observation scores and teacher value added on multiple types of assessment. *Educational Researcher*, 43(6), 293-303.
<https://doi.org/https://doi.org/10.3102/0013189X14544542>
- Grossman, P., Loeb, S., Cohen, J., & Wyckoff, J. (2013). Measure for measure: The relationship between measures of instructional practice in middle school english language arts and teachers' value-added scores. *American Journal of Education*, 119(3), 445-470.
- Hafen, C. A., Hamre, B. K., Allen, J. P., Bell, C. A., Gitomer, D. H., & Pianta, R. C. (2014). Teaching through interactions in secondary classrooms: Revisiting the factor structure

- and practical application of the Classroom Assessment Scoring System—Secondary. *The Journal of Early Adolescence*, 35(5-6), 651-680.
- Hamre, B. K., Pianta, R. C., Downer, J. T., DeCoster, J., & Mashburn, A. J. (2013). Teaching through interactions: Testing a developmental framework of teacher effectiveness in over 4,000 classrooms. *The Elementary School Journal*, 113(4), 461-487.
- Hill, H. C., Blunk, M. L., Charalambous, C. Y., Lewis, J. M., Phelps, G. C., Sleep, L., & Ball, D. L. (2008). Mathematical knowledge for teaching and the mathematical quality of instruction: An exploratory study. *Cognition and instruction*, 26(4), 430-511.
- Hill, H. C., Charalambous, C. Y., & Kraft, M. A. (2012a). When rater reliability is not enough: Teacher observation systems and a case for the generalizability study. *Educational Researcher*, 41(2), 56-64.
- Hill, H. C., Kapitula, L., & Umland, K. (2011). A validity argument approach to evaluating teacher value-added scores. *American Educational Research Journal*, 48(3), 794-831.
- Hill, H. C., Umland, K., Litke, E., & Kapitula, L. R. (2012b). Teacher quality and quality teaching: Examining the relationship of a teacher assessment to practice. *American Journal of Education*, 118(4), 489-519.
- Ho, A. D., & Kane, T. J. (2013). *The reliability of classroom observations by school personnel*. Bill & Melinda Gates Foundation.
- Isoré, M. (2009). *Teacher evaluation: Current practices in OECD countries and a literature review*. Organization for Economic Cooperation and Development (OECD).
- Jackson, C. K. (2013). Match quality, worker productivity, and worker mobility: Direct evidence from teachers. *Review of Economics and Statistics*, 95(4), 1096-1116.
- https://doi.org/10.1162/rest_a_00339

- Jackson, C. K. (2020). What do test scores miss? The importance of teacher effects on non-test-score outcomes. *Journal of Political Economy*, 126(5), 2072-2107.
- Jackson, C. K., & Bruegmann, E. (2009). Teaching students and teaching each other: The importance of peer learning for teachers. *American Economic Journal: Applied Economics*, 1(4), 85-108.
- Jerald, C. (2012). *Ensuring accurate feedback from observations*. Bill and Melinda Gates Foundation.
- Joe, J. N., Tocci, C. M., Holtzman, S. L., & Williams, J. C. (2013). *Foundations of observation: Considerations for developing a classroom observation system that helps districts achieve consistent and accurate scores*. Bill and Melinda Gates Foundation.
- Johnson, S. M., Kraft, M. A., & Papay, J. P. (2012). How context matters in high-need schools: The effects of teachers' working conditions on their professional satisfaction and their students' achievement. *Teachers College Record*, 114(10), 1-39.
- Kane, T. J., Pianta, R. C., & Kerr, K. A. (2014). *Designing teacher evaluation systems: New guidance from the Measures of Effective Teaching project*. John Wiley & Sons.
- Kane, T. J., Rockoff, J. E., & Staiger, D. O. (2008). What does certification tell us about teacher effectiveness? Evidence from New York City. *Economics of Education Review*, 27(6), 615-631.
- Kane, T. J., & Staiger, D. O. (2011). *Learning about teaching: Initial findings from the Measures of Effective Teaching project*. Bill and Melinda Gates Foundation.
- Kane, T. J., & Staiger, D. O. (2012). *Gathering feedback for teachers: Combining high-quality observations with student surveys and achievement gains*.

- Kane, T. J., Taylor, E. S., Tyler, J. H., & Wooten, A. L. (2011). Identifying effective classroom practices using student achievement data. *Journal of Human Resources*, 46(3), 587-613.
- Kimball, S. M., White, B., Milanowski, A. T., & Borman, G. D. (2009). Examining the relationship between teacher evaluation and student assessment results in Washoe County. *Peabody Journal of Education*, 79(4), 54-78.
- Koedel, C., Mihaly, K., & Rockoff, J. E. (2015). Value-added modeling: A review. *Economics of Education Review*, 47, 180-195.
- Kraft, M. A. (2019). Teacher effects on complex cognitive skills and social-emotional competencies. *Journal of Human Resources*, 54(1), 1-36.
- Kraft, M. A., & Gilmour, A. F. (2017). Revisiting the widget effect: Teacher evaluation reforms and the distribution of teacher effectiveness. *Educational Researcher*, 46(5), 234-249.
[https://doi.org/https://doi.org/10.3102/0013189X17718797](https://doi.org/10.3102/0013189X17718797)
- Learning Mathematics for Teaching Project. (2011). Measuring the mathematical quality of instruction. *Journal of Mathematics Teacher Education*, 14(1), 25-47.
- Lockwood, J. R., Savitsky, T. D., & McCaffrey, D. F. (2015). Inferring constructs of effective teaching from classroom observations: An application of Bayesian exploratory factor analysis without restrictions. *The Annals of Applied Statistics*, 9(3), 1484-1509.
- Lord, F. M., & Novick, M. R. (2008). *Statistical theories of mental test scores*. Information Age Publishing.
- Mantzicopoulos, P., French, B. F., & Patrick, H. (2018). The Mathematical Quality of Instruction (MQI) in kindergarten: An evaluation of the stability of the MQI using generalizability theory. *Early Education and Development*, 29(6), 893-908.


- Manzi, J., González, R., & Sun, Y. (2011). *La evaluación docente en Chile*. MIDE UC, Centro de Medición, Pontificia Universidad Católica de Chile.
- Martinez, F., Taut, S., & Schaaf, K. (2016). Classroom observation for evaluating and improving teaching: An international perspective. *Studies in Educational Evaluation*, 49, 15-29.
- Martínez, J. F., & Fernández, M. P. (2021). Teacher evaluation with multiple indicators: Conceptual and methodological considerations regarding validity. In J. Manzi, S. Taut, & M. R. García (Eds.), *Validity of educational assessments in Chile and Latin America* (pp. 373-394). Springer International Publishing.
- Mashburn, A. J., Pianta, R. C., Hamre, B. K., Downer, J. T., Barbarin, O. A., Bryant, D., Burchinal, M., Early, D. M., & Howes, C. (2008). Measures of classroom quality in prekindergarten and children's development of academic, language, and social skills. *Child development*, 79(3), 732-749.
- McClellan, C. (2013). *What it looks like: Master coding videos for observer training and assessment*. Bill and Melinda Gates Foundation.
- MET Project. (2010). *Validation engine for observational protocols*. Bill and Melinda Gates Foundation.
- MET Project. (2013). *Ensuring fair and reliable measures of effective teaching: Culminating findings from the MET Project's three-year study*. Bill and Melinda Gates Foundation.
- Meyer, J. P., Cash, A. H., & Mashburn, A. J. (2011). Occasions and the reliability of classroom observations: Alternative conceptualizations and methods of analysis. *Educational Assessment*, 16(4), 227-243.

- Milanowski, A. (2009). The relationship between teacher performance evaluation scores and student achievement: Evidence from Cincinnati. *Peabody Journal of Education*, 79(4), 33-53.
- Molina, E., Fatima, S. F., Ho, A. D., Melo Hurtado, C., Wilichowski, T., & Pushparatnam, A. (2018). *Measuring teacher practice at scale: Results from the development and validation of the Teach classroom observation tool*. The World Bank.
- Mulhern, C. (2023). Beyond teachers: Estimating individual school counselors' effects on educational attainment. *American Economic Review*, 113(11), 2846-2893.
- Nunnally, J. C. (1978). *Psychometric theory (2nd edition)*. McGraw.
- Nye, B., Konstantopoulos, S., & Hedges, L. V. (2004). How large are teacher effects? *Educational Evaluation and Policy Analysis*, 26(3), 237-257.
- OECD. (2015). *Education at a glance 2015: OECD indicators*.
- OECD. (2025). *Results from TALIS 2024: The state of teaching*. Organization for Economic Cooperation and Development (OECD).
- Papay, J. P. (2011). Different tests, different answers: The stability of teacher value-added estimates across outcome measures. *American Educational Research Journal*, 48(1), 163-193.
- Papay, J. P., Taylor, E. S., Tyler, J. H., & Laski, M. E. (2020). Learning job skills from colleagues at work: Evidence from a field experiment using teacher performance data. *American Economic Journal: Economic Policy*, 12(1), 359–388.
- Patrick, H., French, B. F., & Mantzicopoulos, P. (2020). The Reliability of Framework for Teaching Scores in Kindergarten. *Journal of Psychoeducational Assessment*, 38(7), 831-845.

- Patrick, H., Mantzicopoulos, P., & French, B. F. (2019). The predictive validity of classroom observations: Do teachers' Framework for Teaching scores predict kindergarteners' achievement and motivation? . *American Educational Research Journal*, 57(5), 2021-2058. <https://doi.org/10.3102/0002831219891409>
- Pianta, R. C., Belsky, J., Vandergrift, N., Houts, R., & Morrison, F. J. (2008a). Classroom effects on children's achievement trajectories in elementary school. *American Educational Research Journal*, 45, 365-397. <https://doi.org/10.3102/0002831207308230>
- Pianta, R. C., Hamre, B. K., & Nguyen, T. (2020). Measuring and improving quality in early care and education. *Early Childhood Research Quarterly*, 51, 285-287.
- Pianta, R. C., La Paro, K. M., & Hamre, B. K. (2008b). *The classroom assessment manual, pre-k*. Brookes.
- Pouezevara, S., Pflapsen, A., Nordstrum, L., King, S., & Gove, A. (2016). *Measures of quality through classroom observation for the Sustainable Development Goals: Lessons from low- and middle-income countries*. RTI International; United Nations Educational, Scientific, and Cultural Organization (UNESCO).
- Praetorius, A.-K., Pauli, C., Reusser, K., Rakoczy, K., & Klieme, E. (2014). One lesson is all you need? Stability of instructional quality across lessons. *Learning and Instruction*, 31, 2–12.
- Quezada, M. C., & Salcedo, M. P. M. (2019). *Desarrollo de instrumentos de evaluación: Pautas de obesrvación*. Centro de Medición (MIDE UC) and Instituto Nacional para la Evalaución de la Educación (INEE).
- Rivkin, S. G., Hanushek, E. A., & Kain, J. F. (2005). Teachers, schools, and academic achievement. *Econometrica*, 73(2), 417-458.


- Rockoff, J. E. (2004). The impact of individual teachers on student achievement: Evidence from panel data. *American Economic Review*, 247-252.
- Rockoff, J. E., Jacob, B. A., Kane, T. J., & Staiger, D. O. (2011). Can you recognize an effective teacher when you recruit one? *Education Finance and Policy*, 6(1), 43-74.
- Rothstein, J. (2010). Teacher quality in educational production: Tracking, decay, and student achievement. *The Quarterly Journal of Economics*, 125(1), 175-214.
- Sandilos, L. E., & DiPerna, J. C. (2014). Measuring quality in kindergarten classrooms: Structural analysis of the Classroom Assessment Scoring System (CLASS K-3). *Early Education and Development*, 25(6), 894-914.
- Schweig, J. D. (2014). Quantifying error in survey measures of school and classroom environments. *Applied Measurement in Education*, 27(2), 133-157.
- Seidel, T. (2006). The role of student characteristics in studying micro teaching-learning environments. *Learning Environments Research*, 9(3), 253-271.
- Shavelson, R. J., & Webb, N. M. (1991). *Generalizability theory: A primer*. Sage.
- van der Lans, R. M., van de Grift, W. J. C. M., van Veen, K., & Faokkens-Bruinsma, M. (2016). Once Is not enough: Establishing reliability criteria for feedback and evaluation decisions based on classroom observations. *Studies in Educational Evaluation*, 50, 88-95.
- Weisberg, D., Sexton, S., Mulhern, J., & Keeling, D. (2009). *The widget effect: Our national failure to acknowledge and act on differences in teacher effectiveness*. The New Teacher Project (TNTP).
- Whitehurst, G., Chingos, M. M., & Lindquist, K. M. (2014). *Evaluating teachers with classroom observations*. Brown Center on Education Policy, Brookings Institute.

Figura 1: Confiabilidad de las observaciones de clase según el número de clases, práctica clínica y ciclo lectivo, 2014 y 2015



Notas: Esta figura muestra cómo cambiaría la confiabilidad de las observaciones de clase al aumentar el número de clases. Incluye todos los diseños de la Tabla 2. La línea azul corresponde a la confiabilidad de la posición relativa de los docentes y la roja, a la de los puntajes absolutos de los docentes.

Figura 2: Confiabilidad de las encuestas a estudiantes según el número de evaluadores, práctica clínica y ciclo lectivo, 2014 y 2015



Notas: Esta figura muestra cómo cambiaría la confiabilidad de las encuestas a estudiantes al aumentar el número de evaluadores. Incluye todos los diseños de la Tabla 3. La línea azul corresponde a la confiabilidad de la posición relativa de los docentes y la roja, a la de los puntajes absolutos de los docentes.

Tabla 1: Muestras analíticas, 2014 y 2015

(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
Contexto	Año	Docentes	Clases/ ocasiones	Evaluadores por clase/ocasión	Dominios	Diseño del estudio	Media	DE
<i>A. Observaciones de clase</i>								
Práctica clínica	2014	30	2	Mismo mentor en ambas clases	6	$7[d \times (l:t)]$	2.48	0.73
	2015	37	2	Mismo mentor en ambas clases	6	$8[d \times (l:t)]$	2.60	0.77
	2014	25	2	Mismo par en ambas clases	6	$d \times (l:t)$	2.95	0.78
	2015	43	2	Mismo par en ambas clases	6	$d \times (l:t)$	3.59	0.73
	2014	25	2	Par distinto en cada clase	6	$d \times (l:t)$	2.92	0.70
	2015	20	2	Par distinto en cada clase	6	$d \times (l:t)$	3.49	0.73
Ciclo lectivo	2014	48	2	Mismo mentor en ambas ocasiones	6	$3(t \times d \times o)$	3.01	0.77
	2015	35	2	Mismo mentor en ambas ocasiones	6	$4(t \times d \times o)$	2.96	0.72
<i>B. Encuestas a estudiantes</i>								
Práctica clínica	2014	23	1	Todos los estudiantes en una sola clase	7	$d \times (r:t)$	4.47	0.75
	2015	31	1	Todos los estudiantes en una sola clase	7	$d \times (r:t)$	4.44	0.88
Ciclo lectivo	2014	33	2	Estudiantes distintos en cada ocasión	7	$2[d \times (r:t)]$	3.75	0.94
	2015	28	2	Estudiantes distintos en cada ocasión	7	$2[d \times (r:t)]$	3.86	0.88

Notas: Esta tabla presenta el número de docentes, clases u ocasiones, evaluadores por clase, dominios y el diseño del estudio de las observaciones de clase y las encuestas a estudiantes durante la práctica clínica y el ciclo lectivo en 2014 y 2015. También muestra la media y la desviación estándar de los puntajes “elementales” (es decir, a nivel de docente por clase por evaluador por ítem). En las observaciones durante la práctica clínica, hubo 7 mentores en 2014 y 8 en 2015. En las observaciones durante el ciclo lectivo, hubo 3 mentores en 2014 y 4 en 2015. En las encuestas durante el ciclo lectivo, hubo 2 ocasiones en ambos años. En todos los casos, realizamos estudios G separados (uno por mentor) y reportamos los resultados promedio (véanse las secciones 3.2.1-3.2.2 para más detalles).

Tabla 2: Varianza de los puntajes por dominio en las observaciones de clase, práctica clínica y ciclo lectivo, 2014 y 2015

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
	Práctica clínica				Ciclo lectivo			
	Mismo mentor en ambas clases		Mismo par en ambas clases		Par distinto en cada clase		Mismo mentor en ambas ocasiones	
	2014	2015	2014	2015	2014	2015	2014	2015
Componente de varianza	Var.	Var.	Var.	Var.	Var.	Var.	Var.	Var.
Docente	.034 (.028)	.037 (.030)	.210 (.083)	.180 (.054)	0 (0)	.090 (.062)	.113 (.041)	.073 (.035)
Dominio	.117 (.041)	.244 (.073)	.100 (.066)	.075 (.049)	.093 (.061)	.072 (.051)	.080 (.037)	.068 (.043)
Clase : Docente	.086 (.032)	.036 (.017)	.097 (.037)	.084 (.025)	.194 (.048)	.117 (.047)		
Ocasión							0 (0)	.084 (.095)
Dominio × Docente	.059 (.019)	.015 (.010)	.030 (.021)	.022 (.015)	0 (0)	.072 (.028)	.034 (.018)	.017 (.016)
Ocasión × Docente							.082 (.026)	.032 (.019)
Dominio × Ocasión							.001 (.005)	.045 (.024)
Residual	.142 (.016)	.160 (.018)	.203 (.026)	.190 (.018)	.227 (.021)	.196 (.028)	.229 (.022)	.221 (.022)
DE del efecto docente	.184	.192	.458	.424	0	.300	.336	.270
EEM de una sola observación	.254	.184	.265	.248	.340	.295	.256	.193
Confiabilidad de una sola observación								
Posición relativa de los docentes	.34	.52	.75	.75	0	.51	.63	.66
Puntajes absolutos de los docentes	.29	.33	.71	.71	0	.48	.59	.44
Número de docentes	30	37	25	43	25	20	48	35

Notas: Esta tabla muestra la varianza de los puntajes de las observaciones de clase por contexto y año. Todas las columnas muestran los componentes de varianza del objeto de medición (varianza entre docentes) y de cada faceta de error. Los errores estándar, calculados mediante el método delta, se muestran entre paréntesis. La desviación estándar del efecto docente es la raíz cuadrada de la varianza del puntaje universo. El error estándar de medición de una sola observación es la raíz cuadrada de la varianza del error relativo. Los componentes estimados como negativos se fijaron en cero. Los componentes que se dejan en blanco para un diseño no se estimaron para ese diseño.


Tabla 3: Varianza de los puntajes por dominio en las encuestas a estudiantes, práctica clínica y ciclo lectivo, 2014 y 2015

Componente de varianza	(1)	(2)	(3)	(4)
	Práctica clínica		Ciclo lectivo	
	Todos los estudiantes en una sola clase		Estudiantes distintos en cada clase	
	2014	2015	2014	2015
	Var.	Var.	Var.	Var.
Docente	.007 (.006)	.041 (.019)	.094 (.020)	.020 (.007)
Dominio	.020 (.013)	.011 (.007)	.171 (.070)	.152 (.063)
Evaluable : Docente	.198 (.016)	.506 (.033)	.222 (.010)	.213 (.011)
Dominio x Docente	.014 (.004)	.004 (.002)	.036 (.004)	.026 (.004)
Residual	.296 (.008)	.270 (.007)	.399 (.006)	.369 (.006)
DE del efecto docente	.084	.202	.307	.141
EEM de una sola observación	.119	.173	.129	.119
Confiabilidad de una sola observación				
Posición relativa de los docentes	.33	.58	.85	.59
Puntajes absolutos de los docentes	.29	.57	.70	.36
Número de docentes	23	31	33	25
Número promedio de evaluadores	19.7	18.5	24	25.5

Notas: La tabla muestra la varianza de los puntajes por dominio en cuatro aplicaciones de las encuestas a estudiantes: dos en la práctica clínica y dos durante el ciclo lectivo, en 2014 y 2015. Todas las columnas muestran los componentes de varianza del objeto de medición (varianza entre docentes) y de cada faceta de error. Los errores estándar, calculados mediante el método delta, se muestran entre paréntesis. La desviación estándar del efecto docente está dada por la raíz cuadrada de la varianza del puntaje verdadero y corresponde a la distribución de los puntajes promedio por docente. El error estándar de medición de una sola encuesta está dado por la raíz cuadrada de la varianza del error relativo. Los componentes de varianza estimados como negativos se fijaron en cero. Los componentes de varianza que se dejan en blanco para un diseño no se estimaron para ese diseño.


Anexo A: Figuras y tablas adicionales

Figura A.1: Distribución de los puntajes promedio a nivel de clase/ocasión y a nivel de docente en las observaciones de clase (2014 y 2015)




Notas: Esta figura muestra la distribución de los puntajes promedio a nivel de clase u ocasión (histograma) y a nivel de docente (gráfico de densidad kernel) en las observaciones de clase de los docentes de ExA durante la práctica clínica y el ciclo lectivo en 2014 y 2015.

Figura A.2: Distribución de los puntajes promedio a nivel de evaluador y a nivel de docente en las encuestas a estudiantes (2014 y 2015)




Notas: Esta figura muestra la distribución de los puntajes promedio a nivel de evaluador (histograma) y a nivel de docente (gráfico de densidad kernel) en las encuestas a estudiantes de los docentes de ExA durante la práctica clínica y el ciclo lectivo en 2014 y 2015.

Figura A.3: Distribución de los puntajes por dominio en las observaciones de clase (2014 y 2015)



Notas: Esta figura muestra la distribución de los puntajes por dominio en las observaciones de clase de los docentes de ExA durante la práctica clínica y el ciclo lectivo en 2014 y 2015. Los seis dominios son: presentar contenidos con claridad, verificar la comprensión, gestionar la conducta de los estudiantes, aplicar los procedimientos de clase, crear un ambiente de aprendizaje y desarrollar un sentido de posibilidad (véase la sección 3.4.1).

Figura A.4: Distribución de los puntajes por dominio en las encuestas a estudiantes (2015)



Notas: Esta figura muestra la distribución de los puntajes por dominio en las encuestas a estudiantes sobre los docentes de ExA durante la práctica clínica y el ciclo lectivo en 2014 y 2015. Los siete dominios son: cuidar, consultar, cautivar, clarificar, consolidar, desafiar y controlar (véase la sección 3.4.2).

Tabla A.1: Estudios de generalizabilidad de observaciones de clase y encuestas a estudiantes

(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
Estudio	Contexto	Instrumento	Docentes	Obs. por docente	Media	DE del efecto docente	EEM de una sola obs.	Confiab. de una sola obs.
Observaciones de clase								
A. Nivel inicial								
Mantzicopoulos, French, Patrick, et al. (2018)	Medio Oeste de EE. UU.	CLASS K-3-EMSUP	10	4	4.75/7	0.43	0.48	0.44
		CLASS K-3-CLORG			5.19/7	0.23	0.52	0.16
		CLASS K-3-INSUP			3.04/7	0.41	0.68	0.26
		FfT Ambiente del aula			2.36/4	0.26	0.34	0.36
		FfT Instrucción en el aula			1.87/4	0.19	0.44	0.16
Mantzicopoulos, French and Patrick (2018)	Medio Oeste de EE. UU.	MQI-R	20	5		0.17	0.10	0.74
		MQI-WWSM				0.13	0.10	0.63
		MQI-EI				0.00		0.00
		MQI-CCASP				0.09	0.10	0.45
		Clase completa				0.29	0.14	0.81
Patrick et al. (2020)	Indiana, IN	FfT Lectura	20	10	2.47/4	0.37	0.24	0.70
		FfT Matemática			2.37/4	0.35	0.24	0.67
B. Nivel primario								
Meyer et al. (2011)	Sudeste de EE. UU.	CLASS-EMSUP	118	4	5.37/7	0.52	0.39	0.64
		CLASS-INSUP			2.88/7	0.22	0.43	0.20
		CLASS-CLORG			5.19/7	0.36	0.41	0.43
C. Nivel secundario								
Hill et al. (2012)	Sudoeste de EE. UU.	MQI-R	8	1				0.45
		MQI-EI						0.37
		MQI-SPMMR						0.46
Casabianca et al. (2013)	Sudeste de EE. UU.	CLASS-EMSUP (en vivo)	82	4-5	3.69/7	0.73	0.70	0.52
		CLASS-EMSUP (video)			3.64/7	0.57	0.83	0.33

		CLASS-CLORG (en vivo)			5.69/7	0.68	0.54	0.61
		CLASS-CLORG (video)			5.75/7	0.58	0.65	0.44
		CLASS-INSUP (en vivo)			3.58/7	0.64	0.82	0.38
		CLASS-INSUP (video)			3.26/7	0.47	0.82	0.25
Mashburn, Meyer, et al. (2014)	Sudeste de EE. UU.	CLASS-EMSUP	47	3	4.11/7	0.46	0.61	0.36
		CLASS-INSUP			3.21/7	0.43	0.74	0.25
		CLASS-CLORG			5.18/7	0.65	0.65	0.50
Mashburn, Downer, et al. (2014)	Brooklyn y Queens, NY	CLASS-EMSUP	48	6		0.48	0.53	0.45
		CLASS-INSUP				0.49	0.56	0.40
		CLASS-CLORG				0.56	0.68	0.44
Praetorius et al. (2014)	Alemania y Suiza	CLASS Gestión del aula	38	5	3.64/7	0.54	0.40	0.64
		Apoyo personal al aprendizaje			2.60/7	0.37	0.56	0.45
		Activación cognitiva			1.93/7	0.36	0.97	0.14
<i>D. Múltiples niveles</i>								
Kane and Staiger (2012)	Charlotte-Mecklenburg, NC; Dallas, TX; Denver, CO; Hillsborough Co., FL; New York, NY; Memphis, TN	FfT	1333	4-8		0.29	0.38	0.37
		CLASS						0.31
		PLATO						0.34
		MQI						0.14
		UTOP	1000					0.30
Ho and Kane (2013)	Hillsborough Co., FL	FfT	67	46	2.58/4	0.27	0.34	0.39
Semmelroth and Johnson (2014)	Idaho	RESET-Obj. de la clase	9	3		0.43	0.82	0.22
		RESET-Impl. de EBP				0.91	1.98	0.17

		RESET-Clase completa				1.16	2.11	0.23
van der Lans et al. (2016)	Países Bajos	ICALT3	69	3		1.14		0.51
Briggs and Alzen (2019)	Charlotte-Mecklenburg, NC; Dallas, TX; Denver, CO; Hillsborough Co., FL; New York, NY; Memphis, TN	FfT	458	7-8	2.50/4	0.28	0.37	0.36
Encuestas a estudiantes								
<i>E. Múltiples niveles</i>								
Schweig (2014)	Distrito urbano de California	Tripod-Desafiar	285	17		0.30	0.17	0.16

Notas: Esta tabla ofrece un panorama de los estudios previos sobre la confiabilidad de las observaciones de clase y las encuestas a estudiantes. La desviación estándar (DE) del efecto docente es la raíz cuadrada de la varianza del puntaje verdadero. El error estándar de medición (EEM) de una sola observación es la raíz cuadrada de la varianza del error relativo. La confiabilidad de una sola observación es la proporción de la varianza del puntaje observado atribuible a diferencias persistentes en la práctica docente, estimada para una sola observación realizada por un solo evaluador. Las celdas en blanco corresponden a valores no reportados. CLASS significa Classroom Assessment Scoring System. EMSUP, INSUP y CLORG son sus dominios: Emotional Support, Instructional Support y Classroom Organization. MQI significa Mathematics Quality of Instruction. R, WWSM, EI, CCASP y SPMMR son sus dominios: riqueza, trabajo con los estudiantes y la matemática, errores e imprecisión, prácticas de los estudiantes alineadas con el Common Core, y participación de los estudiantes en la construcción de significado y el razonamiento. RESET significa Recognizing Effective Special Education Teachers y sus dominios son: objetivos de la clase, implementación de prácticas basadas en evidencia (EBP) y revisión de la clase completa. FfT significa Framework for Teaching; PLATO, Protocol for Language Arts Teaching Observation; UTOP, UTeach Observation Protocol; e ICALT3, The International Comparative Analysis of Learning and Teaching. Luna-Bazaldua et al. (2021) reporta resultados para cuatro países no identificados en las cuatro regiones indicadas. La DE del efecto docente y el EEM de una sola observación para Kane and Staiger (2012) se obtuvieron de Ho and Kane (2013). En Ho and Kane (2013), cada docente recibió *en promedio* 46 observaciones, a cargo de distintos observadores y en distintas clases. van der Lans et al. (2016) reportaron los componentes de varianza en escala logit.

Tabla A.2: Correlación entre los puntajes por dominio en las observaciones de clase (2014)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)	(10)	(11)	(12)
	Práctica clínica					Ciclo lectivo						
	Presentar contenidos con claridad	Verificar comprensión	Gestionar conducta estudiantil	Aplicar procedimientos de clase	Crear un ambiente de aprendizaje	Desarrollar sentido de posibilidad	Presentar contenidos con claridad	Verificar comprensión	Gestionar conducta estudiantil	Aplicar procedimientos de clase	Crear un ambiente de aprendizaje	Desarrollar sentido de posibilidad
<i>A. Práctica clínica</i>												
Presentar contenidos con claridad	1.00											
Verificar comprensión	0.79***	1.00										
Gestionar conducta estudiantil	0.52***	0.39**	1.00									
Aplicar procedimientos de clase	0.52***	0.40**	0.59***	1.00								
Crear un ambiente de aprendizaje	0.54***	0.38*	0.57***	0.67***	1.00							
Desarrollar sentido de posibilidad	0.69***	0.60***	0.42**	0.49**	0.65***	1.00						
<i>B. Ciclo lectivo</i>												
Presentar contenidos con claridad	0.18	0.30	0.02	0.23	0.21	0.28	1.00					
Verificar comprensión	0.22	0.32	0.10	0.00	0.19	0.22	0.21	1.00				
Gestionar conducta estudiantil	0.27	0.39*	-0.03	0.12	0.24	0.35*	0.53***	0.50***	1.00			
Aplicar procedimientos de clase	0.36*	0.32	-0.15	-0.01	0.06	0.25	0.25	0.58***	0.67***	1.00		
Crear un ambiente de aprendizaje	0.25	0.35*	0.02	0.12	0.21	0.40**	0.28	0.68***	0.53***	0.64***	1.00	
Desarrollar sentido de posibilidad	0.08	0.15	0.11	0.13	0.21	0.25	0.35*	0.47**	0.44**	0.50***	0.73***	1.00

Notas: Esta tabla muestra los coeficientes de correlación entre los puntajes por dominio en las observaciones de clase de los docentes de ExA durante la práctica clínica y el ciclo lectivo en 2014. Esta tabla incluye solo a los docentes con ambos conjuntos de puntajes. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.3: Correlación entre los puntajes por dominio en las observaciones de clase (2015)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)	(10)	(11)	(12)
	Práctica clínica						Ciclo lectivo					
	Presentar contenidos con claridad	Verificar comprensión	Gestionar conducta estudiantil	Aplicar procedimientos de clase	Crear un ambiente de aprendizaje	Desarrollar sentido de posibilidad	Presentar contenidos con claridad	Verificar comprensión	Gestionar conducta estudiantil	Aplicar procedimientos de clase	Crear un ambiente de aprendizaje	Desarrollar sentido de posibilidad
<i>A. Práctica clínica</i>												
Presentar contenidos con claridad	1.00											
Verificar comprensión	0.57**	1.00										
Gestionar conducta estudiantil	0.65***	0.65***	1.00									
Aplicar procedimientos de clase	0.27	0.13	0.64***	1.00								
Crear un ambiente de aprendizaje	0.60***	0.66***	0.63***	0.39*	1.00							
Desarrollar sentido de posibilidad	0.61***	0.57**	0.74***	0.65***	0.72***	1.00						
<i>B. Ciclo lectivo</i>												
Presentar contenidos con claridad	0.01	-0.14	0.09	0.20	-0.07	-0.02	1.00					
Verificar comprensión	-0.28	-0.01	-0.20	-0.33	-0.25	-0.54**	0.21	1.00				
Gestionar conducta estudiantil	0.21	0.39	0.25	-0.06	0.25	-0.10	0.50**	0.57**	1.00			
Aplicar procedimientos de clase	-0.28	-0.18	-0.33	-0.49**	-0.38	-0.50**	0.25	0.75***	0.34	1.00		
Crear un ambiente de aprendizaje	0.15	0.13	0.27	0.33	0.14	-0.08	0.48**	0.59***	0.70***	0.18	1.00	
Desarrollar sentido de posibilidad	-0.11	0.07	-0.29	-0.47**	0.01	-0.38	0.16	0.68***	0.55**	0.58***	0.36	1.00

Notas: Esta tabla muestra los coeficientes de correlación entre los puntajes por dominio en las observaciones de clase de los docentes de ExA durante la práctica clínica y el ciclo lectivo en 2015. Esta tabla incluye solo a los docentes con ambos conjuntos de puntajes. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.4: Correlación entre los puntajes por dominio en las encuestas a estudiantes (2014)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)	(10)	(11)	(12)	(13)	(14)
	Práctica clínica					Ciclo lectivo								
	Cuidar	Consultar	Cautivar	Clarificar	Consolidar	Desafiar	Controlar	Cuidar	Consultar	Cautivar	Clarificar	Consolidar	Desafiar	Controlar
<i>A. Práctica clínica</i>														
Cuidar	1.00													
Consultar	0.21	1.00												
Cautivar	0.58**	0.80***	1.00											
Clarificar	0.05	0.62**	0.51*	1.00										
Consolidar	0.47	-0.21	-0.04	0.02	1.00									
Desafiar	0.52*	0.19	0.45	-0.23	0.01	1.00								
Controlar	0.48*	0.23	0.44	-0.27	0.16	0.77***	1.00							
<i>B. Ciclo lectivo</i>														
Cuidar	0.09	0.71***	0.66**	0.29	-0.25	0.30	0.50*	1.00						
Consultar	0.18	0.54*	0.71***	0.17	-0.30	0.41	0.42	0.75***	1.00					
Cautivar	0.19	0.71***	0.73***	0.24	-0.34	0.31	0.38	0.90***	0.85***	1.00				
Clarificar	0.15	0.73***	0.68**	0.19	-0.31	0.32	0.45	0.92***	0.75***	0.94***	1.00			
Consolidar	0.40	0.81***	0.88***	0.49*	-0.15	0.44	0.45	0.76***	0.83***	0.84***	0.77***	1.00		
Desafiar	0.02	0.64**	0.65**	0.19	-0.41	0.19	0.33	0.91***	0.87***	0.96***	0.92***	0.75***	1.00	
Controlar	0.04	0.67**	0.62**	0.11	-0.42	0.49*	0.57**	0.92***	0.72***	0.88***	0.91***	0.73***	0.86***	1.00

Notas: Esta tabla muestra los coeficientes de correlación entre los puntajes por dominio en las encuestas a estudiantes sobre los docentes de ExA durante la práctica clínica y el ciclo lectivo en 2014. Esta tabla incluye solo a los docentes con ambos conjuntos de puntajes. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Tabla A.5: Correlación entre los puntajes por dominio en las encuestas a estudiantes (2015)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)	(10)	(11)	(12)	(13)	(14)
	Práctica clínica						Ciclo lectivo							
	Cuidar	Consultar	Cautivar	Clarificar	Consolidar	Desafiar	Controlar	Cuidar	Consultar	Cautivar	Clarificar	Consolidar	Desafiar	Controlar
<i>A. Práctica clínica</i>														
Cuidar	1.00													
Consultar	0.45	1.00												
Cautivar	0.98***	0.60	1.00											
Clarificar	0.69	0.82*	0.76	1.00										
Consolidar	0.79	0.65	0.81*	0.94**	1.00									
Desafiar	0.86*	0.45	0.83*	0.82*	0.96***	1.00								
Controlar	0.69	0.43	0.66	0.85*	0.95**	0.94**	1.00							
<i>B. Ciclo lectivo</i>														
Cuidar	-0.63	-0.68	-0.70	-0.71	-0.80	-0.76	-0.64	1.00						
Consultar	-0.39	-0.66	-0.43	-0.91**	-0.84*	-0.69	-0.85*	0.52	1.00					
Cautivar	-0.20	-0.87*	-0.33	-0.75	-0.65	-0.44	-0.50	0.74	0.76	1.00				
Clarificar	0.23	0.71	0.36	0.44	0.15	-0.04	-0.05	-0.03	-0.26	-0.35	1.00			
Consolidar	-0.52	-0.75	-0.62	-0.65	-0.70	-0.63	-0.50	0.98***	0.47	0.80	-0.12	1.00		
Desafiar	-0.71	-0.38	-0.71	-0.51	-0.71	-0.79	-0.60	0.92**	0.29	0.43	0.24	0.85*	1.00	
Controlar	-0.87*	-0.11	-0.82*	-0.26	-0.43	-0.60	-0.32	0.46	-0.11	-0.18	-0.01	0.36	0.68	1.00

Notas: Esta tabla muestra los coeficientes de correlación entre los puntajes por dominio en las encuestas a estudiantes sobre los docentes de ExA durante la práctica clínica y el ciclo lectivo en 2015. Esta tabla incluye solo a los docentes con ambos conjuntos de puntajes. * significativo al 10%; ** significativo al 5%; *** significativo al 1%.

Anexo B: Instrumentos

B.1 Observación de clase

ExA desarrolló su protocolo de observación de clase a partir de instrumentos previos y lo utilizó para dar retroalimentación a sus docentes durante la práctica clínica y el ciclo lectivo. Abarcaba seis dominios: presentar contenidos con claridad, verificar la comprensión, gestionar la conducta de los estudiantes, aplicar los procedimientos de clase, crear un ambiente propicio para el aprendizaje y desarrollar un sentido de posibilidad. Cada dominio incluía entre cinco y siete ítems. Cada ítem se calificaba de 1 (preprincipiante) a 5 (ejemplar). Cada puntaje posible de un ítem tenía una breve descripción para ayudar a los evaluadores a elegir entre ellos. El protocolo puede consultarse en: <https://bit.ly/3NhS7nv>.

Presentar contenidos con claridad incluía siete ítems: (a) ¿domina el docente el material?; (b) ¿anuncia al inicio de la clase lo que los estudiantes aprenderán?; (c) ¿usa un lenguaje corporal adecuado?; (d) ¿su explicación sigue una estructura clara?; (e) ¿hace un uso eficaz de recursos visuales?; (f) ¿mantiene un ritmo adecuado?; (g) ¿cierra la clase repasando los conceptos clave o lo aprendido?

Verificar la comprensión incluía siete ítems: (a) ¿hace el docente preguntas a los estudiantes para verificar su comprensión?; (b) ¿las preguntas abarcan una amplia gama de habilidades?; (c) ¿participan todos los estudiantes en las preguntas?; (d) ¿el docente da retroalimentación sobre las respuestas de los estudiantes?; (e) ¿alienta a los estudiantes a hablar entre sí?; (f) ¿responde a las respuestas incorrectas ayudando a los estudiantes a mejorarlas?; y (g) ¿logra volver a explicar los conceptos que no quedan claros?

Gestionar la conducta de los estudiantes incluía siete ítems: (a) ¿establece el docente normas de conducta?; (b) ¿hace cumplir esas normas de manera sistemática?; (c) ¿minimiza el

tiempo dedicado a cuestiones de disciplina?; (d) ¿hay recompensas y consecuencias cuando los estudiantes cumplen las normas?; (e) ¿esas recompensas y consecuencias son proporcionales a las normas que se hacen cumplir?; (f) ¿los docentes son respetuosos con los estudiantes al hacer cumplir las normas?; y (g) ¿determinan dónde debe sentarse cada estudiante para que la clase se desarrolle según lo previsto?

Aplicar los procedimientos de clase incluía cinco ítems: (a) ¿ha establecido el docente rutinas para los procedimientos de clase?; (b) ¿aplica esas rutinas de manera sistemática?; (c) ¿minimiza el tiempo dedicado a los procedimientos de clase?; (d) ¿hay consecuencias claras ante el incumplimiento de las rutinas establecidas?; y (e) ¿tiene el docente un sistema para atender circunstancias excepcionales?

Crear un ambiente propicio para el aprendizaje incluía seis ítems: (a) ¿es el docente respetuoso con los estudiantes?; (b) ¿se asegura de que los estudiantes se respeten entre sí?; (c) ¿se asegura de que los estudiantes se sientan cómodos para hacer preguntas?; (d) ¿se asegura de que los estudiantes se sientan cómodos para compartir errores en las tareas o en las actividades de clase?; (e) ¿los carteles y las normas del aula favorecen un ambiente de aprendizaje?; (f) ¿comunica el docente los objetivos de aprendizaje de cada clase?

Desarrollar un sentido de posibilidad incluía siete ítems: (a) ¿reconoce el docente las fortalezas y los progresos de los estudiantes?; (b) ¿muestra los procedimientos adecuados para resolver problemas en actividades, tareas o evaluaciones?; (c) ¿aconseja a los estudiantes sobre cómo estudiar?; (d) ¿ofrece actividades, tareas o evaluaciones modelo?; (e) ¿transmite la relevancia del contenido que se enseña?; (f) ¿transmite la importancia de que les vaya bien en la escuela?; (g) ¿establece altas expectativas para los estudiantes?

B.2 Encuestas a estudiantes

ExA adaptó y tradujo la encuesta Tripod (Ferguson, 2012) para dar retroalimentación a los docentes durante la práctica clínica y el ciclo lectivo. Abarcaba siete dominios: cuidar, consultar, cautivar, clarificar, consolidar, desafiar y controlar. Cada ítem se calificaba de 1 (nunca) a 5 (siempre). Las encuestas están disponibles en: <https://bit.ly/4dvIwV6> (primaria) y <https://bit.ly/3BGRNMw> (secundaria).

Cuidar incluía seis ítems: (a) me gusta cómo me trata mi docente cuando necesito ayuda; (b) mi docente me hace sentir que realmente le importo; (c) si estoy triste o enojado/a, mi docente me ayuda a sentirme mejor; (d) mi docente me alienta a dar lo mejor de mí; (e) mi docente se da cuenta si algo me preocupa; y (f) mi docente nos da tiempo para explicar nuestras ideas.

Consultar incluía siete ítems: (a) cuando nos enseña, mi docente nos pregunta si entendemos; (b) mi docente hace preguntas para asegurarse de que seguimos lo que dice; (c) mi docente verifica que entendamos lo que nos está enseñando; (d) mi docente nos dice qué estamos aprendiendo y por qué; (e) mi docente quiere que compartamos lo que pensamos; (f) los estudiantes hablan y comparten sus ideas sobre el trabajo en clase; (g) mi docente quiere que explique mis respuestas—por qué pienso lo que pienso.

Cautivar incluía dos ítems: (a) el trabajo escolar es interesante; y (b) la tarea me ayuda a aprender.

Clarificar incluía siete ítems: (a) mi docente explica las cosas de manera muy ordenada; (b) en esta clase, aprendemos a corregir nuestros errores; (c) mi docente explica con claridad las cosas difíciles; (d) mi docente tiene varias buenas maneras de explicar cada tema que vemos en

esta clase; (e) esta clase es ordenada—todo tiene su lugar y las cosas son fáciles de encontrar; y (f) si no entiendo algo, mi docente lo explica de otra manera.

Consolidar incluía dos ítems: (a) mi docente se toma el tiempo de resumir lo que aprendemos cada día; y (b) cuando mi docente corrige mis trabajos, escribe comentarios en mis hojas para ayudarme a entender.


Desafiar incluía dos ítems: (a) mi docente nos exige pensar a fondo sobre lo que hacemos; (b) en esta clase, mi docente no acepta menos que nuestro máximo esfuerzo.

Controlar incluía tres ítems: (a) mis compañeros se comportan como mi docente quiere; (b) nuestra clase se mantiene ocupada y no pierde el tiempo; y (c) todos saben lo que deberían estar haciendo y aprendiendo en esta clase.

Anexo C: Diseños del estudio

C.1 Los diseños $d \times (l:t)$ y $d \times (r:t)$

En la teoría G, los diseños $d \times (l:t)$ y $d \times (r:t)$ se representan mediante diagramas de Venn de la siguiente manera:



Esta es una representación gráfica de los diseños del estudio descritos en las secciones 3.2.1 y 3.2.2. En ambos casos, el círculo de d se interseca con todos los demás para indicar que los dominios están cruzados con los docentes y las clases (en el primer caso) o con los evaluadores (en el segundo caso). Los círculos de l y r están dentro de los de t para indicar que las clases y los evaluadores están anidados dentro de los docentes.

En la práctica, esto significa que nuestras bases de datos para cada estudio tienen la siguiente estructura:

Tabla C.1: Segmento de datos para el diseño $d \times (l:t)$


	Docente 1		Docente 2		Docente 3	
	Clase 1	Clase 2	Clase 1	Clase 2	Clase 1	Clase 2
Dominio 1	X	X	X	X	X	X
Dominio 2	X	X	X	X	X	X
Dominio 3	X	X	X	X	X	X
Dominio 4	X	X	X	X	X	X
Dominio 5	X	X	X	X	X	X
Dominio 6	X	X	X	X	X	X

Tabla C.2: Segmento de datos para el diseño $d \times (r:t)$

	Docente 1		Docente 2		Docente 3	
	Evaluador	Evaluador	Evaluador	Evaluador	Evaluador	Evaluador
	1	2	1	2	1	2
Dominio 1	X	X	X	X	X	X
Dominio 2	X	X	X	X	X	X
Dominio 3	X	X	X	X	X	X
Dominio 4	X	X	X	X	X	X
Dominio 5	X	X	X	X	X	X
Dominio 6	X	X	X	X	X	X

C.2 El diseño $t \times d \times o$

En la teoría G, el diseño $t \times d \times o$ se representa mediante el siguiente diagrama de Venn:



En este caso, los círculos de t , d y o se intersecan entre sí para indicar que se trata de un diseño completamente cruzado: todos los docentes son calificados en todos los dominios y ocasiones.

Esto significa que nuestra base de datos para este estudio tiene la siguiente estructura:

Tabla C.2: Segmento de datos para el diseño $t \times d \times o$

	Docente 1		Docente 2		Docente 3	
	Ocasión 1	Ocasión 2	Ocasión 1	Ocasión 2	Ocasión 1	Ocasión 2
Dominio 1	X	X	X	X	X	X
Dominio 2	X	X	X	X	X	X
Dominio 3	X	X	X	X	X	X
Dominio 4	X	X	X	X	X	X
Dominio 5	X	X	X	X	X	X
Dominio 6	X	X	X	X	X	X

Referencias:

- Briggs, D. C., & Alzen, J. L. (2019). Making inferences about teacher observation scores over time. *Educational and Psychological Measurement*, 79(4), 636-664.
- Casabianca, J. M., McCaffrey, D. F., Gitomer, D. H., Bell, C. A., Hamre, B. K., & Pianta, R. C. (2013). Effect of observation mode on measures of secondary mathematics teaching. *Educational and Psychological Measurement*, 75(3), 757-783.
- Ferguson, R. F. (2012). Can student surveys measure teaching quality? *Phi Delta Kappan*, 94(3), 24-28.
- Hill, H. C., Charalambous, C. Y., & Kraft, M. A. (2012). When rater reliability is not enough: Teacher observation systems and a case for the generalizability study. *Educational Researcher*, 41(2), 56-64.
- Ho, A. D., & Kane, T. J. (2013). *The reliability of classroom observations by school personnel*. Bill & Melinda Gates Foundation.
- Kane, T. J., & Staiger, D. O. (2012). *Gathering feedback for teachers: Combining high-quality observations with student surveys and achievement gains*.
- Luna-Bazaldua, D., Molina, E., & Pushparatnam, A. (2021). A generalizability study of Teach, a classroom observation tool. In M. Wilberg, D. Molenaar, J. González, U. Böckenholt, & J.-S. Kim (Eds.), *Quantitative psychology*. Springer.
- Mantzicopoulos, P., French, B. F., & Patrick, H. (2018). The Mathematical Quality of Instruction (MQI) in kindergarten: An evaluation of the stability of the MQI using generalizability theory. *Early Education and Development*, 29(6), 893-908.
- Mantzicopoulos, P., French, B. F., Patrick, H., Watson, J. S., & Ahn, I. (2018). The stability of kindergarten teachers' effectiveness: A generalizability study comparing the Framework

- for Teaching and the Classroom Assessment Scoring System. *Educational Assessment*, 23(1), 24-46.
- Mashburn, A. J., Downer, J. T., Rivers, S. E., Brackett, M. A., & Martinez, A. (2014). Improving the power of an efficacy study of a social and emotional learning program: Application of generalizability theory to the measurement of classroom-level outcomes. *Prevention Science* 15, 146-155.
- Mashburn, A. J., Meyer, J. P., Allen, J. P., & Pianta, R. C. (2014). The effect of observation length and presentation order on the reliability and validity of an observational measure of teaching quality. *Educational and Psychological Measurement*, 74(3), 400–422.
- Meyer, J. P., Cash, A. H., & Mashburn, A. J. (2011). Occasions and the reliability of classroom observations: Alternative conceptualizations and methods of analysis. *Educational Assessment*, 16(4), 227-243.
- Patrick, H., French, B. F., & Mantzicopoulos, P. (2020). The Reliability of Framework for Teaching Scores in Kindergarten. *Journal of Psychoeducational Assessment*, 38(7), 831-845.
- Praetorius, A.-K., Pauli, C., Reusser, K., Rakoczy, K., & Klieme, E. (2014). One lesson is all you need? Stability of instructional quality across lessons. *Learning and Instruction*, 31, 2–12.
- Schweig, J. D. (2014). Quantifying error in survey measures of school and classroom environments. *Applied Measurement in Education*, 27(2), 133-157.
- Semmelroth, C. L., & Johnson, E. (2014). Measuring rater reliability on a special education observation tool. *Assessment for Effective Intervention*, 39(3), 131-145.

van der Lans, R. M., van de Grift, W. J. C. M., van Veen, K., & Faokkens-Bruinsma, M. (2016).

Once Is not enough: Establishing reliability criteria for feedback and evaluation decisions based on classroom observations. *Studies in Educational Evaluation*, 50, 88–95.